



**Метод тяжёлого шарика. Ускоренный  
градиентный метод Нестерова**

**Даня Меркулов**

Методы оптимизации. МФТИ

## Повторение

# Результаты сходимости градиентного спуска для гладких функций

Градиентный спуск:  $\min_{x \in \mathbb{R}^n} f(x)$   $x_{k+1} = x_k - \alpha_k \nabla f(x_k)$   $\lambda(\nabla^2 f(x)) \in [\mu, L], \kappa = \frac{L}{\mu}$

| выпуклая (негладкая)                                                                                                             | гладкая (невыпуклая)                                                                                                                                         | гладкая & выпуклая                                                                                                      | гладкая & сильно выпуклая                                                                                                                                   |
|----------------------------------------------------------------------------------------------------------------------------------|--------------------------------------------------------------------------------------------------------------------------------------------------------------|-------------------------------------------------------------------------------------------------------------------------|-------------------------------------------------------------------------------------------------------------------------------------------------------------|
| $f(x_k) - f^* = \mathcal{O}\left(\frac{1}{\sqrt{k}}\right)$<br>$k_\varepsilon = \mathcal{O}\left(\frac{1}{\varepsilon^2}\right)$ | $\min_{0 \leq i \leq k} \ \nabla f(x_i)\  = \mathcal{O}\left(\frac{1}{\sqrt{k}}\right)$<br>$k_\varepsilon = \mathcal{O}\left(\frac{1}{\varepsilon^2}\right)$ | $f(x_k) - f^* = \mathcal{O}\left(\frac{1}{k}\right)$<br>$k_\varepsilon = \mathcal{O}\left(\frac{1}{\varepsilon}\right)$ | $\ x_k - x^*\ ^2 = \mathcal{O}\left(\left(1 - \frac{\mu}{L}\right)^k\right)$<br>$k_\varepsilon = \mathcal{O}\left(\kappa \log \frac{1}{\varepsilon}\right)$ |

# Нижние оценки для методов I порядка на классе гладких функций

Произвольный метод I порядка:  $\min_{x \in \mathbb{R}^n} f(x)$   $x_{k+1} = x_k - \sum_{i=0}^k \alpha_i \nabla f(x_i)$   $\lambda(\nabla^2 f(x)) \in [\mu, L], \kappa = \frac{L}{\mu}$

| выпуклая (негладкая)                                                                                                   | гладкая (невыпуклая) <sup>1</sup>                                                                                                                  | гладкая & выпуклая <sup>2</sup>                                                                                        | гладкая & сильно выпуклая                                                                                                                                                      |
|------------------------------------------------------------------------------------------------------------------------|----------------------------------------------------------------------------------------------------------------------------------------------------|------------------------------------------------------------------------------------------------------------------------|--------------------------------------------------------------------------------------------------------------------------------------------------------------------------------|
| $f(x_k) - f^* = \Omega\left(\frac{1}{\sqrt{k}}\right)$<br>$k_\varepsilon = \Omega\left(\frac{1}{\varepsilon^2}\right)$ | $\min_{0 \leq i \leq k} \ \nabla f(x_i)\  = \Omega\left(\frac{1}{\sqrt{k}}\right)$<br>$k_\varepsilon = \Omega\left(\frac{1}{\varepsilon^2}\right)$ | $f(x_k) - f^* = \Omega\left(\frac{1}{k^2}\right)$<br>$k_\varepsilon = \Omega\left(\frac{1}{\sqrt{\varepsilon}}\right)$ | $f(x_k) - f^* = \Omega\left(\left(\frac{\sqrt{\kappa}-1}{\sqrt{\kappa}+1}\right)^{2k}\right)$<br>$k_\varepsilon = \Omega\left(\sqrt{\kappa} \log \frac{1}{\varepsilon}\right)$ |

<sup>1</sup>Carmon, Duchi, Hinder, Sidford, 2017


<sup>2</sup>Nemirovski, Yudin, 1979

## Метод тяжёлого шарика


# Колебания и ускорение

$$x_{k+1} = x_k - \alpha \nabla f(x_k) + \beta(x_k - x_{k-1}).$$

Gradient Descent





Heavy Ball



# Метод тяжёлого шарика Поляка

Рассмотрим идею моментума (импульса, тяжёлого шарика), предложенную Б.Т. Поляком в 1964 году. Обновление метода тяжёлого шарика имеет вид

$$x_{k+1} = x_k - \alpha \nabla f(x_k) + \beta(x_k - x_{k-1}).$$





# Метод тяжёлого шарика Поляка

Рассмотрим идею моментума (импульса, тяжёлого шарика), предложенную Б.Т. Поляком в 1964 году. Обновление метода тяжёлого шарика имеет вид



$$x_{k+1} = x_k - \alpha \nabla f(x_k) + \beta(x_k - x_{k-1}).$$

Давайте теперь подставим в итерацию предыдущую итерацию, т.е.  $x_k = x_{k-1} - \alpha \nabla f(x_{k-1}) + \beta(x_{k-1} - x_{k-2})$ , а так же отметим, что  $x_k - x_{k-1} = -\alpha \nabla f(x_{k-1}) + \beta(x_{k-1} - x_{k-2})$ :





# Метод тяжёлого шарика Поляка



Рассмотрим идею моментума (импульса, тяжёлого шарика), предложенную Б.Т. Поляком в 1964 году. Обновление метода тяжёлого шарика имеет вид

$$x_{k+1} = x_k - \alpha \nabla f(x_k) + \beta(x_k - x_{k-1}).$$

Давайте теперь подставим в итерацию предыдущую итерацию, т.е.  $x_k = x_{k-1} - \alpha \nabla f(x_{k-1}) + \beta(x_{k-1} - x_{k-2})$ , а так же отметим, что  $x_k - x_{k-1} = -\alpha \nabla f(x_{k-1}) + \beta(x_{k-1} - x_{k-2})$ :

$$x_{k+1} = x_k - \alpha \nabla f(x_k) + \beta(x_k - x_{k-1})$$



# Метод тяжёлого шарика Поляка

Рассмотрим идею моментума (импульса, тяжёлого шарика), предложенную Б.Т. Поляком в 1964 году. Обновление метода тяжёлого шарика имеет вид



$$x_{k+1} = x_k - \alpha \nabla f(x_k) + \beta(x_k - x_{k-1}).$$

Давайте теперь подставим в итерацию предыдущую итерацию, т.е.  $x_k = x_{k-1} - \alpha \nabla f(x_{k-1}) + \beta(x_{k-1} - x_{k-2})$ , а так же отметим, что  $x_k - x_{k-1} = -\alpha \nabla f(x_{k-1}) + \beta(x_{k-1} - x_{k-2})$ :

$$\begin{aligned} x_{k+1} &= x_k - \alpha \nabla f(x_k) + \beta(x_k - x_{k-1}) \\ &= x_k - \alpha \nabla f(x_k) + \beta(-\alpha \nabla f(x_{k-1}) + \beta(x_{k-1} - x_{k-2})) \end{aligned}$$



# Метод тяжёлого шарика Поляка





Рассмотрим идею импульса (импульса, тяжёлого шарика), предложенную Б.Т. Поляком в 1964 году. Обновление метода тяжёлого шарика имеет вид

$$x_{k+1} = x_k - \alpha \nabla f(x_k) + \beta(x_k - x_{k-1}).$$

Давайте теперь подставим в итерацию предыдущую итерацию, т.е.  $x_k = x_{k-1} - \alpha \nabla f(x_{k-1}) + \beta(x_{k-1} - x_{k-2})$ , а так же отметим, что  $x_k - x_{k-1} = -\alpha \nabla f(x_{k-1}) + \beta(x_{k-1} - x_{k-2})$ :

$$\begin{aligned} x_{k+1} &= x_k - \alpha \nabla f(x_k) + \beta(x_k - x_{k-1}) \\ &= x_k - \alpha \nabla f(x_k) + \beta(-\alpha \nabla f(x_{k-1}) + \beta(x_{k-1} - x_{k-2})) \\ &= x_k - \alpha [\nabla f(x_k) + \beta \nabla f(x_{k-1})] + \beta^2(x_{k-1} - x_{k-2}) \end{aligned}$$

# Метод тяжёлого шарика Поляка



Рассмотрим идею моментума (импульса, тяжёлого шарика), предложенную Б.Т. Поляком в 1964 году. Обновление метода тяжёлого шарика имеет вид



$$x_{k+1} = x_k - \alpha \nabla f(x_k) + \beta(x_k - x_{k-1}).$$

Давайте теперь подставим в итерацию предыдущую итерацию, т.е.

$$x_k = x_{k-1} - \alpha \nabla f(x_{k-1}) + \beta(x_{k-1} - x_{k-2}), \text{ а так же отметим, что } x_k - x_{k-1} = -\alpha \nabla f(x_{k-1}) + \beta(x_{k-1} - x_{k-2}):$$

$$\begin{aligned} x_{k+1} &= x_k - \alpha \nabla f(x_k) + \beta(x_k - x_{k-1}) \\ &= x_k - \alpha \nabla f(x_k) + \beta(-\alpha \nabla f(x_{k-1}) + \beta(x_{k-1} - x_{k-2})) \\ &= x_k - \alpha [\nabla f(x_k) + \beta \nabla f(x_{k-1})] + \beta^2(x_{k-1} - x_{k-2}) \\ &= x_k - \alpha [\nabla f(x_k) + \beta \nabla f(x_{k-1}) + \beta^2 \nabla f(x_{k-2})] + \beta^3(x_{k-2} - x_{k-3}) \end{aligned}$$

# Метод тяжёлого шарика Поляка



Рассмотрим идею моментума (импульса, тяжёлого шарика), предложенную Б.Т. Поляком в 1964 году. Обновление метода тяжёлого шарика имеет вид



$$x_{k+1} = x_k - \alpha \nabla f(x_k) + \beta(x_k - x_{k-1}).$$

Давайте теперь подставим в итерацию предыдущую итерацию, т.е.

$$x_k = x_{k-1} - \alpha \nabla f(x_{k-1}) + \beta(x_{k-1} - x_{k-2}), \text{ а так же отметим, что } x_k - x_{k-1} = -\alpha \nabla f(x_{k-1}) + \beta(x_{k-1} - x_{k-2}):$$

$$\begin{aligned} x_{k+1} &= x_k - \alpha \nabla f(x_k) + \beta(x_k - x_{k-1}) \\ &= x_k - \alpha \nabla f(x_k) + \beta(-\alpha \nabla f(x_{k-1}) + \beta(x_{k-1} - x_{k-2})) \\ &= x_k - \alpha [\nabla f(x_k) + \beta \nabla f(x_{k-1})] + \beta^2(x_{k-1} - x_{k-2}) \\ &= x_k - \alpha [\nabla f(x_k) + \beta \nabla f(x_{k-1}) + \beta^2 \nabla f(x_{k-2})] + \beta^3(x_{k-2} - x_{k-3}) \\ &\vdots \end{aligned}$$

# Метод тяжёлого шарика Поляка



Рассмотрим идею моментума (импульса, тяжёлого шарика), предложенную Б.Т. Поляком в 1964 году. Обновление метода тяжёлого шарика имеет вид



$$x_{k+1} = x_k - \alpha \nabla f(x_k) + \beta(x_k - x_{k-1}).$$

Давайте теперь подставим в итерацию предыдущую итерацию, т.е.

$x_k = x_{k-1} - \alpha \nabla f(x_{k-1}) + \beta(x_{k-1} - x_{k-2})$ , а так же отметим, что  $x_k - x_{k-1} = -\alpha \nabla f(x_{k-1}) + \beta(x_{k-1} - x_{k-2})$ :

$$\begin{aligned} x_{k+1} &= x_k - \alpha \nabla f(x_k) + \beta(x_k - x_{k-1}) \\ &= x_k - \alpha \nabla f(x_k) + \beta(-\alpha \nabla f(x_{k-1}) + \beta(x_{k-1} - x_{k-2})) \\ &= x_k - \alpha [\nabla f(x_k) + \beta \nabla f(x_{k-1})] + \beta^2(x_{k-1} - x_{k-2}) \\ &= x_k - \alpha [\nabla f(x_k) + \beta \nabla f(x_{k-1}) + \beta^2 \nabla f(x_{k-2})] + \beta^3(x_{k-2} - x_{k-3}) \\ &\vdots \\ &= x_k - \alpha [\nabla f(x_k) + \beta \nabla f(x_{k-1}) + \beta^2 \nabla f(x_{k-2}) + \dots + \beta^k \nabla f(x_0)] \end{aligned}$$

# Метод тяжёлого шарика Поляка



Рассмотрим идею моментума (импульса, тяжёлого шарика), предложенную Б.Т. Поляком в 1964 году. Обновление метода тяжёлого шарика имеет вид

$$x_{k+1} = x_k - \alpha \nabla f(x_k) + \beta(x_k - x_{k-1}).$$

Давайте теперь подставим в итерацию предыдущую итерацию, т.е.

$x_k = x_{k-1} - \alpha \nabla f(x_{k-1}) + \beta(x_{k-1} - x_{k-2})$ , а так же отметим, что  $x_k - x_{k-1} = -\alpha \nabla f(x_{k-1}) + \beta(x_{k-1} - x_{k-2})$ :

$$\begin{aligned} x_{k+1} &= x_k - \alpha \nabla f(x_k) + \beta(x_k - x_{k-1}) \\ &= x_k - \alpha \nabla f(x_k) + \beta(-\alpha \nabla f(x_{k-1}) + \beta(x_{k-1} - x_{k-2})) \\ &= x_k - \alpha [\nabla f(x_k) + \beta \nabla f(x_{k-1})] + \beta^2(x_{k-1} - x_{k-2}) \\ &= x_k - \alpha [\nabla f(x_k) + \beta \nabla f(x_{k-1}) + \beta^2 \nabla f(x_{k-2})] + \beta^3(x_{k-2} - x_{k-3}) \\ &\vdots \\ &= x_k - \alpha [\nabla f(x_k) + \beta \nabla f(x_{k-1}) + \beta^2 \nabla f(x_{k-2}) + \dots + \beta^k \nabla f(x_0)] \end{aligned}$$

Таким образом, метод тяжёлого шарика учитывает все предыдущие градиенты с тем меньшим весом, чем старше итерация ( $0 \leq \beta < 1$ ).

## Метод тяжёлого шарика Поляка для сильно выпуклой квадратичной функции

Мы уже до этого показывали, как для произвольной сильно выпуклой квадратичной функции можно сделать замену координат так, чтобы в новых координатах матрица квадратичной формы имела диагональный вид.

Поэтому, можно рассмотреть функцию  $f(x) = \frac{1}{2}x^T \Lambda x$  с диагональной матрицей  $\Lambda$  и собственными значениями  $\lambda(\Lambda) \in [\mu, L]$ . Тогда

$$x_{k+1} = x_k - \alpha \Lambda x_k + \beta(x_k - x_{k-1}) = (I - \alpha \Lambda + \beta I)x_k - \beta x_{k-1}$$



## Метод тяжёлого шарика Поляка для сильно выпуклой квадратичной функции

Мы уже до этого показывали, как для произвольной сильно выпуклой квадратичной функции можно сделать замену координат так, чтобы в новых координатах матрица квадратичной формы имела диагональный вид.

Поэтому, можно рассмотреть функцию  $f(x) = \frac{1}{2}x^T \Lambda x$  с диагональной матрицей  $\Lambda$  и собственными значениями  $\lambda(\Lambda) \in [\mu, L]$ . Тогда

$$x_{k+1} = x_k - \alpha \Lambda x_k + \beta(x_k - x_{k-1}) = (I - \alpha \Lambda + \beta I)x_k - \beta x_{k-1}$$

Это можно переписать как

$$\begin{aligned}\hat{x}_{k+1} &= (I - \alpha \Lambda + \beta I)\hat{x}_k - \beta \hat{x}_{k-1}, \\ \hat{x}_k &= \hat{x}_k.\end{aligned}$$

## Метод тяжёлого шарика Поляка для сильно выпуклой квадратичной функции

Мы уже до этого показывали, как для произвольной сильно выпуклой квадратичной функции можно сделать замену координат так, чтобы в новых координатах матрица квадратичной формы имела диагональный вид.

Поэтому, можно рассмотреть функцию  $f(x) = \frac{1}{2}x^T \Lambda x$  с диагональной матрицей  $\Lambda$  и собственными значениями  $\lambda(\Lambda) \in [\mu, L]$ . Тогда

$$x_{k+1} = x_k - \alpha \Lambda x_k + \beta(x_k - x_{k-1}) = (I - \alpha \Lambda + \beta I)x_k - \beta x_{k-1}$$

Это можно переписать как

$$\begin{aligned}\hat{x}_{k+1} &= (I - \alpha \Lambda + \beta I)\hat{x}_k - \beta \hat{x}_{k-1}, \\ \hat{x}_k &= \hat{x}_k.\end{aligned}$$

Давайте введем следующее обозначение:  $\hat{z}_k = \begin{bmatrix} \hat{x}_{k+1} \\ \hat{x}_k \end{bmatrix}$ . Следовательно,  $\hat{z}_{k+1} = M \hat{z}_k$ , где матрица итерации  $M$  имеет вид:

## Метод тяжёлого шарика Поляка для сильно выпуклой квадратичной функции

Мы уже до этого показывали, как для произвольной сильно выпуклой квадратичной функции можно сделать замену координат так, чтобы в новых координатах матрица квадратичной формы имела диагональный вид.

Поэтому, можно рассмотреть функцию  $f(x) = \frac{1}{2}x^T \Lambda x$  с диагональной матрицей  $\Lambda$  и собственными значениями  $\lambda(\Lambda) \in [\mu, L]$ . Тогда

$$x_{k+1} = x_k - \alpha \Lambda x_k + \beta (x_k - x_{k-1}) = (I - \alpha \Lambda + \beta I)x_k - \beta x_{k-1}$$

Это можно переписать как

$$\begin{aligned}\hat{x}_{k+1} &= (I - \alpha \Lambda + \beta I)\hat{x}_k - \beta \hat{x}_{k-1}, \\ \hat{x}_k &= \hat{x}_k.\end{aligned}$$

Давайте введем следующее обозначение:  $\hat{z}_k = \begin{bmatrix} \hat{x}_{k+1} \\ \hat{x}_k \end{bmatrix}$ . Следовательно,  $\hat{z}_{k+1} = M \hat{z}_k$ , где матрица итерации  $M$  имеет вид:

$$M = \begin{bmatrix} I - \alpha \Lambda + \beta I & -\beta I \\ I & 0_d \end{bmatrix}.$$

## Сведение к скалярному случаю

Обратим внимание, что  $M$  является матрицей  $2d \times 2d$  с четырьмя блочно-диагональными матрицами размера  $d \times d$  внутри. Это означает, что мы можем изменить порядок координат, чтобы сделать  $M$  блочно-диагональной. Обратите внимание, что в уравнении ниже матрица  $M$  обозначает то же самое, что и в обозначении выше, за исключением описанной перестановки строк и столбцов. Мы используем эту небольшую перегрузку обозначений для простоты.

## Сведение к скалярному случаю

Обратим внимание, что  $M$  является матрицей  $2d \times 2d$  с четырьмя блочно-диагональными матрицами размера  $d \times d$  внутри. Это означает, что мы можем изменить порядок координат, чтобы сделать  $M$  блочно-диагональной. Обратите внимание, что в уравнении ниже матрица  $M$  обозначает то же самое, что и в обозначении выше, за исключением описанной перестановки строк и столбцов. Мы используем эту небольшую перегрузку обозначений для простоты.




Рис. 1: Иллюстрация перестановки матрицы  $M$

где  $\hat{x}_k^{(i)}$  является  $i$ -й координатой вектора  $\hat{x}_k \in \mathbb{R}^d$  и  $M_i$  обозначает матрицу размера  $2 \times 2$ . Переупорядочение позволяет нам исследовать динамику метода независимо от размерности. Асимптотическая скорость сходимости последовательности векторов  $\hat{z}_k$  размерности  $2d$  определяется наихудшей скоростью сходимости среди его блока координат. Следовательно, достаточно исследовать оптимизацию в одномерном случае.

## Сведение к скалярному случаю

Для  $i$ -й координаты, где  $\lambda_i$  —  $i$ -е собственное значение матрицы  $A$ , имеем:

$$M_i = \begin{bmatrix} 1 - \alpha\lambda_i + \beta & -\beta \\ 1 & 0 \end{bmatrix}.$$

## Сведение к скалярному случаю

Для  $i$ -й координаты, где  $\lambda_i$  —  $i$ -е собственное значение матрицы  $A$ , имеем:

$$M_i = \begin{bmatrix} 1 - \alpha\lambda_i + \beta & -\beta \\ 1 & 0 \end{bmatrix}.$$

Метод будет сходиться, если  $\rho(M) < 1$ , и оптимальные параметры могут быть вычислены путем оптимизации спектрального радиуса

$$\alpha^*, \beta^* = \arg \min_{\alpha, \beta} \max_i \rho(M_i), \quad \alpha^* = \frac{4}{(\sqrt{L} + \sqrt{\mu})^2}, \quad \beta^* = \left( \frac{\sqrt{L} - \sqrt{\mu}}{\sqrt{L} + \sqrt{\mu}} \right)^2.$$

## Сведение к скалярному случаю

Для  $i$ -й координаты, где  $\lambda_i$  —  $i$ -е собственное значение матрицы  $A$ , имеем:

$$M_i = \begin{bmatrix} 1 - \alpha\lambda_i + \beta & -\beta \\ 1 & 0 \end{bmatrix}.$$

Метод будет сходиться, если  $\rho(M) < 1$ , и оптимальные параметры могут быть вычислены путем оптимизации спектрального радиуса

$$\alpha^*, \beta^* = \arg \min_{\alpha, \beta} \max_i \rho(M_i), \quad \alpha^* = \frac{4}{(\sqrt{L} + \sqrt{\mu})^2}, \quad \beta^* = \left( \frac{\sqrt{L} - \sqrt{\mu}}{\sqrt{L} + \sqrt{\mu}} \right)^2.$$

Можно показать, что для таких параметров матрица  $M$  имеет комплексные собственные значения, которые образуют комплексно-сопряжённую пару, поэтому расстояние до оптимума (в этом случае  $\|z_k\|$ ) обычно не убывает монотонно.



# Характеристическое уравнение

Собственные значения матрицы  $M_i$  определяются из характеристического уравнения  $\det(M_i - zI) = 0$ :

## Характеристическое уравнение

Собственные значения матрицы  $M_i$  определяются из характеристического уравнения  $\det(M_i - zI) = 0$ :

$$\det \begin{pmatrix} 1 - \alpha\lambda_i + \beta - z & -\beta \\ 1 & -z \end{pmatrix} = -z(1 - \alpha\lambda_i + \beta - z) + \beta = z^2 - (1 - \alpha\lambda_i + \beta)z + \beta = 0$$

## Характеристическое уравнение

Собственные значения матрицы  $M_i$  определяются из характеристического уравнения  $\det(M_i - zI) = 0$ :

$$\det \begin{pmatrix} 1 - \alpha\lambda_i + \beta - z & -\beta \\ 1 & -z \end{pmatrix} = -z(1 - \alpha\lambda_i + \beta - z) + \beta = z^2 - (1 - \alpha\lambda_i + \beta)z + \beta = 0$$

Пусть  $z_1, z_2$  — корни этого уравнения. По теореме Виета:

$$z_1 z_2 = \beta, \quad z_1 + z_2 = 1 - \alpha\lambda_i + \beta$$

## Характеристическое уравнение

Собственные значения матрицы  $M_i$  определяются из характеристического уравнения  $\det(M_i - zI) = 0$ :

$$\det \begin{pmatrix} 1 - \alpha\lambda_i + \beta - z & -\beta \\ 1 & -z \end{pmatrix} = -z(1 - \alpha\lambda_i + \beta - z) + \beta = z^2 - (1 - \alpha\lambda_i + \beta)z + \beta = 0$$

Пусть  $z_1, z_2$  — корни этого уравнения. По теореме Виета:

$$z_1 z_2 = \beta, \quad z_1 + z_2 = 1 - \alpha\lambda_i + \beta$$

Спектральный радиус  $\rho(M_i) = \max(|z_1|, |z_2|)$ . Для сходимости необходимо  $\rho(M_i) < 1$ , что подразумевает  $\beta < 1$  (так как  $z_1 z_2 = \beta$ ).

## Анализ дискриминанта: Вещественные корни

Дискриминант квадратного уравнения  $z^2 - (1 - \alpha\lambda_i + \beta)z + \beta = 0$ :

$$D = (1 - \alpha\lambda_i + \beta)^2 - 4\beta$$

Рассмотрим случай **вещественных корней** ( $D \geq 0$ ). Корни вещественны и  $z_1, z_2 = \frac{1 - \alpha\lambda_i + \beta \pm \sqrt{D}}{2}$ . Так как  $z_1 z_2 = \beta$ , то если корни различны, один из них по модулю должен быть больше  $\sqrt{\beta}$  (если только они не равны  $\pm\sqrt{\beta}$ ). Более того, если  $D > 0$ , то  $\max(|z_1|, |z_2|) > \sqrt{\beta}$ . Это означает, что скорость сходимости будет хуже, чем  $\sqrt{\beta}$ .

## Анализ дискриминанта: Комплексные корни

Рассмотрим случай **комплексных корней** ( $D < 0$ ). Корни комплексно-сопряженные:

$$z_{1,2} = \frac{1 - \alpha\lambda_i + \beta \pm i\sqrt{4\beta - (1 - \alpha\lambda_i + \beta)^2}}{2}$$

Вычислим квадрат модуля корней:

$$\begin{aligned} |z_{1,2}|^2 &= \left( \frac{1 - \alpha\lambda_i + \beta}{2} \right)^2 + \left( \frac{\sqrt{4\beta - (1 - \alpha\lambda_i + \beta)^2}}{2} \right)^2 \\ &= \frac{(1 - \alpha\lambda_i + \beta)^2 + 4\beta - (1 - \alpha\lambda_i + \beta)^2}{4} = \frac{4\beta}{4} = \beta \end{aligned}$$

Следовательно,  $|z_1| = |z_2| = \sqrt{\beta}$ .

# Вывод по дискриминанту

## Вывод по дискриминанту

- В случае **комплексных корней** спектральный радиус  $\rho(M_i) = \sqrt{\beta}$  и не зависит от  $\lambda_i$ .



## Вывод по дискриминанту

- В случае **комплексных корней** спектральный радиус  $\rho(M_i) = \sqrt{\beta}$  и **не зависит от  $\lambda_i$** .
- В случае **вещественных корней** спектральный радиус  $\rho(M_i) \geq \sqrt{\beta}$  и **зависит от  $\lambda_i$** .

## Вывод по дискриминанту

- В случае **комплексных корней** спектральный радиус  $\rho(M_i) = \sqrt{\beta}$  и **не зависит от  $\lambda_i$** .
- В случае **вещественных корней** спектральный радиус  $\rho(M_i) \geq \sqrt{\beta}$  и **зависит от  $\lambda_i$** .

## Вывод по дискриминанту

- В случае **комплексных корней** спектральный радиус  $\rho(M_i) = \sqrt{\beta}$  и **не зависит от  $\lambda_i$** .
- В случае **вещественных корней** спектральный радиус  $\rho(M_i) \geq \sqrt{\beta}$  и **зависит от  $\lambda_i$** .

**Стратегия:** Мы хотим минимизировать худший спектральный радиус по всем  $\lambda_i$ . Наилучшая ситуация достигается, когда для всех  $\lambda_i$  корни комплексные (или на границе  $D = 0$ ), и мы минимизируем  $\sqrt{\beta}$ . Поэтому мы требуем выполнения условия  $D \leq 0$  для всех  $\lambda_i \in [\mu, L]$ .

## Постановка задачи оптимизации

Мы ищем  $\alpha > 0, \beta \geq 0$ , минимизирующие спектральный радиус  $\rho(\alpha, \beta) = \max_{\lambda \in [\mu, L]} \max(|z_1(\lambda)|, |z_2(\lambda)|)$ .  
Радиус корней для фиксированного  $\lambda$ :

$$r(\lambda) = \begin{cases} \frac{1}{2} \left( |1 + \beta - \alpha\lambda| + \sqrt{(1 + \beta - \alpha\lambda)^2 - 4\beta} \right), & \text{если } D > 0 \\ \sqrt{\beta}, & \text{если } D \leq 0 \end{cases}$$

## Постановка задачи оптимизации

Мы ищем  $\alpha > 0, \beta \geq 0$ , минимизирующие спектральный радиус  $\rho(\alpha, \beta) = \max_{\lambda \in [\mu, L]} \max(|z_1(\lambda)|, |z_2(\lambda)|)$ . Радиус корней для фиксированного  $\lambda$ :

$$r(\lambda) = \begin{cases} \frac{1}{2} \left( |1 + \beta - \alpha\lambda| + \sqrt{(1 + \beta - \alpha\lambda)^2 - 4\beta} \right), & \text{если } D > 0 \\ \sqrt{\beta}, & \text{если } D \leq 0 \end{cases}$$

Обозначим  $\alpha_{opt} = \left( \frac{2}{\sqrt{L} + \sqrt{\mu}} \right)^2$ . Заметим, что  $D \leq 0 \iff \beta \geq (1 - \sqrt{\alpha\bar{\lambda}})^2$ . Также  $|1 - \sqrt{\alpha\mu}| < |1 - \sqrt{\alpha L}| \iff \alpha > \alpha_{opt}$ .

## Анализ случаев

Рассмотрим 4 случая в зависимости от  $\alpha$  и  $\beta$ :

1.  $0 < \alpha \leq \alpha_{opt}$  и  $\beta \geq (1 - \sqrt{\alpha\mu})^2$ . Тогда  $\rho = \sqrt{\beta} \geq 1 - \sqrt{\alpha\mu} \geq \frac{\sqrt{L} - \sqrt{\mu}}{\sqrt{L} + \sqrt{\mu}}$ .

## Анализ случаев

Рассмотрим 4 случая в зависимости от  $\alpha$  и  $\beta$ :

1.  $0 < \alpha \leq \alpha_{opt}$  и  $\beta \geq (1 - \sqrt{\alpha\mu})^2$ . Тогда  $\rho = \sqrt{\beta} \geq 1 - \sqrt{\alpha\mu} \geq \frac{\sqrt{L} - \sqrt{\mu}}{\sqrt{L} + \sqrt{\mu}}$ .

## Анализ случаев

Рассмотрим 4 случая в зависимости от  $\alpha$  и  $\beta$ :

1.  $0 < \alpha \leq \alpha_{opt}$  и  $\beta \geq (1 - \sqrt{\alpha\mu})^2$ . Тогда  $\rho = \sqrt{\beta} \geq 1 - \sqrt{\alpha\mu} \geq \frac{\sqrt{L} - \sqrt{\mu}}{\sqrt{L} + \sqrt{\mu}}$ .
2.  $0 < \alpha \leq \alpha_{opt}$  и  $\beta < (1 - \sqrt{\alpha\mu})^2$ . Тогда  $\rho \geq r(\mu) > 1 - \sqrt{\alpha\mu} \geq \frac{\sqrt{L} - \sqrt{\mu}}{\sqrt{L} + \sqrt{\mu}}$ . (Здесь  $r(\mu)$  убывает по  $\beta$ ).



## Анализ случаев (продолжение)

3.  $\alpha > \alpha_{opt}$  и  $\beta \geq (\sqrt{\alpha L} - 1)^2$ . Тогда  $\rho = \sqrt{\beta} \geq \sqrt{\alpha L} - 1 > \frac{\sqrt{L} - \sqrt{\mu}}{\sqrt{L} + \sqrt{\mu}}$ .

## Анализ случаев (продолжение)

3.  $\alpha > \alpha_{opt}$  и  $\beta \geq (\sqrt{\alpha L} - 1)^2$ . Тогда  $\rho = \sqrt{\beta} \geq \sqrt{\alpha L} - 1 > \frac{\sqrt{L} - \sqrt{\mu}}{\sqrt{L} + \sqrt{\mu}}$ .

## Анализ случаев (продолжение)

3.  $\alpha > \alpha_{opt}$  и  $\beta \geq (\sqrt{\alpha L} - 1)^2$ . Тогда  $\rho = \sqrt{\beta} \geq \sqrt{\alpha L} - 1 > \frac{\sqrt{L} - \sqrt{\mu}}{\sqrt{L} + \sqrt{\mu}}$ .
4.  $\alpha > \alpha_{opt}$  и  $\beta < (\sqrt{\alpha L} - 1)^2$ . Тогда  $\rho \geq r(L) > \sqrt{\alpha L} - 1 > \frac{\sqrt{L} - \sqrt{\mu}}{\sqrt{L} + \sqrt{\mu}}$ . (Здесь  $r(L)$  убывает по  $\beta$ ).

## Оптимальные параметры

Во всех случаях  $\rho(\alpha, \beta) \geq \frac{\sqrt{L} - \sqrt{\mu}}{\sqrt{L} + \sqrt{\mu}}$ . Равенство достигается только в первом случае на границе:

$$\alpha^* = \left( \frac{2}{\sqrt{L} + \sqrt{\mu}} \right)^2, \quad \beta^* = \left( \frac{\sqrt{L} - \sqrt{\mu}}{\sqrt{L} + \sqrt{\mu}} \right)^2$$

## Оптимальные параметры

Во всех случаях  $\rho(\alpha, \beta) \geq \frac{\sqrt{L} - \sqrt{\mu}}{\sqrt{L} + \sqrt{\mu}}$ . Равенство достигается только в первом случае на границе:

$$\alpha^* = \left( \frac{2}{\sqrt{L} + \sqrt{\mu}} \right)^2, \quad \beta^* = \left( \frac{\sqrt{L} - \sqrt{\mu}}{\sqrt{L} + \sqrt{\mu}} \right)^2$$

При этом оптимальная скорость сходимости:

$$\rho_{opt} = \frac{\sqrt{L} - \sqrt{\mu}}{\sqrt{L} + \sqrt{\mu}} = \frac{\sqrt{\kappa} - 1}{\sqrt{\kappa} + 1}$$

Это соответствует сложности  $O(\sqrt{\kappa} \log \frac{1}{\varepsilon})$ .

# Сходимость метода тяжёлого шарика для квадратичной функции

## i Theorem

Предположим, что  $f$  является  $\mu$ -сильно выпуклой и  $L$ -гладкой квадратичной функцией. Тогда метод тяжёлого шарика с параметрами

$$\alpha = \frac{4}{(\sqrt{L} + \sqrt{\mu})^2}, \beta = \left( \frac{\sqrt{L} - \sqrt{\mu}}{\sqrt{L} + \sqrt{\mu}} \right)^2$$

сходится линейно:

$$\|x_k - x^*\|_2 \leq \left( \frac{\sqrt{\kappa} - 1}{\sqrt{\kappa} + 1} \right)^k \|x_0 - x^*\|$$

# Глобальная сходимость метода тяжёлого шарика<sup>3</sup>

## i Theorem

Предположим, что  $f$  является гладкой и выпуклой и что

$$\beta \in [0, 1), \quad \alpha \in \left(0, \frac{2(1-\beta)}{L}\right).$$

Тогда последовательность  $\{x_k\}$ , генерируемая итерациями тяжёлого шарика, удовлетворяет

$$f(\bar{x}_T) - f^* \leq \begin{cases} \frac{\|x_0 - x^*\|^2}{2(T+1)} \left( \frac{L\beta}{1-\beta} + \frac{1-\beta}{\alpha} \right), & \text{if } \alpha \in \left(0, \frac{1-\beta}{L}\right], \\ \frac{\|x_0 - x^*\|^2}{2(T+1)(2(1-\beta) - \alpha L)} \left( L\beta + \frac{(1-\beta)^2}{\alpha} \right), & \text{if } \alpha \in \left[\frac{1-\beta}{L}, \frac{2(1-\beta)}{L}\right), \end{cases}$$

где  $\bar{x}_T$  среднее Чезаро последовательности итераций, т.е.

$$\bar{x}_T = \frac{1}{T+1} \sum_{k=0}^T x_k.$$

<sup>3</sup>Глобальная сходимость метода тяжёлого шарика для выпуклой оптимизации, Euhanna Ghadimi et al.

# Глобальная сходимость метода тяжёлого шарика<sup>4</sup>

## i Theorem

Предположим, что  $f$  является гладкой и сильно выпуклой и что

$$\alpha \in \left(0, \frac{2}{L}\right), \quad 0 \leq \beta < \frac{1}{2} \left( \frac{\mu\alpha}{2} + \sqrt{\frac{\mu^2\alpha^2}{4} + 4\left(1 - \frac{\alpha L}{2}\right)} \right).$$

Тогда последовательность  $\{x_k\}$ , генерируемая итерациями метода тяжёлого шарика, сходится линейно к единственному оптимальному решению  $x^*$ . В частности,

$$f(x_k) - f^* \leq q^k (f(x_0) - f^*),$$

где  $q \in [0, 1)$ .

<sup>4</sup>Глобальная сходимость метода тяжёлого шарика для выпуклой оптимизации, Euhanna Ghadimi et al.



## Итоги по методу тяжёлого шарика

- Обеспечивает ускоренную сходимость для сильно выпуклых квадратичных задач.

## Итоги по методу тяжёлого шарика

- Обеспечивает ускоренную сходимость для сильно выпуклых квадратичных задач.
- Локально ускоренная сходимость была доказана в оригинальной статье.

## Итоги по методу тяжёлого шарика

- Обеспечивает ускоренную сходимость для сильно выпуклых квадратичных задач.
- Локально ускоренная сходимость была доказана в оригинальной статье.
- Недавно <sup>5</sup> было доказано, что глобального ускорения сходимости для метода не существует.

---

<sup>5</sup>Provable non-accelerations of the heavy-ball method

## Итоги по методу тяжёлого шарика

- Обеспечивает ускоренную сходимость для сильно выпуклых квадратичных задач.
- Локально ускоренная сходимость была доказана в оригинальной статье.
- Недавно <sup>5</sup> было доказано, что глобального ускорения сходимости для метода не существует.
- Метод не был чрезвычайно популярен до ML-бума.

---

<sup>5</sup>Provable non-accelerations of the heavy-ball method

## Итоги по методу тяжёлого шарика

- Обеспечивает ускоренную сходимость для сильно выпуклых квадратичных задач.
- Локально ускоренная сходимость была доказана в оригинальной статье.
- Недавно <sup>5</sup> было доказано, что глобального ускорения сходимости для метода не существует.
- Метод не был чрезвычайно популярен до ML-бума.
- Сейчас он фактически является стандартом для практического ускорения методов градиентного спуска, в том числе для невыпуклых задач (обучение нейронных сетей).

---

<sup>5</sup>Provable non-accelerations of the heavy-ball method

## Ускоренный градиентный метод Нестерова

## Концепция ускоренного градиентного метода Нестерова

$$x_{k+1} = x_k - \alpha \nabla f(x_k) \qquad x_{k+1} = x_k - \alpha \nabla f(x_k) + \beta(x_k - x_{k-1}) \qquad \begin{cases} y_{k+1} = x_k + \beta(x_k - x_{k-1}) \\ x_{k+1} = y_{k+1} - \alpha \nabla f(y_{k+1}) \end{cases}$$

# Концепция ускоренного градиентного метода Нестерова

$$x_{k+1} = x_k - \alpha \nabla f(x_k) \quad x_{k+1} = x_k - \alpha \nabla f(x_k) + \beta(x_k - x_{k-1})$$

Давайте определим следующие обозначения

$$x^+ = x - \alpha \nabla f(x) \quad \text{Градиентный шаг}$$

$$d_k = \beta_k(x_k - x_{k-1}) \quad \text{Импульс}$$

Тогда мы можем записать:


$$x_{k+1} = x_k^+ \quad \text{Градиентный спуск}$$

$$x_{k+1} = x_k^+ + d_k \quad \text{Метод тяжёлого шарика}$$


$$x_{k+1} = (x_k + d_k)^+ \quad \text{Ускоренный градиентный метод Нестерова}$$

$$\begin{cases} y_{k+1} = x_k + \beta(x_k - x_{k-1}) \\ x_{k+1} = y_{k+1} - \alpha \nabla f(y_{k+1}) \end{cases}$$

Polyak momentum



Nesterov momentum





# Сходимость для выпуклых функций

## i Theorem

Предположим, что  $f : \mathbb{R}^n \rightarrow \mathbb{R}$  является выпуклой и  $L$ -гладкой. Ускоренный градиентный метод Нестерова (NAG) предназначен для решения задачи минимизации, начиная с начальной точки  $x_0 = y_0 \in \mathbb{R}^n$  и  $\lambda_0 = 0$ . Алгоритм выполняет следующие шаги:

**Обновление градиента:** 
$$x_{k+1} = y_k - \frac{1}{L} \nabla f(y_k)$$

**Вес экстраполяции:** 
$$\lambda_{k+1} = \frac{1 + \sqrt{1 + 4\lambda_k^2}}{2}$$

$$\gamma_k = \frac{\lambda_k - 1}{\lambda_{k+1}}$$

**Экстраполяция:** 
$$y_{k+1} = x_{k+1} + \gamma_k (x_{k+1} - x_k)$$

Последовательность  $\{f(x_k)\}_{k \in \mathbb{N}}$ , генерируемая алгоритмом, сходится к оптимальному значению  $f^*$  со скоростью  $\mathcal{O}\left(\frac{1}{k^2}\right)$ , в частности:

$$f(x_k) - f^* \leq \frac{2L\|x_0 - x^*\|^2}{k^2}$$

# Ускоренная сходимость для сильно выпуклых функций

## i Theorem

Предположим, что  $f : \mathbb{R}^n \rightarrow \mathbb{R}$  является  $\mu$ -сильно выпуклой и  $L$ -гладкой. Ускоренный градиентный метод Нестерова (NAG) предназначен для решения задачи минимизации, начиная с начальной точки  $x_0 = y_0 \in \mathbb{R}^n$  и  $\lambda_0 = 0$ . Алгоритм выполняет следующие шаги:

**Обновление градиента:** 
$$x_{k+1} = y_k - \frac{1}{L} \nabla f(y_k)$$

**Экстраполяция:** 
$$y_{k+1} = x_{k+1} - \gamma (x_{k+1} - x_k)$$

**Вес экстраполяции:** 
$$\gamma = \frac{\sqrt{L} - \sqrt{\mu}}{\sqrt{L} + \sqrt{\mu}}$$


Последовательность  $\{f(x_k)\}_{k \in \mathbb{N}}$ , генерируемая алгоритмом, сходится к оптимальному значению  $f^*$  линейно:

$$f(x_k) - f^* \leq \frac{\mu + L}{2} \|x_0 - x^*\|_2^2 \exp\left(-\frac{k}{\sqrt{\kappa}}\right)$$

## Численные эксперименты

# Выпуклая квадратичная задача (линейная регрессия)


Convex quadratics:  $n=60$ , random matrix,  $\mu=0$ ,  $L=10$




# Сильно выпуклая квадратичная задача (регуляризованная линейная регрессия)

Strongly convex quadratics:  $n=60$ , random matrix,  $\mu=1$ ,  $L=10$


Function Gap



Domain Gap




Gradient Norm



— Gradient Descent.  $\alpha=1.67\text{e-}01$     - - - Heavy Ball.  $\alpha=2.15\text{e-}01$ ,  $\beta=2.88\text{e-}01$     ... NAG.  $\alpha=9.09\text{e-}02$ ,  $\beta=5.37\text{e-}01$

# Сильно выпуклая квадратичная задача (регуляризованная линейная регрессия)


Strongly convex quadratics:  $n=60$ , random matrix,  $\mu=1$ ,  $L=1000$




# Сильно выпуклая квадратичная задача (регуляризованная линейная регрессия)

Strongly convex quadratics:  $n=1000$ , random matrix,  $\mu=1$ ,  $L=1000$


Function Gap



Domain Gap




Gradient Norm



— Gradient Descent.  $\alpha=2.00\text{e-}03$     - - - Heavy Ball.  $\alpha=3.75\text{e-}03, \beta=8.81\text{e-}01$     ····· NAG.  $\alpha=9.99\text{e-}04, \beta=9.39\text{e-}01$

# Выпуклая бинарная логистическая регрессия


Convex binary logistic regression.  $\mu=0$ .






# Выпуклая бинарная логистическая регрессия

Convex binary logistic regression.  $\mu=0$ .




# Выпуклая бинарная логистическая регрессия

Convex binary logistic regression.  $\mu=0$ .




# Выпуклая бинарная логистическая регрессия

Convex binary logistic regression.  $\mu=0$ .




# Выпуклая бинарная логистическая регрессия

Convex binary logistic regression.  $\mu=0$ .




# Выпуклая бинарная логистическая регрессия

Convex binary logistic regression.  $\mu=0$ .




# Выпуклая бинарная логистическая регрессия

Convex binary logistic regression.  $\mu=0$ .




# Выпуклая бинарная логистическая регрессия

Convex binary logistic regression.  $\mu=0$ .



# Выпуклая бинарная логистическая регрессия


Convex binary logistic regression.  $\mu=0$ .






# Выпуклая бинарная логистическая регрессия

Convex binary logistic regression.  $\mu=0$ .




# Выпуклая бинарная логистическая регрессия

Convex binary logistic regression.  $\mu=0$ .




# Сильно выпуклая бинарная логистическая регрессия

Strongly convex binary logistic regression.  $\mu=1$ .




# Сильно выпуклая бинарная логистическая регрессия

Strongly convex binary logistic regression.  $\mu=1$ .



# Сильно выпуклая бинарная логистическая регрессия

Strongly convex binary logistic regression.  $\mu=1$ .



# Сильно выпуклая бинарная логистическая регрессия

Strongly convex binary logistic regression.  $\mu=1$ .

