

A Corgi dog and a yellow rubber duck are sitting inside a transparent, wireframe cube. The Corgi is on the left, looking towards the camera, and the rubber duck is on the right, facing the Corgi. The cube is made of thin, metallic-looking lines and is centered in the frame. The background is a plain, light-colored surface.

Градиентные методы для задач с ограничениями. Метод проекции градиента. Метод Франк-Вульфа. Метод зеркального спуска

Даня Меркулов

Методы оптимизации. МФТИ

Методы с ограничениями

Условная оптимизация

Безусловная оптимизация

$$\min_{x \in \mathbb{R}^n} f(x)$$

- Любая точка $x_0 \in \mathbb{R}^n$ допустима и может быть решением.

Условная оптимизация

Безусловная оптимизация

$$\min_{x \in \mathbb{R}^n} f(x)$$

- Любая точка $x_0 \in \mathbb{R}^n$ допустима и может быть решением.

Условная оптимизация

Безусловная оптимизация

$$\min_{x \in \mathbb{R}^n} f(x)$$

- Любая точка $x_0 \in \mathbb{R}^n$ допустима и может быть решением.

Условная оптимизация

$$\min_{x \in S} f(x)$$

- Не все $x \in \mathbb{R}^n$ допустимы и могут быть решением.

Условная оптимизация

Безусловная оптимизация

$$\min_{x \in \mathbb{R}^n} f(x)$$

- Любая точка $x_0 \in \mathbb{R}^n$ допустима и может быть решением.

Условная оптимизация

$$\min_{x \in S} f(x)$$

- Не все $x \in \mathbb{R}^n$ допустимы и могут быть решением.
- Решение должно лежать внутри множества S .

Условная оптимизация

Безусловная оптимизация

$$\min_{x \in \mathbb{R}^n} f(x)$$

- Любая точка $x_0 \in \mathbb{R}^n$ допустима и может быть решением.

Условная оптимизация

$$\min_{x \in S} f(x)$$

- Не все $x \in \mathbb{R}^n$ допустимы и могут быть решением.
- Решение должно лежать внутри множества S .
- Пример:

$$\frac{1}{2} \|Ax - b\|_2^2 \rightarrow \min_{\|x\|_2^2 \leq 1}$$

Условная оптимизация

Безусловная оптимизация

$$\min_{x \in \mathbb{R}^n} f(x)$$

- Любая точка $x_0 \in \mathbb{R}^n$ допустима и может быть решением.

Условная оптимизация

$$\min_{x \in S} f(x)$$

- Не все $x \in \mathbb{R}^n$ допустимы и могут быть решением.
- Решение должно лежать внутри множества S .
- Пример:

$$\frac{1}{2} \|Ax - b\|_2^2 \rightarrow \min_{\|x\|_2^2 \leq 1}$$

Условная оптимизация

Безусловная оптимизация

$$\min_{x \in \mathbb{R}^n} f(x)$$

- Любая точка $x_0 \in \mathbb{R}^n$ допустима и может быть решением.

Условная оптимизация

$$\min_{x \in S} f(x)$$

- Не все $x \in \mathbb{R}^n$ допустимы и могут быть решением.
- Решение должно лежать внутри множества S .
- Пример:

$$\frac{1}{2} \|Ax - b\|_2^2 \rightarrow \min_{\|x\|_2^2 \leq 1}$$

Градиентный спуск — отличный способ решения безусловных задач

$$x_{k+1} = x_k - \alpha_k \nabla f(x_k) \quad (\text{GD})$$

Можно ли адаптировать градиентный спуск для задачи с ограничениями?

Условная оптимизация

Безусловная оптимизация

$$\min_{x \in \mathbb{R}^n} f(x)$$

- Любая точка $x_0 \in \mathbb{R}^n$ допустима и может быть решением.

Условная оптимизация

$$\min_{x \in S} f(x)$$

- Не все $x \in \mathbb{R}^n$ допустимы и могут быть решением.
- Решение должно лежать внутри множества S .
- Пример:

$$\frac{1}{2} \|Ax - b\|_2^2 \rightarrow \min_{\|x\|_2^2 \leq 1}$$

Градиентный спуск — отличный способ решения безусловных задач

$$x_{k+1} = x_k - \alpha_k \nabla f(x_k) \quad (\text{GD})$$

Можно ли адаптировать градиентный спуск для задачи с ограничениями?

Да. Для этого нужно использовать проекции, чтобы обеспечить допустимость на каждой итерации.

Пример: adversarial white-box attacks




Рис. 1: Источник

- Математически нейронная сеть — это функция $f(w; x)$

$$\min_{\delta} \text{size}(\delta) \quad \text{s.t.} \quad \text{pred}[f(w; x + \delta)] \neq y$$

или

$$\max_{\delta} l(w; x + \delta, y) \quad \text{s.t.} \quad \text{size}(\delta) \leq \epsilon, \quad 0 \leq x + \delta \leq 1$$

Пример: adversarial white-box attacks




Рис. 1: Источник

- Математически нейронная сеть — это функция $f(w; x)$
- Обычно вход x задан, а веса сети w оптимизируются

$$\min_{\delta} \text{size}(\delta) \quad \text{s.t.} \quad \text{pred}[f(w; x + \delta)] \neq y$$

или

$$\max_{\delta} l(w; x + \delta, y) \quad \text{s.t.} \quad \text{size}(\delta) \leq \epsilon, \quad 0 \leq x + \delta \leq 1$$

Пример: adversarial white-box attacks




Рис. 1: Источник

- Математически нейронная сеть — это функция $f(w; x)$
- Обычно вход x задан, а веса сети w оптимизируются
- Но можно зафиксировать веса w и оптимизировать x !

$$\min_{\delta} \text{size}(\delta) \quad \text{s.t.} \quad \text{pred}[f(w; x + \delta)] \neq y$$

или

$$\max_{\delta} l(w; x + \delta, y) \quad \text{s.t.} \quad \text{size}(\delta) \leq \epsilon, \quad 0 \leq x + \delta \leq 1$$

Идея метода проекции градиента




Рис. 2: Предположим, мы стартуем из точки x_k .

Идея метода проекции градиента




Рис. 3: И движемся в направлении $-\nabla f(x_k)$.

Идея метода проекции градиента




Рис. 4: Иногда мы можем оказаться за пределами допустимого множества.

Идея метода проекции градиента




Рис. 5: Решим эту маленькую проблему с помощью проекции!

Идея метода проекции градиента

$$x_{k+1} = \text{proj}_S(x_k - \alpha_k \nabla f(x_k)) \quad \Leftrightarrow \quad \begin{aligned} y_k &= x_k - \alpha_k \nabla f(x_k) \\ x_{k+1} &= \text{proj}_S(y_k) \end{aligned}$$




Рис. 6: Иллюстрация метода проекции градиента

Проекция

Проекция

Расстояние d от точки $y \in \mathbb{R}^n$ до замкнутого множества $S \subset \mathbb{R}^n$:

$$d(y, S, \|\cdot\|) = \inf\{\|x - y\| \mid x \in S\}$$

Проекция

Расстояние d от точки $y \in \mathbb{R}^n$ до замкнутого множества $S \subset \mathbb{R}^n$:

$$d(y, S, \|\cdot\|) = \inf\{\|x - y\| \mid x \in S\}$$

Мы сосредоточимся на евклидовой проекции (возможны и другие варианты) точки $y \in \mathbb{R}^n$ на множество $S \subseteq \mathbb{R}^n$ — это точка $\text{proj}_S(y) \in S$:

$$\text{proj}_S(y) = \underset{x \in S}{\operatorname{argmin}} \frac{1}{2} \|x - y\|_2^2$$

Проекция

Расстояние d от точки $y \in \mathbb{R}^n$ до замкнутого множества $S \subset \mathbb{R}^n$:

$$d(y, S, \|\cdot\|) = \inf\{\|x - y\| \mid x \in S\}$$

Мы сосредоточимся на евклидовой проекции (возможны и другие варианты) точки $y \in \mathbb{R}^n$ на множество $S \subseteq \mathbb{R}^n$ — это точка $\text{proj}_S(y) \in S$:

$$\text{proj}_S(y) = \underset{x \in S}{\operatorname{argmin}} \frac{1}{2} \|x - y\|_2^2$$

- **Достаточные условия существования проекции.** Если $S \subseteq \mathbb{R}^n$ — замкнутое множество, то проекция на множество S существует для любой точки.

Проекция

Расстояние d от точки $y \in \mathbb{R}^n$ до замкнутого множества $S \subset \mathbb{R}^n$:

$$d(y, S, \|\cdot\|) = \inf\{\|x - y\| \mid x \in S\}$$

Мы сосредоточимся на евклидовой проекции (возможны и другие варианты) точки $y \in \mathbb{R}^n$ на множество $S \subseteq \mathbb{R}^n$ — это точка $\text{proj}_S(y) \in S$:

$$\text{proj}_S(y) = \underset{x \in S}{\operatorname{argmin}} \frac{1}{2} \|x - y\|_2^2$$

- **Достаточные условия существования проекции.** Если $S \subseteq \mathbb{R}^n$ — замкнутое множество, то проекция на множество S существует для любой точки.
- **Достаточные условия единственности проекции.** Если $S \subseteq \mathbb{R}^n$ — замкнутое выпуклое множество, то проекция на множество S единственна для любой точки.

Проекция

Расстояние d от точки $y \in \mathbb{R}^n$ до замкнутого множества $S \subset \mathbb{R}^n$:

$$d(y, S, \|\cdot\|) = \inf\{\|x - y\| \mid x \in S\}$$

Мы сосредоточимся на евклидовой проекции (возможны и другие варианты) точки $y \in \mathbb{R}^n$ на множество $S \subseteq \mathbb{R}^n$ — это точка $\text{proj}_S(y) \in S$:

$$\text{proj}_S(y) = \underset{x \in S}{\operatorname{argmin}} \frac{1}{2} \|x - y\|_2^2$$

- **Достаточные условия существования проекции.** Если $S \subseteq \mathbb{R}^n$ — замкнутое множество, то проекция на множество S существует для любой точки.
- **Достаточные условия единственности проекции.** Если $S \subseteq \mathbb{R}^n$ — замкнутое выпуклое множество, то проекция на множество S единственна для любой точки.
- Если множество открытое, а точка лежит вне этого множества, то её проекция на него может не существовать.

Проекция

Расстояние d от точки $y \in \mathbb{R}^n$ до замкнутого множества $S \subset \mathbb{R}^n$:

$$d(y, S, \|\cdot\|) = \inf\{\|x - y\| \mid x \in S\}$$

Мы сосредоточимся на евклидовой проекции (возможны и другие варианты) точки $y \in \mathbb{R}^n$ на множество $S \subseteq \mathbb{R}^n$ — это точка $\text{proj}_S(y) \in S$:

$$\text{proj}_S(y) = \underset{x \in S}{\operatorname{argmin}} \frac{1}{2} \|x - y\|_2^2$$

- **Достаточные условия существования проекции.** Если $S \subseteq \mathbb{R}^n$ — замкнутое множество, то проекция на множество S существует для любой точки.
- **Достаточные условия единственности проекции.** Если $S \subseteq \mathbb{R}^n$ — замкнутое выпуклое множество, то проекция на множество S единственна для любой точки.
- Если множество открытое, а точка лежит вне этого множества, то её проекция на него может не существовать.
- Если точка принадлежит множеству, то её проекция — это она сама.

Критерий проекции (неравенство Бурбаки-Чейни-Гольдштейна)

i Theorem

Пусть $S \subseteq \mathbb{R}^n$ — замкнутое и выпуклое множество, $\forall x \in S, y \in \mathbb{R}^n$. Тогда

$$\langle y - \text{proj}_S(y), x - \text{proj}_S(y) \rangle \leq 0 \quad (1)$$

$$\|x - \text{proj}_S(y)\|^2 + \|y - \text{proj}_S(y)\|^2 \leq \|x - y\|^2 \quad (2)$$

1. $\text{proj}_S(y)$ - минимизатор дифференцируемой выпуклой функции $d(y, S, \|\cdot\|) = \|x - y\|^2$ на множестве S . Оптимальность:




Рис. 7: Угол должен быть тупым или прямым для любой точки $x \in S$

Критерий проекции (неравенство Бурбаки-Чейни-Гольдштейна)

i Theorem

Пусть $S \subseteq \mathbb{R}^n$ — замкнутое и выпуклое множество, $\forall x \in S, y \in \mathbb{R}^n$. Тогда

$$\langle y - \text{proj}_S(y), x - \text{proj}_S(y) \rangle \leq 0 \quad (1)$$

$$\|x - \text{proj}_S(y)\|^2 + \|y - \text{proj}_S(y)\|^2 \leq \|x - y\|^2 \quad (2)$$

1. $\text{proj}_S(y)$ - минимизатор дифференцируемой выпуклой функции $d(y, S, \|\cdot\|) = \|x - y\|^2$ на множестве S . Оптимальность:

$$\nabla d(\text{proj}_S(y))^T (x - \text{proj}_S(y)) \geq 0$$




Рис. 7: Угол должен быть тупым или прямым для любой точки $x \in S$

Критерий проекции (неравенство Бурбаки-Чейни-Гольдштейна)

i Theorem

Пусть $S \subseteq \mathbb{R}^n$ — замкнутое и выпуклое множество, $\forall x \in S, y \in \mathbb{R}^n$. Тогда

$$\langle y - \text{proj}_S(y), x - \text{proj}_S(y) \rangle \leq 0 \quad (1)$$

$$\|x - \text{proj}_S(y)\|^2 + \|y - \text{proj}_S(y)\|^2 \leq \|x - y\|^2 \quad (2)$$

1. $\text{proj}_S(y)$ - минимизатор дифференцируемой выпуклой функции $d(y, S, \|\cdot\|) = \|x - y\|^2$ на множестве S . Оптимальность:

$$\nabla d(\text{proj}_S(y))^T (x - \text{proj}_S(y)) \geq 0$$

$$2 (\text{proj}_S(y) - y)^T (x - \text{proj}_S(y)) \geq 0$$




Рис. 7: Угол должен быть тупым или прямым для любой точки $x \in S$

Критерий проекции (неравенство Бурбаки-Чейни-Гольдштейна)

i Theorem

Пусть $S \subseteq \mathbb{R}^n$ — замкнутое и выпуклое множество, $\forall x \in S, y \in \mathbb{R}^n$. Тогда

$$\langle y - \text{proj}_S(y), x - \text{proj}_S(y) \rangle \leq 0 \quad (1)$$

$$\|x - \text{proj}_S(y)\|^2 + \|y - \text{proj}_S(y)\|^2 \leq \|x - y\|^2 \quad (2)$$

1. $\text{proj}_S(y)$ - минимизатор дифференцируемой выпуклой функции $d(y, S, \|\cdot\|) = \|x - y\|^2$ на множестве S . Оптимальность:

$$\nabla d(\text{proj}_S(y))^T (x - \text{proj}_S(y)) \geq 0$$

$$2 (\text{proj}_S(y) - y)^T (x - \text{proj}_S(y)) \geq 0$$

$$(y - \text{proj}_S(y))^T (x - \text{proj}_S(y)) \leq 0$$




Рис. 7: Угол должен быть тупым или прямым для любой точки $x \in S$

Критерий проекции (неравенство Бурбаки-Чейни-Гольдштейна)

i Theorem

Пусть $S \subseteq \mathbb{R}^n$ — замкнутое и выпуклое множество, $\forall x \in S, y \in \mathbb{R}^n$. Тогда

$$\langle y - \text{proj}_S(y), x - \text{proj}_S(y) \rangle \leq 0 \quad (1)$$

$$\|x - \text{proj}_S(y)\|^2 + \|y - \text{proj}_S(y)\|^2 \leq \|x - y\|^2 \quad (2)$$

1. $\text{proj}_S(y)$ - минимизатор дифференцируемой выпуклой функции $d(y, S, \|\cdot\|) = \|x - y\|^2$ на множестве S . Оптимальность:

$$\nabla d(\text{proj}_S(y))^T (x - \text{proj}_S(y)) \geq 0$$

$$2 (\text{proj}_S(y) - y)^T (x - \text{proj}_S(y)) \geq 0$$

$$(y - \text{proj}_S(y))^T (x - \text{proj}_S(y)) \leq 0$$

2. Используем теорему косинусов $2x^T y = \|x\|^2 + \|y\|^2 - \|x - y\|^2$ с $x = x - \text{proj}_S(y)$ и $y = y - \text{proj}_S(y)$.




Рис. 7: Угол должен быть тупым или прямым для любой точки $x \in S$

Критерий проекции (неравенство Бурбаки-Чейни-Гольдштейна)

i Theorem

Пусть $S \subseteq \mathbb{R}^n$ — замкнутое и выпуклое множество, $\forall x \in S, y \in \mathbb{R}^n$. Тогда

$$\langle y - \text{proj}_S(y), x - \text{proj}_S(y) \rangle \leq 0 \quad (1)$$

$$\|x - \text{proj}_S(y)\|^2 + \|y - \text{proj}_S(y)\|^2 \leq \|x - y\|^2 \quad (2)$$

1. $\text{proj}_S(y)$ - минимизатор дифференцируемой выпуклой функции $d(y, S, \|\cdot\|) = \|x - y\|^2$ на множестве S . Оптимальность:

$$\nabla d(\text{proj}_S(y))^T (x - \text{proj}_S(y)) \geq 0$$

$$2 (\text{proj}_S(y) - y)^T (x - \text{proj}_S(y)) \geq 0$$

$$(y - \text{proj}_S(y))^T (x - \text{proj}_S(y)) \leq 0$$

2. Используем теорему косинусов $2x^T y = \|x\|^2 + \|y\|^2 - \|x - y\|^2$ с $x = x - \text{proj}_S(y)$ и $y = y - \text{proj}_S(y)$.

$$0 \geq 2x^T y = \|x - \text{proj}_S(y)\|^2 + \|y - \text{proj}_S(y)\|^2 - \|x - y\|^2$$




Рис. 7: Угол должен быть тупым или прямым для любой точки $x \in S$

Критерий проекции (неравенство Бурбаки-Чейни-Гольдштейна)

i Theorem

Пусть $S \subseteq \mathbb{R}^n$ — замкнутое и выпуклое множество, $\forall x \in S, y \in \mathbb{R}^n$. Тогда

$$\langle y - \text{proj}_S(y), x - \text{proj}_S(y) \rangle \leq 0 \quad (1)$$

$$\|x - \text{proj}_S(y)\|^2 + \|y - \text{proj}_S(y)\|^2 \leq \|x - y\|^2 \quad (2)$$

1. $\text{proj}_S(y)$ - минимизатор дифференцируемой выпуклой функции $d(y, S, \|\cdot\|) = \|x - y\|^2$ на множестве S . Оптимальность:

$$\nabla d(\text{proj}_S(y))^T (x - \text{proj}_S(y)) \geq 0$$

$$2 (\text{proj}_S(y) - y)^T (x - \text{proj}_S(y)) \geq 0$$

$$(y - \text{proj}_S(y))^T (x - \text{proj}_S(y)) \leq 0$$

2. Используем теорему косинусов $2x^T y = \|x\|^2 + \|y\|^2 - \|x - y\|^2$ с $x = x - \text{proj}_S(y)$ и $y = y - \text{proj}_S(y)$.

$$0 \geq 2x^T y = \|x - \text{proj}_S(y)\|^2 + \|y - \text{proj}_S(y)\|^2 - \|x - y\|^2$$

$$\|x - \text{proj}_S(y)\|^2 + \|y - \text{proj}_S(y)\|^2 \leq \|x - y\|^2$$




Рис. 7: Угол должен быть тупым или прямым для любой точки $x \in S$

Оператор проекции - нестягивающий

- Функция f называется нестягивающей, если она является L -липшицевой с константой $L \leq 1$ ¹. То есть для любых двух точек $x, y \in \text{dom} f$

$$\|f(x) - f(y)\| \leq L\|x - y\|, \text{ где } L \leq 1.$$

Это означает, что расстояние между образами точек не превосходит расстояния между самими точками.

¹Нестягивающая функция становится сжимающей при $L < 1$.

Оператор проекции - нестягивающий

- Функция f называется нестягивающей, если она является L -липшицевой с константой $L \leq 1$ ¹. То есть для любых двух точек $x, y \in \text{dom} f$

$$\|f(x) - f(y)\| \leq L\|x - y\|, \text{ где } L \leq 1.$$

Это означает, что расстояние между образами точек не превосходит расстояния между самими точками.

- Оператор проекции является нестягивающим:

$$\|\text{proj}(x) - \text{proj}(y)\|_2 \leq \|x - y\|_2.$$

¹Нестягивающая функция становится сжимающей при $L < 1$.

Оператор проекции - нестягивающий

- Функция f называется нестягивающей, если она является L -липшицевой с константой $L \leq 1$ ¹. То есть для любых двух точек $x, y \in \text{dom} f$

$$\|f(x) - f(y)\| \leq L\|x - y\|, \text{ где } L \leq 1.$$

Это означает, что расстояние между образами точек не превосходит расстояния между самими точками.

- Оператор проекции является нестягивающим:

$$\|\text{proj}(x) - \text{proj}(y)\|_2 \leq \|x - y\|_2.$$

- Далее покажем, что из неравенства Бурбаки-Чейни-Гольдштейна следует свойство нестягиваемости, а именно:

$$\langle y - \text{proj}(y), x - \text{proj}(y) \rangle \leq 0 \quad \forall x \in S \quad \Rightarrow \quad \|\text{proj}(x) - \text{proj}(y)\|_2 \leq \|x - y\|_2.$$

¹Нестягивающая функция становится сжимающей при $L < 1$.

Оператор проекции - нестягивающий

Сокращённая запись: пусть $\pi = \text{proj}$ и $\pi(x)$ обозначает $\text{proj}(x)$.

Оператор проекции - нестягивающий

Сокращённая запись: пусть $\pi = \text{proj}$ и $\pi(x)$ обозначает $\text{proj}(x)$.

Начнём с неравенства Бурбаки-Чейни-Гольдштейна

$$\langle y - \pi(y), x - \pi(y) \rangle \leq 0 \quad \forall x \in S. \quad (3)$$

Оператор проекции - нестягивающий

Сокращённая запись: пусть $\pi = \text{proj}$ и $\pi(x)$ обозначает $\text{proj}(x)$.

Начнём с неравенства Бурбаки-Чейни-Гольдштейна

$$\langle y - \pi(y), x - \pi(y) \rangle \leq 0 \quad \forall x \in S. \quad (3)$$

Заменяем x на $\pi(x)$ в (3)

$$\langle y - \pi(y), \pi(x) - \pi(y) \rangle \leq 0. \quad (4)$$

Оператор проекции - нестягивающий

Сокращённая запись: пусть $\pi = \text{proj}$ и $\pi(x)$ обозначает $\text{proj}(x)$.

Начнём с неравенства Бурбаки-Чейни-Гольдштейна

$$\langle y - \pi(y), x - \pi(y) \rangle \leq 0 \quad \forall x \in S. \quad (3)$$

Заменим x на $\pi(x)$ в (3)

$$\langle y - \pi(y), \pi(x) - \pi(y) \rangle \leq 0. \quad (4)$$

Заменим y на x и x на $\pi(y)$ в (3)

$$\langle x - \pi(x), \pi(y) - \pi(x) \rangle \leq 0. \quad (5)$$

Оператор проекции - нестягивающий

Сокращённая запись: пусть $\pi = \text{proj}$ и $\pi(x)$ обозначает $\text{proj}(x)$.

Начнём с неравенства Бурбаки-Чейни-Гольдштейна

$$\langle y - \pi(y), x - \pi(y) \rangle \leq 0 \quad \forall x \in S. \quad (3)$$

Заменим x на $\pi(x)$ в (3)

$$\langle y - \pi(y), \pi(x) - \pi(y) \rangle \leq 0. \quad (4)$$

Заменим y на x и x на $\pi(y)$ в (3)

$$\langle x - \pi(x), \pi(y) - \pi(x) \rangle \leq 0. \quad (5)$$

(4)+(5) сократят $\pi(y) - \pi(x)$, что нежелательно. Поэтому сменим знак в (5):

$$\langle \pi(x) - x, \pi(x) - \pi(y) \rangle \leq 0. \quad (6)$$

Оператор проекции - нерастягивающий

Сокращённая запись: пусть $\pi = \text{proj}$ и $\pi(x)$ обозначает $\text{proj}(x)$.

Начнём с неравенства Бурбаки-Чейни-Гольдштейна

$$\langle y - \pi(y), x - \pi(y) \rangle \leq 0 \quad \forall x \in S. \quad (3)$$

Заменим x на $\pi(x)$ в (3)

$$\langle y - \pi(y), \pi(x) - \pi(y) \rangle \leq 0. \quad (4)$$

Заменим y на x и x на $\pi(y)$ в (3)

$$\langle x - \pi(x), \pi(y) - \pi(x) \rangle \leq 0. \quad (5)$$

(4)+(5) сократят $\pi(y) - \pi(x)$, что нежелательно. Поэтому сменим знак в (5):

$$\langle \pi(x) - x, \pi(x) - \pi(y) \rangle \leq 0. \quad (6)$$

$$\langle y - \pi(y) + \pi(x) - x, \pi(x) - \pi(y) \rangle \leq 0$$

$$\langle y - x, \pi(x) - \pi(y) \rangle \leq -\langle \pi(x) - \pi(y), \pi(x) - \pi(y) \rangle$$

$$\langle y - x, \pi(y) - \pi(x) \rangle \geq \|\pi(x) - \pi(y)\|_2^2$$

$$\|(y - x)^\top (\pi(y) - \pi(x))\|_2 \geq \|\pi(x) - \pi(y)\|_2^2$$

Оператор проекции - нерастягивающий

Сокращённая запись: пусть $\pi = \text{proj}$ и $\pi(x)$ обозначает $\text{proj}(x)$.

Начнём с неравенства Бурбаки-Чейни-Гольдштейна

$$\langle y - \pi(y), x - \pi(y) \rangle \leq 0 \quad \forall x \in S. \quad (3)$$

Заменим x на $\pi(x)$ в (3)

$$\langle y - \pi(y), \pi(x) - \pi(y) \rangle \leq 0. \quad (4)$$

Заменим y на x и x на $\pi(y)$ в (3)

$$\langle x - \pi(x), \pi(y) - \pi(x) \rangle \leq 0. \quad (5)$$

(4)+(5) сократят $\pi(y) - \pi(x)$, что нежелательно. Поэтому сменим знак в (5):

$$\langle \pi(x) - x, \pi(x) - \pi(y) \rangle \leq 0. \quad (6)$$

$$\langle y - \pi(y) + \pi(x) - x, \pi(x) - \pi(y) \rangle \leq 0$$

$$\langle y - x, \pi(x) - \pi(y) \rangle \leq -\langle \pi(x) - \pi(y), \pi(x) - \pi(y) \rangle$$

$$\langle y - x, \pi(y) - \pi(x) \rangle \geq \|\pi(x) - \pi(y)\|_2^2$$

$$\|(y - x)^\top (\pi(y) - \pi(x))\|_2 \geq \|\pi(x) - \pi(y)\|_2^2$$

По неравенству КБШ левая часть ограничена сверху величиной

$\|y - x\|_2 \|\pi(y) - \pi(x)\|_2$, откуда следует $\|y - x\|_2 \|\pi(y) - \pi(x)\|_2 \geq \|\pi(x) - \pi(y)\|_2^2$.
Сокращая на $\|\pi(x) - \pi(y)\|_2$, завершаем доказательство.

Пример: проекция на шар

Найдём $\pi_S(y) = \pi$, если $S = \{x \in \mathbb{R}^n \mid \|x - x_0\| \leq R\}$, $y \notin S$

Пример: проекция на шар

Найдём $\pi_S(y) = \pi$, если $S = \{x \in \mathbb{R}^n \mid \|x - x_0\| \leq R\}$, $y \notin S$

Построим гипотезу по рисунку: $\pi = x_0 + R \cdot \frac{y - x_0}{\|y - x_0\|}$

Пример: проекция на шар

Найдём $\pi_S(y) = \pi$, если $S = \{x \in \mathbb{R}^n \mid \|x - x_0\| \leq R\}$, $y \notin S$

Построим гипотезу по рисунку: $\pi = x_0 + R \cdot \frac{y - x_0}{\|y - x_0\|}$

Проверим неравенство для замкнутого выпуклого множества:

$$(\pi - y)^T (x - \pi) \geq 0$$

Пример: проекция на шар

Найдём $\pi_S(y) = \pi$, если $S = \{x \in \mathbb{R}^n \mid \|x - x_0\| \leq R\}$, $y \notin S$

Построим гипотезу по рисунку: $\pi = x_0 + R \cdot \frac{y - x_0}{\|y - x_0\|}$

Проверим неравенство для замкнутого выпуклого множества:

$$(\pi - y)^T(x - \pi) \geq 0$$

$$\begin{aligned} & \left(x_0 - y + R \frac{y - x_0}{\|y - x_0\|} \right)^T \left(x - x_0 - R \frac{y - x_0}{\|y - x_0\|} \right) = \\ & \left(\frac{(y - x_0)(R - \|y - x_0\|)}{\|y - x_0\|} \right)^T \left(\frac{(x - x_0)\|y - x_0\| - R(y - x_0)}{\|y - x_0\|} \right) = \\ & \frac{R - \|y - x_0\|}{\|y - x_0\|^2} (y - x_0)^T ((x - x_0)\|y - x_0\| - R(y - x_0)) = \\ & \frac{R - \|y - x_0\|}{\|y - x_0\|} \left((y - x_0)^T (x - x_0) - R\|y - x_0\| \right) = \\ & (R - \|y - x_0\|) \left(\frac{(y - x_0)^T (x - x_0)}{\|y - x_0\|} - R \right) \end{aligned}$$

Пример: проекция на шар

Найдём $\pi_S(y) = \pi$, если $S = \{x \in \mathbb{R}^n \mid \|x - x_0\| \leq R\}$, $y \notin S$

Построим гипотезу по рисунку: $\pi = x_0 + R \cdot \frac{y - x_0}{\|y - x_0\|}$

Проверим неравенство для замкнутого выпуклого множества:
 $(\pi - y)^T(x - \pi) \geq 0$

Первый множитель отрицателен по выбору точки y . Второй множитель также отрицателен, что следует из КБШ:

$$\begin{aligned} & \left(x_0 - y + R \frac{y - x_0}{\|y - x_0\|} \right)^T \left(x - x_0 - R \frac{y - x_0}{\|y - x_0\|} \right) = \\ & \left(\frac{(y - x_0)(R - \|y - x_0\|)}{\|y - x_0\|} \right)^T \left(\frac{(x - x_0)\|y - x_0\| - R(y - x_0)}{\|y - x_0\|} \right) = \\ & \frac{R - \|y - x_0\|}{\|y - x_0\|^2} (y - x_0)^T ((x - x_0)\|y - x_0\| - R(y - x_0)) = \\ & \frac{R - \|y - x_0\|}{\|y - x_0\|} \left((y - x_0)^T (x - x_0) - R\|y - x_0\| \right) = \\ & (R - \|y - x_0\|) \left(\frac{(y - x_0)^T (x - x_0)}{\|y - x_0\|} - R \right) \end{aligned}$$

Пример: проекция на шар

Найдём $\pi_S(y) = \pi$, если $S = \{x \in \mathbb{R}^n \mid \|x - x_0\| \leq R\}$, $y \notin S$


Построим гипотезу по рисунку: $\pi = x_0 + R \cdot \frac{y - x_0}{\|y - x_0\|}$

Проверим неравенство для замкнутого выпуклого множества:
 $(\pi - y)^T(x - \pi) \geq 0$

$$\begin{aligned} \left(x_0 - y + R \frac{y - x_0}{\|y - x_0\|}\right)^T \left(x - x_0 - R \frac{y - x_0}{\|y - x_0\|}\right) &= \\ \left(\frac{(y - x_0)(R - \|y - x_0\|)}{\|y - x_0\|}\right)^T \left(\frac{(x - x_0)\|y - x_0\| - R(y - x_0)}{\|y - x_0\|}\right) &= \\ \frac{R - \|y - x_0\|}{\|y - x_0\|^2} (y - x_0)^T ((x - x_0)\|y - x_0\| - R(y - x_0)) &= \\ \frac{R - \|y - x_0\|}{\|y - x_0\|} \left((y - x_0)^T (x - x_0) - R\|y - x_0\|\right) &= \\ (R - \|y - x_0\|) \left(\frac{(y - x_0)^T (x - x_0)}{\|y - x_0\|} - R\right) \end{aligned}$$

Первый множитель отрицателен по выбору точки y . Второй множитель также отрицателен, что следует из КБШ:

$$\begin{aligned} (y - x_0)^T(x - x_0) &\leq \|y - x_0\|\|x - x_0\| \\ \frac{(y - x_0)^T(x - x_0)}{\|y - x_0\|} - R &\leq \frac{\|y - x_0\|\|x - x_0\|}{\|y - x_0\|} - R \end{aligned}$$



Пример: проекция на полупространство

Найдём $\pi_S(y) = \pi$, если $S = \{x \in \mathbb{R}^n \mid c^T x = b\}$, $y \notin S$. Построим гипотезу по рисунку: $\pi = y + \alpha c$. Коэффициент α выбирается так, чтобы $\pi \in S$: $c^T \pi = b$, тогда:

Пример: проекция на полупространство

Найдём $\pi_S(y) = \pi$, если $S = \{x \in \mathbb{R}^n \mid c^T x = b\}$, $y \notin S$. Построим гипотезу по рисунку: $\pi = y + \alpha c$. Коэффициент α выбирается так, чтобы $\pi \in S$: $c^T \pi = b$, тогда:




Рис. 9: Гиперплоскость

Пример: проекция на полупространство

Найдём $\pi_S(y) = \pi$, если $S = \{x \in \mathbb{R}^n \mid c^T x = b\}$, $y \notin S$. Построим гипотезу по рисунку: $\pi = y + \alpha c$. Коэффициент α выбирается так, чтобы $\pi \in S$: $c^T \pi = b$, тогда:




Рис. 9: Гиперплоскость

$$c^T(y + \alpha c) = b$$

$$c^T y + \alpha c^T c = b$$

$$c^T y = b - \alpha c^T c$$

Проверим неравенство для замкнутого выпуклого множества: $(\pi - y)^T(x - \pi) \geq 0$

$$(y + \alpha c - y)^T(x - y - \alpha c) =$$

$$\alpha c^T(x - y - \alpha c) =$$

$$\alpha(c^T x) - \alpha(c^T y) - \alpha^2(c^T c) =$$

$$\alpha b - \alpha(b - \alpha c^T c) - \alpha^2 c^T c =$$

$$\alpha b - \alpha b + \alpha^2 c^T c - \alpha^2 c^T c = 0 \geq 0$$

Метод проекции градиента (PGD)

$$x_{k+1} = \text{proj}_S(x_k - \alpha_k \nabla f(x_k)) \quad \Leftrightarrow \quad \begin{aligned} y_k &= x_k - \alpha_k \nabla f(x_k) \\ x_{k+1} &= \text{proj}_S(y_k) \end{aligned}$$




Рис. 10: Иллюстрация алгоритма метода проекции градиента



i Theorem

Пусть $f : \mathbb{R}^n \rightarrow \mathbb{R}$ — выпуклая функция с L -липшицевым градиентом. Тогда для любых $x, y \in \mathbb{R}^n$ выполняется следующее неравенство:

$$f(x) + \langle \nabla f(x), y - x \rangle + \frac{1}{2L} \|\nabla f(x) - \nabla f(y)\|_2^2 \leq f(y) \text{ или, эквивалентно,}$$
$$\|\nabla f(y) - \nabla f(x)\|_2^2 = \|\nabla f(x) - \nabla f(y)\|_2^2 \leq 2L (f(x) - f(y) - \langle \nabla f(y), x - y \rangle)$$

1. Для доказательства рассмотрим вспомогательную функцию $\varphi(y) = f(y) - \langle \nabla f(x), y \rangle$. Она является выпуклой (как сумма выпуклых функций). Легко проверить, что она является L -гладкой по определению, поскольку $\nabla \varphi(y) = \nabla f(y) - \nabla f(x)$ и $\|\nabla \varphi(y_1) - \nabla \varphi(y_2)\| = \|\nabla f(y_1) - \nabla f(y_2)\| \leq L\|y_1 - y_2\|$.



i Theorem

Пусть $f : \mathbb{R}^n \rightarrow \mathbb{R}$ — выпуклая функция с L -липшицевым градиентом. Тогда для любых $x, y \in \mathbb{R}^n$ выполняется следующее неравенство:

$$f(x) + \langle \nabla f(x), y - x \rangle + \frac{1}{2L} \|\nabla f(x) - \nabla f(y)\|_2^2 \leq f(y) \text{ или, эквивалентно,}$$
$$\|\nabla f(y) - \nabla f(x)\|_2^2 = \|\nabla f(x) - \nabla f(y)\|_2^2 \leq 2L (f(x) - f(y) - \langle \nabla f(y), x - y \rangle)$$

1. Для доказательства рассмотрим вспомогательную функцию $\varphi(y) = f(y) - \langle \nabla f(x), y \rangle$. Она является выпуклой (как сумма выпуклых функций). Легко проверить, что она является L -гладкой по определению, поскольку $\nabla \varphi(y) = \nabla f(y) - \nabla f(x)$ и $\|\nabla \varphi(y_1) - \nabla \varphi(y_2)\| = \|\nabla f(y_1) - \nabla f(y_2)\| \leq L\|y_1 - y_2\|$.
2. Теперь рассмотрим свойство липшицевой параболы для гладкой функции $\varphi(y)$:



i Theorem

Пусть $f : \mathbb{R}^n \rightarrow \mathbb{R}$ — выпуклая функция с L -липшицевым градиентом. Тогда для любых $x, y \in \mathbb{R}^n$ выполняется следующее неравенство:

$$f(x) + \langle \nabla f(x), y - x \rangle + \frac{1}{2L} \|\nabla f(x) - \nabla f(y)\|_2^2 \leq f(y) \text{ или, эквивалентно,}$$
$$\|\nabla f(y) - \nabla f(x)\|_2^2 = \|\nabla f(x) - \nabla f(y)\|_2^2 \leq 2L (f(x) - f(y) - \langle \nabla f(y), x - y \rangle)$$

1. Для доказательства рассмотрим вспомогательную функцию $\varphi(y) = f(y) - \langle \nabla f(x), y \rangle$. Она является выпуклой (как сумма выпуклых функций). Легко проверить, что она является L -гладкой по определению, поскольку $\nabla \varphi(y) = \nabla f(y) - \nabla f(x)$ и $\|\nabla \varphi(y_1) - \nabla \varphi(y_2)\| = \|\nabla f(y_1) - \nabla f(y_2)\| \leq L\|y_1 - y_2\|$.
2. Теперь рассмотрим свойство липшицевой параболы для гладкой функции $\varphi(y)$:

$$\varphi(y) \leq \varphi(x) + \langle \nabla \varphi(x), y - x \rangle + \frac{L}{2} \|y - x\|_2^2$$



i Theorem

Пусть $f : \mathbb{R}^n \rightarrow \mathbb{R}$ — выпуклая функция с L -липшицевым градиентом. Тогда для любых $x, y \in \mathbb{R}^n$ выполняется следующее неравенство:

$$f(x) + \langle \nabla f(x), y - x \rangle + \frac{1}{2L} \|\nabla f(x) - \nabla f(y)\|_2^2 \leq f(y) \text{ или, эквивалентно,}$$
$$\|\nabla f(y) - \nabla f(x)\|_2^2 = \|\nabla f(x) - \nabla f(y)\|_2^2 \leq 2L (f(x) - f(y) - \langle \nabla f(y), x - y \rangle)$$

1. Для доказательства рассмотрим вспомогательную функцию $\varphi(y) = f(y) - \langle \nabla f(x), y \rangle$. Она является выпуклой (как сумма выпуклых функций). Легко проверить, что она является L -гладкой по определению, поскольку $\nabla \varphi(y) = \nabla f(y) - \nabla f(x)$ и $\|\nabla \varphi(y_1) - \nabla \varphi(y_2)\| = \|\nabla f(y_1) - \nabla f(y_2)\| \leq L\|y_1 - y_2\|$.
2. Теперь рассмотрим свойство липшицевой параболы для гладкой функции $\varphi(y)$:

$$\varphi(y) \leq \varphi(x) + \langle \nabla \varphi(x), y - x \rangle + \frac{L}{2} \|y - x\|_2^2$$
$$x := y, y := y - \frac{1}{L} \nabla \varphi(y) \quad \varphi\left(y - \frac{1}{L} \nabla \varphi(y)\right) \leq \varphi(y) + \left\langle \nabla \varphi(y), -\frac{1}{L} \nabla \varphi(y) \right\rangle + \frac{1}{2L} \|\nabla \varphi(y)\|_2^2$$



i Theorem

Пусть $f : \mathbb{R}^n \rightarrow \mathbb{R}$ — выпуклая функция с L -липшицевым градиентом. Тогда для любых $x, y \in \mathbb{R}^n$ выполняется следующее неравенство:

$$f(x) + \langle \nabla f(x), y - x \rangle + \frac{1}{2L} \|\nabla f(x) - \nabla f(y)\|_2^2 \leq f(y) \text{ или, эквивалентно,}$$
$$\|\nabla f(y) - \nabla f(x)\|_2^2 = \|\nabla f(x) - \nabla f(y)\|_2^2 \leq 2L (f(x) - f(y) - \langle \nabla f(y), x - y \rangle)$$

1. Для доказательства рассмотрим вспомогательную функцию $\varphi(y) = f(y) - \langle \nabla f(x), y \rangle$. Она является выпуклой (как сумма выпуклых функций). Легко проверить, что она является L -гладкой по определению, поскольку $\nabla \varphi(y) = \nabla f(y) - \nabla f(x)$ и $\|\nabla \varphi(y_1) - \nabla \varphi(y_2)\| = \|\nabla f(y_1) - \nabla f(y_2)\| \leq L\|y_1 - y_2\|$.
2. Теперь рассмотрим свойство липшицевой параболы для гладкой функции $\varphi(y)$:

$$\varphi(y) \leq \varphi(x) + \langle \nabla \varphi(x), y - x \rangle + \frac{L}{2} \|y - x\|_2^2$$
$$x:=y, y:=y - \frac{1}{L} \nabla \varphi(y) \quad \varphi\left(y - \frac{1}{L} \nabla \varphi(y)\right) \leq \varphi(y) + \left\langle \nabla \varphi(y), -\frac{1}{L} \nabla \varphi(y) \right\rangle + \frac{1}{2L} \|\nabla \varphi(y)\|_2^2$$
$$\varphi\left(y - \frac{1}{L} \nabla \varphi(y)\right) \leq \varphi(y) - \frac{1}{2L} \|\nabla \varphi(y)\|_2^2$$

Инструменты для доказательства сходимости

3. Из условий оптимальности первого порядка для выпуклой функции $\nabla\varphi(y) = \nabla f(y) - \nabla f(x) = 0$. Можно заключить, что для любого x минимум функции $\varphi(y)$ достигается в точке $y = x$. Следовательно:

$$\varphi(x) \leq \varphi\left(y - \frac{1}{L}\nabla\varphi(y)\right) \leq \varphi(y) - \frac{1}{2L}\|\nabla\varphi(y)\|_2^2$$

Инструменты для доказательства сходимости

3. Из условий оптимальности первого порядка для выпуклой функции $\nabla\varphi(y) = \nabla f(y) - \nabla f(x) = 0$. Можно заключить, что для любого x минимум функции $\varphi(y)$ достигается в точке $y = x$. Следовательно:

$$\varphi(x) \leq \varphi\left(y - \frac{1}{L}\nabla\varphi(y)\right) \leq \varphi(y) - \frac{1}{2L}\|\nabla\varphi(y)\|_2^2$$

4. Теперь подставим $\varphi(y) = f(y) - \langle \nabla f(x), y \rangle$:

Инструменты для доказательства сходимости

3. Из условий оптимальности первого порядка для выпуклой функции $\nabla\varphi(y) = \nabla f(y) - \nabla f(x) = 0$. Можно заключить, что для любого x минимум функции $\varphi(y)$ достигается в точке $y = x$. Следовательно:

$$\varphi(x) \leq \varphi\left(y - \frac{1}{L}\nabla\varphi(y)\right) \leq \varphi(y) - \frac{1}{2L}\|\nabla\varphi(y)\|_2^2$$

4. Теперь подставим $\varphi(y) = f(y) - \langle \nabla f(x), y \rangle$:

$$f(x) - \langle \nabla f(x), x \rangle \leq f(y) - \langle \nabla f(x), y \rangle - \frac{1}{2L}\|\nabla f(y) - \nabla f(x)\|_2^2$$

Инструменты для доказательства сходимости

3. Из условий оптимальности первого порядка для выпуклой функции $\nabla\varphi(y) = \nabla f(y) - \nabla f(x) = 0$. Можно заключить, что для любого x минимум функции $\varphi(y)$ достигается в точке $y = x$. Следовательно:

$$\varphi(x) \leq \varphi\left(y - \frac{1}{L}\nabla\varphi(y)\right) \leq \varphi(y) - \frac{1}{2L}\|\nabla\varphi(y)\|_2^2$$

4. Теперь подставим $\varphi(y) = f(y) - \langle \nabla f(x), y \rangle$:

$$f(x) - \langle \nabla f(x), x \rangle \leq f(y) - \langle \nabla f(x), y \rangle - \frac{1}{2L}\|\nabla f(y) - \nabla f(x)\|_2^2$$

$$f(x) + \langle \nabla f(x), y - x \rangle + \frac{1}{2L}\|\nabla f(x) - \nabla f(y)\|_2^2 \leq f(y)$$

Инструменты для доказательства сходимости

3. Из условий оптимальности первого порядка для выпуклой функции $\nabla\varphi(y) = \nabla f(y) - \nabla f(x) = 0$. Можно заключить, что для любого x минимум функции $\varphi(y)$ достигается в точке $y = x$. Следовательно:

$$\varphi(x) \leq \varphi\left(y - \frac{1}{L}\nabla\varphi(y)\right) \leq \varphi(y) - \frac{1}{2L}\|\nabla\varphi(y)\|_2^2$$

4. Теперь подставим $\varphi(y) = f(y) - \langle \nabla f(x), y \rangle$:

$$f(x) - \langle \nabla f(x), x \rangle \leq f(y) - \langle \nabla f(x), y \rangle - \frac{1}{2L}\|\nabla f(y) - \nabla f(x)\|_2^2$$

$$f(x) + \langle \nabla f(x), y - x \rangle + \frac{1}{2L}\|\nabla f(x) - \nabla f(y)\|_2^2 \leq f(y)$$

$$\|\nabla f(y) - \nabla f(x)\|_2^2 \leq 2L(f(y) - f(x) - \langle \nabla f(x), y - x \rangle)$$

Инструменты для доказательства сходимости

3. Из условий оптимальности первого порядка для выпуклой функции $\nabla\varphi(y) = \nabla f(y) - \nabla f(x) = 0$. Можно заключить, что для любого x минимум функции $\varphi(y)$ достигается в точке $y = x$. Следовательно:

$$\varphi(x) \leq \varphi\left(y - \frac{1}{L}\nabla\varphi(y)\right) \leq \varphi(y) - \frac{1}{2L}\|\nabla\varphi(y)\|_2^2$$

4. Теперь подставим $\varphi(y) = f(y) - \langle \nabla f(x), y \rangle$:

$$f(x) - \langle \nabla f(x), x \rangle \leq f(y) - \langle \nabla f(x), y \rangle - \frac{1}{2L}\|\nabla f(y) - \nabla f(x)\|_2^2$$

$$f(x) + \langle \nabla f(x), y - x \rangle + \frac{1}{2L}\|\nabla f(x) - \nabla f(y)\|_2^2 \leq f(y)$$

$$\|\nabla f(y) - \nabla f(x)\|_2^2 \leq 2L(f(y) - f(x) - \langle \nabla f(x), y - x \rangle)$$

меняем x и y

$$\|\nabla f(x) - \nabla f(y)\|_2^2 \leq 2L(f(x) - f(y) - \langle \nabla f(y), x - y \rangle)$$

Инструменты для доказательства сходимости

3. Из условий оптимальности первого порядка для выпуклой функции $\nabla\varphi(y) = \nabla f(y) - \nabla f(x) = 0$. Можно заключить, что для любого x минимум функции $\varphi(y)$ достигается в точке $y = x$. Следовательно:

$$\varphi(x) \leq \varphi\left(y - \frac{1}{L}\nabla\varphi(y)\right) \leq \varphi(y) - \frac{1}{2L}\|\nabla\varphi(y)\|_2^2$$

4. Теперь подставим $\varphi(y) = f(y) - \langle\nabla f(x), y\rangle$:

$$f(x) - \langle\nabla f(x), x\rangle \leq f(y) - \langle\nabla f(x), y\rangle - \frac{1}{2L}\|\nabla f(y) - \nabla f(x)\|_2^2$$

$$f(x) + \langle\nabla f(x), y - x\rangle + \frac{1}{2L}\|\nabla f(x) - \nabla f(y)\|_2^2 \leq f(y)$$

$$\|\nabla f(y) - \nabla f(x)\|_2^2 \leq 2L(f(y) - f(x) - \langle\nabla f(x), y - x\rangle)$$

меняем x и y

$$\|\nabla f(x) - \nabla f(y)\|_2^2 \leq 2L(f(x) - f(y) - \langle\nabla f(y), x - y\rangle)$$

Инструменты для доказательства сходимости

3. Из условий оптимальности первого порядка для выпуклой функции $\nabla\varphi(y) = \nabla f(y) - \nabla f(x) = 0$. Можно заключить, что для любого x минимум функции $\varphi(y)$ достигается в точке $y = x$. Следовательно:

$$\varphi(x) \leq \varphi\left(y - \frac{1}{L}\nabla\varphi(y)\right) \leq \varphi(y) - \frac{1}{2L}\|\nabla\varphi(y)\|_2^2$$

4. Теперь подставим $\varphi(y) = f(y) - \langle \nabla f(x), y \rangle$:

$$f(x) - \langle \nabla f(x), x \rangle \leq f(y) - \langle \nabla f(x), y \rangle - \frac{1}{2L}\|\nabla f(y) - \nabla f(x)\|_2^2$$

$$f(x) + \langle \nabla f(x), y - x \rangle + \frac{1}{2L}\|\nabla f(x) - \nabla f(y)\|_2^2 \leq f(y)$$

$$\|\nabla f(y) - \nabla f(x)\|_2^2 \leq 2L(f(y) - f(x) - \langle \nabla f(x), y - x \rangle)$$

меняем x и y

$$\|\nabla f(x) - \nabla f(y)\|_2^2 \leq 2L(f(x) - f(y) - \langle \nabla f(y), x - y \rangle)$$

Лемма доказана. На первый взгляд она не имеет очевидной геометрической интерпретации, но мы будем использовать её как удобный инструмент для оценки разности градиентов.



i Theorem

Пусть $f : \mathbb{R}^n \rightarrow \mathbb{R}$ — непрерывно дифференцируемая функция на $\mathbb{R}^n$. Тогда функция f является μ -сильно выпуклой тогда и только тогда, когда для любых $x, y \in \mathbb{R}^d$ выполняется:

$$\text{Сильно выпуклый случай } \mu > 0 \quad \langle \nabla f(x) - \nabla f(y), x - y \rangle \geq \mu \|x - y\|^2$$

$$\text{Выпуклый случай } \mu = 0 \quad \langle \nabla f(x) - \nabla f(y), x - y \rangle \geq 0$$

Доказательство

1. Приведём доказательство только для сильно выпуклого случая; выпуклый следует из него при $\mu = 0$. Начнём с необходимости. Для сильно выпуклой функции

$$f(y) \geq f(x) + \langle \nabla f(x), y - x \rangle + \frac{\mu}{2} \|x - y\|_2^2$$

$$f(x) \geq f(y) + \langle \nabla f(y), x - y \rangle + \frac{\mu}{2} \|x - y\|_2^2$$

$$\text{сумма} \quad \langle \nabla f(x) - \nabla f(y), x - y \rangle \geq \mu \|x - y\|^2$$

Инструменты для доказательства сходимости

2. Для достаточности предположим, что $\langle \nabla f(x) - \nabla f(y), x - y \rangle \geq \mu \|x - y\|^2$. Используя формулу Ньютона-Лейбница $f(x) = f(y) + \int_0^1 \langle \nabla f(y + t(x - y)), x - y \rangle dt$:

Инструменты для доказательства сходимости

2. Для достаточности предположим, что $\langle \nabla f(x) - \nabla f(y), x - y \rangle \geq \mu \|x - y\|^2$. Используя формулу Ньютона-Лейбница $f(x) = f(y) + \int_0^1 \langle \nabla f(y + t(x - y)), x - y \rangle dt$:

$$f(x) - f(y) - \langle \nabla f(y), x - y \rangle = \int_0^1 \langle \nabla f(y + t(x - y)), x - y \rangle dt - \langle \nabla f(y), x - y \rangle$$

Инструменты для доказательства сходимости

2. Для достаточности предположим, что $\langle \nabla f(x) - \nabla f(y), x - y \rangle \geq \mu \|x - y\|^2$. Используя формулу Ньютона-Лейбница $f(x) = f(y) + \int_0^1 \langle \nabla f(y + t(x - y)), x - y \rangle dt$:

$$f(x) - f(y) - \langle \nabla f(y), x - y \rangle = \int_0^1 \langle \nabla f(y + t(x - y)), x - y \rangle dt - \langle \nabla f(y), x - y \rangle$$

$$\langle \nabla f(y), x - y \rangle = \int_0^1 \langle \nabla f(y), x - y \rangle dt \quad = \int_0^1 \langle \nabla f(y + t(x - y)) - \nabla f(y), (x - y) \rangle dt$$

Инструменты для доказательства сходимости

2. Для достаточности предположим, что $\langle \nabla f(x) - \nabla f(y), x - y \rangle \geq \mu \|x - y\|^2$. Используя формулу Ньютона-Лейбница $f(x) = f(y) + \int_0^1 \langle \nabla f(y + t(x - y)), x - y \rangle dt$:

$$\begin{aligned} f(x) - f(y) - \langle \nabla f(y), x - y \rangle &= \int_0^1 \langle \nabla f(y + t(x - y)), x - y \rangle dt - \langle \nabla f(y), x - y \rangle \\ \langle \nabla f(y), x - y \rangle &= \int_0^1 \langle \nabla f(y), x - y \rangle dt \\ y + t(x - y) - y &= t(x - y) \end{aligned}$$
$$\begin{aligned} &= \int_0^1 \langle \nabla f(y + t(x - y)) - \nabla f(y), (x - y) \rangle dt \\ &= \int_0^1 t^{-1} \langle \nabla f(y + t(x - y)) - \nabla f(y), t(x - y) \rangle dt \end{aligned}$$

Инструменты для доказательства сходимости

2. Для достаточности предположим, что $\langle \nabla f(x) - \nabla f(y), x - y \rangle \geq \mu \|x - y\|^2$. Используя формулу Ньютона-Лейбница $f(x) = f(y) + \int_0^1 \langle \nabla f(y + t(x - y)), x - y \rangle dt$:

$$\begin{aligned} f(x) - f(y) - \langle \nabla f(y), x - y \rangle &= \int_0^1 \langle \nabla f(y + t(x - y)), x - y \rangle dt - \langle \nabla f(y), x - y \rangle \\ \langle \nabla f(y), x - y \rangle &= \int_0^1 \langle \nabla f(y), x - y \rangle dt \\ y + t(x - y) - y &= t(x - y) \\ &= \int_0^1 \langle \nabla f(y + t(x - y)) - \nabla f(y), t(x - y) \rangle dt \\ &\geq \int_0^1 t^{-1} \mu \|t(x - y)\|^2 dt \end{aligned}$$

Инструменты для доказательства сходимости

2. Для достаточности предположим, что $\langle \nabla f(x) - \nabla f(y), x - y \rangle \geq \mu \|x - y\|^2$. Используя формулу Ньютона-Лейбница $f(x) = f(y) + \int_0^1 \langle \nabla f(y + t(x - y)), x - y \rangle dt$:

$$\begin{aligned} f(x) - f(y) - \langle \nabla f(y), x - y \rangle &= \int_0^1 \langle \nabla f(y + t(x - y)), x - y \rangle dt - \langle \nabla f(y), x - y \rangle \\ \langle \nabla f(y), x - y \rangle &= \int_0^1 \langle \nabla f(y), x - y \rangle dt \\ y + t(x - y) - y &= t(x - y) \\ &= \int_0^1 \langle \nabla f(y + t(x - y)) - \nabla f(y), t(x - y) \rangle dt \\ &\geq \int_0^1 t^{-1} \mu \|t(x - y)\|^2 dt = \mu \|x - y\|^2 \int_0^1 t dt \end{aligned}$$

Инструменты для доказательства сходимости

2. Для достаточности предположим, что $\langle \nabla f(x) - \nabla f(y), x - y \rangle \geq \mu \|x - y\|^2$. Используя формулу Ньютона-Лейбница $f(x) = f(y) + \int_0^1 \langle \nabla f(y + t(x - y)), x - y \rangle dt$:

$$\begin{aligned} f(x) - f(y) - \langle \nabla f(y), x - y \rangle &= \int_0^1 \langle \nabla f(y + t(x - y)), x - y \rangle dt - \langle \nabla f(y), x - y \rangle \\ \langle \nabla f(y), x - y \rangle &= \int_0^1 \langle \nabla f(y), x - y \rangle dt \\ y + t(x - y) - y &= t(x - y) \\ &= \int_0^1 \langle \nabla f(y + t(x - y)) - \nabla f(y), t(x - y) \rangle dt \\ &\geq \int_0^1 t^{-1} \mu \|t(x - y)\|^2 dt = \mu \|x - y\|^2 \int_0^1 t dt = \frac{\mu}{2} \|x - y\|_2^2 \end{aligned}$$

Инструменты для доказательства сходимости

2. Для достаточности предположим, что $\langle \nabla f(x) - \nabla f(y), x - y \rangle \geq \mu \|x - y\|^2$. Используя формулу Ньютона-Лейбница $f(x) = f(y) + \int_0^1 \langle \nabla f(y + t(x - y)), x - y \rangle dt$:

$$\begin{aligned} f(x) - f(y) - \langle \nabla f(y), x - y \rangle &= \int_0^1 \langle \nabla f(y + t(x - y)), x - y \rangle dt - \langle \nabla f(y), x - y \rangle \\ \langle \nabla f(y), x - y \rangle &= \int_0^1 \langle \nabla f(y), x - y \rangle dt \\ y + t(x - y) - y &= t(x - y) \\ &= \int_0^1 \langle \nabla f(y + t(x - y)) - \nabla f(y), t(x - y) \rangle dt \\ &\geq \int_0^1 t^{-1} \mu \|t(x - y)\|^2 dt = \mu \|x - y\|^2 \int_0^1 t dt = \frac{\mu}{2} \|x - y\|_2^2 \end{aligned}$$

Инструменты для доказательства сходимости

2. Для достаточности предположим, что $\langle \nabla f(x) - \nabla f(y), x - y \rangle \geq \mu \|x - y\|^2$. Используя формулу Ньютона-Лейбница $f(x) = f(y) + \int_0^1 \langle \nabla f(y + t(x - y)), x - y \rangle dt$:

$$\begin{aligned} f(x) - f(y) - \langle \nabla f(y), x - y \rangle &= \int_0^1 \langle \nabla f(y + t(x - y)), x - y \rangle dt - \langle \nabla f(y), x - y \rangle \\ \langle \nabla f(y), x - y \rangle &= \int_0^1 \langle \nabla f(y), x - y \rangle dt \\ y + t(x - y) - y &= t(x - y) \\ &= \int_0^1 \langle \nabla f(y + t(x - y)) - \nabla f(y), t(x - y) \rangle dt \\ &\geq \int_0^1 t^{-1} \mu \|t(x - y)\|^2 dt = \mu \|x - y\|^2 \int_0^1 t dt = \frac{\mu}{2} \|x - y\|_2^2 \end{aligned}$$

Таким образом, критерий сильной выпуклости выполнен

$$f(x) \geq f(y) + \langle \nabla f(y), x - y \rangle + \frac{\mu}{2} \|x - y\|_2^2$$

Инструменты для доказательства сходимости

2. Для достаточности предположим, что $\langle \nabla f(x) - \nabla f(y), x - y \rangle \geq \mu \|x - y\|^2$. Используя формулу Ньютона-Лейбница $f(x) = f(y) + \int_0^1 \langle \nabla f(y + t(x - y)), x - y \rangle dt$:

$$\begin{aligned} f(x) - f(y) - \langle \nabla f(y), x - y \rangle &= \int_0^1 \langle \nabla f(y + t(x - y)), x - y \rangle dt - \langle \nabla f(y), x - y \rangle \\ \langle \nabla f(y), x - y \rangle &= \int_0^1 \langle \nabla f(y), x - y \rangle dt \\ y + t(x - y) - y &= t(x - y) \\ &= \int_0^1 \langle \nabla f(y + t(x - y)) - \nabla f(y), t(x - y) \rangle dt \\ &\geq \int_0^1 t^{-1} \mu \|t(x - y)\|^2 dt = \mu \|x - y\|^2 \int_0^1 t dt = \frac{\mu}{2} \|x - y\|_2^2 \end{aligned}$$

Таким образом, критерий сильной выпуклости выполнен

$$f(x) \geq f(y) + \langle \nabla f(y), x - y \rangle + \frac{\mu}{2} \|x - y\|_2^2 \text{ или, эквивалентно:}$$

Инструменты для доказательства сходимости

2. Для достаточности предположим, что $\langle \nabla f(x) - \nabla f(y), x - y \rangle \geq \mu \|x - y\|^2$. Используя формулу Ньютона-Лейбница $f(x) = f(y) + \int_0^1 \langle \nabla f(y + t(x - y)), x - y \rangle dt$:

$$\begin{aligned} f(x) - f(y) - \langle \nabla f(y), x - y \rangle &= \int_0^1 \langle \nabla f(y + t(x - y)), x - y \rangle dt - \langle \nabla f(y), x - y \rangle \\ \langle \nabla f(y), x - y \rangle &= \int_0^1 \langle \nabla f(y), x - y \rangle dt \\ y + t(x - y) - y &= t(x - y) \\ &= \int_0^1 \langle \nabla f(y + t(x - y)) - \nabla f(y), t(x - y) \rangle dt \\ &\geq \int_0^1 t^{-1} \mu \|t(x - y)\|^2 dt = \mu \|x - y\|^2 \int_0^1 t dt = \frac{\mu}{2} \|x - y\|_2^2 \end{aligned}$$

Таким образом, критерий сильной выпуклости выполнен

$$f(x) \geq f(y) + \langle \nabla f(y), x - y \rangle + \frac{\mu}{2} \|x - y\|_2^2 \text{ или, эквивалентно:}$$

$$\text{меняем } x \text{ и } y \quad - \langle \nabla f(x), x - y \rangle \leq - \left(f(x) - f(y) + \frac{\mu}{2} \|x - y\|_2^2 \right)$$

Скорость сходимости для гладкого выпуклого случая

Theorem

Пусть $f : \mathbb{R}^n \rightarrow \mathbb{R}$ — выпуклая и дифференцируемая функция. Пусть $S \subseteq \mathbb{R}^n$ — замкнутое выпуклое множество, и существует минимизатор x^* функции f на S ; кроме того, предположим, что f является гладкой на S с параметром L . Алгоритм метода проекции градиента с шагом $\frac{1}{L}$ обеспечивает следующую сходимость после $k > 0$ итераций:

$$f(x_k) - f^* \leq \frac{L\|x_0 - x^*\|_2^2}{2k}$$

Скорость сходимости для гладкого выпуклого случая

Theorem

Пусть $f : \mathbb{R}^n \rightarrow \mathbb{R}$ — выпуклая и дифференцируемая функция. Пусть $S \subseteq \mathbb{R}^n$ — замкнутое выпуклое множество, и существует минимизатор x^* функции f на S ; кроме того, предположим, что f является гладкой на S с параметром L . Алгоритм метода проекции градиента с шагом $\frac{1}{L}$ обеспечивает следующую сходимость после $k > 0$ итераций:

$$f(x_k) - f^* \leq \frac{L\|x_0 - x^*\|_2^2}{2k}$$

1. Докажем лемму о достаточном убывании, полагая $y_k = x_k - \frac{1}{L}\nabla f(x_k)$ и используя теорему косинусов $2x^T y = \|x\|^2 + \|y\|^2 - \|x - y\|^2$:

Скорость сходимости для гладкого выпуклого случая

Theorem

Пусть $f : \mathbb{R}^n \rightarrow \mathbb{R}$ — выпуклая и дифференцируемая функция. Пусть $S \subseteq \mathbb{R}^n$ — замкнутое выпуклое множество, и существует минимизатор x^* функции f на S ; кроме того, предположим, что f является гладкой на S с параметром L . Алгоритм метода проекции градиента с шагом $\frac{1}{L}$ обеспечивает следующую сходимость после $k > 0$ итераций:

$$f(x_k) - f^* \leq \frac{L\|x_0 - x^*\|_2^2}{2k}$$

1. Докажем лемму о достаточном убывании, полагая $y_k = x_k - \frac{1}{L}\nabla f(x_k)$ и используя теорему косинусов $2x^T y = \|x\|^2 + \|y\|^2 - \|x - y\|^2$:

Гладкость:
$$f(x_{k+1}) \leq f(x_k) + \langle \nabla f(x_k), x_{k+1} - x_k \rangle + \frac{L}{2}\|x_{k+1} - x_k\|^2$$

Скорость сходимости для гладкого выпуклого случая

Theorem

Пусть $f : \mathbb{R}^n \rightarrow \mathbb{R}$ — выпуклая и дифференцируемая функция. Пусть $S \subseteq \mathbb{R}^n$ — замкнутое выпуклое множество, и существует минимизатор x^* функции f на S ; кроме того, предположим, что f является гладкой на S с параметром L . Алгоритм метода проекции градиента с шагом $\frac{1}{L}$ обеспечивает следующую сходимость после $k > 0$ итераций:

$$f(x_k) - f^* \leq \frac{L\|x_0 - x^*\|_2^2}{2k}$$

1. Докажем лемму о достаточном убывании, полагая $y_k = x_k - \frac{1}{L}\nabla f(x_k)$ и используя теорему косинусов $2x^T y = \|x\|^2 + \|y\|^2 - \|x - y\|^2$:

Гладкость:
$$f(x_{k+1}) \leq f(x_k) + \langle \nabla f(x_k), x_{k+1} - x_k \rangle + \frac{L}{2}\|x_{k+1} - x_k\|^2$$

Метод:
$$= f(x_k) - L\langle y_k - x_k, x_{k+1} - x_k \rangle + \frac{L}{2}\|x_{k+1} - x_k\|^2$$

Скорость сходимости для гладкого выпуклого случая

Theorem

Пусть $f : \mathbb{R}^n \rightarrow \mathbb{R}$ — выпуклая и дифференцируемая функция. Пусть $S \subseteq \mathbb{R}^n$ — замкнутое выпуклое множество, и существует минимизатор x^* функции f на S ; кроме того, предположим, что f является гладкой на S с параметром L . Алгоритм метода проекции градиента с шагом $\frac{1}{L}$ обеспечивает следующую сходимость после $k > 0$ итераций:

$$f(x_k) - f^* \leq \frac{L\|x_0 - x^*\|_2^2}{2k}$$

1. Докажем лемму о достаточном убывании, полагая $y_k = x_k - \frac{1}{L}\nabla f(x_k)$ и используя теорему косинусов $2x^T y = \|x\|^2 + \|y\|^2 - \|x - y\|^2$:

Гладкость:
$$f(x_{k+1}) \leq f(x_k) + \langle \nabla f(x_k), x_{k+1} - x_k \rangle + \frac{L}{2}\|x_{k+1} - x_k\|^2$$

Метод:
$$= f(x_k) - L\langle y_k - x_k, x_{k+1} - x_k \rangle + \frac{L}{2}\|x_{k+1} - x_k\|^2$$

Теорема косинусов:
$$= f(x_k) - \frac{L}{2}(\|y_k - x_k\|^2 + \|x_{k+1} - x_k\|^2 - \|y_k - x_{k+1}\|^2) + \frac{L}{2}\|x_{k+1} - x_k\|^2$$

Скорость сходимости для гладкого выпуклого случая

Theorem

Пусть $f : \mathbb{R}^n \rightarrow \mathbb{R}$ — выпуклая и дифференцируемая функция. Пусть $S \subseteq \mathbb{R}^n$ — замкнутое выпуклое множество, и существует минимизатор x^* функции f на S ; кроме того, предположим, что f является гладкой на S с параметром L . Алгоритм метода проекции градиента с шагом $\frac{1}{L}$ обеспечивает следующую сходимость после $k > 0$ итераций:

$$f(x_k) - f^* \leq \frac{L\|x_0 - x^*\|_2^2}{2k}$$

1. Докажем лемму о достаточном убывании, полагая $y_k = x_k - \frac{1}{L}\nabla f(x_k)$ и используя теорему косинусов $2x^T y = \|x\|^2 + \|y\|^2 - \|x - y\|^2$:

Гладкость:
$$f(x_{k+1}) \leq f(x_k) + \langle \nabla f(x_k), x_{k+1} - x_k \rangle + \frac{L}{2}\|x_{k+1} - x_k\|^2$$

Метод:
$$= f(x_k) - L\langle y_k - x_k, x_{k+1} - x_k \rangle + \frac{L}{2}\|x_{k+1} - x_k\|^2$$

Теорема косинусов:
$$\begin{aligned} &= f(x_k) - \frac{L}{2}(\|y_k - x_k\|^2 + \|x_{k+1} - x_k\|^2 - \|y_k - x_{k+1}\|^2) + \frac{L}{2}\|x_{k+1} - x_k\|^2 \\ &= f(x_k) - \frac{1}{2L}\|\nabla f(x_k)\|^2 + \frac{L}{2}\|y_k - x_{k+1}\|^2 \end{aligned}$$

Скорость сходимости для гладкого выпуклого случая

2. Пока что мы не получаем немедленного прогресса на каждом шаге. Снова используем теорему косинусов:

$$\left\langle \frac{1}{L} \nabla f(x_k), x_k - x^* \right\rangle = \frac{1}{2} \left(\frac{1}{L^2} \|\nabla f(x_k)\|^2 + \|x_k - x^*\|^2 - \|x_k - x^* - \frac{1}{L} \nabla f(x_k)\|^2 \right)$$
$$\langle \nabla f(x_k), x_k - x^* \rangle = \frac{L}{2} \left(\frac{1}{L^2} \|\nabla f(x_k)\|^2 + \|x_k - x^*\|^2 - \|y_k - x^*\|^2 \right)$$

Скорость сходимости для гладкого выпуклого случая

2. Пока что мы не получаем немедленного прогресса на каждом шаге. Снова используем теорему косинусов:

$$\begin{aligned}\left\langle \frac{1}{L} \nabla f(x_k), x_k - x^* \right\rangle &= \frac{1}{2} \left(\frac{1}{L^2} \|\nabla f(x_k)\|^2 + \|x_k - x^*\|^2 - \|x_k - x^* - \frac{1}{L} \nabla f(x_k)\|^2 \right) \\ \langle \nabla f(x_k), x_k - x^* \rangle &= \frac{L}{2} \left(\frac{1}{L^2} \|\nabla f(x_k)\|^2 + \|x_k - x^*\|^2 - \|y_k - x^*\|^2 \right)\end{aligned}$$

3. Теперь используем свойство проекции: $\|x - \text{proj}_S(y)\|^2 + \|y - \text{proj}_S(y)\|^2 \leq \|x - y\|^2$ с $x = x^*, y = y_k$:

$$\begin{aligned}\|x^* - \text{proj}_S(y_k)\|^2 + \|y_k - \text{proj}_S(y_k)\|^2 &\leq \|x^* - y_k\|^2 \\ \|y_k - x^*\|^2 &\geq \|x^* - x_{k+1}\|^2 + \|y_k - x_{k+1}\|^2\end{aligned}$$

Скорость сходимости для гладкого выпуклого случая

2. Пока что мы не получаем немедленного прогресса на каждом шаге. Снова используем теорему косинусов:

$$\begin{aligned}\left\langle \frac{1}{L} \nabla f(x_k), x_k - x^* \right\rangle &= \frac{1}{2} \left(\frac{1}{L^2} \|\nabla f(x_k)\|^2 + \|x_k - x^*\|^2 - \|x_k - x^* - \frac{1}{L} \nabla f(x_k)\|^2 \right) \\ \langle \nabla f(x_k), x_k - x^* \rangle &= \frac{L}{2} \left(\frac{1}{L^2} \|\nabla f(x_k)\|^2 + \|x_k - x^*\|^2 - \|y_k - x^*\|^2 \right)\end{aligned}$$

3. Теперь используем свойство проекции: $\|x - \text{proj}_S(y)\|^2 + \|y - \text{proj}_S(y)\|^2 \leq \|x - y\|^2$ с $x = x^*, y = y_k$:

$$\begin{aligned}\|x^* - \text{proj}_S(y_k)\|^2 + \|y_k - \text{proj}_S(y_k)\|^2 &\leq \|x^* - y_k\|^2 \\ \|y_k - x^*\|^2 &\geq \|x^* - x_{k+1}\|^2 + \|y_k - x_{k+1}\|^2\end{aligned}$$

4. Теперь, используя выпуклость и предыдущую часть:

Скорость сходимости для гладкого выпуклого случая

2. Пока что мы не получаем немедленного прогресса на каждом шаге. Снова используем теорему косинусов:

$$\begin{aligned}\left\langle \frac{1}{L} \nabla f(x_k), x_k - x^* \right\rangle &= \frac{1}{2} \left(\frac{1}{L^2} \|\nabla f(x_k)\|^2 + \|x_k - x^*\|^2 - \|x_k - x^* - \frac{1}{L} \nabla f(x_k)\|^2 \right) \\ \langle \nabla f(x_k), x_k - x^* \rangle &= \frac{L}{2} \left(\frac{1}{L^2} \|\nabla f(x_k)\|^2 + \|x_k - x^*\|^2 - \|y_k - x^*\|^2 \right)\end{aligned}$$

3. Теперь используем свойство проекции: $\|x - \text{proj}_S(y)\|^2 + \|y - \text{proj}_S(y)\|^2 \leq \|x - y\|^2$ с $x = x^*, y = y_k$:

$$\begin{aligned}\|x^* - \text{proj}_S(y_k)\|^2 + \|y_k - \text{proj}_S(y_k)\|^2 &\leq \|x^* - y_k\|^2 \\ \|y_k - x^*\|^2 &\geq \|x^* - x_{k+1}\|^2 + \|y_k - x_{k+1}\|^2\end{aligned}$$

4. Теперь, используя выпуклость и предыдущую часть:

Выпуклость:
$$f(x_k) - f^* \leq \langle \nabla f(x_k), x_k - x^* \rangle$$

Скорость сходимости для гладкого выпуклого случая

2. Пока что мы не получаем немедленного прогресса на каждом шаге. Снова используем теорему косинусов:

$$\begin{aligned}\left\langle \frac{1}{L} \nabla f(x_k), x_k - x^* \right\rangle &= \frac{1}{2} \left(\frac{1}{L^2} \|\nabla f(x_k)\|^2 + \|x_k - x^*\|^2 - \|x_k - x^* - \frac{1}{L} \nabla f(x_k)\|^2 \right) \\ \langle \nabla f(x_k), x_k - x^* \rangle &= \frac{L}{2} \left(\frac{1}{L^2} \|\nabla f(x_k)\|^2 + \|x_k - x^*\|^2 - \|y_k - x^*\|^2 \right)\end{aligned}$$

3. Теперь используем свойство проекции: $\|x - \text{proj}_S(y)\|^2 + \|y - \text{proj}_S(y)\|^2 \leq \|x - y\|^2$ с $x = x^*, y = y_k$:

$$\begin{aligned}\|x^* - \text{proj}_S(y_k)\|^2 + \|y_k - \text{proj}_S(y_k)\|^2 &\leq \|x^* - y_k\|^2 \\ \|y_k - x^*\|^2 &\geq \|x^* - x_{k+1}\|^2 + \|y_k - x_{k+1}\|^2\end{aligned}$$

4. Теперь, используя выпуклость и предыдущую часть:

Выпуклость:

$$\begin{aligned}f(x_k) - f^* &\leq \langle \nabla f(x_k), x_k - x^* \rangle \\ &\leq \frac{L}{2} \left(\frac{1}{L^2} \|\nabla f(x_k)\|^2 + \|x_k - x^*\|^2 - \|x_{k+1} - x^*\|^2 - \|y_k - x_{k+1}\|^2 \right)\end{aligned}$$

Скорость сходимости для гладкого выпуклого случая

2. Пока что мы не получаем немедленного прогресса на каждом шаге. Снова используем теорему косинусов:

$$\begin{aligned}\left\langle \frac{1}{L} \nabla f(x_k), x_k - x^* \right\rangle &= \frac{1}{2} \left(\frac{1}{L^2} \|\nabla f(x_k)\|^2 + \|x_k - x^*\|^2 - \|x_k - x^* - \frac{1}{L} \nabla f(x_k)\|^2 \right) \\ \langle \nabla f(x_k), x_k - x^* \rangle &= \frac{L}{2} \left(\frac{1}{L^2} \|\nabla f(x_k)\|^2 + \|x_k - x^*\|^2 - \|y_k - x^*\|^2 \right)\end{aligned}$$

3. Теперь используем свойство проекции: $\|x - \text{proj}_S(y)\|^2 + \|y - \text{proj}_S(y)\|^2 \leq \|x - y\|^2$ с $x = x^*, y = y_k$:

$$\begin{aligned}\|x^* - \text{proj}_S(y_k)\|^2 + \|y_k - \text{proj}_S(y_k)\|^2 &\leq \|x^* - y_k\|^2 \\ \|y_k - x^*\|^2 &\geq \|x^* - x_{k+1}\|^2 + \|y_k - x_{k+1}\|^2\end{aligned}$$

4. Теперь, используя выпуклость и предыдущую часть:

Выпуклость:

$$\begin{aligned}f(x_k) - f^* &\leq \langle \nabla f(x_k), x_k - x^* \rangle \\ &\leq \frac{L}{2} \left(\frac{1}{L^2} \|\nabla f(x_k)\|^2 + \|x_k - x^*\|^2 - \|x_{k+1} - x^*\|^2 - \|y_k - x_{k+1}\|^2 \right)\end{aligned}$$

$$\text{Сумма для } i = 0, k-1 \quad \sum_{i=0}^{k-1} [f(x_i) - f^*] \leq \sum_{i=0}^{k-1} \frac{1}{2L} \|\nabla f(x_i)\|^2 + \frac{L}{2} \|x_0 - x^*\|^2 - \frac{L}{2} \sum_{i=0}^{i-1} \|y_i - x_{i+1}\|^2$$

Скорость сходимости для гладкого выпуклого случая

- Оценим градиенты с помощью неравенства достаточного убывания 7:

Скорость сходимости для гладкого выпуклого случая

5. Оценим градиенты с помощью неравенства достаточного убывания 7:

$$\sum_{i=0}^{k-1} [f(x_i) - f^*] \leq \sum_{i=0}^{k-1} \left[f(x_i) - f(x_{i+1}) + \frac{L}{2} \|y_i - x_{i+1}\|^2 \right] + \frac{L}{2} \|x_0 - x^*\|^2 - \frac{L}{2} \sum_{i=0}^{i-1} \|y_i - x_{i+1}\|^2$$

Скорость сходимости для гладкого выпуклого случая

5. Оценим градиенты с помощью неравенства достаточного убывания 7:

$$\begin{aligned}\sum_{i=0}^{k-1} [f(x_i) - f^*] &\leq \sum_{i=0}^{k-1} \left[f(x_i) - f(x_{i+1}) + \frac{L}{2} \|y_i - x_{i+1}\|^2 \right] + \frac{L}{2} \|x_0 - x^*\|^2 - \frac{L}{2} \sum_{i=0}^{i-1} \|y_i - x_{i+1}\|^2 \\ &\leq f(x_0) - f(x_k) + \frac{L}{2} \sum_{i=0}^{i-1} \|y_i - x_{i+1}\|^2 + \frac{L}{2} \|x_0 - x^*\|^2 - \frac{L}{2} \sum_{i=0}^{i-1} \|y_i - x_{i+1}\|^2\end{aligned}$$

Скорость сходимости для гладкого выпуклого случая

5. Оценим градиенты с помощью неравенства достаточного убывания 7:

$$\begin{aligned}\sum_{i=0}^{k-1} [f(x_i) - f^*] &\leq \sum_{i=0}^{k-1} \left[f(x_i) - f(x_{i+1}) + \frac{L}{2} \|y_i - x_{i+1}\|^2 \right] + \frac{L}{2} \|x_0 - x^*\|^2 - \frac{L}{2} \sum_{i=0}^{i-1} \|y_i - x_{i+1}\|^2 \\ &\leq f(x_0) - f(x_k) + \frac{L}{2} \sum_{i=0}^{i-1} \|y_i - x_{i+1}\|^2 + \frac{L}{2} \|x_0 - x^*\|^2 - \frac{L}{2} \sum_{i=0}^{i-1} \|y_i - x_{i+1}\|^2 \\ &\leq f(x_0) - f(x_k) + \frac{L}{2} \|x_0 - x^*\|^2\end{aligned}$$

Скорость сходимости для гладкого выпуклого случая

5. Оценим градиенты с помощью неравенства достаточного убывания 7:

$$\begin{aligned}\sum_{i=0}^{k-1} [f(x_i) - f^*] &\leq \sum_{i=0}^{k-1} \left[f(x_i) - f(x_{i+1}) + \frac{L}{2} \|y_i - x_{i+1}\|^2 \right] + \frac{L}{2} \|x_0 - x^*\|^2 - \frac{L}{2} \sum_{i=0}^{i-1} \|y_i - x_{i+1}\|^2 \\ &\leq f(x_0) - f(x_k) + \frac{L}{2} \sum_{i=0}^{i-1} \|y_i - x_{i+1}\|^2 + \frac{L}{2} \|x_0 - x^*\|^2 - \frac{L}{2} \sum_{i=0}^{i-1} \|y_i - x_{i+1}\|^2 \\ &\leq f(x_0) - f(x_k) + \frac{L}{2} \|x_0 - x^*\|^2 \\ \sum_{i=0}^{k-1} f(x_i) - kf^* &\leq f(x_0) - f(x_k) + \frac{L}{2} \|x_0 - x^*\|^2\end{aligned}$$

Скорость сходимости для гладкого выпуклого случая

5. Оценим градиенты с помощью неравенства достаточного убывания 7:

$$\begin{aligned}\sum_{i=0}^{k-1} [f(x_i) - f^*] &\leq \sum_{i=0}^{k-1} \left[f(x_i) - f(x_{i+1}) + \frac{L}{2} \|y_i - x_{i+1}\|^2 \right] + \frac{L}{2} \|x_0 - x^*\|^2 - \frac{L}{2} \sum_{i=0}^{i-1} \|y_i - x_{i+1}\|^2 \\ &\leq f(x_0) - f(x_k) + \frac{L}{2} \sum_{i=0}^{i-1} \|y_i - x_{i+1}\|^2 + \frac{L}{2} \|x_0 - x^*\|^2 - \frac{L}{2} \sum_{i=0}^{i-1} \|y_i - x_{i+1}\|^2 \\ &\leq f(x_0) - f(x_k) + \frac{L}{2} \|x_0 - x^*\|^2 \\ \sum_{i=0}^{k-1} f(x_i) - kf^* &\leq f(x_0) - f(x_k) + \frac{L}{2} \|x_0 - x^*\|^2 \\ \sum_{i=1}^k [f(x_i) - f^*] &\leq \frac{L}{2} \|x_0 - x^*\|^2\end{aligned}$$

Скорость сходимости для гладкого выпуклого случая

6. Из неравенства достаточного убывания

$$f(x_{k+1}) \leq f(x_k) - \frac{1}{2L} \|\nabla f(x_k)\|^2 + \frac{L}{2} \|y_k - x_{k+1}\|^2,$$

Скорость сходимости для гладкого выпуклого случая

6. Из неравенства достаточного убывания

$$f(x_{k+1}) \leq f(x_k) - \frac{1}{2L} \|\nabla f(x_k)\|^2 + \frac{L}{2} \|y_k - x_{k+1}\|^2,$$

Скорость сходимости для гладкого выпуклого случая

6. Из неравенства достаточного убывания

$$f(x_{k+1}) \leq f(x_k) - \frac{1}{2L} \|\nabla f(x_k)\|^2 + \frac{L}{2} \|y_k - x_{k+1}\|^2,$$

используем тот факт, что $x_{k+1} = \text{proj}_S(y_k)$. По определению проекции,

$$\|y_k - x_{k+1}\| \leq \|y_k - x_k\|,$$

Скорость сходимости для гладкого выпуклого случая

6. Из неравенства достаточного убывания

$$f(x_{k+1}) \leq f(x_k) - \frac{1}{2L} \|\nabla f(x_k)\|^2 + \frac{L}{2} \|y_k - x_{k+1}\|^2,$$

используем тот факт, что $x_{k+1} = \text{proj}_S(y_k)$. По определению проекции,

$$\|y_k - x_{k+1}\| \leq \|y_k - x_k\|,$$

и вспомним, что $y_k = x_k - \frac{1}{L} \nabla f(x_k)$ означает $\|y_k - x_k\| = \frac{1}{L} \|\nabla f(x_k)\|$. Следовательно,

$$\frac{L}{2} \|y_k - x_{k+1}\|^2 \leq \frac{L}{2} \|y_k - x_k\|^2 = \frac{L}{2} \frac{1}{L^2} \|\nabla f(x_k)\|^2 = \frac{1}{2L} \|\nabla f(x_k)\|^2.$$

Скорость сходимости для гладкого выпуклого случая

6. Из неравенства достаточного убывания

$$f(x_{k+1}) \leq f(x_k) - \frac{1}{2L} \|\nabla f(x_k)\|^2 + \frac{L}{2} \|y_k - x_{k+1}\|^2,$$

используем тот факт, что $x_{k+1} = \text{proj}_S(y_k)$. По определению проекции,

$$\|y_k - x_{k+1}\| \leq \|y_k - x_k\|,$$

и вспомним, что $y_k = x_k - \frac{1}{L} \nabla f(x_k)$ означает $\|y_k - x_k\| = \frac{1}{L} \|\nabla f(x_k)\|$. Следовательно,

$$\frac{L}{2} \|y_k - x_{k+1}\|^2 \leq \frac{L}{2} \|y_k - x_k\|^2 = \frac{L}{2} \frac{1}{L^2} \|\nabla f(x_k)\|^2 = \frac{1}{2L} \|\nabla f(x_k)\|^2.$$

Подставим обратно в (*):

$$f(x_{k+1}) \leq f(x_k) - \frac{1}{2L} \|\nabla f(x_k)\|^2 + \frac{1}{2L} \|\nabla f(x_k)\|^2 = f(x_k).$$

Скорость сходимости для гладкого выпуклого случая

6. Из неравенства достаточного убывания

$$f(x_{k+1}) \leq f(x_k) - \frac{1}{2L} \|\nabla f(x_k)\|^2 + \frac{L}{2} \|y_k - x_{k+1}\|^2,$$

используем тот факт, что $x_{k+1} = \text{proj}_S(y_k)$. По определению проекции,

$$\|y_k - x_{k+1}\| \leq \|y_k - x_k\|,$$

и вспомним, что $y_k = x_k - \frac{1}{L} \nabla f(x_k)$ означает $\|y_k - x_k\| = \frac{1}{L} \|\nabla f(x_k)\|$. Следовательно,

$$\frac{L}{2} \|y_k - x_{k+1}\|^2 \leq \frac{L}{2} \|y_k - x_k\|^2 = \frac{L}{2} \frac{1}{L^2} \|\nabla f(x_k)\|^2 = \frac{1}{2L} \|\nabla f(x_k)\|^2.$$

Подставим обратно в (*):

$$f(x_{k+1}) \leq f(x_k) - \frac{1}{2L} \|\nabla f(x_k)\|^2 + \frac{1}{2L} \|\nabla f(x_k)\|^2 = f(x_k).$$

Таким образом,

$$f(x_{k+1}) \leq f(x_k) \quad \text{для каждого } k,$$

то есть $\{f(x_k)\}$ — монотонно невозрастающая последовательность.

Скорость сходимости для гладкого выпуклого случая

7. Итоговая оценка сходимости Из шага 5 мы уже установили

$$\sum_{i=0}^{k-1} [f(x_i) - f^*] \leq \frac{L}{2} \|x_0 - x^*\|_2^2.$$

Скорость сходимости для гладкого выпуклого случая

7. Итоговая оценка сходимости Из шага 5 мы уже установили

$$\sum_{i=0}^{k-1} [f(x_i) - f^*] \leq \frac{L}{2} \|x_0 - x^*\|_2^2.$$

Скорость сходимости для гладкого выпуклого случая

7. Итоговая оценка сходимости Из шага 5 мы уже установили

$$\sum_{i=0}^{k-1} [f(x_i) - f^*] \leq \frac{L}{2} \|x_0 - x^*\|_2^2.$$

Поскольку $f(x_i)$ убывает по i , в частности $f(x_k) \leq f(x_i)$ для всех $i \leq k$. Следовательно,

$$k [f(x_k) - f^*] \leq \sum_{i=0}^{k-1} [f(x_i) - f^*] \leq \frac{L}{2} \|x_0 - x^*\|_2^2,$$

Скорость сходимости для гладкого выпуклого случая

7. Итоговая оценка сходимости Из шага 5 мы уже установили

$$\sum_{i=0}^{k-1} [f(x_i) - f^*] \leq \frac{L}{2} \|x_0 - x^*\|_2^2.$$

Поскольку $f(x_i)$ убывает по i , в частности $f(x_k) \leq f(x_i)$ для всех $i \leq k$. Следовательно,

$$k [f(x_k) - f^*] \leq \sum_{i=0}^{k-1} [f(x_i) - f^*] \leq \frac{L}{2} \|x_0 - x^*\|_2^2,$$

откуда немедленно получаем

$$f(x_k) - f^* \leq \frac{L \|x_0 - x^*\|_2^2}{2k}.$$

Это завершает доказательство скорости сходимости $\mathcal{O}(\frac{1}{k})$ для выпуклой L -гладкой функции f в условной задаче оптимизации.

Скорость сходимости для гладкого сильно выпуклого случая

Theorem

Пусть $f : \mathbb{R}^n \rightarrow \mathbb{R}$ — μ -сильно выпуклая функция. Пусть $S \subseteq \mathbb{R}^n$ — замкнутое выпуклое множество, и существует минимизатор x^* функции f на S ; кроме того, предположим, что f является гладкой на S с параметром L . Алгоритм метода проекции градиента с шагом $\alpha \leq \frac{1}{L}$ обеспечивает следующую сходимость после $k > 0$ итераций:

$$\|x_k - x^*\|_2^2 \leq (1 - \alpha\mu)^k \|x_0 - x^*\|_2^2$$

Доказательство

1. Сначала докажем свойство стационарной точки: $\text{proj}_S(x^* - \alpha \nabla f(x^*)) = x^*$.

Это следует из критерия проекции и условия оптимальности первого порядка для x^* . Пусть $y = x^* - \alpha \nabla f(x^*)$. Нужно показать, что $\langle y - x^*, x - x^* \rangle \leq 0$ для всех $x \in S$.

$$\langle (x^* - \alpha \nabla f(x^*)) - x^*, x - x^* \rangle = -\alpha \langle \nabla f(x^*), x - x^* \rangle \leq 0$$

Неравенство выполняется, так как $\alpha > 0$ и $\langle \nabla f(x^*), x - x^* \rangle \geq 0$ — условие оптимальности для x^* .

Скорость сходимости для гладкого сильно выпуклого случая

1. Рассмотрим расстояние до решения, используя свойство стационарной точки:

Скорость сходимости для гладкого сильно выпуклого случая

1. Рассмотрим расстояние до решения, используя свойство стационарной точки:

$$\|x_{k+1} - x^*\|_2^2 = \|\text{proj}_S(x_k - \alpha \nabla f(x_k)) - x^*\|_2^2$$

Скорость сходимости для гладкого сильно выпуклого случая

1. Рассмотрим расстояние до решения, используя свойство стационарной точки:

$$\|x_{k+1} - x^*\|_2^2 = \|\text{proj}_S(x_k - \alpha \nabla f(x_k)) - x^*\|_2^2$$

$$\text{свойство стационарной точки} = \|\text{proj}_S(x_k - \alpha \nabla f(x_k)) - \text{proj}_S(x^* - \alpha \nabla f(x^*))\|_2^2$$

Скорость сходимости для гладкого сильно выпуклого случая

1. Рассмотрим расстояние до решения, используя свойство стационарной точки:

$$\begin{aligned}\|x_{k+1} - x^*\|_2^2 &= \|\text{proj}_S(x_k - \alpha \nabla f(x_k)) - x^*\|_2^2 \\ \text{свойство стационарной точки} &= \|\text{proj}_S(x_k - \alpha \nabla f(x_k)) - \text{proj}_S(x^* - \alpha \nabla f(x^*))\|_2^2 \\ \text{нерастягиваемость} &\leq \|x_k - \alpha \nabla f(x_k) - (x^* - \alpha \nabla f(x^*))\|_2^2\end{aligned}$$

Скорость сходимости для гладкого сильно выпуклого случая

1. Рассмотрим расстояние до решения, используя свойство стационарной точки:

$$\begin{aligned}\|x_{k+1} - x^*\|_2^2 &= \|\text{proj}_S(x_k - \alpha \nabla f(x_k)) - x^*\|_2^2 \\ \text{свойство стационарной точки} &= \|\text{proj}_S(x_k - \alpha \nabla f(x_k)) - \text{proj}_S(x^* - \alpha \nabla f(x^*))\|_2^2 \\ \text{нерастягиваемость} &\leq \|x_k - \alpha \nabla f(x_k) - (x^* - \alpha \nabla f(x^*))\|_2^2 \\ &= \|x_k - x^*\|^2 - 2\alpha \langle \nabla f(x_k) - \nabla f(x^*), x_k - x^* \rangle + \alpha^2 \|\nabla f(x_k) - \nabla f(x^*)\|_2^2\end{aligned}$$

Скорость сходимости для гладкого сильно выпуклого случая

1. Рассмотрим расстояние до решения, используя свойство стационарной точки:

$$\begin{aligned}\|x_{k+1} - x^*\|_2^2 &= \|\text{proj}_S(x_k - \alpha \nabla f(x_k)) - x^*\|_2^2 \\ \text{свойство стационарной точки} &= \|\text{proj}_S(x_k - \alpha \nabla f(x_k)) - \text{proj}_S(x^* - \alpha \nabla f(x^*))\|_2^2 \\ \text{нерастягиваемость} &\leq \|x_k - \alpha \nabla f(x_k) - (x^* - \alpha \nabla f(x^*))\|_2^2 \\ &= \|x_k - x^*\|^2 - 2\alpha \langle \nabla f(x_k) - \nabla f(x^*), x_k - x^* \rangle + \alpha^2 \|\nabla f(x_k) - \nabla f(x^*)\|_2^2\end{aligned}$$

2. Теперь используем гладкость из инструментов сходимости и сильную выпуклость:

Скорость сходимости для гладкого сильно выпуклого случая

1. Рассмотрим расстояние до решения, используя свойство стационарной точки:

$$\begin{aligned}\|x_{k+1} - x^*\|_2^2 &= \|\text{proj}_S(x_k - \alpha \nabla f(x_k)) - x^*\|_2^2 \\ \text{свойство стационарной точки} &= \|\text{proj}_S(x_k - \alpha \nabla f(x_k)) - \text{proj}_S(x^* - \alpha \nabla f(x^*))\|_2^2 \\ \text{нерастягиваемость} &\leq \|x_k - \alpha \nabla f(x_k) - (x^* - \alpha \nabla f(x^*))\|_2^2 \\ &= \|x_k - x^*\|^2 - 2\alpha \langle \nabla f(x_k) - \nabla f(x^*), x_k - x^* \rangle + \alpha^2 \|\nabla f(x_k) - \nabla f(x^*)\|_2^2\end{aligned}$$

2. Теперь используем гладкость из инструментов сходимости и сильную выпуклость:

$$\text{гладкость} \quad \|\nabla f(x_k) - \nabla f(x^*)\|_2^2 \leq 2L (f(x_k) - f(x^*) - \langle \nabla f(x^*), x_k - x^* \rangle)$$

Скорость сходимости для гладкого сильно выпуклого случая

1. Рассмотрим расстояние до решения, используя свойство стационарной точки:

$$\begin{aligned}\|x_{k+1} - x^*\|_2^2 &= \|\text{proj}_S(x_k - \alpha \nabla f(x_k)) - x^*\|_2^2 \\ \text{свойство стационарной точки} &= \|\text{proj}_S(x_k - \alpha \nabla f(x_k)) - \text{proj}_S(x^* - \alpha \nabla f(x^*))\|_2^2 \\ \text{нерастягиваемость} &\leq \|x_k - \alpha \nabla f(x_k) - (x^* - \alpha \nabla f(x^*))\|_2^2 \\ &= \|x_k - x^*\|^2 - 2\alpha \langle \nabla f(x_k) - \nabla f(x^*), x_k - x^* \rangle + \alpha^2 \|\nabla f(x_k) - \nabla f(x^*)\|_2^2\end{aligned}$$

2. Теперь используем гладкость из инструментов сходимости и сильную выпуклость:

$$\begin{aligned}\text{гладкость} \quad \|\nabla f(x_k) - \nabla f(x^*)\|_2^2 &\leq 2L (f(x_k) - f(x^*) - \langle \nabla f(x^*), x_k - x^* \rangle) \\ \text{сильная выпуклость} \quad -\langle \nabla f(x_k) - \nabla f(x^*), x_k - x^* \rangle &\leq -\left(f(x_k) - f(x^*) + \frac{\mu}{2} \|x_k - x^*\|_2^2\right) - \langle \nabla f(x^*), x_k - x^* \rangle\end{aligned}$$

Скорость сходимости для гладкого сильно выпуклого случая

3. Подставим:



3. Подставим:

$$\begin{aligned}\|x_{k+1} - x^*\|_2^2 &\leq \|x_k - x^*\|^2 - 2\alpha \left(f(x_k) - f(x^*) + \frac{\mu}{2} \|x_k - x^*\|_2^2 \right) - 2\alpha \langle \nabla f(x^*), x_k - x^* \rangle + \\ &\quad + \alpha^2 2L (f(x_k) - f(x^*) - \langle \nabla f(x^*), x_k - x^* \rangle)\end{aligned}$$



3. Подставим:

$$\begin{aligned}\|x_{k+1} - x^*\|_2^2 &\leq \|x_k - x^*\|^2 - 2\alpha \left(f(x_k) - f(x^*) + \frac{\mu}{2} \|x_k - x^*\|_2^2 \right) - 2\alpha \langle \nabla f(x^*), x_k - x^* \rangle + \\ &\quad + \alpha^2 2L (f(x_k) - f(x^*) - \langle \nabla f(x^*), x_k - x^* \rangle) \\ &\leq (1 - \alpha\mu) \|x_k - x^*\|^2 + 2\alpha(\alpha L - 1) (f(x_k) - f(x^*) - \langle \nabla f(x^*), x_k - x^* \rangle)\end{aligned}$$

Скорость сходимости для гладкого сильно выпуклого случая

3. Подставим:

$$\begin{aligned}\|x_{k+1} - x^*\|_2^2 &\leq \|x_k - x^*\|^2 - 2\alpha \left(f(x_k) - f(x^*) + \frac{\mu}{2} \|x_k - x^*\|_2^2 \right) - 2\alpha \langle \nabla f(x^*), x_k - x^* \rangle + \\ &\quad + \alpha^2 2L (f(x_k) - f(x^*) - \langle \nabla f(x^*), x_k - x^* \rangle) \\ &\leq (1 - \alpha\mu) \|x_k - x^*\|^2 + 2\alpha(\alpha L - 1) (f(x_k) - f(x^*) - \langle \nabla f(x^*), x_k - x^* \rangle)\end{aligned}$$

4. В силу выпуклости f : $f(x_k) - f(x^*) - \langle \nabla f(x^*), x_k - x^* \rangle \geq 0$. Следовательно, при $\alpha \leq \frac{1}{L}$:

$$\|x_{k+1} - x^*\|_2^2 \leq (1 - \alpha\mu) \|x_k - x^*\|^2,$$

что означает линейную сходимость метода со скоростью $1 - \frac{\mu}{L}$.

Метод Франк-Вульфа



Рис. 11: Маргарит Страус Франк (1927-2024)



Рис. 12: Филип Вульф (1927-2016)




Рис. 13: Иллюстрация алгоритма Франк-Вульфа (условного градиента)




Рис. 14: Иллюстрация алгоритма Франк-Вульфа (условного градиента)




Рис. 15: Иллюстрация алгоритма Франк-Вульфа (условного градиента)




Рис. 16: Иллюстрация алгоритма Франк-Вульфа (условного градиента)




Рис. 17: Иллюстрация алгоритма Франк-Вульфа (условного градиента)




Рис. 18: Иллюстрация алгоритма Франк-Вульфа (условного градиента)




Рис. 19: Иллюстрация алгоритма Франк-Вульфа (условного градиента)

$$y_k = \arg \min_{x \in S} f^I_{x_k}(x) = \arg \min_{x \in S} \langle \nabla f(x_k), x \rangle$$

$$x_{k+1} = \gamma_k x_k + (1 - \gamma_k) y_k$$




Рис. 20: Иллюстрация алгоритма Франк-Вульфа (условного градиента)

Скорость сходимости для гладкого выпуклого случая

Theorem

Пусть $f : \mathbb{R}^n \rightarrow \mathbb{R}$ — выпуклая и дифференцируемая функция. Пусть $S \subseteq \mathbb{R}^n$ — замкнутое выпуклое множество, и существует минимизатор x^* функции f на S ; кроме того, предположим, что f является гладкой на S с параметром L . Алгоритм Франк-Вульфа с размером шага $\gamma_k = \frac{k-1}{k+1}$ обеспечивает следующую сходимость после $k > 0$ итераций:

$$f(x_k) - f^* \leq \frac{2LR^2}{k+1}$$

где $R = \max_{x,y \in S} \|x - y\|$ — диаметр множества S .

Скорость сходимости для гладкого выпуклого случая

Theorem

Пусть $f : \mathbb{R}^n \rightarrow \mathbb{R}$ — выпуклая и дифференцируемая функция. Пусть $S \subseteq \mathbb{R}^n$ — замкнутое выпуклое множество, и существует минимизатор x^* функции f на S ; кроме того, предположим, что f является гладкой на S с параметром L . Алгоритм Франк-Вульфа с размером шага $\gamma_k = \frac{k-1}{k+1}$ обеспечивает следующую сходимость после $k > 0$ итераций:

$$f(x_k) - f^* \leq \frac{2LR^2}{k+1}$$

где $R = \max_{x, y \in S} \|x - y\|$ — диаметр множества S .

1. Из L -гладкости f имеем:

$$\begin{aligned} f(x_{k+1}) - f(x_k) &\leq \langle \nabla f(x_k), x_{k+1} - x_k \rangle + \frac{L}{2} \|x_{k+1} - x_k\|^2 \\ &= (1 - \gamma_k) \langle \nabla f(x_k), y_k - x_k \rangle + \frac{L(1 - \gamma_k)^2}{2} \|y_k - x_k\|^2 \end{aligned}$$

Скорость сходимости для гладкого выпуклого случая

2. Из выпуклости f для любого $x \in S$, включая x^* :

$$\langle \nabla f(x_k), x - x_k \rangle \leq f(x) - f(x_k)$$

В частности, для $x = x^*$:

$$\langle \nabla f(x_k), x^* - x_k \rangle \leq f(x^*) - f(x_k)$$

Скорость сходимости для гладкого выпуклого случая

2. Из выпуклости f для любого $x \in S$, включая x^* :

$$\langle \nabla f(x_k), x - x_k \rangle \leq f(x) - f(x_k)$$

В частности, для $x = x^*$:

$$\langle \nabla f(x_k), x^* - x_k \rangle \leq f(x^*) - f(x_k)$$

3. По определению y_k имеем $\langle \nabla f(x_k), y_k \rangle \leq \langle \nabla f(x_k), x^* \rangle$, поэтому:

$$\langle \nabla f(x_k), y_k - x_k \rangle \leq \langle \nabla f(x_k), x^* - x_k \rangle \leq f(x^*) - f(x_k)$$

Скорость сходимости для гладкого выпуклого случая

2. Из выпуклости f для любого $x \in S$, включая x^* :

$$\langle \nabla f(x_k), x - x_k \rangle \leq f(x) - f(x_k)$$

В частности, для $x = x^*$:

$$\langle \nabla f(x_k), x^* - x_k \rangle \leq f(x^*) - f(x_k)$$

3. По определению y_k имеем $\langle \nabla f(x_k), y_k \rangle \leq \langle \nabla f(x_k), x^* \rangle$, поэтому:

$$\langle \nabla f(x_k), y_k - x_k \rangle \leq \langle \nabla f(x_k), x^* - x_k \rangle \leq f(x^*) - f(x_k)$$

4. Объединяя приведённые неравенства:

$$\begin{aligned} f(x_{k+1}) - f(x_k) &\leq (1 - \gamma_k) \langle \nabla f(x_k), y_k - x_k \rangle + \frac{L(1 - \gamma_k)^2}{2} \|y_k - x_k\|^2 \\ &\leq (1 - \gamma_k) (f(x^*) - f(x_k)) + \frac{L(1 - \gamma_k)^2}{2} R^2 \end{aligned}$$

Скорость сходимости для гладкого выпуклого случая

2. Из выпуклости f для любого $x \in S$, включая x^* :

$$\langle \nabla f(x_k), x - x_k \rangle \leq f(x) - f(x_k)$$

В частности, для $x = x^*$:

$$\langle \nabla f(x_k), x^* - x_k \rangle \leq f(x^*) - f(x_k)$$

3. По определению y_k имеем $\langle \nabla f(x_k), y_k \rangle \leq \langle \nabla f(x_k), x^* \rangle$, поэтому:

$$\langle \nabla f(x_k), y_k - x_k \rangle \leq \langle \nabla f(x_k), x^* - x_k \rangle \leq f(x^*) - f(x_k)$$

4. Объединяя приведённые неравенства:

$$\begin{aligned} f(x_{k+1}) - f(x_k) &\leq (1 - \gamma_k) \langle \nabla f(x_k), y_k - x_k \rangle + \frac{L(1 - \gamma_k)^2}{2} \|y_k - x_k\|^2 \\ &\leq (1 - \gamma_k) (f(x^*) - f(x_k)) + \frac{L(1 - \gamma_k)^2}{2} R^2 \end{aligned}$$

5. Перегруппируем слагаемые:

$$f(x_{k+1}) - f(x^*) \leq \gamma_k (f(x_k) - f(x^*)) + (1 - \gamma_k)^2 \frac{LR^2}{2}$$

Скорость сходимости для гладкого выпуклого случая

6. Обозначив $\delta_k = \frac{f(x_k) - f(x^*)}{LR^2}$, получаем:

$$\delta_{k+1} \leq \gamma_k \delta_k + \frac{(1 - \gamma_k)^2}{2} = \frac{k-1}{k+1} \delta_k + \frac{2}{(k+1)^2}$$

Скорость сходимости для гладкого выпуклого случая

6. Обозначив $\delta_k = \frac{f(x_k) - f(x^*)}{LR^2}$, получаем:

$$\delta_{k+1} \leq \gamma_k \delta_k + \frac{(1 - \gamma_k)^2}{2} = \frac{k-1}{k+1} \delta_k + \frac{2}{(k+1)^2}$$

7. Докажем по индукции, что $\delta_k \leq \frac{2}{k+1}$.

что даёт нам искомый результат:

$$f(x_k) - f^* \leq \frac{2LR^2}{k+1}$$

Скорость сходимости для гладкого выпуклого случая

6. Обозначив $\delta_k = \frac{f(x_k) - f(x^*)}{LR^2}$, получаем:

$$\delta_{k+1} \leq \gamma_k \delta_k + \frac{(1 - \gamma_k)^2}{2} = \frac{k-1}{k+1} \delta_k + \frac{2}{(k+1)^2}$$

7. Докажем по индукции, что $\delta_k \leq \frac{2}{k+1}$.

- База: $\delta_2 \leq \frac{1}{2} < \frac{2}{3}$

что даёт нам искомый результат:

$$f(x_k) - f^* \leq \frac{2LR^2}{k+1}$$

Скорость сходимости для гладкого выпуклого случая

6. Обозначив $\delta_k = \frac{f(x_k) - f(x^*)}{LR^2}$, получаем:

$$\delta_{k+1} \leq \gamma_k \delta_k + \frac{(1 - \gamma_k)^2}{2} = \frac{k-1}{k+1} \delta_k + \frac{2}{(k+1)^2}$$

7. Докажем по индукции, что $\delta_k \leq \frac{2}{k+1}$.

- База: $\delta_2 \leq \frac{1}{2} < \frac{2}{3}$
- Предположим $\delta_k \leq \frac{2}{k+1}$

что даёт нам искомый результат:

$$f(x_k) - f^* \leq \frac{2LR^2}{k+1}$$

Скорость сходимости для гладкого выпуклого случая

6. Обозначив $\delta_k = \frac{f(x_k) - f(x^*)}{LR^2}$, получаем:

$$\delta_{k+1} \leq \gamma_k \delta_k + \frac{(1 - \gamma_k)^2}{2} = \frac{k-1}{k+1} \delta_k + \frac{2}{(k+1)^2}$$

7. Докажем по индукции, что $\delta_k \leq \frac{2}{k+1}$.

- База: $\delta_2 \leq \frac{1}{2} < \frac{2}{3}$
- Предположим $\delta_k \leq \frac{2}{k+1}$
- Тогда $\delta_{k+1} \leq \frac{k-1}{k+1} \cdot \frac{2}{k+1} + \frac{2}{(k+1)^2} = \frac{2k}{k^2+2k+1} < \frac{2}{k+2}$ 

что даёт нам искомый результат:

$$f(x_k) - f^* \leq \frac{2LR^2}{k+1}$$

Нижняя оценка для метода Франк-Вульфа²

Theorem

Рассмотрим произвольный алгоритм, который обращается к допустимому множеству $S \subseteq \mathbb{R}^n$ только через оракул линейной минимизации (LMO). Пусть диаметр множества S равен R . Существует L -гладкая сильно выпуклая функция $f : \mathbb{R}^n \rightarrow \mathbb{R}$, для которой этому алгоритму потребуется не менее

$$\min \left(\frac{n}{2}, \frac{LR^2}{16\varepsilon} \right)$$

итераций (то есть вызовов LMO), чтобы построить точку $\hat{x} \in S$ с $f(\hat{x}) - \min_{x \in S} f(x) \leq \varepsilon$. Нижняя оценка справедлива как для выпуклых, так и для сильно выпуклых функций.

²  The Complexity of Large-scale Convex Programming under a Linear Optimization Oracle

Нижняя оценка для метода Франк-Вульфа ²

Theorem

Рассмотрим произвольный алгоритм, который обращается к допустимому множеству $S \subseteq \mathbb{R}^n$ только через оракул линейной минимизации (LMO). Пусть диаметр множества S равен R . Существует L -гладкая сильно выпуклая функция $f : \mathbb{R}^n \rightarrow \mathbb{R}$, для которой этому алгоритму потребуется не менее

$$\min \left(\frac{n}{2}, \frac{LR^2}{16\varepsilon} \right)$$

итераций (то есть вызовов LMO), чтобы построить точку $\hat{x} \in S$ с $f(\hat{x}) - \min_{x \in S} f(x) \leq \varepsilon$. Нижняя оценка справедлива как для выпуклых, так и для сильно выпуклых функций.

Набросок доказательства. Рассмотрим следующую задачу оптимизации:

$$\min_{x \in S} f(x) = \min_{x \in S} \frac{1}{2} \|x\|_2^2$$

$$S = \left\{ x \in \mathbb{R}^n \mid x \geq 0, \sum_{i=1}^n x_i = 1 \right\}$$

Заметим, что:

- f является 1-гладкой;
- диаметр S равен $R = 2$;
- f сильно выпукла.

²  The Complexity of Large-scale Convex Programming under a Linear Optimization Oracle

Нижняя оценка для метода Франк-Вульфа ³

1. Оптимальное решение:

$$x^* = \frac{1}{n} \mathbf{1} = \frac{1}{n} \sum_{i=1}^n e_i, \quad \text{и} \quad f(x^*) = \frac{1}{2n},$$

где $e_i = (0, \dots, 0, \underset{\text{позиция } i}{1}, 0, \dots, 0)^\top$ — i -й стандартный базисный вектор.

Нижняя оценка для метода Франк-Вульфа ³

1. Оптимальное решение:

$$x^* = \frac{1}{n} \mathbf{1} = \frac{1}{n} \sum_{i=1}^n e_i, \quad \text{и} \quad f(x^*) = \frac{1}{2n},$$

где $e_i = (0, \dots, 0, \underset{\text{позиция } i}{1}, 0, \dots, 0)^\top$ — i -й стандартный базисный вектор.

2. Оракул линейной минимизации (LMO) на S возвращает вершину e_i . После k итераций метод обнаружит не более k различных базисных векторов $e_{i_1}, \dots, e_{i_k}$. Наилучшая выпуклая комбинация, которую можно составить:

$$\hat{x} = \frac{1}{k} \sum_{j=1}^k e_{i_j}.$$

Нижняя оценка для метода Франк-Вульфа ³

1. Оптимальное решение:

$$x^* = \frac{1}{n} \mathbf{1} = \frac{1}{n} \sum_{i=1}^n e_i, \quad \text{и} \quad f(x^*) = \frac{1}{2n},$$

где $e_i = (0, \dots, 0, \underset{\text{позиция } i}{1}, 0, \dots, 0)^\top$ — i -й стандартный базисный вектор.

2. Оракул линейной минимизации (LMO) на S возвращает вершину e_i . После k итераций метод обнаружит не более k различных базисных векторов $e_{i_1}, \dots, e_{i_k}$. Наилучшая выпуклая комбинация, которую можно составить:

$$\hat{x} = \frac{1}{k} \sum_{j=1}^k e_{i_j}.$$

3. Вычислив значение функции в точке $\hat{x}$, получаем:

$$f(\hat{x}) - f(x^*) \geq \frac{1}{2} \left(\frac{1}{\min\{k, n\}} - \frac{1}{n} \right).$$

Нижняя оценка для метода Франк-Вульфа ³

1. Оптимальное решение:

$$x^* = \frac{1}{n} \mathbf{1} = \frac{1}{n} \sum_{i=1}^n e_i, \quad \text{и} \quad f(x^*) = \frac{1}{2n},$$

где $e_i = (0, \dots, 0, \underset{\text{позиция } i}{1}, 0, \dots, 0)^\top$ — i -й стандартный базисный вектор.

2. Оракул линейной минимизации (LMO) на S возвращает вершину e_i . После k итераций метод обнаружит не более k различных базисных векторов $e_{i_1}, \dots, e_{i_k}$. Наилучшая выпуклая комбинация, которую можно составить:

$$\hat{x} = \frac{1}{k} \sum_{j=1}^k e_{i_j}.$$

3. Вычислив значение функции в точке $\hat{x}$, получаем:

$$f(\hat{x}) - f(x^*) \geq \frac{1}{2} \left(\frac{1}{\min\{k, n\}} - \frac{1}{n} \right).$$

4. Чтобы обеспечить $f(\hat{x}) - f(x^*) \leq \varepsilon$, необходимо (полное доказательство приведено в статье):

$$k \geq \min \left\{ \frac{n}{2}, \frac{1}{4\varepsilon} \right\} = \min \left\{ \frac{n}{2}, \frac{LR^2}{16\varepsilon} \right\}.$$

Итоги метода Франк-Вульфа

- Метод не требует проекций, а в некоторых случаях позволяет вычислять итерации в замкнутой форме

Итоги метода Франк-Вульфа

- Метод не требует проекций, а в некоторых случаях позволяет вычислять итерации в замкнутой форме
- Глобальная скорость сходимости составляет $O\left(\frac{1}{k}\right)$ для гладких выпуклых функций. Сильная выпуклость не улучшает скорость. Это нижняя оценка для LMO

Итоги метода Франк-Вульфа

- Метод не требует проекций, а в некоторых случаях позволяет вычислять итерации в замкнутой форме
- Глобальная скорость сходимости составляет $O\left(\frac{1}{k}\right)$ для гладких выпуклых функций. Сильная выпуклость не улучшает скорость. Это нижняя оценка для LMO
- По сравнению с методом проекции градиента скорость сходимости хуже, однако стоимость итерации может быть ниже, а решения — более разреженными

Итоги метода Франк-Вульфа

- Метод не требует проекций, а в некоторых случаях позволяет вычислять итерации в замкнутой форме
- Глобальная скорость сходимости составляет $O\left(\frac{1}{k}\right)$ для гладких выпуклых функций. Сильная выпуклость не улучшает скорость. Это нижняя оценка для LMO
- По сравнению с методом проекции градиента скорость сходимости хуже, однако стоимость итерации может быть ниже, а решения — более разреженными
- Недавно было показано, что для сильно выпуклых множеств скорость может быть улучшена до $O\left(\frac{1}{k^2}\right)$ ( статья)

Итоги метода Франк-Вульфа

- Метод не требует проекций, а в некоторых случаях позволяет вычислять итерации в замкнутой форме
- Глобальная скорость сходимости составляет $O\left(\frac{1}{k}\right)$ для гладких выпуклых функций. Сильная выпуклость не улучшает скорость. Это нижняя оценка для LMO
- По сравнению с методом проекции градиента скорость сходимости хуже, однако стоимость итерации может быть ниже, а решения — более разреженными
- Недавно было показано, что для сильно выпуклых множеств скорость может быть улучшена до $O\left(\frac{1}{k^2}\right)$ (📄 статья)
- Если допустить шаги удаления, сходимость становится линейной (📄 статья) в сильно выпуклом случае


Итоги метода Франк-Вульфа

- Метод не требует проекций, а в некоторых случаях позволяет вычислять итерации в замкнутой форме
- Глобальная скорость сходимости составляет $O\left(\frac{1}{k}\right)$ для гладких выпуклых функций. Сильная выпуклость не улучшает скорость. Это нижняя оценка для LMO
- По сравнению с методом проекции градиента скорость сходимости хуже, однако стоимость итерации может быть ниже, а решения — более разреженными
- Недавно было показано, что для сильно выпуклых множеств скорость может быть улучшена до $O\left(\frac{1}{k^2}\right)$ (📄 статья)
- Если допустить шаги удаления, сходимость становится линейной (📄 статья) в сильно выпуклом случае
- В недавних работах показано обобщение на негладкий случай (📄 статья) со скоростью сходимости $O\left(\frac{1}{\sqrt{k}}\right)$

Численные эксперименты


Двумерный пример. Метод Франк-Вульфа

Frank-Wolfe Method: Iteration 0




Двумерный пример. Метод Франк-Вульфа

Frank-Wolfe Method: Iteration 1




Двумерный пример. Метод Франк-Вульфа

Frank-Wolfe Method: Iteration 2




Двумерный пример. Метод Франк-Вульфа

Frank-Wolfe Method: Iteration 3




Двумерный пример. Метод Франк-Вульфа

Frank-Wolfe Method: Iteration 4




Двумерный пример. Метод Франк-Вульфа

Frank-Wolfe Method: Iteration 5




Двумерный пример. Метод Франк-Вульфа

Frank-Wolfe Method: Iteration 6



Двумерный пример. Метод Франк-Вульфа

Frank-Wolfe Method: Iteration 7



Квадратичная функция. Покоординатные ограничения

$$\min_{\substack{x \in \mathbb{R}^n \\ -1 \leq x \leq 1}} \frac{1}{2} x^\top A x - b^\top x,$$

$$A \in \mathbb{R}^{n \times n}, \quad \lambda(A) \in [\mu; L].$$

Проекция тривиальна:

$$\pi_S(x) = \text{clip}(x, -1, 1).$$

или





$$\pi_S(x) = \max(-1, \min(1, x)).$$

Оракул линейной минимизации (LMO) для заданного градиента g имеет вид $y = \operatorname{argmin}_{z \in S} \langle g, z \rangle$.

Поскольку допустимое множество сепарабельно по координатам, решение вычисляется покоординатно:

$$y_i = \begin{cases} -1, & \text{если } g_i > 0, \\ 1, & \text{если } g_i \leq 0. \end{cases}$$

Constrained convex quadratic problem: $n=80, \mu=0, L=10$



— Projected Gradient Descent - - - Frank-Wolfe

Квадратичная функция. Покоординатные ограничения

$$\min_{\substack{x \in \mathbb{R}^n \\ -1 \leq x \leq 1}} \frac{1}{2} x^\top A x - b^\top x,$$

$$A \in \mathbb{R}^{n \times n}, \quad \lambda(A) \in [\mu; L].$$

Проекция тривиальна:

$$\pi_S(x) = \text{clip}(x, -1, 1).$$

или





$$\pi_S(x) = \max(-1, \min(1, x)).$$

Оракул линейной минимизации (LMO) для заданного градиента g имеет вид $y = \operatorname{argmin}_{z \in S} \langle g, z \rangle$.

Поскольку допустимое множество сепарабельно по координатам, решение вычисляется покоординатно:

$$y_i = \begin{cases} -1, & \text{если } g_i > 0, \\ 1, & \text{если } g_i \leq 0. \end{cases}$$

Constrained strongly Convex quadratic problem: $n=80, \mu=1, L=10$



— Projected Gradient Descent - - - Frank-Wolfe

Квадратичная функция. Симплексные ограничения (удачная задача с диагональной матрицей)

$$\min_{\substack{x \in \mathbb{R}^n \\ x \geq 0, 1^T x = 1}} \frac{1}{2} x^T A x,$$

$$A \in \mathbb{R}^{n \times n}, \quad \lambda(A) \in [0; 100].$$

$$\min_{1^T x = 1, x \geq 0} \frac{1}{2} x^T A x, n = 200$$





Метод	Время шага, мс	Время LMO/проекции, мс
PGD	0.0069	0.0167
FW	0.0070	0.0066

Проекция на единичный симплекс $\pi_S(x)$ выполняется за $\mathcal{O}(n \log n)$ или за ожидаемое $\mathcal{O}(n)$ время.⁴

LMO для заданного градиента g имеет вид $y = \operatorname{argmin}_{z \in S} \langle g, z \rangle$. Решение соответствует вершине симплекса:

$$y = e_j \quad \text{где} \quad j = \operatorname{argmin}_i g_i.$$

⁴ Efficient Projections onto the ℓ_1 -Ball for Learning in High Dimensions



-- Frank-Wolfe — Projected Gradient Descent


Квадратичная функция. Симплексные ограничения

$$\min_{\substack{x \in \mathbb{R}^n \\ x \geq 0, 1^T x = 1}} \frac{1}{2} x^T A x,$$

$$A \in \mathbb{R}^{n \times n}, \quad \lambda(A) \in [0; 100].$$

$$\min_{1^T x = 1, x \geq 0} \frac{1}{2} x^T A x, n = 200$$

Метод	Время шага, мс	Время LMO/проекции, мс
PGD	0.0069	0.0420
FW	0.0069	0.0066







Квадратичная функция. Симплексные ограничения

$$\min_{\substack{x \in \mathbb{R}^n \\ x \geq 0, 1^T x = 1}} \frac{1}{2} x^T A x,$$

$$A \in \mathbb{R}^{n \times n}, \quad \lambda(A) \in [0; 100].$$

$$\min_{1^T x = 1, x \geq 0} \frac{1}{2} x^T A x, n = 300$$

Метод	Время шага, мс	Время LMO/проекции, мс
PGD	0.0068	0.0761
FW	0.0069	0.0070



--- Frank-Wolfe — Projected Gradient Descent





Квадратичная функция. Симплексные ограничения

$$\min_{\substack{x \in \mathbb{R}^n \\ x \geq 0, 1^T x = 1}} \frac{1}{2} x^T A x,$$

$$A \in \mathbb{R}^{n \times n}, \quad \lambda(A) \in [1; 100].$$

$$\min_{1^T x = 1, x \geq 0} \frac{1}{2} x^T A x, n = 300$$

Метод	Время шага, мс	Время LMO/проекции, мс
PGD	0.0068	0.0752
FW	0.0067	0.0068



--- Frank-Wolfe — Projected Gradient Descent

PGD и метод Франк-Вульфа

Ключевое различие между PGD и FW состоит в том, что PGD требует проекции, тогда как FW — лишь оракул линейной минимизации (LMO).

В недавней статье авторы представили следующую сравнительную таблицу сложностей линейной минимизации и проекций на некоторые выпуклые множества с точностью до аддитивной ошибки ϵ в евклидовой норме.

Множество	Линейная минимизация	Проекция
n -мерный ℓ_p -шар, $p \neq 1, 2, \infty$	$\mathcal{O}(n)$	$\tilde{\mathcal{O}}(\frac{n}{\epsilon^2})$
Шар ядерной нормы для $n \times m$ матриц	$\mathcal{O}\left(\nu \ln(m+n) \frac{\sqrt{\sigma_1}}{\sqrt{\epsilon}}\right)$	$\mathcal{O}(mn \min\{m, n\})$
Потоковый многогранник на графе с m вершинами и n рёбрами (ограничение пропускной способности на рёбрах)	$\mathcal{O}\left((n \log m)(n + m \log m)\right)$	$\tilde{\mathcal{O}}(\frac{n}{\epsilon^2})$ или $\mathcal{O}(n^4 \log n)$
Многогранник Биркгофа ($n \times n$ дважды стохастические матрицы)	$\mathcal{O}(n^3)$	$\tilde{\mathcal{O}}(\frac{n^2}{\epsilon^2})$

Когда ϵ отсутствует, аддитивной ошибки нет. Обозначение $\tilde{\mathcal{O}}$ скрывает полилогарифмические множители по размерности и полиномиальные множители в константах, связанных с расстоянием до оптимума. Для шара ядерной нормы (спектраэдра) ν обозначает число ненулевых элементов, а σ_1 — наибольшее сингулярное

число проецируемой матрицы.

Дополнительные численные эксперименты

Траектории PGD и FW на ℓ_2 -шаре


$$\min_{x \in \mathbb{R}^2} \frac{1}{2} x^\top A x - b^\top x, \quad \|x\|_2 \leq 1$$

PGD: проекция $\rightarrow$ кратчайший путь к границе, затем движение вдоль неё к оптимуму.

FW: каждый шаг — выпуклая комбинация текущей точки и **антиградиентной точки на границе**. Характерный зигзаг вдоль множества.

Оба метода стартуют из $x_0 = (-0.5, -0.5)$.


Траектории PGD и FW, ℓ_2 -шар



Траектории PGD и FW на 2-симплексе

$$\min_{\substack{x \in \mathbb{R}^3 \\ x \geq 0, \mathbf{1}^\top x = 1}} \frac{1}{2} x^\top A x$$

FW на каждом шаге выбирает одну из вершин симплекса (e_1, e_2, e_3) , движется к ней $\rightarrow$ траектория проходит через рёбра. PGD: проекция на симплекс допускает движение в любом направлении $\rightarrow$ более прямой путь к оптимуму.





ℓ_2 -шар. Проекция и LMO одинаково дёшевы

$$\min_{\|x\|_2 \leq 2} \frac{1}{2} x^\top A x - b^\top x$$

- $n = 200, \kappa = 50$

Когда проекция и LMO стоят одинаково, PGD выигрывает за счёт **линейной скорости** при сильной выпуклости.





ℓ_2 -шар. Проекция и LMO одинаково дёшевы

$$\min_{\|x\|_2 \leq 2} \frac{1}{2} x^\top A x - b^\top x$$

- $n = 200, \kappa = 50$
- Проекция: $\pi_S(x) = x \cdot \min\left(1, \frac{R}{\|x\|}\right)$ — $\mathcal{O}(n)$

Когда проекция и LMO стоят одинаково, PGD выигрывает за счёт **линейной скорости** при сильной выпуклости.





ℓ_2 -шар. Проекция и LMO одинаково дёшевы

$$\min_{\|x\|_2 \leq 2} \frac{1}{2} x^\top A x - b^\top x$$

- $n = 200, \kappa = 50$
- Проекция: $\pi_S(x) = x \cdot \min\left(1, \frac{R}{\|x\|}\right)$ — $\mathcal{O}(n)$
- LMO: $y = -R \frac{g}{\|g\|}$ — $\mathcal{O}(n)$

Когда проекция и LMO стоят одинаково, PGD выигрывает за счёт **линейной скорости** при сильной выпуклости.





Разреженность итераций FW на симплексе

$$\min_{\substack{x \geq 0 \\ \mathbf{1}^\top x = 1}} \frac{1}{2} x^\top A x, \quad n = 500$$

Ключевое свойство FW: итерация x_k есть **выпуклая комбинация k вершин** $\Rightarrow$ не более k ненулевых компонент.

- PGD: после проекции число ненулевых компонент скачком достигает ~ 400

Это важно, когда нужно получить разреженное решение.





Разреженность итераций FW на симплексе

$$\min_{\substack{x \geq 0 \\ \mathbf{1}^\top x = 1}} \frac{1}{2} x^\top A x, \quad n = 500$$

Ключевое свойство FW: итерация x_k есть **выпуклая комбинация k вершин** $\Rightarrow$ не более k ненулевых компонент.

- PGD: после проекции число ненулевых компонент скачком достигает ~ 400
- FW: число ненулевых растёт **линейно** с итерациями

Это важно, когда нужно получить разреженное решение.



Сильная выпуклость: PGD ускоряется, FW — нет

$$\min_{\substack{x \geq 0 \\ \mathbf{1}^\top x = 1}} \frac{1}{2} x^\top A x$$



- $n = 200$, $\mu = 5$, $L = 100$, $\kappa = 20$

PGD с шагом $\frac{1}{L}$: **линейная сходимость**

$(1 - \mu/L)^k$, ведь проекция на выпуклое множество — нестягивающий оператор.

FW: остаётся $\mathcal{O}(1/k)$ — сильная выпуклость **не помогает** со стандартным шагом

$$\gamma_k = \frac{2}{k+2}.$$





Скорость сходимости: выпуклая vs сильно выпуклая задача

$$\min_{-1 \leq x \leq 1} \frac{1}{2} x^\top A x, \quad n = 100$$

- Левая панель: $\mu \approx 0$ — оба метода $\mathcal{O}(1/k)$, но PGD быстрее по константе

Главный вывод: сильная выпуклость кардинально меняет картину в пользу PGD.





Скорость сходимости: выпуклая vs сильно выпуклая задача

$$\min_{-1 \leq x \leq 1} \frac{1}{2} x^\top A x, \quad n = 100$$

- Левая панель: $\mu \approx 0$ — оба метода $\mathcal{O}(1/k)$, но PGD быстрее по константе
- Правая панель: $\mu = 2$ — PGD получает **экспоненциальную** скорость, FW остаётся сублинейным

Главный вывод: сильная выпуклость кардинально меняет картину в пользу PGD.



Стоимость итерации: проекция vs LMO на симплексе


Измеряем **только** стоимость проекции и LMO, без вычисления градиента.

- Проекция на симплекс: сортировка + $O(n)$ — всего $O(n \log n)$

При $n = 10000$ проекция дороже LMO на **порядок**.

В задачах, где градиент считается быстро (разреженная матрица), разница в стоимости шага между PGD и FW определяется именно проекцией/LMO.

Стоимость проекции vs LMO на симплексе (без вычисления градиента)



Стоимость итерации: проекция vs LMO на симплексе


Измеряем **только** стоимость проекции и LMO, без вычисления градиента.

- Проекция на симплекс: сортировка + $O(n)$ — всего $\mathcal{O}(n \log n)$
- LMO (argmin): один проход — $\mathcal{O}(n)$

При $n = 10000$ проекция дороже LMO **на порядок**.

В задачах, где градиент считается быстро (разреженная матрица), разница в стоимости шага между PGD и FW определяется именно проекцией/LMO.

Стоимость проекции vs LMO на симплексе (без вычисления градиента)





Ядерная норма: когда FW — единственный вариант

$$\min_{\|X\|_* \leq R} \frac{1}{2} \|X - B\|_F^2, \quad X \in \mathbb{R}^{n \times n}$$

- PGD: полное SVD $\mathcal{O}(n^3)$ на каждой итерации

По итерациям PGD выигрывает. Но стоимость одной итерации PGD растёт **кубически**: при $n = 800$ полное SVD в **75 раз** дороже rank-1 SVD.

Для матриц размера $10^4 \times 10^4$ и больше полное SVD вычислительно неподъёмно — FW становится единственным разумным методом.





Ядерная норма: когда FW — единственный вариант

$$\min_{\|X\|_* \leq R} \frac{1}{2} \|X - B\|_F^2, \quad X \in \mathbb{R}^{n \times n}$$

- PGD: полное SVD $\mathcal{O}(n^3)$ на каждой итерации
- FW: rank-1 SVD (power iteration) $\mathcal{O}(n^2)$

По итерациям PGD выигрывает. Но стоимость одной итерации PGD растёт **кубически**: при $n = 800$ полное SVD в **75 раз** дороже rank-1 SVD.

Для матриц размера $10^4 \times 10^4$ и больше полное SVD вычислительно неподъёмно — FW становится единственным разумным методом.



Ядерная норма: определение и свойства

i Ядерная норма (trace norm)

Ядерная норма матрицы $X \in \mathbb{R}^{m \times n}$ определяется как сумма её сингулярных чисел:

$$\|X\|_* = \sum_{i=1}^{\min(m,n)} \sigma_i(X) = \text{tr} \left(\sqrt{X^\top X} \right)$$

Ядерная норма: определение и свойства

i Ядерная норма (trace norm)

Ядерная норма матрицы $X \in \mathbb{R}^{m \times n}$ определяется как сумма её сингулярных чисел:

$$\|X\|_* = \sum_{i=1}^{\min(m,n)} \sigma_i(X) = \text{tr}(\sqrt{X^\top X})$$

- Ядерная норма — выпуклая оболочка ранга матрицы на единичном спектральном шаре:
 $\|X\|_* = \text{conv}(\text{rank}(X))$ при $\|X\|_{\text{op}} \leq 1$.

Ядерная норма: определение и свойства

i Ядерная норма (trace norm)

Ядерная норма матрицы $X \in \mathbb{R}^{m \times n}$ определяется как сумма её сингулярных чисел:

$$\|X\|_* = \sum_{i=1}^{\min(m,n)} \sigma_i(X) = \text{tr}(\sqrt{X^\top X})$$

- Ядерная норма — выпуклая оболочка ранга матрицы на единичном спектральном шаре:
 $\|X\|_* = \text{conv}(\text{rank}(X))$ при $\|X\|_{\text{op}} \leq 1$.
- Поэтому ограничение $\|X\|_* \leq R$ — стандартный выпуклый релаксант для ограничения на ранг.

Ядерная норма: определение и свойства

i Ядерная норма (trace norm)

Ядерная норма матрицы $X \in \mathbb{R}^{m \times n}$ определяется как сумма её сингулярных чисел:

$$\|X\|_* = \sum_{i=1}^{\min(m,n)} \sigma_i(X) = \text{tr}(\sqrt{X^\top X})$$

- Ядерная норма — выпуклая оболочка ранга матрицы на единичном спектральном шаре:
 $\|X\|_* = \text{conv}(\text{rank}(X))$ при $\|X\|_{\text{op}} \leq 1$.
- Поэтому ограничение $\|X\|_* \leq R$ — стандартный выпуклый релаксант для ограничения на ранг.
- Шар ядерной нормы $\mathcal{B}_* = \{X \in \mathbb{R}^{m \times n} \mid \|X\|_* \leq R\}$ — выпуклое компактное множество.

Ядерная норма: определение и свойства

i Ядерная норма (trace norm)

Ядерная норма матрицы $X \in \mathbb{R}^{m \times n}$ определяется как сумма её сингулярных чисел:

$$\|X\|_* = \sum_{i=1}^{\min(m,n)} \sigma_i(X) = \text{tr}(\sqrt{X^\top X})$$

- Ядерная норма — выпуклая оболочка ранга матрицы на единичном спектральном шаре:
 $\|X\|_* = \text{conv}(\text{rank}(X))$ при $\|X\|_{\text{op}} \leq 1$.
- Поэтому ограничение $\|X\|_* \leq R$ — стандартный выпуклый релаксант для ограничения на ранг.
- Шар ядерной нормы $\mathcal{B}_* = \{X \in \mathbb{R}^{m \times n} \mid \|X\|_* \leq R\}$ — выпуклое компактное множество.
- Крайние точки $\mathcal{B}_*$ — матрицы ранга 1 вида $R \cdot uv^\top$, где $\|u\|_2 = \|v\|_2 = 1$.

Ядерная норма: определение и свойства

i Ядерная норма (trace norm)

Ядерная норма матрицы $X \in \mathbb{R}^{m \times n}$ определяется как сумма её сингулярных чисел:

$$\|X\|_* = \sum_{i=1}^{\min(m,n)} \sigma_i(X) = \text{tr}(\sqrt{X^\top X})$$

- Ядерная норма — выпуклая оболочка ранга матрицы на единичном спектральном шаре:
 $\|X\|_* = \text{conv}(\text{rank}(X))$ при $\|X\|_{\text{op}} \leq 1$.
- Поэтому ограничение $\|X\|_* \leq R$ — стандартный выпуклый релаксант для ограничения на ранг.
- Шар ядерной нормы $\mathcal{B}_* = \{X \in \mathbb{R}^{m \times n} \mid \|X\|_* \leq R\}$ — выпуклое компактное множество.
- Крайние точки $\mathcal{B}_*$ — матрицы ранга 1 вида $R \cdot uv^\top$, где $\|u\|_2 = \|v\|_2 = 1$.

Ядерная норма: определение и свойства

i Ядерная норма (trace norm)

Ядерная норма матрицы $X \in \mathbb{R}^{m \times n}$ определяется как сумма её сингулярных чисел:

$$\|X\|_* = \sum_{i=1}^{\min(m,n)} \sigma_i(X) = \text{tr}(\sqrt{X^\top X})$$

- Ядерная норма — выпуклая оболочка ранга матрицы на единичном спектральном шаре:
 $\|X\|_* = \text{conv}(\text{rank}(X))$ при $\|X\|_{\text{op}} \leq 1$.
- Поэтому ограничение $\|X\|_* \leq R$ — стандартный выпуклый релаксант для ограничения на ранг.
- Шар ядерной нормы $\mathcal{B}_* = \{X \in \mathbb{R}^{m \times n} \mid \|X\|_* \leq R\}$ — выпуклое компактное множество.
- Крайние точки $\mathcal{B}_*$ — матрицы ранга 1 вида $R \cdot uv^\top$, где $\|u\|_2 = \|v\|_2 = 1$.

Приложения: matrix completion (рекомендательные системы), robust PCA, low-rank matrix recovery, сжатие нейронных сетей.

Итерации PGD и FW на шаре ядерной нормы

Задача: $\min_{\|X\|_* \leq R} f(X)$, где $X \in \mathbb{R}^{m \times n}$.

Итерации PGD и FW на шаре ядерной нормы

Задача: $\min_{\|X\|_* \leq R} f(X)$, где $X \in \mathbb{R}^{m \times n}$.

Итерация PGD

$$X_{k+1} = \text{proj}_{\mathcal{B}_*}(X_k - \alpha \nabla f(X_k))$$

1. Вычислить $Y = X_k - \alpha \nabla f(X_k)$

Итерации PGD и FW на шаре ядерной нормы

Задача: $\min_{\|X\|_* \leq R} f(X)$, где $X \in \mathbb{R}^{m \times n}$.

Итерация PGD

$$X_{k+1} = \text{proj}_{\mathcal{B}_*}(X_k - \alpha \nabla f(X_k))$$

1. Вычислить $Y = X_k - \alpha \nabla f(X_k)$
2. **Полное SVD:** $Y = U \Sigma V^\top$ — стоимость $\mathcal{O}(mn \cdot \min(m, n))$

Итерации PGD и FW на шаре ядерной нормы

Задача: $\min_{\|X\|_* \leq R} f(X)$, где $X \in \mathbb{R}^{m \times n}$.

Итерация PGD

$$X_{k+1} = \text{proj}_{\mathcal{B}_*}(X_k - \alpha \nabla f(X_k))$$

1. Вычислить $Y = X_k - \alpha \nabla f(X_k)$
2. **Полное SVD:** $Y = U \Sigma V^\top$ — стоимость $\mathcal{O}(mn \cdot \min(m, n))$
3. Мягкое пороговое отсечение (soft thresholding) сингулярных чисел для проекции на $\mathcal{B}_*$:

$$\text{proj}_{\mathcal{B}_*}(Y) = U \cdot \text{diag}(\max(\sigma_i - \lambda, 0)) \cdot V^\top$$

где $\lambda \geq 0$ выбирается так, чтобы
 $\sum_i \max(\sigma_i - \lambda, 0) = R$.

Итерации PGD и FW на шаре ядерной нормы

Задача: $\min_{\|X\|_* \leq R} f(X)$, где $X \in \mathbb{R}^{m \times n}$.

Итерация PGD

$$X_{k+1} = \text{proj}_{\mathcal{B}_*}(X_k - \alpha \nabla f(X_k))$$

1. Вычислить $Y = X_k - \alpha \nabla f(X_k)$
2. **Полное SVD:** $Y = U \Sigma V^\top$ — стоимость $\mathcal{O}(mn \cdot \min(m, n))$
3. Мягкое пороговое отсечение (soft thresholding) сингулярных чисел для проекции на $\mathcal{B}_*$:

$$\text{proj}_{\mathcal{B}_*}(Y) = U \cdot \text{diag}(\max(\sigma_i - \lambda, 0)) \cdot V^\top$$

где $\lambda \geq 0$ выбирается так, чтобы
 $\sum_i \max(\sigma_i - \lambda, 0) = R$.

Итерации PGD и FW на шаре ядерной нормы

Задача: $\min_{\|X\|_* \leq R} f(X)$, где $X \in \mathbb{R}^{m \times n}$.

Итерация PGD

$$X_{k+1} = \text{proj}_{\mathcal{B}_*}(X_k - \alpha \nabla f(X_k))$$

1. Вычислить $Y = X_k - \alpha \nabla f(X_k)$
2. **Полное SVD:** $Y = U \Sigma V^\top$ — стоимость $\mathcal{O}(mn \cdot \min(m, n))$
3. Мягкое пороговое отсечение (soft thresholding) сингулярных чисел для проекции на $\mathcal{B}_*$:

$$\text{proj}_{\mathcal{B}_*}(Y) = U \cdot \text{diag}(\max(\sigma_i - \lambda, 0)) \cdot V^\top$$

где $\lambda \geq 0$ выбирается так, чтобы
 $\sum_i \max(\sigma_i - \lambda, 0) = R$.

Итерация FW

$$S_k = \arg \min_{\|S\|_* \leq R} \langle \nabla f(X_k), S \rangle$$

$$X_{k+1} = (1 - \gamma_k) X_k + \gamma_k S_k$$

1. Вычислить $G = \nabla f(X_k)$

Бонус: X_k имеет ранг $\leq k$ после k итераций.

Итерации PGD и FW на шаре ядерной нормы

Задача: $\min_{\|X\|_* \leq R} f(X)$, где $X \in \mathbb{R}^{m \times n}$.

Итерация PGD

$$X_{k+1} = \text{proj}_{\mathcal{B}_*}(X_k - \alpha \nabla f(X_k))$$

1. Вычислить $Y = X_k - \alpha \nabla f(X_k)$
2. **Полное SVD:** $Y = U \Sigma V^\top$ — стоимость $\mathcal{O}(mn \cdot \min(m, n))$
3. Мягкое пороговое отсечение (soft thresholding) сингулярных чисел для проекции на $\mathcal{B}_*$:

$$\text{proj}_{\mathcal{B}_*}(Y) = U \cdot \text{diag}(\max(\sigma_i - \lambda, 0)) \cdot V^\top$$

где $\lambda \geq 0$ выбирается так, чтобы $\sum_i \max(\sigma_i - \lambda, 0) = R$.

Итерация FW

$$S_k = \arg \min_{\|S\|_* \leq R} \langle \nabla f(X_k), S \rangle$$

$$X_{k+1} = (1 - \gamma_k) X_k + \gamma_k S_k$$

1. Вычислить $G = \nabla f(X_k)$
2. **Rank-1 SVD** (степенная итерация): найти ведущие сингулярные векторы u_1, v_1 матрицы $-G$ — стоимость $\mathcal{O}(\text{nnz}(G))$

Бонус: X_k имеет ранг $\leq k$ после k итераций.

Итерации PGD и FW на шаре ядерной нормы

Задача: $\min_{\|X\|_* \leq R} f(X)$, где $X \in \mathbb{R}^{m \times n}$.

Итерация PGD

$$X_{k+1} = \text{proj}_{\mathcal{B}_*}(X_k - \alpha \nabla f(X_k))$$

1. Вычислить $Y = X_k - \alpha \nabla f(X_k)$
2. **Полное SVD:** $Y = U \Sigma V^\top$ — стоимость $\mathcal{O}(mn \cdot \min(m, n))$
3. Мягкое пороговое отсечение (soft thresholding) сингулярных чисел для проекции на $\mathcal{B}_*$:

$$\text{proj}_{\mathcal{B}_*}(Y) = U \cdot \text{diag}(\max(\sigma_i - \lambda, 0)) \cdot V^\top$$

где $\lambda \geq 0$ выбирается так, чтобы $\sum_i \max(\sigma_i - \lambda, 0) = R$.

Итерация FW

$$S_k = \arg \min_{\|S\|_* \leq R} \langle \nabla f(X_k), S \rangle$$

$$X_{k+1} = (1 - \gamma_k) X_k + \gamma_k S_k$$

1. Вычислить $G = \nabla f(X_k)$
2. **Rank-1 SVD** (степенная итерация): найти ведущие сингулярные векторы u_1, v_1 матрицы $-G$ — стоимость $\mathcal{O}(\text{nnz}(G))$
3. $S_k = R \cdot u_1 v_1^\top$ — ранг-1 матрица

Бонус: X_k имеет ранг $\leq k$ после k итераций.

Итерации PGD и FW на шаре ядерной нормы

Задача: $\min_{\|X\|_* \leq R} f(X)$, где $X \in \mathbb{R}^{m \times n}$.

Итерация PGD

$$X_{k+1} = \text{proj}_{\mathcal{B}_*}(X_k - \alpha \nabla f(X_k))$$

1. Вычислить $Y = X_k - \alpha \nabla f(X_k)$
2. **Полное SVD:** $Y = U \Sigma V^\top$ — стоимость $\mathcal{O}(mn \cdot \min(m, n))$
3. Мягкое пороговое отсечение (soft thresholding) сингулярных чисел для проекции на $\mathcal{B}_*$:

$$\text{proj}_{\mathcal{B}_*}(Y) = U \cdot \text{diag}(\max(\sigma_i - \lambda, 0)) \cdot V^\top$$

где $\lambda \geq 0$ выбирается так, чтобы
 $\sum_i \max(\sigma_i - \lambda, 0) = R$.

Итерация FW

$$S_k = \arg \min_{\|S\|_* \leq R} \langle \nabla f(X_k), S \rangle$$

$$X_{k+1} = (1 - \gamma_k)X_k + \gamma_k S_k$$

1. Вычислить $G = \nabla f(X_k)$
 2. **Rank-1 SVD** (степенная итерация): найти ведущие сингулярные векторы u_1, v_1 матрицы $-G$ — стоимость $\mathcal{O}(\text{nnz}(G))$
 3. $S_k = R \cdot u_1 v_1^\top$ — ранг-1 матрица
 4. $X_{k+1} = (1 - \gamma_k)X_k + \gamma_k S_k$
- Бонус:** X_k имеет ранг $\leq k$ после k итераций.

FW побеждает: matrix completion + ядерная норма

Задача: matrix completion с ограничением

$$\|X\|_* \leq R:$$



$$\min_{\|X\|_* \leq R} \frac{1}{2} \sum_{(i,j) \in \Omega} (X_{ij} - B_{ij})^2$$

Ключ: градиент ∇f **разрежен** (ненулевой только на Ω).

- Степенная итерация для rank-1 SVD на разреженном ∇f : $\mathcal{O}(|\Omega|)$

FW компенсирует медленную сходимость $\mathcal{O}(1/k)$ огромным числом дешёвых итераций и **побеждает PGD по времени**.

Matrix completion + ядерная норма: FW побеждает по времени



FW побеждает: matrix completion + ядерная норма

Задача: matrix completion с ограничением

$$\|X\|_* \leq R:$$



$$\min_{\|X\|_* \leq R} \frac{1}{2} \sum_{(i,j) \in \Omega} (X_{ij} - B_{ij})^2$$

Ключ: градиент ∇f **разрежен** (ненулевой только на Ω).

- Степенная итерация для rank-1 SVD на разреженном ∇f : $\mathcal{O}(|\Omega|)$
- Полное SVD плотной матрицы Y : $\mathcal{O}(n^3)$

FW компенсирует медленную сходимость $\mathcal{O}(1/k)$ огромным числом дешёвых итераций и **побеждает PGD по времени**.

Matrix completion + ядерная норма: FW побеждает по времени



FW побеждает: matrix completion + ядерная норма

Задача: matrix completion с ограничением

$$\|X\|_* \leq R:$$



$$\min_{\|X\|_* \leq R} \frac{1}{2} \sum_{(i,j) \in \Omega} (X_{ij} - B_{ij})^2$$

Ключ: градиент ∇f **разрежен** (ненулевой только на Ω).

- Степенная итерация для rank-1 SVD на разреженном ∇f : $\mathcal{O}(|\Omega|)$
- Полное SVD плотной матрицы Y : $\mathcal{O}(n^3)$
- При $n = 2500$, $|\Omega| = 3\% \cdot n^2$:
отношение $\approx 900\times$

FW компенсирует медленную сходимость $\mathcal{O}(1/k)$ огромным числом дешёвых итераций и **побеждает PGD по времени**.

Matrix completion + ядерная норма: FW побеждает по времени



Matrix completion: почему ядерная норма?

Задача восстановления матрицы. Дана матрица $B \in \mathbb{R}^{m \times n}$, наблюдаемая лишь на подмножестве индексов $\Omega \subset [m] \times [n]$. Нужно восстановить всю матрицу, предполагая, что она имеет малый ранг.

Matrix completion: почему ядерная норма?

Задача восстановления матрицы. Дана матрица $B \in \mathbb{R}^{m \times n}$, наблюдаемая лишь на подмножестве индексов $\Omega \subset [m] \times [n]$. Нужно восстановить всю матрицу, предполагая, что она имеет малый ранг.

Некорректная (невыпуклая) постановка

$$\min_X \frac{1}{2} \sum_{(i,j) \in \Omega} (X_{ij} - B_{ij})^2 \quad \text{s.t.} \quad \text{rank}(X) \leq r$$

- Ограничение $\text{rank}(X) \leq r$ — невыпуклое

Matrix completion: почему ядерная норма?

Задача восстановления матрицы. Дана матрица $B \in \mathbb{R}^{m \times n}$, наблюдаемая лишь на подмножестве индексов $\Omega \subset [m] \times [n]$. Нужно восстановить всю матрицу, предполагая, что она имеет малый ранг.

Некорректная (невыпуклая) постановка

$$\min_X \frac{1}{2} \sum_{(i,j) \in \Omega} (X_{ij} - B_{ij})^2 \quad \text{s.t.} \quad \text{rank}(X) \leq r$$

- Ограничение $\text{rank}(X) \leq r$ — **невыпуклое**
- NP-трудная задача в общем случае

Matrix completion: почему ядерная норма?

Задача восстановления матрицы. Дана матрица $B \in \mathbb{R}^{m \times n}$, наблюдаемая лишь на подмножестве индексов $\Omega \subset [m] \times [n]$. Нужно восстановить всю матрицу, предполагая, что она имеет малый ранг.

Некорректная (невыпуклая) постановка

$$\min_X \frac{1}{2} \sum_{(i,j) \in \Omega} (X_{ij} - B_{ij})^2 \quad \text{s.t.} \quad \text{rank}(X) \leq r$$

- Ограничение $\text{rank}(X) \leq r$ — **невыпуклое**
- NP-трудная задача в общем случае
- Нет гарантий глобальной оптимальности

Matrix completion: почему ядерная норма?

Задача восстановления матрицы. Дана матрица $B \in \mathbb{R}^{m \times n}$, наблюдаемая лишь на подмножестве индексов $\Omega \subset [m] \times [n]$. Нужно восстановить всю матрицу, предполагая, что она имеет малый ранг.

Некорректная (невыпуклая) постановка

$$\min_X \frac{1}{2} \sum_{(i,j) \in \Omega} (X_{ij} - B_{ij})^2 \quad \text{s.t.} \quad \text{rank}(X) \leq r$$

- Ограничение $\text{rank}(X) \leq r$ — **невыпуклое**
- NP-трудная задача в общем случае
- Нет гарантий глобальной оптимальности

Matrix completion: почему ядерная норма?

Задача восстановления матрицы. Дана матрица $B \in \mathbb{R}^{m \times n}$, наблюдаемая лишь на подмножестве индексов $\Omega \subset [m] \times [n]$. Нужно восстановить всю матрицу, предполагая, что она имеет малый ранг.

Некорректная (невыпуклая) постановка

$$\min_X \frac{1}{2} \sum_{(i,j) \in \Omega} (X_{ij} - B_{ij})^2 \quad \text{s.t.} \quad \text{rank}(X) \leq r$$

- Ограничение $\text{rank}(X) \leq r$ — **невыпуклое**
- NP-трудная задача в общем случае
- Нет гарантий глобальной оптимальности

Выпуклая релаксация

$$\min_X \frac{1}{2} \sum_{(i,j) \in \Omega} (X_{ij} - B_{ij})^2 \quad \text{s.t.} \quad \|X\|_* \leq R$$

- Ядерная норма — **выпуклая оболочка** ранга

Matrix completion: почему ядерная норма?

Задача восстановления матрицы. Дана матрица $B \in \mathbb{R}^{m \times n}$, наблюдаемая лишь на подмножестве индексов $\Omega \subset [m] \times [n]$. Нужно восстановить всю матрицу, предполагая, что она имеет малый ранг.

Некорректная (невыпуклая) постановка

$$\min_X \frac{1}{2} \sum_{(i,j) \in \Omega} (X_{ij} - B_{ij})^2 \quad \text{s.t.} \quad \text{rank}(X) \leq r$$

- Ограничение $\text{rank}(X) \leq r$ — **невыпуклое**
- NP-трудная задача в общем случае
- Нет гарантий глобальной оптимальности

Выпуклая релаксация

$$\min_X \frac{1}{2} \sum_{(i,j) \in \Omega} (X_{ij} - B_{ij})^2 \quad \text{s.t.} \quad \|X\|_* \leq R$$

- Ядерная норма — **выпуклая оболочка** ранга
- Задача выпуклая, можно применять PGD и FW

Matrix completion: почему ядерная норма?

Задача восстановления матрицы. Дана матрица $B \in \mathbb{R}^{m \times n}$, наблюдаемая лишь на подмножестве индексов $\Omega \subset [m] \times [n]$. Нужно восстановить всю матрицу, предполагая, что она имеет малый ранг.

Некорректная (невыпуклая) постановка

$$\min_X \frac{1}{2} \sum_{(i,j) \in \Omega} (X_{ij} - B_{ij})^2 \quad \text{s.t.} \quad \text{rank}(X) \leq r$$

- Ограничение $\text{rank}(X) \leq r$ — **невыпуклое**
- NP-трудная задача в общем случае
- Нет гарантий глобальной оптимальности

Выпуклая релаксация

$$\min_X \frac{1}{2} \sum_{(i,j) \in \Omega} (X_{ij} - B_{ij})^2 \quad \text{s.t.} \quad \|X\|_* \leq R$$

- Ядерная норма — **выпуклая оболочка** ранга
- Задача выпуклая, можно применять PGD и FW
- Гарантии точного восстановления при определённых условиях ⁵

⁵  Candès, Recht. Exact Matrix Completion via Convex Optimization.

Matrix completion: почему ядерная норма?

Задача восстановления матрицы. Дана матрица $B \in \mathbb{R}^{m \times n}$, наблюдаемая лишь на подмножестве индексов $\Omega \subset [m] \times [n]$. Нужно восстановить всю матрицу, предполагая, что она имеет малый ранг.

Некорректная (невыпуклая) постановка

$$\min_X \frac{1}{2} \sum_{(i,j) \in \Omega} (X_{ij} - B_{ij})^2 \quad \text{s.t.} \quad \text{rank}(X) \leq r$$

- Ограничение $\text{rank}(X) \leq r$ — **невыпуклое**
- NP-трудная задача в общем случае
- Нет гарантий глобальной оптимальности

Выпуклая релаксация

$$\min_X \frac{1}{2} \sum_{(i,j) \in \Omega} (X_{ij} - B_{ij})^2 \quad \text{s.t.} \quad \|X\|_* \leq R$$

- Ядерная норма — **выпуклая оболочка** ранга
- Задача выпуклая, можно применять PGD и FW
- Гарантии точного восстановления при определённых условиях ⁵

⁵  Candès, Recht. Exact Matrix Completion via Convex Optimization.

Matrix completion: почему ядерная норма?

Задача восстановления матрицы. Дана матрица $B \in \mathbb{R}^{m \times n}$, наблюдаемая лишь на подмножестве индексов $\Omega \subset [m] \times [n]$. Нужно восстановить всю матрицу, предполагая, что она имеет малый ранг.

Некорректная (невыпуклая) постановка

Выпуклая релаксация

$$\min_X \frac{1}{2} \sum_{(i,j) \in \Omega} (X_{ij} - B_{ij})^2 \quad \text{s.t.} \quad \text{rank}(X) \leq r$$

- Ограничение $\text{rank}(X) \leq r$ — **невыпуклое**
- NP-трудная задача в общем случае
- Нет гарантий глобальной оптимальности

$$\min_X \frac{1}{2} \sum_{(i,j) \in \Omega} (X_{ij} - B_{ij})^2 \quad \text{s.t.} \quad \|X\|_* \leq R$$

- Ядерная норма — **выпуклая оболочка** ранга
- Задача выпуклая, можно применять PGD и FW
- Гарантии точного восстановления при определённых условиях ⁵

Пример из практики: Netflix Prize — предсказание оценок пользователей для фильмов. Матрица $\sim 500K \times 17K$, известно $\sim 1\%$ записей. Ядерная норма + FW позволяют эффективно решать эту задачу.

⁵ Candès, Recht. Exact Matrix Completion via Convex Optimization.

Метод зеркального спуска

Мотивация: зачем нужен зеркальный спуск?

Вспомним итерацию метода проекции градиента:

$$x_{k+1} = \text{proj}_S(x_k - \alpha_k \nabla f(x_k))$$

Мотивация: зачем нужен зеркальный спуск?

Вспомним итерацию метода проекции градиента:

$$x_{k+1} = \text{proj}_S(x_k - \alpha_k \nabla f(x_k))$$

Эта формула опирается на **евклидову норму** $\|\cdot\|_2$, как в шаге градиента, так и в проекции. Но что, если:

- Геометрия задачи **неевклидова**? Например, оптимизация на симплексе $\Delta_n = \{x \geq 0, \mathbf{1}^\top x = 1\}$ — естественная геометрия описывается не ℓ_2 , а ℓ_1 -нормой.

Мотивация: зачем нужен зеркальный спуск?

Вспомним итерацию метода проекции градиента:

$$x_{k+1} = \text{proj}_S(x_k - \alpha_k \nabla f(x_k))$$

Эта формула опирается на **евклидову норму** $\|\cdot\|_2$, как в шаге градиента, так и в проекции. Но что, если:

- Геометрия задачи **неевклидова**? Например, оптимизация на симплексе $\Delta_n = \{x \geq 0, \mathbf{1}^\top x = 1\}$ — естественная геометрия описывается не ℓ_2 , а ℓ_1 -нормой.
- Функция f гладкая относительно **неевклидовой** нормы $\|\cdot\|$?

$$f(y) \leq f(x) + \langle \nabla f(x), y - x \rangle + \frac{L}{2} \|y - x\|^2$$

Мотивация: зачем нужен зеркальный спуск?

Вспомним итерацию метода проекции градиента:

$$x_{k+1} = \text{proj}_S(x_k - \alpha_k \nabla f(x_k))$$

Эта формула опирается на **евклидову норму** $\|\cdot\|_2$, как в шаге градиента, так и в проекции. Но что, если:

- Геометрия задачи **неевклидова**? Например, оптимизация на симплексе $\Delta_n = \{x \geq 0, \mathbf{1}^\top x = 1\}$ — естественная геометрия описывается не ℓ_2 , а ℓ_1 -нормой.
- Функция f гладкая относительно **неевклидовой** нормы $\|\cdot\|$?

$$f(y) \leq f(x) + \langle \nabla f(x), y - x \rangle + \frac{L}{2} \|y - x\|^2$$

Мотивация: зачем нужен зеркальный спуск?

Вспомним итерацию метода проекции градиента:

$$x_{k+1} = \text{proj}_S(x_k - \alpha_k \nabla f(x_k))$$

Эта формула опирается на **евклидову норму** $\|\cdot\|_2$, как в шаге градиента, так и в проекции. Но что, если:

- Геометрия задачи **неевклидова**? Например, оптимизация на симплексе $\Delta_n = \{x \geq 0, \mathbf{1}^\top x = 1\}$ — естественная геометрия описывается не ℓ_2 , а ℓ_1 -нормой.
- Функция f гладкая относительно **неевклидовой** нормы $\|\cdot\|$?

$$f(y) \leq f(x) + \langle \nabla f(x), y - x \rangle + \frac{L}{2} \|y - x\|^2$$

Проблема: PGD с евклидовой проекцией может давать оценку $\mathcal{O}\left(\frac{L_2 R_2^2}{k}\right)$, но L_2 и R_2 могут **зависеть от размерности** n , что делает оценку бессмысленной для задач большой размерности.

Мотивация: пример на симплексе

Рассмотрим задачу на стандартном симплексе $\Delta_n = \{x \in \mathbb{R}^n \mid x \geq 0, \mathbf{1}^\top x = 1\}$:

$$\min_{x \in \Delta_n} f(x)$$

Мотивация: пример на симплексе

Рассмотрим задачу на стандартном симплексе $\Delta_n = \{x \in \mathbb{R}^n \mid x \geq 0, \mathbf{1}^\top x = 1\}$:

$$\min_{x \in \Delta_n} f(x)$$

Пусть f является L_1 -гладкой относительно ℓ_1 -нормы: $f(y) \leq f(x) + \langle \nabla f(x), y - x \rangle + \frac{L_1}{2} \|y - x\|_1^2$.

Мотивация: пример на симплексе

Рассмотрим задачу на стандартном симплексе $\Delta_n = \{x \in \mathbb{R}^n \mid x \geq 0, \mathbf{1}^\top x = 1\}$:

$$\min_{x \in \Delta_n} f(x)$$

Пусть f является L_1 -гладкой относительно ℓ_1 -нормы: $f(y) \leq f(x) + \langle \nabla f(x), y - x \rangle + \frac{L_1}{2} \|y - x\|_1^2$.

PGD (евклидова геометрия)

- Гладкость: $L_2 \leq n \cdot L_1$ (из $\|x\|_2 \leq \|x\|_1$)

Мотивация: пример на симплексе

Рассмотрим задачу на стандартном симплексе $\Delta_n = \{x \in \mathbb{R}^n \mid x \geq 0, \mathbf{1}^\top x = 1\}$:

$$\min_{x \in \Delta_n} f(x)$$

Пусть f является L_1 -гладкой относительно ℓ_1 -нормы: $f(y) \leq f(x) + \langle \nabla f(x), y - x \rangle + \frac{L_1}{2} \|y - x\|_1^2$.

PGD (евклидова геометрия)

- Гладкость: $L_2 \leq n \cdot L_1$ (из $\|x\|_2 \leq \|x\|_1$)
- Диаметр: $R_2 = \sqrt{2}$

Мотивация: пример на симплексе

Рассмотрим задачу на стандартном симплексе $\Delta_n = \{x \in \mathbb{R}^n \mid x \geq 0, \mathbf{1}^\top x = 1\}$:

$$\min_{x \in \Delta_n} f(x)$$

Пусть f является L_1 -гладкой относительно ℓ_1 -нормы: $f(y) \leq f(x) + \langle \nabla f(x), y - x \rangle + \frac{L_1}{2} \|y - x\|_1^2$.

PGD (евклидова геометрия)

- Гладкость: $L_2 \leq n \cdot L_1$ (из $\|x\|_2 \leq \|x\|_1$)
- Диаметр: $R_2 = \sqrt{2}$
- Оценка:

$$f(x_k) - f^* \leq \frac{n \cdot L_1 \cdot 2}{2k} = \frac{nL_1}{k}$$

Мотивация: пример на симплексе

Рассмотрим задачу на стандартном симплексе $\Delta_n = \{x \in \mathbb{R}^n \mid x \geq 0, \mathbf{1}^\top x = 1\}$:

$$\min_{x \in \Delta_n} f(x)$$

Пусть f является L_1 -гладкой относительно ℓ_1 -нормы: $f(y) \leq f(x) + \langle \nabla f(x), y - x \rangle + \frac{L_1}{2} \|y - x\|_1^2$.

PGD (евклидова геометрия)

- Гладкость: $L_2 \leq n \cdot L_1$ (из $\|x\|_2 \leq \|x\|_1$)
- Диаметр: $R_2 = \sqrt{2}$
- Оценка:

$$f(x_k) - f^* \leq \frac{n \cdot L_1 \cdot 2}{2k} = \frac{nL_1}{k}$$

Мотивация: пример на симплексе

Рассмотрим задачу на стандартном симплексе $\Delta_n = \{x \in \mathbb{R}^n \mid x \geq 0, \mathbf{1}^\top x = 1\}$:

$$\min_{x \in \Delta_n} f(x)$$

Пусть f является L_1 -гладкой относительно ℓ_1 -нормы: $f(y) \leq f(x) + \langle \nabla f(x), y - x \rangle + \frac{L_1}{2} \|y - x\|_1^2$.

PGD (евклидова геометрия)

- Гладкость: $L_2 \leq n \cdot L_1$ (из $\|x\|_2 \leq \|x\|_1$)
- Диаметр: $R_2 = \sqrt{2}$
- Оценка:

$$f(x_k) - f^* \leq \frac{n \cdot L_1 \cdot 2}{2k} = \frac{nL_1}{k}$$

Зеркальный спуск (ℓ_1 -геометрия)

- Гладкость: L_1 (без множителя!)

Мотивация: пример на симплексе

Рассмотрим задачу на стандартном симплексе $\Delta_n = \{x \in \mathbb{R}^n \mid x \geq 0, \mathbf{1}^\top x = 1\}$:

$$\min_{x \in \Delta_n} f(x)$$

Пусть f является L_1 -гладкой относительно ℓ_1 -нормы: $f(y) \leq f(x) + \langle \nabla f(x), y - x \rangle + \frac{L_1}{2} \|y - x\|_1^2$.

PGD (евклидова геометрия)

- Гладкость: $L_2 \leq n \cdot L_1$ (из $\|x\|_2 \leq \|x\|_1$)
- Диаметр: $R_2 = \sqrt{2}$
- Оценка:

$$f(x_k) - f^* \leq \frac{n \cdot L_1 \cdot 2}{2k} = \frac{nL_1}{k}$$

Зеркальный спуск (ℓ_1 -геометрия)

- Гладкость: L_1 (без множителя!)
- «Диаметр»: $R_1 = \sqrt{2 \ln n}$ (в смысле дивергенции Брэгмана)

Мотивация: пример на симплексе

Рассмотрим задачу на стандартном симплексе $\Delta_n = \{x \in \mathbb{R}^n \mid x \geq 0, \mathbf{1}^\top x = 1\}$:

$$\min_{x \in \Delta_n} f(x)$$

Пусть f является L_1 -гладкой относительно ℓ_1 -нормы: $f(y) \leq f(x) + \langle \nabla f(x), y - x \rangle + \frac{L_1}{2} \|y - x\|_1^2$.

PGD (евклидова геометрия)

- Гладкость: $L_2 \leq n \cdot L_1$ (из $\|x\|_2 \leq \|x\|_1$)
- Диаметр: $R_2 = \sqrt{2}$
- Оценка:

$$f(x_k) - f^* \leq \frac{n \cdot L_1 \cdot 2}{2k} = \frac{nL_1}{k}$$

Зеркальный спуск (ℓ_1 -геометрия)

- Гладкость: L_1 (без множителя!)
- «Диаметр»: $R_1 = \sqrt{2 \ln n}$ (в смысле дивергенции Брэгмана)
- Оценка:

$$f(x_k) - f^* \leq \frac{L_1 \cdot 2 \ln n}{2k} = \frac{L_1 \ln n}{k}$$

Мотивация: пример на симплексе

Рассмотрим задачу на стандартном симплексе $\Delta_n = \{x \in \mathbb{R}^n \mid x \geq 0, \mathbf{1}^\top x = 1\}$:

$$\min_{x \in \Delta_n} f(x)$$

Пусть f является L_1 -гладкой относительно ℓ_1 -нормы: $f(y) \leq f(x) + \langle \nabla f(x), y - x \rangle + \frac{L_1}{2} \|y - x\|_1^2$.

PGD (евклидова геометрия)

- Гладкость: $L_2 \leq n \cdot L_1$ (из $\|x\|_2 \leq \|x\|_1$)
- Диаметр: $R_2 = \sqrt{2}$
- Оценка:

$$f(x_k) - f^* \leq \frac{n \cdot L_1 \cdot 2}{2k} = \frac{nL_1}{k}$$

Зеркальный спуск (ℓ_1 -геометрия)

- Гладкость: L_1 (без множителя!)
- «Диаметр»: $R_1 = \sqrt{2 \ln n}$ (в смысле дивергенции Брэгмана)
- Оценка:

$$f(x_k) - f^* \leq \frac{L_1 \cdot 2 \ln n}{2k} = \frac{L_1 \ln n}{k}$$

Мотивация: пример на симплексе

Рассмотрим задачу на стандартном симплексе $\Delta_n = \{x \in \mathbb{R}^n \mid x \geq 0, \mathbf{1}^\top x = 1\}$:

$$\min_{x \in \Delta_n} f(x)$$

Пусть f является L_1 -гладкой относительно ℓ_1 -нормы: $f(y) \leq f(x) + \langle \nabla f(x), y - x \rangle + \frac{L_1}{2} \|y - x\|_1^2$.

PGD (евклидова геометрия)

- Гладкость: $L_2 \leq n \cdot L_1$ (из $\|x\|_2 \leq \|x\|_1$)
- Диаметр: $R_2 = \sqrt{2}$
- Оценка:

$$f(x_k) - f^* \leq \frac{n \cdot L_1 \cdot 2}{2k} = \frac{nL_1}{k}$$

Зеркальный спуск (ℓ_1 -геометрия)

- Гладкость: L_1 (без множителя!)
- «Диаметр»: $R_1 = \sqrt{2 \ln n}$ (в смысле дивергенции Брэгмана)
- Оценка:

$$f(x_k) - f^* \leq \frac{L_1 \cdot 2 \ln n}{2k} = \frac{L_1 \ln n}{k}$$

Выигрыш: $\frac{n}{\ln n}$ — экспоненциальный по размерности!

Мотивация: прямое и двойственное пространство

Идея. Градиент $\nabla f(x)$ живёт в **двойственном** пространстве $(\mathbb{R}^n)^*$ с нормой $\|\cdot\|_*$, а переменная x — в **прямом** пространстве $\mathbb{R}^n$ с нормой $\|\cdot\|$.

Мотивация: прямое и двойственное пространство

Идея. Градиент $\nabla f(x)$ живёт в **двойственном** пространстве $(\mathbb{R}^n)^*$ с нормой $\|\cdot\|_*$, а переменная x — в **прямом** пространстве $\mathbb{R}^n$ с нормой $\|\cdot\|$.

В PGD мы неявно отождествляем прямое и двойственное пространство (что корректно только для ℓ_2):

$$x_{k+1} = x_k - \alpha_k \nabla f(x_k)$$

Вычитаем **градиент** (двойственный вектор) из **точки** (прямой вектор) напрямую.

Мотивация: прямое и двойственное пространство

Идея. Градиент $\nabla f(x)$ живёт в **двойственном** пространстве $(\mathbb{R}^n)^*$ с нормой $\|\cdot\|_*$, а переменная x — в **прямом** пространстве $\mathbb{R}^n$ с нормой $\|\cdot\|$.

В PGD мы неявно отождествляем прямое и двойственное пространство (что корректно только для ℓ_2):

$$x_{k+1} = x_k - \alpha_k \nabla f(x_k)$$

Вычитаем **градиент** (двойственный вектор) из **точки** (прямой вектор) напрямую.

В зеркальном спуске мы **явно** работаем с двумя пространствами через **зеркальное отображение** $\nabla\omega$:

$$\begin{aligned}\nabla\omega(y_{k+1}) &= \nabla\omega(x_k) - \alpha_k \nabla f(x_k) \\ x_{k+1} &= \nabla\omega^*(y_{k+1})\end{aligned}$$

Шаг делается в двойственном пространстве, затем результат отображается обратно.

Мотивация: прямое и двойственное пространство

Идея. Градиент $\nabla f(x)$ живёт в **двойственном** пространстве $(\mathbb{R}^n)^*$ с нормой $\|\cdot\|_*$, а переменная x — в **прямом** пространстве $\mathbb{R}^n$ с нормой $\|\cdot\|$.

В PGD мы неявно отождествляем прямое и двойственное пространство (что корректно только для ℓ_2):

$$x_{k+1} = x_k - \alpha_k \nabla f(x_k)$$

Вычитаем **градиент** (двойственный вектор) из **точки** (прямой вектор) напрямую.

Функция ω называется **прокс-функцией** (distance-generating function). Она задаёт геометрию через дивергенцию Брэгмана.

В зеркальном спуске мы **явно** работаем с двумя пространствами через **зеркальное отображение** $\nabla\omega$:

$$\begin{aligned}\nabla\omega(y_{k+1}) &= \nabla\omega(x_k) - \alpha_k \nabla f(x_k) \\ x_{k+1} &= \nabla\omega^*(y_{k+1})\end{aligned}$$

Шаг делается в двойственном пространстве, затем результат отображается обратно.

Дивергенция Брэгмана

i Дивергенция Брэгмана

Пусть $\omega : \mathbb{R}^n \rightarrow \mathbb{R}$ — непрерывно дифференцируемая и строго выпуклая функция. **Дивергенция Брэгмана**, порождённая функцией ω , определяется как:

$$V_{\omega}(x, y) = \omega(x) - \omega(y) - \langle \nabla \omega(y), x - y \rangle$$

Дивергенция Брэгмана

i Дивергенция Брэгмана

Пусть $\omega : \mathbb{R}^n \rightarrow \mathbb{R}$ — непрерывно дифференцируемая и строго выпуклая функция. **Дивергенция Брэгмана**, порождённая функцией ω , определяется как:

$$V_{\omega}(x, y) = \omega(x) - \omega(y) - \langle \nabla \omega(y), x - y \rangle$$

Свойства:

- $V_{\omega}(x, y) \geq 0$ для всех x, y (из строгой выпуклости ω).

Дивергенция Брэгмана

i Дивергенция Брэгмана

Пусть $\omega : \mathbb{R}^n \rightarrow \mathbb{R}$ — непрерывно дифференцируемая и строго выпуклая функция. **Дивергенция Брэгмана**, порождённая функцией ω , определяется как:

$$V_{\omega}(x, y) = \omega(x) - \omega(y) - \langle \nabla \omega(y), x - y \rangle$$

Свойства:

- $V_{\omega}(x, y) \geq 0$ для всех x, y (из строгой выпуклости ω).
- $V_{\omega}(x, y) = 0 \Leftrightarrow x = y$.

Дивергенция Брэгмана

i Дивергенция Брэгмана

Пусть $\omega : \mathbb{R}^n \rightarrow \mathbb{R}$ — непрерывно дифференцируемая и строго выпуклая функция. **Дивергенция Брэгмана**, порождённая функцией ω , определяется как:

$$V_{\omega}(x, y) = \omega(x) - \omega(y) - \langle \nabla \omega(y), x - y \rangle$$

Свойства:

- $V_{\omega}(x, y) \geq 0$ для всех x, y (из строгой выпуклости ω).
- $V_{\omega}(x, y) = 0 \Leftrightarrow x = y$.
- **Не симметрична** в общем случае: $V_{\omega}(x, y) \neq V_{\omega}(y, x)$.

Дивергенция Брэгмана

i Дивергенция Брэгмана

Пусть $\omega : \mathbb{R}^n \rightarrow \mathbb{R}$ — непрерывно дифференцируемая и строго выпуклая функция. **Дивергенция Брэгмана**, порождённая функцией ω , определяется как:

$$V_{\omega}(x, y) = \omega(x) - \omega(y) - \langle \nabla \omega(y), x - y \rangle$$

Свойства:

- $V_{\omega}(x, y) \geq 0$ для всех x, y (из строгой выпуклости ω).
- $V_{\omega}(x, y) = 0 \Leftrightarrow x = y$.
- **Не симметрична** в общем случае: $V_{\omega}(x, y) \neq V_{\omega}(y, x)$.
- **Не удовлетворяет** неравенству треугольника.

Дивергенция Брэгмана

i Дивергенция Брэгмана

Пусть $\omega : \mathbb{R}^n \rightarrow \mathbb{R}$ — непрерывно дифференцируемая и строго выпуклая функция. **Дивергенция Брэгмана**, порождённая функцией ω , определяется как:

$$V_{\omega}(x, y) = \omega(x) - \omega(y) - \langle \nabla \omega(y), x - y \rangle$$

Свойства:

- $V_{\omega}(x, y) \geq 0$ для всех x, y (из строгой выпуклости ω).
- $V_{\omega}(x, y) = 0 \Leftrightarrow x = y$.
- **Не симметрична** в общем случае: $V_{\omega}(x, y) \neq V_{\omega}(y, x)$.
- **Не удовлетворяет** неравенству треугольника.
- Геометрически: $V_{\omega}(x, y)$ — разность между $\omega(x)$ и значением касательной к ω в точке y , вычисленным в точке x .

Примеры дивергенций Брэгмана

Евклидова дивергенция

$$\omega(x) = \frac{1}{2}\|x\|_2^2$$

$$V_\omega(x, y) = \frac{1}{2}\|x\|_2^2 - \frac{1}{2}\|y\|_2^2 - \langle y, x - y \rangle = \frac{1}{2}\|x - y\|_2^2$$

Воспроизводит обычный PGD.

Примеры дивергенций Брэгмана

Евклидова дивергенция

$$\omega(x) = \frac{1}{2} \|x\|_2^2$$

$$V_\omega(x, y) = \frac{1}{2} \|x\|_2^2 - \frac{1}{2} \|y\|_2^2 - \langle y, x - y \rangle = \frac{1}{2} \|x - y\|_2^2$$

Воспроизводит обычный PGD.

Дивергенция Кульбака-Лейблера (KL)

$$\omega(x) = \sum_{i=1}^n x_i \ln x_i \text{ (негативная энтропия) на } \Delta_n$$

$$V_\omega(x, y) = \sum_{i=1}^n x_i \ln \frac{x_i}{y_i}$$

Естественна для задач на симплексе.

Примеры дивергенций Брэгмана

Евклидова дивергенция

$$\omega(x) = \frac{1}{2}\|x\|_2^2$$

$$V_\omega(x, y) = \frac{1}{2}\|x\|_2^2 - \frac{1}{2}\|y\|_2^2 - \langle y, x - y \rangle = \frac{1}{2}\|x - y\|_2^2$$

Воспроизводит обычный PGD.

Дивергенция Кульбака-Лейблера (KL)

$$\omega(x) = \sum_{i=1}^n x_i \ln x_i \text{ (негативная энтропия) на } \Delta_n$$

$$V_\omega(x, y) = \sum_{i=1}^n x_i \ln \frac{x_i}{y_i}$$

Естественна для задач на симплексе.

Дивергенция Итакура-Саито

$$\omega(x) = -\sum_{i=1}^n \ln x_i \text{ на } \mathbb{R}_{++}^n$$

$$V_\omega(x, y) = \sum_{i=1}^n \left(\frac{x_i}{y_i} - \ln \frac{x_i}{y_i} - 1 \right)$$

Используется в обработке сигналов.

Примеры дивергенций Брэгмана

Евклидова дивергенция

$$\omega(x) = \frac{1}{2}\|x\|_2^2$$

$$V_\omega(x, y) = \frac{1}{2}\|x\|_2^2 - \frac{1}{2}\|y\|_2^2 - \langle y, x - y \rangle = \frac{1}{2}\|x - y\|_2^2$$

Воспроизводит обычный PGD.

Дивергенция Кульбака-Лейблера (KL)

$$\omega(x) = \sum_{i=1}^n x_i \ln x_i \text{ (негативная энтропия) на } \Delta_n$$

$$V_\omega(x, y) = \sum_{i=1}^n x_i \ln \frac{x_i}{y_i}$$

Естественна для задач на симплексе.

Дивергенция Итакура-Саито

$$\omega(x) = -\sum_{i=1}^n \ln x_i \text{ на } \mathbb{R}_{++}^n$$

$$V_\omega(x, y) = \sum_{i=1}^n \left(\frac{x_i}{y_i} - \ln \frac{x_i}{y_i} - 1 \right)$$

Используется в обработке сигналов.

Дивергенция Махаланобиса

$$\omega(x) = \frac{1}{2}x^\top Qx, \text{ где } Q \succ 0$$

$$V_\omega(x, y) = \frac{1}{2}(x - y)^\top Q(x - y)$$

Обобщённая евклидова геометрия.

Сильная выпуклость относительно нормы

Definition

Функция ω называется **σ -сильно выпуклой относительно нормы $\|\cdot\|$** , если для всех x, y из области определения:

$$V_{\omega}(x, y) \geq \frac{\sigma}{2} \|x - y\|^2$$

Сильная выпуклость относительно нормы

Definition

Функция ω называется **σ -сильно выпуклой относительно нормы $\|\cdot\|$** , если для всех x, y из области определения:

$$V_{\omega}(x, y) \geq \frac{\sigma}{2} \|x - y\|^2$$

Ключевые примеры:

- $\omega(x) = \frac{1}{2} \|x\|_2^2$ является 1-сильно выпуклой относительно $\|\cdot\|_2$.

Сильная выпуклость относительно нормы

i Definition

Функция ω называется σ -**сильно выпуклой относительно нормы** $\|\cdot\|$, если для всех x, y из области определения:

$$V_{\omega}(x, y) \geq \frac{\sigma}{2} \|x - y\|^2$$

Ключевые примеры:

- $\omega(x) = \frac{1}{2} \|x\|_2^2$ является 1-сильно выпуклой относительно $\|\cdot\|_2$.
- $\omega(x) = \sum_i x_i \ln x_i$ (негативная энтропия) является 1-сильно выпуклой относительно $\|\cdot\|_1$ на симплексе Δ_n .

Сильная выпуклость относительно нормы

i Definition

Функция ω называется σ -**сильно выпуклой относительно нормы** $\|\cdot\|$, если для всех x, y из области определения:

$$V_{\omega}(x, y) \geq \frac{\sigma}{2} \|x - y\|^2$$

Ключевые примеры:

- $\omega(x) = \frac{1}{2} \|x\|_2^2$ является 1-сильно выпуклой относительно $\|\cdot\|_2$.
- $\omega(x) = \sum_i x_i \ln x_i$ (негативная энтропия) является 1-сильно выпуклой относительно $\|\cdot\|_1$ на симплексе Δ_n .
 - Это утверждение известно как **неравенство Пинскера** и является нетривиальным результатом.

Сильная выпуклость относительно нормы

i Definition

Функция ω называется σ -**сильно выпуклой относительно нормы** $\|\cdot\|$, если для всех x, y из области определения:

$$V_{\omega}(x, y) \geq \frac{\sigma}{2} \|x - y\|^2$$

Ключевые примеры:

- $\omega(x) = \frac{1}{2} \|x\|_2^2$ является 1-сильно выпуклой относительно $\|\cdot\|_2$.
- $\omega(x) = \sum_i x_i \ln x_i$ (негативная энтропия) является 1-сильно выпуклой относительно $\|\cdot\|_1$ на симплексе Δ_n .
 - Это утверждение известно как **неравенство Пинскера** и является нетривиальным результатом.

Сильная выпуклость относительно нормы

i Definition

Функция ω называется σ -**сильно выпуклой относительно нормы** $\|\cdot\|$, если для всех x, y из области определения:

$$V_{\omega}(x, y) \geq \frac{\sigma}{2} \|x - y\|^2$$

Ключевые примеры:

- $\omega(x) = \frac{1}{2} \|x\|_2^2$ является 1-сильно выпуклой относительно $\|\cdot\|_2$.
- $\omega(x) = \sum_i x_i \ln x_i$ (негативная энтропия) является 1-сильно выпуклой относительно $\|\cdot\|_1$ на симплексе Δ_n .
- Это утверждение известно как **неравенство Пинскера** и является нетривиальным результатом.

Именно σ -сильная выпуклость прокс-функции ω относительно нормы $\|\cdot\|$ позволяет дивергенции Брэгмана «измерять расстояния» в геометрии, задаваемой нормой $\|\cdot\|$.

Алгоритм зеркального спуска

Задача: $\min_{x \in S} f(x)$, где f — выпуклая функция, S — замкнутое выпуклое множество.

Алгоритм зеркального спуска

Задача: $\min_{x \in S} f(x)$, где f — выпуклая функция, S — замкнутое выпуклое множество.

i Метод зеркального спуска (Mirror Descent)

Вход: $x_0 \in S$, шаги $\{\alpha_k\}$, прокс-функция ω .

Для $k = 0, 1, 2, \dots$:

1. Вычислить градиент $g_k = \nabla f(x_k)$

Алгоритм зеркального спуска

Задача: $\min_{x \in S} f(x)$, где f — выпуклая функция, S — замкнутое выпуклое множество.

i Метод зеркального спуска (Mirror Descent)

Вход: $x_0 \in S$, шаги $\{\alpha_k\}$, прокс-функция ω .

Для $k = 0, 1, 2, \dots$:

1. Вычислить градиент $g_k = \nabla f(x_k)$
2. Шаг в двойственном пространстве:

$$x_{k+1} = \arg \min_{x \in S} \left\{ \langle g_k, x \rangle + \frac{1}{\alpha_k} V_\omega(x, x_k) \right\}$$

Алгоритм зеркального спуска

Задача: $\min_{x \in S} f(x)$, где f — выпуклая функция, S — замкнутое выпуклое множество.

i Метод зеркального спуска (Mirror Descent)

Вход: $x_0 \in S$, шаги $\{\alpha_k\}$, прокс-функция ω .

Для $k = 0, 1, 2, \dots$:

1. Вычислить градиент $g_k = \nabla f(x_k)$
2. Шаг в двойственном пространстве:

$$x_{k+1} = \arg \min_{x \in S} \left\{ \langle g_k, x \rangle + \frac{1}{\alpha_k} V_\omega(x, x_k) \right\}$$

Алгоритм зеркального спуска

Задача: $\min_{x \in S} f(x)$, где f — выпуклая функция, S — замкнутое выпуклое множество.

i Метод зеркального спуска (Mirror Descent)

Вход: $x_0 \in S$, шаги $\{\alpha_k\}$, прокс-функция ω .

Для $k = 0, 1, 2, \dots$:

1. Вычислить градиент $g_k = \nabla f(x_k)$
2. Шаг в двойственном пространстве:

$$x_{k+1} = \arg \min_{x \in S} \left\{ \langle g_k, x \rangle + \frac{1}{\alpha_k} V_\omega(x, x_k) \right\}$$

Интерпретация: на каждом шаге минимизируем линейное приближение f с регуляризацией дивергенцией Брэгмана вместо $\frac{1}{2\alpha} \|x - x_k\|_2^2$.

Алгоритм зеркального спуска

Задача: $\min_{x \in S} f(x)$, где f — выпуклая функция, S — замкнутое выпуклое множество.

i Метод зеркального спуска (Mirror Descent)

Вход: $x_0 \in S$, шаги $\{\alpha_k\}$, прокс-функция ω .

Для $k = 0, 1, 2, \dots$:

1. Вычислить градиент $g_k = \nabla f(x_k)$
2. Шаг в двойственном пространстве:

$$x_{k+1} = \arg \min_{x \in S} \left\{ \langle g_k, x \rangle + \frac{1}{\alpha_k} V_\omega(x, x_k) \right\}$$

Интерпретация: на каждом шаге минимизируем линейное приближение f с регуляризацией дивергенцией Брэгмана вместо $\frac{1}{2\alpha} \|x - x_k\|_2^2$.

Частный случай: при $\omega(x) = \frac{1}{2} \|x\|_2^2$ получаем $V_\omega(x, y) = \frac{1}{2} \|x - y\|_2^2$, и итерация принимает вид:

$$x_{k+1} = \arg \min_{x \in S} \left\{ \langle \nabla f(x_k), x \rangle + \frac{1}{2\alpha_k} \|x - x_k\|_2^2 \right\} = \text{proj}_S(x_k - \alpha_k \nabla f(x_k))$$

то есть стандартный PGD.

Зеркальный спуск: эквивалентные формы итерации

Итерацию зеркального спуска можно записать в нескольких эквивалентных формах:

Зеркальный спуск: эквивалентные формы итерации

Итерацию зеркального спуска можно записать в нескольких эквивалентных формах:

1. Проксимальная форма (основная):

$$x_{k+1} = \arg \min_{x \in S} \{ \alpha_k \langle \nabla f(x_k), x \rangle + V_\omega(x, x_k) \}$$

Зеркальный спуск: эквивалентные формы итерации

Итерацию зеркального спуска можно записать в нескольких эквивалентных формах:

1. Проксимальная форма (основная):

$$x_{k+1} = \arg \min_{x \in S} \{ \alpha_k \langle \nabla f(x_k), x \rangle + V_\omega(x, x_k) \}$$

2. Двойственная форма (через зеркальное отображение):

Для безусловной задачи ($S = \mathbb{R}^n$), используя условие оптимальности $\nabla_x V_\omega(x, x_k) = \nabla \omega(x) - \nabla \omega(x_k)$:

$$\nabla \omega(x_{k+1}) = \nabla \omega(x_k) - \alpha_k \nabla f(x_k)$$

Зеркальный спуск: эквивалентные формы итерации

Итерацию зеркального спуска можно записать в нескольких эквивалентных формах:

1. Проксимальная форма (основная):

$$x_{k+1} = \arg \min_{x \in S} \{ \alpha_k \langle \nabla f(x_k), x \rangle + V_\omega(x, x_k) \}$$

2. Двойственная форма (через зеркальное отображение):

Для безусловной задачи ($S = \mathbb{R}^n$), используя условие оптимальности $\nabla_x V_\omega(x, x_k) = \nabla \omega(x) - \nabla \omega(x_k)$:

$$\nabla \omega(x_{k+1}) = \nabla \omega(x_k) - \alpha_k \nabla f(x_k)$$

3. Проекция Брэгмана (для условной задачи):

$$y_{k+1} : \quad \nabla \omega(y_{k+1}) = \nabla \omega(x_k) - \alpha_k \nabla f(x_k)$$

$$x_{k+1} = \arg \min_{x \in S} V_\omega(x, y_{k+1})$$

Зеркальный спуск: эквивалентные формы итерации

Итерацию зеркального спуска можно записать в нескольких эквивалентных формах:

1. Проксимальная форма (основная):

$$x_{k+1} = \arg \min_{x \in S} \{ \alpha_k \langle \nabla f(x_k), x \rangle + V_\omega(x, x_k) \}$$

2. Двойственная форма (через зеркальное отображение):

Для безусловной задачи ($S = \mathbb{R}^n$), используя условие оптимальности $\nabla_x V_\omega(x, x_k) = \nabla \omega(x) - \nabla \omega(x_k)$:

$$\nabla \omega(x_{k+1}) = \nabla \omega(x_k) - \alpha_k \nabla f(x_k)$$

3. Проекция Брэгмана (для условной задачи):

$$y_{k+1} : \quad \nabla \omega(y_{k+1}) = \nabla \omega(x_k) - \alpha_k \nabla f(x_k)$$

$$x_{k+1} = \arg \min_{x \in S} V_\omega(x, y_{k+1})$$

В евклидовом случае ($\omega = \frac{1}{2} \|\cdot\|_2^2$) проекция Брэгмана совпадает с евклидовой проекцией.

Зеркальный спуск на симплексе: Exponentiated Gradient

Важнейший частный случай: $S = \Delta_n$, $\omega(x) = \sum_i x_i \ln x_i$.

Зеркальный спуск на симплексе: Exponentiated Gradient

Важнейший частный случай: $S = \Delta_n$, $\omega(x) = \sum_i x_i \ln x_i$.

Итерация зеркального спуска принимает **замкнутую форму**:

$$x_{k+1,i} = \frac{x_{k,i} \exp(-\alpha_k [\nabla f(x_k)]_i)}{\sum_{j=1}^n x_{k,j} \exp(-\alpha_k [\nabla f(x_k)]_j)}, \quad i = 1, \dots, n$$

Зеркальный спуск на симплексе: Exponentiated Gradient

Важнейший частный случай: $S = \Delta_n$, $\omega(x) = \sum_i x_i \ln x_i$.

Итерация зеркального спуска принимает **замкнутую форму**:

$$x_{k+1,i} = \frac{x_{k,i} \exp(-\alpha_k [\nabla f(x_k)]_i)}{\sum_{j=1}^n x_{k,j} \exp(-\alpha_k [\nabla f(x_k)]_j)}, \quad i = 1, \dots, n$$

Этот метод известен как **Exponentiated Gradient (EG)** или **Multiplicative Weights Update**.

Зеркальный спуск на симплексе: Exponentiated Gradient

Важнейший частный случай: $S = \Delta_n$, $\omega(x) = \sum_i x_i \ln x_i$.

Итерация зеркального спуска принимает **замкнутую форму**:

$$x_{k+1,i} = \frac{x_{k,i} \exp(-\alpha_k [\nabla f(x_k)]_i)}{\sum_{j=1}^n x_{k,j} \exp(-\alpha_k [\nabla f(x_k)]_j)}, \quad i = 1, \dots, n$$

Этот метод известен как **Exponentiated Gradient (EG)** или **Multiplicative Weights Update**.

Вывод. Из условия оптимальности: $\ln x_{k+1,i} + 1 - \ln x_{k,i} - 1 + \alpha_k g_i + \lambda = 0$, где λ — множитель Лагранжа для ограничения $\sum_i x_i = 1$. Тогда $x_{k+1,i} \propto x_{k,i} \exp(-\alpha_k g_i)$, и нормировка даёт формулу выше.

Зеркальный спуск на симплексе: Exponentiated Gradient

Важнейший частный случай: $S = \Delta_n$, $\omega(x) = \sum_i x_i \ln x_i$.

Итерация зеркального спуска принимает **замкнутую форму**:

$$x_{k+1,i} = \frac{x_{k,i} \exp(-\alpha_k [\nabla f(x_k)]_i)}{\sum_{j=1}^n x_{k,j} \exp(-\alpha_k [\nabla f(x_k)]_j)}, \quad i = 1, \dots, n$$

Этот метод известен как **Exponentiated Gradient (EG)** или **Multiplicative Weights Update**.

Вывод. Из условия оптимальности: $\ln x_{k+1,i} + 1 - \ln x_{k,i} - 1 + \alpha_k g_i + \lambda = 0$, где λ — множитель Лагранжа для ограничения $\sum_i x_i = 1$. Тогда $x_{k+1,i} \propto x_{k,i} \exp(-\alpha_k g_i)$, и нормировка даёт формулу выше.

Стоимость: $\mathcal{O}(n)$ — **не требуется** сортировка (в отличие от евклидовой проекции на симплекс, которая стоит $\mathcal{O}(n \log n)$).



i Theorem

Пусть $f : S \rightarrow \mathbb{R}$ — выпуклая функция с L -липшицевым градиентом относительно нормы $\|\cdot\|$:

$$\|\nabla f(x) - \nabla f(y)\|_* \leq L\|x - y\| \quad \forall x, y \in S$$

Пусть прокс-функция ω является σ -сильно выпуклой относительно $\|\cdot\|$, и $R^2 = \max_{x \in S} V_\omega(x, x_0)$. Тогда зеркальный спуск с шагом $\alpha_k = \frac{1}{L/\sigma}$ обеспечивает:

$$f(x_k) - f^* \leq \frac{LR^2}{\sigma k}$$

Скорость сходимости зеркального спуска

Theorem

Пусть $f : S \rightarrow \mathbb{R}$ — выпуклая функция с L -липшицевым градиентом относительно нормы $\|\cdot\|$:

$$\|\nabla f(x) - \nabla f(y)\|_* \leq L\|x - y\| \quad \forall x, y \in S$$

Пусть прокс-функция ω является σ -сильно выпуклой относительно $\|\cdot\|$, и $R^2 = \max_{x \in S} V_\omega(x, x_0)$. Тогда зеркальный спуск с шагом $\alpha_k = \frac{1}{L/\sigma}$ обеспечивает:

$$f(x_k) - f^* \leq \frac{LR^2}{\sigma k}$$

Сравнение с PGD:

	PGD	Зеркальный спуск
Норма	$\ \cdot\ _2$	$\ \cdot\ $ (произвольная)
Гладкость	L_2	L (отн. $\ \cdot\ $)
«Радиус»	$R_2 = \ x_0 - x^*\ _2$	$R^2 = V_\omega(x^*, x_0)$
Оценка	$\frac{L_2 R_2^2}{k}$	$\frac{LR^2}{\sigma k}$

Доказательство сходимости

1. Из L -гладкости f относительно нормы $\|\cdot\|$ при шаге $\alpha = \sigma/L$:

$$f(x_{k+1}) \leq f(x_k) + \langle \nabla f(x_k), x_{k+1} - x_k \rangle + \frac{L}{2} \|x_{k+1} - x_k\|^2$$

Доказательство сходимости

1. Из L -гладкости f относительно нормы $\|\cdot\|$ при шаге $\alpha = \sigma/L$:

$$f(x_{k+1}) \leq f(x_k) + \langle \nabla f(x_k), x_{k+1} - x_k \rangle + \frac{L}{2} \|x_{k+1} - x_k\|^2$$

Доказательство сходимости

1. Из L -гладкости f относительно нормы $\|\cdot\|$ при шаге $\alpha = \sigma/L$:

$$f(x_{k+1}) \leq f(x_k) + \langle \nabla f(x_k), x_{k+1} - x_k \rangle + \frac{L}{2} \|x_{k+1} - x_k\|^2$$

2. Из σ -сильной выпуклости ω : $\frac{L}{2} \|x_{k+1} - x_k\|^2 \leq \frac{L}{\sigma} V_\omega(x_{k+1}, x_k)$. Следовательно:

$$f(x_{k+1}) \leq f(x_k) + \langle \nabla f(x_k), x_{k+1} - x_k \rangle + \frac{L}{\sigma} V_\omega(x_{k+1}, x_k)$$

Доказательство сходимости

1. Из L -гладкости f относительно нормы $\|\cdot\|$ при шаге $\alpha = \sigma/L$:

$$f(x_{k+1}) \leq f(x_k) + \langle \nabla f(x_k), x_{k+1} - x_k \rangle + \frac{L}{2} \|x_{k+1} - x_k\|^2$$

2. Из σ -сильной выпуклости ω : $\frac{L}{2} \|x_{k+1} - x_k\|^2 \leq \frac{L}{\sigma} V_\omega(x_{k+1}, x_k)$. Следовательно:

$$f(x_{k+1}) \leq f(x_k) + \langle \nabla f(x_k), x_{k+1} - x_k \rangle + \frac{L}{\sigma} V_\omega(x_{k+1}, x_k)$$

Доказательство сходимости

1. Из L -гладкости f относительно нормы $\|\cdot\|$ при шаге $\alpha = \sigma/L$:

$$f(x_{k+1}) \leq f(x_k) + \langle \nabla f(x_k), x_{k+1} - x_k \rangle + \frac{L}{2} \|x_{k+1} - x_k\|^2$$

2. Из σ -сильной выпуклости ω : $\frac{L}{2} \|x_{k+1} - x_k\|^2 \leq \frac{L}{\sigma} V_\omega(x_{k+1}, x_k)$. Следовательно:

$$f(x_{k+1}) \leq f(x_k) + \langle \nabla f(x_k), x_{k+1} - x_k \rangle + \frac{L}{\sigma} V_\omega(x_{k+1}, x_k)$$

3. Из определения итерации (условие оптимальности) и выпуклости f для любого $x \in S$:

$$\alpha_k \langle \nabla f(x_k), x_{k+1} - x \rangle \leq V_\omega(x, x_k) - V_\omega(x, x_{k+1}) - V_\omega(x_{k+1}, x_k)$$

Доказательство сходимости

1. Из L -гладкости f относительно нормы $\|\cdot\|$ при шаге $\alpha = \sigma/L$:

$$f(x_{k+1}) \leq f(x_k) + \langle \nabla f(x_k), x_{k+1} - x_k \rangle + \frac{L}{2} \|x_{k+1} - x_k\|^2$$

2. Из σ -сильной выпуклости ω : $\frac{L}{2} \|x_{k+1} - x_k\|^2 \leq \frac{L}{\sigma} V_\omega(x_{k+1}, x_k)$. Следовательно:

$$f(x_{k+1}) \leq f(x_k) + \langle \nabla f(x_k), x_{k+1} - x_k \rangle + \frac{L}{\sigma} V_\omega(x_{k+1}, x_k)$$

3. Из определения итерации (условие оптимальности) и выпуклости f для любого $x \in S$:

$$\alpha_k \langle \nabla f(x_k), x_{k+1} - x \rangle \leq V_\omega(x, x_k) - V_\omega(x, x_{k+1}) - V_\omega(x_{k+1}, x_k)$$

Доказательство сходимости

1. Из L -гладкости f относительно нормы $\|\cdot\|$ при шаге $\alpha = \sigma/L$:

$$f(x_{k+1}) \leq f(x_k) + \langle \nabla f(x_k), x_{k+1} - x_k \rangle + \frac{L}{2} \|x_{k+1} - x_k\|^2$$

2. Из σ -сильной выпуклости ω : $\frac{L}{2} \|x_{k+1} - x_k\|^2 \leq \frac{L}{\sigma} V_\omega(x_{k+1}, x_k)$. Следовательно:

$$f(x_{k+1}) \leq f(x_k) + \langle \nabla f(x_k), x_{k+1} - x_k \rangle + \frac{L}{\sigma} V_\omega(x_{k+1}, x_k)$$

3. Из определения итерации (условие оптимальности) и выпуклости f для любого $x \in S$:

$$\alpha_k \langle \nabla f(x_k), x_{k+1} - x \rangle \leq V_\omega(x, x_k) - V_\omega(x, x_{k+1}) - V_\omega(x_{k+1}, x_k)$$

Это **лемма трёх точек** (three-point identity) для дивергенции Брэгмана:

$$V_\omega(x, x_k) - V_\omega(x, x_{k+1}) = \langle \nabla \omega(x_{k+1}) - \nabla \omega(x_k), x - x_{k+1} \rangle + V_\omega(x_{k+1}, x_k)$$

Доказательство сходимости (продолжение)

4. Подставляя $x = x^*$ и используя выпуклость $f(x_k) - f^* \leq \langle \nabla f(x_k), x_k - x^* \rangle$:

$$\begin{aligned}\alpha_k(f(x_k) - f^*) &\leq \alpha_k \langle \nabla f(x_k), x_k - x^* \rangle \\ &= \alpha_k \langle \nabla f(x_k), x_k - x_{k+1} \rangle + \alpha_k \langle \nabla f(x_k), x_{k+1} - x^* \rangle \\ &\leq \alpha_k \langle \nabla f(x_k), x_k - x_{k+1} \rangle + V_\omega(x^*, x_k) - V_\omega(x^*, x_{k+1}) - V_\omega(x_{k+1}, x_k)\end{aligned}$$

Доказательство сходимости (продолжение)

4. Подставляя $x = x^*$ и используя выпуклость $f(x_k) - f^* \leq \langle \nabla f(x_k), x_k - x^* \rangle$:

$$\begin{aligned}\alpha_k(f(x_k) - f^*) &\leq \alpha_k \langle \nabla f(x_k), x_k - x^* \rangle \\ &= \alpha_k \langle \nabla f(x_k), x_k - x_{k+1} \rangle + \alpha_k \langle \nabla f(x_k), x_{k+1} - x^* \rangle \\ &\leq \alpha_k \langle \nabla f(x_k), x_k - x_{k+1} \rangle + V_\omega(x^*, x_k) - V_\omega(x^*, x_{k+1}) - V_\omega(x_{k+1}, x_k)\end{aligned}$$

Доказательство сходимости (продолжение)

4. Подставляя $x = x^*$ и используя выпуклость $f(x_k) - f^* \leq \langle \nabla f(x_k), x_k - x^* \rangle$:

$$\begin{aligned}\alpha_k(f(x_k) - f^*) &\leq \alpha_k \langle \nabla f(x_k), x_k - x^* \rangle \\ &= \alpha_k \langle \nabla f(x_k), x_k - x_{k+1} \rangle + \alpha_k \langle \nabla f(x_k), x_{k+1} - x^* \rangle \\ &\leq \alpha_k \langle \nabla f(x_k), x_k - x_{k+1} \rangle + V_\omega(x^*, x_k) - V_\omega(x^*, x_{k+1}) - V_\omega(x_{k+1}, x_k)\end{aligned}$$

5. Суммируя по $k = 0, \dots, K - 1$ и используя телескопирование:

$$\sum_{k=0}^{K-1} \alpha_k(f(x_k) - f^*) \leq V_\omega(x^*, x_0) + \sum_{k=0}^{K-1} [\alpha_k \langle \nabla f(x_k), x_k - x_{k+1} \rangle - V_\omega(x_{k+1}, x_k)]$$

Доказательство сходимости (продолжение)

4. Подставляя $x = x^*$ и используя выпуклость $f(x_k) - f^* \leq \langle \nabla f(x_k), x_k - x^* \rangle$:

$$\begin{aligned}\alpha_k(f(x_k) - f^*) &\leq \alpha_k \langle \nabla f(x_k), x_k - x^* \rangle \\ &= \alpha_k \langle \nabla f(x_k), x_k - x_{k+1} \rangle + \alpha_k \langle \nabla f(x_k), x_{k+1} - x^* \rangle \\ &\leq \alpha_k \langle \nabla f(x_k), x_k - x_{k+1} \rangle + V_\omega(x^*, x_k) - V_\omega(x^*, x_{k+1}) - V_\omega(x_{k+1}, x_k)\end{aligned}$$

5. Суммируя по $k = 0, \dots, K - 1$ и используя телескопирование:

$$\sum_{k=0}^{K-1} \alpha_k(f(x_k) - f^*) \leq V_\omega(x^*, x_0) + \sum_{k=0}^{K-1} [\alpha_k \langle \nabla f(x_k), x_k - x_{k+1} \rangle - V_\omega(x_{k+1}, x_k)]$$

Доказательство сходимости (продолжение)

4. Подставляя $x = x^*$ и используя выпуклость $f(x_k) - f^* \leq \langle \nabla f(x_k), x_k - x^* \rangle$:

$$\begin{aligned}\alpha_k(f(x_k) - f^*) &\leq \alpha_k \langle \nabla f(x_k), x_k - x^* \rangle \\ &= \alpha_k \langle \nabla f(x_k), x_k - x_{k+1} \rangle + \alpha_k \langle \nabla f(x_k), x_{k+1} - x^* \rangle \\ &\leq \alpha_k \langle \nabla f(x_k), x_k - x_{k+1} \rangle + V_\omega(x^*, x_k) - V_\omega(x^*, x_{k+1}) - V_\omega(x_{k+1}, x_k)\end{aligned}$$

5. Суммируя по $k = 0, \dots, K-1$ и используя телескопирование:

$$\sum_{k=0}^{K-1} \alpha_k(f(x_k) - f^*) \leq V_\omega(x^*, x_0) + \sum_{k=0}^{K-1} [\alpha_k \langle \nabla f(x_k), x_k - x_{k+1} \rangle - V_\omega(x_{k+1}, x_k)]$$

6. Используя шаг 2 для оценки каждого слагаемого и монотонность $f(x_k)$:

$$K \cdot (f(x_K) - f^*) \leq \frac{L}{\sigma} V_\omega(x^*, x_0) = \frac{LR^2}{\sigma}$$

откуда $f(x_K) - f^* \leq \frac{LR^2}{\sigma K}$, что и требовалось доказать.

Пример: зеркальный спуск vs PGD на симплексе

Рассмотрим задачу

$$\min_{x \in \Delta_n} f(x) = \frac{1}{2} \|Ax - b\|_2^2$$

- PGD: евклидова проекция на Δ_n , $\mathcal{O}(n \log n)$ на шаг

Пример: зеркальный спуск vs PGD на симплексе

Рассмотрим задачу

$$\min_{x \in \Delta_n} f(x) = \frac{1}{2} \|Ax - b\|_2^2$$

- PGD: евклидова проекция на Δ_n , $\mathcal{O}(n \log n)$ на шаг
- MD (EG): мультипликативное обновление, $\mathcal{O}(n)$ на шаг

Пример: зеркальный спуск vs PGD на симплексе

Рассмотрим задачу

$$\min_{x \in \Delta_n} f(x) = \frac{1}{2} \|Ax - b\|_2^2$$

- PGD: евклидова проекция на Δ_n , $\mathcal{O}(n \log n)$ на шаг
- MD (EG): мультипликативное обновление, $\mathcal{O}(n)$ на шаг

Пример: зеркальный спуск vs PGD на симплексе

Рассмотрим задачу

$$\min_{x \in \Delta_n} f(x) = \frac{1}{2} \|Ax - b\|_2^2$$

- PGD: евклидова проекция на Δ_n , $\mathcal{O}(n \log n)$ на шаг
- MD (EG): мультипликативное обновление, $\mathcal{O}(n)$ на шаг

Когда A имеет слабую корреляцию между столбцами:
 $L_2 \approx n \cdot L_\infty$. Тогда:

- PGD: $\mathcal{O}\left(\frac{nL_\infty}{k}\right)$

Параметр	PGD	MD (EG)
Гладкость	$L_2 = \ A^\top A\ _{\text{op}}$	$L_\infty = \max_{ij} A^\top A _{ij}$
«Радиус»	$R_2^2 \leq 2$	$R^2 \leq \ln n$
Оценка	$\frac{L_2}{k}$	$\frac{L_\infty \ln n}{k}$

Пример: зеркальный спуск vs PGD на симплексе

Рассмотрим задачу

$$\min_{x \in \Delta_n} f(x) = \frac{1}{2} \|Ax - b\|_2^2$$

- PGD: евклидова проекция на Δ_n , $\mathcal{O}(n \log n)$ на шаг
- MD (EG): мультипликативное обновление, $\mathcal{O}(n)$ на шаг

Когда A имеет слабую корреляцию между столбцами:

$L_2 \approx n \cdot L_\infty$. Тогда:

- PGD: $\mathcal{O}\left(\frac{nL_\infty}{k}\right)$
- MD: $\mathcal{O}\left(\frac{L_\infty \ln n}{k}\right)$

Параметр	PGD	MD (EG)
Гладкость	$L_2 = \ A^\top A\ _{\text{op}}$	$L_\infty = \max_{ij} A^\top A _{ij}$
«Радиус»	$R_2^2 \leq 2$	$R^2 \leq \ln n$
Оценка	$\frac{L_2}{k}$	$\frac{L_\infty \ln n}{k}$

Пример: зеркальный спуск vs PGD на симплексе

Рассмотрим задачу

$$\min_{x \in \Delta_n} f(x) = \frac{1}{2} \|Ax - b\|_2^2$$

- PGD: евклидова проекция на Δ_n , $\mathcal{O}(n \log n)$ на шаг
- MD (EG): мультипликативное обновление, $\mathcal{O}(n)$ на шаг

Когда A имеет слабую корреляцию между столбцами:

$L_2 \approx n \cdot L_\infty$. Тогда:

- PGD: $\mathcal{O}\left(\frac{nL_\infty}{k}\right)$
- MD: $\mathcal{O}\left(\frac{L_\infty \ln n}{k}\right)$

Параметр	PGD	MD (EG)
Гладкость	$L_2 = \ A^\top A\ _{\text{op}}$	$L_\infty = \max_{ij} A^\top A _{ij}$
«Радиус»	$R_2^2 \leq 2$	$R^2 \leq \ln n$
Оценка	$\frac{L_2}{k}$	$\frac{L_\infty \ln n}{k}$

Пример: зеркальный спуск vs PGD на симплексе

Рассмотрим задачу

$$\min_{x \in \Delta_n} f(x) = \frac{1}{2} \|Ax - b\|_2^2$$

- PGD: евклидова проекция на Δ_n , $\mathcal{O}(n \log n)$ на шаг
- MD (EG): мультипликативное обновление, $\mathcal{O}(n)$ на шаг

Когда A имеет слабую корреляцию между столбцами:

$L_2 \approx n \cdot L_\infty$. Тогда:

- PGD: $\mathcal{O}\left(\frac{nL_\infty}{k}\right)$
- MD: $\mathcal{O}\left(\frac{L_\infty \ln n}{k}\right)$

Выигрыш: $\frac{n}{\ln n}$ раз!

Параметр	PGD	MD (EG)
Гладкость	$L_2 = \ A^\top A\ _{\text{op}}$	$L_\infty = \max_{ij} A^\top A _{ij}$
«Радиус»	$R_2^2 \leq 2$	$R^2 \leq \ln n$
Оценка	$\frac{L_2}{k}$	$\frac{L_\infty \ln n}{k}$

Пример: зеркальный спуск vs PGD на симплексе

Рассмотрим задачу

$$\min_{x \in \Delta_n} f(x) = \frac{1}{2} \|Ax - b\|_2^2$$

- PGD: евклидова проекция на Δ_n , $\mathcal{O}(n \log n)$ на шаг
- MD (EG): мультипликативное обновление, $\mathcal{O}(n)$ на шаг

Когда A имеет слабую корреляцию между столбцами:

$L_2 \approx n \cdot L_\infty$. Тогда:

- PGD: $\mathcal{O}\left(\frac{nL_\infty}{k}\right)$
- MD: $\mathcal{O}\left(\frac{L_\infty \ln n}{k}\right)$

Выигрыш: $\frac{n}{\ln n}$ раз!

Для $n = 1000$: выигрыш ≈ 145 раз.

Для $n = 10^6$: выигрыш $\approx 72\,400$ раз.


Параметр	PGD	MD (EG)
Гладкость	$L_2 = \ A^\top A\ _{\text{op}}$	$L_\infty = \max_{ij} A^\top A _{ij}$
«Радиус»	$R_2^2 \leq 2$	$R^2 \leq \ln n$
Оценка	$\frac{L_2}{k}$	$\frac{L_\infty \ln n}{k}$

Негладкая задача: MD побеждает по итерациям


Задача Бека: $\min_{x \in \Delta_n} \|Ax - b\|_1$ — негладкая оптимизация на симплексе

$\min \|Ax - b\|_1$ на Δ_n : по итерациям с теорией


$n = 100, m = 50$
 $\|g\|_2 / \|g\|_\infty = 3.3$



$n = 500, m = 200$
 $\|g\|_2 / \|g\|_\infty = 4.6$



$n = 2000, m = 500$
 $\|g\|_2 / \|g\|_\infty = 5.1$




- Субградиент $g = A^\top \text{sign}(Ax - b)$: $\|g\|_2$ растёт с $\sqrt{n}$, а $\|g\|_\infty$ остаётся ограниченным

Негладкая задача: MD побеждает по итерациям


Задача Бека: $\min_{x \in \Delta_n} \|Ax - b\|_1$ — негладкая оптимизация на симплексе

$\min \|Ax - b\|_1$ на Δ_n : по итерациям с теорией


$n = 100, m = 50$
 $\|g\|_2 / \|g\|_\infty = 3.3$



$n = 500, m = 200$
 $\|g\|_2 / \|g\|_\infty = 4.6$






$n = 2000, m = 500$
 $\|g\|_2 / \|g\|_\infty = 5.1$



- Субградиент $g = A^\top \text{sign}(Ax - b)$: $\|g\|_2$ растёт с $\sqrt{n}$, а $\|g\|_\infty$ остаётся ограниченным
- **Зеркальный спуск** использует ℓ_∞ -геометрию и побеждает в $\sim \sqrt{n / \ln n}$ раз!

Негладкая задача: честное сравнение по времени




$\min \|Ax - b\|_1$ на Δ_n : по времени



- MD побеждает **и по времени**: стоимость итерации сравнима ($O(n)$ vs $O(n \log n)$), но MD сходится существенно быстрее



Негладкая задача: честное сравнение по времени

$\min \|Ax - b\|_1$ на Δ_n : по времени





- MD побеждает **и по времени**: стоимость итерации сравнима ($O(n)$ vs $O(n \log n)$), но MD сходится существенно быстрее
- Преимущество растёт с размерностью: для $n = 2000$ субградиентный метод за то же время далеко от оптимума

Масштабирование преимущества MD





- При росте n невязка субградиентного метода растёт, а MD остаётся малой

Масштабирование преимущества MD




- При росте n невязка субградиентного метода **растёт**, а MD остаётся малой
- Число итераций до ε -точности: MD требует меньше при любом n

Масштабирование преимущества MD




- При росте n невязка субградиентного метода **растёт**, а MD остаётся малой
- Число итераций до ε -точности: MD требует меньше при любом n

Масштабирование преимущества MD




- При росте n невязка субградиентного метода **растёт**, а MD остаётся малой
- Число итераций до ε -точности: MD требует меньше при любом n




- Стоимость шага MD — $\mathcal{O}(n)$, дешевле PGD — $\mathcal{O}(n \log n)$

Масштабирование преимущества MD



- При росте n невязка субградиентного метода **растёт**, а MD остаётся малой
- Число итераций до ε -точности: MD требует меньше при любом n






- Стоимость шага MD — $\mathcal{O}(n)$, дешевле PGD — $\mathcal{O}(n \log n)$
- MD и FW имеют одинаковую асимптотику $\mathcal{O}(n)$

KL-дивергенция: относительная гладкость

$f(x) = \sum_{i=1}^m \text{KL}(A_i x \| b_i)$ на Δ_n — задача с неограниченной L_2 -гладкостью, но **ограниченной** относительной гладкостью по Брэгману!

$f(x) = \sum \text{KL}(A_i x \| b_i)$ на Δ_n : относительная гладкость






- Константа $L_h = \max_k \sum_{i,j} (A_i)_{jk}$ вычислима из данных задачи; MD шаг $\eta = 1/L_h$ — теория гарантирует $O(1/k)$

KL-дивергенция: относительная гладкость

$f(x) = \sum_{i=1}^m \text{KL}(A_i x \| b_i)$ на Δ_n — задача с неограниченной L_2 -гладкостью, но **ограниченной** относительной гладкостью по Брэгману!

$f(x) = \sum \text{KL}(A_i x \| b_i)$ на Δ_n : относительная гладкость






- Константа $L_h = \max_k \sum_{i,j} (A_i)_{jk}$ вычислима из данных задачи; MD шаг $\eta = 1/L_h$ — теория гарантирует $O(1/k)$
- L_2 константа Липшица в **175 раз** больше $L_h \rightarrow$ шаг PGD $\alpha = 1/L_2$ сверхконсервативен; Armijo — медленнее по времени

KL-дивергенция: относительная гладкость

$f(x) = \sum_{i=1}^m \text{KL}(A_i x \| b_i)$ на Δ_n — задача с неограниченной L_2 -гладкостью, но **ограниченной** относительной гладкостью по Брэману!

$$f(x) = \sum \text{KL}(A_i x \| b_i) \text{ на } \Delta_n: \text{ относительная гладкость}$$



- Константа $L_h = \max_k \sum_{i,j} (A_i)_{jk}$ вычислима из данных задачи; MD шаг $\eta = 1/L_h$ — теория гарантирует $O(1/k)$
- L_2 константа Липшица в **175 раз** больше $L_h \rightarrow$ шаг PGD $\alpha = 1/L_2$ сверхконсервативен; Armijo — медленнее по времени
- Правый график: L_h vs $L_2(x_k)$ — **почему** неевклидова геометрия выигрывает

Итоги: зеркальный спуск

- **Обобщение PGD:** заменяем евклидову проекцию дивергенцией Брэгмана, адаптируя геометрию метода к задаче.

Итоги: зеркальный спуск

- **Обобщение PGD:** заменяем евклидову проекцию дивергенцией Брэгмана, адаптируя геометрию метода к задаче.
- **Скорость сходимости:** $\mathcal{O}\left(\frac{LR^2}{\sigma k}\right)$ — та же структура, что у PGD, но с параметрами, адаптированными к «правильной» норме.

Итоги: зеркальный спуск

- **Обобщение PGD:** заменяем евклидову проекцию дивергенцией Брэгмана, адаптируя геометрию метода к задаче.
- **Скорость сходимости:** $\mathcal{O}\left(\frac{LR^2}{\sigma k}\right)$ — та же структура, что у PGD, но с параметрами, адаптированными к «правильной» норме.
- **Когда выигрывает:**

Итоги: зеркальный спуск

- **Обобщение PGD:** заменяем евклидову проекцию дивергенцией Брэгмана, адаптируя геометрию метода к задаче.
- **Скорость сходимости:** $\mathcal{O}\left(\frac{LR^2}{\sigma k}\right)$ — та же структура, что у PGD, но с параметрами, адаптированными к «правильной» норме.
- **Когда выигрывает:**
 - **Негладкие задачи на симплексе:** $\min \|Ax - b\|_1$ — выигрыш в $\sim \sqrt{n/\ln n}$ раз (и по итерациям, и по времени!)

Итоги: зеркальный спуск

- **Обобщение PGD:** заменяем евклидову проекцию дивергенцией Брэгмана, адаптируя геометрию метода к задаче.
- **Скорость сходимости:** $\mathcal{O}\left(\frac{LR^2}{\sigma k}\right)$ — та же структура, что у PGD, но с параметрами, адаптированными к «правильной» норме.
- **Когда выигрывает:**
 - **Негладкие задачи** на симплексе: $\min \|Ax - b\|_1$ — выигрыш в $\sim \sqrt{n/\ln n}$ раз (и по итерациям, и по времени!)
 - **KL-дивергенция** и задачи с **относительной гладкостью**: L_2 неограничена, но MD сходится с фиксированным шагом

Итоги: зеркальный спуск

- **Обобщение PGD:** заменяем евклидову проекцию дивергенцией Брэгмана, адаптируя геометрию метода к задаче.
- **Скорость сходимости:** $\mathcal{O}\left(\frac{LR^2}{\sigma k}\right)$ — та же структура, что у PGD, но с параметрами, адаптированными к «правильной» норме.
- **Когда выигрывает:**
 - **Негладкие** задачи на симплексе: $\min \|Ax - b\|_1$ — выигрыш в $\sim \sqrt{n/\ln n}$ раз (и по итерациям, и по времени!)
 - **KL-дивергенция** и задачи с **относительной гладкостью**: L_2 неограничена, но MD сходится с фиксированным шагом
 - Задачи, где $\|g\|_2 \gg \|g\|_\infty$; высокоразмерные задачи, где ℓ_2 -оценки зависят от n

Итоги: зеркальный спуск

- **Обобщение PGD:** заменяем евклидову проекцию дивергенцией Брэгмана, адаптируя геометрию метода к задаче.
- **Скорость сходимости:** $\mathcal{O}\left(\frac{LR^2}{\sigma k}\right)$ — та же структура, что у PGD, но с параметрами, адаптированными к «правильной» норме.
- **Когда выигрывает:**
 - **Негладкие задачи на симплексе:** $\min \|Ax - b\|_1$ — выигрыш в $\sim \sqrt{n/\ln n}$ раз (и по итерациям, и по времени!)
 - **KL-дивергенция** и задачи с **относительной гладкостью:** L_2 неограничена, но MD сходится с фиксированным шагом
 - Задачи, где $\|g\|_2 \gg \|g\|_\infty$; высокоразмерные задачи, где ℓ_2 -оценки зависят от n
- **Ключевой результат на симплексе:** с прокс-функцией $\omega(x) = \sum_i x_i \ln x_i$ зеркальный спуск даёт оценку $\mathcal{O}\left(\frac{L_\infty \ln n}{k}\right)$ вместо $\mathcal{O}\left(\frac{nL_\infty}{k}\right)$ у PGD — экспоненциальный выигрыш по размерности.

Итоги: зеркальный спуск

- **Обобщение PGD:** заменяем евклидову проекцию дивергенцией Брэгмана, адаптируя геометрию метода к задаче.
- **Скорость сходимости:** $\mathcal{O}\left(\frac{LR^2}{\sigma k}\right)$ — та же структура, что у PGD, но с параметрами, адаптированными к «правильной» норме.
- **Когда выигрывает:**
 - **Негладкие задачи на симплексе:** $\min \|Ax - b\|_1$ — выигрыш в $\sim \sqrt{n/\ln n}$ раз (и по итерациям, и по времени!)
 - **KL-дивергенция** и задачи с **относительной гладкостью:** L_2 неограничена, но MD сходится с фиксированным шагом
 - Задачи, где $\|g\|_2 \gg \|g\|_\infty$; высокоразмерные задачи, где ℓ_2 -оценки зависят от n
- **Ключевой результат на симплексе:** с прокс-функцией $\omega(x) = \sum_i x_i \ln x_i$ зеркальный спуск даёт оценку $\mathcal{O}\left(\frac{L_\infty \ln n}{k}\right)$ вместо $\mathcal{O}\left(\frac{nL_\infty}{k}\right)$ у PGD — экспоненциальный выигрыш по размерности.
- Выбор прокс-функции ω — ключевое решение при применении метода. Общее правило: ω должна быть сильно выпуклой относительно нормы, в которой f является гладкой.