

A Corgi dog and a yellow rubber duck are sitting inside a transparent wireframe cube. The Corgi is on the left, looking towards the camera, and the rubber duck is on the right, facing the Corgi. The cube is made of thin, metallic-looking lines and is centered in the frame. The background is a plain, light-colored surface.

Градиентные методы для задач с ограничениями. Метод проекции градиента. Метод Франк-Вульфа. Метод зеркального спуска

Даня Меркулов

Методы оптимизации. МФТИ

Методы с ограничениями

Условная оптимизация

Безусловная оптимизация

$$\min_{x \in \mathbb{R}^n} f(x)$$

- Любая точка $x_0 \in \mathbb{R}^n$ допустима и может быть решением.

Условная оптимизация

Безусловная оптимизация

$$\min_{x \in \mathbb{R}^n} f(x)$$

- Любая точка $x_0 \in \mathbb{R}^n$ допустима и может быть решением.

Условная оптимизация

Безусловная оптимизация

$$\min_{x \in \mathbb{R}^n} f(x)$$

- Любая точка $x_0 \in \mathbb{R}^n$ допустима и может быть решением.

Условная оптимизация

$$\min_{x \in S} f(x)$$

- Не все $x \in \mathbb{R}^n$ допустимы и могут быть решением.

Условная оптимизация

Безусловная оптимизация

$$\min_{x \in \mathbb{R}^n} f(x)$$

- Любая точка $x_0 \in \mathbb{R}^n$ допустима и может быть решением.

Условная оптимизация

$$\min_{x \in S} f(x)$$

- Не все $x \in \mathbb{R}^n$ допустимы и могут быть решением.
- Решение должно лежать внутри множества S .

Условная оптимизация

Безусловная оптимизация

$$\min_{x \in \mathbb{R}^n} f(x)$$

- Любая точка $x_0 \in \mathbb{R}^n$ допустима и может быть решением.

Условная оптимизация

$$\min_{x \in S} f(x)$$

- Не все $x \in \mathbb{R}^n$ допустимы и могут быть решением.
- Решение должно лежать внутри множества S .
- Пример:

$$\frac{1}{2} \|Ax - b\|_2^2 \rightarrow \min_{\|x\|_2^2 \leq 1}$$

Условная оптимизация

Безусловная оптимизация

$$\min_{x \in \mathbb{R}^n} f(x)$$

- Любая точка $x_0 \in \mathbb{R}^n$ допустима и может быть решением.

Условная оптимизация

$$\min_{x \in S} f(x)$$

- Не все $x \in \mathbb{R}^n$ допустимы и могут быть решением.
- Решение должно лежать внутри множества S .
- Пример:

$$\frac{1}{2} \|Ax - b\|_2^2 \rightarrow \min_{\|x\|_2^2 \leq 1}$$

Условная оптимизация

Безусловная оптимизация

$$\min_{x \in \mathbb{R}^n} f(x)$$

- Любая точка $x_0 \in \mathbb{R}^n$ допустима и может быть решением.

Условная оптимизация

$$\min_{x \in S} f(x)$$

- Не все $x \in \mathbb{R}^n$ допустимы и могут быть решением.
- Решение должно лежать внутри множества S .
- Пример:

$$\frac{1}{2} \|Ax - b\|_2^2 \rightarrow \min_{\|x\|_2^2 \leq 1}$$

Градиентный спуск — отличный способ решения безусловных задач

$$x_{k+1} = x_k - \alpha_k \nabla f(x_k) \quad (\text{GD})$$

Можно ли адаптировать градиентный спуск для задачи с ограничениями?

Условная оптимизация

Безусловная оптимизация

$$\min_{x \in \mathbb{R}^n} f(x)$$

- Любая точка $x_0 \in \mathbb{R}^n$ допустима и может быть решением.

Условная оптимизация

$$\min_{x \in S} f(x)$$

- Не все $x \in \mathbb{R}^n$ допустимы и могут быть решением.
- Решение должно лежать внутри множества S .
- Пример:

$$\frac{1}{2} \|Ax - b\|_2^2 \rightarrow \min_{\|x\|_2^2 \leq 1}$$

Градиентный спуск — отличный способ решения безусловных задач

$$x_{k+1} = x_k - \alpha_k \nabla f(x_k) \quad (\text{GD})$$

Можно ли адаптировать градиентный спуск для задачи с ограничениями?

Да. Для этого нужно использовать проекции, чтобы обеспечить допустимость на каждой итерации.

Пример: adversarial white-box attacks




Рис. 1: Источник

- Математически нейронная сеть — это функция $f(w; x)$

$$\min_{\delta} \text{size}(\delta) \quad \text{s.t.} \quad \text{pred}[f(w; x + \delta)] \neq y$$

или

$$\max_{\delta} l(w; x + \delta, y) \quad \text{s.t.} \quad \text{size}(\delta) \leq \epsilon, \quad 0 \leq x + \delta \leq 1$$

Пример: adversarial white-box attacks




Рис. 1: Источник

- Математически нейронная сеть — это функция $f(w; x)$
- Обычно вход x задан, а веса сети w оптимизируются

$$\min_{\delta} \text{size}(\delta) \quad \text{s.t.} \quad \text{pred}[f(w; x + \delta)] \neq y$$

или

$$\max_{\delta} l(w; x + \delta, y) \quad \text{s.t.} \quad \text{size}(\delta) \leq \epsilon, \quad 0 \leq x + \delta \leq 1$$

Пример: adversarial white-box attacks




Рис. 1: Источник

- Математически нейронная сеть — это функция $f(w; x)$
- Обычно вход x задан, а веса сети w оптимизируются
- Но можно зафиксировать веса w и оптимизировать x !

$$\min_{\delta} \text{size}(\delta) \quad \text{s.t.} \quad \text{pred}[f(w; x + \delta)] \neq y$$

или

$$\max_{\delta} l(w; x + \delta, y) \quad \text{s.t.} \quad \text{size}(\delta) \leq \epsilon, \quad 0 \leq x + \delta \leq 1$$

Идея метода проекции градиента




Рис. 2: Предположим, мы стартуем из точки x_k .

Идея метода проекции градиента




Рис. 3: И движемся в направлении $-\nabla f(x_k)$.

Идея метода проекции градиента




Рис. 4: Иногда мы можем оказаться за пределами допустимого множества.

Идея метода проекции градиента




Рис. 5: Решим эту маленькую проблему с помощью проекции!

Идея метода проекции градиента

$$x_{k+1} = \text{proj}_S(x_k - \alpha_k \nabla f(x_k)) \quad \Leftrightarrow \quad \begin{aligned} y_k &= x_k - \alpha_k \nabla f(x_k) \\ x_{k+1} &= \text{proj}_S(y_k) \end{aligned}$$




Рис. 6: Иллюстрация метода проекции градиента

Проекция

Проекция

Расстояние d от точки $y \in \mathbb{R}^n$ до замкнутого множества $S \subset \mathbb{R}^n$:

$$d(y, S, \|\cdot\|) = \inf\{\|x - y\| \mid x \in S\}$$

Проекция

Расстояние d от точки $y \in \mathbb{R}^n$ до замкнутого множества $S \subset \mathbb{R}^n$:

$$d(y, S, \|\cdot\|) = \inf\{\|x - y\| \mid x \in S\}$$

Мы сосредоточимся на евклидовой проекции (возможны и другие варианты) точки $y \in \mathbb{R}^n$ на множество $S \subseteq \mathbb{R}^n$ — это точка $\text{proj}_S(y) \in S$:

$$\text{proj}_S(y) = \underset{x \in S}{\operatorname{argmin}} \frac{1}{2} \|x - y\|_2^2$$

Проекция

Расстояние d от точки $y \in \mathbb{R}^n$ до замкнутого множества $S \subset \mathbb{R}^n$:

$$d(y, S, \|\cdot\|) = \inf\{\|x - y\| \mid x \in S\}$$

Мы сосредоточимся на евклидовой проекции (возможны и другие варианты) точки $y \in \mathbb{R}^n$ на множество $S \subseteq \mathbb{R}^n$ — это точка $\text{proj}_S(y) \in S$:

$$\text{proj}_S(y) = \underset{x \in S}{\operatorname{argmin}} \frac{1}{2} \|x - y\|_2^2$$

- **Достаточные условия существования проекции.** Если $S \subseteq \mathbb{R}^n$ — замкнутое множество, то проекция на множество S существует для любой точки.

Проекция

Расстояние d от точки $y \in \mathbb{R}^n$ до замкнутого множества $S \subset \mathbb{R}^n$:

$$d(y, S, \|\cdot\|) = \inf\{\|x - y\| \mid x \in S\}$$

Мы сосредоточимся на евклидовой проекции (возможны и другие варианты) точки $y \in \mathbb{R}^n$ на множество $S \subseteq \mathbb{R}^n$ — это точка $\text{proj}_S(y) \in S$:

$$\text{proj}_S(y) = \underset{x \in S}{\operatorname{argmin}} \frac{1}{2} \|x - y\|_2^2$$

- **Достаточные условия существования проекции.** Если $S \subseteq \mathbb{R}^n$ — замкнутое множество, то проекция на множество S существует для любой точки.
- **Достаточные условия единственности проекции.** Если $S \subseteq \mathbb{R}^n$ — замкнутое выпуклое множество, то проекция на множество S единственна для любой точки.

Проекция

Расстояние d от точки $y \in \mathbb{R}^n$ до замкнутого множества $S \subset \mathbb{R}^n$:

$$d(y, S, \|\cdot\|) = \inf\{\|x - y\| \mid x \in S\}$$

Мы сосредоточимся на евклидовой проекции (возможны и другие варианты) точки $y \in \mathbb{R}^n$ на множество $S \subseteq \mathbb{R}^n$ — это точка $\text{proj}_S(y) \in S$:

$$\text{proj}_S(y) = \underset{x \in S}{\operatorname{argmin}} \frac{1}{2} \|x - y\|_2^2$$

- **Достаточные условия существования проекции.** Если $S \subseteq \mathbb{R}^n$ — замкнутое множество, то проекция на множество S существует для любой точки.
- **Достаточные условия единственности проекции.** Если $S \subseteq \mathbb{R}^n$ — замкнутое выпуклое множество, то проекция на множество S единственна для любой точки.
- Если множество открытое, а точка лежит вне этого множества, то её проекция на него может не существовать.

Проекция

Расстояние d от точки $y \in \mathbb{R}^n$ до замкнутого множества $S \subset \mathbb{R}^n$:

$$d(y, S, \|\cdot\|) = \inf\{\|x - y\| \mid x \in S\}$$

Мы сосредоточимся на евклидовой проекции (возможны и другие варианты) точки $y \in \mathbb{R}^n$ на множество $S \subseteq \mathbb{R}^n$ — это точка $\text{proj}_S(y) \in S$:

$$\text{proj}_S(y) = \underset{x \in S}{\operatorname{argmin}} \frac{1}{2} \|x - y\|_2^2$$

- **Достаточные условия существования проекции.** Если $S \subseteq \mathbb{R}^n$ — замкнутое множество, то проекция на множество S существует для любой точки.
- **Достаточные условия единственности проекции.** Если $S \subseteq \mathbb{R}^n$ — замкнутое выпуклое множество, то проекция на множество S единственна для любой точки.
- Если множество открытое, а точка лежит вне этого множества, то её проекция на него может не существовать.
- Если точка принадлежит множеству, то её проекция — это она сама.

Критерий проекции (неравенство Бурбаки-Чейни-Гольдштейна)

i Theorem

Пусть $S \subseteq \mathbb{R}^n$ — замкнутое и выпуклое множество, $\forall x \in S, y \in \mathbb{R}^n$. Тогда

$$\langle y - \text{proj}_S(y), x - \text{proj}_S(y) \rangle \leq 0 \quad (1)$$

$$\|x - \text{proj}_S(y)\|^2 + \|y - \text{proj}_S(y)\|^2 \leq \|x - y\|^2 \quad (2)$$

1. $\text{proj}_S(y)$ - минимизатор дифференцируемой выпуклой функции $d(y, S, \|\cdot\|) = \|x - y\|^2$ на множестве S . Оптимальность:




Рис. 7: Угол должен быть тупым или прямым для любой точки $x \in S$

Критерий проекции (неравенство Бурбаки-Чейни-Гольдштейна)

i Theorem

Пусть $S \subseteq \mathbb{R}^n$ — замкнутое и выпуклое множество, $\forall x \in S, y \in \mathbb{R}^n$. Тогда

$$\langle y - \text{proj}_S(y), x - \text{proj}_S(y) \rangle \leq 0 \quad (1)$$

$$\|x - \text{proj}_S(y)\|^2 + \|y - \text{proj}_S(y)\|^2 \leq \|x - y\|^2 \quad (2)$$

1. $\text{proj}_S(y)$ - минимизатор дифференцируемой выпуклой функции $d(y, S, \|\cdot\|) = \|x - y\|^2$ на множестве S . Оптимальность:

$$\nabla d(\text{proj}_S(y))^T (x - \text{proj}_S(y)) \geq 0$$




Рис. 7: Угол должен быть тупым или прямым для любой точки $x \in S$

Критерий проекции (неравенство Бурбаки-Чейни-Гольдштейна)

i Theorem

Пусть $S \subseteq \mathbb{R}^n$ — замкнутое и выпуклое множество, $\forall x \in S, y \in \mathbb{R}^n$. Тогда

$$\langle y - \text{proj}_S(y), x - \text{proj}_S(y) \rangle \leq 0 \quad (1)$$

$$\|x - \text{proj}_S(y)\|^2 + \|y - \text{proj}_S(y)\|^2 \leq \|x - y\|^2 \quad (2)$$

1. $\text{proj}_S(y)$ - минимизатор дифференцируемой выпуклой функции $d(y, S, \|\cdot\|) = \|x - y\|^2$ на множестве S . Оптимальность:

$$\nabla d(\text{proj}_S(y))^T (x - \text{proj}_S(y)) \geq 0$$

$$2 (\text{proj}_S(y) - y)^T (x - \text{proj}_S(y)) \geq 0$$




Рис. 7: Угол должен быть тупым или прямым для любой точки $x \in S$

Критерий проекции (неравенство Бурбаки-Чейни-Гольдштейна)

i Theorem

Пусть $S \subseteq \mathbb{R}^n$ — замкнутое и выпуклое множество, $\forall x \in S, y \in \mathbb{R}^n$. Тогда

$$\langle y - \text{proj}_S(y), x - \text{proj}_S(y) \rangle \leq 0 \quad (1)$$

$$\|x - \text{proj}_S(y)\|^2 + \|y - \text{proj}_S(y)\|^2 \leq \|x - y\|^2 \quad (2)$$

1. $\text{proj}_S(y)$ - минимизатор дифференцируемой выпуклой функции $d(y, S, \|\cdot\|) = \|x - y\|^2$ на множестве S . Оптимальность:

$$\nabla d(\text{proj}_S(y))^T (x - \text{proj}_S(y)) \geq 0$$

$$2 (\text{proj}_S(y) - y)^T (x - \text{proj}_S(y)) \geq 0$$

$$(y - \text{proj}_S(y))^T (x - \text{proj}_S(y)) \leq 0$$




Рис. 7: Угол должен быть тупым или прямым для любой точки $x \in S$

Критерий проекции (неравенство Бурбаки-Чейни-Гольдштейна)

i Theorem

Пусть $S \subseteq \mathbb{R}^n$ — замкнутое и выпуклое множество, $\forall x \in S, y \in \mathbb{R}^n$. Тогда

$$\langle y - \text{proj}_S(y), x - \text{proj}_S(y) \rangle \leq 0 \quad (1)$$

$$\|x - \text{proj}_S(y)\|^2 + \|y - \text{proj}_S(y)\|^2 \leq \|x - y\|^2 \quad (2)$$

1. $\text{proj}_S(y)$ - минимизатор дифференцируемой выпуклой функции $d(y, S, \|\cdot\|) = \|x - y\|^2$ на множестве S . Оптимальность:

$$\nabla d(\text{proj}_S(y))^T (x - \text{proj}_S(y)) \geq 0$$

$$2 (\text{proj}_S(y) - y)^T (x - \text{proj}_S(y)) \geq 0$$

$$(y - \text{proj}_S(y))^T (x - \text{proj}_S(y)) \leq 0$$

2. Используем теорему косинусов $2x^T y = \|x\|^2 + \|y\|^2 - \|x - y\|^2$ с $x = x - \text{proj}_S(y)$ и $y = y - \text{proj}_S(y)$.




Рис. 7: Угол должен быть тупым или прямым для любой точки $x \in S$

Критерий проекции (неравенство Бурбаки-Чейни-Гольдштейна)

i Theorem

Пусть $S \subseteq \mathbb{R}^n$ — замкнутое и выпуклое множество, $\forall x \in S, y \in \mathbb{R}^n$. Тогда

$$\langle y - \text{proj}_S(y), x - \text{proj}_S(y) \rangle \leq 0 \quad (1)$$

$$\|x - \text{proj}_S(y)\|^2 + \|y - \text{proj}_S(y)\|^2 \leq \|x - y\|^2 \quad (2)$$

1. $\text{proj}_S(y)$ - минимизатор дифференцируемой выпуклой функции $d(y, S, \|\cdot\|) = \|x - y\|^2$ на множестве S . Оптимальность:

$$\nabla d(\text{proj}_S(y))^T (x - \text{proj}_S(y)) \geq 0$$

$$2 (\text{proj}_S(y) - y)^T (x - \text{proj}_S(y)) \geq 0$$

$$(y - \text{proj}_S(y))^T (x - \text{proj}_S(y)) \leq 0$$

2. Используем теорему косинусов $2x^T y = \|x\|^2 + \|y\|^2 - \|x - y\|^2$ с $x = x - \text{proj}_S(y)$ и $y = y - \text{proj}_S(y)$.

$$0 \geq 2x^T y = \|x - \text{proj}_S(y)\|^2 + \|y - \text{proj}_S(y)\|^2 - \|x - y\|^2$$




Рис. 7: Угол должен быть тупым или прямым для любой точки $x \in S$

Критерий проекции (неравенство Бурбаки-Чейни-Гольдштейна)

i Theorem

Пусть $S \subseteq \mathbb{R}^n$ — замкнутое и выпуклое множество, $\forall x \in S, y \in \mathbb{R}^n$. Тогда

$$\langle y - \text{proj}_S(y), x - \text{proj}_S(y) \rangle \leq 0 \quad (1)$$

$$\|x - \text{proj}_S(y)\|^2 + \|y - \text{proj}_S(y)\|^2 \leq \|x - y\|^2 \quad (2)$$

1. $\text{proj}_S(y)$ - минимизатор дифференцируемой выпуклой функции $d(y, S, \|\cdot\|) = \|x - y\|^2$ на множестве S . Оптимальность:

$$\nabla d(\text{proj}_S(y))^T (x - \text{proj}_S(y)) \geq 0$$

$$2 (\text{proj}_S(y) - y)^T (x - \text{proj}_S(y)) \geq 0$$

$$(y - \text{proj}_S(y))^T (x - \text{proj}_S(y)) \leq 0$$

2. Используем теорему косинусов $2x^T y = \|x\|^2 + \|y\|^2 - \|x - y\|^2$ с $x = x - \text{proj}_S(y)$ и $y = y - \text{proj}_S(y)$.

$$0 \geq 2x^T y = \|x - \text{proj}_S(y)\|^2 + \|y - \text{proj}_S(y)\|^2 - \|x - y\|^2$$

$$\|x - \text{proj}_S(y)\|^2 + \|y - \text{proj}_S(y)\|^2 \leq \|x - y\|^2$$




Рис. 7: Угол должен быть тупым или прямым для любой точки $x \in S$

Оператор проекции - нестягивающий

- Функция f называется нестягивающей, если она является L -липшицевой с константой $L \leq 1$ ¹. То есть для любых двух точек $x, y \in \text{dom} f$

$$\|f(x) - f(y)\| \leq L\|x - y\|, \text{ где } L \leq 1.$$

Это означает, что расстояние между образами точек не превосходит расстояния между самими точками.

¹Нестягивающая функция становится сжимающей при $L < 1$.

Оператор проекции - нестягивающий

- Функция f называется нестягивающей, если она является L -липшицевой с константой $L \leq 1$ ¹. То есть для любых двух точек $x, y \in \text{dom} f$

$$\|f(x) - f(y)\| \leq L\|x - y\|, \text{ где } L \leq 1.$$

Это означает, что расстояние между образами точек не превосходит расстояния между самими точками.

- Оператор проекции является нестягивающим:

$$\|\text{proj}(x) - \text{proj}(y)\|_2 \leq \|x - y\|_2.$$

¹Нестягивающая функция становится сжимающей при $L < 1$.

Оператор проекции - нестягивающий

- Функция f называется нестягивающей, если она является L -липшицевой с константой $L \leq 1$ ¹. То есть для любых двух точек $x, y \in \text{dom} f$

$$\|f(x) - f(y)\| \leq L\|x - y\|, \text{ где } L \leq 1.$$

Это означает, что расстояние между образами точек не превосходит расстояния между самими точками.

- Оператор проекции является нестягивающим:

$$\|\text{proj}(x) - \text{proj}(y)\|_2 \leq \|x - y\|_2.$$

- Далее покажем, что из неравенства Бурбаки-Чейни-Гольдштейна следует свойство нестягиваемости, а именно:

$$\langle y - \text{proj}(y), x - \text{proj}(y) \rangle \leq 0 \quad \forall x \in S \quad \Rightarrow \quad \|\text{proj}(x) - \text{proj}(y)\|_2 \leq \|x - y\|_2.$$

¹Нестягивающая функция становится сжимающей при $L < 1$.

Оператор проекции - нестягивающий

Сокращённая запись: пусть $\pi = \text{proj}$ и $\pi(x)$ обозначает $\text{proj}(x)$.

Оператор проекции - нестягивающий

Сокращённая запись: пусть $\pi = \text{proj}$ и $\pi(x)$ обозначает $\text{proj}(x)$.

Начнём с неравенства Бурбаки-Чейни-Гольдштейна

$$\langle y - \pi(y), x - \pi(y) \rangle \leq 0 \quad \forall x \in S. \quad (3)$$

Оператор проекции - нестягивающий

Сокращённая запись: пусть $\pi = \text{proj}$ и $\pi(x)$ обозначает $\text{proj}(x)$.

Начнём с неравенства Бурбаки-Чейни-Гольдштейна

$$\langle y - \pi(y), x - \pi(y) \rangle \leq 0 \quad \forall x \in S. \quad (3)$$

Заменяем x на $\pi(x)$ в (3)

$$\langle y - \pi(y), \pi(x) - \pi(y) \rangle \leq 0. \quad (4)$$

Оператор проекции - нестягивающий

Сокращённая запись: пусть $\pi = \text{proj}$ и $\pi(x)$ обозначает $\text{proj}(x)$.

Начнём с неравенства Бурбаки-Чейни-Гольдштейна

$$\langle y - \pi(y), x - \pi(y) \rangle \leq 0 \quad \forall x \in S. \quad (3)$$

Заменим x на $\pi(x)$ в (3)

$$\langle y - \pi(y), \pi(x) - \pi(y) \rangle \leq 0. \quad (4)$$

Заменим y на x и x на $\pi(y)$ в (3)

$$\langle x - \pi(x), \pi(y) - \pi(x) \rangle \leq 0. \quad (5)$$

Оператор проекции - нестягивающий

Сокращённая запись: пусть $\pi = \text{proj}$ и $\pi(x)$ обозначает $\text{proj}(x)$.

Начнём с неравенства Бурбаки-Чейни-Гольдштейна

$$\langle y - \pi(y), x - \pi(y) \rangle \leq 0 \quad \forall x \in S. \quad (3)$$

Заменим x на $\pi(x)$ в (3)

$$\langle y - \pi(y), \pi(x) - \pi(y) \rangle \leq 0. \quad (4)$$

Заменим y на x и x на $\pi(y)$ в (3)

$$\langle x - \pi(x), \pi(y) - \pi(x) \rangle \leq 0. \quad (5)$$

(4)+(5) сократят $\pi(y) - \pi(x)$, что нежелательно. Поэтому сменим знак в (5):

$$\langle \pi(x) - x, \pi(x) - \pi(y) \rangle \leq 0. \quad (6)$$

Оператор проекции - нерастягивающий

Сокращённая запись: пусть $\pi = \text{proj}$ и $\pi(x)$ обозначает $\text{proj}(x)$.

Начнём с неравенства Бурбаки-Чейни-Гольдштейна

$$\langle y - \pi(y), x - \pi(y) \rangle \leq 0 \quad \forall x \in S. \quad (3)$$

Заменим x на $\pi(x)$ в (3)

$$\langle y - \pi(y), \pi(x) - \pi(y) \rangle \leq 0. \quad (4)$$

Заменим y на x и x на $\pi(y)$ в (3)

$$\langle x - \pi(x), \pi(y) - \pi(x) \rangle \leq 0. \quad (5)$$

(4)+(5) сократят $\pi(y) - \pi(x)$, что нежелательно. Поэтому сменим знак в (5):

$$\langle \pi(x) - x, \pi(x) - \pi(y) \rangle \leq 0. \quad (6)$$

$$\langle y - \pi(y) + \pi(x) - x, \pi(x) - \pi(y) \rangle \leq 0$$

$$\langle y - x, \pi(x) - \pi(y) \rangle \leq -\langle \pi(x) - \pi(y), \pi(x) - \pi(y) \rangle$$

$$\langle y - x, \pi(y) - \pi(x) \rangle \geq \|\pi(x) - \pi(y)\|_2^2$$

$$\|(y - x)^\top (\pi(y) - \pi(x))\|_2 \geq \|\pi(x) - \pi(y)\|_2^2$$

Оператор проекции - нерастягивающий

Сокращённая запись: пусть $\pi = \text{proj}$ и $\pi(x)$ обозначает $\text{proj}(x)$.

Начнём с неравенства Бурбаки-Чейни-Гольдштейна

$$\langle y - \pi(y), x - \pi(y) \rangle \leq 0 \quad \forall x \in S. \quad (3)$$

Заменим x на $\pi(x)$ в (3)

$$\langle y - \pi(y), \pi(x) - \pi(y) \rangle \leq 0. \quad (4)$$

Заменим y на x и x на $\pi(y)$ в (3)

$$\langle x - \pi(x), \pi(y) - \pi(x) \rangle \leq 0. \quad (5)$$

(4)+(5) сократят $\pi(y) - \pi(x)$, что нежелательно. Поэтому сменим знак в (5):

$$\langle \pi(x) - x, \pi(x) - \pi(y) \rangle \leq 0. \quad (6)$$

$$\langle y - \pi(y) + \pi(x) - x, \pi(x) - \pi(y) \rangle \leq 0$$

$$\langle y - x, \pi(x) - \pi(y) \rangle \leq -\langle \pi(x) - \pi(y), \pi(x) - \pi(y) \rangle$$

$$\langle y - x, \pi(y) - \pi(x) \rangle \geq \|\pi(x) - \pi(y)\|_2^2$$

$$\|(y - x)^\top (\pi(y) - \pi(x))\|_2 \geq \|\pi(x) - \pi(y)\|_2^2$$

По неравенству КБШ левая часть ограничена сверху величиной

$\|y - x\|_2 \|\pi(y) - \pi(x)\|_2$, откуда следует $\|y - x\|_2 \|\pi(y) - \pi(x)\|_2 \geq \|\pi(x) - \pi(y)\|_2^2$. Сокращая на $\|\pi(x) - \pi(y)\|_2$, завершаем доказательство.

Пример: проекция на шар

Найдём $\pi_S(y) = \pi$, если $S = \{x \in \mathbb{R}^n \mid \|x - x_0\| \leq R\}$, $y \notin S$

Пример: проекция на шар

Найдём $\pi_S(y) = \pi$, если $S = \{x \in \mathbb{R}^n \mid \|x - x_0\| \leq R\}$, $y \notin S$

Построим гипотезу по рисунку: $\pi = x_0 + R \cdot \frac{y - x_0}{\|y - x_0\|}$

Пример: проекция на шар

Найдём $\pi_S(y) = \pi$, если $S = \{x \in \mathbb{R}^n \mid \|x - x_0\| \leq R\}$, $y \notin S$

Построим гипотезу по рисунку: $\pi = x_0 + R \cdot \frac{y - x_0}{\|y - x_0\|}$

Проверим неравенство для замкнутого выпуклого множества:

$$(\pi - y)^T (x - \pi) \geq 0$$

Пример: проекция на шар

Найдём $\pi_S(y) = \pi$, если $S = \{x \in \mathbb{R}^n \mid \|x - x_0\| \leq R\}$, $y \notin S$

Построим гипотезу по рисунку: $\pi = x_0 + R \cdot \frac{y - x_0}{\|y - x_0\|}$

Проверим неравенство для замкнутого выпуклого множества:

$$(\pi - y)^T(x - \pi) \geq 0$$

$$\begin{aligned} & \left(x_0 - y + R \frac{y - x_0}{\|y - x_0\|} \right)^T \left(x - x_0 - R \frac{y - x_0}{\|y - x_0\|} \right) = \\ & \left(\frac{(y - x_0)(R - \|y - x_0\|)}{\|y - x_0\|} \right)^T \left(\frac{(x - x_0)\|y - x_0\| - R(y - x_0)}{\|y - x_0\|} \right) = \\ & \frac{R - \|y - x_0\|}{\|y - x_0\|^2} (y - x_0)^T ((x - x_0)\|y - x_0\| - R(y - x_0)) = \\ & \frac{R - \|y - x_0\|}{\|y - x_0\|} \left((y - x_0)^T (x - x_0) - R\|y - x_0\| \right) = \\ & (R - \|y - x_0\|) \left(\frac{(y - x_0)^T (x - x_0)}{\|y - x_0\|} - R \right) \end{aligned}$$

Пример: проекция на шар

Найдём $\pi_S(y) = \pi$, если $S = \{x \in \mathbb{R}^n \mid \|x - x_0\| \leq R\}$, $y \notin S$

Построим гипотезу по рисунку: $\pi = x_0 + R \cdot \frac{y - x_0}{\|y - x_0\|}$

Проверим неравенство для замкнутого выпуклого множества:
 $(\pi - y)^T(x - \pi) \geq 0$

Первый множитель отрицателен по выбору точки y . Второй множитель также отрицателен, что следует из КБШ:

$$\begin{aligned} & \left(x_0 - y + R \frac{y - x_0}{\|y - x_0\|} \right)^T \left(x - x_0 - R \frac{y - x_0}{\|y - x_0\|} \right) = \\ & \left(\frac{(y - x_0)(R - \|y - x_0\|)}{\|y - x_0\|} \right)^T \left(\frac{(x - x_0)\|y - x_0\| - R(y - x_0)}{\|y - x_0\|} \right) = \\ & \frac{R - \|y - x_0\|}{\|y - x_0\|^2} (y - x_0)^T ((x - x_0)\|y - x_0\| - R(y - x_0)) = \\ & \frac{R - \|y - x_0\|}{\|y - x_0\|} \left((y - x_0)^T (x - x_0) - R\|y - x_0\| \right) = \\ & (R - \|y - x_0\|) \left(\frac{(y - x_0)^T (x - x_0)}{\|y - x_0\|} - R \right) \end{aligned}$$

Пример: проекция на шар

Найдём $\pi_S(y) = \pi$, если $S = \{x \in \mathbb{R}^n \mid \|x - x_0\| \leq R\}$, $y \notin S$


Построим гипотезу по рисунку: $\pi = x_0 + R \cdot \frac{y - x_0}{\|y - x_0\|}$

Проверим неравенство для замкнутого выпуклого множества:
 $(\pi - y)^T(x - \pi) \geq 0$

$$\begin{aligned} \left(x_0 - y + R \frac{y - x_0}{\|y - x_0\|}\right)^T \left(x - x_0 - R \frac{y - x_0}{\|y - x_0\|}\right) &= \\ \left(\frac{(y - x_0)(R - \|y - x_0\|)}{\|y - x_0\|}\right)^T \left(\frac{(x - x_0)\|y - x_0\| - R(y - x_0)}{\|y - x_0\|}\right) &= \\ \frac{R - \|y - x_0\|}{\|y - x_0\|^2} (y - x_0)^T ((x - x_0)\|y - x_0\| - R(y - x_0)) &= \\ \frac{R - \|y - x_0\|}{\|y - x_0\|} \left((y - x_0)^T (x - x_0) - R\|y - x_0\|\right) &= \\ (R - \|y - x_0\|) \left(\frac{(y - x_0)^T (x - x_0)}{\|y - x_0\|} - R\right) \end{aligned}$$

Первый множитель отрицателен по выбору точки y . Второй множитель также отрицателен, что следует из КБШ:

$$\begin{aligned} (y - x_0)^T(x - x_0) &\leq \|y - x_0\|\|x - x_0\| \\ \frac{(y - x_0)^T(x - x_0)}{\|y - x_0\|} - R &\leq \frac{\|y - x_0\|\|x - x_0\|}{\|y - x_0\|} - R \end{aligned}$$



Пример: проекция на полупространство

Найдём $\pi_S(y) = \pi$, если $S = \{x \in \mathbb{R}^n \mid c^T x = b\}$, $y \notin S$. Построим гипотезу по рисунку: $\pi = y + \alpha c$. Коэффициент α выбирается так, чтобы $\pi \in S$: $c^T \pi = b$, тогда:

Пример: проекция на полупространство

Найдём $\pi_S(y) = \pi$, если $S = \{x \in \mathbb{R}^n \mid c^T x = b\}$, $y \notin S$. Построим гипотезу по рисунку: $\pi = y + \alpha c$. Коэффициент α выбирается так, чтобы $\pi \in S$: $c^T \pi = b$, тогда:




Рис. 9: Гиперплоскость

Пример: проекция на полупространство

Найдём $\pi_S(y) = \pi$, если $S = \{x \in \mathbb{R}^n \mid c^T x = b\}$, $y \notin S$. Построим гипотезу по рисунку: $\pi = y + \alpha c$. Коэффициент α выбирается так, чтобы $\pi \in S$: $c^T \pi = b$, тогда:




Рис. 9: Гиперплоскость

$$c^T(y + \alpha c) = b$$

$$c^T y + \alpha c^T c = b$$

$$c^T y = b - \alpha c^T c$$

Проверим неравенство для замкнутого выпуклого множества: $(\pi - y)^T(x - \pi) \geq 0$

$$(y + \alpha c - y)^T(x - y - \alpha c) =$$

$$\alpha c^T(x - y - \alpha c) =$$

$$\alpha(c^T x) - \alpha(c^T y) - \alpha^2(c^T c) =$$

$$\alpha b - \alpha(b - \alpha c^T c) - \alpha^2 c^T c =$$

$$\alpha b - \alpha b + \alpha^2 c^T c - \alpha^2 c^T c = 0 \geq 0$$

Метод проекции градиента (PGD)

$$x_{k+1} = \text{proj}_S(x_k - \alpha_k \nabla f(x_k)) \quad \Leftrightarrow \quad \begin{aligned} y_k &= x_k - \alpha_k \nabla f(x_k) \\ x_{k+1} &= \text{proj}_S(y_k) \end{aligned}$$




Рис. 10: Иллюстрация алгоритма метода проекции градиента



i Theorem

Пусть $f : \mathbb{R}^n \rightarrow \mathbb{R}$ — выпуклая функция с L -липшицевым градиентом. Тогда для любых $x, y \in \mathbb{R}^n$ выполняется следующее неравенство:

$$f(x) + \langle \nabla f(x), y - x \rangle + \frac{1}{2L} \|\nabla f(x) - \nabla f(y)\|_2^2 \leq f(y) \text{ или, эквивалентно,}$$
$$\|\nabla f(y) - \nabla f(x)\|_2^2 = \|\nabla f(x) - \nabla f(y)\|_2^2 \leq 2L (f(x) - f(y) - \langle \nabla f(y), x - y \rangle)$$

1. Для доказательства рассмотрим вспомогательную функцию $\varphi(y) = f(y) - \langle \nabla f(x), y \rangle$. Она является выпуклой (как сумма выпуклых функций). Легко проверить, что она является L -гладкой по определению, поскольку $\nabla \varphi(y) = \nabla f(y) - \nabla f(x)$ и $\|\nabla \varphi(y_1) - \nabla \varphi(y_2)\| = \|\nabla f(y_1) - \nabla f(y_2)\| \leq L\|y_1 - y_2\|$.



i Theorem

Пусть $f : \mathbb{R}^n \rightarrow \mathbb{R}$ — выпуклая функция с L -липшицевым градиентом. Тогда для любых $x, y \in \mathbb{R}^n$ выполняется следующее неравенство:

$$f(x) + \langle \nabla f(x), y - x \rangle + \frac{1}{2L} \|\nabla f(x) - \nabla f(y)\|_2^2 \leq f(y) \text{ или, эквивалентно,}$$
$$\|\nabla f(y) - \nabla f(x)\|_2^2 = \|\nabla f(x) - \nabla f(y)\|_2^2 \leq 2L (f(x) - f(y) - \langle \nabla f(y), x - y \rangle)$$

1. Для доказательства рассмотрим вспомогательную функцию $\varphi(y) = f(y) - \langle \nabla f(x), y \rangle$. Она является выпуклой (как сумма выпуклых функций). Легко проверить, что она является L -гладкой по определению, поскольку $\nabla \varphi(y) = \nabla f(y) - \nabla f(x)$ и $\|\nabla \varphi(y_1) - \nabla \varphi(y_2)\| = \|\nabla f(y_1) - \nabla f(y_2)\| \leq L\|y_1 - y_2\|$.
2. Теперь рассмотрим свойство липшицевой параболы для гладкой функции $\varphi(y)$:



i Theorem

Пусть $f : \mathbb{R}^n \rightarrow \mathbb{R}$ — выпуклая функция с L -липшицевым градиентом. Тогда для любых $x, y \in \mathbb{R}^n$ выполняется следующее неравенство:

$$f(x) + \langle \nabla f(x), y - x \rangle + \frac{1}{2L} \|\nabla f(x) - \nabla f(y)\|_2^2 \leq f(y) \text{ или, эквивалентно,}$$
$$\|\nabla f(y) - \nabla f(x)\|_2^2 = \|\nabla f(x) - \nabla f(y)\|_2^2 \leq 2L (f(x) - f(y) - \langle \nabla f(y), x - y \rangle)$$

1. Для доказательства рассмотрим вспомогательную функцию $\varphi(y) = f(y) - \langle \nabla f(x), y \rangle$. Она является выпуклой (как сумма выпуклых функций). Легко проверить, что она является L -гладкой по определению, поскольку $\nabla \varphi(y) = \nabla f(y) - \nabla f(x)$ и $\|\nabla \varphi(y_1) - \nabla \varphi(y_2)\| = \|\nabla f(y_1) - \nabla f(y_2)\| \leq L\|y_1 - y_2\|$.
2. Теперь рассмотрим свойство липшицевой параболы для гладкой функции $\varphi(y)$:

$$\varphi(y) \leq \varphi(x) + \langle \nabla \varphi(x), y - x \rangle + \frac{L}{2} \|y - x\|_2^2$$



i Theorem

Пусть $f : \mathbb{R}^n \rightarrow \mathbb{R}$ — выпуклая функция с L -липшицевым градиентом. Тогда для любых $x, y \in \mathbb{R}^n$ выполняется следующее неравенство:

$$f(x) + \langle \nabla f(x), y - x \rangle + \frac{1}{2L} \|\nabla f(x) - \nabla f(y)\|_2^2 \leq f(y) \text{ или, эквивалентно,}$$
$$\|\nabla f(y) - \nabla f(x)\|_2^2 = \|\nabla f(x) - \nabla f(y)\|_2^2 \leq 2L (f(x) - f(y) - \langle \nabla f(y), x - y \rangle)$$

1. Для доказательства рассмотрим вспомогательную функцию $\varphi(y) = f(y) - \langle \nabla f(x), y \rangle$. Она является выпуклой (как сумма выпуклых функций). Легко проверить, что она является L -гладкой по определению, поскольку $\nabla \varphi(y) = \nabla f(y) - \nabla f(x)$ и $\|\nabla \varphi(y_1) - \nabla \varphi(y_2)\| = \|\nabla f(y_1) - \nabla f(y_2)\| \leq L\|y_1 - y_2\|$.
2. Теперь рассмотрим свойство липшицевой параболы для гладкой функции $\varphi(y)$:

$$\varphi(y) \leq \varphi(x) + \langle \nabla \varphi(x), y - x \rangle + \frac{L}{2} \|y - x\|_2^2$$
$$x:=y, y:=y - \frac{1}{L} \nabla \varphi(y) \quad \varphi\left(y - \frac{1}{L} \nabla \varphi(y)\right) \leq \varphi(y) + \left\langle \nabla \varphi(y), -\frac{1}{L} \nabla \varphi(y) \right\rangle + \frac{1}{2L} \|\nabla \varphi(y)\|_2^2$$



i Theorem

Пусть $f : \mathbb{R}^n \rightarrow \mathbb{R}$ — выпуклая функция с L -липшицевым градиентом. Тогда для любых $x, y \in \mathbb{R}^n$ выполняется следующее неравенство:

$$f(x) + \langle \nabla f(x), y - x \rangle + \frac{1}{2L} \|\nabla f(x) - \nabla f(y)\|_2^2 \leq f(y) \text{ или, эквивалентно,}$$
$$\|\nabla f(y) - \nabla f(x)\|_2^2 = \|\nabla f(x) - \nabla f(y)\|_2^2 \leq 2L (f(x) - f(y) - \langle \nabla f(y), x - y \rangle)$$

1. Для доказательства рассмотрим вспомогательную функцию $\varphi(y) = f(y) - \langle \nabla f(x), y \rangle$. Она является выпуклой (как сумма выпуклых функций). Легко проверить, что она является L -гладкой по определению, поскольку $\nabla \varphi(y) = \nabla f(y) - \nabla f(x)$ и $\|\nabla \varphi(y_1) - \nabla \varphi(y_2)\| = \|\nabla f(y_1) - \nabla f(y_2)\| \leq L\|y_1 - y_2\|$.
2. Теперь рассмотрим свойство липшицевой параболы для гладкой функции $\varphi(y)$:

$$\varphi(y) \leq \varphi(x) + \langle \nabla \varphi(x), y - x \rangle + \frac{L}{2} \|y - x\|_2^2$$
$$x:=y, y:=y - \frac{1}{L} \nabla \varphi(y) \quad \varphi\left(y - \frac{1}{L} \nabla \varphi(y)\right) \leq \varphi(y) + \left\langle \nabla \varphi(y), -\frac{1}{L} \nabla \varphi(y) \right\rangle + \frac{1}{2L} \|\nabla \varphi(y)\|_2^2$$
$$\varphi\left(y - \frac{1}{L} \nabla \varphi(y)\right) \leq \varphi(y) - \frac{1}{2L} \|\nabla \varphi(y)\|_2^2$$

Инструменты для доказательства сходимости

3. Из условий оптимальности первого порядка для выпуклой функции $\nabla\varphi(y) = \nabla f(y) - \nabla f(x) = 0$. Можно заключить, что для любого x минимум функции $\varphi(y)$ достигается в точке $y = x$. Следовательно:

$$\varphi(x) \leq \varphi\left(y - \frac{1}{L}\nabla\varphi(y)\right) \leq \varphi(y) - \frac{1}{2L}\|\nabla\varphi(y)\|_2^2$$

Инструменты для доказательства сходимости

3. Из условий оптимальности первого порядка для выпуклой функции $\nabla\varphi(y) = \nabla f(y) - \nabla f(x) = 0$. Можно заключить, что для любого x минимум функции $\varphi(y)$ достигается в точке $y = x$. Следовательно:

$$\varphi(x) \leq \varphi\left(y - \frac{1}{L}\nabla\varphi(y)\right) \leq \varphi(y) - \frac{1}{2L}\|\nabla\varphi(y)\|_2^2$$

4. Теперь подставим $\varphi(y) = f(y) - \langle \nabla f(x), y \rangle$:

Инструменты для доказательства сходимости

3. Из условий оптимальности первого порядка для выпуклой функции $\nabla\varphi(y) = \nabla f(y) - \nabla f(x) = 0$. Можно заключить, что для любого x минимум функции $\varphi(y)$ достигается в точке $y = x$. Следовательно:

$$\varphi(x) \leq \varphi\left(y - \frac{1}{L}\nabla\varphi(y)\right) \leq \varphi(y) - \frac{1}{2L}\|\nabla\varphi(y)\|_2^2$$

4. Теперь подставим $\varphi(y) = f(y) - \langle \nabla f(x), y \rangle$:

$$f(x) - \langle \nabla f(x), x \rangle \leq f(y) - \langle \nabla f(x), y \rangle - \frac{1}{2L}\|\nabla f(y) - \nabla f(x)\|_2^2$$

Инструменты для доказательства сходимости

3. Из условий оптимальности первого порядка для выпуклой функции $\nabla\varphi(y) = \nabla f(y) - \nabla f(x) = 0$. Можно заключить, что для любого x минимум функции $\varphi(y)$ достигается в точке $y = x$. Следовательно:

$$\varphi(x) \leq \varphi\left(y - \frac{1}{L}\nabla\varphi(y)\right) \leq \varphi(y) - \frac{1}{2L}\|\nabla\varphi(y)\|_2^2$$

4. Теперь подставим $\varphi(y) = f(y) - \langle \nabla f(x), y \rangle$:

$$f(x) - \langle \nabla f(x), x \rangle \leq f(y) - \langle \nabla f(x), y \rangle - \frac{1}{2L}\|\nabla f(y) - \nabla f(x)\|_2^2$$

$$f(x) + \langle \nabla f(x), y - x \rangle + \frac{1}{2L}\|\nabla f(x) - \nabla f(y)\|_2^2 \leq f(y)$$

Инструменты для доказательства сходимости

3. Из условий оптимальности первого порядка для выпуклой функции $\nabla\varphi(y) = \nabla f(y) - \nabla f(x) = 0$. Можно заключить, что для любого x минимум функции $\varphi(y)$ достигается в точке $y = x$. Следовательно:

$$\varphi(x) \leq \varphi\left(y - \frac{1}{L}\nabla\varphi(y)\right) \leq \varphi(y) - \frac{1}{2L}\|\nabla\varphi(y)\|_2^2$$

4. Теперь подставим $\varphi(y) = f(y) - \langle \nabla f(x), y \rangle$:

$$f(x) - \langle \nabla f(x), x \rangle \leq f(y) - \langle \nabla f(x), y \rangle - \frac{1}{2L}\|\nabla f(y) - \nabla f(x)\|_2^2$$

$$f(x) + \langle \nabla f(x), y - x \rangle + \frac{1}{2L}\|\nabla f(x) - \nabla f(y)\|_2^2 \leq f(y)$$

$$\|\nabla f(y) - \nabla f(x)\|_2^2 \leq 2L(f(y) - f(x) - \langle \nabla f(x), y - x \rangle)$$

Инструменты для доказательства сходимости

3. Из условий оптимальности первого порядка для выпуклой функции $\nabla\varphi(y) = \nabla f(y) - \nabla f(x) = 0$. Можно заключить, что для любого x минимум функции $\varphi(y)$ достигается в точке $y = x$. Следовательно:

$$\varphi(x) \leq \varphi\left(y - \frac{1}{L}\nabla\varphi(y)\right) \leq \varphi(y) - \frac{1}{2L}\|\nabla\varphi(y)\|_2^2$$

4. Теперь подставим $\varphi(y) = f(y) - \langle\nabla f(x), y\rangle$:

$$f(x) - \langle\nabla f(x), x\rangle \leq f(y) - \langle\nabla f(x), y\rangle - \frac{1}{2L}\|\nabla f(y) - \nabla f(x)\|_2^2$$

$$f(x) + \langle\nabla f(x), y - x\rangle + \frac{1}{2L}\|\nabla f(x) - \nabla f(y)\|_2^2 \leq f(y)$$

$$\|\nabla f(y) - \nabla f(x)\|_2^2 \leq 2L(f(y) - f(x) - \langle\nabla f(x), y - x\rangle)$$

меняем x и y

$$\|\nabla f(x) - \nabla f(y)\|_2^2 \leq 2L(f(x) - f(y) - \langle\nabla f(y), x - y\rangle)$$

Инструменты для доказательства сходимости

3. Из условий оптимальности первого порядка для выпуклой функции $\nabla\varphi(y) = \nabla f(y) - \nabla f(x) = 0$. Можно заключить, что для любого x минимум функции $\varphi(y)$ достигается в точке $y = x$. Следовательно:

$$\varphi(x) \leq \varphi\left(y - \frac{1}{L}\nabla\varphi(y)\right) \leq \varphi(y) - \frac{1}{2L}\|\nabla\varphi(y)\|_2^2$$

4. Теперь подставим $\varphi(y) = f(y) - \langle \nabla f(x), y \rangle$:

$$f(x) - \langle \nabla f(x), x \rangle \leq f(y) - \langle \nabla f(x), y \rangle - \frac{1}{2L}\|\nabla f(y) - \nabla f(x)\|_2^2$$

$$f(x) + \langle \nabla f(x), y - x \rangle + \frac{1}{2L}\|\nabla f(x) - \nabla f(y)\|_2^2 \leq f(y)$$

$$\|\nabla f(y) - \nabla f(x)\|_2^2 \leq 2L(f(y) - f(x) - \langle \nabla f(x), y - x \rangle)$$

меняем x и y

$$\|\nabla f(x) - \nabla f(y)\|_2^2 \leq 2L(f(x) - f(y) - \langle \nabla f(y), x - y \rangle)$$

Инструменты для доказательства сходимости

3. Из условий оптимальности первого порядка для выпуклой функции $\nabla\varphi(y) = \nabla f(y) - \nabla f(x) = 0$. Можно заключить, что для любого x минимум функции $\varphi(y)$ достигается в точке $y = x$. Следовательно:

$$\varphi(x) \leq \varphi\left(y - \frac{1}{L}\nabla\varphi(y)\right) \leq \varphi(y) - \frac{1}{2L}\|\nabla\varphi(y)\|_2^2$$

4. Теперь подставим $\varphi(y) = f(y) - \langle \nabla f(x), y \rangle$:

$$f(x) - \langle \nabla f(x), x \rangle \leq f(y) - \langle \nabla f(x), y \rangle - \frac{1}{2L}\|\nabla f(y) - \nabla f(x)\|_2^2$$

$$f(x) + \langle \nabla f(x), y - x \rangle + \frac{1}{2L}\|\nabla f(x) - \nabla f(y)\|_2^2 \leq f(y)$$

$$\|\nabla f(y) - \nabla f(x)\|_2^2 \leq 2L(f(y) - f(x) - \langle \nabla f(x), y - x \rangle)$$

меняем x и y

$$\|\nabla f(x) - \nabla f(y)\|_2^2 \leq 2L(f(x) - f(y) - \langle \nabla f(y), x - y \rangle)$$

Лемма доказана. На первый взгляд она не имеет очевидной геометрической интерпретации, но мы будем использовать её как удобный инструмент для оценки разности градиентов.



i Theorem

Пусть $f : \mathbb{R}^n \rightarrow \mathbb{R}$ — непрерывно дифференцируемая функция на $\mathbb{R}^n$. Тогда функция f является μ -сильно выпуклой тогда и только тогда, когда для любых $x, y \in \mathbb{R}^d$ выполняется:

$$\text{Сильно выпуклый случай } \mu > 0 \quad \langle \nabla f(x) - \nabla f(y), x - y \rangle \geq \mu \|x - y\|^2$$

$$\text{Выпуклый случай } \mu = 0 \quad \langle \nabla f(x) - \nabla f(y), x - y \rangle \geq 0$$

Доказательство

1. Приведём доказательство только для сильно выпуклого случая; выпуклый следует из него при $\mu = 0$. Начнём с необходимости. Для сильно выпуклой функции

$$f(y) \geq f(x) + \langle \nabla f(x), y - x \rangle + \frac{\mu}{2} \|x - y\|_2^2$$

$$f(x) \geq f(y) + \langle \nabla f(y), x - y \rangle + \frac{\mu}{2} \|x - y\|_2^2$$

$$\text{сумма} \quad \langle \nabla f(x) - \nabla f(y), x - y \rangle \geq \mu \|x - y\|^2$$

Инструменты для доказательства сходимости

2. Для достаточности предположим, что $\langle \nabla f(x) - \nabla f(y), x - y \rangle \geq \mu \|x - y\|^2$. Используя формулу Ньютона-Лейбница $f(x) = f(y) + \int_0^1 \langle \nabla f(y + t(x - y)), x - y \rangle dt$:

Инструменты для доказательства сходимости

2. Для достаточности предположим, что $\langle \nabla f(x) - \nabla f(y), x - y \rangle \geq \mu \|x - y\|^2$. Используя формулу Ньютона-Лейбница $f(x) = f(y) + \int_0^1 \langle \nabla f(y + t(x - y)), x - y \rangle dt$:

$$f(x) - f(y) - \langle \nabla f(y), x - y \rangle = \int_0^1 \langle \nabla f(y + t(x - y)), x - y \rangle dt - \langle \nabla f(y), x - y \rangle$$

Инструменты для доказательства сходимости

2. Для достаточности предположим, что $\langle \nabla f(x) - \nabla f(y), x - y \rangle \geq \mu \|x - y\|^2$. Используя формулу Ньютона-Лейбница $f(x) = f(y) + \int_0^1 \langle \nabla f(y + t(x - y)), x - y \rangle dt$:

$$f(x) - f(y) - \langle \nabla f(y), x - y \rangle = \int_0^1 \langle \nabla f(y + t(x - y)), x - y \rangle dt - \langle \nabla f(y), x - y \rangle$$

$$\langle \nabla f(y), x - y \rangle = \int_0^1 \langle \nabla f(y), x - y \rangle dt \quad = \int_0^1 \langle \nabla f(y + t(x - y)) - \nabla f(y), (x - y) \rangle dt$$

Инструменты для доказательства сходимости

2. Для достаточности предположим, что $\langle \nabla f(x) - \nabla f(y), x - y \rangle \geq \mu \|x - y\|^2$. Используя формулу Ньютона-Лейбница $f(x) = f(y) + \int_0^1 \langle \nabla f(y + t(x - y)), x - y \rangle dt$:

$$\begin{aligned} f(x) - f(y) - \langle \nabla f(y), x - y \rangle &= \int_0^1 \langle \nabla f(y + t(x - y)), x - y \rangle dt - \langle \nabla f(y), x - y \rangle \\ \langle \nabla f(y), x - y \rangle &= \int_0^1 \langle \nabla f(y), x - y \rangle dt \\ y + t(x - y) - y &= t(x - y) \end{aligned} \quad \begin{aligned} &= \int_0^1 \langle \nabla f(y + t(x - y)) - \nabla f(y), (x - y) \rangle dt \\ &= \int_0^1 t^{-1} \langle \nabla f(y + t(x - y)) - \nabla f(y), t(x - y) \rangle dt \end{aligned}$$

Инструменты для доказательства сходимости

2. Для достаточности предположим, что $\langle \nabla f(x) - \nabla f(y), x - y \rangle \geq \mu \|x - y\|^2$. Используя формулу Ньютона-Лейбница $f(x) = f(y) + \int_0^1 \langle \nabla f(y + t(x - y)), x - y \rangle dt$:

$$\begin{aligned} f(x) - f(y) - \langle \nabla f(y), x - y \rangle &= \int_0^1 \langle \nabla f(y + t(x - y)), x - y \rangle dt - \langle \nabla f(y), x - y \rangle \\ \langle \nabla f(y), x - y \rangle &= \int_0^1 \langle \nabla f(y), x - y \rangle dt \\ y + t(x - y) - y &= t(x - y) \\ &= \int_0^1 \langle \nabla f(y + t(x - y)) - \nabla f(y), t(x - y) \rangle dt \\ &\geq \int_0^1 t^{-1} \mu \|t(x - y)\|^2 dt \end{aligned}$$

Инструменты для доказательства сходимости

2. Для достаточности предположим, что $\langle \nabla f(x) - \nabla f(y), x - y \rangle \geq \mu \|x - y\|^2$. Используя формулу Ньютона-Лейбница $f(x) = f(y) + \int_0^1 \langle \nabla f(y + t(x - y)), x - y \rangle dt$:

$$\begin{aligned} f(x) - f(y) - \langle \nabla f(y), x - y \rangle &= \int_0^1 \langle \nabla f(y + t(x - y)), x - y \rangle dt - \langle \nabla f(y), x - y \rangle \\ \langle \nabla f(y), x - y \rangle &= \int_0^1 \langle \nabla f(y), x - y \rangle dt \\ y + t(x - y) - y &= t(x - y) \\ &= \int_0^1 \langle \nabla f(y + t(x - y)) - \nabla f(y), t(x - y) \rangle dt \\ &\geq \int_0^1 t^{-1} \mu \|t(x - y)\|^2 dt = \mu \|x - y\|^2 \int_0^1 t dt \end{aligned}$$

Инструменты для доказательства сходимости

2. Для достаточности предположим, что $\langle \nabla f(x) - \nabla f(y), x - y \rangle \geq \mu \|x - y\|^2$. Используя формулу Ньютона-Лейбница $f(x) = f(y) + \int_0^1 \langle \nabla f(y + t(x - y)), x - y \rangle dt$:

$$\begin{aligned} f(x) - f(y) - \langle \nabla f(y), x - y \rangle &= \int_0^1 \langle \nabla f(y + t(x - y)), x - y \rangle dt - \langle \nabla f(y), x - y \rangle \\ \langle \nabla f(y), x - y \rangle &= \int_0^1 \langle \nabla f(y), x - y \rangle dt \\ y + t(x - y) - y &= t(x - y) \\ &= \int_0^1 \langle \nabla f(y + t(x - y)) - \nabla f(y), t(x - y) \rangle dt \\ &\geq \int_0^1 t^{-1} \mu \|t(x - y)\|^2 dt = \mu \|x - y\|^2 \int_0^1 t dt = \frac{\mu}{2} \|x - y\|_2^2 \end{aligned}$$

Инструменты для доказательства сходимости

2. Для достаточности предположим, что $\langle \nabla f(x) - \nabla f(y), x - y \rangle \geq \mu \|x - y\|^2$. Используя формулу Ньютона-Лейбница $f(x) = f(y) + \int_0^1 \langle \nabla f(y + t(x - y)), x - y \rangle dt$:

$$\begin{aligned} f(x) - f(y) - \langle \nabla f(y), x - y \rangle &= \int_0^1 \langle \nabla f(y + t(x - y)), x - y \rangle dt - \langle \nabla f(y), x - y \rangle \\ \langle \nabla f(y), x - y \rangle &= \int_0^1 \langle \nabla f(y), x - y \rangle dt \\ y + t(x - y) - y &= t(x - y) \\ &= \int_0^1 \langle \nabla f(y + t(x - y)) - \nabla f(y), t(x - y) \rangle dt \\ &\geq \int_0^1 t^{-1} \mu \|t(x - y)\|^2 dt = \mu \|x - y\|^2 \int_0^1 t dt = \frac{\mu}{2} \|x - y\|_2^2 \end{aligned}$$

Инструменты для доказательства сходимости

2. Для достаточности предположим, что $\langle \nabla f(x) - \nabla f(y), x - y \rangle \geq \mu \|x - y\|^2$. Используя формулу Ньютона-Лейбница $f(x) = f(y) + \int_0^1 \langle \nabla f(y + t(x - y)), x - y \rangle dt$:

$$\begin{aligned} f(x) - f(y) - \langle \nabla f(y), x - y \rangle &= \int_0^1 \langle \nabla f(y + t(x - y)), x - y \rangle dt - \langle \nabla f(y), x - y \rangle \\ \langle \nabla f(y), x - y \rangle &= \int_0^1 \langle \nabla f(y), x - y \rangle dt \\ y + t(x - y) - y &= t(x - y) \\ &= \int_0^1 \langle \nabla f(y + t(x - y)) - \nabla f(y), t(x - y) \rangle dt \\ &\geq \int_0^1 t^{-1} \mu \|t(x - y)\|^2 dt = \mu \|x - y\|^2 \int_0^1 t dt = \frac{\mu}{2} \|x - y\|_2^2 \end{aligned}$$

Таким образом, критерий сильной выпуклости выполнен

$$f(x) \geq f(y) + \langle \nabla f(y), x - y \rangle + \frac{\mu}{2} \|x - y\|_2^2$$

Инструменты для доказательства сходимости

2. Для достаточности предположим, что $\langle \nabla f(x) - \nabla f(y), x - y \rangle \geq \mu \|x - y\|^2$. Используя формулу Ньютона-Лейбница $f(x) = f(y) + \int_0^1 \langle \nabla f(y + t(x - y)), x - y \rangle dt$:

$$\begin{aligned} f(x) - f(y) - \langle \nabla f(y), x - y \rangle &= \int_0^1 \langle \nabla f(y + t(x - y)), x - y \rangle dt - \langle \nabla f(y), x - y \rangle \\ \langle \nabla f(y), x - y \rangle &= \int_0^1 \langle \nabla f(y), x - y \rangle dt \\ y + t(x - y) - y &= t(x - y) \\ &= \int_0^1 \langle \nabla f(y + t(x - y)) - \nabla f(y), t(x - y) \rangle dt \\ &\geq \int_0^1 t^{-1} \mu \|t(x - y)\|^2 dt = \mu \|x - y\|^2 \int_0^1 t dt = \frac{\mu}{2} \|x - y\|_2^2 \end{aligned}$$

Таким образом, критерий сильной выпуклости выполнен

$$f(x) \geq f(y) + \langle \nabla f(y), x - y \rangle + \frac{\mu}{2} \|x - y\|_2^2 \text{ или, эквивалентно:}$$

Инструменты для доказательства сходимости

2. Для достаточности предположим, что $\langle \nabla f(x) - \nabla f(y), x - y \rangle \geq \mu \|x - y\|^2$. Используя формулу Ньютона-Лейбница $f(x) = f(y) + \int_0^1 \langle \nabla f(y + t(x - y)), x - y \rangle dt$:

$$\begin{aligned} f(x) - f(y) - \langle \nabla f(y), x - y \rangle &= \int_0^1 \langle \nabla f(y + t(x - y)), x - y \rangle dt - \langle \nabla f(y), x - y \rangle \\ \langle \nabla f(y), x - y \rangle &= \int_0^1 \langle \nabla f(y), x - y \rangle dt \\ y + t(x - y) - y &= t(x - y) \\ &= \int_0^1 \langle \nabla f(y + t(x - y)) - \nabla f(y), t(x - y) \rangle dt \\ &\geq \int_0^1 t^{-1} \mu \|t(x - y)\|^2 dt = \mu \|x - y\|^2 \int_0^1 t dt = \frac{\mu}{2} \|x - y\|_2^2 \end{aligned}$$

Таким образом, критерий сильной выпуклости выполнен

$$f(x) \geq f(y) + \langle \nabla f(y), x - y \rangle + \frac{\mu}{2} \|x - y\|_2^2 \text{ или, эквивалентно:}$$

$$\text{меняем } x \text{ и } y \quad - \langle \nabla f(x), x - y \rangle \leq - \left(f(x) - f(y) + \frac{\mu}{2} \|x - y\|_2^2 \right)$$

Скорость сходимости для гладкого выпуклого случая

Theorem

Пусть $f : \mathbb{R}^n \rightarrow \mathbb{R}$ — выпуклая и дифференцируемая функция. Пусть $S \subseteq \mathbb{R}^n$ — замкнутое выпуклое множество, и существует минимизатор x^* функции f на S ; кроме того, предположим, что f является гладкой на S с параметром L . Алгоритм метода проекции градиента с шагом $\frac{1}{L}$ обеспечивает следующую сходимость после $k > 0$ итераций:

$$f(x_k) - f^* \leq \frac{L\|x_0 - x^*\|_2^2}{2k}$$

Скорость сходимости для гладкого выпуклого случая

Theorem

Пусть $f : \mathbb{R}^n \rightarrow \mathbb{R}$ — выпуклая и дифференцируемая функция. Пусть $S \subseteq \mathbb{R}^n$ — замкнутое выпуклое множество, и существует минимизатор x^* функции f на S ; кроме того, предположим, что f является гладкой на S с параметром L . Алгоритм метода проекции градиента с шагом $\frac{1}{L}$ обеспечивает следующую сходимость после $k > 0$ итераций:

$$f(x_k) - f^* \leq \frac{L\|x_0 - x^*\|_2^2}{2k}$$

1. Докажем лемму о достаточном убывании, полагая $y_k = x_k - \frac{1}{L}\nabla f(x_k)$ и используя теорему косинусов $2x^T y = \|x\|^2 + \|y\|^2 - \|x - y\|^2$:

Скорость сходимости для гладкого выпуклого случая

Theorem

Пусть $f : \mathbb{R}^n \rightarrow \mathbb{R}$ — выпуклая и дифференцируемая функция. Пусть $S \subseteq \mathbb{R}^n$ — замкнутое выпуклое множество, и существует минимизатор x^* функции f на S ; кроме того, предположим, что f является гладкой на S с параметром L . Алгоритм метода проекции градиента с шагом $\frac{1}{L}$ обеспечивает следующую сходимость после $k > 0$ итераций:

$$f(x_k) - f^* \leq \frac{L\|x_0 - x^*\|_2^2}{2k}$$

1. Докажем лемму о достаточном убывании, полагая $y_k = x_k - \frac{1}{L}\nabla f(x_k)$ и используя теорему косинусов $2x^T y = \|x\|^2 + \|y\|^2 - \|x - y\|^2$:

Гладкость:
$$f(x_{k+1}) \leq f(x_k) + \langle \nabla f(x_k), x_{k+1} - x_k \rangle + \frac{L}{2}\|x_{k+1} - x_k\|^2$$

Скорость сходимости для гладкого выпуклого случая

Theorem

Пусть $f : \mathbb{R}^n \rightarrow \mathbb{R}$ — выпуклая и дифференцируемая функция. Пусть $S \subseteq \mathbb{R}^n$ — замкнутое выпуклое множество, и существует минимизатор x^* функции f на S ; кроме того, предположим, что f является гладкой на S с параметром L . Алгоритм метода проекции градиента с шагом $\frac{1}{L}$ обеспечивает следующую сходимость после $k > 0$ итераций:

$$f(x_k) - f^* \leq \frac{L\|x_0 - x^*\|_2^2}{2k}$$

1. Докажем лемму о достаточном убывании, полагая $y_k = x_k - \frac{1}{L}\nabla f(x_k)$ и используя теорему косинусов $2x^T y = \|x\|^2 + \|y\|^2 - \|x - y\|^2$:

Гладкость:
$$f(x_{k+1}) \leq f(x_k) + \langle \nabla f(x_k), x_{k+1} - x_k \rangle + \frac{L}{2}\|x_{k+1} - x_k\|^2$$

Метод:
$$= f(x_k) - L\langle y_k - x_k, x_{k+1} - x_k \rangle + \frac{L}{2}\|x_{k+1} - x_k\|^2$$

Скорость сходимости для гладкого выпуклого случая

Theorem

Пусть $f : \mathbb{R}^n \rightarrow \mathbb{R}$ — выпуклая и дифференцируемая функция. Пусть $S \subseteq \mathbb{R}^n$ — замкнутое выпуклое множество, и существует минимизатор x^* функции f на S ; кроме того, предположим, что f является гладкой на S с параметром L . Алгоритм метода проекции градиента с шагом $\frac{1}{L}$ обеспечивает следующую сходимость после $k > 0$ итераций:

$$f(x_k) - f^* \leq \frac{L\|x_0 - x^*\|_2^2}{2k}$$

1. Докажем лемму о достаточном убывании, полагая $y_k = x_k - \frac{1}{L}\nabla f(x_k)$ и используя теорему косинусов $2x^T y = \|x\|^2 + \|y\|^2 - \|x - y\|^2$:

Гладкость:
$$f(x_{k+1}) \leq f(x_k) + \langle \nabla f(x_k), x_{k+1} - x_k \rangle + \frac{L}{2}\|x_{k+1} - x_k\|^2$$

Метод:
$$= f(x_k) - L\langle y_k - x_k, x_{k+1} - x_k \rangle + \frac{L}{2}\|x_{k+1} - x_k\|^2$$

Теорема косинусов:
$$= f(x_k) - \frac{L}{2}(\|y_k - x_k\|^2 + \|x_{k+1} - x_k\|^2 - \|y_k - x_{k+1}\|^2) + \frac{L}{2}\|x_{k+1} - x_k\|^2$$

Скорость сходимости для гладкого выпуклого случая

Theorem

Пусть $f : \mathbb{R}^n \rightarrow \mathbb{R}$ — выпуклая и дифференцируемая функция. Пусть $S \subseteq \mathbb{R}^n$ — замкнутое выпуклое множество, и существует минимизатор x^* функции f на S ; кроме того, предположим, что f является гладкой на S с параметром L . Алгоритм метода проекции градиента с шагом $\frac{1}{L}$ обеспечивает следующую сходимость после $k > 0$ итераций:

$$f(x_k) - f^* \leq \frac{L\|x_0 - x^*\|_2^2}{2k}$$

1. Докажем лемму о достаточном убывании, полагая $y_k = x_k - \frac{1}{L}\nabla f(x_k)$ и используя теорему косинусов $2x^T y = \|x\|^2 + \|y\|^2 - \|x - y\|^2$:

Гладкость:
$$f(x_{k+1}) \leq f(x_k) + \langle \nabla f(x_k), x_{k+1} - x_k \rangle + \frac{L}{2}\|x_{k+1} - x_k\|^2$$

Метод:
$$= f(x_k) - L\langle y_k - x_k, x_{k+1} - x_k \rangle + \frac{L}{2}\|x_{k+1} - x_k\|^2$$

Теорема косинусов:
$$\begin{aligned} &= f(x_k) - \frac{L}{2}(\|y_k - x_k\|^2 + \|x_{k+1} - x_k\|^2 - \|y_k - x_{k+1}\|^2) + \frac{L}{2}\|x_{k+1} - x_k\|^2 \\ &= f(x_k) - \frac{1}{2L}\|\nabla f(x_k)\|^2 + \frac{L}{2}\|y_k - x_{k+1}\|^2 \end{aligned}$$

Скорость сходимости для гладкого выпуклого случая

2. Пока что мы не получаем немедленного прогресса на каждом шаге. Снова используем теорему косинусов:

$$\begin{aligned}\left\langle \frac{1}{L} \nabla f(x_k), x_k - x^* \right\rangle &= \frac{1}{2} \left(\frac{1}{L^2} \|\nabla f(x_k)\|^2 + \|x_k - x^*\|^2 - \|x_k - x^* - \frac{1}{L} \nabla f(x_k)\|^2 \right) \\ \langle \nabla f(x_k), x_k - x^* \rangle &= \frac{L}{2} \left(\frac{1}{L^2} \|\nabla f(x_k)\|^2 + \|x_k - x^*\|^2 - \|y_k - x^*\|^2 \right)\end{aligned}$$

Скорость сходимости для гладкого выпуклого случая

2. Пока что мы не получаем немедленного прогресса на каждом шаге. Снова используем теорему косинусов:

$$\left\langle \frac{1}{L} \nabla f(x_k), x_k - x^* \right\rangle = \frac{1}{2} \left(\frac{1}{L^2} \|\nabla f(x_k)\|^2 + \|x_k - x^*\|^2 - \|x_k - x^* - \frac{1}{L} \nabla f(x_k)\|^2 \right)$$
$$\langle \nabla f(x_k), x_k - x^* \rangle = \frac{L}{2} \left(\frac{1}{L^2} \|\nabla f(x_k)\|^2 + \|x_k - x^*\|^2 - \|y_k - x^*\|^2 \right)$$

3. Теперь используем свойство проекции: $\|x - \text{proj}_S(y)\|^2 + \|y - \text{proj}_S(y)\|^2 \leq \|x - y\|^2$ с $x = x^*, y = y_k$:

$$\|x^* - \text{proj}_S(y_k)\|^2 + \|y_k - \text{proj}_S(y_k)\|^2 \leq \|x^* - y_k\|^2$$
$$\|y_k - x^*\|^2 \geq \|x^* - x_{k+1}\|^2 + \|y_k - x_{k+1}\|^2$$

Скорость сходимости для гладкого выпуклого случая

2. Пока что мы не получаем немедленного прогресса на каждом шаге. Снова используем теорему косинусов:

$$\begin{aligned}\left\langle \frac{1}{L} \nabla f(x_k), x_k - x^* \right\rangle &= \frac{1}{2} \left(\frac{1}{L^2} \|\nabla f(x_k)\|^2 + \|x_k - x^*\|^2 - \|x_k - x^* - \frac{1}{L} \nabla f(x_k)\|^2 \right) \\ \langle \nabla f(x_k), x_k - x^* \rangle &= \frac{L}{2} \left(\frac{1}{L^2} \|\nabla f(x_k)\|^2 + \|x_k - x^*\|^2 - \|y_k - x^*\|^2 \right)\end{aligned}$$

3. Теперь используем свойство проекции: $\|x - \text{proj}_S(y)\|^2 + \|y - \text{proj}_S(y)\|^2 \leq \|x - y\|^2$ с $x = x^*, y = y_k$:

$$\begin{aligned}\|x^* - \text{proj}_S(y_k)\|^2 + \|y_k - \text{proj}_S(y_k)\|^2 &\leq \|x^* - y_k\|^2 \\ \|y_k - x^*\|^2 &\geq \|x^* - x_{k+1}\|^2 + \|y_k - x_{k+1}\|^2\end{aligned}$$

4. Теперь, используя выпуклость и предыдущую часть:

Скорость сходимости для гладкого выпуклого случая

2. Пока что мы не получаем немедленного прогресса на каждом шаге. Снова используем теорему косинусов:

$$\begin{aligned}\left\langle \frac{1}{L} \nabla f(x_k), x_k - x^* \right\rangle &= \frac{1}{2} \left(\frac{1}{L^2} \|\nabla f(x_k)\|^2 + \|x_k - x^*\|^2 - \|x_k - x^* - \frac{1}{L} \nabla f(x_k)\|^2 \right) \\ \langle \nabla f(x_k), x_k - x^* \rangle &= \frac{L}{2} \left(\frac{1}{L^2} \|\nabla f(x_k)\|^2 + \|x_k - x^*\|^2 - \|y_k - x^*\|^2 \right)\end{aligned}$$

3. Теперь используем свойство проекции: $\|x - \text{proj}_S(y)\|^2 + \|y - \text{proj}_S(y)\|^2 \leq \|x - y\|^2$ с $x = x^*, y = y_k$:

$$\begin{aligned}\|x^* - \text{proj}_S(y_k)\|^2 + \|y_k - \text{proj}_S(y_k)\|^2 &\leq \|x^* - y_k\|^2 \\ \|y_k - x^*\|^2 &\geq \|x^* - x_{k+1}\|^2 + \|y_k - x_{k+1}\|^2\end{aligned}$$

4. Теперь, используя выпуклость и предыдущую часть:

Выпуклость:
$$f(x_k) - f^* \leq \langle \nabla f(x_k), x_k - x^* \rangle$$

Скорость сходимости для гладкого выпуклого случая

2. Пока что мы не получаем немедленного прогресса на каждом шаге. Снова используем теорему косинусов:

$$\begin{aligned}\left\langle \frac{1}{L} \nabla f(x_k), x_k - x^* \right\rangle &= \frac{1}{2} \left(\frac{1}{L^2} \|\nabla f(x_k)\|^2 + \|x_k - x^*\|^2 - \|x_k - x^* - \frac{1}{L} \nabla f(x_k)\|^2 \right) \\ \langle \nabla f(x_k), x_k - x^* \rangle &= \frac{L}{2} \left(\frac{1}{L^2} \|\nabla f(x_k)\|^2 + \|x_k - x^*\|^2 - \|y_k - x^*\|^2 \right)\end{aligned}$$

3. Теперь используем свойство проекции: $\|x - \text{proj}_S(y)\|^2 + \|y - \text{proj}_S(y)\|^2 \leq \|x - y\|^2$ с $x = x^*, y = y_k$:

$$\begin{aligned}\|x^* - \text{proj}_S(y_k)\|^2 + \|y_k - \text{proj}_S(y_k)\|^2 &\leq \|x^* - y_k\|^2 \\ \|y_k - x^*\|^2 &\geq \|x^* - x_{k+1}\|^2 + \|y_k - x_{k+1}\|^2\end{aligned}$$

4. Теперь, используя выпуклость и предыдущую часть:

Выпуклость:

$$\begin{aligned}f(x_k) - f^* &\leq \langle \nabla f(x_k), x_k - x^* \rangle \\ &\leq \frac{L}{2} \left(\frac{1}{L^2} \|\nabla f(x_k)\|^2 + \|x_k - x^*\|^2 - \|x_{k+1} - x^*\|^2 - \|y_k - x_{k+1}\|^2 \right)\end{aligned}$$

Скорость сходимости для гладкого выпуклого случая

2. Пока что мы не получаем немедленного прогресса на каждом шаге. Снова используем теорему косинусов:

$$\begin{aligned}\left\langle \frac{1}{L} \nabla f(x_k), x_k - x^* \right\rangle &= \frac{1}{2} \left(\frac{1}{L^2} \|\nabla f(x_k)\|^2 + \|x_k - x^*\|^2 - \|x_k - x^* - \frac{1}{L} \nabla f(x_k)\|^2 \right) \\ \langle \nabla f(x_k), x_k - x^* \rangle &= \frac{L}{2} \left(\frac{1}{L^2} \|\nabla f(x_k)\|^2 + \|x_k - x^*\|^2 - \|y_k - x^*\|^2 \right)\end{aligned}$$

3. Теперь используем свойство проекции: $\|x - \text{proj}_S(y)\|^2 + \|y - \text{proj}_S(y)\|^2 \leq \|x - y\|^2$ с $x = x^*, y = y_k$:

$$\begin{aligned}\|x^* - \text{proj}_S(y_k)\|^2 + \|y_k - \text{proj}_S(y_k)\|^2 &\leq \|x^* - y_k\|^2 \\ \|y_k - x^*\|^2 &\geq \|x^* - x_{k+1}\|^2 + \|y_k - x_{k+1}\|^2\end{aligned}$$

4. Теперь, используя выпуклость и предыдущую часть:

Выпуклость:

$$\begin{aligned}f(x_k) - f^* &\leq \langle \nabla f(x_k), x_k - x^* \rangle \\ &\leq \frac{L}{2} \left(\frac{1}{L^2} \|\nabla f(x_k)\|^2 + \|x_k - x^*\|^2 - \|x_{k+1} - x^*\|^2 - \|y_k - x_{k+1}\|^2 \right)\end{aligned}$$

$$\text{Сумма для } i = 0, k-1 \quad \sum_{i=0}^{k-1} [f(x_i) - f^*] \leq \sum_{i=0}^{k-1} \frac{1}{2L} \|\nabla f(x_i)\|^2 + \frac{L}{2} \|x_0 - x^*\|^2 - \frac{L}{2} \sum_{i=0}^{i-1} \|y_i - x_{i+1}\|^2$$

Скорость сходимости для гладкого выпуклого случая

5. Оценим градиенты с помощью неравенства достаточного убывания 7:

Скорость сходимости для гладкого выпуклого случая

5. Оценим градиенты с помощью неравенства достаточного убывания 7:

$$\sum_{i=0}^{k-1} [f(x_i) - f^*] \leq \sum_{i=0}^{k-1} \left[f(x_i) - f(x_{i+1}) + \frac{L}{2} \|y_i - x_{i+1}\|^2 \right] + \frac{L}{2} \|x_0 - x^*\|^2 - \frac{L}{2} \sum_{i=0}^{i-1} \|y_i - x_{i+1}\|^2$$

Скорость сходимости для гладкого выпуклого случая

5. Оценим градиенты с помощью неравенства достаточного убывания 7:

$$\begin{aligned}\sum_{i=0}^{k-1} [f(x_i) - f^*] &\leq \sum_{i=0}^{k-1} \left[f(x_i) - f(x_{i+1}) + \frac{L}{2} \|y_i - x_{i+1}\|^2 \right] + \frac{L}{2} \|x_0 - x^*\|^2 - \frac{L}{2} \sum_{i=0}^{i-1} \|y_i - x_{i+1}\|^2 \\ &\leq f(x_0) - f(x_k) + \frac{L}{2} \sum_{i=0}^{i-1} \|y_i - x_{i+1}\|^2 + \frac{L}{2} \|x_0 - x^*\|^2 - \frac{L}{2} \sum_{i=0}^{i-1} \|y_i - x_{i+1}\|^2\end{aligned}$$

Скорость сходимости для гладкого выпуклого случая

5. Оценим градиенты с помощью неравенства достаточного убывания 7:

$$\begin{aligned}\sum_{i=0}^{k-1} [f(x_i) - f^*] &\leq \sum_{i=0}^{k-1} \left[f(x_i) - f(x_{i+1}) + \frac{L}{2} \|y_i - x_{i+1}\|^2 \right] + \frac{L}{2} \|x_0 - x^*\|^2 - \frac{L}{2} \sum_{i=0}^{i-1} \|y_i - x_{i+1}\|^2 \\ &\leq f(x_0) - f(x_k) + \frac{L}{2} \sum_{i=0}^{i-1} \|y_i - x_{i+1}\|^2 + \frac{L}{2} \|x_0 - x^*\|^2 - \frac{L}{2} \sum_{i=0}^{i-1} \|y_i - x_{i+1}\|^2 \\ &\leq f(x_0) - f(x_k) + \frac{L}{2} \|x_0 - x^*\|^2\end{aligned}$$

Скорость сходимости для гладкого выпуклого случая

5. Оценим градиенты с помощью неравенства достаточного убывания 7:

$$\begin{aligned}\sum_{i=0}^{k-1} [f(x_i) - f^*] &\leq \sum_{i=0}^{k-1} \left[f(x_i) - f(x_{i+1}) + \frac{L}{2} \|y_i - x_{i+1}\|^2 \right] + \frac{L}{2} \|x_0 - x^*\|^2 - \frac{L}{2} \sum_{i=0}^{i-1} \|y_i - x_{i+1}\|^2 \\ &\leq f(x_0) - f(x_k) + \frac{L}{2} \sum_{i=0}^{i-1} \|y_i - x_{i+1}\|^2 + \frac{L}{2} \|x_0 - x^*\|^2 - \frac{L}{2} \sum_{i=0}^{i-1} \|y_i - x_{i+1}\|^2 \\ &\leq f(x_0) - f(x_k) + \frac{L}{2} \|x_0 - x^*\|^2 \\ \sum_{i=0}^{k-1} f(x_i) - kf^* &\leq f(x_0) - f(x_k) + \frac{L}{2} \|x_0 - x^*\|^2\end{aligned}$$

Скорость сходимости для гладкого выпуклого случая

5. Оценим градиенты с помощью неравенства достаточного убывания 7:

$$\begin{aligned}\sum_{i=0}^{k-1} [f(x_i) - f^*] &\leq \sum_{i=0}^{k-1} \left[f(x_i) - f(x_{i+1}) + \frac{L}{2} \|y_i - x_{i+1}\|^2 \right] + \frac{L}{2} \|x_0 - x^*\|^2 - \frac{L}{2} \sum_{i=0}^{i-1} \|y_i - x_{i+1}\|^2 \\ &\leq f(x_0) - f(x_k) + \frac{L}{2} \sum_{i=0}^{i-1} \|y_i - x_{i+1}\|^2 + \frac{L}{2} \|x_0 - x^*\|^2 - \frac{L}{2} \sum_{i=0}^{i-1} \|y_i - x_{i+1}\|^2 \\ &\leq f(x_0) - f(x_k) + \frac{L}{2} \|x_0 - x^*\|^2 \\ \sum_{i=0}^{k-1} f(x_i) - kf^* &\leq f(x_0) - f(x_k) + \frac{L}{2} \|x_0 - x^*\|^2 \\ \sum_{i=1}^k [f(x_i) - f^*] &\leq \frac{L}{2} \|x_0 - x^*\|^2\end{aligned}$$

Скорость сходимости для гладкого выпуклого случая

6. Из неравенства достаточного убывания

$$f(x_{k+1}) \leq f(x_k) - \frac{1}{2L} \|\nabla f(x_k)\|^2 + \frac{L}{2} \|y_k - x_{k+1}\|^2,$$

Скорость сходимости для гладкого выпуклого случая

6. Из неравенства достаточного убывания

$$f(x_{k+1}) \leq f(x_k) - \frac{1}{2L} \|\nabla f(x_k)\|^2 + \frac{L}{2} \|y_k - x_{k+1}\|^2,$$

Скорость сходимости для гладкого выпуклого случая

6. Из неравенства достаточного убывания

$$f(x_{k+1}) \leq f(x_k) - \frac{1}{2L} \|\nabla f(x_k)\|^2 + \frac{L}{2} \|y_k - x_{k+1}\|^2,$$

используем тот факт, что $x_{k+1} = \text{proj}_S(y_k)$. По определению проекции,

$$\|y_k - x_{k+1}\| \leq \|y_k - x_k\|,$$

Скорость сходимости для гладкого выпуклого случая

6. Из неравенства достаточного убывания

$$f(x_{k+1}) \leq f(x_k) - \frac{1}{2L} \|\nabla f(x_k)\|^2 + \frac{L}{2} \|y_k - x_{k+1}\|^2,$$

используем тот факт, что $x_{k+1} = \text{proj}_S(y_k)$. По определению проекции,

$$\|y_k - x_{k+1}\| \leq \|y_k - x_k\|,$$

и вспомним, что $y_k = x_k - \frac{1}{L} \nabla f(x_k)$ означает $\|y_k - x_k\| = \frac{1}{L} \|\nabla f(x_k)\|$. Следовательно,

$$\frac{L}{2} \|y_k - x_{k+1}\|^2 \leq \frac{L}{2} \|y_k - x_k\|^2 = \frac{L}{2} \frac{1}{L^2} \|\nabla f(x_k)\|^2 = \frac{1}{2L} \|\nabla f(x_k)\|^2.$$

Скорость сходимости для гладкого выпуклого случая

6. Из неравенства достаточного убывания

$$f(x_{k+1}) \leq f(x_k) - \frac{1}{2L} \|\nabla f(x_k)\|^2 + \frac{L}{2} \|y_k - x_{k+1}\|^2,$$

используем тот факт, что $x_{k+1} = \text{proj}_S(y_k)$. По определению проекции,

$$\|y_k - x_{k+1}\| \leq \|y_k - x_k\|,$$

и вспомним, что $y_k = x_k - \frac{1}{L} \nabla f(x_k)$ означает $\|y_k - x_k\| = \frac{1}{L} \|\nabla f(x_k)\|$. Следовательно,

$$\frac{L}{2} \|y_k - x_{k+1}\|^2 \leq \frac{L}{2} \|y_k - x_k\|^2 = \frac{L}{2} \frac{1}{L^2} \|\nabla f(x_k)\|^2 = \frac{1}{2L} \|\nabla f(x_k)\|^2.$$

Подставим обратно в (*):

$$f(x_{k+1}) \leq f(x_k) - \frac{1}{2L} \|\nabla f(x_k)\|^2 + \frac{1}{2L} \|\nabla f(x_k)\|^2 = f(x_k).$$

Скорость сходимости для гладкого выпуклого случая

6. Из неравенства достаточного убывания

$$f(x_{k+1}) \leq f(x_k) - \frac{1}{2L} \|\nabla f(x_k)\|^2 + \frac{L}{2} \|y_k - x_{k+1}\|^2,$$

используем тот факт, что $x_{k+1} = \text{proj}_S(y_k)$. По определению проекции,

$$\|y_k - x_{k+1}\| \leq \|y_k - x_k\|,$$

и вспомним, что $y_k = x_k - \frac{1}{L} \nabla f(x_k)$ означает $\|y_k - x_k\| = \frac{1}{L} \|\nabla f(x_k)\|$. Следовательно,

$$\frac{L}{2} \|y_k - x_{k+1}\|^2 \leq \frac{L}{2} \|y_k - x_k\|^2 = \frac{L}{2} \frac{1}{L^2} \|\nabla f(x_k)\|^2 = \frac{1}{2L} \|\nabla f(x_k)\|^2.$$

Подставим обратно в (*):

$$f(x_{k+1}) \leq f(x_k) - \frac{1}{2L} \|\nabla f(x_k)\|^2 + \frac{1}{2L} \|\nabla f(x_k)\|^2 = f(x_k).$$

Таким образом,

$$f(x_{k+1}) \leq f(x_k) \quad \text{для каждого } k,$$

то есть $\{f(x_k)\}$ — монотонно невозрастающая последовательность.

Скорость сходимости для гладкого выпуклого случая

7. Итоговая оценка сходимости Из шага 5 мы уже установили

$$\sum_{i=0}^{k-1} [f(x_i) - f^*] \leq \frac{L}{2} \|x_0 - x^*\|_2^2.$$

Скорость сходимости для гладкого выпуклого случая

7. Итоговая оценка сходимости Из шага 5 мы уже установили

$$\sum_{i=0}^{k-1} [f(x_i) - f^*] \leq \frac{L}{2} \|x_0 - x^*\|_2^2.$$

Скорость сходимости для гладкого выпуклого случая

7. Итоговая оценка сходимости Из шага 5 мы уже установили

$$\sum_{i=0}^{k-1} [f(x_i) - f^*] \leq \frac{L}{2} \|x_0 - x^*\|_2^2.$$

Поскольку $f(x_i)$ убывает по i , в частности $f(x_k) \leq f(x_i)$ для всех $i \leq k$. Следовательно,

$$k [f(x_k) - f^*] \leq \sum_{i=0}^{k-1} [f(x_i) - f^*] \leq \frac{L}{2} \|x_0 - x^*\|_2^2,$$

Скорость сходимости для гладкого выпуклого случая

7. Итоговая оценка сходимости Из шага 5 мы уже установили

$$\sum_{i=0}^{k-1} [f(x_i) - f^*] \leq \frac{L}{2} \|x_0 - x^*\|_2^2.$$

Поскольку $f(x_i)$ убывает по i , в частности $f(x_k) \leq f(x_i)$ для всех $i \leq k$. Следовательно,

$$k [f(x_k) - f^*] \leq \sum_{i=0}^{k-1} [f(x_i) - f^*] \leq \frac{L}{2} \|x_0 - x^*\|_2^2,$$

откуда немедленно получаем

$$f(x_k) - f^* \leq \frac{L \|x_0 - x^*\|_2^2}{2k}.$$

Это завершает доказательство скорости сходимости $\mathcal{O}(\frac{1}{k})$ для выпуклой L -гладкой функции f в условной задаче оптимизации.

Скорость сходимости для гладкого сильно выпуклого случая

Theorem

Пусть $f : \mathbb{R}^n \rightarrow \mathbb{R}$ — μ -сильно выпуклая функция. Пусть $S \subseteq \mathbb{R}^n$ — замкнутое выпуклое множество, и существует минимизатор x^* функции f на S ; кроме того, предположим, что f является гладкой на S с параметром L . Алгоритм метода проекции градиента с шагом $\alpha \leq \frac{1}{L}$ обеспечивает следующую сходимость после $k > 0$ итераций:

$$\|x_k - x^*\|_2^2 \leq (1 - \alpha\mu)^k \|x_0 - x^*\|_2^2$$

Доказательство

1. Сначала докажем свойство стационарной точки: $\text{proj}_S(x^* - \alpha \nabla f(x^*)) = x^*$.

Это следует из критерия проекции и условия оптимальности первого порядка для x^* . Пусть $y = x^* - \alpha \nabla f(x^*)$. Нужно показать, что $\langle y - x^*, x - x^* \rangle \leq 0$ для всех $x \in S$.

$$\langle (x^* - \alpha \nabla f(x^*)) - x^*, x - x^* \rangle = -\alpha \langle \nabla f(x^*), x - x^* \rangle \leq 0$$

Неравенство выполняется, так как $\alpha > 0$ и $\langle \nabla f(x^*), x - x^* \rangle \geq 0$ — условие оптимальности для x^* .

Скорость сходимости для гладкого сильно выпуклого случая

1. Рассмотрим расстояние до решения, используя свойство стационарной точки:

Скорость сходимости для гладкого сильно выпуклого случая

1. Рассмотрим расстояние до решения, используя свойство стационарной точки:

$$\|x_{k+1} - x^*\|_2^2 = \|\text{proj}_S(x_k - \alpha \nabla f(x_k)) - x^*\|_2^2$$

Скорость сходимости для гладкого сильно выпуклого случая

1. Рассмотрим расстояние до решения, используя свойство стационарной точки:

$$\|x_{k+1} - x^*\|_2^2 = \|\text{proj}_S(x_k - \alpha \nabla f(x_k)) - x^*\|_2^2$$

$$\text{свойство стационарной точки} = \|\text{proj}_S(x_k - \alpha \nabla f(x_k)) - \text{proj}_S(x^* - \alpha \nabla f(x^*))\|_2^2$$

Скорость сходимости для гладкого сильно выпуклого случая

1. Рассмотрим расстояние до решения, используя свойство стационарной точки:

$$\begin{aligned}\|x_{k+1} - x^*\|_2^2 &= \|\text{proj}_S(x_k - \alpha \nabla f(x_k)) - x^*\|_2^2 \\ \text{свойство стационарной точки} &= \|\text{proj}_S(x_k - \alpha \nabla f(x_k)) - \text{proj}_S(x^* - \alpha \nabla f(x^*))\|_2^2 \\ \text{нерастягиваемость} &\leq \|x_k - \alpha \nabla f(x_k) - (x^* - \alpha \nabla f(x^*))\|_2^2\end{aligned}$$

Скорость сходимости для гладкого сильно выпуклого случая

1. Рассмотрим расстояние до решения, используя свойство стационарной точки:

$$\begin{aligned}\|x_{k+1} - x^*\|_2^2 &= \|\text{proj}_S(x_k - \alpha \nabla f(x_k)) - x^*\|_2^2 \\ \text{свойство стационарной точки} &= \|\text{proj}_S(x_k - \alpha \nabla f(x_k)) - \text{proj}_S(x^* - \alpha \nabla f(x^*))\|_2^2 \\ \text{нерастягиваемость} &\leq \|x_k - \alpha \nabla f(x_k) - (x^* - \alpha \nabla f(x^*))\|_2^2 \\ &= \|x_k - x^*\|^2 - 2\alpha \langle \nabla f(x_k) - \nabla f(x^*), x_k - x^* \rangle + \alpha^2 \|\nabla f(x_k) - \nabla f(x^*)\|_2^2\end{aligned}$$

Скорость сходимости для гладкого сильно выпуклого случая

1. Рассмотрим расстояние до решения, используя свойство стационарной точки:

$$\begin{aligned}\|x_{k+1} - x^*\|_2^2 &= \|\text{proj}_S(x_k - \alpha \nabla f(x_k)) - x^*\|_2^2 \\ \text{свойство стационарной точки} &= \|\text{proj}_S(x_k - \alpha \nabla f(x_k)) - \text{proj}_S(x^* - \alpha \nabla f(x^*))\|_2^2 \\ \text{нерастягиваемость} &\leq \|x_k - \alpha \nabla f(x_k) - (x^* - \alpha \nabla f(x^*))\|_2^2 \\ &= \|x_k - x^*\|^2 - 2\alpha \langle \nabla f(x_k) - \nabla f(x^*), x_k - x^* \rangle + \alpha^2 \|\nabla f(x_k) - \nabla f(x^*)\|_2^2\end{aligned}$$

2. Теперь используем гладкость из инструментов сходимости и сильную выпуклость:

Скорость сходимости для гладкого сильно выпуклого случая

1. Рассмотрим расстояние до решения, используя свойство стационарной точки:

$$\begin{aligned}\|x_{k+1} - x^*\|_2^2 &= \|\text{proj}_S(x_k - \alpha \nabla f(x_k)) - x^*\|_2^2 \\ \text{свойство стационарной точки} &= \|\text{proj}_S(x_k - \alpha \nabla f(x_k)) - \text{proj}_S(x^* - \alpha \nabla f(x^*))\|_2^2 \\ \text{нерастягиваемость} &\leq \|x_k - \alpha \nabla f(x_k) - (x^* - \alpha \nabla f(x^*))\|_2^2 \\ &= \|x_k - x^*\|^2 - 2\alpha \langle \nabla f(x_k) - \nabla f(x^*), x_k - x^* \rangle + \alpha^2 \|\nabla f(x_k) - \nabla f(x^*)\|_2^2\end{aligned}$$

2. Теперь используем гладкость из инструментов сходимости и сильную выпуклость:

$$\text{гладкость} \quad \|\nabla f(x_k) - \nabla f(x^*)\|_2^2 \leq 2L (f(x_k) - f(x^*) - \langle \nabla f(x^*), x_k - x^* \rangle)$$

Скорость сходимости для гладкого сильно выпуклого случая

1. Рассмотрим расстояние до решения, используя свойство стационарной точки:

$$\begin{aligned}\|x_{k+1} - x^*\|_2^2 &= \|\text{proj}_S(x_k - \alpha \nabla f(x_k)) - x^*\|_2^2 \\ \text{свойство стационарной точки} &= \|\text{proj}_S(x_k - \alpha \nabla f(x_k)) - \text{proj}_S(x^* - \alpha \nabla f(x^*))\|_2^2 \\ \text{нерастягиваемость} &\leq \|x_k - \alpha \nabla f(x_k) - (x^* - \alpha \nabla f(x^*))\|_2^2 \\ &= \|x_k - x^*\|^2 - 2\alpha \langle \nabla f(x_k) - \nabla f(x^*), x_k - x^* \rangle + \alpha^2 \|\nabla f(x_k) - \nabla f(x^*)\|_2^2\end{aligned}$$

2. Теперь используем гладкость из инструментов сходимости и сильную выпуклость:

$$\begin{aligned}\text{гладкость} \quad \|\nabla f(x_k) - \nabla f(x^*)\|_2^2 &\leq 2L (f(x_k) - f(x^*) - \langle \nabla f(x^*), x_k - x^* \rangle) \\ \text{сильная выпуклость} \quad -\langle \nabla f(x_k) - \nabla f(x^*), x_k - x^* \rangle &\leq -\left(f(x_k) - f(x^*) + \frac{\mu}{2} \|x_k - x^*\|_2^2\right) - \langle \nabla f(x^*), x_k - x^* \rangle\end{aligned}$$

Скорость сходимости для гладкого сильно выпуклого случая

3. Подставим:



3. Подставим:

$$\begin{aligned}\|x_{k+1} - x^*\|_2^2 &\leq \|x_k - x^*\|^2 - 2\alpha \left(f(x_k) - f(x^*) + \frac{\mu}{2} \|x_k - x^*\|_2^2 \right) - 2\alpha \langle \nabla f(x^*), x_k - x^* \rangle + \\ &\quad + \alpha^2 2L (f(x_k) - f(x^*) - \langle \nabla f(x^*), x_k - x^* \rangle)\end{aligned}$$



3. Подставим:

$$\begin{aligned}\|x_{k+1} - x^*\|_2^2 &\leq \|x_k - x^*\|^2 - 2\alpha \left(f(x_k) - f(x^*) + \frac{\mu}{2} \|x_k - x^*\|_2^2 \right) - 2\alpha \langle \nabla f(x^*), x_k - x^* \rangle + \\ &\quad + \alpha^2 2L (f(x_k) - f(x^*) - \langle \nabla f(x^*), x_k - x^* \rangle) \\ &\leq (1 - \alpha\mu) \|x_k - x^*\|^2 + 2\alpha(\alpha L - 1) (f(x_k) - f(x^*) - \langle \nabla f(x^*), x_k - x^* \rangle)\end{aligned}$$



3. Подставим:

$$\begin{aligned}\|x_{k+1} - x^*\|_2^2 &\leq \|x_k - x^*\|^2 - 2\alpha \left(f(x_k) - f(x^*) + \frac{\mu}{2} \|x_k - x^*\|_2^2 \right) - 2\alpha \langle \nabla f(x^*), x_k - x^* \rangle + \\ &\quad + \alpha^2 2L (f(x_k) - f(x^*) - \langle \nabla f(x^*), x_k - x^* \rangle) \\ &\leq (1 - \alpha\mu) \|x_k - x^*\|^2 + 2\alpha(\alpha L - 1) (f(x_k) - f(x^*) - \langle \nabla f(x^*), x_k - x^* \rangle)\end{aligned}$$

4. В силу выпуклости f : $f(x_k) - f(x^*) - \langle \nabla f(x^*), x_k - x^* \rangle \geq 0$. Следовательно, при $\alpha \leq \frac{1}{L}$:

$$\|x_{k+1} - x^*\|_2^2 \leq (1 - \alpha\mu) \|x_k - x^*\|^2,$$

что означает линейную сходимость метода со скоростью $1 - \frac{\mu}{L}$.

Метод Франк-Вульфа



Рис. 11: Маргарит Страус Франк (1927-2024)



Рис. 12: Филип Вульф (1927-2016)




Рис. 13: Иллюстрация алгоритма Франк-Вульфа (условного градиента)




Рис. 14: Иллюстрация алгоритма Франк-Вульфа (условного градиента)




Рис. 15: Иллюстрация алгоритма Франк-Вульфа (условного градиента)




Рис. 16: Иллюстрация алгоритма Франк-Вульфа (условного градиента)




Рис. 17: Иллюстрация алгоритма Франк-Вульфа (условного градиента)




Рис. 18: Иллюстрация алгоритма Франк-Вульфа (условного градиента)




Рис. 19: Иллюстрация алгоритма Франк-Вульфа (условного градиента)

$$y_k = \arg \min_{x \in S} f^I_{x_k}(x) = \arg \min_{x \in S} \langle \nabla f(x_k), x \rangle$$

$$x_{k+1} = \gamma_k x_k + (1 - \gamma_k) y_k$$




Рис. 20: Иллюстрация алгоритма Франк-Вульфа (условного градиента)

Скорость сходимости для гладкого выпуклого случая

Theorem

Пусть $f : \mathbb{R}^n \rightarrow \mathbb{R}$ — выпуклая и дифференцируемая функция. Пусть $S \subseteq \mathbb{R}^n$ — замкнутое выпуклое множество, и существует минимизатор x^* функции f на S ; кроме того, предположим, что f является гладкой на S с параметром L . Алгоритм Франк-Вульфа с размером шага $\gamma_k = \frac{k-1}{k+1}$ обеспечивает следующую сходимость после $k > 0$ итераций:

$$f(x_k) - f^* \leq \frac{2LR^2}{k+1}$$

где $R = \max_{x,y \in S} \|x - y\|$ — диаметр множества S .

Скорость сходимости для гладкого выпуклого случая

Theorem

Пусть $f : \mathbb{R}^n \rightarrow \mathbb{R}$ — выпуклая и дифференцируемая функция. Пусть $S \subseteq \mathbb{R}^n$ — замкнутое выпуклое множество, и существует минимизатор x^* функции f на S ; кроме того, предположим, что f является гладкой на S с параметром L . Алгоритм Франк-Вульфа с размером шага $\gamma_k = \frac{k-1}{k+1}$ обеспечивает следующую сходимость после $k > 0$ итераций:

$$f(x_k) - f^* \leq \frac{2LR^2}{k+1}$$

где $R = \max_{x, y \in S} \|x - y\|$ — диаметр множества S .

1. Из L -гладкости f имеем:

$$\begin{aligned} f(x_{k+1}) - f(x_k) &\leq \langle \nabla f(x_k), x_{k+1} - x_k \rangle + \frac{L}{2} \|x_{k+1} - x_k\|^2 \\ &= (1 - \gamma_k) \langle \nabla f(x_k), y_k - x_k \rangle + \frac{L(1 - \gamma_k)^2}{2} \|y_k - x_k\|^2 \end{aligned}$$

Скорость сходимости для гладкого выпуклого случая

2. Из выпуклости f для любого $x \in S$, включая x^* :

$$\langle \nabla f(x_k), x - x_k \rangle \leq f(x) - f(x_k)$$

В частности, для $x = x^*$:

$$\langle \nabla f(x_k), x^* - x_k \rangle \leq f(x^*) - f(x_k)$$

Скорость сходимости для гладкого выпуклого случая

2. Из выпуклости f для любого $x \in S$, включая x^* :

$$\langle \nabla f(x_k), x - x_k \rangle \leq f(x) - f(x_k)$$

В частности, для $x = x^*$:

$$\langle \nabla f(x_k), x^* - x_k \rangle \leq f(x^*) - f(x_k)$$

3. По определению y_k имеем $\langle \nabla f(x_k), y_k \rangle \leq \langle \nabla f(x_k), x^* \rangle$, поэтому:

$$\langle \nabla f(x_k), y_k - x_k \rangle \leq \langle \nabla f(x_k), x^* - x_k \rangle \leq f(x^*) - f(x_k)$$

Скорость сходимости для гладкого выпуклого случая

2. Из выпуклости f для любого $x \in S$, включая x^* :

$$\langle \nabla f(x_k), x - x_k \rangle \leq f(x) - f(x_k)$$

В частности, для $x = x^*$:

$$\langle \nabla f(x_k), x^* - x_k \rangle \leq f(x^*) - f(x_k)$$

3. По определению y_k имеем $\langle \nabla f(x_k), y_k \rangle \leq \langle \nabla f(x_k), x^* \rangle$, поэтому:

$$\langle \nabla f(x_k), y_k - x_k \rangle \leq \langle \nabla f(x_k), x^* - x_k \rangle \leq f(x^*) - f(x_k)$$

4. Объединяя приведённые неравенства:

$$\begin{aligned} f(x_{k+1}) - f(x_k) &\leq (1 - \gamma_k) \langle \nabla f(x_k), y_k - x_k \rangle + \frac{L(1 - \gamma_k)^2}{2} \|y_k - x_k\|^2 \\ &\leq (1 - \gamma_k) (f(x^*) - f(x_k)) + \frac{L(1 - \gamma_k)^2}{2} R^2 \end{aligned}$$

Скорость сходимости для гладкого выпуклого случая

2. Из выпуклости f для любого $x \in S$, включая x^* :

$$\langle \nabla f(x_k), x - x_k \rangle \leq f(x) - f(x_k)$$

В частности, для $x = x^*$:

$$\langle \nabla f(x_k), x^* - x_k \rangle \leq f(x^*) - f(x_k)$$

3. По определению y_k имеем $\langle \nabla f(x_k), y_k \rangle \leq \langle \nabla f(x_k), x^* \rangle$, поэтому:

$$\langle \nabla f(x_k), y_k - x_k \rangle \leq \langle \nabla f(x_k), x^* - x_k \rangle \leq f(x^*) - f(x_k)$$

4. Объединяя приведённые неравенства:

$$\begin{aligned} f(x_{k+1}) - f(x_k) &\leq (1 - \gamma_k) \langle \nabla f(x_k), y_k - x_k \rangle + \frac{L(1 - \gamma_k)^2}{2} \|y_k - x_k\|^2 \\ &\leq (1 - \gamma_k) (f(x^*) - f(x_k)) + \frac{L(1 - \gamma_k)^2}{2} R^2 \end{aligned}$$

5. Перегруппируем слагаемые:

$$f(x_{k+1}) - f(x^*) \leq \gamma_k (f(x_k) - f(x^*)) + (1 - \gamma_k)^2 \frac{LR^2}{2}$$

Скорость сходимости для гладкого выпуклого случая

6. Обозначив $\delta_k = \frac{f(x_k) - f(x^*)}{LR^2}$, получаем:

$$\delta_{k+1} \leq \gamma_k \delta_k + \frac{(1 - \gamma_k)^2}{2} = \frac{k-1}{k+1} \delta_k + \frac{2}{(k+1)^2}$$

Скорость сходимости для гладкого выпуклого случая

6. Обозначив $\delta_k = \frac{f(x_k) - f(x^*)}{LR^2}$, получаем:

$$\delta_{k+1} \leq \gamma_k \delta_k + \frac{(1 - \gamma_k)^2}{2} = \frac{k-1}{k+1} \delta_k + \frac{2}{(k+1)^2}$$

7. Докажем по индукции, что $\delta_k \leq \frac{2}{k+1}$.

что даёт нам искомый результат:

$$f(x_k) - f^* \leq \frac{2LR^2}{k+1}$$

Скорость сходимости для гладкого выпуклого случая

6. Обозначив $\delta_k = \frac{f(x_k) - f(x^*)}{LR^2}$, получаем:

$$\delta_{k+1} \leq \gamma_k \delta_k + \frac{(1 - \gamma_k)^2}{2} = \frac{k-1}{k+1} \delta_k + \frac{2}{(k+1)^2}$$

7. Докажем по индукции, что $\delta_k \leq \frac{2}{k+1}$.

- База: $\delta_2 \leq \frac{1}{2} < \frac{2}{3}$

что даёт нам искомый результат:

$$f(x_k) - f^* \leq \frac{2LR^2}{k+1}$$

Скорость сходимости для гладкого выпуклого случая

6. Обозначив $\delta_k = \frac{f(x_k) - f(x^*)}{LR^2}$, получаем:

$$\delta_{k+1} \leq \gamma_k \delta_k + \frac{(1 - \gamma_k)^2}{2} = \frac{k-1}{k+1} \delta_k + \frac{2}{(k+1)^2}$$

7. Докажем по индукции, что $\delta_k \leq \frac{2}{k+1}$.

- База: $\delta_2 \leq \frac{1}{2} < \frac{2}{3}$
- Предположим $\delta_k \leq \frac{2}{k+1}$

что даёт нам искомый результат:

$$f(x_k) - f^* \leq \frac{2LR^2}{k+1}$$

Скорость сходимости для гладкого выпуклого случая

6. Обозначив $\delta_k = \frac{f(x_k) - f(x^*)}{LR^2}$, получаем:

$$\delta_{k+1} \leq \gamma_k \delta_k + \frac{(1 - \gamma_k)^2}{2} = \frac{k-1}{k+1} \delta_k + \frac{2}{(k+1)^2}$$

7. Докажем по индукции, что $\delta_k \leq \frac{2}{k+1}$.

- База: $\delta_2 \leq \frac{1}{2} < \frac{2}{3}$
- Предположим $\delta_k \leq \frac{2}{k+1}$
- Тогда $\delta_{k+1} \leq \frac{k-1}{k+1} \cdot \frac{2}{k+1} + \frac{2}{(k+1)^2} = \frac{2k}{k^2+2k+1} < \frac{2}{k+2}$ 

что даёт нам искомый результат:

$$f(x_k) - f^* \leq \frac{2LR^2}{k+1}$$

Нижняя оценка для метода Франк-Вульфа ²

Theorem

Рассмотрим произвольный алгоритм, который обращается к допустимому множеству $S \subseteq \mathbb{R}^n$ только через оракул линейной минимизации (LMO). Пусть диаметр множества S равен R . Существует L -гладкая сильно выпуклая функция $f : \mathbb{R}^n \rightarrow \mathbb{R}$, для которой этому алгоритму потребуется не менее

$$\min \left(\frac{n}{2}, \frac{LR^2}{16\varepsilon} \right)$$

итераций (то есть вызовов LMO), чтобы построить точку $\hat{x} \in S$ с $f(\hat{x}) - \min_{x \in S} f(x) \leq \varepsilon$. Нижняя оценка справедлива как для выпуклых, так и для сильно выпуклых функций.

²  The Complexity of Large-scale Convex Programming under a Linear Optimization Oracle

Нижняя оценка для метода Франк-Вульфа ²

Theorem

Рассмотрим произвольный алгоритм, который обращается к допустимому множеству $S \subseteq \mathbb{R}^n$ только через оракул линейной минимизации (LMO). Пусть диаметр множества S равен R . Существует L -гладкая сильно выпуклая функция $f : \mathbb{R}^n \rightarrow \mathbb{R}$, для которой этому алгоритму потребуется не менее

$$\min \left(\frac{n}{2}, \frac{LR^2}{16\varepsilon} \right)$$

итераций (то есть вызовов LMO), чтобы построить точку $\hat{x} \in S$ с $f(\hat{x}) - \min_{x \in S} f(x) \leq \varepsilon$. Нижняя оценка справедлива как для выпуклых, так и для сильно выпуклых функций.

Набросок доказательства. Рассмотрим следующую задачу оптимизации:

$$\min_{x \in S} f(x) = \min_{x \in S} \frac{1}{2} \|x\|_2^2$$

$$S = \left\{ x \in \mathbb{R}^n \mid x \geq 0, \sum_{i=1}^n x_i = 1 \right\}$$

Заметим, что:

- f является 1-гладкой;
- диаметр S равен $R = 2$;
- f сильно выпукла.

²  The Complexity of Large-scale Convex Programming under a Linear Optimization Oracle

Нижняя оценка для метода Франк-Вульфа ³

1. Оптимальное решение:

$$x^* = \frac{1}{n} \mathbf{1} = \frac{1}{n} \sum_{i=1}^n e_i, \quad \text{и} \quad f(x^*) = \frac{1}{2n},$$

где $e_i = (0, \dots, 0, \underset{\text{позиция } i}{1}, 0, \dots, 0)^\top$ — i -й стандартный базисный вектор.

Нижняя оценка для метода Франк-Вульфа ³

1. Оптимальное решение:

$$x^* = \frac{1}{n} \mathbf{1} = \frac{1}{n} \sum_{i=1}^n e_i, \quad \text{и} \quad f(x^*) = \frac{1}{2n},$$

где $e_i = (0, \dots, 0, \underset{\text{позиция } i}{1}, 0, \dots, 0)^\top$ — i -й стандартный базисный вектор.

2. Оракул линейной минимизации (LMO) на S возвращает вершину e_i . После k итераций метод обнаружит не более k различных базисных векторов $e_{i_1}, \dots, e_{i_k}$. Наилучшая выпуклая комбинация, которую можно составить:

$$\hat{x} = \frac{1}{k} \sum_{j=1}^k e_{i_j}.$$

Нижняя оценка для метода Франк-Вульфа ³

1. Оптимальное решение:

$$x^* = \frac{1}{n} \mathbf{1} = \frac{1}{n} \sum_{i=1}^n e_i, \quad \text{и} \quad f(x^*) = \frac{1}{2n},$$

где $e_i = (0, \dots, 0, \underset{\text{позиция } i}{1}, 0, \dots, 0)^\top$ — i -й стандартный базисный вектор.

2. Оракул линейной минимизации (LMO) на S возвращает вершину e_i . После k итераций метод обнаружит не более k различных базисных векторов $e_{i_1}, \dots, e_{i_k}$. Наилучшая выпуклая комбинация, которую можно составить:

$$\hat{x} = \frac{1}{k} \sum_{j=1}^k e_{i_j}.$$

3. Вычислив значение функции в точке $\hat{x}$, получаем:

$$f(\hat{x}) - f(x^*) \geq \frac{1}{2} \left(\frac{1}{\min\{k, n\}} - \frac{1}{n} \right).$$

Нижняя оценка для метода Франк-Вульфа ³

1. Оптимальное решение:

$$x^* = \frac{1}{n} \mathbf{1} = \frac{1}{n} \sum_{i=1}^n e_i, \quad \text{и} \quad f(x^*) = \frac{1}{2n},$$

где $e_i = (0, \dots, 0, \underset{\text{позиция } i}{1}, 0, \dots, 0)^\top$ — i -й стандартный базисный вектор.

2. Оракул линейной минимизации (LMO) на S возвращает вершину e_i . После k итераций метод обнаружит не более k различных базисных векторов $e_{i_1}, \dots, e_{i_k}$. Наилучшая выпуклая комбинация, которую можно составить:

$$\hat{x} = \frac{1}{k} \sum_{j=1}^k e_{i_j}.$$

3. Вычислив значение функции в точке $\hat{x}$, получаем:

$$f(\hat{x}) - f(x^*) \geq \frac{1}{2} \left(\frac{1}{\min\{k, n\}} - \frac{1}{n} \right).$$

4. Чтобы обеспечить $f(\hat{x}) - f(x^*) \leq \varepsilon$, необходимо (полное доказательство приведено в статье):

$$k \geq \min \left\{ \frac{n}{2}, \frac{1}{4\varepsilon} \right\} = \min \left\{ \frac{n}{2}, \frac{LR^2}{16\varepsilon} \right\}.$$

Итоги метода Франк-Вульфа

- Метод не требует проекций, а в некоторых случаях позволяет вычислять итерации в замкнутой форме

Итоги метода Франк-Вульфа

- Метод не требует проекций, а в некоторых случаях позволяет вычислять итерации в замкнутой форме
- Глобальная скорость сходимости составляет $O\left(\frac{1}{k}\right)$ для гладких выпуклых функций. Сильная выпуклость не улучшает скорость. Это нижняя оценка для LMO

Итоги метода Франк-Вульфа

- Метод не требует проекций, а в некоторых случаях позволяет вычислять итерации в замкнутой форме
- Глобальная скорость сходимости составляет $O\left(\frac{1}{k}\right)$ для гладких выпуклых функций. Сильная выпуклость не улучшает скорость. Это нижняя оценка для LMO
- По сравнению с методом проекции градиента скорость сходимости хуже, однако стоимость итерации может быть ниже, а решения — более разреженными

Итоги метода Франк-Вульфа

- Метод не требует проекций, а в некоторых случаях позволяет вычислять итерации в замкнутой форме
- Глобальная скорость сходимости составляет $O\left(\frac{1}{k}\right)$ для гладких выпуклых функций. Сильная выпуклость не улучшает скорость. Это нижняя оценка для LMO
- По сравнению с методом проекции градиента скорость сходимости хуже, однако стоимость итерации может быть ниже, а решения — более разреженными
- Недавно было показано, что для сильно выпуклых множеств скорость может быть улучшена до $O\left(\frac{1}{k^2}\right)$ ( статья)

Итоги метода Франк-Вульфа

- Метод не требует проекций, а в некоторых случаях позволяет вычислять итерации в замкнутой форме
- Глобальная скорость сходимости составляет $O\left(\frac{1}{k}\right)$ для гладких выпуклых функций. Сильная выпуклость не улучшает скорость. Это нижняя оценка для LMO
- По сравнению с методом проекции градиента скорость сходимости хуже, однако стоимость итерации может быть ниже, а решения — более разреженными
- Недавно было показано, что для сильно выпуклых множеств скорость может быть улучшена до $O\left(\frac{1}{k^2}\right)$ (📄 статья)
- Если допустить шаги удаления, сходимость становится линейной (📄 статья) в сильно выпуклом случае


Итоги метода Франк-Вульфа

- Метод не требует проекций, а в некоторых случаях позволяет вычислять итерации в замкнутой форме
- Глобальная скорость сходимости составляет $O\left(\frac{1}{k}\right)$ для гладких выпуклых функций. Сильная выпуклость не улучшает скорость. Это нижняя оценка для LMO
- По сравнению с методом проекции градиента скорость сходимости хуже, однако стоимость итерации может быть ниже, а решения — более разреженными
- Недавно было показано, что для сильно выпуклых множеств скорость может быть улучшена до $O\left(\frac{1}{k^2}\right)$ (📄 статья)
- Если допустить шаги удаления, сходимость становится линейной (📄 статья) в сильно выпуклом случае
- В недавних работах показано обобщение на негладкий случай (📄 статья) со скоростью сходимости $O\left(\frac{1}{\sqrt{k}}\right)$

Численные эксперименты


Двумерный пример. Метод Франк-Вульфа

Frank-Wolfe Method: Iteration 0




Двумерный пример. Метод Франк-Вульфа

Frank-Wolfe Method: Iteration 1




Двумерный пример. Метод Франк-Вульфа

Frank-Wolfe Method: Iteration 2




Двумерный пример. Метод Франк-Вульфа

Frank-Wolfe Method: Iteration 3




Двумерный пример. Метод Франк-Вульфа

Frank-Wolfe Method: Iteration 4




Двумерный пример. Метод Франк-Вульфа

Frank-Wolfe Method: Iteration 5




Двумерный пример. Метод Франк-Вульфа

Frank-Wolfe Method: Iteration 6



Двумерный пример. Метод Франк-Вульфа

Frank-Wolfe Method: Iteration 7



Квадратичная функция. Покоординатные ограничения

$$\min_{\substack{x \in \mathbb{R}^n \\ -1 \leq x \leq 1}} \frac{1}{2} x^\top A x - b^\top x,$$

$$A \in \mathbb{R}^{n \times n}, \quad \lambda(A) \in [\mu; L].$$

Проекция тривиальна:

$$\pi_S(x) = \text{clip}(x, -1, 1).$$

или





$$\pi_S(x) = \max(-1, \min(1, x)).$$

Оракул линейной минимизации (LMO) для заданного градиента g имеет вид $y = \operatorname{argmin}_{z \in S} \langle g, z \rangle$.

Поскольку допустимое множество сепарабельно по координатам, решение вычисляется покоординатно:

$$y_i = \begin{cases} -1, & \text{если } g_i > 0, \\ 1, & \text{если } g_i \leq 0. \end{cases}$$

Constrained convex quadratic problem: $n=80, \mu=0, L=10$



— Projected Gradient Descent - - - Frank-Wolfe

Квадратичная функция. Покоординатные ограничения

$$\min_{\substack{x \in \mathbb{R}^n \\ -1 \leq x \leq 1}} \frac{1}{2} x^\top A x - b^\top x,$$

$$A \in \mathbb{R}^{n \times n}, \quad \lambda(A) \in [\mu; L].$$

Проекция тривиальна:

$$\pi_S(x) = \text{clip}(x, -1, 1).$$

или





$$\pi_S(x) = \max(-1, \min(1, x)).$$

Оракул линейной минимизации (LMO) для заданного градиента g имеет вид $y = \operatorname{argmin}_{z \in S} \langle g, z \rangle$.

Поскольку допустимое множество сепарабельно по координатам, решение вычисляется покоординатно:

$$y_i = \begin{cases} -1, & \text{если } g_i > 0, \\ 1, & \text{если } g_i \leq 0. \end{cases}$$

Constrained strongly Convex quadratic problem: $n=80, \mu=1, L=10$



— Projected Gradient Descent - - - Frank-Wolfe

Квадратичная функция. Симплексные ограничения (удачная задача с диагональной матрицей)

$$\min_{\substack{x \in \mathbb{R}^n \\ x \geq 0, 1^T x = 1}} \frac{1}{2} x^T A x,$$

$$A \in \mathbb{R}^{n \times n}, \quad \lambda(A) \in [0; 100].$$

$$\min_{1^T x = 1, x \geq 0} \frac{1}{2} x^T A x, n = 200$$





Метод	Время шага, мс	Время LMO/проекции, мс
PGD	0.0069	0.0167
FW	0.0070	0.0066

Проекция на единичный симплекс $\pi_S(x)$ выполняется за $\mathcal{O}(n \log n)$ или за ожидаемое $\mathcal{O}(n)$ время.⁴

LMO для заданного градиента g имеет вид $y = \operatorname{argmin}_{z \in S} \langle g, z \rangle$. Решение соответствует вершине симплекса:

$$y = e_j \quad \text{где} \quad j = \operatorname{argmin}_i g_i.$$

⁴ Efficient Projections onto the ℓ_1 -Ball for Learning in High Dimensions



--- Frank-Wolfe — Projected Gradient Descent





Квадратичная функция. Симплексные ограничения

$$\min_{\substack{x \in \mathbb{R}^n \\ x \geq 0, 1^T x = 1}} \frac{1}{2} x^T A x,$$

$$A \in \mathbb{R}^{n \times n}, \quad \lambda(A) \in [0; 100].$$

$$\min_{1^T x = 1, x \geq 0} \frac{1}{2} x^T A x, n = 200$$

Метод	Время шага, мс	Время LMO/проекции, мс
PGD	0.0069	0.0420
FW	0.0069	0.0066



--- Frank-Wolfe — Projected Gradient Descent





Квадратичная функция. Симплексные ограничения

$$\min_{\substack{x \in \mathbb{R}^n \\ x \geq 0, 1^T x = 1}} \frac{1}{2} x^T A x,$$

$$A \in \mathbb{R}^{n \times n}, \quad \lambda(A) \in [0; 100].$$

$$\min_{1^T x = 1, x \geq 0} \frac{1}{2} x^T A x, n = 300$$

Метод	Время шага, мс	Время LMO/проекции, мс
PGD	0.0068	0.0761
FW	0.0069	0.0070



--- Frank-Wolfe — Projected Gradient Descent





Квадратичная функция. Симплексные ограничения

$$\min_{\substack{x \in \mathbb{R}^n \\ x \geq 0, 1^T x = 1}} \frac{1}{2} x^T A x,$$

$$A \in \mathbb{R}^{n \times n}, \quad \lambda(A) \in [1; 100].$$

$$\min_{1^T x = 1, x \geq 0} \frac{1}{2} x^T A x, n = 300$$

Метод	Время шага, мс	Время LMO/проекции, мс
PGD	0.0068	0.0752
FW	0.0067	0.0068



--- Frank-Wolfe — Projected Gradient Descent

PGD и метод Франк-Вульфа

Ключевое различие между PGD и FW состоит в том, что PGD требует проекции, тогда как FW — лишь оракул линейной минимизации (LMO).

В недавней статье авторы представили следующую сравнительную таблицу сложностей линейной минимизации и проекций на некоторые выпуклые множества с точностью до аддитивной ошибки ϵ в евклидовой норме.

Множество	Линейная минимизация	Проекция
n -мерный ℓ_p -шар, $p \neq 1, 2, \infty$	$\mathcal{O}(n)$	$\tilde{\mathcal{O}}(\frac{n}{\epsilon^2})$
Шар ядерной нормы для $n \times m$ матриц	$\mathcal{O}\left(\nu \ln(m+n) \frac{\sqrt{\sigma_1}}{\sqrt{\epsilon}}\right)$	$\mathcal{O}(mn \min\{m, n\})$
Потоковый многогранник на графе с m вершинами и n рёбрами (ограничение пропускной способности на рёбрах)	$\mathcal{O}\left((n \log m)(n + m \log m)\right)$	$\tilde{\mathcal{O}}(\frac{n}{\epsilon^2})$ или $\mathcal{O}(n^4 \log n)$
Многогранник Биркгофа ($n \times n$ дважды стохастические матрицы)	$\mathcal{O}(n^3)$	$\tilde{\mathcal{O}}(\frac{n^2}{\epsilon^2})$

Когда ϵ отсутствует, аддитивной ошибки нет. Обозначение $\tilde{\mathcal{O}}$ скрывает полилогарифмические множители по размерности и полиномиальные множители в константах, связанных с расстоянием до оптимума. Для шара ядерной нормы (спектраэдра) ν обозначает число ненулевых элементов, а σ_1 — наибольшее сингулярное

число проецируемой матрицы.

Дополнительные численные эксперименты

Траектории PGD и FW на ℓ_2 -шаре


$$\min_{x \in \mathbb{R}^2} \frac{1}{2} x^\top A x - b^\top x, \quad \|x\|_2 \leq 1$$

PGD: проекция $\rightarrow$ кратчайший путь к границе, затем движение вдоль неё к оптимуму.

FW: каждый шаг — выпуклая комбинация текущей точки и **антиградиентной точки на границе**. Характерный зигзаг вдоль множества.

Оба метода стартуют из $x_0 = (-0.5, -0.5)$.


Траектории PGD и FW, ℓ_2 -шар



Траектории PGD и FW на 2-симплексе

$$\min_{\substack{x \in \mathbb{R}^3 \\ x \geq 0, \mathbf{1}^\top x = 1}} \frac{1}{2} x^\top A x$$

FW на каждом шаге выбирает одну из вершин симплекса (e_1, e_2, e_3) , движется к ней $\rightarrow$ траектория проходит через рёбра. PGD: проекция на симплекс допускает движение в любом направлении $\rightarrow$ более прямой путь к оптимуму.





ℓ_2 -шар. Проекция и LMO одинаково дёшевы

$$\min_{\|x\|_2 \leq 2} \frac{1}{2} x^\top A x - b^\top x$$

- $n = 200, \kappa = 50$

Когда проекция и LMO стоят одинаково, PGD выигрывает за счёт **линейной скорости** при сильной выпуклости.





ℓ_2 -шар. Проекция и LMO одинаково дешёвы

$$\min_{\|x\|_2 \leq 2} \frac{1}{2} x^\top A x - b^\top x$$

- $n = 200, \kappa = 50$
- Проекция: $\pi_S(x) = x \cdot \min\left(1, \frac{R}{\|x\|}\right)$ — $\mathcal{O}(n)$

Когда проекция и LMO стоят одинаково, PGD выигрывает за счёт **линейной скорости** при сильной выпуклости.





ℓ_2 -шар. Проекция и LMO одинаково дешёвы

$$\min_{\|x\|_2 \leq 2} \frac{1}{2} x^\top A x - b^\top x$$

- $n = 200, \kappa = 50$
- Проекция: $\pi_S(x) = x \cdot \min\left(1, \frac{R}{\|x\|}\right)$ — $\mathcal{O}(n)$
- LMO: $y = -R \frac{g}{\|g\|}$ — $\mathcal{O}(n)$

Когда проекция и LMO стоят одинаково, PGD выигрывает за счёт **линейной скорости** при сильной выпуклости.





Разреженность итераций FW на симплексе

$$\min_{\substack{x \geq 0 \\ \mathbf{1}^\top x = 1}} \frac{1}{2} x^\top A x, \quad n = 500$$

Ключевое свойство FW: итерация x_k есть **выпуклая комбинация k вершин** $\Rightarrow$ не более k ненулевых компонент.

- PGD: после проекции число ненулевых компонент скачком достигает ~ 400

Это важно, когда нужно получить разреженное решение.





Разреженность итераций FW на симплексе

$$\min_{\substack{x \geq 0 \\ \mathbf{1}^\top x = 1}} \frac{1}{2} x^\top A x, \quad n = 500$$

Ключевое свойство FW: итерация x_k есть **выпуклая комбинация k вершин** $\Rightarrow$ не более k ненулевых компонент.

- PGD: после проекции число ненулевых компонент скачком достигает ~ 400
- FW: число ненулевых растёт **линейно** с итерациями

Это важно, когда нужно получить разреженное решение.



Сильная выпуклость: PGD ускоряется, FW — нет

$$\min_{\substack{x \geq 0 \\ \mathbf{1}^\top x = 1}} \frac{1}{2} x^\top A x$$



- $n = 200, \mu = 5, L = 100, \kappa = 20$

PGD с шагом $\frac{1}{L}$: **линейная сходимость**

$(1 - \mu/L)^k$, ведь проекция на выпуклое множество — нестягивающий оператор.

FW: остаётся $\mathcal{O}(1/k)$ — сильная выпуклость **не помогает** со стандартным шагом

$$\gamma_k = \frac{2}{k+2}.$$





Скорость сходимости: выпуклая vs сильно выпуклая задача

$$\min_{-1 \preceq x \preceq 1} \frac{1}{2} x^\top A x, \quad n = 100$$

- Левая панель: $\mu \approx 0$ — оба метода $\mathcal{O}(1/k)$, но PGD быстрее по константе

Главный вывод: сильная выпуклость кардинально меняет картину в пользу PGD.





Скорость сходимости: выпуклая vs сильно выпуклая задача

$$\min_{-1 \leq x \leq 1} \frac{1}{2} x^\top A x, \quad n = 100$$

- Левая панель: $\mu \approx 0$ — оба метода $\mathcal{O}(1/k)$, но PGD быстрее по константе
- Правая панель: $\mu = 2$ — PGD получает **экспоненциальную** скорость, FW остаётся сублинейным

Главный вывод: сильная выпуклость кардинально меняет картину в пользу PGD.



Стоимость итерации: проекция vs LMO на симплексе


Измеряем **только** стоимость проекции и LMO, без вычисления градиента.

- Проекция на симплекс: сортировка + $O(n)$ — всего $O(n \log n)$

При $n = 10000$ проекция дороже LMO на **порядок**.

В задачах, где градиент считается быстро (разреженная матрица), разница в стоимости шага между PGD и FW определяется именно проекцией/LMO.

Стоимость проекции vs LMO на симплексе (без вычисления градиента)



Стоимость итерации: проекция vs LMO на симплексе


Измеряем **только** стоимость проекции и LMO, без вычисления градиента.

- Проекция на симплекс: сортировка + $O(n)$ — всего $\mathcal{O}(n \log n)$
- LMO (argmin): один проход — $\mathcal{O}(n)$

При $n = 10000$ проекция дороже LMO **на порядок**.

В задачах, где градиент считается быстро (разреженная матрица), разница в стоимости шага между PGD и FW определяется именно проекцией/LMO.

Стоимость проекции vs LMO на симплексе (без вычисления градиента)





Ядерная норма: когда FW — единственный вариант

$$\min_{\|X\|_* \leq R} \frac{1}{2} \|X - B\|_F^2, \quad X \in \mathbb{R}^{n \times n}$$

- PGD: полное SVD $\mathcal{O}(n^3)$ на каждой итерации

По итерациям PGD выигрывает. Но стоимость одной итерации PGD растёт **кубически**: при $n = 800$ полное SVD в **75 раз** дороже rank-1 SVD.

Для матриц размера $10^4 \times 10^4$ и больше полное SVD вычислительно неподъёмно — FW становится единственным разумным методом.





Ядерная норма: когда FW — единственный вариант

$$\min_{\|X\|_* \leq R} \frac{1}{2} \|X - B\|_F^2, \quad X \in \mathbb{R}^{n \times n}$$

- PGD: полное SVD $\mathcal{O}(n^3)$ на каждой итерации
- FW: rank-1 SVD (power iteration) $\mathcal{O}(n^2)$

По итерациям PGD выигрывает. Но стоимость одной итерации PGD растёт **кубически**: при $n = 800$ полное SVD в **75 раз** дороже rank-1 SVD.

Для матриц размера $10^4 \times 10^4$ и больше полное SVD вычислительно неподъёмно — FW становится единственным разумным методом.



Ядерная норма: определение и свойства

i Ядерная норма (trace norm)

Ядерная норма матрицы $X \in \mathbb{R}^{m \times n}$ определяется как сумма её сингулярных чисел:

$$\|X\|_* = \sum_{i=1}^{\min(m,n)} \sigma_i(X) = \text{tr} \left(\sqrt{X^\top X} \right)$$

Ядерная норма: определение и свойства

i Ядерная норма (trace norm)

Ядерная норма матрицы $X \in \mathbb{R}^{m \times n}$ определяется как сумма её сингулярных чисел:

$$\|X\|_* = \sum_{i=1}^{\min(m,n)} \sigma_i(X) = \text{tr}(\sqrt{X^\top X})$$

- Ядерная норма — выпуклая оболочка ранга матрицы на единичном спектральном шаре:
 $\|X\|_* = \text{conv}(\text{rank}(X))$ при $\|X\|_{\text{op}} \leq 1$.

Ядерная норма: определение и свойства

i Ядерная норма (trace norm)

Ядерная норма матрицы $X \in \mathbb{R}^{m \times n}$ определяется как сумма её сингулярных чисел:

$$\|X\|_* = \sum_{i=1}^{\min(m,n)} \sigma_i(X) = \text{tr}(\sqrt{X^\top X})$$

- Ядерная норма — выпуклая оболочка ранга матрицы на единичном спектральном шаре:
 $\|X\|_* = \text{conv}(\text{rank}(X))$ при $\|X\|_{\text{op}} \leq 1$.
- Поэтому ограничение $\|X\|_* \leq R$ — стандартный выпуклый релаксант для ограничения на ранг.

Ядерная норма: определение и свойства

i Ядерная норма (trace norm)

Ядерная норма матрицы $X \in \mathbb{R}^{m \times n}$ определяется как сумма её сингулярных чисел:

$$\|X\|_* = \sum_{i=1}^{\min(m,n)} \sigma_i(X) = \text{tr}(\sqrt{X^\top X})$$

- Ядерная норма — выпуклая оболочка ранга матрицы на единичном спектральном шаре:
 $\|X\|_* = \text{conv}(\text{rank}(X))$ при $\|X\|_{\text{op}} \leq 1$.
- Поэтому ограничение $\|X\|_* \leq R$ — стандартный выпуклый релаксант для ограничения на ранг.
- Шар ядерной нормы $\mathcal{B}_* = \{X \in \mathbb{R}^{m \times n} \mid \|X\|_* \leq R\}$ — выпуклое компактное множество.

Ядерная норма: определение и свойства

i Ядерная норма (trace norm)

Ядерная норма матрицы $X \in \mathbb{R}^{m \times n}$ определяется как сумма её сингулярных чисел:

$$\|X\|_* = \sum_{i=1}^{\min(m,n)} \sigma_i(X) = \text{tr}(\sqrt{X^\top X})$$

- Ядерная норма — выпуклая оболочка ранга матрицы на единичном спектральном шаре:
 $\|X\|_* = \text{conv}(\text{rank}(X))$ при $\|X\|_{\text{op}} \leq 1$.
- Поэтому ограничение $\|X\|_* \leq R$ — стандартный выпуклый релаксант для ограничения на ранг.
- Шар ядерной нормы $\mathcal{B}_* = \{X \in \mathbb{R}^{m \times n} \mid \|X\|_* \leq R\}$ — выпуклое компактное множество.
- Крайние точки $\mathcal{B}_*$ — матрицы ранга 1 вида $R \cdot uv^\top$, где $\|u\|_2 = \|v\|_2 = 1$.

Ядерная норма: определение и свойства

i Ядерная норма (trace norm)

Ядерная норма матрицы $X \in \mathbb{R}^{m \times n}$ определяется как сумма её сингулярных чисел:

$$\|X\|_* = \sum_{i=1}^{\min(m,n)} \sigma_i(X) = \text{tr}(\sqrt{X^\top X})$$

- Ядерная норма — выпуклая оболочка ранга матрицы на единичном спектральном шаре:
 $\|X\|_* = \text{conv}(\text{rank}(X))$ при $\|X\|_{\text{op}} \leq 1$.
- Поэтому ограничение $\|X\|_* \leq R$ — стандартный выпуклый релаксант для ограничения на ранг.
- Шар ядерной нормы $\mathcal{B}_* = \{X \in \mathbb{R}^{m \times n} \mid \|X\|_* \leq R\}$ — выпуклое компактное множество.
- Крайние точки $\mathcal{B}_*$ — матрицы ранга 1 вида $R \cdot uv^\top$, где $\|u\|_2 = \|v\|_2 = 1$.

Ядерная норма: определение и свойства

i Ядерная норма (trace norm)

Ядерная норма матрицы $X \in \mathbb{R}^{m \times n}$ определяется как сумма её сингулярных чисел:

$$\|X\|_* = \sum_{i=1}^{\min(m,n)} \sigma_i(X) = \text{tr}(\sqrt{X^\top X})$$

- Ядерная норма — выпуклая оболочка ранга матрицы на единичном спектральном шаре:
 $\|X\|_* = \text{conv}(\text{rank}(X))$ при $\|X\|_{\text{op}} \leq 1$.
- Поэтому ограничение $\|X\|_* \leq R$ — стандартный выпуклый релаксант для ограничения на ранг.
- Шар ядерной нормы $\mathcal{B}_* = \{X \in \mathbb{R}^{m \times n} \mid \|X\|_* \leq R\}$ — выпуклое компактное множество.
- Крайние точки $\mathcal{B}_*$ — матрицы ранга 1 вида $R \cdot uv^\top$, где $\|u\|_2 = \|v\|_2 = 1$.

Приложения: matrix completion (рекомендательные системы), robust PCA, low-rank matrix recovery, сжатие нейронных сетей.

Итерации PGD и FW на шаре ядерной нормы

Задача: $\min_{\|X\|_* \leq R} f(X)$, где $X \in \mathbb{R}^{m \times n}$.

Итерации PGD и FW на шаре ядерной нормы

Задача: $\min_{\|X\|_* \leq R} f(X)$, где $X \in \mathbb{R}^{m \times n}$.

Итерация PGD

$$X_{k+1} = \text{proj}_{\mathcal{B}_*}(X_k - \alpha \nabla f(X_k))$$

1. Вычислить $Y = X_k - \alpha \nabla f(X_k)$

Итерации PGD и FW на шаре ядерной нормы

Задача: $\min_{\|X\|_* \leq R} f(X)$, где $X \in \mathbb{R}^{m \times n}$.

Итерация PGD

$$X_{k+1} = \text{proj}_{\mathcal{B}_*}(X_k - \alpha \nabla f(X_k))$$

1. Вычислить $Y = X_k - \alpha \nabla f(X_k)$
2. **Полное SVD:** $Y = U \Sigma V^\top$ — стоимость $\mathcal{O}(mn \cdot \min(m, n))$

Итерации PGD и FW на шаре ядерной нормы

Задача: $\min_{\|X\|_* \leq R} f(X)$, где $X \in \mathbb{R}^{m \times n}$.

Итерация PGD

$$X_{k+1} = \text{proj}_{\mathcal{B}_*}(X_k - \alpha \nabla f(X_k))$$

1. Вычислить $Y = X_k - \alpha \nabla f(X_k)$
2. **Полное SVD:** $Y = U \Sigma V^\top$ — стоимость $\mathcal{O}(mn \cdot \min(m, n))$
3. Мягкое пороговое отсечение (soft thresholding) сингулярных чисел для проекции на $\mathcal{B}_*$:

$$\text{proj}_{\mathcal{B}_*}(Y) = U \cdot \text{diag}(\max(\sigma_i - \lambda, 0)) \cdot V^\top$$

где $\lambda \geq 0$ выбирается так, чтобы
 $\sum_i \max(\sigma_i - \lambda, 0) = R$.

Итерации PGD и FW на шаре ядерной нормы

Задача: $\min_{\|X\|_* \leq R} f(X)$, где $X \in \mathbb{R}^{m \times n}$.

Итерация PGD

$$X_{k+1} = \text{proj}_{\mathcal{B}_*}(X_k - \alpha \nabla f(X_k))$$

1. Вычислить $Y = X_k - \alpha \nabla f(X_k)$
2. **Полное SVD:** $Y = U \Sigma V^\top$ — стоимость $\mathcal{O}(mn \cdot \min(m, n))$
3. Мягкое пороговое отсечение (soft thresholding) сингулярных чисел для проекции на $\mathcal{B}_*$:

$$\text{proj}_{\mathcal{B}_*}(Y) = U \cdot \text{diag}(\max(\sigma_i - \lambda, 0)) \cdot V^\top$$

где $\lambda \geq 0$ выбирается так, чтобы
 $\sum_i \max(\sigma_i - \lambda, 0) = R$.

Итерации PGD и FW на шаре ядерной нормы

Задача: $\min_{\|X\|_* \leq R} f(X)$, где $X \in \mathbb{R}^{m \times n}$.

Итерация PGD

$$X_{k+1} = \text{proj}_{\mathcal{B}_*}(X_k - \alpha \nabla f(X_k))$$

1. Вычислить $Y = X_k - \alpha \nabla f(X_k)$
2. **Полное SVD:** $Y = U \Sigma V^\top$ — стоимость $\mathcal{O}(mn \cdot \min(m, n))$
3. Мягкое пороговое отсечение (soft thresholding) сингулярных чисел для проекции на $\mathcal{B}_*$:

$$\text{proj}_{\mathcal{B}_*}(Y) = U \cdot \text{diag}(\max(\sigma_i - \lambda, 0)) \cdot V^\top$$

где $\lambda \geq 0$ выбирается так, чтобы $\sum_i \max(\sigma_i - \lambda, 0) = R$.

Итерация FW

$$S_k = \arg \min_{\|S\|_* \leq R} \langle \nabla f(X_k), S \rangle$$

$$X_{k+1} = (1 - \gamma_k) X_k + \gamma_k S_k$$

1. Вычислить $G = \nabla f(X_k)$

Бонус: X_k имеет ранг $\leq k$ после k итераций.

Итерации PGD и FW на шаре ядерной нормы

Задача: $\min_{\|X\|_* \leq R} f(X)$, где $X \in \mathbb{R}^{m \times n}$.

Итерация PGD

$$X_{k+1} = \text{proj}_{\mathcal{B}_*}(X_k - \alpha \nabla f(X_k))$$

1. Вычислить $Y = X_k - \alpha \nabla f(X_k)$
2. **Полное SVD:** $Y = U \Sigma V^\top$ — стоимость $\mathcal{O}(mn \cdot \min(m, n))$
3. Мягкое пороговое отсечение (soft thresholding) сингулярных чисел для проекции на $\mathcal{B}_*$:

$$\text{proj}_{\mathcal{B}_*}(Y) = U \cdot \text{diag}(\max(\sigma_i - \lambda, 0)) \cdot V^\top$$

где $\lambda \geq 0$ выбирается так, чтобы $\sum_i \max(\sigma_i - \lambda, 0) = R$.

Итерация FW

$$S_k = \arg \min_{\|S\|_* \leq R} \langle \nabla f(X_k), S \rangle$$

$$X_{k+1} = (1 - \gamma_k) X_k + \gamma_k S_k$$

1. Вычислить $G = \nabla f(X_k)$
2. **Rank-1 SVD** (степенная итерация): найти ведущие сингулярные векторы u_1, v_1 матрицы $-G$ — стоимость $\mathcal{O}(\text{nnz}(G))$

Бонус: X_k имеет ранг $\leq k$ после k итераций.

Итерации PGD и FW на шаре ядерной нормы

Задача: $\min_{\|X\|_* \leq R} f(X)$, где $X \in \mathbb{R}^{m \times n}$.

Итерация PGD

$$X_{k+1} = \text{proj}_{\mathcal{B}_*}(X_k - \alpha \nabla f(X_k))$$

1. Вычислить $Y = X_k - \alpha \nabla f(X_k)$
2. **Полное SVD:** $Y = U \Sigma V^\top$ — стоимость $\mathcal{O}(mn \cdot \min(m, n))$
3. Мягкое пороговое отсечение (soft thresholding) сингулярных чисел для проекции на $\mathcal{B}_*$:

$$\text{proj}_{\mathcal{B}_*}(Y) = U \cdot \text{diag}(\max(\sigma_i - \lambda, 0)) \cdot V^\top$$

где $\lambda \geq 0$ выбирается так, чтобы $\sum_i \max(\sigma_i - \lambda, 0) = R$.

Итерация FW

$$S_k = \arg \min_{\|S\|_* \leq R} \langle \nabla f(X_k), S \rangle$$

$$X_{k+1} = (1 - \gamma_k) X_k + \gamma_k S_k$$

1. Вычислить $G = \nabla f(X_k)$
2. **Rank-1 SVD** (степенная итерация): найти ведущие сингулярные векторы u_1, v_1 матрицы $-G$ — стоимость $\mathcal{O}(\text{nnz}(G))$
3. $S_k = R \cdot u_1 v_1^\top$ — ранг-1 матрица

Бонус: X_k имеет ранг $\leq k$ после k итераций.

Итерации PGD и FW на шаре ядерной нормы

Задача: $\min_{\|X\|_* \leq R} f(X)$, где $X \in \mathbb{R}^{m \times n}$.

Итерация PGD

$$X_{k+1} = \text{proj}_{\mathcal{B}_*}(X_k - \alpha \nabla f(X_k))$$

1. Вычислить $Y = X_k - \alpha \nabla f(X_k)$
2. **Полное SVD:** $Y = U \Sigma V^\top$ — стоимость $\mathcal{O}(mn \cdot \min(m, n))$
3. Мягкое пороговое отсечение (soft thresholding) сингулярных чисел для проекции на $\mathcal{B}_*$:

$$\text{proj}_{\mathcal{B}_*}(Y) = U \cdot \text{diag}(\max(\sigma_i - \lambda, 0)) \cdot V^\top$$

где $\lambda \geq 0$ выбирается так, чтобы
 $\sum_i \max(\sigma_i - \lambda, 0) = R$.

Итерация FW

$$S_k = \arg \min_{\|S\|_* \leq R} \langle \nabla f(X_k), S \rangle$$

$$X_{k+1} = (1 - \gamma_k)X_k + \gamma_k S_k$$

1. Вычислить $G = \nabla f(X_k)$
 2. **Rank-1 SVD** (степенная итерация): найти ведущие сингулярные векторы u_1, v_1 матрицы $-G$ — стоимость $\mathcal{O}(\text{nnz}(G))$
 3. $S_k = R \cdot u_1 v_1^\top$ — ранг-1 матрица
 4. $X_{k+1} = (1 - \gamma_k)X_k + \gamma_k S_k$
- Бонус:** X_k имеет ранг $\leq k$ после k итераций.

FW побеждает: matrix completion + ядерная норма

Задача: matrix completion с ограничением

$$\|X\|_* \leq R:$$



$$\min_{\|X\|_* \leq R} \frac{1}{2} \sum_{(i,j) \in \Omega} (X_{ij} - B_{ij})^2$$

Ключ: градиент ∇f **разрежен** (ненулевой только на Ω).

- Степенная итерация для rank-1 SVD на разреженном ∇f : $\mathcal{O}(|\Omega|)$

FW компенсирует медленную сходимость $\mathcal{O}(1/k)$ огромным числом дешёвых итераций и **побеждает PGD по времени**.

Matrix completion + ядерная норма: FW побеждает по времени



FW побеждает: matrix completion + ядерная норма

Задача: matrix completion с ограничением

$$\|X\|_* \leq R:$$



$$\min_{\|X\|_* \leq R} \frac{1}{2} \sum_{(i,j) \in \Omega} (X_{ij} - B_{ij})^2$$

Ключ: градиент ∇f **разрежен** (ненулевой только на Ω).

- Степенная итерация для rank-1 SVD на разреженном ∇f : $\mathcal{O}(|\Omega|)$
- Полное SVD плотной матрицы Y : $\mathcal{O}(n^3)$

FW компенсирует медленную сходимость $\mathcal{O}(1/k)$ огромным числом дешёвых итераций и **побеждает PGD по времени**.

Matrix completion + ядерная норма: FW побеждает по времени



FW побеждает: matrix completion + ядерная норма

Задача: matrix completion с ограничением

$$\|X\|_* \leq R:$$



$$\min_{\|X\|_* \leq R} \frac{1}{2} \sum_{(i,j) \in \Omega} (X_{ij} - B_{ij})^2$$

Ключ: градиент ∇f **разрежен** (ненулевой только на Ω).

- Степенная итерация для rank-1 SVD на разреженном ∇f : $\mathcal{O}(|\Omega|)$
- Полное SVD плотной матрицы Y : $\mathcal{O}(n^3)$
- При $n = 2500$, $|\Omega| = 3\% \cdot n^2$:
отношение $\approx 900\times$

FW компенсирует медленную сходимость $\mathcal{O}(1/k)$ огромным числом дешёвых итераций и **побеждает PGD по времени**.

Matrix completion + ядерная норма: FW побеждает по времени



Matrix completion: почему ядерная норма?

Задача восстановления матрицы. Дана матрица $B \in \mathbb{R}^{m \times n}$, наблюдаемая лишь на подмножестве индексов $\Omega \subset [m] \times [n]$. Нужно восстановить всю матрицу, предполагая, что она имеет малый ранг.

Matrix completion: почему ядерная норма?

Задача восстановления матрицы. Дана матрица $B \in \mathbb{R}^{m \times n}$, наблюдаемая лишь на подмножестве индексов $\Omega \subset [m] \times [n]$. Нужно восстановить всю матрицу, предполагая, что она имеет малый ранг.

Некорректная (невыпуклая) постановка

$$\min_X \frac{1}{2} \sum_{(i,j) \in \Omega} (X_{ij} - B_{ij})^2 \quad \text{s.t.} \quad \text{rank}(X) \leq r$$

- Ограничение $\text{rank}(X) \leq r$ — невыпуклое

Matrix completion: почему ядерная норма?

Задача восстановления матрицы. Дана матрица $B \in \mathbb{R}^{m \times n}$, наблюдаемая лишь на подмножестве индексов $\Omega \subset [m] \times [n]$. Нужно восстановить всю матрицу, предполагая, что она имеет малый ранг.

Некорректная (невыпуклая) постановка

$$\min_X \frac{1}{2} \sum_{(i,j) \in \Omega} (X_{ij} - B_{ij})^2 \quad \text{s.t.} \quad \text{rank}(X) \leq r$$

- Ограничение $\text{rank}(X) \leq r$ — **невыпуклое**
- NP-трудная задача в общем случае

Matrix completion: почему ядерная норма?

Задача восстановления матрицы. Дана матрица $B \in \mathbb{R}^{m \times n}$, наблюдаемая лишь на подмножестве индексов $\Omega \subset [m] \times [n]$. Нужно восстановить всю матрицу, предполагая, что она имеет малый ранг.

Некорректная (невыпуклая) постановка

$$\min_X \frac{1}{2} \sum_{(i,j) \in \Omega} (X_{ij} - B_{ij})^2 \quad \text{s.t.} \quad \text{rank}(X) \leq r$$

- Ограничение $\text{rank}(X) \leq r$ — **невыпуклое**
- NP-трудная задача в общем случае
- Нет гарантий глобальной оптимальности

Matrix completion: почему ядерная норма?

Задача восстановления матрицы. Дана матрица $B \in \mathbb{R}^{m \times n}$, наблюдаемая лишь на подмножестве индексов $\Omega \subset [m] \times [n]$. Нужно восстановить всю матрицу, предполагая, что она имеет малый ранг.

Некорректная (невыпуклая) постановка

$$\min_X \frac{1}{2} \sum_{(i,j) \in \Omega} (X_{ij} - B_{ij})^2 \quad \text{s.t.} \quad \text{rank}(X) \leq r$$

- Ограничение $\text{rank}(X) \leq r$ — **невыпуклое**
- NP-трудная задача в общем случае
- Нет гарантий глобальной оптимальности

Matrix completion: почему ядерная норма?

Задача восстановления матрицы. Дана матрица $B \in \mathbb{R}^{m \times n}$, наблюдаемая лишь на подмножестве индексов $\Omega \subset [m] \times [n]$. Нужно восстановить всю матрицу, предполагая, что она имеет малый ранг.

Некорректная (невыпуклая) постановка

$$\min_X \frac{1}{2} \sum_{(i,j) \in \Omega} (X_{ij} - B_{ij})^2 \quad \text{s.t.} \quad \text{rank}(X) \leq r$$

- Ограничение $\text{rank}(X) \leq r$ — **невыпуклое**
- NP-трудная задача в общем случае
- Нет гарантий глобальной оптимальности

Выпуклая релаксация

$$\min_X \frac{1}{2} \sum_{(i,j) \in \Omega} (X_{ij} - B_{ij})^2 \quad \text{s.t.} \quad \|X\|_* \leq R$$

- Ядерная норма — **выпуклая оболочка** ранга

Matrix completion: почему ядерная норма?

Задача восстановления матрицы. Дана матрица $B \in \mathbb{R}^{m \times n}$, наблюдаемая лишь на подмножестве индексов $\Omega \subset [m] \times [n]$. Нужно восстановить всю матрицу, предполагая, что она имеет малый ранг.

Некорректная (невыпуклая) постановка

$$\min_X \frac{1}{2} \sum_{(i,j) \in \Omega} (X_{ij} - B_{ij})^2 \quad \text{s.t.} \quad \text{rank}(X) \leq r$$

- Ограничение $\text{rank}(X) \leq r$ — **невыпуклое**
- NP-трудная задача в общем случае
- Нет гарантий глобальной оптимальности

Выпуклая релаксация

$$\min_X \frac{1}{2} \sum_{(i,j) \in \Omega} (X_{ij} - B_{ij})^2 \quad \text{s.t.} \quad \|X\|_* \leq R$$

- Ядерная норма — **выпуклая оболочка** ранга
- Задача выпуклая, можно применять PGD и FW

Matrix completion: почему ядерная норма?

Задача восстановления матрицы. Дана матрица $B \in \mathbb{R}^{m \times n}$, наблюдаемая лишь на подмножестве индексов $\Omega \subset [m] \times [n]$. Нужно восстановить всю матрицу, предполагая, что она имеет малый ранг.

Некорректная (невыпуклая) постановка

$$\min_X \frac{1}{2} \sum_{(i,j) \in \Omega} (X_{ij} - B_{ij})^2 \quad \text{s.t.} \quad \text{rank}(X) \leq r$$

- Ограничение $\text{rank}(X) \leq r$ — **невыпуклое**
- NP-трудная задача в общем случае
- Нет гарантий глобальной оптимальности

Выпуклая релаксация

$$\min_X \frac{1}{2} \sum_{(i,j) \in \Omega} (X_{ij} - B_{ij})^2 \quad \text{s.t.} \quad \|X\|_* \leq R$$

- Ядерная норма — **выпуклая оболочка** ранга
- Задача выпуклая, можно применять PGD и FW
- Гарантии точного восстановления при определённых условиях ⁵

⁵  Candès, Recht. Exact Matrix Completion via Convex Optimization.

Matrix completion: почему ядерная норма?

Задача восстановления матрицы. Дана матрица $B \in \mathbb{R}^{m \times n}$, наблюдаемая лишь на подмножестве индексов $\Omega \subset [m] \times [n]$. Нужно восстановить всю матрицу, предполагая, что она имеет малый ранг.

Некорректная (невыпуклая) постановка

$$\min_X \frac{1}{2} \sum_{(i,j) \in \Omega} (X_{ij} - B_{ij})^2 \quad \text{s.t.} \quad \text{rank}(X) \leq r$$

- Ограничение $\text{rank}(X) \leq r$ — **невыпуклое**
- NP-трудная задача в общем случае
- Нет гарантий глобальной оптимальности

Выпуклая релаксация

$$\min_X \frac{1}{2} \sum_{(i,j) \in \Omega} (X_{ij} - B_{ij})^2 \quad \text{s.t.} \quad \|X\|_* \leq R$$

- Ядерная норма — **выпуклая оболочка** ранга
- Задача выпуклая, можно применять PGD и FW
- Гарантии точного восстановления при определённых условиях ⁵

⁵  Candès, Recht. Exact Matrix Completion via Convex Optimization.

Matrix completion: почему ядерная норма?

Задача восстановления матрицы. Дана матрица $B \in \mathbb{R}^{m \times n}$, наблюдаемая лишь на подмножестве индексов $\Omega \subset [m] \times [n]$. Нужно восстановить всю матрицу, предполагая, что она имеет малый ранг.

Некорректная (невыпуклая) постановка

Выпуклая релаксация

$$\min_X \frac{1}{2} \sum_{(i,j) \in \Omega} (X_{ij} - B_{ij})^2 \quad \text{s.t.} \quad \text{rank}(X) \leq r$$

- Ограничение $\text{rank}(X) \leq r$ — **невыпуклое**
- NP-трудная задача в общем случае
- Нет гарантий глобальной оптимальности

$$\min_X \frac{1}{2} \sum_{(i,j) \in \Omega} (X_{ij} - B_{ij})^2 \quad \text{s.t.} \quad \|X\|_* \leq R$$

- Ядерная норма — **выпуклая оболочка** ранга
- Задача выпуклая, можно применять PGD и FW
- Гарантии точного восстановления при определённых условиях ⁵

Пример из практики: Netflix Prize — предсказание оценок пользователей для фильмов. Матрица $\sim 500K \times 17K$, известно $\sim 1\%$ записей. Ядерная норма + FW позволяют эффективно решать эту задачу.

⁵ Candès, Recht. Exact Matrix Completion via Convex Optimization.

Метод зеркального спуска

Мотивация: зачем нужен зеркальный спуск?

Вспомним итерацию метода проекции градиента:

$$x_{k+1} = \text{proj}_S(x_k - \alpha_k \nabla f(x_k))$$

Мотивация: зачем нужен зеркальный спуск?

Вспомним итерацию метода проекции градиента:

$$x_{k+1} = \text{proj}_S(x_k - \alpha_k \nabla f(x_k))$$

Эта формула опирается на **евклидову норму** $\|\cdot\|_2$, как в шаге градиента, так и в проекции. Но что, если:

- Геометрия задачи **неевклидова**? Например, оптимизация на симплексе $\Delta_n = \{x \geq 0, \mathbf{1}^\top x = 1\}$ — естественная геометрия описывается не ℓ_2 , а ℓ_1 -нормой.

Мотивация: зачем нужен зеркальный спуск?

Вспомним итерацию метода проекции градиента:

$$x_{k+1} = \text{proj}_S(x_k - \alpha_k \nabla f(x_k))$$

Эта формула опирается на **евклидову норму** $\|\cdot\|_2$, как в шаге градиента, так и в проекции. Но что, если:

- Геометрия задачи **неевклидова**? Например, оптимизация на симплексе $\Delta_n = \{x \geq 0, \mathbf{1}^\top x = 1\}$ — естественная геометрия описывается не ℓ_2 , а ℓ_1 -нормой.
- Функция f гладкая относительно **неевклидовой** нормы $\|\cdot\|$?

$$f(y) \leq f(x) + \langle \nabla f(x), y - x \rangle + \frac{L}{2} \|y - x\|^2$$

Мотивация: зачем нужен зеркальный спуск?

Вспомним итерацию метода проекции градиента:

$$x_{k+1} = \text{proj}_S(x_k - \alpha_k \nabla f(x_k))$$

Эта формула опирается на **евклидову норму** $\|\cdot\|_2$, как в шаге градиента, так и в проекции. Но что, если:

- Геометрия задачи **неевклидова**? Например, оптимизация на симплексе $\Delta_n = \{x \geq 0, \mathbf{1}^\top x = 1\}$ — естественная геометрия описывается не ℓ_2 , а ℓ_1 -нормой.
- Функция f гладкая относительно **неевклидовой** нормы $\|\cdot\|$?

$$f(y) \leq f(x) + \langle \nabla f(x), y - x \rangle + \frac{L}{2} \|y - x\|^2$$

Мотивация: зачем нужен зеркальный спуск?

Вспомним итерацию метода проекции градиента:

$$x_{k+1} = \text{proj}_S(x_k - \alpha_k \nabla f(x_k))$$

Эта формула опирается на **евклидову норму** $\|\cdot\|_2$, как в шаге градиента, так и в проекции. Но что, если:

- Геометрия задачи **неевклидова**? Например, оптимизация на симплексе $\Delta_n = \{x \geq 0, \mathbf{1}^\top x = 1\}$ — естественная геометрия описывается не ℓ_2 , а ℓ_1 -нормой.
- Функция f гладкая относительно **неевклидовой** нормы $\|\cdot\|$?

$$f(y) \leq f(x) + \langle \nabla f(x), y - x \rangle + \frac{L}{2} \|y - x\|^2$$

Проблема: PGD с евклидовой проекцией может давать оценку $\mathcal{O}\left(\frac{L_2 R_2^2}{k}\right)$, но L_2 и R_2 могут **зависеть от размерности** n , что делает оценку бессмысленной для задач большой размерности.

Мотивация: пример на симплексе

Рассмотрим задачу на стандартном симплексе $\Delta_n = \{x \in \mathbb{R}^n \mid x \geq 0, \mathbf{1}^\top x = 1\}$:

$$\min_{x \in \Delta_n} f(x)$$

Мотивация: пример на симплексе

Рассмотрим задачу на стандартном симплексе $\Delta_n = \{x \in \mathbb{R}^n \mid x \geq 0, \mathbf{1}^\top x = 1\}$:

$$\min_{x \in \Delta_n} f(x)$$

Пусть f является L_1 -гладкой относительно ℓ_1 -нормы: $f(y) \leq f(x) + \langle \nabla f(x), y - x \rangle + \frac{L_1}{2} \|y - x\|_1^2$.

Мотивация: пример на симплексе

Рассмотрим задачу на стандартном симплексе $\Delta_n = \{x \in \mathbb{R}^n \mid x \geq 0, \mathbf{1}^\top x = 1\}$:

$$\min_{x \in \Delta_n} f(x)$$

Пусть f является L_1 -гладкой относительно ℓ_1 -нормы: $f(y) \leq f(x) + \langle \nabla f(x), y - x \rangle + \frac{L_1}{2} \|y - x\|_1^2$.

PGD (евклидова геометрия)

- Гладкость: $L_2 \leq n \cdot L_1$ (из $\|x\|_2 \leq \|x\|_1$)

Мотивация: пример на симплексе

Рассмотрим задачу на стандартном симплексе $\Delta_n = \{x \in \mathbb{R}^n \mid x \geq 0, \mathbf{1}^\top x = 1\}$:

$$\min_{x \in \Delta_n} f(x)$$

Пусть f является L_1 -гладкой относительно ℓ_1 -нормы: $f(y) \leq f(x) + \langle \nabla f(x), y - x \rangle + \frac{L_1}{2} \|y - x\|_1^2$.

PGD (евклидова геометрия)

- Гладкость: $L_2 \leq n \cdot L_1$ (из $\|x\|_2 \leq \|x\|_1$)
- Диаметр: $R_2 = \sqrt{2}$

Мотивация: пример на симплексе

Рассмотрим задачу на стандартном симплексе $\Delta_n = \{x \in \mathbb{R}^n \mid x \geq 0, \mathbf{1}^\top x = 1\}$:

$$\min_{x \in \Delta_n} f(x)$$

Пусть f является L_1 -гладкой относительно ℓ_1 -нормы: $f(y) \leq f(x) + \langle \nabla f(x), y - x \rangle + \frac{L_1}{2} \|y - x\|_1^2$.

PGD (евклидова геометрия)

- Гладкость: $L_2 \leq n \cdot L_1$ (из $\|x\|_2 \leq \|x\|_1$)
- Диаметр: $R_2 = \sqrt{2}$
- Оценка:

$$f(x_k) - f^* \leq \frac{n \cdot L_1 \cdot 2}{2k} = \frac{nL_1}{k}$$

Мотивация: пример на симплексе

Рассмотрим задачу на стандартном симплексе $\Delta_n = \{x \in \mathbb{R}^n \mid x \geq 0, \mathbf{1}^\top x = 1\}$:

$$\min_{x \in \Delta_n} f(x)$$

Пусть f является L_1 -гладкой относительно ℓ_1 -нормы: $f(y) \leq f(x) + \langle \nabla f(x), y - x \rangle + \frac{L_1}{2} \|y - x\|_1^2$.

PGD (евклидова геометрия)

- Гладкость: $L_2 \leq n \cdot L_1$ (из $\|x\|_2 \leq \|x\|_1$)
- Диаметр: $R_2 = \sqrt{2}$
- Оценка:

$$f(x_k) - f^* \leq \frac{n \cdot L_1 \cdot 2}{2k} = \frac{nL_1}{k}$$

Мотивация: пример на симплексе

Рассмотрим задачу на стандартном симплексе $\Delta_n = \{x \in \mathbb{R}^n \mid x \geq 0, \mathbf{1}^\top x = 1\}$:

$$\min_{x \in \Delta_n} f(x)$$

Пусть f является L_1 -гладкой относительно ℓ_1 -нормы: $f(y) \leq f(x) + \langle \nabla f(x), y - x \rangle + \frac{L_1}{2} \|y - x\|_1^2$.

PGD (евклидова геометрия)

- Гладкость: $L_2 \leq n \cdot L_1$ (из $\|x\|_2 \leq \|x\|_1$)
- Диаметр: $R_2 = \sqrt{2}$
- Оценка:

$$f(x_k) - f^* \leq \frac{n \cdot L_1 \cdot 2}{2k} = \frac{nL_1}{k}$$

Зеркальный спуск (ℓ_1 -геометрия)

- Гладкость: L_1 (без множителя!)

Мотивация: пример на симплексе

Рассмотрим задачу на стандартном симплексе $\Delta_n = \{x \in \mathbb{R}^n \mid x \geq 0, \mathbf{1}^\top x = 1\}$:

$$\min_{x \in \Delta_n} f(x)$$

Пусть f является L_1 -гладкой относительно ℓ_1 -нормы: $f(y) \leq f(x) + \langle \nabla f(x), y - x \rangle + \frac{L_1}{2} \|y - x\|_1^2$.

PGD (евклидова геометрия)

- Гладкость: $L_2 \leq n \cdot L_1$ (из $\|x\|_2 \leq \|x\|_1$)
- Диаметр: $R_2 = \sqrt{2}$
- Оценка:

$$f(x_k) - f^* \leq \frac{n \cdot L_1 \cdot 2}{2k} = \frac{nL_1}{k}$$

Зеркальный спуск (ℓ_1 -геометрия)

- Гладкость: L_1 (без множителя!)
- «Диаметр»: $R_1 = \sqrt{2 \ln n}$ (в смысле дивергенции Брэгмана)

Мотивация: пример на симплексе

Рассмотрим задачу на стандартном симплексе $\Delta_n = \{x \in \mathbb{R}^n \mid x \geq 0, \mathbf{1}^\top x = 1\}$:

$$\min_{x \in \Delta_n} f(x)$$

Пусть f является L_1 -гладкой относительно ℓ_1 -нормы: $f(y) \leq f(x) + \langle \nabla f(x), y - x \rangle + \frac{L_1}{2} \|y - x\|_1^2$.

PGD (евклидова геометрия)

- Гладкость: $L_2 \leq n \cdot L_1$ (из $\|x\|_2 \leq \|x\|_1$)
- Диаметр: $R_2 = \sqrt{2}$
- Оценка:

$$f(x_k) - f^* \leq \frac{n \cdot L_1 \cdot 2}{2k} = \frac{nL_1}{k}$$

Зеркальный спуск (ℓ_1 -геометрия)

- Гладкость: L_1 (без множителя!)
- «Диаметр»: $R_1 = \sqrt{2 \ln n}$ (в смысле дивергенции Брэгмана)
- Оценка:

$$f(x_k) - f^* \leq \frac{L_1 \cdot 2 \ln n}{2k} = \frac{L_1 \ln n}{k}$$

Мотивация: пример на симплексе

Рассмотрим задачу на стандартном симплексе $\Delta_n = \{x \in \mathbb{R}^n \mid x \geq 0, \mathbf{1}^\top x = 1\}$:

$$\min_{x \in \Delta_n} f(x)$$

Пусть f является L_1 -гладкой относительно ℓ_1 -нормы: $f(y) \leq f(x) + \langle \nabla f(x), y - x \rangle + \frac{L_1}{2} \|y - x\|_1^2$.

PGD (евклидова геометрия)

- Гладкость: $L_2 \leq n \cdot L_1$ (из $\|x\|_2 \leq \|x\|_1$)
- Диаметр: $R_2 = \sqrt{2}$
- Оценка:

$$f(x_k) - f^* \leq \frac{n \cdot L_1 \cdot 2}{2k} = \frac{nL_1}{k}$$

Зеркальный спуск (ℓ_1 -геометрия)

- Гладкость: L_1 (без множителя!)
- «Диаметр»: $R_1 = \sqrt{2 \ln n}$ (в смысле дивергенции Брэгмана)
- Оценка:

$$f(x_k) - f^* \leq \frac{L_1 \cdot 2 \ln n}{2k} = \frac{L_1 \ln n}{k}$$

Мотивация: пример на симплексе

Рассмотрим задачу на стандартном симплексе $\Delta_n = \{x \in \mathbb{R}^n \mid x \geq 0, \mathbf{1}^\top x = 1\}$:

$$\min_{x \in \Delta_n} f(x)$$

Пусть f является L_1 -гладкой относительно ℓ_1 -нормы: $f(y) \leq f(x) + \langle \nabla f(x), y - x \rangle + \frac{L_1}{2} \|y - x\|_1^2$.

PGD (евклидова геометрия)

- Гладкость: $L_2 \leq n \cdot L_1$ (из $\|x\|_2 \leq \|x\|_1$)
- Диаметр: $R_2 = \sqrt{2}$
- Оценка:

$$f(x_k) - f^* \leq \frac{n \cdot L_1 \cdot 2}{2k} = \frac{nL_1}{k}$$

Зеркальный спуск (ℓ_1 -геометрия)

- Гладкость: L_1 (без множителя!)
- «Диаметр»: $R_1 = \sqrt{2 \ln n}$ (в смысле дивергенции Брэгмана)
- Оценка:

$$f(x_k) - f^* \leq \frac{L_1 \cdot 2 \ln n}{2k} = \frac{L_1 \ln n}{k}$$

Выигрыш: $\frac{n}{\ln n}$ — экспоненциальный по размерности!

Мотивация: прямое и двойственное пространство

Идея. Градиент $\nabla f(x)$ живёт в **двойственном** пространстве $(\mathbb{R}^n)^*$ с нормой $\|\cdot\|_*$, а переменная x — в **прямом** пространстве $\mathbb{R}^n$ с нормой $\|\cdot\|$.

Мотивация: прямое и двойственное пространство

Идея. Градиент $\nabla f(x)$ живёт в **двойственном** пространстве $(\mathbb{R}^n)^*$ с нормой $\|\cdot\|_*$, а переменная x — в **прямом** пространстве $\mathbb{R}^n$ с нормой $\|\cdot\|$.

В PGD мы неявно отождествляем прямое и двойственное пространство (что корректно только для ℓ_2):

$$x_{k+1} = x_k - \alpha_k \nabla f(x_k)$$

Вычитаем **градиент** (двойственный вектор) из **точки** (прямой вектор) напрямую.

Мотивация: прямое и двойственное пространство

Идея. Градиент $\nabla f(x)$ живёт в **двойственном** пространстве $(\mathbb{R}^n)^*$ с нормой $\|\cdot\|_*$, а переменная x — в **прямом** пространстве $\mathbb{R}^n$ с нормой $\|\cdot\|$.

В PGD мы неявно отождествляем прямое и двойственное пространство (что корректно только для ℓ_2):

$$x_{k+1} = x_k - \alpha_k \nabla f(x_k)$$

Вычитаем **градиент** (двойственный вектор) из **точки** (прямой вектор) напрямую.

В зеркальном спуске мы **явно** работаем с двумя пространствами через **зеркальное отображение** $\nabla\omega$:

$$\begin{aligned}\nabla\omega(y_{k+1}) &= \nabla\omega(x_k) - \alpha_k \nabla f(x_k) \\ x_{k+1} &= \nabla\omega^*(y_{k+1})\end{aligned}$$

Шаг делается в двойственном пространстве, затем результат отображается обратно.

Мотивация: прямое и двойственное пространство

Идея. Градиент $\nabla f(x)$ живёт в **двойственном** пространстве $(\mathbb{R}^n)^*$ с нормой $\|\cdot\|_*$, а переменная x — в **прямом** пространстве $\mathbb{R}^n$ с нормой $\|\cdot\|$.

В PGD мы неявно отождествляем прямое и двойственное пространство (что корректно только для ℓ_2):

$$x_{k+1} = x_k - \alpha_k \nabla f(x_k)$$

Вычитаем **градиент** (двойственный вектор) из **точки** (прямой вектор) напрямую.

Функция ω называется **прокс-функцией** (distance-generating function). Она задаёт геометрию через дивергенцию Брэгмана.

В зеркальном спуске мы **явно** работаем с двумя пространствами через **зеркальное отображение** $\nabla\omega$:

$$\begin{aligned}\nabla\omega(y_{k+1}) &= \nabla\omega(x_k) - \alpha_k \nabla f(x_k) \\ x_{k+1} &= \nabla\omega^*(y_{k+1})\end{aligned}$$

Шаг делается в двойственном пространстве, затем результат отображается обратно.

Дивергенция Брэгмана

i Дивергенция Брэгмана

Пусть $\omega : \mathbb{R}^n \rightarrow \mathbb{R}$ — непрерывно дифференцируемая и строго выпуклая функция. **Дивергенция Брэгмана**, порождённая функцией ω , определяется как:

$$V_{\omega}(x, y) = \omega(x) - \omega(y) - \langle \nabla \omega(y), x - y \rangle$$

Дивергенция Брэгмана

i Дивергенция Брэгмана

Пусть $\omega : \mathbb{R}^n \rightarrow \mathbb{R}$ — непрерывно дифференцируемая и строго выпуклая функция. **Дивергенция Брэгмана**, порождённая функцией ω , определяется как:

$$V_{\omega}(x, y) = \omega(x) - \omega(y) - \langle \nabla \omega(y), x - y \rangle$$

Свойства:

- $V_{\omega}(x, y) \geq 0$ для всех x, y (из строгой выпуклости ω).

Дивергенция Брэгмана

i Дивергенция Брэгмана

Пусть $\omega : \mathbb{R}^n \rightarrow \mathbb{R}$ — непрерывно дифференцируемая и строго выпуклая функция. **Дивергенция Брэгмана**, порождённая функцией ω , определяется как:

$$V_{\omega}(x, y) = \omega(x) - \omega(y) - \langle \nabla \omega(y), x - y \rangle$$

Свойства:

- $V_{\omega}(x, y) \geq 0$ для всех x, y (из строгой выпуклости ω).
- $V_{\omega}(x, y) = 0 \Leftrightarrow x = y$.

Дивергенция Брэгмана

i Дивергенция Брэгмана

Пусть $\omega : \mathbb{R}^n \rightarrow \mathbb{R}$ — непрерывно дифференцируемая и строго выпуклая функция. **Дивергенция Брэгмана**, порождённая функцией ω , определяется как:

$$V_{\omega}(x, y) = \omega(x) - \omega(y) - \langle \nabla \omega(y), x - y \rangle$$

Свойства:

- $V_{\omega}(x, y) \geq 0$ для всех x, y (из строгой выпуклости ω).
- $V_{\omega}(x, y) = 0 \Leftrightarrow x = y$.
- **Не симметрична** в общем случае: $V_{\omega}(x, y) \neq V_{\omega}(y, x)$.

Дивергенция Брэгмана

i Дивергенция Брэгмана

Пусть $\omega : \mathbb{R}^n \rightarrow \mathbb{R}$ — непрерывно дифференцируемая и строго выпуклая функция. **Дивергенция Брэгмана**, порождённая функцией ω , определяется как:

$$V_{\omega}(x, y) = \omega(x) - \omega(y) - \langle \nabla \omega(y), x - y \rangle$$

Свойства:

- $V_{\omega}(x, y) \geq 0$ для всех x, y (из строгой выпуклости ω).
- $V_{\omega}(x, y) = 0 \Leftrightarrow x = y$.
- **Не симметрична** в общем случае: $V_{\omega}(x, y) \neq V_{\omega}(y, x)$.
- **Не удовлетворяет** неравенству треугольника.

Дивергенция Брэгмана

i Дивергенция Брэгмана

Пусть $\omega : \mathbb{R}^n \rightarrow \mathbb{R}$ — непрерывно дифференцируемая и строго выпуклая функция. **Дивергенция Брэгмана**, порождённая функцией ω , определяется как:

$$V_{\omega}(x, y) = \omega(x) - \omega(y) - \langle \nabla \omega(y), x - y \rangle$$

Свойства:

- $V_{\omega}(x, y) \geq 0$ для всех x, y (из строгой выпуклости ω).
- $V_{\omega}(x, y) = 0 \Leftrightarrow x = y$.
- **Не симметрична** в общем случае: $V_{\omega}(x, y) \neq V_{\omega}(y, x)$.
- **Не удовлетворяет** неравенству треугольника.
- Геометрически: $V_{\omega}(x, y)$ — разность между $\omega(x)$ и значением касательной к ω в точке y , вычисленным в точке x .

Примеры дивергенций Брэгмана

Евклидова дивергенция

$$\omega(x) = \frac{1}{2}\|x\|_2^2$$

$$V_\omega(x, y) = \frac{1}{2}\|x\|_2^2 - \frac{1}{2}\|y\|_2^2 - \langle y, x - y \rangle = \frac{1}{2}\|x - y\|_2^2$$

Воспроизводит обычный PGD.

Примеры дивергенций Брэгмана

Евклидова дивергенция

$$\omega(x) = \frac{1}{2} \|x\|_2^2$$

$$V_\omega(x, y) = \frac{1}{2} \|x\|_2^2 - \frac{1}{2} \|y\|_2^2 - \langle y, x - y \rangle = \frac{1}{2} \|x - y\|_2^2$$

Воспроизводит обычный PGD.

Дивергенция Кульбака-Лейблера (KL)

$$\omega(x) = \sum_{i=1}^n x_i \ln x_i \text{ (негативная энтропия) на } \Delta_n$$

$$V_\omega(x, y) = \sum_{i=1}^n x_i \ln \frac{x_i}{y_i}$$

Естественна для задач на симплексе.

Примеры дивергенций Брэгмана

Евклидова дивергенция

$$\omega(x) = \frac{1}{2}\|x\|_2^2$$

$$V_\omega(x, y) = \frac{1}{2}\|x\|_2^2 - \frac{1}{2}\|y\|_2^2 - \langle y, x - y \rangle = \frac{1}{2}\|x - y\|_2^2$$

Воспроизводит обычный PGD.

Дивергенция Кульбака-Лейблера (KL)

$$\omega(x) = \sum_{i=1}^n x_i \ln x_i \text{ (негативная энтропия) на } \Delta_n$$

$$V_\omega(x, y) = \sum_{i=1}^n x_i \ln \frac{x_i}{y_i}$$

Естественна для задач на симплексе.

Дивергенция Итакура-Саито

$$\omega(x) = -\sum_{i=1}^n \ln x_i \text{ на } \mathbb{R}_{++}^n$$

$$V_\omega(x, y) = \sum_{i=1}^n \left(\frac{x_i}{y_i} - \ln \frac{x_i}{y_i} - 1 \right)$$

Используется в обработке сигналов.

Примеры дивергенций Брэгмана

Евклидова дивергенция

$$\omega(x) = \frac{1}{2}\|x\|_2^2$$

$$V_\omega(x, y) = \frac{1}{2}\|x\|_2^2 - \frac{1}{2}\|y\|_2^2 - \langle y, x - y \rangle = \frac{1}{2}\|x - y\|_2^2$$

Воспроизводит обычный PGD.

Дивергенция Кульбака-Лейблера (KL)

$$\omega(x) = \sum_{i=1}^n x_i \ln x_i \text{ (негативная энтропия) на } \Delta_n$$

$$V_\omega(x, y) = \sum_{i=1}^n x_i \ln \frac{x_i}{y_i}$$

Естественна для задач на симплексе.

Дивергенция Итакура-Саито

$$\omega(x) = -\sum_{i=1}^n \ln x_i \text{ на } \mathbb{R}_{++}^n$$

$$V_\omega(x, y) = \sum_{i=1}^n \left(\frac{x_i}{y_i} - \ln \frac{x_i}{y_i} - 1 \right)$$

Используется в обработке сигналов.

Дивергенция Махаланобиса

$$\omega(x) = \frac{1}{2}x^\top Qx, \text{ где } Q \succ 0$$

$$V_\omega(x, y) = \frac{1}{2}(x - y)^\top Q(x - y)$$

Обобщённая евклидова геометрия.

Сильная выпуклость относительно нормы

Definition

Функция ω называется **σ -сильно выпуклой относительно нормы $\|\cdot\|$** , если для всех x, y из области определения:

$$V_{\omega}(x, y) \geq \frac{\sigma}{2} \|x - y\|^2$$

Сильная выпуклость относительно нормы

Definition

Функция ω называется σ -**сильно выпуклой относительно нормы** $\|\cdot\|$, если для всех x, y из области определения:

$$V_{\omega}(x, y) \geq \frac{\sigma}{2} \|x - y\|^2$$

Ключевые примеры:

- $\omega(x) = \frac{1}{2} \|x\|_2^2$ является 1-сильно выпуклой относительно $\|\cdot\|_2$.

Сильная выпуклость относительно нормы

Definition

Функция ω называется σ -**сильно выпуклой относительно нормы** $\|\cdot\|$, если для всех x, y из области определения:

$$V_{\omega}(x, y) \geq \frac{\sigma}{2} \|x - y\|^2$$

Ключевые примеры:

- $\omega(x) = \frac{1}{2} \|x\|_2^2$ является 1-сильно выпуклой относительно $\|\cdot\|_2$.
- $\omega(x) = \sum_i x_i \ln x_i$ (негативная энтропия) является 1-сильно выпуклой относительно $\|\cdot\|_1$ на симплексе Δ_n .

Сильная выпуклость относительно нормы

i Definition

Функция ω называется σ -**сильно выпуклой относительно нормы** $\|\cdot\|$, если для всех x, y из области определения:

$$V_{\omega}(x, y) \geq \frac{\sigma}{2} \|x - y\|^2$$

Ключевые примеры:

- $\omega(x) = \frac{1}{2} \|x\|_2^2$ является 1-сильно выпуклой относительно $\|\cdot\|_2$.
- $\omega(x) = \sum_i x_i \ln x_i$ (негативная энтропия) является 1-сильно выпуклой относительно $\|\cdot\|_1$ на симплексе Δ_n .
 - Это утверждение известно как **неравенство Пинскера** и является нетривиальным результатом.

Сильная выпуклость относительно нормы

i Definition

Функция ω называется σ -**сильно выпуклой относительно нормы** $\|\cdot\|$, если для всех x, y из области определения:

$$V_{\omega}(x, y) \geq \frac{\sigma}{2} \|x - y\|^2$$

Ключевые примеры:

- $\omega(x) = \frac{1}{2} \|x\|_2^2$ является 1-сильно выпуклой относительно $\|\cdot\|_2$.
- $\omega(x) = \sum_i x_i \ln x_i$ (негативная энтропия) является 1-сильно выпуклой относительно $\|\cdot\|_1$ на симплексе Δ_n .
 - Это утверждение известно как **неравенство Пинскера** и является нетривиальным результатом.

Сильная выпуклость относительно нормы

i Definition

Функция ω называется σ -**сильно выпуклой относительно нормы** $\|\cdot\|$, если для всех x, y из области определения:

$$V_{\omega}(x, y) \geq \frac{\sigma}{2} \|x - y\|^2$$

Ключевые примеры:

- $\omega(x) = \frac{1}{2} \|x\|_2^2$ является 1-сильно выпуклой относительно $\|\cdot\|_2$.
- $\omega(x) = \sum_i x_i \ln x_i$ (негативная энтропия) является 1-сильно выпуклой относительно $\|\cdot\|_1$ на симплексе Δ_n .
- Это утверждение известно как **неравенство Пинскера** и является нетривиальным результатом.

Именно σ -сильная выпуклость прокс-функции ω относительно нормы $\|\cdot\|$ позволяет дивергенции Брэгмана «измерять расстояния» в геометрии, задаваемой нормой $\|\cdot\|$.

Алгоритм зеркального спуска

Задача: $\min_{x \in S} f(x)$, где f — выпуклая функция, S — замкнутое выпуклое множество.

Алгоритм зеркального спуска

Задача: $\min_{x \in S} f(x)$, где f — выпуклая функция, S — замкнутое выпуклое множество.

i Метод зеркального спуска (Mirror Descent)

Вход: $x_0 \in S$, шаги $\{\alpha_k\}$, прокс-функция ω .

Для $k = 0, 1, 2, \dots$:

1. Вычислить градиент $g_k = \nabla f(x_k)$

Алгоритм зеркального спуска

Задача: $\min_{x \in S} f(x)$, где f — выпуклая функция, S — замкнутое выпуклое множество.

i Метод зеркального спуска (Mirror Descent)

Вход: $x_0 \in S$, шаги $\{\alpha_k\}$, прокс-функция ω .

Для $k = 0, 1, 2, \dots$:

1. Вычислить градиент $g_k = \nabla f(x_k)$
2. Шаг в двойственном пространстве:

$$x_{k+1} = \arg \min_{x \in S} \left\{ \langle g_k, x \rangle + \frac{1}{\alpha_k} V_\omega(x, x_k) \right\}$$

Алгоритм зеркального спуска

Задача: $\min_{x \in S} f(x)$, где f — выпуклая функция, S — замкнутое выпуклое множество.

i Метод зеркального спуска (Mirror Descent)

Вход: $x_0 \in S$, шаги $\{\alpha_k\}$, прокс-функция ω .

Для $k = 0, 1, 2, \dots$:

1. Вычислить градиент $g_k = \nabla f(x_k)$
2. Шаг в двойственном пространстве:

$$x_{k+1} = \arg \min_{x \in S} \left\{ \langle g_k, x \rangle + \frac{1}{\alpha_k} V_\omega(x, x_k) \right\}$$

Алгоритм зеркального спуска

Задача: $\min_{x \in S} f(x)$, где f — выпуклая функция, S — замкнутое выпуклое множество.

i Метод зеркального спуска (Mirror Descent)

Вход: $x_0 \in S$, шаги $\{\alpha_k\}$, прокс-функция ω .

Для $k = 0, 1, 2, \dots$:

1. Вычислить градиент $g_k = \nabla f(x_k)$
2. Шаг в двойственном пространстве:

$$x_{k+1} = \arg \min_{x \in S} \left\{ \langle g_k, x \rangle + \frac{1}{\alpha_k} V_\omega(x, x_k) \right\}$$

Интерпретация: на каждом шаге минимизируем линейное приближение f с регуляризацией дивергенцией Брэгмана вместо $\frac{1}{2\alpha} \|x - x_k\|_2^2$.

Алгоритм зеркального спуска

Задача: $\min_{x \in S} f(x)$, где f — выпуклая функция, S — замкнутое выпуклое множество.

i Метод зеркального спуска (Mirror Descent)

Вход: $x_0 \in S$, шаги $\{\alpha_k\}$, прокс-функция ω .

Для $k = 0, 1, 2, \dots$:

1. Вычислить градиент $g_k = \nabla f(x_k)$
2. Шаг в двойственном пространстве:

$$x_{k+1} = \arg \min_{x \in S} \left\{ \langle g_k, x \rangle + \frac{1}{\alpha_k} V_\omega(x, x_k) \right\}$$

Интерпретация: на каждом шаге минимизируем линейное приближение f с регуляризацией дивергенцией Брэгмана вместо $\frac{1}{2\alpha} \|x - x_k\|_2^2$.

Частный случай: при $\omega(x) = \frac{1}{2} \|x\|_2^2$ получаем $V_\omega(x, y) = \frac{1}{2} \|x - y\|_2^2$, и итерация принимает вид:

$$x_{k+1} = \arg \min_{x \in S} \left\{ \langle \nabla f(x_k), x \rangle + \frac{1}{2\alpha_k} \|x - x_k\|_2^2 \right\} = \text{proj}_S(x_k - \alpha_k \nabla f(x_k))$$

то есть стандартный PGD.

Зеркальный спуск: эквивалентные формы итерации

Итерацию зеркального спуска можно записать в нескольких эквивалентных формах:

Зеркальный спуск: эквивалентные формы итерации

Итерацию зеркального спуска можно записать в нескольких эквивалентных формах:

1. Проксимальная форма (основная):

$$x_{k+1} = \arg \min_{x \in S} \{ \alpha_k \langle \nabla f(x_k), x \rangle + V_\omega(x, x_k) \}$$

Зеркальный спуск: эквивалентные формы итерации

Итерацию зеркального спуска можно записать в нескольких эквивалентных формах:

1. Проксимальная форма (основная):

$$x_{k+1} = \arg \min_{x \in S} \{ \alpha_k \langle \nabla f(x_k), x \rangle + V_\omega(x, x_k) \}$$

2. Двойственная форма (через зеркальное отображение):

Для безусловной задачи ($S = \mathbb{R}^n$), используя условие оптимальности $\nabla_x V_\omega(x, x_k) = \nabla \omega(x) - \nabla \omega(x_k)$:

$$\nabla \omega(x_{k+1}) = \nabla \omega(x_k) - \alpha_k \nabla f(x_k)$$

Зеркальный спуск: эквивалентные формы итерации

Итерацию зеркального спуска можно записать в нескольких эквивалентных формах:

1. Проксимальная форма (основная):

$$x_{k+1} = \arg \min_{x \in S} \{ \alpha_k \langle \nabla f(x_k), x \rangle + V_\omega(x, x_k) \}$$

2. Двойственная форма (через зеркальное отображение):

Для безусловной задачи ($S = \mathbb{R}^n$), используя условие оптимальности $\nabla_x V_\omega(x, x_k) = \nabla \omega(x) - \nabla \omega(x_k)$:

$$\nabla \omega(x_{k+1}) = \nabla \omega(x_k) - \alpha_k \nabla f(x_k)$$

3. Проекция Брэгмана (для условной задачи):

$$y_{k+1} : \quad \nabla \omega(y_{k+1}) = \nabla \omega(x_k) - \alpha_k \nabla f(x_k)$$

$$x_{k+1} = \arg \min_{x \in S} V_\omega(x, y_{k+1})$$

Зеркальный спуск: эквивалентные формы итерации

Итерацию зеркального спуска можно записать в нескольких эквивалентных формах:

1. Проксимальная форма (основная):

$$x_{k+1} = \arg \min_{x \in S} \{ \alpha_k \langle \nabla f(x_k), x \rangle + V_\omega(x, x_k) \}$$

2. Двойственная форма (через зеркальное отображение):

Для безусловной задачи ($S = \mathbb{R}^n$), используя условие оптимальности $\nabla_x V_\omega(x, x_k) = \nabla \omega(x) - \nabla \omega(x_k)$:

$$\nabla \omega(x_{k+1}) = \nabla \omega(x_k) - \alpha_k \nabla f(x_k)$$

3. Проекция Брэгмана (для условной задачи):

$$y_{k+1} : \quad \nabla \omega(y_{k+1}) = \nabla \omega(x_k) - \alpha_k \nabla f(x_k)$$

$$x_{k+1} = \arg \min_{x \in S} V_\omega(x, y_{k+1})$$

В евклидовом случае ($\omega = \frac{1}{2} \|\cdot\|_2^2$) проекция Брэгмана совпадает с евклидовой проекцией.

Зеркальный спуск на симплексе: Exponentiated Gradient

Важнейший частный случай: $S = \Delta_n$, $\omega(x) = \sum_i x_i \ln x_i$.

Зеркальный спуск на симплексе: Exponentiated Gradient

Важнейший частный случай: $S = \Delta_n$, $\omega(x) = \sum_i x_i \ln x_i$.

Итерация зеркального спуска принимает **замкнутую форму**:

$$x_{k+1,i} = \frac{x_{k,i} \exp(-\alpha_k [\nabla f(x_k)]_i)}{\sum_{j=1}^n x_{k,j} \exp(-\alpha_k [\nabla f(x_k)]_j)}, \quad i = 1, \dots, n$$

Зеркальный спуск на симплексе: Exponentiated Gradient

Важнейший частный случай: $S = \Delta_n$, $\omega(x) = \sum_i x_i \ln x_i$.

Итерация зеркального спуска принимает **замкнутую форму**:

$$x_{k+1,i} = \frac{x_{k,i} \exp(-\alpha_k [\nabla f(x_k)]_i)}{\sum_{j=1}^n x_{k,j} \exp(-\alpha_k [\nabla f(x_k)]_j)}, \quad i = 1, \dots, n$$

Этот метод известен как **Exponentiated Gradient (EG)** или **Multiplicative Weights Update**.

Зеркальный спуск на симплексе: Exponentiated Gradient

Важнейший частный случай: $S = \Delta_n$, $\omega(x) = \sum_i x_i \ln x_i$.

Итерация зеркального спуска принимает **замкнутую форму**:

$$x_{k+1,i} = \frac{x_{k,i} \exp(-\alpha_k [\nabla f(x_k)]_i)}{\sum_{j=1}^n x_{k,j} \exp(-\alpha_k [\nabla f(x_k)]_j)}, \quad i = 1, \dots, n$$

Этот метод известен как **Exponentiated Gradient (EG)** или **Multiplicative Weights Update**.

Вывод. Из условия оптимальности: $\ln x_{k+1,i} + 1 - \ln x_{k,i} - 1 + \alpha_k g_i + \lambda = 0$, где λ — множитель Лагранжа для ограничения $\sum_i x_i = 1$. Тогда $x_{k+1,i} \propto x_{k,i} \exp(-\alpha_k g_i)$, и нормировка даёт формулу выше.

Зеркальный спуск на симплексе: Exponentiated Gradient

Важнейший частный случай: $S = \Delta_n$, $\omega(x) = \sum_i x_i \ln x_i$.

Итерация зеркального спуска принимает **замкнутую форму**:

$$x_{k+1,i} = \frac{x_{k,i} \exp(-\alpha_k [\nabla f(x_k)]_i)}{\sum_{j=1}^n x_{k,j} \exp(-\alpha_k [\nabla f(x_k)]_j)}, \quad i = 1, \dots, n$$

Этот метод известен как **Exponentiated Gradient (EG)** или **Multiplicative Weights Update**.

Вывод. Из условия оптимальности: $\ln x_{k+1,i} + 1 - \ln x_{k,i} - 1 + \alpha_k g_i + \lambda = 0$, где λ — множитель Лагранжа для ограничения $\sum_i x_i = 1$. Тогда $x_{k+1,i} \propto x_{k,i} \exp(-\alpha_k g_i)$, и нормировка даёт формулу выше.

Стоимость: $\mathcal{O}(n)$ — **не требуется** сортировка (в отличие от евклидовой проекции на симплекс, которая стоит $\mathcal{O}(n \log n)$).



i Theorem

Пусть $f : S \rightarrow \mathbb{R}$ — выпуклая функция с L -липшицевым градиентом относительно нормы $\|\cdot\|$:

$$\|\nabla f(x) - \nabla f(y)\|_* \leq L\|x - y\| \quad \forall x, y \in S$$

Пусть прокс-функция ω является σ -сильно выпуклой относительно $\|\cdot\|$, и $R^2 = \max_{x \in S} V_\omega(x, x_0)$. Тогда зеркальный спуск с шагом $\alpha_k = \frac{1}{L/\sigma}$ обеспечивает:

$$f(x_k) - f^* \leq \frac{LR^2}{\sigma k}$$

Скорость сходимости зеркального спуска

Theorem

Пусть $f : S \rightarrow \mathbb{R}$ — выпуклая функция с L -липшицевым градиентом относительно нормы $\|\cdot\|$:

$$\|\nabla f(x) - \nabla f(y)\|_* \leq L\|x - y\| \quad \forall x, y \in S$$

Пусть прокс-функция ω является σ -сильно выпуклой относительно $\|\cdot\|$, и $R^2 = \max_{x \in S} V_\omega(x, x_0)$. Тогда зеркальный спуск с шагом $\alpha_k = \frac{1}{L/\sigma}$ обеспечивает:

$$f(x_k) - f^* \leq \frac{LR^2}{\sigma k}$$

Сравнение с PGD:

	PGD	Зеркальный спуск
Норма	$\ \cdot\ _2$	$\ \cdot\ $ (произвольная)
Гладкость	L_2	L (отн. $\ \cdot\ $)
«Радиус»	$R_2 = \ x_0 - x^*\ _2$	$R^2 = V_\omega(x^*, x_0)$
Оценка	$\frac{L_2 R_2^2}{k}$	$\frac{LR^2}{\sigma k}$

Доказательство сходимости

1. Из L -гладкости f относительно нормы $\|\cdot\|$ при шаге $\alpha = \sigma/L$:

$$f(x_{k+1}) \leq f(x_k) + \langle \nabla f(x_k), x_{k+1} - x_k \rangle + \frac{L}{2} \|x_{k+1} - x_k\|^2$$

Доказательство сходимости

1. Из L -гладкости f относительно нормы $\|\cdot\|$ при шаге $\alpha = \sigma/L$:

$$f(x_{k+1}) \leq f(x_k) + \langle \nabla f(x_k), x_{k+1} - x_k \rangle + \frac{L}{2} \|x_{k+1} - x_k\|^2$$

Доказательство сходимости

1. Из L -гладкости f относительно нормы $\|\cdot\|$ при шаге $\alpha = \sigma/L$:

$$f(x_{k+1}) \leq f(x_k) + \langle \nabla f(x_k), x_{k+1} - x_k \rangle + \frac{L}{2} \|x_{k+1} - x_k\|^2$$

2. Из σ -сильной выпуклости ω : $\frac{L}{2} \|x_{k+1} - x_k\|^2 \leq \frac{L}{\sigma} V_\omega(x_{k+1}, x_k)$. Следовательно:

$$f(x_{k+1}) \leq f(x_k) + \langle \nabla f(x_k), x_{k+1} - x_k \rangle + \frac{L}{\sigma} V_\omega(x_{k+1}, x_k)$$

Доказательство сходимости

1. Из L -гладкости f относительно нормы $\|\cdot\|$ при шаге $\alpha = \sigma/L$:

$$f(x_{k+1}) \leq f(x_k) + \langle \nabla f(x_k), x_{k+1} - x_k \rangle + \frac{L}{2} \|x_{k+1} - x_k\|^2$$

2. Из σ -сильной выпуклости ω : $\frac{L}{2} \|x_{k+1} - x_k\|^2 \leq \frac{L}{\sigma} V_\omega(x_{k+1}, x_k)$. Следовательно:

$$f(x_{k+1}) \leq f(x_k) + \langle \nabla f(x_k), x_{k+1} - x_k \rangle + \frac{L}{\sigma} V_\omega(x_{k+1}, x_k)$$

Доказательство сходимости

1. Из L -гладкости f относительно нормы $\|\cdot\|$ при шаге $\alpha = \sigma/L$:

$$f(x_{k+1}) \leq f(x_k) + \langle \nabla f(x_k), x_{k+1} - x_k \rangle + \frac{L}{2} \|x_{k+1} - x_k\|^2$$

2. Из σ -сильной выпуклости ω : $\frac{L}{2} \|x_{k+1} - x_k\|^2 \leq \frac{L}{\sigma} V_\omega(x_{k+1}, x_k)$. Следовательно:

$$f(x_{k+1}) \leq f(x_k) + \langle \nabla f(x_k), x_{k+1} - x_k \rangle + \frac{L}{\sigma} V_\omega(x_{k+1}, x_k)$$

3. Из определения итерации (условие оптимальности) и выпуклости f для любого $x \in S$:

$$\alpha_k \langle \nabla f(x_k), x_{k+1} - x \rangle \leq V_\omega(x, x_k) - V_\omega(x, x_{k+1}) - V_\omega(x_{k+1}, x_k)$$

Доказательство сходимости

1. Из L -гладкости f относительно нормы $\|\cdot\|$ при шаге $\alpha = \sigma/L$:

$$f(x_{k+1}) \leq f(x_k) + \langle \nabla f(x_k), x_{k+1} - x_k \rangle + \frac{L}{2} \|x_{k+1} - x_k\|^2$$

2. Из σ -сильной выпуклости ω : $\frac{L}{2} \|x_{k+1} - x_k\|^2 \leq \frac{L}{\sigma} V_\omega(x_{k+1}, x_k)$. Следовательно:

$$f(x_{k+1}) \leq f(x_k) + \langle \nabla f(x_k), x_{k+1} - x_k \rangle + \frac{L}{\sigma} V_\omega(x_{k+1}, x_k)$$

3. Из определения итерации (условие оптимальности) и выпуклости f для любого $x \in S$:

$$\alpha_k \langle \nabla f(x_k), x_{k+1} - x \rangle \leq V_\omega(x, x_k) - V_\omega(x, x_{k+1}) - V_\omega(x_{k+1}, x_k)$$

Доказательство сходимости

1. Из L -гладкости f относительно нормы $\|\cdot\|$ при шаге $\alpha = \sigma/L$:

$$f(x_{k+1}) \leq f(x_k) + \langle \nabla f(x_k), x_{k+1} - x_k \rangle + \frac{L}{2} \|x_{k+1} - x_k\|^2$$

2. Из σ -сильной выпуклости ω : $\frac{L}{2} \|x_{k+1} - x_k\|^2 \leq \frac{L}{\sigma} V_\omega(x_{k+1}, x_k)$. Следовательно:

$$f(x_{k+1}) \leq f(x_k) + \langle \nabla f(x_k), x_{k+1} - x_k \rangle + \frac{L}{\sigma} V_\omega(x_{k+1}, x_k)$$

3. Из определения итерации (условие оптимальности) и выпуклости f для любого $x \in S$:

$$\alpha_k \langle \nabla f(x_k), x_{k+1} - x \rangle \leq V_\omega(x, x_k) - V_\omega(x, x_{k+1}) - V_\omega(x_{k+1}, x_k)$$

Это **лемма трёх точек** (three-point identity) для дивергенции Брэгмана:

$$V_\omega(x, x_k) - V_\omega(x, x_{k+1}) = \langle \nabla \omega(x_{k+1}) - \nabla \omega(x_k), x - x_{k+1} \rangle + V_\omega(x_{k+1}, x_k)$$

Доказательство сходимости (продолжение)

4. Подставляя $x = x^*$ и используя выпуклость $f(x_k) - f^* \leq \langle \nabla f(x_k), x_k - x^* \rangle$:

$$\begin{aligned}\alpha_k(f(x_k) - f^*) &\leq \alpha_k \langle \nabla f(x_k), x_k - x^* \rangle \\ &= \alpha_k \langle \nabla f(x_k), x_k - x_{k+1} \rangle + \alpha_k \langle \nabla f(x_k), x_{k+1} - x^* \rangle \\ &\leq \alpha_k \langle \nabla f(x_k), x_k - x_{k+1} \rangle + V_\omega(x^*, x_k) - V_\omega(x^*, x_{k+1}) - V_\omega(x_{k+1}, x_k)\end{aligned}$$

Доказательство сходимости (продолжение)

4. Подставляя $x = x^*$ и используя выпуклость $f(x_k) - f^* \leq \langle \nabla f(x_k), x_k - x^* \rangle$:

$$\begin{aligned}\alpha_k(f(x_k) - f^*) &\leq \alpha_k \langle \nabla f(x_k), x_k - x^* \rangle \\ &= \alpha_k \langle \nabla f(x_k), x_k - x_{k+1} \rangle + \alpha_k \langle \nabla f(x_k), x_{k+1} - x^* \rangle \\ &\leq \alpha_k \langle \nabla f(x_k), x_k - x_{k+1} \rangle + V_\omega(x^*, x_k) - V_\omega(x^*, x_{k+1}) - V_\omega(x_{k+1}, x_k)\end{aligned}$$

Доказательство сходимости (продолжение)

4. Подставляя $x = x^*$ и используя выпуклость $f(x_k) - f^* \leq \langle \nabla f(x_k), x_k - x^* \rangle$:

$$\begin{aligned}\alpha_k(f(x_k) - f^*) &\leq \alpha_k \langle \nabla f(x_k), x_k - x^* \rangle \\ &= \alpha_k \langle \nabla f(x_k), x_k - x_{k+1} \rangle + \alpha_k \langle \nabla f(x_k), x_{k+1} - x^* \rangle \\ &\leq \alpha_k \langle \nabla f(x_k), x_k - x_{k+1} \rangle + V_\omega(x^*, x_k) - V_\omega(x^*, x_{k+1}) - V_\omega(x_{k+1}, x_k)\end{aligned}$$

5. Суммируя по $k = 0, \dots, K - 1$ и используя телескопирование:

$$\sum_{k=0}^{K-1} \alpha_k(f(x_k) - f^*) \leq V_\omega(x^*, x_0) + \sum_{k=0}^{K-1} [\alpha_k \langle \nabla f(x_k), x_k - x_{k+1} \rangle - V_\omega(x_{k+1}, x_k)]$$

Доказательство сходимости (продолжение)

4. Подставляя $x = x^*$ и используя выпуклость $f(x_k) - f^* \leq \langle \nabla f(x_k), x_k - x^* \rangle$:

$$\begin{aligned}\alpha_k(f(x_k) - f^*) &\leq \alpha_k \langle \nabla f(x_k), x_k - x^* \rangle \\ &= \alpha_k \langle \nabla f(x_k), x_k - x_{k+1} \rangle + \alpha_k \langle \nabla f(x_k), x_{k+1} - x^* \rangle \\ &\leq \alpha_k \langle \nabla f(x_k), x_k - x_{k+1} \rangle + V_\omega(x^*, x_k) - V_\omega(x^*, x_{k+1}) - V_\omega(x_{k+1}, x_k)\end{aligned}$$

5. Суммируя по $k = 0, \dots, K - 1$ и используя телескопирование:

$$\sum_{k=0}^{K-1} \alpha_k(f(x_k) - f^*) \leq V_\omega(x^*, x_0) + \sum_{k=0}^{K-1} [\alpha_k \langle \nabla f(x_k), x_k - x_{k+1} \rangle - V_\omega(x_{k+1}, x_k)]$$

Доказательство сходимости (продолжение)

4. Подставляя $x = x^*$ и используя выпуклость $f(x_k) - f^* \leq \langle \nabla f(x_k), x_k - x^* \rangle$:

$$\begin{aligned}\alpha_k(f(x_k) - f^*) &\leq \alpha_k \langle \nabla f(x_k), x_k - x^* \rangle \\ &= \alpha_k \langle \nabla f(x_k), x_k - x_{k+1} \rangle + \alpha_k \langle \nabla f(x_k), x_{k+1} - x^* \rangle \\ &\leq \alpha_k \langle \nabla f(x_k), x_k - x_{k+1} \rangle + V_\omega(x^*, x_k) - V_\omega(x^*, x_{k+1}) - V_\omega(x_{k+1}, x_k)\end{aligned}$$

5. Суммируя по $k = 0, \dots, K-1$ и используя телескопирование:

$$\sum_{k=0}^{K-1} \alpha_k(f(x_k) - f^*) \leq V_\omega(x^*, x_0) + \sum_{k=0}^{K-1} [\alpha_k \langle \nabla f(x_k), x_k - x_{k+1} \rangle - V_\omega(x_{k+1}, x_k)]$$

6. Используя шаг 2 для оценки каждого слагаемого и монотонность $f(x_k)$:

$$K \cdot (f(x_K) - f^*) \leq \frac{L}{\sigma} V_\omega(x^*, x_0) = \frac{LR^2}{\sigma}$$

откуда $f(x_K) - f^* \leq \frac{LR^2}{\sigma K}$, что и требовалось доказать.

Пример: зеркальный спуск vs PGD на симплексе

Рассмотрим задачу

$$\min_{x \in \Delta_n} f(x) = \frac{1}{2} \|Ax - b\|_2^2$$

- PGD: евклидова проекция на Δ_n , $\mathcal{O}(n \log n)$ на шаг

Пример: зеркальный спуск vs PGD на симплексе

Рассмотрим задачу

$$\min_{x \in \Delta_n} f(x) = \frac{1}{2} \|Ax - b\|_2^2$$

- PGD: евклидова проекция на Δ_n , $\mathcal{O}(n \log n)$ на шаг
- MD (EG): мультипликативное обновление, $\mathcal{O}(n)$ на шаг

Пример: зеркальный спуск vs PGD на симплексе

Рассмотрим задачу

$$\min_{x \in \Delta_n} f(x) = \frac{1}{2} \|Ax - b\|_2^2$$

- PGD: евклидова проекция на Δ_n , $\mathcal{O}(n \log n)$ на шаг
- MD (EG): мультипликативное обновление, $\mathcal{O}(n)$ на шаг

Пример: зеркальный спуск vs PGD на симплексе

Рассмотрим задачу

$$\min_{x \in \Delta_n} f(x) = \frac{1}{2} \|Ax - b\|_2^2$$

- PGD: евклидова проекция на Δ_n , $\mathcal{O}(n \log n)$ на шаг
- MD (EG): мультипликативное обновление, $\mathcal{O}(n)$ на шаг

Когда A имеет слабую корреляцию между столбцами:
 $L_2 \approx n \cdot L_\infty$. Тогда:

- PGD: $\mathcal{O}\left(\frac{nL_\infty}{k}\right)$

Параметр	PGD	MD (EG)
Гладкость	$L_2 = \ A^\top A\ _{\text{op}}$	$L_\infty = \max_{ij} A^\top A _{ij}$
«Радиус»	$R_2^2 \leq 2$	$R^2 \leq \ln n$
Оценка	$\frac{L_2}{k}$	$\frac{L_\infty \ln n}{k}$

Пример: зеркальный спуск vs PGD на симплексе

Рассмотрим задачу

$$\min_{x \in \Delta_n} f(x) = \frac{1}{2} \|Ax - b\|_2^2$$

- PGD: евклидова проекция на Δ_n , $\mathcal{O}(n \log n)$ на шаг
- MD (EG): мультипликативное обновление, $\mathcal{O}(n)$ на шаг

Когда A имеет слабую корреляцию между столбцами:

$L_2 \approx n \cdot L_\infty$. Тогда:

- PGD: $\mathcal{O}\left(\frac{nL_\infty}{k}\right)$
- MD: $\mathcal{O}\left(\frac{L_\infty \ln n}{k}\right)$

Параметр	PGD	MD (EG)
Гладкость	$L_2 = \ A^\top A\ _{\text{op}}$	$L_\infty = \max_{ij} A^\top A _{ij}$
«Радиус»	$R_2^2 \leq 2$	$R^2 \leq \ln n$
Оценка	$\frac{L_2}{k}$	$\frac{L_\infty \ln n}{k}$

Пример: зеркальный спуск vs PGD на симплексе

Рассмотрим задачу

$$\min_{x \in \Delta_n} f(x) = \frac{1}{2} \|Ax - b\|_2^2$$

- PGD: евклидова проекция на Δ_n , $\mathcal{O}(n \log n)$ на шаг
- MD (EG): мультипликативное обновление, $\mathcal{O}(n)$ на шаг

Когда A имеет слабую корреляцию между столбцами:

$L_2 \approx n \cdot L_\infty$. Тогда:

- PGD: $\mathcal{O}\left(\frac{nL_\infty}{k}\right)$
- MD: $\mathcal{O}\left(\frac{L_\infty \ln n}{k}\right)$

Параметр	PGD	MD (EG)
Гладкость	$L_2 = \ A^\top A\ _{\text{op}}$	$L_\infty = \max_{ij} A^\top A _{ij}$
«Радиус»	$R_2^2 \leq 2$	$R^2 \leq \ln n$
Оценка	$\frac{L_2}{k}$	$\frac{L_\infty \ln n}{k}$

Пример: зеркальный спуск vs PGD на симплексе

Рассмотрим задачу

$$\min_{x \in \Delta_n} f(x) = \frac{1}{2} \|Ax - b\|_2^2$$

- PGD: евклидова проекция на Δ_n , $\mathcal{O}(n \log n)$ на шаг
- MD (EG): мультипликативное обновление, $\mathcal{O}(n)$ на шаг

Когда A имеет слабую корреляцию между столбцами:

$L_2 \approx n \cdot L_\infty$. Тогда:

- PGD: $\mathcal{O}\left(\frac{nL_\infty}{k}\right)$
- MD: $\mathcal{O}\left(\frac{L_\infty \ln n}{k}\right)$

Выигрыш: $\frac{n}{\ln n}$ раз!

Параметр	PGD	MD (EG)
Гладкость	$L_2 = \ A^\top A\ _{\text{op}}$	$L_\infty = \max_{ij} A^\top A _{ij}$
«Радиус»	$R_2^2 \leq 2$	$R^2 \leq \ln n$
Оценка	$\frac{L_2}{k}$	$\frac{L_\infty \ln n}{k}$

Пример: зеркальный спуск vs PGD на симплексе

Рассмотрим задачу

$$\min_{x \in \Delta_n} f(x) = \frac{1}{2} \|Ax - b\|_2^2$$

- PGD: евклидова проекция на Δ_n , $\mathcal{O}(n \log n)$ на шаг
- MD (EG): мультипликативное обновление, $\mathcal{O}(n)$ на шаг

Когда A имеет слабую корреляцию между столбцами:

$L_2 \approx n \cdot L_\infty$. Тогда:

- PGD: $\mathcal{O}\left(\frac{nL_\infty}{k}\right)$
- MD: $\mathcal{O}\left(\frac{L_\infty \ln n}{k}\right)$

Выигрыш: $\frac{n}{\ln n}$ раз!

Для $n = 1000$: выигрыш ≈ 145 раз.




Для $n = 10^6$: выигрыш $\approx 72\,400$ раз.

Параметр	PGD	MD (EG)
Гладкость	$L_2 = \ A^\top A\ _{\text{op}}$	$L_\infty = \max_{ij} A^\top A _{ij}$
«Радиус»	$R_2^2 \leq 2$	$R^2 \leq \ln n$
Оценка	$\frac{L_2}{k}$	$\frac{L_\infty \ln n}{k}$

Негладкая задача: MD побеждает по итерациям

Задача Бека: $\min_{x \in \Delta_n} \|Ax - b\|_1$ — негладкая оптимизация на симплексе

$\min \|Ax - b\|_1$ на Δ_n : по итерациям с теорией




- Субградиент $g = A^\top \text{sign}(Ax - b)$: $\|g\|_2$ растёт с $\sqrt{n}$, а $\|g\|_\infty$ остаётся ограниченным

Негладкая задача: MD побеждает по итерациям


Задача Бека: $\min_{x \in \Delta_n} \|Ax - b\|_1$ — негладкая оптимизация на симплексе

$\min \|Ax - b\|_1$ на Δ_n : по итерациям с теорией


$n = 100, m = 50$
 $\|g\|_2 / \|g\|_\infty = 3.3$



$n = 500, m = 200$
 $\|g\|_2 / \|g\|_\infty = 4.6$






$n = 2000, m = 500$
 $\|g\|_2 / \|g\|_\infty = 5.1$



- Субградиент $g = A^\top \text{sign}(Ax - b)$: $\|g\|_2$ растёт с $\sqrt{n}$, а $\|g\|_\infty$ остаётся ограниченным
- **Зеркальный спуск** использует ℓ_∞ -геометрию и побеждает в $\sim \sqrt{n / \ln n}$ раз!

Негладкая задача: честное сравнение по времени




$\min \|Ax - b\|_1$ на Δ_n : по времени



- MD побеждает **и по времени**: стоимость итерации сравнима ($O(n)$ vs $O(n \log n)$), но MD сходится существенно быстрее



Негладкая задача: честное сравнение по времени

$\min \|Ax - b\|_1$ на Δ_n : по времени





- MD побеждает **и по времени**: стоимость итерации сравнима ($O(n)$ vs $O(n \log n)$), но MD сходится существенно быстрее
- Преимущество растёт с размерностью: для $n = 2000$ субградиентный метод за то же время далеко от оптимума

Масштабирование преимущества MD





- При росте n невязка субградиентного метода растёт, а MD остаётся малой

Масштабирование преимущества MD




- При росте n невязка субградиентного метода **растёт**, а MD остаётся малой
- Число итераций до ε -точности: MD требует меньше при любом n

Масштабирование преимущества MD




- При росте n невязка субградиентного метода **растёт**, а MD остаётся малой
- Число итераций до ε -точности: MD требует меньше при любом n

Масштабирование преимущества MD




- При росте n невязка субградиентного метода **растёт**, а MD остаётся малой
- Число итераций до ε -точности: MD требует меньше при любом n




- Стоимость шага MD — $\mathcal{O}(n)$, дешевле PGD — $\mathcal{O}(n \log n)$

Масштабирование преимущества MD



- При росте n невязка субградиентного метода **растёт**, а MD остаётся малой
- Число итераций до ε -точности: MD требует меньше при любом n






- Стоимость шага MD — $\mathcal{O}(n)$, дешевле PGD — $\mathcal{O}(n \log n)$
- MD и FW имеют одинаковую асимптотику $\mathcal{O}(n)$

KL-дивергенция: относительная гладкость

$f(x) = \sum_{i=1}^m \text{KL}(A_i x \| b_i)$ на Δ_n — задача с неограниченной L_2 -гладкостью, но **ограниченной** относительной гладкостью по Брэгману!

$f(x) = \sum \text{KL}(A_i x \| b_i)$ на Δ_n : относительная гладкость






- Константа $L_h = \max_k \sum_{i,j} (A_i)_{jk}$ вычислима из данных задачи; MD шаг $\eta = 1/L_h$ — теория гарантирует $O(1/k)$

KL-дивергенция: относительная гладкость

$f(x) = \sum_{i=1}^m \text{KL}(A_i x \| b_i)$ на Δ_n — задача с неограниченной L_2 -гладкостью, но **ограниченной** относительной гладкостью по Брэгману!

$f(x) = \sum \text{KL}(A_i x \| b_i)$ на Δ_n : относительная гладкость






- Константа $L_h = \max_k \sum_{i,j} (A_i)_{jk}$ вычислима из данных задачи; MD шаг $\eta = 1/L_h$ — теория гарантирует $O(1/k)$
- L_2 константа Липшица в **175 раз** больше $L_h \rightarrow$ шаг PGD $\alpha = 1/L_2$ сверхконсервативен; Armijo — медленнее по времени

KL-дивергенция: относительная гладкость

$f(x) = \sum_{i=1}^m \text{KL}(A_i x \| b_i)$ на Δ_n — задача с неограниченной L_2 -гладкостью, но **ограниченной** относительной гладкостью по Брэгману!

$$f(x) = \sum \text{KL}(A_i x \| b_i) \text{ на } \Delta_n: \text{относительная гладкость}$$



- Константа $L_h = \max_k \sum_{i,j} (A_i)_{jk}$ вычислима из данных задачи; MD шаг $\eta = 1/L_h$ — теория гарантирует $O(1/k)$
- L_2 константа Липшица в **175 раз** больше $L_h \rightarrow$ шаг PGD $\alpha = 1/L_2$ сверхконсервативен; Armijo — медленнее по времени
- Правый график: L_h vs $L_2(x_k)$ — **почему** неевклидова геометрия выигрывает

Итоги: зеркальный спуск

- **Обобщение PGD:** заменяем евклидову проекцию дивергенцией Брэгмана, адаптируя геометрию метода к задаче.

Итоги: зеркальный спуск

- **Обобщение PGD:** заменяем евклидову проекцию дивергенцией Брэгмана, адаптируя геометрию метода к задаче.
- **Скорость сходимости:** $\mathcal{O}\left(\frac{LR^2}{\sigma k}\right)$ — та же структура, что у PGD, но с параметрами, адаптированными к «правильной» норме.

Итоги: зеркальный спуск

- **Обобщение PGD:** заменяем евклидову проекцию дивергенцией Брэгмана, адаптируя геометрию метода к задаче.
- **Скорость сходимости:** $\mathcal{O}\left(\frac{LR^2}{\sigma k}\right)$ — та же структура, что у PGD, но с параметрами, адаптированными к «правильной» норме.
- **Когда выигрывает:**

Итоги: зеркальный спуск

- **Обобщение PGD:** заменяем евклидову проекцию дивергенцией Брэгмана, адаптируя геометрию метода к задаче.
- **Скорость сходимости:** $\mathcal{O}\left(\frac{LR^2}{\sigma k}\right)$ — та же структура, что у PGD, но с параметрами, адаптированными к «правильной» норме.
- **Когда выигрывает:**
 - **Негладкие задачи на симплексе:** $\min \|Ax - b\|_1$ — выигрыш в $\sim \sqrt{n/\ln n}$ раз (и по итерациям, и по времени!)

Итоги: зеркальный спуск

- **Обобщение PGD:** заменяем евклидову проекцию дивергенцией Брэгмана, адаптируя геометрию метода к задаче.
- **Скорость сходимости:** $\mathcal{O}\left(\frac{LR^2}{\sigma k}\right)$ — та же структура, что у PGD, но с параметрами, адаптированными к «правильной» норме.
- **Когда выигрывает:**
 - **Негладкие задачи на симплексе:** $\min \|Ax - b\|_1$ — выигрыш в $\sim \sqrt{n/\ln n}$ раз (и по итерациям, и по времени!)
 - **KL-дивергенция** и задачи с **относительной гладкостью:** L_2 неограничена, но MD сходится с фиксированным шагом

Итоги: зеркальный спуск

- **Обобщение PGD:** заменяем евклидову проекцию дивергенцией Брэгмана, адаптируя геометрию метода к задаче.
- **Скорость сходимости:** $\mathcal{O}\left(\frac{LR^2}{\sigma^k}\right)$ — та же структура, что у PGD, но с параметрами, адаптированными к «правильной» норме.
- **Когда выигрывает:**
 - **Негладкие** задачи на симплексе: $\min \|Ax - b\|_1$ — выигрыш в $\sim \sqrt{n/\ln n}$ раз (и по итерациям, и по времени!)
 - **KL-дивергенция** и задачи с **относительной гладкостью**: L_2 неограничена, но MD сходится с фиксированным шагом
 - Задачи, где $\|g\|_2 \gg \|g\|_\infty$; высокоразмерные задачи, где ℓ_2 -оценки зависят от n

Итоги: зеркальный спуск

- **Обобщение PGD:** заменяем евклидову проекцию дивергенцией Брэгмана, адаптируя геометрию метода к задаче.
- **Скорость сходимости:** $\mathcal{O}\left(\frac{LR^2}{\sigma k}\right)$ — та же структура, что у PGD, но с параметрами, адаптированными к «правильной» норме.
- **Когда выигрывает:**
 - **Негладкие задачи на симплексе:** $\min \|Ax - b\|_1$ — выигрыш в $\sim \sqrt{n/\ln n}$ раз (и по итерациям, и по времени!)
 - **KL-дивергенция** и задачи с **относительной гладкостью:** L_2 неограничена, но MD сходится с фиксированным шагом
 - Задачи, где $\|g\|_2 \gg \|g\|_\infty$; высокоразмерные задачи, где ℓ_2 -оценки зависят от n
- **Ключевой результат на симплексе:** с прокс-функцией $\omega(x) = \sum_i x_i \ln x_i$ зеркальный спуск даёт оценку $\mathcal{O}\left(\frac{L_\infty \ln n}{k}\right)$ вместо $\mathcal{O}\left(\frac{nL_\infty}{k}\right)$ у PGD — экспоненциальный выигрыш по размерности.

Итоги: зеркальный спуск

- **Обобщение PGD:** заменяем евклидову проекцию дивергенцией Брэгмана, адаптируя геометрию метода к задаче.
- **Скорость сходимости:** $\mathcal{O}\left(\frac{LR^2}{\sigma k}\right)$ — та же структура, что у PGD, но с параметрами, адаптированными к «правильной» норме.
- **Когда выигрывает:**
 - **Негладкие задачи на симплексе:** $\min \|Ax - b\|_1$ — выигрыш в $\sim \sqrt{n/\ln n}$ раз (и по итерациям, и по времени!)
 - **KL-дивергенция** и задачи с **относительной гладкостью:** L_2 неограничена, но MD сходится с фиксированным шагом
 - Задачи, где $\|g\|_2 \gg \|g\|_\infty$; высокоразмерные задачи, где ℓ_2 -оценки зависят от n
- **Ключевой результат на симплексе:** с прокс-функцией $\omega(x) = \sum_i x_i \ln x_i$ зеркальный спуск даёт оценку $\mathcal{O}\left(\frac{L_\infty \ln n}{k}\right)$ вместо $\mathcal{O}\left(\frac{nL_\infty}{k}\right)$ у PGD — экспоненциальный выигрыш по размерности.
- Выбор прокс-функции ω — ключевое решение при применении метода. Общее правило: ω должна быть сильно выпуклой относительно нормы, в которой f является гладкой.