

A low-poly, geometric illustration of a cat and a duck. The cat is on the left, rendered in shades of orange, yellow, and white. The duck is on the right, rendered in shades of yellow and orange. Both are composed of many flat, triangular faces. A semi-transparent white box with a rounded top and a small orange tab on the right side is centered over the cat's face.

**Негладкая выпуклая оптимизация. Нижние
оценки. Субградиентный метод.**

Даниил Меркулов


Методы оптимизации. МФТИ

Негладкие задачи

Линейный МНК с ℓ_1 -регуляризацией

ℓ_1 induces sparsity

ℓ_2 regularization. $\|Xw - y\|_2^2 \rightarrow \min_{\|w\|_2 \leq 1}$



ℓ_1 regularization. $\|Xw - y\|_2^2 \rightarrow \min_{\|w\|_1 \leq 1}$




@fminxyz

Нормы не являются гладкими


$$\min_{x \in \mathbb{R}^n} f(x),$$

Рассмотрим классическую задачу выпуклой оптимизации. Предположим, что $f(x)$ выпукла, но теперь мы не требуем гладкости.

$p = 1$ Norm Cone



$p = 2$ Norm Cone



$p = \infty$ Norm Cone




Рис. 1: Конусы норм для разных p : нормы негладкие

Пример Вульфа

Wolfe's example





Рис. 2: Пример Вульфа. [Открыть в Colab](#)

Субградиентное исчисление

Линейная нижняя оценка выпуклой функции




Важное свойство непрерывной выпуклой функции $f(x)$ состоит в том, что в любой выбранной точке x_0 для всех $x \in \text{dom } f$ выполняется неравенство:

$$f(x) \geq f(x_0) + \langle g, x - x_0 \rangle$$

Рис. 3: Линейная аппроксимация по Тейлору является глобальной нижней оценкой выпуклой функции

Линейная нижняя оценка выпуклой функции



Важное свойство непрерывной выпуклой функции $f(x)$ состоит в том, что в любой выбранной точке x_0 для всех $x \in \text{dom } f$ выполняется неравенство:


$$f(x) \geq f(x_0) + \langle g, x - x_0 \rangle$$

для некоторого вектора g , то есть касательная к графику функции даёт глобальную нижнюю оценку функции.

- Если $f(x)$ дифференцируема, то $g = \nabla f(x_0)$

Рис. 3: Линейная аппроксимация по Тейлору является глобальной нижней оценкой выпуклой функции

Линейная нижняя оценка выпуклой функции



Важное свойство непрерывной выпуклой функции $f(x)$ состоит в том, что в любой выбранной точке x_0 для всех $x \in \text{dom } f$ выполняется неравенство:


$$f(x) \geq f(x_0) + \langle g, x - x_0 \rangle$$

для некоторого вектора g , то есть касательная к графику функции даёт глобальную нижнюю оценку функции.

- Если $f(x)$ дифференцируема, то $g = \nabla f(x_0)$
- Не всякая непрерывная выпуклая функция дифференцируема.

Рис. 3: Линейная аппроксимация по Тейлору является глобальной нижней оценкой выпуклой функции

Линейная нижняя оценка выпуклой функции



Важное свойство непрерывной выпуклой функции $f(x)$ состоит в том, что в любой выбранной точке x_0 для всех $x \in \text{dom } f$ выполняется неравенство:


$$f(x) \geq f(x_0) + \langle g, x - x_0 \rangle$$

для некоторого вектора g , то есть касательная к графику функции даёт глобальную нижнюю оценку функции.

- Если $f(x)$ дифференцируема, то $g = \nabla f(x_0)$
- Не всякая непрерывная выпуклая функция дифференцируема.

Рис. 3: Линейная аппроксимация по Тейлору является глобальной нижней оценкой выпуклой функции

Линейная нижняя оценка выпуклой функции



Важное свойство непрерывной выпуклой функции $f(x)$ состоит в том, что в любой выбранной точке x_0 для всех $x \in \text{dom } f$ выполняется неравенство:

$$f(x) \geq f(x_0) + \langle g, x - x_0 \rangle$$

для некоторого вектора g , то есть касательная к графику функции даёт глобальную нижнюю оценку функции.

- Если $f(x)$ дифференцируема, то $g = \nabla f(x_0)$
- Не всякая непрерывная выпуклая функция дифференцируема.

Нам не хочется терять это прекрасное свойство.

Рис. 3: Линейная аппроксимация по Тейлору является глобальной нижней оценкой выпуклой функции

Субградиент и субдифференциал

Вектор g называется **субградиентом** функции $f(x) : S \rightarrow \mathbb{R}$ в точке x_0 , если $\forall x \in S$:

$$f(x) \geq f(x_0) + \langle g, x - x_0 \rangle$$

Субградиент и субдифференциал

Вектор g называется **субградиентом** функции $f(x) : S \rightarrow \mathbb{R}$ в точке x_0 , если $\forall x \in S$:

$$f(x) \geq f(x_0) + \langle g, x - x_0 \rangle$$

Множество всех субградиентов функции $f(x)$ в точке x_0 называется **субдифференциалом** f в точке x_0 и обозначается $\partial f(x_0)$.

Субградиент и субдифференциал

Вектор g называется **субградиентом** функции $f(x) : S \rightarrow \mathbb{R}$ в точке x_0 , если $\forall x \in S$:

$$f(x) \geq f(x_0) + \langle g, x - x_0 \rangle$$

Множество всех субградиентов функции $f(x)$ в точке x_0 называется **субдифференциалом** f в точке x_0 и обозначается $\partial f(x_0)$.




Рис. 4: Субдифференциал — множество всех возможных субградиентов


Субградиент и субдифференциал

Найдите $\partial f(x)$, если $f(x) = |x|$


Субградиент и субдифференциал

Найдите $\partial f(x)$, если $f(x) = |x|$

$$f(x) = |x|$$



$$\partial f(x)$$



Свойства субдифференциала

- Если $x_0 \in \text{ri}(S)$, то $\partial f(x_0)$ — выпуклое компактное множество.

Свойства субдифференциала

- Если $x_0 \in \text{ri}(S)$, то $\partial f(x_0)$ — выпуклое компактное множество.
- Если выпуклая функция $f(x)$ дифференцируема в точке x_0 , то $\partial f(x_0) = \{\nabla f(x_0)\}$.

Свойства субдифференциала

- Если $x_0 \in \text{ri}(S)$, то $\partial f(x_0)$ — выпуклое компактное множество.
- Если выпуклая функция $f(x)$ дифференцируема в точке x_0 , то $\partial f(x_0) = \{\nabla f(x_0)\}$.
- Если $\partial f(x_0) \neq \emptyset \quad \forall x_0 \in S$, то $f(x)$ выпукла на S .

Свойства субдифференциала

- Если $x_0 \in \text{ri}(S)$, то $\partial f(x_0)$ — выпуклое компактное множество.
- Если выпуклая функция $f(x)$ дифференцируема в точке x_0 , то $\partial f(x_0) = \{\nabla f(x_0)\}$.
- Если $\partial f(x_0) \neq \emptyset \quad \forall x_0 \in S$, то $f(x)$ выпукла на S .

Свойства субдифференциала

- Если $x_0 \in \text{ri}(S)$, то $\partial f(x_0)$ — выпуклое компактное множество.
- Если выпуклая функция $f(x)$ дифференцируема в точке x_0 , то $\partial f(x_0) = \{\nabla f(x_0)\}$.
- Если $\partial f(x_0) \neq \emptyset \quad \forall x_0 \in S$, то $f(x)$ выпукла на S .

i Субдифференциал дифференцируемой функции

Пусть $f : S \rightarrow \mathbb{R}$, $x_0 \in \text{ri}(S)$. Если f дифференцируема в точке x_0 , то либо $\partial f(x_0) = \emptyset$, либо $\partial f(x_0) = \{\nabla f(x_0)\}$. Если f выпукла, то $\partial f(x_0) = \{\nabla f(x_0)\}$.

Свойства субдифференциала (доказательство)

1. Пусть $s \in \partial f(x_0)$ и v — единичный вектор. Для достаточно малых $t > 0$ выполняется

$$f(x_0 + tv) \geq f(x_0) + t\langle s, v \rangle.$$

Делим на t и переходим к пределу при $t \rightarrow 0^+$:

$$\langle \nabla f(x_0), v \rangle \geq \langle s, v \rangle.$$

Свойства субдифференциала (доказательство)

1. Пусть $s \in \partial f(x_0)$ и v — единичный вектор. Для достаточно малых $t > 0$ выполняется

$$f(x_0 + tv) \geq f(x_0) + t\langle s, v \rangle.$$

Делим на t и переходим к пределу при $t \rightarrow 0^+$:

$$\langle \nabla f(x_0), v \rangle \geq \langle s, v \rangle.$$

Свойства субдифференциала (доказательство)

1. Пусть $s \in \partial f(x_0)$ и v — единичный вектор. Для достаточно малых $t > 0$ выполняется

$$f(x_0 + tv) \geq f(x_0) + t\langle s, v \rangle.$$

Делим на t и переходим к пределу при $t \rightarrow 0^+$:

$$\langle \nabla f(x_0), v \rangle \geq \langle s, v \rangle.$$

2. Значит $\langle \nabla f(x_0) - s, v \rangle \geq 0$ для всех единичных v ; берём

$$v = -\frac{\nabla f(x_0) - s}{\|\nabla f(x_0) - s\|}$$

и получаем $s = \nabla f(x_0)$.

Свойства субдифференциала (доказательство)

1. Пусть $s \in \partial f(x_0)$ и v — единичный вектор. Для достаточно малых $t > 0$ выполняется

$$f(x_0 + tv) \geq f(x_0) + t\langle s, v \rangle.$$

Делим на t и переходим к пределу при $t \rightarrow 0^+$:

$$\langle \nabla f(x_0), v \rangle \geq \langle s, v \rangle.$$

2. Значит $\langle \nabla f(x_0) - s, v \rangle \geq 0$ для всех единичных v ; берём

$$v = -\frac{\nabla f(x_0) - s}{\|\nabla f(x_0) - s\|}$$

и получаем $s = \nabla f(x_0)$.

Свойства субдифференциала (доказательство)

1. Пусть $s \in \partial f(x_0)$ и v — единичный вектор. Для достаточно малых $t > 0$ выполняется

$$f(x_0 + tv) \geq f(x_0) + t\langle s, v \rangle.$$

Делим на t и переходим к пределу при $t \rightarrow 0^+$:

$$\langle \nabla f(x_0), v \rangle \geq \langle s, v \rangle.$$

2. Значит $\langle \nabla f(x_0) - s, v \rangle \geq 0$ для всех единичных v ; берём

$$v = -\frac{\nabla f(x_0) - s}{\|\nabla f(x_0) - s\|}$$

и получаем $s = \nabla f(x_0)$.

3. Если f выпукла, то $f(x) \geq f(x_0) + \langle \nabla f(x_0), x - x_0 \rangle$ для всех $x \in S$, то есть $\nabla f(x_0) \in \partial f(x_0)$ и $\partial f(x_0) = \{\nabla f(x_0)\}$.

Вычисление субдифференциалов

i Теорема Моро — Рокафеллара
(субдифференциал линейной комбинации)

Пусть $f_i(x)$ — выпуклые функции на выпуклых множествах S_i , $i = \overline{1, n}$. Тогда если $\bigcap_{i=1}^n \text{ri}(S_i) \neq$

$\emptyset$, то функция $f(x) = \sum_{i=1}^n a_i f_i(x)$, $a_i > 0$

имеет субдифференциал $\partial_S f(x)$ на множестве $S = \bigcap_{i=1}^n S_i$, причём

$$\partial_S f(x) = \sum_{i=1}^n a_i \partial_{S_i} f_i(x)$$

Вычисление субдифференциалов

i Теорема Моро — Рокафеллара
(субдифференциал линейной комбинации)

Пусть $f_i(x)$ — выпуклые функции на выпуклых множествах S_i , $i = \overline{1, n}$. Тогда если $\bigcap_{i=1}^n \text{ri}(S_i) \neq \emptyset$, то функция $f(x) = \sum_{i=1}^n a_i f_i(x)$, $a_i > 0$ имеет субдифференциал $\partial_S f(x)$ на множестве $S = \bigcap_{i=1}^n S_i$, причём

$$\partial_S f(x) = \sum_{i=1}^n a_i \partial_{S_i} f_i(x)$$

i Теорема Дубовицкого — Милютина
(субдифференциал поточечного максимума)

Пусть $f_i(x)$ — выпуклые функции на открытом выпуклом множестве $S \subseteq \mathbb{R}^n$, $x_0 \in S$, и поточечный максимум задан как $f(x) = \max_i f_i(x)$. Тогда:

$$\partial_S f(x_0) = \text{conv} \left\{ \bigcup_{i \in I(x_0)} \partial_S f_i(x_0) \right\}, \quad I(x) = \{i \in [1, n] \mid f_i(x) = f(x)\}$$

Вычисление субдифференциалов

- $\partial(\alpha f)(x) = \alpha \partial f(x)$, для $\alpha \geq 0$

Вычисление субдифференциалов

- $\partial(\alpha f)(x) = \alpha \partial f(x)$, для $\alpha \geq 0$
- $\partial(\sum f_i)(x) = \sum \partial f_i(x)$, f_i — выпуклые функции

Вычисление субдифференциалов

- $\partial(\alpha f)(x) = \alpha \partial f(x)$, для $\alpha \geq 0$
- $\partial(\sum f_i)(x) = \sum \partial f_i(x)$, f_i — выпуклые функции
- $\partial(f(Ax + b))(x) = A^T \partial f(Ax + b)$, f — выпуклая функция

Вычисление субдифференциалов

- $\partial(\alpha f)(x) = \alpha \partial f(x)$, для $\alpha \geq 0$
- $\partial(\sum f_i)(x) = \sum \partial f_i(x)$, f_i — выпуклые функции
- $\partial(f(Ax + b))(x) = A^T \partial f(Ax + b)$, f — выпуклая функция
- $z \in \partial f(x)$ тогда и только тогда, когда $x \in \partial f^*(z)$.

Субградиентный метод

Алгоритм

Вектор g называется **субградиентом** функции $f(x) : S \rightarrow \mathbb{R}$ в точке x_0 , если $\forall x \in S$:

$$f(x) \geq f(x_0) + \langle g, x - x_0 \rangle$$

Алгоритм

Вектор g называется **субградиентом** функции $f(x) : S \rightarrow \mathbb{R}$ в точке x_0 , если $\forall x \in S$:

$$f(x) \geq f(x_0) + \langle g, x - x_0 \rangle$$

Идея очень простая: заменим градиент $\nabla f(x_k)$ в алгоритме градиентного спуска на субградиент g_k в точке x_k :

$$x_{k+1} = x_k - \alpha_k g_k,$$

где g_k — произвольный субградиент функции $f(x)$ в точке x_k , $g_k \in \partial f(x_k)$

Алгоритм

Вектор g называется **субградиентом** функции $f(x) : S \rightarrow \mathbb{R}$ в точке x_0 , если $\forall x \in S$:

$$f(x) \geq f(x_0) + \langle g, x - x_0 \rangle$$

Идея очень простая: заменим градиент $\nabla f(x_k)$ в алгоритме градиентного спуска на субградиент g_k в точке x_k :

$$x_{k+1} = x_k - \alpha_k g_k,$$

где g_k — произвольный субградиент функции $f(x)$ в точке x_k , $g_k \in \partial f(x_k)$

Заметим, что **субградиентный метод не обязан быть методом спуска**: отрицательный субградиент может не быть направлением спуска, а выбор шага может привести к $f(x_{k+1}) > f(x_k)$.

Поэтому обычно отслеживают лучшее достигнутое значение целевой функции

$$f_k^{\text{best}} = \min_{i=1, \dots, k} f(x_i).$$

Оценка сходимости

$$\|x_{k+1} - x^*\|^2 = \|x_k - x^* - \alpha_k g_k\|^2 =$$

Оценка сходимости

$$\begin{aligned}\|x_{k+1} - x^*\|^2 &= \|x_k - x^* - \alpha_k g_k\|^2 = \\ &= \|x_k - x^*\|^2 + \alpha_k^2 \|g_k\|^2 - 2\alpha_k \langle g_k, x_k - x^* \rangle\end{aligned}$$

Оценка сходимости

$$\begin{aligned}\|x_{k+1} - x^*\|^2 &= \|x_k - x^* - \alpha_k g_k\|^2 = \\ &= \|x_k - x^*\|^2 + \alpha_k^2 \|g_k\|^2 - 2\alpha_k \langle g_k, x_k - x^* \rangle \\ &\leq \|x_k - x^*\|^2 + \alpha_k^2 \|g_k\|^2 - 2\alpha_k (f(x_k) - f(x^*))\end{aligned}$$

Оценка сходимости

$$\begin{aligned}\|x_{k+1} - x^*\|^2 &= \|x_k - x^* - \alpha_k g_k\|^2 = \\ &= \|x_k - x^*\|^2 + \alpha_k^2 \|g_k\|^2 - 2\alpha_k \langle g_k, x_k - x^* \rangle \\ &\leq \|x_k - x^*\|^2 + \alpha_k^2 \|g_k\|^2 - 2\alpha_k (f(x_k) - f(x^*))\end{aligned}$$

$$2\alpha_k (f(x_k) - f(x^*)) \leq \|x_k - x^*\|^2 - \|x_{k+1} - x^*\|^2 + \alpha_k^2 \|g_k\|^2$$

Оценка сходимости

$$\begin{aligned}\|x_{k+1} - x^*\|^2 &= \|x_k - x^* - \alpha_k g_k\|^2 = \\ &= \|x_k - x^*\|^2 + \alpha_k^2 \|g_k\|^2 - 2\alpha_k \langle g_k, x_k - x^* \rangle \\ &\leq \|x_k - x^*\|^2 + \alpha_k^2 \|g_k\|^2 - 2\alpha_k (f(x_k) - f(x^*))\end{aligned}$$

$$2\alpha_k (f(x_k) - f(x^*)) \leq \|x_k - x^*\|^2 - \|x_{k+1} - x^*\|^2 + \alpha_k^2 \|g_k\|^2$$

Оценка сходимости

$$\begin{aligned}\|x_{k+1} - x^*\|^2 &= \|x_k - x^* - \alpha_k g_k\|^2 = \\ &= \|x_k - x^*\|^2 + \alpha_k^2 \|g_k\|^2 - 2\alpha_k \langle g_k, x_k - x^* \rangle \\ &\leq \|x_k - x^*\|^2 + \alpha_k^2 \|g_k\|^2 - 2\alpha_k (f(x_k) - f(x^*))\end{aligned}$$

$$2\alpha_k (f(x_k) - f(x^*)) \leq \|x_k - x^*\|^2 - \|x_{k+1} - x^*\|^2 + \alpha_k^2 \|g_k\|^2$$

Просуммируем полученное неравенство по $k = 0, \dots, T-1$:

$$\sum_{k=0}^{T-1} 2\alpha_k (f(x_k) - f(x^*)) \leq \|x_0 - x^*\|^2 - \|x_T - x^*\|^2 + \sum_{k=0}^{T-1} \alpha_k^2 \|g_k\|^2$$

Оценка сходимости

$$\begin{aligned}\|x_{k+1} - x^*\|^2 &= \|x_k - x^* - \alpha_k g_k\|^2 = \\ &= \|x_k - x^*\|^2 + \alpha_k^2 \|g_k\|^2 - 2\alpha_k \langle g_k, x_k - x^* \rangle \\ &\leq \|x_k - x^*\|^2 + \alpha_k^2 \|g_k\|^2 - 2\alpha_k (f(x_k) - f(x^*))\end{aligned}$$

$$2\alpha_k (f(x_k) - f(x^*)) \leq \|x_k - x^*\|^2 - \|x_{k+1} - x^*\|^2 + \alpha_k^2 \|g_k\|^2$$

Просуммируем полученное неравенство по $k = 0, \dots, T-1$:

$$\begin{aligned}\sum_{k=0}^{T-1} 2\alpha_k (f(x_k) - f(x^*)) &\leq \|x_0 - x^*\|^2 - \|x_T - x^*\|^2 + \sum_{k=0}^{T-1} \alpha_k^2 \|g_k\|^2 \\ &\leq \|x_0 - x^*\|^2 + \sum_{k=0}^{T-1} \alpha_k^2 \|g_k\|^2\end{aligned}$$

Оценка сходимости

$$\begin{aligned}\|x_{k+1} - x^*\|^2 &= \|x_k - x^* - \alpha_k g_k\|^2 = \\ &= \|x_k - x^*\|^2 + \alpha_k^2 \|g_k\|^2 - 2\alpha_k \langle g_k, x_k - x^* \rangle \\ &\leq \|x_k - x^*\|^2 + \alpha_k^2 \|g_k\|^2 - 2\alpha_k (f(x_k) - f(x^*))\end{aligned}$$

$$2\alpha_k (f(x_k) - f(x^*)) \leq \|x_k - x^*\|^2 - \|x_{k+1} - x^*\|^2 + \alpha_k^2 \|g_k\|^2$$

Просуммируем полученное неравенство по $k = 0, \dots, T-1$:

$$\begin{aligned}\sum_{k=0}^{T-1} 2\alpha_k (f(x_k) - f(x^*)) &\leq \|x_0 - x^*\|^2 - \|x_T - x^*\|^2 + \sum_{k=0}^{T-1} \alpha_k^2 \|g_k\|^2 \\ &\leq \|x_0 - x^*\|^2 + \sum_{k=0}^{T-1} \alpha_k^2 \|g_k\|^2 \\ &\leq R^2 + G^2 \sum_{k=0}^{T-1} \alpha_k^2\end{aligned}$$

Оценка сходимости

$$\begin{aligned}\|x_{k+1} - x^*\|^2 &= \|x_k - x^* - \alpha_k g_k\|^2 = \\ &= \|x_k - x^*\|^2 + \alpha_k^2 \|g_k\|^2 - 2\alpha_k \langle g_k, x_k - x^* \rangle \\ &\leq \|x_k - x^*\|^2 + \alpha_k^2 \|g_k\|^2 - 2\alpha_k (f(x_k) - f(x^*))\end{aligned}$$

$$2\alpha_k (f(x_k) - f(x^*)) \leq \|x_k - x^*\|^2 - \|x_{k+1} - x^*\|^2 + \alpha_k^2 \|g_k\|^2$$

Просуммируем полученное неравенство по $k = 0, \dots, T-1$:

$$\begin{aligned}\sum_{k=0}^{T-1} 2\alpha_k (f(x_k) - f(x^*)) &\leq \|x_0 - x^*\|^2 - \|x_T - x^*\|^2 + \sum_{k=0}^{T-1} \alpha_k^2 \|g_k\|^2 \\ &\leq \|x_0 - x^*\|^2 + \sum_{k=0}^{T-1} \alpha_k^2 \|g_k\|^2 \\ &\leq R^2 + G^2 \sum_{k=0}^{T-1} \alpha_k^2\end{aligned}$$

- Запишем, насколько близко мы подошли к оптимуму $x^* = \arg \min_{x \in \mathbb{R}^n} f(x) = \arg f^*$ на последней итерации:

Оценка сходимости

$$\begin{aligned}\|x_{k+1} - x^*\|^2 &= \|x_k - x^* - \alpha_k g_k\|^2 = \\ &= \|x_k - x^*\|^2 + \alpha_k^2 \|g_k\|^2 - 2\alpha_k \langle g_k, x_k - x^* \rangle \\ &\leq \|x_k - x^*\|^2 + \alpha_k^2 \|g_k\|^2 - 2\alpha_k (f(x_k) - f(x^*))\end{aligned}$$

$$2\alpha_k (f(x_k) - f(x^*)) \leq \|x_k - x^*\|^2 - \|x_{k+1} - x^*\|^2 + \alpha_k^2 \|g_k\|^2$$

Просуммируем полученное неравенство по $k = 0, \dots, T-1$:

$$\begin{aligned}\sum_{k=0}^{T-1} 2\alpha_k (f(x_k) - f(x^*)) &\leq \|x_0 - x^*\|^2 - \|x_T - x^*\|^2 + \sum_{k=0}^{T-1} \alpha_k^2 \|g_k\|^2 \\ &\leq \|x_0 - x^*\|^2 + \sum_{k=0}^{T-1} \alpha_k^2 \|g_k\|^2 \\ &\leq R^2 + G^2 \sum_{k=0}^{T-1} \alpha_k^2\end{aligned}$$

- Запишем, насколько близко мы подошли к оптимуму $x^* = \arg \min_{x \in \mathbb{R}^n} f(x) = \arg f^*$ на последней итерации:
- Для субградиента: $\langle g_k, x^* - x_k \rangle \leq f(x^*) - f(x_k)$.

Оценка сходимости

$$\begin{aligned}\|x_{k+1} - x^*\|^2 &= \|x_k - x^* - \alpha_k g_k\|^2 = \\ &= \|x_k - x^*\|^2 + \alpha_k^2 \|g_k\|^2 - 2\alpha_k \langle g_k, x_k - x^* \rangle \\ &\leq \|x_k - x^*\|^2 + \alpha_k^2 \|g_k\|^2 - 2\alpha_k (f(x_k) - f(x^*))\end{aligned}$$

$$2\alpha_k (f(x_k) - f(x^*)) \leq \|x_k - x^*\|^2 - \|x_{k+1} - x^*\|^2 + \alpha_k^2 \|g_k\|^2$$

Просуммируем полученное неравенство по $k = 0, \dots, T-1$:

$$\begin{aligned}\sum_{k=0}^{T-1} 2\alpha_k (f(x_k) - f(x^*)) &\leq \|x_0 - x^*\|^2 - \|x_T - x^*\|^2 + \sum_{k=0}^{T-1} \alpha_k^2 \|g_k\|^2 \\ &\leq \|x_0 - x^*\|^2 + \sum_{k=0}^{T-1} \alpha_k^2 \|g_k\|^2 \\ &\leq R^2 + G^2 \sum_{k=0}^{T-1} \alpha_k^2\end{aligned}$$

- Запишем, насколько близко мы подошли к оптимуму $x^* = \arg \min_{x \in \mathbb{R}^n} f(x) = \arg f^*$ на последней итерации:
- Для субградиента: $\langle g_k, x^* - x_k \rangle \leq f(x^*) - f(x_k)$.
- Дополнительно предположим, что $\|g_k\|^2 \leq G^2$

Оценка сходимости

$$\begin{aligned}\|x_{k+1} - x^*\|^2 &= \|x_k - x^* - \alpha_k g_k\|^2 = \\ &= \|x_k - x^*\|^2 + \alpha_k^2 \|g_k\|^2 - 2\alpha_k \langle g_k, x_k - x^* \rangle \\ &\leq \|x_k - x^*\|^2 + \alpha_k^2 \|g_k\|^2 - 2\alpha_k (f(x_k) - f(x^*))\end{aligned}$$

$$2\alpha_k (f(x_k) - f(x^*)) \leq \|x_k - x^*\|^2 - \|x_{k+1} - x^*\|^2 + \alpha_k^2 \|g_k\|^2$$

Просуммируем полученное неравенство по $k = 0, \dots, T-1$:

$$\begin{aligned}\sum_{k=0}^{T-1} 2\alpha_k (f(x_k) - f(x^*)) &\leq \|x_0 - x^*\|^2 - \|x_T - x^*\|^2 + \sum_{k=0}^{T-1} \alpha_k^2 \|g_k\|^2 \\ &\leq \|x_0 - x^*\|^2 + \sum_{k=0}^{T-1} \alpha_k^2 \|g_k\|^2 \\ &\leq R^2 + G^2 \sum_{k=0}^{T-1} \alpha_k^2\end{aligned}$$

- Запишем, насколько близко мы подошли к оптимуму $x^* = \arg \min_{x \in \mathbb{R}^n} f(x) = \arg f^*$ на последней итерации:
- Для субградиента: $\langle g_k, x^* - x_k \rangle \leq f(x^*) - f(x_k)$.
- Дополнительно предположим, что $\|g_k\|^2 \leq G^2$
- Используем обозначение $R = \|x_0 - x^*\|_2$

Оценка сходимости

- Наконец, заметим:

$$\sum_{k=0}^{T-1} 2\alpha_k (f(x_k) - f(x^*)) \geq \sum_{k=0}^{T-1} 2\alpha_k (f_k^{\text{best}} - f(x^*)) = (f_k^{\text{best}} - f(x^*)) \sum_{k=0}^{T-1} 2\alpha_k$$

Оценка сходимости

- Наконец, заметим:

$$\sum_{k=0}^{T-1} 2\alpha_k (f(x_k) - f(x^*)) \geq \sum_{k=0}^{T-1} 2\alpha_k (f_k^{\text{best}} - f(x^*)) = (f_k^{\text{best}} - f(x^*)) \sum_{k=0}^{T-1} 2\alpha_k$$

- что приводит к базовому неравенству:

$$f_k^{\text{best}} - f(x^*) \leq \frac{R^2 + G^2 \sum_{k=0}^{T-1} \alpha_k^2}{2 \sum_{k=0}^{T-1} \alpha_k}$$

Оценка сходимости

- Наконец, заметим:

$$\sum_{k=0}^{T-1} 2\alpha_k (f(x_k) - f(x^*)) \geq \sum_{k=0}^{T-1} 2\alpha_k (f_k^{\text{best}} - f(x^*)) = (f_k^{\text{best}} - f(x^*)) \sum_{k=0}^{T-1} 2\alpha_k$$

- что приводит к базовому неравенству:







$$f_k^{\text{best}} - f(x^*) \leq \frac{R^2 + G^2 \sum_{k=0}^{T-1} \alpha_k^2}{2 \sum_{k=0}^{T-1} \alpha_k}$$

- Отсюда видно, что если стратегия выбора шага такова, что







$$\sum_{k=0}^{T-1} \alpha_k^2 < \infty, \quad \sum_{k=0}^{T-1} \alpha_k = \infty,$$

то субградиентный метод сходится (шаг должен убывать, но не слишком быстро).

Различные стратегии выбора шага



Различные стратегии выбора шага



Оценка сходимости. Негладкий выпуклый случай. Постоянный шаг

Theorem

Пусть f — выпуклая G -липшицева функция и $R = \|x_0 - x^*\|_2$. Тогда при фиксированном шаге α субградиентный метод удовлетворяет оценке

$$f_k^{\text{best}} - f(x^*) \leq \frac{R^2}{2\alpha k} + \frac{\alpha}{2} G^2$$

- Заметим, что при любом постоянном шаге первый член правой части убывает, но второй остаётся постоянным.

Оценка сходимости. Негладкий выпуклый случай. Постоянный шаг

i Theorem

Пусть f — выпуклая G -липшицева функция и $R = \|x_0 - x^*\|_2$. Тогда при фиксированном шаге α субградиентный метод удовлетворяет оценке

$$f_k^{\text{best}} - f(x^*) \leq \frac{R^2}{2\alpha k} + \frac{\alpha}{2} G^2$$

- Заметим, что при любом постоянном шаге первый член правой части убывает, но второй остаётся постоянным.
- Некоторые варианты субградиентного метода (например, убывающие несуммируемые длины шагов) работают и когда предположение $\|g_k\|_2 \leq G$ не выполнено; см. ¹ или ².

¹B. Polyak. Introduction to Optimization. Optimization Software, Inc., 1987.

²N. Shor. Minimization Methods for Non-differentiable Functions. Springer Series in Computational Mathematics. Springer, 1985.

Оценка сходимости. Негладкий выпуклый случай. Постоянный шаг

i Theorem

Пусть f — выпуклая G -липшицева функция и $R = \|x_0 - x^*\|_2$. Тогда при фиксированном шаге α субградиентный метод удовлетворяет оценке

$$f_k^{\text{best}} - f(x^*) \leq \frac{R^2}{2\alpha k} + \frac{\alpha}{2} G^2$$

- Заметим, что при любом постоянном шаге первый член правой части убывает, но второй остаётся постоянным.
- Некоторые варианты субградиентного метода (например, убывающие несуммируемые длины шагов) работают и когда предположение $\|g_k\|_2 \leq G$ не выполнено; см. ¹ или ².
- Найдём оптимальный шаг α , минимизирующий правую часть неравенства.

¹B. Polyak. Introduction to Optimization. Optimization Software, Inc., 1987.

²N. Shor. Minimization Methods for Non-differentiable Functions. Springer Series in Computational Mathematics. Springer, 1985.

Оценка сходимости. Негладкий выпуклый случай. Постоянный шаг

Theorem

Пусть f — выпуклая G -липшицева функция и $R = \|x_0 - x^*\|_2$. Тогда при выборе шага $\alpha = \frac{R}{G} \sqrt{\frac{1}{k}}$ субградиентный метод удовлетворяет оценке

$$f_k^{\text{best}} - f(x^*) \leq \frac{GR}{\sqrt{k}}$$

- Эта версия требует заранее знать число итераций, что обычно непрактично.

Оценка сходимости. Негладкий выпуклый случай. Постоянный шаг

Theorem

Пусть f — выпуклая G -липшицева функция и $R = \|x_0 - x^*\|_2$. Тогда при выборе шага $\alpha = \frac{R}{G} \sqrt{\frac{1}{k}}$ субградиентный метод удовлетворяет оценке

$$f_k^{\text{best}} - f(x^*) \leq \frac{GR}{\sqrt{k}}$$

- Эта версия требует заранее знать число итераций, что обычно непрактично.
- Интересно, что если искать оптимальные шаги для всей последовательности $\alpha_0, \alpha_1, \dots, \alpha_{k-1}$, получится тот же результат.

Оценка сходимости. Негладкий выпуклый случай. Постоянный шаг

i Theorem

Пусть f — выпуклая G -липшицева функция и $R = \|x_0 - x^*\|_2$. Тогда при выборе шага $\alpha = \frac{R}{G} \sqrt{\frac{1}{k}}$ субградиентный метод удовлетворяет оценке

$$f_k^{\text{best}} - f(x^*) \leq \frac{GR}{\sqrt{k}}$$

- Эта версия требует заранее знать число итераций, что обычно непрактично.
- Интересно, что если искать оптимальные шаги для всей последовательности $\alpha_0, \alpha_1, \dots, \alpha_{k-1}$, получится тот же результат.
- Почему? Потому что правая часть является выпуклой и **симметричной** функцией от $\alpha_0, \alpha_1, \dots, \alpha_{k-1}$.

Оценка сходимости. Негладкий выпуклый случай. Постоянная длина шага

i Theorem

Пусть f — выпуклая G -липшицева функция и $R = \|x_0 - x^*\|_2$. Тогда для фиксированной длины шага $\gamma = \alpha_k \|g_k\|_2$, т.е. $\alpha_k = \frac{\gamma}{\|g_k\|_2}$, субградиентный метод удовлетворяет оценке

$$f_k^{\text{best}} - f(x^*) \leq \frac{GR^2}{2\gamma k} + \frac{G\gamma}{2}$$

- Заметим, что в субградиентном методе обычно нельзя использовать норму субградиента как критерий остановки (представьте $f(x) = |x|$). Существуют более продвинутые критерии, но сходимость и так очень медленная, поэтому обычно просто задают максимальное число итераций.

Оценка сходимости. Негладкий выпуклый случай. Практическая стратегия

i Theorem

Пусть f — выпуклая G -липшицева функция и $R = \|x_0 - x^*\|_2$. Тогда для убывающей стратегии шага $\alpha_k = \frac{R}{G\sqrt{k+1}}$ субградиентный метод удовлетворяет оценке

$$f_k^{\text{best}} - f(x^*) \leq \frac{GR(2 + \ln k)}{4\sqrt{k+1}}$$

1. Оценим суммы:

Оценка сходимости. Негладкий выпуклый случай. Практическая стратегия

i Theorem

Пусть f — выпуклая G -липшицева функция и $R = \|x_0 - x^*\|_2$. Тогда для убывающей стратегии шага $\alpha_k = \frac{R}{G\sqrt{k+1}}$ субградиентный метод удовлетворяет оценке

$$f_k^{\text{best}} - f(x^*) \leq \frac{GR(2 + \ln k)}{4\sqrt{k+1}}$$

1. Оценим суммы:

$$\sum_{k=0}^{T-1} \alpha_k^2 = \frac{R^2}{G^2} \sum_{k=1}^T \frac{1}{k} \leq \frac{R^2}{G^2} (1 + \ln T);$$

Оценка сходимости. Негладкий выпуклый случай. Практическая стратегия

i Theorem

Пусть f — выпуклая G -липшицева функция и $R = \|x_0 - x^*\|_2$. Тогда для убывающей стратегии шага $\alpha_k = \frac{R}{G\sqrt{k+1}}$ субградиентный метод удовлетворяет оценке

$$f_k^{\text{best}} - f(x^*) \leq \frac{GR(2 + \ln k)}{4\sqrt{k+1}}$$

1. Оценим суммы:

$$\sum_{k=0}^{T-1} \alpha_k^2 = \frac{R^2}{G^2} \sum_{k=1}^T \frac{1}{k} \leq \frac{R^2}{G^2} (1 + \ln T); \quad \sum_{k=0}^{T-1} \alpha_k = \frac{R}{G} \sum_{k=1}^T \frac{1}{\sqrt{k}} \geq \frac{R}{G} \int_1^{T+1} \frac{1}{\sqrt{t}} dt = \frac{2R}{G} (\sqrt{T+1} - 1).$$

Оценка сходимости. Негладкий выпуклый случай. Практическая стратегия

i Theorem

Пусть f — выпуклая G -липшицева функция и $R = \|x_0 - x^*\|_2$. Тогда для убывающей стратегии шага $\alpha_k = \frac{R}{G\sqrt{k+1}}$ субградиентный метод удовлетворяет оценке

$$f_k^{\text{best}} - f(x^*) \leq \frac{GR(2 + \ln k)}{4\sqrt{k+1}}$$

1. Оценим суммы:

$$\sum_{k=0}^{T-1} \alpha_k^2 = \frac{R^2}{G^2} \sum_{k=1}^T \frac{1}{k} \leq \frac{R^2}{G^2} (1 + \ln T); \quad \sum_{k=0}^{T-1} \alpha_k = \frac{R}{G} \sum_{k=1}^T \frac{1}{\sqrt{k}} \geq \frac{R}{G} \int_1^{T+1} \frac{1}{\sqrt{t}} dt = \frac{2R}{G} (\sqrt{T+1} - 1).$$

2. В верхней оценке выше отбросим последнее -1 и воспользуемся базовым неравенством:

Оценка сходимости. Негладкий выпуклый случай. Практическая стратегия

i Theorem

Пусть f — выпуклая G -липшицева функция и $R = \|x_0 - x^*\|_2$. Тогда для убывающей стратегии шага $\alpha_k = \frac{R}{G\sqrt{k+1}}$ субградиентный метод удовлетворяет оценке

$$f_k^{\text{best}} - f(x^*) \leq \frac{GR(2 + \ln k)}{4\sqrt{k+1}}$$

1. Оценим суммы:

$$\sum_{k=0}^{T-1} \alpha_k^2 = \frac{R^2}{G^2} \sum_{k=1}^T \frac{1}{k} \leq \frac{R^2}{G^2} (1 + \ln T); \quad \sum_{k=0}^{T-1} \alpha_k = \frac{R}{G} \sum_{k=1}^T \frac{1}{\sqrt{k}} \geq \frac{R}{G} \int_1^{T+1} \frac{1}{\sqrt{t}} dt = \frac{2R}{G} (\sqrt{T+1} - 1).$$

2. В верхней оценке выше отбросим последнее -1 и воспользуемся базовым неравенством:

$$f_T^{\text{best}} - f(x^*) \leq \frac{R^2 + G^2 \sum_{k=0}^{T-1} \alpha_k^2}{2 \sum_{k=0}^{T-1} \alpha_k}$$

Оценка сходимости. Негладкий выпуклый случай. Практическая стратегия

i Theorem

Пусть f — выпуклая G -липшицева функция и $R = \|x_0 - x^*\|_2$. Тогда для убывающей стратегии шага $\alpha_k = \frac{R}{G\sqrt{k+1}}$ субградиентный метод удовлетворяет оценке

$$f_k^{\text{best}} - f(x^*) \leq \frac{GR(2 + \ln k)}{4\sqrt{k+1}}$$

1. Оценим суммы:

$$\sum_{k=0}^{T-1} \alpha_k^2 = \frac{R^2}{G^2} \sum_{k=1}^T \frac{1}{k} \leq \frac{R^2}{G^2} (1 + \ln T); \quad \sum_{k=0}^{T-1} \alpha_k = \frac{R}{G} \sum_{k=1}^T \frac{1}{\sqrt{k}} \geq \frac{R}{G} \int_1^{T+1} \frac{1}{\sqrt{t}} dt = \frac{2R}{G} (\sqrt{T+1} - 1).$$

2. В верхней оценке выше отбросим последнее -1 и воспользуемся базовым неравенством:

$$f_T^{\text{best}} - f(x^*) \leq \frac{R^2 + G^2 \sum_{k=0}^{T-1} \alpha_k^2}{2 \sum_{k=0}^{T-1} \alpha_k} \leq \frac{R^2 + R^2(1 + \ln T)}{4 \frac{R}{G} (\sqrt{T+1})}$$

Оценка сходимости. Негладкий выпуклый случай. Практическая стратегия

i Theorem

Пусть f — выпуклая G -липшицева функция и $R = \|x_0 - x^*\|_2$. Тогда для убывающей стратегии шага $\alpha_k = \frac{R}{G\sqrt{k+1}}$ субградиентный метод удовлетворяет оценке

$$f_k^{\text{best}} - f(x^*) \leq \frac{GR(2 + \ln k)}{4\sqrt{k+1}}$$


1. Оценим суммы:

$$\sum_{k=0}^{T-1} \alpha_k^2 = \frac{R^2}{G^2} \sum_{k=1}^T \frac{1}{k} \leq \frac{R^2}{G^2} (1 + \ln T); \quad \sum_{k=0}^{T-1} \alpha_k = \frac{R}{G} \sum_{k=1}^T \frac{1}{\sqrt{k}} \geq \frac{R}{G} \int_1^{T+1} \frac{1}{\sqrt{t}} dt = \frac{2R}{G} (\sqrt{T+1} - 1).$$


2. В верхней оценке выше отбросим последнее -1 и воспользуемся базовым неравенством:

$$f_T^{\text{best}} - f(x^*) \leq \frac{R^2 + G^2 \sum_{k=0}^{T-1} \alpha_k^2}{2 \sum_{k=0}^{T-1} \alpha_k} \leq \frac{R^2 + R^2(1 + \ln T)}{4 \frac{R}{G} (\sqrt{T+1})} = \frac{GR(2 + \ln T)}{4\sqrt{T+1}}$$

Негладкий сильно выпуклый случай




Негладкая
Выпуклая




Негладкая
 μ - сильно выпуклая

Негладкий сильно выпуклый случай



Негладкая
Выпуклая

$$\mathcal{O}\left(\frac{1}{\sqrt{k}}\right)$$



Негладкая
 μ - сильно выпуклая

$$\mathcal{O}\left(\frac{1}{k}\right)$$

Негладкий сильно выпуклый случай

i Theorem

Пусть f μ -сильно выпукла на выпуклом множестве, а x, y — произвольные точки. Тогда для любого $g \in \partial f(x)$

$$\langle g, x - y \rangle \geq f(x) - f(y) + \frac{\mu}{2} \|x - y\|^2.$$

1. Для любого $\lambda \in [0, 1)$ из μ -сильной выпуклости следует

$$f(\lambda x + (1 - \lambda)y) \leq \lambda f(x) + (1 - \lambda)f(y) - \frac{\mu}{2} \lambda(1 - \lambda) \|x - y\|^2.$$

Негладкий сильно выпуклый случай

i Theorem

Пусть f μ -сильно выпукла на выпуклом множестве, а x, y — произвольные точки. Тогда для любого $g \in \partial f(x)$

$$\langle g, x - y \rangle \geq f(x) - f(y) + \frac{\mu}{2} \|x - y\|^2.$$

1. Для любого $\lambda \in [0, 1)$ из μ -сильной выпуклости следует

$$f(\lambda x + (1 - \lambda)y) \leq \lambda f(x) + (1 - \lambda)f(y) - \frac{\mu}{2} \lambda(1 - \lambda) \|x - y\|^2.$$

2. Из субградиентного неравенства в точке x получаем

$$f(\lambda x + (1 - \lambda)y) \geq f(x) + \langle g, \lambda x + (1 - \lambda)y - x \rangle \quad \rightarrow \quad f(\lambda x + (1 - \lambda)y) \geq f(x) - (1 - \lambda) \langle g, x - y \rangle.$$

Негладкий сильно выпуклый случай

i Theorem

Пусть f μ -сильно выпукла на выпуклом множестве, а x, y — произвольные точки. Тогда для любого $g \in \partial f(x)$

$$\langle g, x - y \rangle \geq f(x) - f(y) + \frac{\mu}{2} \|x - y\|^2.$$

1. Для любого $\lambda \in [0, 1)$ из μ -сильной выпуклости следует

$$f(\lambda x + (1 - \lambda)y) \leq \lambda f(x) + (1 - \lambda)f(y) - \frac{\mu}{2} \lambda(1 - \lambda) \|x - y\|^2.$$

2. Из субградиентного неравенства в точке x получаем

$$f(\lambda x + (1 - \lambda)y) \geq f(x) + \langle g, \lambda x + (1 - \lambda)y - x \rangle \rightarrow f(\lambda x + (1 - \lambda)y) \geq f(x) - (1 - \lambda) \langle g, x - y \rangle.$$

3. Следовательно,

$$f(x) - (1 - \lambda) \langle g, x - y \rangle \leq \lambda f(x) + (1 - \lambda)f(y) - \frac{\mu}{2} \lambda(1 - \lambda) \|x - y\|^2$$

$$(1 - \lambda)f(x) \leq (1 - \lambda)f(y) + (1 - \lambda) \langle g, x - y \rangle - \frac{\mu}{2} \lambda(1 - \lambda) \|x - y\|^2$$

$$f(x) \leq f(y) + \langle g, x - y \rangle - \frac{\mu}{2} \lambda \|x - y\|^2$$

Негладкий сильно выпуклый случай

i Theorem

Пусть f μ -сильно выпукла на выпуклом множестве, а x, y — произвольные точки. Тогда для любого $g \in \partial f(x)$

$$\langle g, x - y \rangle \geq f(x) - f(y) + \frac{\mu}{2} \|x - y\|^2.$$

1. Для любого $\lambda \in [0, 1)$ из μ -сильной выпуклости следует

$$f(\lambda x + (1 - \lambda)y) \leq \lambda f(x) + (1 - \lambda)f(y) - \frac{\mu}{2} \lambda(1 - \lambda) \|x - y\|^2.$$

2. Из субградиентного неравенства в точке x получаем

$$f(\lambda x + (1 - \lambda)y) \geq f(x) + \langle g, \lambda x + (1 - \lambda)y - x \rangle \rightarrow f(\lambda x + (1 - \lambda)y) \geq f(x) - (1 - \lambda) \langle g, x - y \rangle.$$

3. Следовательно,

$$f(x) - (1 - \lambda) \langle g, x - y \rangle \leq \lambda f(x) + (1 - \lambda)f(y) - \frac{\mu}{2} \lambda(1 - \lambda) \|x - y\|^2$$

$$(1 - \lambda)f(x) \leq (1 - \lambda)f(y) + (1 - \lambda) \langle g, x - y \rangle - \frac{\mu}{2} \lambda(1 - \lambda) \|x - y\|^2$$

$$f(x) \leq f(y) + \langle g, x - y \rangle - \frac{\mu}{2} \lambda \|x - y\|^2$$

Оценка сходимости. Негладкий сильно выпуклый случай.

i Theorem

Пусть f — μ -сильно выпуклая (возможно, негладкая) функция с минимизатором x^* и ограниченными субградиентами $\|g_k\| \leq G$. При выборе шага $\alpha_k = \frac{2}{\mu(k+1)}$ субградиентный метод гарантирует для $k > 0$:

$$f_k^{\text{best}} - f(x^*) \leq \frac{2G^2}{\mu k}.$$

1. Начинаем с той же записи метода, что и ранее:

Оценка сходимости. Негладкий сильно выпуклый случай.

Theorem

Пусть f — μ -сильно выпуклая (возможно, негладкая) функция с минимизатором x^* и ограниченными субградиентами $\|g_k\| \leq G$. При выборе шага $\alpha_k = \frac{2}{\mu(k+1)}$ субградиентный метод гарантирует для $k > 0$:

$$f_k^{\text{best}} - f(x^*) \leq \frac{2G^2}{\mu k}.$$

1. Начинаем с той же записи метода, что и ранее:

$$\|x_{k+1} - x^*\|^2 = \|x_k - x^* - \alpha_k g_k\|^2 =$$

Оценка сходимости. Негладкий сильно выпуклый случай.

i Theorem

Пусть f — μ -сильно выпуклая (возможно, негладкая) функция с минимизатором x^* и ограниченными субградиентами $\|g_k\| \leq G$. При выборе шага $\alpha_k = \frac{2}{\mu(k+1)}$ субградиентный метод гарантирует для $k > 0$:

$$f_k^{\text{best}} - f(x^*) \leq \frac{2G^2}{\mu k}.$$

1. Начинаем с той же записи метода, что и ранее:

$$\begin{aligned}\|x_{k+1} - x^*\|^2 &= \|x_k - x^* - \alpha_k g_k\|^2 = \\ &= \|x_k - x^*\|^2 + \alpha_k^2 \|g_k\|^2 - 2\alpha_k \langle g_k, x_k - x^* \rangle\end{aligned}$$

Оценка сходимости. Негладкий сильно выпуклый случай.

i Theorem

Пусть f — μ -сильно выпуклая (возможно, негладкая) функция с минимизатором x^* и ограниченными субградиентами $\|g_k\| \leq G$. При выборе шага $\alpha_k = \frac{2}{\mu(k+1)}$ субградиентный метод гарантирует для $k > 0$:

$$f_k^{\text{best}} - f(x^*) \leq \frac{2G^2}{\mu k}.$$

1. Начинаем с той же записи метода, что и ранее:

$$\begin{aligned}\|x_{k+1} - x^*\|^2 &= \|x_k - x^* - \alpha_k g_k\|^2 = \\ &= \|x_k - x^*\|^2 + \alpha_k^2 \|g_k\|^2 - 2\alpha_k \langle g_k, x_k - x^* \rangle \\ &\leq \|x_k - x^*\|^2 + \alpha_k^2 \|g_k\|^2 - 2\alpha_k (f(x_k) - f(x^*)) - \alpha_k \mu \|x_k - x^*\|^2\end{aligned}$$

Оценка сходимости. Негладкий сильно выпуклый случай.

i Theorem

Пусть f — μ -сильно выпуклая (возможно, негладкая) функция с минимизатором x^* и ограниченными субградиентами $\|g_k\| \leq G$. При выборе шага $\alpha_k = \frac{2}{\mu(k+1)}$ субградиентный метод гарантирует для $k > 0$:

$$f_k^{\text{best}} - f(x^*) \leq \frac{2G^2}{\mu k}.$$

1. Начинаем с той же записи метода, что и ранее:

$$\begin{aligned}\|x_{k+1} - x^*\|^2 &= \|x_k - x^* - \alpha_k g_k\|^2 = \\ &= \|x_k - x^*\|^2 + \alpha_k^2 \|g_k\|^2 - 2\alpha_k \langle g_k, x_k - x^* \rangle \\ &\leq \|x_k - x^*\|^2 + \alpha_k^2 \|g_k\|^2 - 2\alpha_k (f(x_k) - f(x^*)) - \alpha_k \mu \|x_k - x^*\|^2 \\ &= (1 - \mu \alpha_k) \|x_k - x^*\|^2 + \alpha_k^2 \|g_k\|^2 - 2\alpha_k (f(x_k) - f(x^*))\end{aligned}$$

Оценка сходимости. Негладкий сильно выпуклый случай.

i Theorem

Пусть f — μ -сильно выпуклая (возможно, негладкая) функция с минимизатором x^* и ограниченными субградиентами $\|g_k\| \leq G$. При выборе шага $\alpha_k = \frac{2}{\mu(k+1)}$ субградиентный метод гарантирует для $k > 0$:

$$f_k^{\text{best}} - f(x^*) \leq \frac{2G^2}{\mu k}.$$

1. Начинаем с той же записи метода, что и ранее:

$$\begin{aligned}\|x_{k+1} - x^*\|^2 &= \|x_k - x^* - \alpha_k g_k\|^2 = \\ &= \|x_k - x^*\|^2 + \alpha_k^2 \|g_k\|^2 - 2\alpha_k \langle g_k, x_k - x^* \rangle \\ &\leq \|x_k - x^*\|^2 + \alpha_k^2 \|g_k\|^2 - 2\alpha_k (f(x_k) - f(x^*)) - \alpha_k \mu \|x_k - x^*\|^2 \\ &= (1 - \mu\alpha_k) \|x_k - x^*\|^2 + \alpha_k^2 \|g_k\|^2 - 2\alpha_k (f(x_k) - f(x^*)) \\ 2\alpha_k (f(x_k) - f(x^*)) &\leq (1 - \mu\alpha_k) \|x_k - x^*\|^2 - \|x_{k+1} - x^*\|^2 + \alpha_k^2 \|g_k\|^2\end{aligned}$$

Оценка сходимости. Негладкий сильно выпуклый случай.

i Theorem

Пусть f — μ -сильно выпуклая (возможно, негладкая) функция с минимизатором x^* и ограниченными субградиентами $\|g_k\| \leq G$. При выборе шага $\alpha_k = \frac{2}{\mu(k+1)}$ субградиентный метод гарантирует для $k > 0$:

$$f_k^{\text{best}} - f(x^*) \leq \frac{2G^2}{\mu k}.$$

1. Начинаем с той же записи метода, что и ранее:

$$\begin{aligned}\|x_{k+1} - x^*\|^2 &= \|x_k - x^* - \alpha_k g_k\|^2 = \\ &= \|x_k - x^*\|^2 + \alpha_k^2 \|g_k\|^2 - 2\alpha_k \langle g_k, x_k - x^* \rangle \\ &\leq \|x_k - x^*\|^2 + \alpha_k^2 \|g_k\|^2 - 2\alpha_k (f(x_k) - f(x^*)) - \alpha_k \mu \|x_k - x^*\|^2 \\ &= (1 - \mu \alpha_k) \|x_k - x^*\|^2 + \alpha_k^2 \|g_k\|^2 - 2\alpha_k (f(x_k) - f(x^*)) \\ 2\alpha_k (f(x_k) - f(x^*)) &\leq (1 - \mu \alpha_k) \|x_k - x^*\|^2 - \|x_{k+1} - x^*\|^2 + \alpha_k^2 \|g_k\|^2 \\ f(x_k) - f(x^*) &\leq \frac{1 - \mu \alpha_k}{2\alpha_k} \|x_k - x^*\|^2 - \frac{1}{2\alpha_k} \|x_{k+1} - x^*\|^2 + \frac{\alpha_k}{2} \|g_k\|^2\end{aligned}$$

Оценка сходимости. Негладкий сильно выпуклый случай. Доказательство

2. Подставим шаг $\alpha_k = \frac{2}{\mu(k+1)}$ в неравенство:

Оценка сходимости. Негладкий сильно выпуклый случай. Доказательство

2. Подставим шаг $\alpha_k = \frac{2}{\mu(k+1)}$ в неравенство:

$$f(x_k) - f(x^*) \leq \frac{\mu(k-1)}{4} \|x_k - x^*\|^2 - \frac{\mu(k+1)}{4} \|x_{k+1} - x^*\|^2 + \frac{1}{\mu(k+1)} \|g_k\|^2$$

Оценка сходимости. Негладкий сильно выпуклый случай. Доказательство

2. Подставим шаг $\alpha_k = \frac{2}{\mu(k+1)}$ в неравенство:

$$f(x_k) - f(x^*) \leq \frac{\mu(k-1)}{4} \|x_k - x^*\|^2 - \frac{\mu(k+1)}{4} \|x_{k+1} - x^*\|^2 + \frac{1}{\mu(k+1)} \|g_k\|^2$$

$$f(x_k) - f(x^*) \leq \frac{\mu(k-1)}{4} \|x_k - x^*\|^2 - \frac{\mu(k+1)}{4} \|x_{k+1} - x^*\|^2 + \frac{1}{\mu k} \|g_k\|^2$$

Оценка сходимости. Негладкий сильно выпуклый случай. Доказательство

2. Подставим шаг $\alpha_k = \frac{2}{\mu(k+1)}$ в неравенство:

$$f(x_k) - f(x^*) \leq \frac{\mu(k-1)}{4} \|x_k - x^*\|^2 - \frac{\mu(k+1)}{4} \|x_{k+1} - x^*\|^2 + \frac{1}{\mu(k+1)} \|g_k\|^2$$

$$f(x_k) - f(x^*) \leq \frac{\mu(k-1)}{4} \|x_k - x^*\|^2 - \frac{\mu(k+1)}{4} \|x_{k+1} - x^*\|^2 + \frac{1}{\mu k} \|g_k\|^2$$

$$k(f(x_k) - f(x^*)) \leq \frac{\mu k(k-1)}{4} \|x_k - x^*\|^2 - \frac{\mu k(k+1)}{4} \|x_{k+1} - x^*\|^2 + \frac{1}{\mu} \|g_k\|^2$$

Оценка сходимости. Негладкий сильно выпуклый случай. Доказательство

2. Подставим шаг $\alpha_k = \frac{2}{\mu(k+1)}$ в неравенство:

$$f(x_k) - f(x^*) \leq \frac{\mu(k-1)}{4} \|x_k - x^*\|^2 - \frac{\mu(k+1)}{4} \|x_{k+1} - x^*\|^2 + \frac{1}{\mu(k+1)} \|g_k\|^2$$

$$f(x_k) - f(x^*) \leq \frac{\mu(k-1)}{4} \|x_k - x^*\|^2 - \frac{\mu(k+1)}{4} \|x_{k+1} - x^*\|^2 + \frac{1}{\mu k} \|g_k\|^2$$

$$k(f(x_k) - f(x^*)) \leq \frac{\mu k(k-1)}{4} \|x_k - x^*\|^2 - \frac{\mu k(k+1)}{4} \|x_{k+1} - x^*\|^2 + \frac{1}{\mu} \|g_k\|^2$$

3. Просуммировав неравенства по всем $k = 0, 1, \dots, T-1$, получаем:

Оценка сходимости. Негладкий сильно выпуклый случай. Доказательство

2. Подставим шаг $\alpha_k = \frac{2}{\mu(k+1)}$ в неравенство:

$$f(x_k) - f(x^*) \leq \frac{\mu(k-1)}{4} \|x_k - x^*\|^2 - \frac{\mu(k+1)}{4} \|x_{k+1} - x^*\|^2 + \frac{1}{\mu(k+1)} \|g_k\|^2$$

$$f(x_k) - f(x^*) \leq \frac{\mu(k-1)}{4} \|x_k - x^*\|^2 - \frac{\mu(k+1)}{4} \|x_{k+1} - x^*\|^2 + \frac{1}{\mu k} \|g_k\|^2$$

$$k(f(x_k) - f(x^*)) \leq \frac{\mu k(k-1)}{4} \|x_k - x^*\|^2 - \frac{\mu k(k+1)}{4} \|x_{k+1} - x^*\|^2 + \frac{1}{\mu} \|g_k\|^2$$

3. Просуммировав неравенства по всем $k = 0, 1, \dots, T-1$, получаем:

$$\sum_{k=0}^{T-1} k(f(x_k) - f(x^*)) \leq 0 - \frac{\mu(T-1)T}{4} \|x_T - x^*\|^2 + \frac{1}{\mu} \sum_{k=0}^{T-1} \|g_k\|^2$$

Оценка сходимости. Негладкий сильно выпуклый случай. Доказательство

2. Подставим шаг $\alpha_k = \frac{2}{\mu(k+1)}$ в неравенство:

$$f(x_k) - f(x^*) \leq \frac{\mu(k-1)}{4} \|x_k - x^*\|^2 - \frac{\mu(k+1)}{4} \|x_{k+1} - x^*\|^2 + \frac{1}{\mu(k+1)} \|g_k\|^2$$

$$f(x_k) - f(x^*) \leq \frac{\mu(k-1)}{4} \|x_k - x^*\|^2 - \frac{\mu(k+1)}{4} \|x_{k+1} - x^*\|^2 + \frac{1}{\mu k} \|g_k\|^2$$

$$k(f(x_k) - f(x^*)) \leq \frac{\mu k(k-1)}{4} \|x_k - x^*\|^2 - \frac{\mu k(k+1)}{4} \|x_{k+1} - x^*\|^2 + \frac{1}{\mu} \|g_k\|^2$$

3. Просуммировав неравенства по всем $k = 0, 1, \dots, T-1$, получаем:

$$\sum_{k=0}^{T-1} k(f(x_k) - f(x^*)) \leq 0 - \frac{\mu(T-1)T}{4} \|x_T - x^*\|^2 + \frac{1}{\mu} \sum_{k=0}^{T-1} \|g_k\|^2 \leq \frac{G^2 T}{\mu}$$

Оценка сходимости. Негладкий сильно выпуклый случай. Доказательство

2. Подставим шаг $\alpha_k = \frac{2}{\mu(k+1)}$ в неравенство:

$$f(x_k) - f(x^*) \leq \frac{\mu(k-1)}{4} \|x_k - x^*\|^2 - \frac{\mu(k+1)}{4} \|x_{k+1} - x^*\|^2 + \frac{1}{\mu(k+1)} \|g_k\|^2$$

$$f(x_k) - f(x^*) \leq \frac{\mu(k-1)}{4} \|x_k - x^*\|^2 - \frac{\mu(k+1)}{4} \|x_{k+1} - x^*\|^2 + \frac{1}{\mu k} \|g_k\|^2$$

$$k(f(x_k) - f(x^*)) \leq \frac{\mu k(k-1)}{4} \|x_k - x^*\|^2 - \frac{\mu k(k+1)}{4} \|x_{k+1} - x^*\|^2 + \frac{1}{\mu} \|g_k\|^2$$

3. Просуммировав неравенства по всем $k = 0, 1, \dots, T-1$, получаем:

$$\sum_{k=0}^{T-1} k(f(x_k) - f(x^*)) \leq 0 - \frac{\mu(T-1)T}{4} \|x_T - x^*\|^2 + \frac{1}{\mu} \sum_{k=0}^{T-1} \|g_k\|^2 \leq \frac{G^2 T}{\mu}$$

$$(f_{T-1}^{\text{best}} - f(x^*)) \sum_{k=0}^{T-1} k = \sum_{k=0}^{T-1} k(f_{T-1}^{\text{best}} - f(x^*))$$

Оценка сходимости. Негладкий сильно выпуклый случай. Доказательство

2. Подставим шаг $\alpha_k = \frac{2}{\mu(k+1)}$ в неравенство:

$$f(x_k) - f(x^*) \leq \frac{\mu(k-1)}{4} \|x_k - x^*\|^2 - \frac{\mu(k+1)}{4} \|x_{k+1} - x^*\|^2 + \frac{1}{\mu(k+1)} \|g_k\|^2$$

$$f(x_k) - f(x^*) \leq \frac{\mu(k-1)}{4} \|x_k - x^*\|^2 - \frac{\mu(k+1)}{4} \|x_{k+1} - x^*\|^2 + \frac{1}{\mu k} \|g_k\|^2$$

$$k(f(x_k) - f(x^*)) \leq \frac{\mu k(k-1)}{4} \|x_k - x^*\|^2 - \frac{\mu k(k+1)}{4} \|x_{k+1} - x^*\|^2 + \frac{1}{\mu} \|g_k\|^2$$

3. Просуммировав неравенства по всем $k = 0, 1, \dots, T-1$, получаем:

$$\sum_{k=0}^{T-1} k(f(x_k) - f(x^*)) \leq 0 - \frac{\mu(T-1)T}{4} \|x_T - x^*\|^2 + \frac{1}{\mu} \sum_{k=0}^{T-1} \|g_k\|^2 \leq \frac{G^2 T}{\mu}$$

$$(f_{T-1}^{\text{best}} - f(x^*)) \sum_{k=0}^{T-1} k = \sum_{k=0}^{T-1} k(f_{T-1}^{\text{best}} - f(x^*)) \leq \sum_{k=0}^{T-1} k(f(x_k) - f(x^*))$$

Оценка сходимости. Негладкий сильно выпуклый случай. Доказательство

2. Подставим шаг $\alpha_k = \frac{2}{\mu(k+1)}$ в неравенство:

$$f(x_k) - f(x^*) \leq \frac{\mu(k-1)}{4} \|x_k - x^*\|^2 - \frac{\mu(k+1)}{4} \|x_{k+1} - x^*\|^2 + \frac{1}{\mu(k+1)} \|g_k\|^2$$

$$f(x_k) - f(x^*) \leq \frac{\mu(k-1)}{4} \|x_k - x^*\|^2 - \frac{\mu(k+1)}{4} \|x_{k+1} - x^*\|^2 + \frac{1}{\mu k} \|g_k\|^2$$

$$k(f(x_k) - f(x^*)) \leq \frac{\mu k(k-1)}{4} \|x_k - x^*\|^2 - \frac{\mu k(k+1)}{4} \|x_{k+1} - x^*\|^2 + \frac{1}{\mu} \|g_k\|^2$$

3. Просуммировав неравенства по всем $k = 0, 1, \dots, T-1$, получаем:

$$\sum_{k=0}^{T-1} k(f(x_k) - f(x^*)) \leq 0 - \frac{\mu(T-1)T}{4} \|x_T - x^*\|^2 + \frac{1}{\mu} \sum_{k=0}^{T-1} \|g_k\|^2 \leq \frac{G^2 T}{\mu}$$

$$(f_{T-1}^{\text{best}} - f(x^*)) \sum_{k=0}^{T-1} k = \sum_{k=0}^{T-1} k(f_{T-1}^{\text{best}} - f(x^*)) \leq \sum_{k=0}^{T-1} k(f(x_k) - f(x^*)) \leq \frac{G^2 T}{\mu}$$

Оценка сходимости. Негладкий сильно выпуклый случай. Доказательство

2. Подставим шаг $\alpha_k = \frac{2}{\mu(k+1)}$ в неравенство:

$$f(x_k) - f(x^*) \leq \frac{\mu(k-1)}{4} \|x_k - x^*\|^2 - \frac{\mu(k+1)}{4} \|x_{k+1} - x^*\|^2 + \frac{1}{\mu(k+1)} \|g_k\|^2$$

$$f(x_k) - f(x^*) \leq \frac{\mu(k-1)}{4} \|x_k - x^*\|^2 - \frac{\mu(k+1)}{4} \|x_{k+1} - x^*\|^2 + \frac{1}{\mu k} \|g_k\|^2$$

$$k(f(x_k) - f(x^*)) \leq \frac{\mu k(k-1)}{4} \|x_k - x^*\|^2 - \frac{\mu k(k+1)}{4} \|x_{k+1} - x^*\|^2 + \frac{1}{\mu} \|g_k\|^2$$

3. Просуммировав неравенства по всем $k = 0, 1, \dots, T-1$, получаем:

$$\sum_{k=0}^{T-1} k(f(x_k) - f(x^*)) \leq 0 - \frac{\mu(T-1)T}{4} \|x_T - x^*\|^2 + \frac{1}{\mu} \sum_{k=0}^{T-1} \|g_k\|^2 \leq \frac{G^2 T}{\mu}$$

$$(f_{T-1}^{\text{best}} - f(x^*)) \sum_{k=0}^{T-1} k = \sum_{k=0}^{T-1} k(f_{T-1}^{\text{best}} - f(x^*)) \leq \sum_{k=0}^{T-1} k(f(x_k) - f(x^*)) \leq \frac{G^2 T}{\mu}$$

$$f_{T-1}^{\text{best}} - f(x^*) \leq \frac{G^2 T}{\mu \sum_{k=0}^{T-1} k}$$

Оценка сходимости. Негладкий сильно выпуклый случай. Доказательство

2. Подставим шаг $\alpha_k = \frac{2}{\mu(k+1)}$ в неравенство:

$$f(x_k) - f(x^*) \leq \frac{\mu(k-1)}{4} \|x_k - x^*\|^2 - \frac{\mu(k+1)}{4} \|x_{k+1} - x^*\|^2 + \frac{1}{\mu(k+1)} \|g_k\|^2$$

$$f(x_k) - f(x^*) \leq \frac{\mu(k-1)}{4} \|x_k - x^*\|^2 - \frac{\mu(k+1)}{4} \|x_{k+1} - x^*\|^2 + \frac{1}{\mu k} \|g_k\|^2$$

$$k(f(x_k) - f(x^*)) \leq \frac{\mu k(k-1)}{4} \|x_k - x^*\|^2 - \frac{\mu k(k+1)}{4} \|x_{k+1} - x^*\|^2 + \frac{1}{\mu} \|g_k\|^2$$

3. Просуммировав неравенства по всем $k = 0, 1, \dots, T-1$, получаем:

$$\sum_{k=0}^{T-1} k(f(x_k) - f(x^*)) \leq 0 - \frac{\mu(T-1)T}{4} \|x_T - x^*\|^2 + \frac{1}{\mu} \sum_{k=0}^{T-1} \|g_k\|^2 \leq \frac{G^2 T}{\mu}$$

$$(f_{T-1}^{\text{best}} - f(x^*)) \sum_{k=0}^{T-1} k = \sum_{k=0}^{T-1} k(f_{T-1}^{\text{best}} - f(x^*)) \leq \sum_{k=0}^{T-1} k(f(x_k) - f(x^*)) \leq \frac{G^2 T}{\mu}$$

$$f_{T-1}^{\text{best}} - f(x^*) \leq \frac{G^2 T}{\mu \sum_{k=0}^{T-1} k} = \frac{2G^2 T}{\mu T(T-1)}$$

Оценка сходимости. Негладкий сильно выпуклый случай. Доказательство

2. Подставим шаг $\alpha_k = \frac{2}{\mu(k+1)}$ в неравенство:

$$f(x_k) - f(x^*) \leq \frac{\mu(k-1)}{4} \|x_k - x^*\|^2 - \frac{\mu(k+1)}{4} \|x_{k+1} - x^*\|^2 + \frac{1}{\mu(k+1)} \|g_k\|^2$$

$$f(x_k) - f(x^*) \leq \frac{\mu(k-1)}{4} \|x_k - x^*\|^2 - \frac{\mu(k+1)}{4} \|x_{k+1} - x^*\|^2 + \frac{1}{\mu k} \|g_k\|^2$$

$$k(f(x_k) - f(x^*)) \leq \frac{\mu k(k-1)}{4} \|x_k - x^*\|^2 - \frac{\mu k(k+1)}{4} \|x_{k+1} - x^*\|^2 + \frac{1}{\mu} \|g_k\|^2$$

3. Просуммировав неравенства по всем $k = 0, 1, \dots, T-1$, получаем:

$$\sum_{k=0}^{T-1} k(f(x_k) - f(x^*)) \leq 0 - \frac{\mu(T-1)T}{4} \|x_T - x^*\|^2 + \frac{1}{\mu} \sum_{k=0}^{T-1} \|g_k\|^2 \leq \frac{G^2 T}{\mu}$$

$$(f_{T-1}^{\text{best}} - f(x^*)) \sum_{k=0}^{T-1} k = \sum_{k=0}^{T-1} k(f_{T-1}^{\text{best}} - f(x^*)) \leq \sum_{k=0}^{T-1} k(f(x_k) - f(x^*)) \leq \frac{G^2 T}{\mu}$$

$$f_{T-1}^{\text{best}} - f(x^*) \leq \frac{G^2 T}{\mu \sum_{k=0}^{T-1} k} = \frac{2G^2 T}{\mu T(T-1)} \quad f_k^{\text{best}} - f(x^*) \leq \frac{2G^2}{\mu k}.$$

Резюме. Субградиентный метод

Тип задачи	Правило выбора шага	Скорость сходимости	Итерационная сложность
Выпуклые липшицевы задачи	$\alpha \sim \frac{1}{\sqrt{k}}$	$\mathcal{O}\left(\frac{1}{\sqrt{k}}\right)$	$\mathcal{O}\left(\frac{1}{\varepsilon^2}\right)$
Сильно выпуклые липшицевы задачи	$\alpha \sim \frac{1}{k}$	$\mathcal{O}\left(\frac{1}{k}\right)$	$\mathcal{O}\left(\frac{1}{\varepsilon}\right)$

Численные эксперименты

$$f(x) = \frac{1}{2m} \|Ax - b\|_2^2 + \lambda \|x\|_1 \rightarrow \min_{x \in \mathbb{R}^n}, \quad A \in \mathbb{R}^{m \times n}, \quad \lambda \left(\frac{1}{m} A^T A \right) \in [\mu; L].$$

Linear Least Squares with ℓ_1 Regularization (LASSO).
m=1000, n=100, $\lambda=0$, $\mu=0$, L=10. Optimal sparsity: 0.0e+00




Рис. 6: Гладкий выпуклый случай. Сублинейная сходимость, нет сходимости по аргументу

Численные эксперименты

$$f(x) = \frac{1}{2m} \|Ax - b\|_2^2 + \lambda \|x\|_1 \rightarrow \min_{x \in \mathbb{R}^n}, \quad A \in \mathbb{R}^{m \times n}, \quad \lambda \left(\frac{1}{m} A^T A \right) \in [\mu; L].$$

Linear Least Squares with ℓ_1 Regularization (LASSO).
 $m=1000, n=100, \lambda=0.1, \mu=0, L=10$. Optimal sparsity: $1.0e-02$




Рис. 7: Негладкий выпуклый случай. Малое значение λ делает задачу негладкой. Нет сходимости при постоянном шаге

Численные эксперименты

$$f(x) = \frac{1}{2m} \|Ax - b\|_2^2 + \lambda \|x\|_1 \rightarrow \min_{x \in \mathbb{R}^n}, \quad A \in \mathbb{R}^{m \times n}, \quad \lambda \left(\frac{1}{m} A^T A \right) \in [\mu; L].$$

Linear Least Squares with ℓ_1 Regularization (LASSO).
 $m=1000, n=100, \lambda=1, \mu=0, L=10$. Optimal sparsity: 7.0×10^{-2}




Рис. 8: Негладкий выпуклый случай. Большее значение λ проявляет немонотонность $f(x_k)$. Меньший постоянный шаг приводит к более низкому стационарному уровню

Численные эксперименты

$$f(x) = \frac{1}{2m} \|Ax - b\|_2^2 + \lambda \|x\|_1 \rightarrow \min_{x \in \mathbb{R}^n}, \quad A \in \mathbb{R}^{m \times n}, \quad \lambda \left(\frac{1}{m} A^T A \right) \in [\mu; L].$$

Linear Least Squares with ℓ_1 Regularization (LASSO).
 $m=100, n=100, \lambda=1, \mu=0, L=10$. Optimal sparsity: $2.3e-01$




Рис. 9: Негладкий выпуклый случай. Убывающий шаг обеспечивает сходимость f_k^{best}

Численные эксперименты

$$f(x) = \frac{1}{2m} \|Ax - b\|_2^2 + \lambda \|x\|_1 \rightarrow \min_{x \in \mathbb{R}^n}, \quad A \in \mathbb{R}^{m \times n}, \quad \lambda \left(\frac{1}{m} A^T A \right) \in [\mu; L].$$

Linear Least Squares with ℓ_1 Regularization (LASSO).
 $m=100, n=100, \lambda=1, \mu=0, L=10$. Optimal sparsity: 2.3e-01




Рис. 10: Негладкий выпуклый случай. Шаг $\frac{\alpha_0}{\sqrt{k}}$ обеспечивает сходимость f_k^{best}

Численные эксперименты

$$f(x) = \frac{1}{2m} \|Ax - b\|_2^2 + \lambda \|x\|_1 \rightarrow \min_{x \in \mathbb{R}^n}, \quad A \in \mathbb{R}^{m \times n}, \quad \lambda \left(\frac{1}{m} A^T A \right) \in [\mu; L].$$

Linear Least Squares with ℓ_1 Regularization (LASSO).
 $m=100, n=100, \lambda=1, \mu=0, L=10$. Optimal sparsity: $2.3e-01$




Рис. 11: Негладкий выпуклый случай. Шаг $\frac{\alpha_0}{\sqrt{k}}$ обеспечивает сходимость f_k^{best}

Численные эксперименты

$$f(x) = \frac{1}{2m} \|Ax - b\|_2^2 + \lambda \|x\|_1 \rightarrow \min_{x \in \mathbb{R}^n}, \quad A \in \mathbb{R}^{m \times n}, \quad \lambda \left(\frac{1}{m} A^T A \right) \in [\mu; L].$$

Linear Least Squares with ℓ_1 Regularization (LASSO).
 $m=100, n=100, \lambda=1, \mu=1, L=10$. Optimal sparsity: $2.0e-01$




Рис. 12: Негладкий сильно выпуклый случай. Шаг $\frac{\alpha_0}{k}$ обеспечивает сходимость f_k^{best}

Численные эксперименты

$$f(x) = \frac{1}{2m} \|Ax - b\|_2^2 + \lambda \|x\|_1 \rightarrow \min_{x \in \mathbb{R}^n}, \quad A \in \mathbb{R}^{m \times n}, \quad \lambda \left(\frac{1}{m} A^T A \right) \in [\mu; L].$$

Linear Least Squares with ℓ_1 Regularization (LASSO).
 $m=100, n=100, \lambda=1, \mu=1, L=10$. Optimal sparsity: 2.0×10^{-1}




Рис. 13: Негладкий сильно выпуклый случай. Шаг $\frac{\alpha_0}{\sqrt{k}}$ работает хуже

Численные эксперименты

$$f(x) = \frac{1}{m} \sum_{i=1}^m \log(1 + \exp(-b_i(A_i x))) + \lambda \|x\|_1 \rightarrow \min_{x \in \mathbb{R}^n}, \quad A_i \in \mathbb{R}^n, \quad b_i \in \{-1, 1\}$$

Binary Logistic Regression with ℓ_1 Regularization.
m=300, n=50, $\lambda=0.1$. Optimal sparsity: 8.6e-01




Рис. 14: Логистическая регрессия с ℓ_1 -регуляризацией

Численные эксперименты

$$f(x) = \frac{1}{m} \sum_{i=1}^m \log(1 + \exp(-b_i(A_i x))) + \lambda \|x\|_1 \rightarrow \min_{x \in \mathbb{R}^n}, \quad A_i \in \mathbb{R}^n, \quad b_i \in \{-1, 1\}$$

Binary Logistic Regression with ℓ_1 Regularization.
 $m=300$, $n=50$, $\lambda=0.1$. Optimal sparsity: $8.6e-01$




Рис. 15: Логистическая регрессия с ℓ_1 -регуляризацией

Численные эксперименты

$$f(x) = \frac{1}{m} \sum_{i=1}^m \log(1 + \exp(-b_i(A_i x))) + \lambda \|x\|_1 \rightarrow \min_{x \in \mathbb{R}^n}, \quad A_i \in \mathbb{R}^n, \quad b_i \in \{-1, 1\}$$

Binary Logistic Regression with ℓ_1 Regularization.
m=300, n=50, $\lambda=0.25$. Optimal sparsity: 9.6e-01




Рис. 16: Логистическая регрессия с ℓ_1 -регуляризацией

Численные эксперименты

$$f(x) = \frac{1}{m} \sum_{i=1}^m \log(1 + \exp(-b_i(A_i x))) + \lambda \|x\|_1 \rightarrow \min_{x \in \mathbb{R}^n}, \quad A_i \in \mathbb{R}^n, \quad b_i \in \{-1, 1\}$$

Binary Logistic Regression with ℓ_1 Regularization.
m=300, n=50, $\lambda=0.25$. Optimal sparsity: 9.6e-01




Рис. 17: Логистическая регрессия с ℓ_1 -регуляризацией

Численные эксперименты

$$f(x) = \frac{1}{m} \sum_{i=1}^m \log(1 + \exp(-b_i(A_i x))) + \lambda \|x\|_1 \rightarrow \min_{x \in \mathbb{R}^n}, \quad A_i \in \mathbb{R}^n, \quad b_i \in \{-1, 1\}$$

Binary Logistic Regression with ℓ_1 Regularization.
m=300, n=50, $\lambda=0.27$. Optimal sparsity: 1.0e+00




Рис. 18: Логистическая регрессия с ℓ_1 -регуляризацией

Численные эксперименты

$$f(x) = \frac{1}{m} \sum_{i=1}^m \log(1 + \exp(-b_i(A_i x))) + \lambda \|x\|_1 \rightarrow \min_{x \in \mathbb{R}^n}, \quad A_i \in \mathbb{R}^n, \quad b_i \in \{-1, 1\}$$

Binary Logistic Regression with ℓ_1 Regularization.
m=300, n=50, $\lambda=0.27$. Optimal sparsity: 1.0e+00




Рис. 19: Логистическая регрессия с ℓ_1 -регуляризацией

Нижние оценки

Нижние оценки

выпуклая (негладкая) ³	гладкая (невыпуклая) ⁴	гладкая & выпуклая ⁵	гладкая & сильно выпуклая (или PL) ¹
$\mathcal{O}\left(\frac{1}{\sqrt{k}}\right)$	$\mathcal{O}\left(\frac{1}{k^2}\right)$	$\mathcal{O}\left(\frac{1}{k^2}\right)$	$\mathcal{O}\left(\left(\frac{\sqrt{\kappa}-1}{\sqrt{\kappa}+1}\right)^k\right)$
$k_\varepsilon \sim \mathcal{O}\left(\frac{1}{\varepsilon^2}\right)$	$k_\varepsilon \sim \mathcal{O}\left(\frac{1}{\sqrt{\varepsilon}}\right)$	$k_\varepsilon \sim \mathcal{O}\left(\frac{1}{\sqrt{\varepsilon}}\right)$	$k_\varepsilon \sim \mathcal{O}\left(\sqrt{\kappa} \log \frac{1}{\varepsilon}\right)$

³Nesterov, Lectures on Convex Optimization

⁴Carmon, Duchi, Hinder, Sidford, 2017

⁵Nemirovski, Yudin, 1979

Итерация «чёрного ящика»

Итерация градиентного спуска:

$$\begin{aligned}x^{k+1} &= x^k - \alpha^k \nabla f(x^k) \\&= x^{k-1} - \alpha^{k-1} \nabla f(x^{k-1}) - \alpha^k \nabla f(x^k) \\&\vdots \\&= x^0 - \sum_{i=0}^k \alpha^{k-i} \nabla f(x^{k-i})\end{aligned}$$

Итерация «чёрного ящика»

Итерация градиентного спуска:

$$\begin{aligned}x^{k+1} &= x^k - \alpha^k \nabla f(x^k) \\&= x^{k-1} - \alpha^{k-1} \nabla f(x^{k-1}) - \alpha^k \nabla f(x^k) \\&\vdots \\&= x^0 - \sum_{i=0}^k \alpha^{k-i} \nabla f(x^{k-i})\end{aligned}$$

Рассмотрим семейство методов первого порядка, для которых

$$\begin{aligned}x^{k+1} &\in x^0 + \text{span} \{ \nabla f(x^0), \nabla f(x^1), \dots, \nabla f(x^k) \} && f - \text{smooth} \\x^{k+1} &\in x^0 + \text{span} \{ g_0, g_1, \dots, g_k \}, \text{ where } g_i \in \partial f(x^i) && f - \text{non-smooth}\end{aligned} \tag{1}$$

Итерация «чёрного ящика»

Итерация градиентного спуска:

$$\begin{aligned}x^{k+1} &= x^k - \alpha^k \nabla f(x^k) \\&= x^{k-1} - \alpha^{k-1} \nabla f(x^{k-1}) - \alpha^k \nabla f(x^k) \\&\vdots \\&= x^0 - \sum_{i=0}^k \alpha^{k-i} \nabla f(x^{k-i})\end{aligned}$$

Рассмотрим семейство методов первого порядка, для которых

$$\begin{aligned}x^{k+1} &\in x^0 + \text{span} \{ \nabla f(x^0), \nabla f(x^1), \dots, \nabla f(x^k) \} && f - \text{smooth} \\x^{k+1} &\in x^0 + \text{span} \{ g_0, g_1, \dots, g_k \}, \text{ where } g_i \in \partial f(x^i) && f - \text{non-smooth}\end{aligned} \tag{1}$$

Чтобы построить нижнюю оценку, нужно найти функцию f из соответствующего класса так, чтобы любой метод из семейства 1 работал не быстрее, чем предсказано нижней оценкой.

Негладкий выпуклый случай

i Theorem

Существует функция f , которая является G -липшицевой и выпуклой, такая что любой метод 1 удовлетворяет

$$\min_{i \in [1, k]} f(x^i) - \min_{x \in \mathbb{B}(R)} f(x) \geq \frac{GR}{2(1 + \sqrt{k})}$$

для $R > 0$ и $k \leq n$, где n — размерность задачи.

Негладкий выпуклый случай

i Theorem

Существует функция f , которая является G -липшицевой и выпуклой, такая что любой метод 1 удовлетворяет

$$\min_{i \in [1, k]} f(x^i) - \min_{x \in \mathbb{B}(R)} f(x) \geq \frac{GR}{2(1 + \sqrt{k})}$$

для $R > 0$ и $k \leq n$, где n — размерность задачи.

Идея доказательства: построить такую функцию f , что для любого метода 1 выполняется

$$\text{span} \{g_0, g_1, \dots, g_k\} \subset \text{span} \{e_1, e_2, \dots, e_i\}$$

где e_i — i -й вектор стандартного базиса. На итерации $k \leq n$ как минимум $n - k$ координат x равны 0. Это помогает получить оценку погрешности.

Негладкий случай (доказательство)

Рассмотрим функцию:

$$f(x) = \beta \max_{i \in [1, k]} x[i] + \frac{\alpha}{2} \|x\|_2^2,$$

где $\alpha, \beta \in \mathbb{R}$ — параметры, а $x[1 : k]$ обозначает первые k компонент вектора x .

Негладкий случай (доказательство)

Рассмотрим функцию:

$$f(x) = \beta \max_{i \in [1, k]} x[i] + \frac{\alpha}{2} \|x\|_2^2,$$

где $\alpha, \beta \in \mathbb{R}$ — параметры, а $x[1 : k]$ обозначает первые k компонент вектора x .

Ключевые свойства:

- Функция $f(x)$ является α -сильно выпуклой благодаря квадратичному слагаемому $\frac{\alpha}{2} \|x\|_2^2$.

Негладкий случай (доказательство)

Рассмотрим функцию:

$$f(x) = \beta \max_{i \in [1, k]} x[i] + \frac{\alpha}{2} \|x\|_2^2,$$

где $\alpha, \beta \in \mathbb{R}$ — параметры, а $x[1 : k]$ обозначает первые k компонент вектора x .

Ключевые свойства:

- Функция $f(x)$ является α -сильно выпуклой благодаря квадратичному слагаемому $\frac{\alpha}{2} \|x\|_2^2$.
- Функция негладкая, потому что первое слагаемое недифференцируемо в точке, где достигается максимум по координатам x .

Негладкий случай (доказательство)

Рассмотрим функцию:

$$f(x) = \beta \max_{i \in [1, k]} x[i] + \frac{\alpha}{2} \|x\|_2^2,$$

где $\alpha, \beta \in \mathbb{R}$ — параметры, а $x[1 : k]$ обозначает первые k компонент вектора x .

Ключевые свойства:

- Функция $f(x)$ является α -сильно выпуклой благодаря квадратичному слагаемому $\frac{\alpha}{2} \|x\|_2^2$.
- Функция негладкая, потому что первое слагаемое недифференцируемо в точке, где достигается максимум по координатам x .

Негладкий случай (доказательство)

Рассмотрим функцию:

$$f(x) = \beta \max_{i \in [1, k]} x[i] + \frac{\alpha}{2} \|x\|_2^2,$$

где $\alpha, \beta \in \mathbb{R}$ — параметры, а $x[1 : k]$ обозначает первые k компонент вектора x .

Ключевые свойства:

- Функция $f(x)$ является α -сильно выпуклой благодаря квадратичному слагаемому $\frac{\alpha}{2} \|x\|_2^2$.
- Функция негладкая, потому что первое слагаемое недифференцируемо в точке, где достигается максимум по координатам x .

Рассмотрим субдифференциал $f(x)$ в точке x :

$$\begin{aligned} \partial f(x) &= \partial \left(\beta \max_{i \in [1, k]} x[i] \right) + \partial \left(\frac{\alpha}{2} \|x\|_2^2 \right) \\ &= \beta \partial \left(\max_{i \in [1, k]} x[i] \right) + \alpha x \\ &= \beta \text{conv} \left\{ e_i \mid i : x[i] = \max_j x[j] \right\} + \alpha x \end{aligned}$$

Негладкий случай (доказательство)

Рассмотрим функцию:

$$f(x) = \beta \max_{i \in [1, k]} x[i] + \frac{\alpha}{2} \|x\|_2^2,$$

где $\alpha, \beta \in \mathbb{R}$ — параметры, а $x[1 : k]$ обозначает первые k компонент вектора x .

Ключевые свойства:

- Функция $f(x)$ является α -сильно выпуклой благодаря квадратичному слагаемому $\frac{\alpha}{2} \|x\|_2^2$.
- Функция негладкая, потому что первое слагаемое недифференцируемо в точке, где достигается максимум по координатам x .

Рассмотрим субдифференциал $f(x)$ в точке x :

$$\begin{aligned} \partial f(x) &= \partial \left(\beta \max_{i \in [1, k]} x[i] \right) + \partial \left(\frac{\alpha}{2} \|x\|_2^2 \right) \\ &= \beta \partial \left(\max_{i \in [1, k]} x[i] \right) + \alpha x \\ &= \beta \text{conv} \left\{ e_i \mid i : x[i] = \max_j x[j] \right\} + \alpha x \end{aligned}$$

Легко видеть, что если $g \in \partial f(x)$ и $\|x\| \leq R$, то

$$\|g\| \leq \alpha R + \beta$$

Следовательно, f является $\alpha R + \beta$ -липшицевой на $B(R)$.

Негладкий случай (доказательство)

Далее опишем оракул первого порядка для этой функции. При запросе субградиента в точке x оракул возвращает

$$\alpha x + \beta e_i,$$

где i — *первая* координата, для которой $x[i] = \max_{1 \leq j \leq k} x[j]$.

- Гарантируем $\|x^0\| \leq R$, начиная с $x^0 = 0$.

Негладкий случай (доказательство)

Далее опишем оракул первого порядка для этой функции. При запросе субградиента в точке x оракул возвращает

$$\alpha x + \beta e_i,$$

где i — *первая* координата, для которой $x[i] = \max_{1 \leq j \leq k} x[j]$.

- Гарантируем $\|x^0\| \leq R$, начиная с $x^0 = 0$.
- При запросе в точке $x^0 = 0$ оракул возвращает e_1 . Следовательно, x^1 лежит на прямой, порождённой e_1 .

Негладкий случай (доказательство)

Далее опишем оракул первого порядка для этой функции. При запросе субградиента в точке x оракул возвращает

$$\alpha x + \beta e_i,$$

где i — первая координата, для которой $x[i] = \max_{1 \leq j \leq k} x[j]$.

- Гарантируем $\|x^0\| \leq R$, начиная с $x^0 = 0$.
- При запросе в точке $x^0 = 0$ оракул возвращает e_1 . Следовательно, x^1 лежит на прямой, порождённой e_1 .
- По индукции можно показать, что для всех i итерат x^i лежит в линейной оболочке $\{e_1, \dots, e_i\}$. В частности, при $i \leq k$ координата $k+1$ у x_i равна нулю, и из структуры $f(x)$ следует:

$$f(x^i) \geq 0.$$

Негладкий случай (доказательство)

- Осталось вычислить минимальное значение f . Определим точку $y \in \mathbb{R}^n$ как

$$y[i] = -\frac{\beta}{\alpha k} \quad \text{for } 1 \leq i \leq k, \quad y[i] = 0 \quad \text{for } k+1 \leq i \leq n.$$

Негладкий случай (доказательство)

- Осталось вычислить минимальное значение f . Определим точку $y \in \mathbb{R}^n$ как

$$y[i] = -\frac{\beta}{\alpha k} \quad \text{for } 1 \leq i \leq k, \quad y[i] = 0 \quad \text{for } k+1 \leq i \leq n.$$

- Заметим, что $0 \in \partial f(y)$:

$$\begin{aligned} \partial f(y) &= \alpha y + \beta \text{conv} \left\{ e_i \mid i : y[i] = \max_j y[j] \right\} \\ &= \alpha y + \beta \text{conv} \{ e_i \mid i : y[i] = 0 \} \\ 0 &\in \partial f(y). \end{aligned}$$

Негладкий случай (доказательство)

- Осталось вычислить минимальное значение f . Определим точку $y \in \mathbb{R}^n$ как

$$y[i] = -\frac{\beta}{\alpha k} \quad \text{for } 1 \leq i \leq k, \quad y[i] = 0 \quad \text{for } k+1 \leq i \leq n.$$

- Заметим, что $0 \in \partial f(y)$:

$$\begin{aligned} \partial f(y) &= \alpha y + \beta \text{conv} \left\{ e_i \mid i : y[i] = \max_j y[j] \right\} \\ &= \alpha y + \beta \text{conv} \{ e_i \mid i : y[i] = 0 \} \\ 0 &\in \partial f(y). \end{aligned}$$

- Следовательно, минимальное значение $f = f(y) = f(x^*)$ равно

$$f(y) = -\frac{\beta^2}{\alpha k} + \frac{\alpha}{2} \cdot \frac{\beta^2}{\alpha^2 k} = -\frac{\beta^2}{2\alpha k}.$$

Негладкий случай (доказательство)

- Осталось вычислить минимальное значение f . Определим точку $y \in \mathbb{R}^n$ как

$$y[i] = -\frac{\beta}{\alpha k} \quad \text{for } 1 \leq i \leq k, \quad y[i] = 0 \quad \text{for } k+1 \leq i \leq n.$$

- Заметим, что $0 \in \partial f(y)$:

$$\begin{aligned} \partial f(y) &= \alpha y + \beta \text{conv} \left\{ e_i \mid i : y[i] = \max_j y[j] \right\} \\ &= \alpha y + \beta \text{conv} \{ e_i \mid i : y[i] = 0 \} \\ 0 &\in \partial f(y). \end{aligned}$$

- Следовательно, минимальное значение $f = f(y) = f(x^*)$ равно

$$f(y) = -\frac{\beta^2}{\alpha k} + \frac{\alpha}{2} \cdot \frac{\beta^2}{\alpha^2 k} = -\frac{\beta^2}{2\alpha k}.$$

- Тогда имеем:

$$f(x^i) - f(x^*) \geq 0 - \left(-\frac{\beta^2}{2\alpha k} \right) \geq \frac{\beta^2}{2\alpha k}.$$

Негладкий случай (доказательство)

Мы получили: $f(x^i) - f(x^*) \geq \frac{\beta^2}{2\alpha k}$, но нам нужно доказать, что $\min_{i \in [1, k]} f(x^i) - f(x^*) \geq \frac{GR}{2(1+\sqrt{k})}$.

Негладкий случай (доказательство)

Мы получили: $f(x^i) - f(x^*) \geq \frac{\beta^2}{2\alpha k}$, но нам нужно доказать, что $\min_{i \in [1, k]} f(x^i) - f(x^*) \geq \frac{GR}{2(1+\sqrt{k})}$.

Выпуклый случай

$$\alpha = \frac{G}{R} \frac{1}{1 + \sqrt{k}} \quad \beta = \frac{\sqrt{k}}{1 + \sqrt{k}}$$

$$\frac{\beta^2}{2\alpha} = \frac{GRk}{2(1 + \sqrt{k})}$$

Заметим, в частности, что $\|y\|_2^2 = \frac{\beta^2}{\alpha^2 k} = R^2$ при этих параметрах

$$\min_{i \in [1, k]} f(x^i) - f(x^*) \geq \frac{\beta^2}{2\alpha k} = \frac{GR}{2(1 + \sqrt{k})}$$

Негладкий случай (доказательство)

Мы получили: $f(x^i) - f(x^*) \geq \frac{\beta^2}{2\alpha k}$, но нам нужно доказать, что $\min_{i \in [1, k]} f(x^i) - f(x^*) \geq \frac{GR}{2(1+\sqrt{k})}$.

Выпуклый случай

$$\alpha = \frac{G}{R} \frac{1}{1 + \sqrt{k}} \quad \beta = \frac{\sqrt{k}}{1 + \sqrt{k}}$$

$$\frac{\beta^2}{2\alpha} = \frac{GRk}{2(1 + \sqrt{k})}$$

Заметим, в частности, что $\|y\|_2^2 = \frac{\beta^2}{\alpha^2 k} = R^2$ при этих параметрах

$$\min_{i \in [1, k]} f(x^i) - f(x^*) \geq \frac{\beta^2}{2\alpha k} = \frac{GR}{2(1 + \sqrt{k})}$$

Сильно выпуклый случай

$$\alpha = \frac{G}{2R} \quad \beta = \frac{G}{2}$$

Заметим, в частности, что $\|y\|_2^2 = \frac{\beta^2}{\alpha^2 k} = \frac{G^2}{4\alpha^2 k} = R^2$ при этих параметрах

$$\min_{i \in [1, k]} f(x^i) - f(x^*) \geq \frac{G^2}{8\alpha k}$$

Приложения

Линейные наименьшие квадраты с l_1 -регуляризацией



$$\min_{x \in \mathbb{R}^n} \frac{1}{2} \|Ax - b\|_2^2 + \lambda \|x\|_1$$

Алгоритм можно записать так:

$$x_{k+1} = x_k - \alpha_k (A^\top (Ax_k - b) + \lambda \text{sign}(x_k)) ,$$

где функция знака применяется поэлементно.

LLS with l_1 regularization. 2 runs. $\lambda = 1$



Логистическая регрессия с регуляризацией

Пусть $(x_i, y_i) \in \mathbb{R}^p \times \{0, 1\}$ для $i = 1, \dots, n$. Тогда функция логистической регрессии задаётся как:

$$f(\theta) = \sum_{i=1}^n (-y_i x_i^T \theta + \log(1 + \exp(x_i^T \theta)))$$

Это гладкая выпуклая функция; её градиент равен:

$$\nabla f(\theta) = \sum_{i=1}^n (y_i - s_i(\theta)) x_i$$

где $s_i(\theta) = \frac{\exp(x_i^T \theta)}{1 + \exp(x_i^T \theta)}$, $i = 1, \dots, n$. Рассмотрим регуляризованную задачу:

$$f(\theta) + \lambda r(\theta) \rightarrow \min_{\theta}$$

где $r(\theta) = \|\theta\|_2^2$ соответствует гребневой (ridge) регуляризации, а $r(\theta) = \|\theta\|_1$ — лассо (lasso).

Метод опорных векторов

Пусть $D = \{(x_i, y_i) \mid x_i \in \mathbb{R}^n, y_i \in \{\pm 1\}\}$

Нужно найти $\theta \in \mathbb{R}^n$ и $b \in \mathbb{R}$ такие, что

$$\min_{\theta \in \mathbb{R}^n, b \in \mathbb{R}} \frac{1}{2} \|\theta\|_2^2 + C \sum_{i=1}^m \max[0, 1 - y_i(\theta^\top x_i + b)]$$

Метод опорных векторов. Субградиент

Субградиент hinge loss $h(\theta) = \max[0, 1 - y_i(\theta^\top x_i + b)]$:

$$\partial_\theta h = \begin{cases} 0, & \text{если } y_i(\theta^\top x_i + b) > 1 \\ -y_i x_i, & \text{если } y_i(\theta^\top x_i + b) < 1 \\ [-y_i x_i, 0], & \text{если } y_i(\theta^\top x_i + b) = 1 \end{cases}$$

Метод опорных векторов. Субградиент

Субградиент hinge loss $h(\theta) = \max[0, 1 - y_i(\theta^\top x_i + b)]$:

$$\partial_\theta h = \begin{cases} 0, & \text{если } y_i(\theta^\top x_i + b) > 1 \\ -y_i x_i, & \text{если } y_i(\theta^\top x_i + b) < 1 \\ [-y_i x_i, 0], & \text{если } y_i(\theta^\top x_i + b) = 1 \end{cases}$$

Итерация субградиентного метода (для упрощённой SVM без b):

$$\theta_{k+1} = \theta_k - \alpha_k \left(\theta_k - C \frac{1}{m} \sum_{i: y_i \theta_k^\top x_i < 1} y_i x_i \right)$$

Метод опорных векторов. Численные эксперименты

SVM (Hinge Loss + ℓ_2 -регуляризация). $m=400$, $n=30$, $C=1.0$




Рис. 21: Субградиентный метод для SVM. Сравнение различных стратегий выбора шага

Метод опорных векторов. Немонотонность

SVM. Немонотонность субградиентного метода. $m=400$, $n=30$, $C=1.0$




Рис. 22: Немонотонность $f(\theta_k)$ при постоянном шаге. Убывающий шаг уменьшает осцилляции. Сходимость по аргументу зависит от стратегии


Дополнительные эксперименты

Скорость сходимости: теория vs практика


$$f(x) = \frac{1}{m} \|Ax - b\|_1$$

Скорость сходимости субградиентного метода: теория vs практика

Выпуклый: $f(x) = \frac{1}{m} \|Ax - b\|_1$



Сильно выпуклый: $f(x) = \frac{1}{m} \|Ax - b\|_1 + \frac{\mu}{2} \|x\|^2$




Шаг Поляка

$$\alpha_k = \frac{f(x_k) - f^*}{\|g_k\|^2}$$


Если известно оптимальное значение f^* , шаг Поляка значительно ускоряет сходимость субградиентного метода.

$f(x) = \frac{1}{m} \|Ax - b\|_1$. Шаг Поляка vs стандартные стратегии. $m=200$, $n=50$


Function Gap



Distance to Optimal Solution



Polyak: немонотонность




— $\alpha_k = 0.1$ — $\alpha_k = R/(G\sqrt{k})$ — $\alpha_k = 2/k$ — Polyak: $(f(x_k) - f^*)/\|g_k\|^2$

Влияние размерности задачи


$$f(x) = \frac{1}{m} \|Ax - b\|_1, \quad \alpha_k = \frac{R}{G\sqrt{k}}$$

Влияние размерности n на сходимость. $f(x) = \frac{1}{m} \|Ax - b\|_1$, $m = 500$, $\alpha_k = R/(G\sqrt{k})$

Линейная шкала



Лог-лог шкала



- Subgradient Methods Stephen Boyd (with help from Jaehyun Park)