



**Негладкая выпуклая оптимизация. Нижние  
оценки. Субградиентный метод.**

**Даниил Меркулов**


Методы оптимизации. МФТИ

## Негладкие задачи


# Линейный МНК с $\ell_1$ -регуляризацией

$\ell_1$  induces sparsity

$\ell_2$  regularization.  $\|Xw - y\|_2^2 \rightarrow \min_{\|w\|_2 \leq 1}$



$\ell_1$  regularization.  $\|Xw - y\|_2^2 \rightarrow \min_{\|w\|_1 \leq 1}$




@fminxyz

# Нормы не являются гладкими


$$\min_{x \in \mathbb{R}^n} f(x),$$

Рассмотрим классическую задачу выпуклой оптимизации. Предположим, что  $f(x)$  выпукла, но теперь мы не требуем гладкости.

$p = 1$  Norm Cone



$p = 2$  Norm Cone



$p = \infty$  Norm Cone




Рис. 1: Конусы норм для разных  $p$ : нормы негладкие

# Пример Вульфа

Wolfe's example





Рис. 2: Пример Вульфа. [Открыть в Colab](#)

# Субградиентное исчисление

## Линейная нижняя оценка выпуклой функции




Важное свойство непрерывной выпуклой функции  $f(x)$  состоит в том, что в любой выбранной точке  $x_0$  для всех  $x \in \text{dom } f$  выполняется неравенство:

$$f(x) \geq f(x_0) + \langle g, x - x_0 \rangle$$

Рис. 3: Линейная аппроксимация по Тейлору является глобальной нижней оценкой выпуклой функции

## Линейная нижняя оценка выпуклой функции



Важное свойство непрерывной выпуклой функции  $f(x)$  состоит в том, что в любой выбранной точке  $x_0$  для всех  $x \in \text{dom } f$  выполняется неравенство:

$$f(x) \geq f(x_0) + \langle g, x - x_0 \rangle$$


для некоторого вектора  $g$ , то есть касательная к графику функции даёт глобальную нижнюю оценку функции.

- Если  $f(x)$  дифференцируема, то  $g = \nabla f(x_0)$

Рис. 3: Линейная аппроксимация по Тейлору является глобальной нижней оценкой выпуклой функции



## Линейная нижняя оценка выпуклой функции



Важное свойство непрерывной выпуклой функции  $f(x)$  состоит в том, что в любой выбранной точке  $x_0$  для всех  $x \in \text{dom } f$  выполняется неравенство:


$$f(x) \geq f(x_0) + \langle g, x - x_0 \rangle$$

для некоторого вектора  $g$ , то есть касательная к графику функции даёт глобальную нижнюю оценку функции.

- Если  $f(x)$  дифференцируема, то  $g = \nabla f(x_0)$
- Не всякая непрерывная выпуклая функция дифференцируема.

Рис. 3: Линейная аппроксимация по Тейлору является глобальной нижней оценкой выпуклой функции

## Линейная нижняя оценка выпуклой функции



Важное свойство непрерывной выпуклой функции  $f(x)$  состоит в том, что в любой выбранной точке  $x_0$  для всех  $x \in \text{dom } f$  выполняется неравенство:


$$f(x) \geq f(x_0) + \langle g, x - x_0 \rangle$$

для некоторого вектора  $g$ , то есть касательная к графику функции даёт глобальную нижнюю оценку функции.

- Если  $f(x)$  дифференцируема, то  $g = \nabla f(x_0)$
- Не всякая непрерывная выпуклая функция дифференцируема.

Рис. 3: Линейная аппроксимация по Тейлору является глобальной нижней оценкой выпуклой функции

## Линейная нижняя оценка выпуклой функции



Важное свойство непрерывной выпуклой функции  $f(x)$  состоит в том, что в любой выбранной точке  $x_0$  для всех  $x \in \text{dom } f$  выполняется неравенство:

$$f(x) \geq f(x_0) + \langle g, x - x_0 \rangle$$

для некоторого вектора  $g$ , то есть касательная к графику функции даёт глобальную нижнюю оценку функции.

- Если  $f(x)$  дифференцируема, то  $g = \nabla f(x_0)$
- Не всякая непрерывная выпуклая функция дифференцируема.

Нам не хочется терять это прекрасное свойство.

Рис. 3: Линейная аппроксимация по Тейлору является глобальной нижней оценкой выпуклой функции

## Субградиент и субдифференциал

Вектор  $g$  называется **субградиентом** функции  $f(x) : S \rightarrow \mathbb{R}$  в точке  $x_0$ , если  $\forall x \in S$ :

$$f(x) \geq f(x_0) + \langle g, x - x_0 \rangle$$

## Субградиент и субдифференциал

Вектор  $g$  называется **субградиентом** функции  $f(x) : S \rightarrow \mathbb{R}$  в точке  $x_0$ , если  $\forall x \in S$ :

$$f(x) \geq f(x_0) + \langle g, x - x_0 \rangle$$

Множество всех субградиентов функции  $f(x)$  в точке  $x_0$  называется **субдифференциалом**  $f$  в точке  $x_0$  и обозначается  $\partial f(x_0)$ .

## Субградиент и субдифференциал

Вектор  $g$  называется **субградиентом** функции  $f(x) : S \rightarrow \mathbb{R}$  в точке  $x_0$ , если  $\forall x \in S$ :

$$f(x) \geq f(x_0) + \langle g, x - x_0 \rangle$$

Множество всех субградиентов функции  $f(x)$  в точке  $x_0$  называется **субдифференциалом**  $f$  в точке  $x_0$  и обозначается  $\partial f(x_0)$ .




Рис. 4: Субдифференциал — множество всех возможных субградиентов


# Субградиент и субдифференциал

Найдите  $\partial f(x)$ , если  $f(x) = |x|$


# Субградиент и субдифференциал

Найдите  $\partial f(x)$ , если  $f(x) = |x|$

$$f(x) = |x|$$



$$\partial f(x)$$





# Свойства субдифференциала

- Если  $x_0 \in \text{ri}(S)$ , то  $\partial f(x_0)$  — выпуклое компактное множество.

# Свойства субдифференциала

- Если  $x_0 \in \text{ri}(S)$ , то  $\partial f(x_0)$  — выпуклое компактное множество.
- Если выпуклая функция  $f(x)$  дифференцируема в точке  $x_0$ , то  $\partial f(x_0) = \{\nabla f(x_0)\}$ .

# Свойства субдифференциала

- Если  $x_0 \in \text{ri}(S)$ , то  $\partial f(x_0)$  — выпуклое компактное множество.
- Если выпуклая функция  $f(x)$  дифференцируема в точке  $x_0$ , то  $\partial f(x_0) = \{\nabla f(x_0)\}$ .
- Если  $\partial f(x_0) \neq \emptyset \quad \forall x_0 \in S$ , то  $f(x)$  выпукла на  $S$ .

# Свойства субдифференциала

- Если  $x_0 \in \text{ri}(S)$ , то  $\partial f(x_0)$  — выпуклое компактное множество.
- Если выпуклая функция  $f(x)$  дифференцируема в точке  $x_0$ , то  $\partial f(x_0) = \{\nabla f(x_0)\}$ .
- Если  $\partial f(x_0) \neq \emptyset \quad \forall x_0 \in S$ , то  $f(x)$  выпукла на  $S$ .

# Свойства субдифференциала

- Если  $x_0 \in \text{ri}(S)$ , то  $\partial f(x_0)$  — выпуклое компактное множество.
- Если выпуклая функция  $f(x)$  дифференцируема в точке  $x_0$ , то  $\partial f(x_0) = \{\nabla f(x_0)\}$ .
- Если  $\partial f(x_0) \neq \emptyset \quad \forall x_0 \in S$ , то  $f(x)$  выпукла на  $S$ .

## i Субдифференциал дифференцируемой функции

Пусть  $f : S \rightarrow \mathbb{R}$ ,  $x_0 \in \text{ri}(S)$ . Если  $f$  дифференцируема в точке  $x_0$ , то либо  $\partial f(x_0) = \emptyset$ , либо  $\partial f(x_0) = \{\nabla f(x_0)\}$ . Если  $f$  выпукла, то  $\partial f(x_0) = \{\nabla f(x_0)\}$ .

## Свойства субдифференциала (доказательство)

1. Пусть  $s \in \partial f(x_0)$  и  $v$  — единичный вектор. Для достаточно малых  $t > 0$  выполняется

$$f(x_0 + tv) \geq f(x_0) + t\langle s, v \rangle.$$

Делим на  $t$  и переходим к пределу при  $t \rightarrow 0^+$ :

$$\langle \nabla f(x_0), v \rangle \geq \langle s, v \rangle.$$

## Свойства субдифференциала (доказательство)

1. Пусть  $s \in \partial f(x_0)$  и  $v$  — единичный вектор. Для достаточно малых  $t > 0$  выполняется

$$f(x_0 + tv) \geq f(x_0) + t\langle s, v \rangle.$$

Делим на  $t$  и переходим к пределу при  $t \rightarrow 0^+$ :

$$\langle \nabla f(x_0), v \rangle \geq \langle s, v \rangle.$$

## Свойства субдифференциала (доказательство)

1. Пусть  $s \in \partial f(x_0)$  и  $v$  — единичный вектор. Для достаточно малых  $t > 0$  выполняется

$$f(x_0 + tv) \geq f(x_0) + t\langle s, v \rangle.$$

Делим на  $t$  и переходим к пределу при  $t \rightarrow 0^+$ :

$$\langle \nabla f(x_0), v \rangle \geq \langle s, v \rangle.$$

2. Значит  $\langle \nabla f(x_0) - s, v \rangle \geq 0$  для всех единичных  $v$ ; берём

$$v = -\frac{\nabla f(x_0) - s}{\|\nabla f(x_0) - s\|}$$

и получаем  $s = \nabla f(x_0)$ .



## Свойства субдифференциала (доказательство)

1. Пусть  $s \in \partial f(x_0)$  и  $v$  — единичный вектор. Для достаточно малых  $t > 0$  выполняется

$$f(x_0 + tv) \geq f(x_0) + t\langle s, v \rangle.$$

Делим на  $t$  и переходим к пределу при  $t \rightarrow 0^+$ :

$$\langle \nabla f(x_0), v \rangle \geq \langle s, v \rangle.$$

2. Значит  $\langle \nabla f(x_0) - s, v \rangle \geq 0$  для всех единичных  $v$ ; берём

$$v = -\frac{\nabla f(x_0) - s}{\|\nabla f(x_0) - s\|}$$

и получаем  $s = \nabla f(x_0)$ .

## Свойства субдифференциала (доказательство)

1. Пусть  $s \in \partial f(x_0)$  и  $v$  — единичный вектор. Для достаточно малых  $t > 0$  выполняется

$$f(x_0 + tv) \geq f(x_0) + t\langle s, v \rangle.$$

Делим на  $t$  и переходим к пределу при  $t \rightarrow 0^+$ :

$$\langle \nabla f(x_0), v \rangle \geq \langle s, v \rangle.$$

2. Значит  $\langle \nabla f(x_0) - s, v \rangle \geq 0$  для всех единичных  $v$ ; берём

$$v = -\frac{\nabla f(x_0) - s}{\|\nabla f(x_0) - s\|}$$

и получаем  $s = \nabla f(x_0)$ .

3. Если  $f$  выпукла, то  $f(x) \geq f(x_0) + \langle \nabla f(x_0), x - x_0 \rangle$  для всех  $x \in S$ , то есть  $\nabla f(x_0) \in \partial f(x_0)$  и  $\partial f(x_0) = \{\nabla f(x_0)\}$ .

# Вычисление субдифференциалов

**i** Теорема Моро — Рокафеллара  
(субдифференциал линейной комбинации)

Пусть  $f_i(x)$  — выпуклые функции на выпуклых множествах  $S_i$ ,  $i = \overline{1, n}$ . Тогда если  $\bigcap_{i=1}^n \text{ri}(S_i) \neq$

$\emptyset$ , то функция  $f(x) = \sum_{i=1}^n a_i f_i(x)$ ,  $a_i > 0$

имеет субдифференциал  $\partial_S f(x)$  на множестве  $S = \bigcap_{i=1}^n S_i$ , причём

$$\partial_S f(x) = \sum_{i=1}^n a_i \partial_{S_i} f_i(x)$$

# Вычисление субдифференциалов

**i** Теорема Моро — Рокафеллара  
(субдифференциал линейной комбинации)

Пусть  $f_i(x)$  — выпуклые функции на выпуклых множествах  $S_i$ ,  $i = \overline{1, n}$ . Тогда если  $\bigcap_{i=1}^n \text{ri}(S_i) \neq \emptyset$ , то функция  $f(x) = \sum_{i=1}^n a_i f_i(x)$ ,  $a_i > 0$  имеет субдифференциал  $\partial_S f(x)$  на множестве  $S = \bigcap_{i=1}^n S_i$ , причём

$$\partial_S f(x) = \sum_{i=1}^n a_i \partial_{S_i} f_i(x)$$

**i** Теорема Дубовицкого — Милютина  
(субдифференциал поточечного максимума)

Пусть  $f_i(x)$  — выпуклые функции на открытом выпуклом множестве  $S \subseteq \mathbb{R}^n$ ,  $x_0 \in S$ , и поточечный максимум задан как  $f(x) = \max_i f_i(x)$ . Тогда:

$$\partial_S f(x_0) = \text{conv} \left\{ \bigcup_{i \in I(x_0)} \partial_S f_i(x_0) \right\}, \quad I(x) = \{i \in [1, n] \mid f_i(x) = f(x)\}$$

# Вычисление субдифференциалов

- $\partial(\alpha f)(x) = \alpha \partial f(x)$ , для  $\alpha \geq 0$

# Вычисление субдифференциалов

- $\partial(\alpha f)(x) = \alpha \partial f(x)$ , для  $\alpha \geq 0$
- $\partial(\sum f_i)(x) = \sum \partial f_i(x)$ ,  $f_i$  — выпуклые функции

# Вычисление субдифференциалов

- $\partial(\alpha f)(x) = \alpha \partial f(x)$ , для  $\alpha \geq 0$
- $\partial(\sum f_i)(x) = \sum \partial f_i(x)$ ,  $f_i$  — выпуклые функции
- $\partial(f(Ax + b))(x) = A^T \partial f(Ax + b)$ ,  $f$  — выпуклая функция

# Вычисление субдифференциалов

- $\partial(\alpha f)(x) = \alpha \partial f(x)$ , для  $\alpha \geq 0$
- $\partial(\sum f_i)(x) = \sum \partial f_i(x)$ ,  $f_i$  — выпуклые функции
- $\partial(f(Ax + b))(x) = A^T \partial f(Ax + b)$ ,  $f$  — выпуклая функция
- $z \in \partial f(x)$  тогда и только тогда, когда  $x \in \partial f^*(z)$ .



## Субградиентный метод

# Алгоритм

Вектор  $g$  называется **субградиентом** функции  $f(x) : S \rightarrow \mathbb{R}$  в точке  $x_0$ , если  $\forall x \in S$ :

$$f(x) \geq f(x_0) + \langle g, x - x_0 \rangle$$

# Алгоритм

Вектор  $g$  называется **субградиентом** функции  $f(x) : S \rightarrow \mathbb{R}$  в точке  $x_0$ , если  $\forall x \in S$ :

$$f(x) \geq f(x_0) + \langle g, x - x_0 \rangle$$

Идея очень простая: заменим градиент  $\nabla f(x_k)$  в алгоритме градиентного спуска на субградиент  $g_k$  в точке  $x_k$ :

$$x_{k+1} = x_k - \alpha_k g_k,$$

где  $g_k$  — произвольный субградиент функции  $f(x)$  в точке  $x_k$ ,  $g_k \in \partial f(x_k)$

# Алгоритм

Вектор  $g$  называется **субградиентом** функции  $f(x) : S \rightarrow \mathbb{R}$  в точке  $x_0$ , если  $\forall x \in S$ :

$$f(x) \geq f(x_0) + \langle g, x - x_0 \rangle$$

Идея очень простая: заменим градиент  $\nabla f(x_k)$  в алгоритме градиентного спуска на субградиент  $g_k$  в точке  $x_k$ :

$$x_{k+1} = x_k - \alpha_k g_k,$$

где  $g_k$  — произвольный субградиент функции  $f(x)$  в точке  $x_k$ ,  $g_k \in \partial f(x_k)$

Заметим, что **субградиентный метод не обязан быть методом спуска**: отрицательный субградиент может не быть направлением спуска, а выбор шага может привести к  $f(x_{k+1}) > f(x_k)$ .

Поэтому обычно отслеживают лучшее достигнутое значение целевой функции

$$f_k^{\text{best}} = \min_{i=1, \dots, k} f(x_i).$$

# Оценка сходимости

$$\|x_{k+1} - x^*\|^2 = \|x_k - x^* - \alpha_k g_k\|^2 =$$

## Оценка сходимости

$$\begin{aligned}\|x_{k+1} - x^*\|^2 &= \|x_k - x^* - \alpha_k g_k\|^2 = \\ &= \|x_k - x^*\|^2 + \alpha_k^2 \|g_k\|^2 - 2\alpha_k \langle g_k, x_k - x^* \rangle\end{aligned}$$

## Оценка сходимости

$$\begin{aligned}\|x_{k+1} - x^*\|^2 &= \|x_k - x^* - \alpha_k g_k\|^2 = \\ &= \|x_k - x^*\|^2 + \alpha_k^2 \|g_k\|^2 - 2\alpha_k \langle g_k, x_k - x^* \rangle \\ &\leq \|x_k - x^*\|^2 + \alpha_k^2 \|g_k\|^2 - 2\alpha_k (f(x_k) - f(x^*))\end{aligned}$$

## Оценка сходимости

$$\begin{aligned}\|x_{k+1} - x^*\|^2 &= \|x_k - x^* - \alpha_k g_k\|^2 = \\ &= \|x_k - x^*\|^2 + \alpha_k^2 \|g_k\|^2 - 2\alpha_k \langle g_k, x_k - x^* \rangle \\ &\leq \|x_k - x^*\|^2 + \alpha_k^2 \|g_k\|^2 - 2\alpha_k (f(x_k) - f(x^*))\end{aligned}$$

$$2\alpha_k (f(x_k) - f(x^*)) \leq \|x_k - x^*\|^2 - \|x_{k+1} - x^*\|^2 + \alpha_k^2 \|g_k\|^2$$



## Оценка сходимости

$$\begin{aligned}\|x_{k+1} - x^*\|^2 &= \|x_k - x^* - \alpha_k g_k\|^2 = \\ &= \|x_k - x^*\|^2 + \alpha_k^2 \|g_k\|^2 - 2\alpha_k \langle g_k, x_k - x^* \rangle \\ &\leq \|x_k - x^*\|^2 + \alpha_k^2 \|g_k\|^2 - 2\alpha_k (f(x_k) - f(x^*))\end{aligned}$$

$$2\alpha_k (f(x_k) - f(x^*)) \leq \|x_k - x^*\|^2 - \|x_{k+1} - x^*\|^2 + \alpha_k^2 \|g_k\|^2$$

## Оценка сходимости

$$\begin{aligned}\|x_{k+1} - x^*\|^2 &= \|x_k - x^* - \alpha_k g_k\|^2 = \\ &= \|x_k - x^*\|^2 + \alpha_k^2 \|g_k\|^2 - 2\alpha_k \langle g_k, x_k - x^* \rangle \\ &\leq \|x_k - x^*\|^2 + \alpha_k^2 \|g_k\|^2 - 2\alpha_k (f(x_k) - f(x^*))\end{aligned}$$

$$2\alpha_k (f(x_k) - f(x^*)) \leq \|x_k - x^*\|^2 - \|x_{k+1} - x^*\|^2 + \alpha_k^2 \|g_k\|^2$$

Просуммируем полученное неравенство по  $k = 0, \dots, T-1$ :

$$\sum_{k=0}^{T-1} 2\alpha_k (f(x_k) - f(x^*)) \leq \|x_0 - x^*\|^2 - \|x_T - x^*\|^2 + \sum_{k=0}^{T-1} \alpha_k^2 \|g_k\|^2$$

## Оценка сходимости

$$\begin{aligned}\|x_{k+1} - x^*\|^2 &= \|x_k - x^* - \alpha_k g_k\|^2 = \\ &= \|x_k - x^*\|^2 + \alpha_k^2 \|g_k\|^2 - 2\alpha_k \langle g_k, x_k - x^* \rangle \\ &\leq \|x_k - x^*\|^2 + \alpha_k^2 \|g_k\|^2 - 2\alpha_k (f(x_k) - f(x^*))\end{aligned}$$

$$2\alpha_k (f(x_k) - f(x^*)) \leq \|x_k - x^*\|^2 - \|x_{k+1} - x^*\|^2 + \alpha_k^2 \|g_k\|^2$$

Просуммируем полученное неравенство по  $k = 0, \dots, T-1$ :

$$\begin{aligned}\sum_{k=0}^{T-1} 2\alpha_k (f(x_k) - f(x^*)) &\leq \|x_0 - x^*\|^2 - \|x_T - x^*\|^2 + \sum_{k=0}^{T-1} \alpha_k^2 \|g_k\|^2 \\ &\leq \|x_0 - x^*\|^2 + \sum_{k=0}^{T-1} \alpha_k^2 \|g_k\|^2\end{aligned}$$

## Оценка сходимости

$$\begin{aligned}\|x_{k+1} - x^*\|^2 &= \|x_k - x^* - \alpha_k g_k\|^2 = \\ &= \|x_k - x^*\|^2 + \alpha_k^2 \|g_k\|^2 - 2\alpha_k \langle g_k, x_k - x^* \rangle \\ &\leq \|x_k - x^*\|^2 + \alpha_k^2 \|g_k\|^2 - 2\alpha_k (f(x_k) - f(x^*))\end{aligned}$$

$$2\alpha_k (f(x_k) - f(x^*)) \leq \|x_k - x^*\|^2 - \|x_{k+1} - x^*\|^2 + \alpha_k^2 \|g_k\|^2$$

Просуммируем полученное неравенство по  $k = 0, \dots, T-1$ :

$$\begin{aligned}\sum_{k=0}^{T-1} 2\alpha_k (f(x_k) - f(x^*)) &\leq \|x_0 - x^*\|^2 - \|x_T - x^*\|^2 + \sum_{k=0}^{T-1} \alpha_k^2 \|g_k\|^2 \\ &\leq \|x_0 - x^*\|^2 + \sum_{k=0}^{T-1} \alpha_k^2 \|g_k\|^2 \\ &\leq R^2 + G^2 \sum_{k=0}^{T-1} \alpha_k^2\end{aligned}$$

## Оценка сходимости

$$\begin{aligned}\|x_{k+1} - x^*\|^2 &= \|x_k - x^* - \alpha_k g_k\|^2 = \\ &= \|x_k - x^*\|^2 + \alpha_k^2 \|g_k\|^2 - 2\alpha_k \langle g_k, x_k - x^* \rangle \\ &\leq \|x_k - x^*\|^2 + \alpha_k^2 \|g_k\|^2 - 2\alpha_k (f(x_k) - f(x^*))\end{aligned}$$

$$2\alpha_k (f(x_k) - f(x^*)) \leq \|x_k - x^*\|^2 - \|x_{k+1} - x^*\|^2 + \alpha_k^2 \|g_k\|^2$$

Просуммируем полученное неравенство по  $k = 0, \dots, T-1$ :

$$\begin{aligned}\sum_{k=0}^{T-1} 2\alpha_k (f(x_k) - f(x^*)) &\leq \|x_0 - x^*\|^2 - \|x_T - x^*\|^2 + \sum_{k=0}^{T-1} \alpha_k^2 \|g_k\|^2 \\ &\leq \|x_0 - x^*\|^2 + \sum_{k=0}^{T-1} \alpha_k^2 \|g_k\|^2 \\ &\leq R^2 + G^2 \sum_{k=0}^{T-1} \alpha_k^2\end{aligned}$$

- Запишем, насколько близко мы подошли к оптимуму  $x^* = \arg \min_{x \in \mathbb{R}^n} f(x) = \arg f^*$  на последней итерации:

## Оценка сходимости

$$\begin{aligned}\|x_{k+1} - x^*\|^2 &= \|x_k - x^* - \alpha_k g_k\|^2 = \\ &= \|x_k - x^*\|^2 + \alpha_k^2 \|g_k\|^2 - 2\alpha_k \langle g_k, x_k - x^* \rangle \\ &\leq \|x_k - x^*\|^2 + \alpha_k^2 \|g_k\|^2 - 2\alpha_k (f(x_k) - f(x^*))\end{aligned}$$

$$2\alpha_k (f(x_k) - f(x^*)) \leq \|x_k - x^*\|^2 - \|x_{k+1} - x^*\|^2 + \alpha_k^2 \|g_k\|^2$$

Просуммируем полученное неравенство по  $k = 0, \dots, T-1$ :

$$\begin{aligned}\sum_{k=0}^{T-1} 2\alpha_k (f(x_k) - f(x^*)) &\leq \|x_0 - x^*\|^2 - \|x_T - x^*\|^2 + \sum_{k=0}^{T-1} \alpha_k^2 \|g_k\|^2 \\ &\leq \|x_0 - x^*\|^2 + \sum_{k=0}^{T-1} \alpha_k^2 \|g_k\|^2 \\ &\leq R^2 + G^2 \sum_{k=0}^{T-1} \alpha_k^2\end{aligned}$$

- Запишем, насколько близко мы подошли к оптимуму  $x^* = \arg \min_{x \in \mathbb{R}^n} f(x) = \arg f^*$  на последней итерации:
- Для субградиента:  $\langle g_k, x^* - x_k \rangle \leq f(x^*) - f(x_k)$ .

## Оценка сходимости

$$\begin{aligned}\|x_{k+1} - x^*\|^2 &= \|x_k - x^* - \alpha_k g_k\|^2 = \\ &= \|x_k - x^*\|^2 + \alpha_k^2 \|g_k\|^2 - 2\alpha_k \langle g_k, x_k - x^* \rangle \\ &\leq \|x_k - x^*\|^2 + \alpha_k^2 \|g_k\|^2 - 2\alpha_k (f(x_k) - f(x^*)) \\ 2\alpha_k (f(x_k) - f(x^*)) &\leq \|x_k - x^*\|^2 - \|x_{k+1} - x^*\|^2 + \alpha_k^2 \|g_k\|^2\end{aligned}$$

Просуммируем полученное неравенство по  $k = 0, \dots, T-1$ :

$$\begin{aligned}\sum_{k=0}^{T-1} 2\alpha_k (f(x_k) - f(x^*)) &\leq \|x_0 - x^*\|^2 - \|x_T - x^*\|^2 + \sum_{k=0}^{T-1} \alpha_k^2 \|g_k\|^2 \\ &\leq \|x_0 - x^*\|^2 + \sum_{k=0}^{T-1} \alpha_k^2 \|g_k\|^2 \\ &\leq R^2 + G^2 \sum_{k=0}^{T-1} \alpha_k^2\end{aligned}$$

- Запишем, насколько близко мы подошли к оптимуму  $x^* = \arg \min_{x \in \mathbb{R}^n} f(x) = \arg f^*$  на последней итерации:
- Для субградиента:  $\langle g_k, x^* - x_k \rangle \leq f(x^*) - f(x_k)$ .
- Дополнительно предположим, что  $\|g_k\|^2 \leq G^2$

## Оценка сходимости

$$\begin{aligned}\|x_{k+1} - x^*\|^2 &= \|x_k - x^* - \alpha_k g_k\|^2 = \\ &= \|x_k - x^*\|^2 + \alpha_k^2 \|g_k\|^2 - 2\alpha_k \langle g_k, x_k - x^* \rangle \\ &\leq \|x_k - x^*\|^2 + \alpha_k^2 \|g_k\|^2 - 2\alpha_k (f(x_k) - f(x^*))\end{aligned}$$

$$2\alpha_k (f(x_k) - f(x^*)) \leq \|x_k - x^*\|^2 - \|x_{k+1} - x^*\|^2 + \alpha_k^2 \|g_k\|^2$$

Просуммируем полученное неравенство по  $k = 0, \dots, T-1$ :

$$\begin{aligned}\sum_{k=0}^{T-1} 2\alpha_k (f(x_k) - f(x^*)) &\leq \|x_0 - x^*\|^2 - \|x_T - x^*\|^2 + \sum_{k=0}^{T-1} \alpha_k^2 \|g_k\|^2 \\ &\leq \|x_0 - x^*\|^2 + \sum_{k=0}^{T-1} \alpha_k^2 \|g_k\|^2 \\ &\leq R^2 + G^2 \sum_{k=0}^{T-1} \alpha_k^2\end{aligned}$$

- Запишем, насколько близко мы подошли к оптимуму  $x^* = \arg \min_{x \in \mathbb{R}^n} f(x) = \arg f^*$  на последней итерации:
- Для субградиента:  $\langle g_k, x^* - x_k \rangle \leq f(x^*) - f(x_k)$ .
- Дополнительно предположим, что  $\|g_k\|^2 \leq G^2$
- Используем обозначение  $R = \|x_0 - x^*\|_2$



## Оценка сходимости

- Наконец, заметим:

$$\sum_{k=0}^{T-1} 2\alpha_k (f(x_k) - f(x^*)) \geq \sum_{k=0}^{T-1} 2\alpha_k (f_k^{\text{best}} - f(x^*)) = (f_k^{\text{best}} - f(x^*)) \sum_{k=0}^{T-1} 2\alpha_k$$

## Оценка сходимости

- Наконец, заметим:

$$\sum_{k=0}^{T-1} 2\alpha_k (f(x_k) - f(x^*)) \geq \sum_{k=0}^{T-1} 2\alpha_k (f_k^{\text{best}} - f(x^*)) = (f_k^{\text{best}} - f(x^*)) \sum_{k=0}^{T-1} 2\alpha_k$$

- что приводит к базовому неравенству:

$$f_k^{\text{best}} - f(x^*) \leq \frac{R^2 + G^2 \sum_{k=0}^{T-1} \alpha_k^2}{2 \sum_{k=0}^{T-1} \alpha_k}$$

## Оценка сходимости

- Наконец, заметим:

$$\sum_{k=0}^{T-1} 2\alpha_k (f(x_k) - f(x^*)) \geq \sum_{k=0}^{T-1} 2\alpha_k (f_k^{\text{best}} - f(x^*)) = (f_k^{\text{best}} - f(x^*)) \sum_{k=0}^{T-1} 2\alpha_k$$

- что приводит к базовому неравенству:







$$f_k^{\text{best}} - f(x^*) \leq \frac{R^2 + G^2 \sum_{k=0}^{T-1} \alpha_k^2}{2 \sum_{k=0}^{T-1} \alpha_k}$$

- Отсюда видно, что если стратегия выбора шага такова, что







$$\sum_{k=0}^{T-1} \alpha_k^2 < \infty, \quad \sum_{k=0}^{T-1} \alpha_k = \infty,$$

то субградиентный метод сходится (шаг должен убывать, но не слишком быстро).

## Различные стратегии выбора шага



# Различные стратегии выбора шага



## Оценка сходимости. Негладкий выпуклый случай. Постоянный шаг

### Theorem

Пусть  $f$  — выпуклая  $G$ -липшицева функция и  $R = \|x_0 - x^*\|_2$ . Тогда при фиксированном шаге  $\alpha$  субградиентный метод удовлетворяет оценке

$$f_k^{\text{best}} - f(x^*) \leq \frac{R^2}{2\alpha k} + \frac{\alpha}{2} G^2$$

- Заметим, что при любом постоянном шаге первый член правой части убывает, но второй остаётся постоянным.

## Оценка сходимости. Негладкий выпуклый случай. Постоянный шаг

### i Theorem

Пусть  $f$  — выпуклая  $G$ -липшицева функция и  $R = \|x_0 - x^*\|_2$ . Тогда при фиксированном шаге  $\alpha$  субградиентный метод удовлетворяет оценке

$$f_k^{\text{best}} - f(x^*) \leq \frac{R^2}{2\alpha k} + \frac{\alpha}{2} G^2$$

- Заметим, что при любом постоянном шаге первый член правой части убывает, но второй остаётся постоянным.
- Некоторые варианты субградиентного метода (например, убывающие несуммируемые длины шагов) работают и когда предположение  $\|g_k\|_2 \leq G$  не выполнено; см. <sup>1</sup> или <sup>2</sup>.

<sup>1</sup>B. Polyak. Introduction to Optimization. Optimization Software, Inc., 1987.

<sup>2</sup>N. Shor. Minimization Methods for Non-differentiable Functions. Springer Series in Computational Mathematics. Springer, 1985.

## Оценка сходимости. Негладкий выпуклый случай. Постоянный шаг

### i Theorem

Пусть  $f$  — выпуклая  $G$ -липшицева функция и  $R = \|x_0 - x^*\|_2$ . Тогда при фиксированном шаге  $\alpha$  субградиентный метод удовлетворяет оценке

$$f_k^{\text{best}} - f(x^*) \leq \frac{R^2}{2\alpha k} + \frac{\alpha}{2} G^2$$

- Заметим, что при любом постоянном шаге первый член правой части убывает, но второй остаётся постоянным.
- Некоторые варианты субградиентного метода (например, убывающие несуммируемые длины шагов) работают и когда предположение  $\|g_k\|_2 \leq G$  не выполнено; см. <sup>1</sup> или <sup>2</sup>.
- Найдём оптимальный шаг  $\alpha$ , минимизирующий правую часть неравенства.

<sup>1</sup>B. Polyak. Introduction to Optimization. Optimization Software, Inc., 1987.

<sup>2</sup>N. Shor. Minimization Methods for Non-differentiable Functions. Springer Series in Computational Mathematics. Springer, 1985.



## Оценка сходимости. Негладкий выпуклый случай. Постоянный шаг

### Theorem

Пусть  $f$  — выпуклая  $G$ -липшицева функция и  $R = \|x_0 - x^*\|_2$ . Тогда при выборе шага  $\alpha = \frac{R}{G} \sqrt{\frac{1}{k}}$  субградиентный метод удовлетворяет оценке

$$f_k^{\text{best}} - f(x^*) \leq \frac{GR}{\sqrt{k}}$$

- Эта версия требует заранее знать число итераций, что обычно непрактично.

## Оценка сходимости. Негладкий выпуклый случай. Постоянный шаг

### Theorem

Пусть  $f$  — выпуклая  $G$ -липшицева функция и  $R = \|x_0 - x^*\|_2$ . Тогда при выборе шага  $\alpha = \frac{R}{G} \sqrt{\frac{1}{k}}$  субградиентный метод удовлетворяет оценке

$$f_k^{\text{best}} - f(x^*) \leq \frac{GR}{\sqrt{k}}$$

- Эта версия требует заранее знать число итераций, что обычно непрактично.
- Интересно, что если искать оптимальные шаги для всей последовательности  $\alpha_0, \alpha_1, \dots, \alpha_{k-1}$ , получится тот же результат.

## Оценка сходимости. Негладкий выпуклый случай. Постоянный шаг

### i Theorem

Пусть  $f$  — выпуклая  $G$ -липшицева функция и  $R = \|x_0 - x^*\|_2$ . Тогда при выборе шага  $\alpha = \frac{R}{G} \sqrt{\frac{1}{k}}$  субградиентный метод удовлетворяет оценке

$$f_k^{\text{best}} - f(x^*) \leq \frac{GR}{\sqrt{k}}$$

- Эта версия требует заранее знать число итераций, что обычно непрактично.
- Интересно, что если искать оптимальные шаги для всей последовательности  $\alpha_0, \alpha_1, \dots, \alpha_{k-1}$ , получится тот же результат.
- Почему? Потому что правая часть является выпуклой и **симметричной** функцией от  $\alpha_0, \alpha_1, \dots, \alpha_{k-1}$ .

# Оценка сходимости. Негладкий выпуклый случай. Постоянная длина шага

## i Theorem

Пусть  $f$  — выпуклая  $G$ -липшицева функция и  $R = \|x_0 - x^*\|_2$ . Тогда для фиксированной длины шага  $\gamma = \alpha_k \|g_k\|_2$ , т.е.  $\alpha_k = \frac{\gamma}{\|g_k\|_2}$ , субградиентный метод удовлетворяет оценке

$$f_k^{\text{best}} - f(x^*) \leq \frac{GR^2}{2\gamma k} + \frac{G\gamma}{2}$$

- Заметим, что в субградиентном методе обычно нельзя использовать норму субградиента как критерий остановки (представьте  $f(x) = |x|$ ). Существуют более продвинутые критерии, но сходимость и так очень медленная, поэтому обычно просто задают максимальное число итераций.

# Оценка сходимости. Негладкий выпуклый случай. Практическая стратегия

## i Theorem

Пусть  $f$  — выпуклая  $G$ -липшицева функция и  $R = \|x_0 - x^*\|_2$ . Тогда для убывающей стратегии шага  $\alpha_k = \frac{R}{G\sqrt{k+1}}$  субградиентный метод удовлетворяет оценке

$$f_k^{\text{best}} - f(x^*) \leq \frac{GR(2 + \ln k)}{4\sqrt{k+1}}$$

1. Оценим суммы:

# Оценка сходимости. Негладкий выпуклый случай. Практическая стратегия

## i Theorem

Пусть  $f$  — выпуклая  $G$ -липшицева функция и  $R = \|x_0 - x^*\|_2$ . Тогда для убывающей стратегии шага  $\alpha_k = \frac{R}{G\sqrt{k+1}}$  субградиентный метод удовлетворяет оценке

$$f_k^{\text{best}} - f(x^*) \leq \frac{GR(2 + \ln k)}{4\sqrt{k+1}}$$

1. Оценим суммы:

$$\sum_{k=0}^{T-1} \alpha_k^2 = \frac{R^2}{G^2} \sum_{k=1}^T \frac{1}{k} \leq \frac{R^2}{G^2} (1 + \ln T);$$

# Оценка сходимости. Негладкий выпуклый случай. Практическая стратегия

## i Theorem

Пусть  $f$  — выпуклая  $G$ -липшицева функция и  $R = \|x_0 - x^*\|_2$ . Тогда для убывающей стратегии шага  $\alpha_k = \frac{R}{G\sqrt{k+1}}$  субградиентный метод удовлетворяет оценке

$$f_k^{\text{best}} - f(x^*) \leq \frac{GR(2 + \ln k)}{4\sqrt{k+1}}$$

### 1. Оценим суммы:

$$\sum_{k=0}^{T-1} \alpha_k^2 = \frac{R^2}{G^2} \sum_{k=1}^T \frac{1}{k} \leq \frac{R^2}{G^2} (1 + \ln T); \quad \sum_{k=0}^{T-1} \alpha_k = \frac{R}{G} \sum_{k=1}^T \frac{1}{\sqrt{k}} \geq \frac{R}{G} \int_1^{T+1} \frac{1}{\sqrt{t}} dt = \frac{2R}{G} (\sqrt{T+1} - 1).$$

# Оценка сходимости. Негладкий выпуклый случай. Практическая стратегия

## i Theorem

Пусть  $f$  — выпуклая  $G$ -липшицева функция и  $R = \|x_0 - x^*\|_2$ . Тогда для убывающей стратегии шага  $\alpha_k = \frac{R}{G\sqrt{k+1}}$  субградиентный метод удовлетворяет оценке

$$f_k^{\text{best}} - f(x^*) \leq \frac{GR(2 + \ln k)}{4\sqrt{k+1}}$$

1. Оценим суммы:

$$\sum_{k=0}^{T-1} \alpha_k^2 = \frac{R^2}{G^2} \sum_{k=1}^T \frac{1}{k} \leq \frac{R^2}{G^2} (1 + \ln T); \quad \sum_{k=0}^{T-1} \alpha_k = \frac{R}{G} \sum_{k=1}^T \frac{1}{\sqrt{k}} \geq \frac{R}{G} \int_1^{T+1} \frac{1}{\sqrt{t}} dt = \frac{2R}{G} (\sqrt{T+1} - 1).$$

2. В верхней оценке выше отбросим последнее  $-1$  и воспользуемся базовым неравенством:



# Оценка сходимости. Негладкий выпуклый случай. Практическая стратегия

## i Theorem

Пусть  $f$  — выпуклая  $G$ -липшицева функция и  $R = \|x_0 - x^*\|_2$ . Тогда для убывающей стратегии шага  $\alpha_k = \frac{R}{G\sqrt{k+1}}$  субградиентный метод удовлетворяет оценке

$$f_k^{\text{best}} - f(x^*) \leq \frac{GR(2 + \ln k)}{4\sqrt{k+1}}$$

1. Оценим суммы:

$$\sum_{k=0}^{T-1} \alpha_k^2 = \frac{R^2}{G^2} \sum_{k=1}^T \frac{1}{k} \leq \frac{R^2}{G^2} (1 + \ln T); \quad \sum_{k=0}^{T-1} \alpha_k = \frac{R}{G} \sum_{k=1}^T \frac{1}{\sqrt{k}} \geq \frac{R}{G} \int_1^{T+1} \frac{1}{\sqrt{t}} dt = \frac{2R}{G} (\sqrt{T+1} - 1).$$

2. В верхней оценке выше отбросим последнее  $-1$  и воспользуемся базовым неравенством:

$$f_T^{\text{best}} - f(x^*) \leq \frac{R^2 + G^2 \sum_{k=0}^{T-1} \alpha_k^2}{2 \sum_{k=0}^{T-1} \alpha_k}$$

# Оценка сходимости. Негладкий выпуклый случай. Практическая стратегия

## i Theorem

Пусть  $f$  — выпуклая  $G$ -липшицева функция и  $R = \|x_0 - x^*\|_2$ . Тогда для убывающей стратегии шага  $\alpha_k = \frac{R}{G\sqrt{k+1}}$  субградиентный метод удовлетворяет оценке

$$f_k^{\text{best}} - f(x^*) \leq \frac{GR(2 + \ln k)}{4\sqrt{k+1}}$$

1. Оценим суммы:

$$\sum_{k=0}^{T-1} \alpha_k^2 = \frac{R^2}{G^2} \sum_{k=1}^T \frac{1}{k} \leq \frac{R^2}{G^2} (1 + \ln T); \quad \sum_{k=0}^{T-1} \alpha_k = \frac{R}{G} \sum_{k=1}^T \frac{1}{\sqrt{k}} \geq \frac{R}{G} \int_1^{T+1} \frac{1}{\sqrt{t}} dt = \frac{2R}{G} (\sqrt{T+1} - 1).$$

2. В верхней оценке выше отбросим последнее  $-1$  и воспользуемся базовым неравенством:

$$f_T^{\text{best}} - f(x^*) \leq \frac{R^2 + G^2 \sum_{k=0}^{T-1} \alpha_k^2}{2 \sum_{k=0}^{T-1} \alpha_k} \leq \frac{R^2 + R^2(1 + \ln T)}{4 \frac{R}{G} (\sqrt{T+1})}$$

# Оценка сходимости. Негладкий выпуклый случай. Практическая стратегия

## i Theorem

Пусть  $f$  — выпуклая  $G$ -липшицева функция и  $R = \|x_0 - x^*\|_2$ . Тогда для убывающей стратегии шага  $\alpha_k = \frac{R}{G\sqrt{k+1}}$  субградиентный метод удовлетворяет оценке

$$f_k^{\text{best}} - f(x^*) \leq \frac{GR(2 + \ln k)}{4\sqrt{k+1}}$$


1. Оценим суммы:

$$\sum_{k=0}^{T-1} \alpha_k^2 = \frac{R^2}{G^2} \sum_{k=1}^T \frac{1}{k} \leq \frac{R^2}{G^2} (1 + \ln T); \quad \sum_{k=0}^{T-1} \alpha_k = \frac{R}{G} \sum_{k=1}^T \frac{1}{\sqrt{k}} \geq \frac{R}{G} \int_1^{T+1} \frac{1}{\sqrt{t}} dt = \frac{2R}{G} (\sqrt{T+1} - 1).$$


2. В верхней оценке выше отбросим последнее  $-1$  и воспользуемся базовым неравенством:

$$f_T^{\text{best}} - f(x^*) \leq \frac{R^2 + G^2 \sum_{k=0}^{T-1} \alpha_k^2}{2 \sum_{k=0}^{T-1} \alpha_k} \leq \frac{R^2 + R^2(1 + \ln T)}{4 \frac{R}{G} (\sqrt{T+1})} = \frac{GR(2 + \ln T)}{4\sqrt{T+1}}$$

## Негладкий сильно выпуклый случай




Негладкая  
Выпуклая




Негладкая  
 $\mu$  - сильно выпуклая

## Негладкий сильно выпуклый случай



Негладкая  
Выпуклая

$$\mathcal{O}\left(\frac{1}{\sqrt{k}}\right)$$



Негладкая  
 $\mu$  - сильно выпуклая

$$\mathcal{O}\left(\frac{1}{k}\right)$$

## Негладкий сильно выпуклый случай

### i Theorem

Пусть  $f$   $\mu$ -сильно выпукла на выпуклом множестве, а  $x, y$  — произвольные точки. Тогда для любого  $g \in \partial f(x)$

$$\langle g, x - y \rangle \geq f(x) - f(y) + \frac{\mu}{2} \|x - y\|^2.$$

1. Для любого  $\lambda \in [0, 1)$  из  $\mu$ -сильной выпуклости следует

$$f(\lambda x + (1 - \lambda)y) \leq \lambda f(x) + (1 - \lambda)f(y) - \frac{\mu}{2} \lambda(1 - \lambda) \|x - y\|^2.$$

## Негладкий сильно выпуклый случай

### i Theorem

Пусть  $f$   $\mu$ -сильно выпукла на выпуклом множестве, а  $x, y$  — произвольные точки. Тогда для любого  $g \in \partial f(x)$

$$\langle g, x - y \rangle \geq f(x) - f(y) + \frac{\mu}{2} \|x - y\|^2.$$

1. Для любого  $\lambda \in [0, 1)$  из  $\mu$ -сильной выпуклости следует

$$f(\lambda x + (1 - \lambda)y) \leq \lambda f(x) + (1 - \lambda)f(y) - \frac{\mu}{2} \lambda(1 - \lambda) \|x - y\|^2.$$

2. Из субградиентного неравенства в точке  $x$  получаем

$$f(\lambda x + (1 - \lambda)y) \geq f(x) + \langle g, \lambda x + (1 - \lambda)y - x \rangle \quad \rightarrow \quad f(\lambda x + (1 - \lambda)y) \geq f(x) - (1 - \lambda) \langle g, x - y \rangle.$$

## Негладкий сильно выпуклый случай

### i Theorem

Пусть  $f$   $\mu$ -сильно выпукла на выпуклом множестве, а  $x, y$  — произвольные точки. Тогда для любого  $g \in \partial f(x)$

$$\langle g, x - y \rangle \geq f(x) - f(y) + \frac{\mu}{2} \|x - y\|^2.$$

1. Для любого  $\lambda \in [0, 1)$  из  $\mu$ -сильной выпуклости следует

$$f(\lambda x + (1 - \lambda)y) \leq \lambda f(x) + (1 - \lambda)f(y) - \frac{\mu}{2} \lambda(1 - \lambda) \|x - y\|^2.$$

2. Из субградиентного неравенства в точке  $x$  получаем

$$f(\lambda x + (1 - \lambda)y) \geq f(x) + \langle g, \lambda x + (1 - \lambda)y - x \rangle \rightarrow f(\lambda x + (1 - \lambda)y) \geq f(x) - (1 - \lambda) \langle g, x - y \rangle.$$

3. Следовательно,

$$f(x) - (1 - \lambda) \langle g, x - y \rangle \leq \lambda f(x) + (1 - \lambda)f(y) - \frac{\mu}{2} \lambda(1 - \lambda) \|x - y\|^2$$

$$(1 - \lambda)f(x) \leq (1 - \lambda)f(y) + (1 - \lambda) \langle g, x - y \rangle - \frac{\mu}{2} \lambda(1 - \lambda) \|x - y\|^2$$

$$f(x) \leq f(y) + \langle g, x - y \rangle - \frac{\mu}{2} \lambda \|x - y\|^2$$



## Негладкий сильно выпуклый случай

### i Theorem

Пусть  $f$   $\mu$ -сильно выпукла на выпуклом множестве, а  $x, y$  — произвольные точки. Тогда для любого  $g \in \partial f(x)$

$$\langle g, x - y \rangle \geq f(x) - f(y) + \frac{\mu}{2} \|x - y\|^2.$$

1. Для любого  $\lambda \in [0, 1)$  из  $\mu$ -сильной выпуклости следует

$$f(\lambda x + (1 - \lambda)y) \leq \lambda f(x) + (1 - \lambda)f(y) - \frac{\mu}{2} \lambda(1 - \lambda) \|x - y\|^2.$$

2. Из субградиентного неравенства в точке  $x$  получаем

$$f(\lambda x + (1 - \lambda)y) \geq f(x) + \langle g, \lambda x + (1 - \lambda)y - x \rangle \rightarrow f(\lambda x + (1 - \lambda)y) \geq f(x) - (1 - \lambda) \langle g, x - y \rangle.$$

3. Следовательно,

$$f(x) - (1 - \lambda) \langle g, x - y \rangle \leq \lambda f(x) + (1 - \lambda)f(y) - \frac{\mu}{2} \lambda(1 - \lambda) \|x - y\|^2$$

$$(1 - \lambda)f(x) \leq (1 - \lambda)f(y) + (1 - \lambda) \langle g, x - y \rangle - \frac{\mu}{2} \lambda(1 - \lambda) \|x - y\|^2$$

$$f(x) \leq f(y) + \langle g, x - y \rangle - \frac{\mu}{2} \lambda \|x - y\|^2$$

## Оценка сходимости. Негладкий сильно выпуклый случай.

### i Theorem

Пусть  $f$  —  $\mu$ -сильно выпуклая (возможно, негладкая) функция с минимизатором  $x^*$  и ограниченными субградиентами  $\|g_k\| \leq G$ . При выборе шага  $\alpha_k = \frac{2}{\mu(k+1)}$  субградиентный метод гарантирует для  $k > 0$ :

$$f_k^{\text{best}} - f(x^*) \leq \frac{2G^2}{\mu k}.$$

1. Начинаем с той же записи метода, что и ранее:

## Оценка сходимости. Негладкий сильно выпуклый случай.

### i Theorem

Пусть  $f$  —  $\mu$ -сильно выпуклая (возможно, негладкая) функция с минимизатором  $x^*$  и ограниченными субградиентами  $\|g_k\| \leq G$ . При выборе шага  $\alpha_k = \frac{2}{\mu(k+1)}$  субградиентный метод гарантирует для  $k > 0$ :

$$f_k^{\text{best}} - f(x^*) \leq \frac{2G^2}{\mu k}.$$

1. Начинаем с той же записи метода, что и ранее:

$$\|x_{k+1} - x^*\|^2 = \|x_k - x^* - \alpha_k g_k\|^2 =$$

## Оценка сходимости. Негладкий сильно выпуклый случай.

### i Theorem

Пусть  $f$  —  $\mu$ -сильно выпуклая (возможно, негладкая) функция с минимизатором  $x^*$  и ограниченными субградиентами  $\|g_k\| \leq G$ . При выборе шага  $\alpha_k = \frac{2}{\mu(k+1)}$  субградиентный метод гарантирует для  $k > 0$ :

$$f_k^{\text{best}} - f(x^*) \leq \frac{2G^2}{\mu k}.$$

1. Начинаем с той же записи метода, что и ранее:

$$\begin{aligned}\|x_{k+1} - x^*\|^2 &= \|x_k - x^* - \alpha_k g_k\|^2 = \\ &= \|x_k - x^*\|^2 + \alpha_k^2 \|g_k\|^2 - 2\alpha_k \langle g_k, x_k - x^* \rangle\end{aligned}$$

## Оценка сходимости. Негладкий сильно выпуклый случай.

### i Theorem

Пусть  $f$  —  $\mu$ -сильно выпуклая (возможно, негладкая) функция с минимизатором  $x^*$  и ограниченными субградиентами  $\|g_k\| \leq G$ . При выборе шага  $\alpha_k = \frac{2}{\mu(k+1)}$  субградиентный метод гарантирует для  $k > 0$ :

$$f_k^{\text{best}} - f(x^*) \leq \frac{2G^2}{\mu k}.$$

1. Начинаем с той же записи метода, что и ранее:

$$\begin{aligned}\|x_{k+1} - x^*\|^2 &= \|x_k - x^* - \alpha_k g_k\|^2 = \\ &= \|x_k - x^*\|^2 + \alpha_k^2 \|g_k\|^2 - 2\alpha_k \langle g_k, x_k - x^* \rangle \\ &\leq \|x_k - x^*\|^2 + \alpha_k^2 \|g_k\|^2 - 2\alpha_k (f(x_k) - f(x^*)) - \alpha_k \mu \|x_k - x^*\|^2\end{aligned}$$

## Оценка сходимости. Негладкий сильно выпуклый случай.

### i Theorem

Пусть  $f$  —  $\mu$ -сильно выпуклая (возможно, негладкая) функция с минимизатором  $x^*$  и ограниченными субградиентами  $\|g_k\| \leq G$ . При выборе шага  $\alpha_k = \frac{2}{\mu(k+1)}$  субградиентный метод гарантирует для  $k > 0$ :

$$f_k^{\text{best}} - f(x^*) \leq \frac{2G^2}{\mu k}.$$

1. Начинаем с той же записи метода, что и ранее:

$$\begin{aligned}\|x_{k+1} - x^*\|^2 &= \|x_k - x^* - \alpha_k g_k\|^2 = \\ &= \|x_k - x^*\|^2 + \alpha_k^2 \|g_k\|^2 - 2\alpha_k \langle g_k, x_k - x^* \rangle \\ &\leq \|x_k - x^*\|^2 + \alpha_k^2 \|g_k\|^2 - 2\alpha_k (f(x_k) - f(x^*)) - \alpha_k \mu \|x_k - x^*\|^2 \\ &= (1 - \mu \alpha_k) \|x_k - x^*\|^2 + \alpha_k^2 \|g_k\|^2 - 2\alpha_k (f(x_k) - f(x^*))\end{aligned}$$

## Оценка сходимости. Негладкий сильно выпуклый случай.

### i Theorem

Пусть  $f$  —  $\mu$ -сильно выпуклая (возможно, негладкая) функция с минимизатором  $x^*$  и ограниченными субградиентами  $\|g_k\| \leq G$ . При выборе шага  $\alpha_k = \frac{2}{\mu(k+1)}$  субградиентный метод гарантирует для  $k > 0$ :

$$f_k^{\text{best}} - f(x^*) \leq \frac{2G^2}{\mu k}.$$

1. Начинаем с той же записи метода, что и ранее:

$$\begin{aligned}\|x_{k+1} - x^*\|^2 &= \|x_k - x^* - \alpha_k g_k\|^2 = \\ &= \|x_k - x^*\|^2 + \alpha_k^2 \|g_k\|^2 - 2\alpha_k \langle g_k, x_k - x^* \rangle \\ &\leq \|x_k - x^*\|^2 + \alpha_k^2 \|g_k\|^2 - 2\alpha_k (f(x_k) - f(x^*)) - \alpha_k \mu \|x_k - x^*\|^2 \\ &= (1 - \mu\alpha_k) \|x_k - x^*\|^2 + \alpha_k^2 \|g_k\|^2 - 2\alpha_k (f(x_k) - f(x^*)) \\ 2\alpha_k (f(x_k) - f(x^*)) &\leq (1 - \mu\alpha_k) \|x_k - x^*\|^2 - \|x_{k+1} - x^*\|^2 + \alpha_k^2 \|g_k\|^2\end{aligned}$$

## Оценка сходимости. Негладкий сильно выпуклый случай.

### i Theorem

Пусть  $f$  —  $\mu$ -сильно выпуклая (возможно, негладкая) функция с минимизатором  $x^*$  и ограниченными субградиентами  $\|g_k\| \leq G$ . При выборе шага  $\alpha_k = \frac{2}{\mu(k+1)}$  субградиентный метод гарантирует для  $k > 0$ :

$$f_k^{\text{best}} - f(x^*) \leq \frac{2G^2}{\mu k}.$$

1. Начинаем с той же записи метода, что и ранее:

$$\begin{aligned}\|x_{k+1} - x^*\|^2 &= \|x_k - x^* - \alpha_k g_k\|^2 = \\ &= \|x_k - x^*\|^2 + \alpha_k^2 \|g_k\|^2 - 2\alpha_k \langle g_k, x_k - x^* \rangle \\ &\leq \|x_k - x^*\|^2 + \alpha_k^2 \|g_k\|^2 - 2\alpha_k (f(x_k) - f(x^*)) - \alpha_k \mu \|x_k - x^*\|^2 \\ &= (1 - \mu\alpha_k) \|x_k - x^*\|^2 + \alpha_k^2 \|g_k\|^2 - 2\alpha_k (f(x_k) - f(x^*)) \\ 2\alpha_k (f(x_k) - f(x^*)) &\leq (1 - \mu\alpha_k) \|x_k - x^*\|^2 - \|x_{k+1} - x^*\|^2 + \alpha_k^2 \|g_k\|^2 \\ f(x_k) - f(x^*) &\leq \frac{1 - \mu\alpha_k}{2\alpha_k} \|x_k - x^*\|^2 - \frac{1}{2\alpha_k} \|x_{k+1} - x^*\|^2 + \frac{\alpha_k}{2} \|g_k\|^2\end{aligned}$$



## Оценка сходимости. Негладкий сильно выпуклый случай. Доказательство

2. Подставим шаг  $\alpha_k = \frac{2}{\mu(k+1)}$  в неравенство:

## Оценка сходимости. Негладкий сильно выпуклый случай. Доказательство

2. Подставим шаг  $\alpha_k = \frac{2}{\mu(k+1)}$  в неравенство:

$$f(x_k) - f(x^*) \leq \frac{\mu(k-1)}{4} \|x_k - x^*\|^2 - \frac{\mu(k+1)}{4} \|x_{k+1} - x^*\|^2 + \frac{1}{\mu(k+1)} \|g_k\|^2$$

## Оценка сходимости. Негладкий сильно выпуклый случай. Доказательство

2. Подставим шаг  $\alpha_k = \frac{2}{\mu(k+1)}$  в неравенство:

$$f(x_k) - f(x^*) \leq \frac{\mu(k-1)}{4} \|x_k - x^*\|^2 - \frac{\mu(k+1)}{4} \|x_{k+1} - x^*\|^2 + \frac{1}{\mu(k+1)} \|g_k\|^2$$

$$f(x_k) - f(x^*) \leq \frac{\mu(k-1)}{4} \|x_k - x^*\|^2 - \frac{\mu(k+1)}{4} \|x_{k+1} - x^*\|^2 + \frac{1}{\mu k} \|g_k\|^2$$

## Оценка сходимости. Негладкий сильно выпуклый случай. Доказательство

2. Подставим шаг  $\alpha_k = \frac{2}{\mu(k+1)}$  в неравенство:

$$f(x_k) - f(x^*) \leq \frac{\mu(k-1)}{4} \|x_k - x^*\|^2 - \frac{\mu(k+1)}{4} \|x_{k+1} - x^*\|^2 + \frac{1}{\mu(k+1)} \|g_k\|^2$$

$$f(x_k) - f(x^*) \leq \frac{\mu(k-1)}{4} \|x_k - x^*\|^2 - \frac{\mu(k+1)}{4} \|x_{k+1} - x^*\|^2 + \frac{1}{\mu k} \|g_k\|^2$$

$$k(f(x_k) - f(x^*)) \leq \frac{\mu k(k-1)}{4} \|x_k - x^*\|^2 - \frac{\mu k(k+1)}{4} \|x_{k+1} - x^*\|^2 + \frac{1}{\mu} \|g_k\|^2$$

## Оценка сходимости. Негладкий сильно выпуклый случай. Доказательство

2. Подставим шаг  $\alpha_k = \frac{2}{\mu(k+1)}$  в неравенство:

$$f(x_k) - f(x^*) \leq \frac{\mu(k-1)}{4} \|x_k - x^*\|^2 - \frac{\mu(k+1)}{4} \|x_{k+1} - x^*\|^2 + \frac{1}{\mu(k+1)} \|g_k\|^2$$

$$f(x_k) - f(x^*) \leq \frac{\mu(k-1)}{4} \|x_k - x^*\|^2 - \frac{\mu(k+1)}{4} \|x_{k+1} - x^*\|^2 + \frac{1}{\mu k} \|g_k\|^2$$

$$k(f(x_k) - f(x^*)) \leq \frac{\mu k(k-1)}{4} \|x_k - x^*\|^2 - \frac{\mu k(k+1)}{4} \|x_{k+1} - x^*\|^2 + \frac{1}{\mu} \|g_k\|^2$$

3. Просуммировав неравенства по всем  $k = 0, 1, \dots, T-1$ , получаем:

## Оценка сходимости. Негладкий сильно выпуклый случай. Доказательство

2. Подставим шаг  $\alpha_k = \frac{2}{\mu(k+1)}$  в неравенство:

$$f(x_k) - f(x^*) \leq \frac{\mu(k-1)}{4} \|x_k - x^*\|^2 - \frac{\mu(k+1)}{4} \|x_{k+1} - x^*\|^2 + \frac{1}{\mu(k+1)} \|g_k\|^2$$

$$f(x_k) - f(x^*) \leq \frac{\mu(k-1)}{4} \|x_k - x^*\|^2 - \frac{\mu(k+1)}{4} \|x_{k+1} - x^*\|^2 + \frac{1}{\mu k} \|g_k\|^2$$

$$k(f(x_k) - f(x^*)) \leq \frac{\mu k(k-1)}{4} \|x_k - x^*\|^2 - \frac{\mu k(k+1)}{4} \|x_{k+1} - x^*\|^2 + \frac{1}{\mu} \|g_k\|^2$$

3. Просуммировав неравенства по всем  $k = 0, 1, \dots, T-1$ , получаем:

$$\sum_{k=0}^{T-1} k(f(x_k) - f(x^*)) \leq 0 - \frac{\mu(T-1)T}{4} \|x_T - x^*\|^2 + \frac{1}{\mu} \sum_{k=0}^{T-1} \|g_k\|^2$$

## Оценка сходимости. Негладкий сильно выпуклый случай. Доказательство

2. Подставим шаг  $\alpha_k = \frac{2}{\mu(k+1)}$  в неравенство:

$$f(x_k) - f(x^*) \leq \frac{\mu(k-1)}{4} \|x_k - x^*\|^2 - \frac{\mu(k+1)}{4} \|x_{k+1} - x^*\|^2 + \frac{1}{\mu(k+1)} \|g_k\|^2$$

$$f(x_k) - f(x^*) \leq \frac{\mu(k-1)}{4} \|x_k - x^*\|^2 - \frac{\mu(k+1)}{4} \|x_{k+1} - x^*\|^2 + \frac{1}{\mu k} \|g_k\|^2$$

$$k(f(x_k) - f(x^*)) \leq \frac{\mu k(k-1)}{4} \|x_k - x^*\|^2 - \frac{\mu k(k+1)}{4} \|x_{k+1} - x^*\|^2 + \frac{1}{\mu} \|g_k\|^2$$

3. Просуммировав неравенства по всем  $k = 0, 1, \dots, T-1$ , получаем:

$$\sum_{k=0}^{T-1} k(f(x_k) - f(x^*)) \leq 0 - \frac{\mu(T-1)T}{4} \|x_T - x^*\|^2 + \frac{1}{\mu} \sum_{k=0}^{T-1} \|g_k\|^2 \leq \frac{G^2 T}{\mu}$$

## Оценка сходимости. Негладкий сильно выпуклый случай. Доказательство

2. Подставим шаг  $\alpha_k = \frac{2}{\mu(k+1)}$  в неравенство:

$$f(x_k) - f(x^*) \leq \frac{\mu(k-1)}{4} \|x_k - x^*\|^2 - \frac{\mu(k+1)}{4} \|x_{k+1} - x^*\|^2 + \frac{1}{\mu(k+1)} \|g_k\|^2$$

$$f(x_k) - f(x^*) \leq \frac{\mu(k-1)}{4} \|x_k - x^*\|^2 - \frac{\mu(k+1)}{4} \|x_{k+1} - x^*\|^2 + \frac{1}{\mu k} \|g_k\|^2$$

$$k(f(x_k) - f(x^*)) \leq \frac{\mu k(k-1)}{4} \|x_k - x^*\|^2 - \frac{\mu k(k+1)}{4} \|x_{k+1} - x^*\|^2 + \frac{1}{\mu} \|g_k\|^2$$

3. Просуммировав неравенства по всем  $k = 0, 1, \dots, T-1$ , получаем:

$$\sum_{k=0}^{T-1} k(f(x_k) - f(x^*)) \leq 0 - \frac{\mu(T-1)T}{4} \|x_T - x^*\|^2 + \frac{1}{\mu} \sum_{k=0}^{T-1} \|g_k\|^2 \leq \frac{G^2 T}{\mu}$$

$$(f_{T-1}^{\text{best}} - f(x^*)) \sum_{k=0}^{T-1} k = \sum_{k=0}^{T-1} k(f_{T-1}^{\text{best}} - f(x^*))$$



## Оценка сходимости. Негладкий сильно выпуклый случай. Доказательство

2. Подставим шаг  $\alpha_k = \frac{2}{\mu(k+1)}$  в неравенство:

$$f(x_k) - f(x^*) \leq \frac{\mu(k-1)}{4} \|x_k - x^*\|^2 - \frac{\mu(k+1)}{4} \|x_{k+1} - x^*\|^2 + \frac{1}{\mu(k+1)} \|g_k\|^2$$

$$f(x_k) - f(x^*) \leq \frac{\mu(k-1)}{4} \|x_k - x^*\|^2 - \frac{\mu(k+1)}{4} \|x_{k+1} - x^*\|^2 + \frac{1}{\mu k} \|g_k\|^2$$

$$k(f(x_k) - f(x^*)) \leq \frac{\mu k(k-1)}{4} \|x_k - x^*\|^2 - \frac{\mu k(k+1)}{4} \|x_{k+1} - x^*\|^2 + \frac{1}{\mu} \|g_k\|^2$$

3. Просуммировав неравенства по всем  $k = 0, 1, \dots, T-1$ , получаем:

$$\sum_{k=0}^{T-1} k(f(x_k) - f(x^*)) \leq 0 - \frac{\mu(T-1)T}{4} \|x_T - x^*\|^2 + \frac{1}{\mu} \sum_{k=0}^{T-1} \|g_k\|^2 \leq \frac{G^2 T}{\mu}$$

$$(f_{T-1}^{\text{best}} - f(x^*)) \sum_{k=0}^{T-1} k = \sum_{k=0}^{T-1} k(f_{T-1}^{\text{best}} - f(x^*)) \leq \sum_{k=0}^{T-1} k(f(x_k) - f(x^*))$$

## Оценка сходимости. Негладкий сильно выпуклый случай. Доказательство

2. Подставим шаг  $\alpha_k = \frac{2}{\mu(k+1)}$  в неравенство:

$$f(x_k) - f(x^*) \leq \frac{\mu(k-1)}{4} \|x_k - x^*\|^2 - \frac{\mu(k+1)}{4} \|x_{k+1} - x^*\|^2 + \frac{1}{\mu(k+1)} \|g_k\|^2$$

$$f(x_k) - f(x^*) \leq \frac{\mu(k-1)}{4} \|x_k - x^*\|^2 - \frac{\mu(k+1)}{4} \|x_{k+1} - x^*\|^2 + \frac{1}{\mu k} \|g_k\|^2$$

$$k(f(x_k) - f(x^*)) \leq \frac{\mu k(k-1)}{4} \|x_k - x^*\|^2 - \frac{\mu k(k+1)}{4} \|x_{k+1} - x^*\|^2 + \frac{1}{\mu} \|g_k\|^2$$

3. Просуммировав неравенства по всем  $k = 0, 1, \dots, T-1$ , получаем:

$$\sum_{k=0}^{T-1} k(f(x_k) - f(x^*)) \leq 0 - \frac{\mu(T-1)T}{4} \|x_T - x^*\|^2 + \frac{1}{\mu} \sum_{k=0}^{T-1} \|g_k\|^2 \leq \frac{G^2 T}{\mu}$$

$$(f_{T-1}^{\text{best}} - f(x^*)) \sum_{k=0}^{T-1} k = \sum_{k=0}^{T-1} k(f_{T-1}^{\text{best}} - f(x^*)) \leq \sum_{k=0}^{T-1} k(f(x_k) - f(x^*)) \leq \frac{G^2 T}{\mu}$$

## Оценка сходимости. Негладкий сильно выпуклый случай. Доказательство

2. Подставим шаг  $\alpha_k = \frac{2}{\mu(k+1)}$  в неравенство:

$$f(x_k) - f(x^*) \leq \frac{\mu(k-1)}{4} \|x_k - x^*\|^2 - \frac{\mu(k+1)}{4} \|x_{k+1} - x^*\|^2 + \frac{1}{\mu(k+1)} \|g_k\|^2$$

$$f(x_k) - f(x^*) \leq \frac{\mu(k-1)}{4} \|x_k - x^*\|^2 - \frac{\mu(k+1)}{4} \|x_{k+1} - x^*\|^2 + \frac{1}{\mu k} \|g_k\|^2$$

$$k(f(x_k) - f(x^*)) \leq \frac{\mu k(k-1)}{4} \|x_k - x^*\|^2 - \frac{\mu k(k+1)}{4} \|x_{k+1} - x^*\|^2 + \frac{1}{\mu} \|g_k\|^2$$

3. Просуммировав неравенства по всем  $k = 0, 1, \dots, T-1$ , получаем:

$$\sum_{k=0}^{T-1} k(f(x_k) - f(x^*)) \leq 0 - \frac{\mu(T-1)T}{4} \|x_T - x^*\|^2 + \frac{1}{\mu} \sum_{k=0}^{T-1} \|g_k\|^2 \leq \frac{G^2 T}{\mu}$$

$$(f_{T-1}^{\text{best}} - f(x^*)) \sum_{k=0}^{T-1} k = \sum_{k=0}^{T-1} k(f_{T-1}^{\text{best}} - f(x^*)) \leq \sum_{k=0}^{T-1} k(f(x_k) - f(x^*)) \leq \frac{G^2 T}{\mu}$$

$$f_{T-1}^{\text{best}} - f(x^*) \leq \frac{G^2 T}{\mu \sum_{k=0}^{T-1} k}$$

## Оценка сходимости. Негладкий сильно выпуклый случай. Доказательство

2. Подставим шаг  $\alpha_k = \frac{2}{\mu(k+1)}$  в неравенство:

$$f(x_k) - f(x^*) \leq \frac{\mu(k-1)}{4} \|x_k - x^*\|^2 - \frac{\mu(k+1)}{4} \|x_{k+1} - x^*\|^2 + \frac{1}{\mu(k+1)} \|g_k\|^2$$

$$f(x_k) - f(x^*) \leq \frac{\mu(k-1)}{4} \|x_k - x^*\|^2 - \frac{\mu(k+1)}{4} \|x_{k+1} - x^*\|^2 + \frac{1}{\mu k} \|g_k\|^2$$

$$k(f(x_k) - f(x^*)) \leq \frac{\mu k(k-1)}{4} \|x_k - x^*\|^2 - \frac{\mu k(k+1)}{4} \|x_{k+1} - x^*\|^2 + \frac{1}{\mu} \|g_k\|^2$$

3. Просуммировав неравенства по всем  $k = 0, 1, \dots, T-1$ , получаем:

$$\sum_{k=0}^{T-1} k(f(x_k) - f(x^*)) \leq 0 - \frac{\mu(T-1)T}{4} \|x_T - x^*\|^2 + \frac{1}{\mu} \sum_{k=0}^{T-1} \|g_k\|^2 \leq \frac{G^2 T}{\mu}$$

$$(f_{T-1}^{\text{best}} - f(x^*)) \sum_{k=0}^{T-1} k = \sum_{k=0}^{T-1} k(f_{T-1}^{\text{best}} - f(x^*)) \leq \sum_{k=0}^{T-1} k(f(x_k) - f(x^*)) \leq \frac{G^2 T}{\mu}$$

$$f_{T-1}^{\text{best}} - f(x^*) \leq \frac{G^2 T}{\mu \sum_{k=0}^{T-1} k} = \frac{2G^2 T}{\mu T(T-1)}$$

## Оценка сходимости. Негладкий сильно выпуклый случай. Доказательство

2. Подставим шаг  $\alpha_k = \frac{2}{\mu(k+1)}$  в неравенство:

$$f(x_k) - f(x^*) \leq \frac{\mu(k-1)}{4} \|x_k - x^*\|^2 - \frac{\mu(k+1)}{4} \|x_{k+1} - x^*\|^2 + \frac{1}{\mu(k+1)} \|g_k\|^2$$

$$f(x_k) - f(x^*) \leq \frac{\mu(k-1)}{4} \|x_k - x^*\|^2 - \frac{\mu(k+1)}{4} \|x_{k+1} - x^*\|^2 + \frac{1}{\mu k} \|g_k\|^2$$

$$k(f(x_k) - f(x^*)) \leq \frac{\mu k(k-1)}{4} \|x_k - x^*\|^2 - \frac{\mu k(k+1)}{4} \|x_{k+1} - x^*\|^2 + \frac{1}{\mu} \|g_k\|^2$$

3. Просуммировав неравенства по всем  $k = 0, 1, \dots, T-1$ , получаем:

$$\sum_{k=0}^{T-1} k(f(x_k) - f(x^*)) \leq 0 - \frac{\mu(T-1)T}{4} \|x_T - x^*\|^2 + \frac{1}{\mu} \sum_{k=0}^{T-1} \|g_k\|^2 \leq \frac{G^2 T}{\mu}$$

$$(f_{T-1}^{\text{best}} - f(x^*)) \sum_{k=0}^{T-1} k = \sum_{k=0}^{T-1} k(f_{T-1}^{\text{best}} - f(x^*)) \leq \sum_{k=0}^{T-1} k(f(x_k) - f(x^*)) \leq \frac{G^2 T}{\mu}$$

$$f_{T-1}^{\text{best}} - f(x^*) \leq \frac{G^2 T}{\mu \sum_{k=0}^{T-1} k} = \frac{2G^2 T}{\mu T(T-1)} \quad f_k^{\text{best}} - f(x^*) \leq \frac{2G^2}{\mu k}.$$

## Резюме. Субградиентный метод

| Тип задачи                       | Правило выбора шага              | Скорость сходимости                          | Итерационная сложность                            |
|----------------------------------|----------------------------------|----------------------------------------------|---------------------------------------------------|
| Выпуклые липшицевы задачи        | $\alpha \sim \frac{1}{\sqrt{k}}$ | $\mathcal{O}\left(\frac{1}{\sqrt{k}}\right)$ | $\mathcal{O}\left(\frac{1}{\varepsilon^2}\right)$ |
| Сильно выпуклые липшицевы задачи | $\alpha \sim \frac{1}{k}$        | $\mathcal{O}\left(\frac{1}{k}\right)$        | $\mathcal{O}\left(\frac{1}{\varepsilon}\right)$   |

## Численные эксперименты

$$f(x) = \frac{1}{2m} \|Ax - b\|_2^2 + \lambda \|x\|_1 \rightarrow \min_{x \in \mathbb{R}^n}, \quad A \in \mathbb{R}^{m \times n}, \quad \lambda \left( \frac{1}{m} A^T A \right) \in [\mu; L].$$

Linear Least Squares with  $\ell_1$  Regularization (LASSO).  
m=1000, n=100,  $\lambda=0$ ,  $\mu=0$ , L=10. Optimal sparsity: 0.0e+00




Рис. 6: Гладкий выпуклый случай. Сублинейная сходимость, нет сходимости по аргументу

## Численные эксперименты

$$f(x) = \frac{1}{2m} \|Ax - b\|_2^2 + \lambda \|x\|_1 \rightarrow \min_{x \in \mathbb{R}^n}, \quad A \in \mathbb{R}^{m \times n}, \quad \lambda \left( \frac{1}{m} A^T A \right) \in [\mu; L].$$

Linear Least Squares with  $\ell_1$  Regularization (LASSO).  
 $m=1000, n=100, \lambda=0.1, \mu=0, L=10$ . Optimal sparsity:  $1.0e-02$




Рис. 7: Негладкий выпуклый случай. Малое значение  $\lambda$  делает задачу негладкой. Нет сходимости при постоянном шаге



## Численные эксперименты

$$f(x) = \frac{1}{2m} \|Ax - b\|_2^2 + \lambda \|x\|_1 \rightarrow \min_{x \in \mathbb{R}^n}, \quad A \in \mathbb{R}^{m \times n}, \quad \lambda \left( \frac{1}{m} A^T A \right) \in [\mu; L].$$

Linear Least Squares with  $\ell_1$  Regularization (LASSO).  
m=1000, n=100,  $\lambda=1$ ,  $\mu=0$ , L=10. Optimal sparsity: 7.0e-02




Рис. 8: Негладкий выпуклый случай. Большее значение  $\lambda$  проявляет немонотонность  $f(x_k)$ . Меньший постоянный шаг приводит к более низкому стационарному уровню

## Численные эксперименты

$$f(x) = \frac{1}{2m} \|Ax - b\|_2^2 + \lambda \|x\|_1 \rightarrow \min_{x \in \mathbb{R}^n}, \quad A \in \mathbb{R}^{m \times n}, \quad \lambda \left( \frac{1}{m} A^T A \right) \in [\mu; L].$$

Linear Least Squares with  $\ell_1$  Regularization (LASSO).  
 $m=100, n=100, \lambda=1, \mu=0, L=10$ . Optimal sparsity:  $2.3e-01$




Рис. 9: Негладкий выпуклый случай. Убывающий шаг обеспечивает сходимость  $f_k^{\text{best}}$

## Численные эксперименты

$$f(x) = \frac{1}{2m} \|Ax - b\|_2^2 + \lambda \|x\|_1 \rightarrow \min_{x \in \mathbb{R}^n}, \quad A \in \mathbb{R}^{m \times n}, \quad \lambda \left( \frac{1}{m} A^T A \right) \in [\mu; L].$$

Linear Least Squares with  $\ell_1$  Regularization (LASSO).  
 $m=100, n=100, \lambda=1, \mu=0, L=10$ . Optimal sparsity: 2.3e-01




Рис. 10: Негладкий выпуклый случай. Шаг  $\frac{\alpha_0}{\sqrt{k}}$  обеспечивает сходимость  $f_k^{\text{best}}$

## Численные эксперименты

$$f(x) = \frac{1}{2m} \|Ax - b\|_2^2 + \lambda \|x\|_1 \rightarrow \min_{x \in \mathbb{R}^n}, \quad A \in \mathbb{R}^{m \times n}, \quad \lambda \left( \frac{1}{m} A^T A \right) \in [\mu; L].$$

Linear Least Squares with  $\ell_1$  Regularization (LASSO).  
m=100, n=100,  $\lambda=1$ ,  $\mu=0$ ,  $L=10$ . Optimal sparsity: 2.3e-01




Рис. 11: Негладкий выпуклый случай. Шаг  $\frac{\alpha_0}{\sqrt{k}}$  обеспечивает сходимость  $f_k^{\text{best}}$

## Численные эксперименты

$$f(x) = \frac{1}{2m} \|Ax - b\|_2^2 + \lambda \|x\|_1 \rightarrow \min_{x \in \mathbb{R}^n}, \quad A \in \mathbb{R}^{m \times n}, \quad \lambda \left( \frac{1}{m} A^T A \right) \in [\mu; L].$$

Linear Least Squares with  $\ell_1$  Regularization (LASSO).  
 $m=100, n=100, \lambda=1, \mu=1, L=10$ . Optimal sparsity:  $2.0e-01$




Рис. 12: Негладкий сильно выпуклый случай. Шаг  $\frac{\alpha_0}{k}$  обеспечивает сходимость  $f_k^{\text{best}}$

## Численные эксперименты

$$f(x) = \frac{1}{2m} \|Ax - b\|_2^2 + \lambda \|x\|_1 \rightarrow \min_{x \in \mathbb{R}^n}, \quad A \in \mathbb{R}^{m \times n}, \quad \lambda \left( \frac{1}{m} A^T A \right) \in [\mu; L].$$

Linear Least Squares with  $\ell_1$  Regularization (LASSO).  
 $m=100, n=100, \lambda=1, \mu=1, L=10$ . Optimal sparsity:  $2.0 \times 10^{-1}$




Рис. 13: Негладкий сильно выпуклый случай. Шаг  $\frac{\alpha_0}{\sqrt{k}}$  работает хуже

## Численные эксперименты

$$f(x) = \frac{1}{m} \sum_{i=1}^m \log(1 + \exp(-b_i(A_i x))) + \lambda \|x\|_1 \rightarrow \min_{x \in \mathbb{R}^n}, \quad A_i \in \mathbb{R}^n, \quad b_i \in \{-1, 1\}$$

Binary Logistic Regression with  $\ell_1$  Regularization.  
m=300, n=50,  $\lambda=0.1$ . Optimal sparsity: 8.6e-01




Рис. 14: Логистическая регрессия с  $\ell_1$ -регуляризацией

## Численные эксперименты

$$f(x) = \frac{1}{m} \sum_{i=1}^m \log(1 + \exp(-b_i(A_i x))) + \lambda \|x\|_1 \rightarrow \min_{x \in \mathbb{R}^n}, \quad A_i \in \mathbb{R}^n, \quad b_i \in \{-1, 1\}$$

Binary Logistic Regression with  $\ell_1$  Regularization.  
 $m=300$ ,  $n=50$ ,  $\lambda=0.1$ . Optimal sparsity:  $8.6e-01$




Рис. 15: Логистическая регрессия с  $\ell_1$ -регуляризацией



## Численные эксперименты

$$f(x) = \frac{1}{m} \sum_{i=1}^m \log(1 + \exp(-b_i(A_i x))) + \lambda \|x\|_1 \rightarrow \min_{x \in \mathbb{R}^n}, \quad A_i \in \mathbb{R}^n, \quad b_i \in \{-1, 1\}$$

Binary Logistic Regression with  $\ell_1$  Regularization.  
m=300, n=50,  $\lambda=0.25$ . Optimal sparsity: 9.6e-01




Рис. 16: Логистическая регрессия с  $\ell_1$ -регуляризацией

## Численные эксперименты

$$f(x) = \frac{1}{m} \sum_{i=1}^m \log(1 + \exp(-b_i(A_i x))) + \lambda \|x\|_1 \rightarrow \min_{x \in \mathbb{R}^n}, \quad A_i \in \mathbb{R}^n, \quad b_i \in \{-1, 1\}$$

Binary Logistic Regression with  $\ell_1$  Regularization.  
m=300, n=50,  $\lambda=0.25$ . Optimal sparsity: 9.6e-01




Рис. 17: Логистическая регрессия с  $\ell_1$ -регуляризацией

## Численные эксперименты

$$f(x) = \frac{1}{m} \sum_{i=1}^m \log(1 + \exp(-b_i(A_i x))) + \lambda \|x\|_1 \rightarrow \min_{x \in \mathbb{R}^n}, \quad A_i \in \mathbb{R}^n, \quad b_i \in \{-1, 1\}$$

Binary Logistic Regression with  $\ell_1$  Regularization.  
m=300, n=50,  $\lambda=0.27$ . Optimal sparsity: 1.0e+00




Рис. 18: Логистическая регрессия с  $\ell_1$ -регуляризацией

## Численные эксперименты

$$f(x) = \frac{1}{m} \sum_{i=1}^m \log(1 + \exp(-b_i(A_i x))) + \lambda \|x\|_1 \rightarrow \min_{x \in \mathbb{R}^n}, \quad A_i \in \mathbb{R}^n, \quad b_i \in \{-1, 1\}$$

Binary Logistic Regression with  $\ell_1$  Regularization.  
m=300, n=50,  $\lambda=0.27$ . Optimal sparsity: 1.0e+00




Рис. 19: Логистическая регрессия с  $\ell_1$ -регуляризацией

## Нижние оценки

## Нижние оценки

| выпуклая (негладкая)<br><sup>3</sup>                                 | гладкая (невыпуклая) <sup>4</sup>                                         | гладкая & выпуклая <sup>5</sup>                                           | гладкая & сильно выпуклая (или PL) <sup>1</sup>                                       |
|----------------------------------------------------------------------|---------------------------------------------------------------------------|---------------------------------------------------------------------------|---------------------------------------------------------------------------------------|
| $\mathcal{O}\left(\frac{1}{\sqrt{k}}\right)$                         | $\mathcal{O}\left(\frac{1}{k^2}\right)$                                   | $\mathcal{O}\left(\frac{1}{k^2}\right)$                                   | $\mathcal{O}\left(\left(\frac{\sqrt{\kappa}-1}{\sqrt{\kappa}+1}\right)^k\right)$      |
| $k_\varepsilon \sim \mathcal{O}\left(\frac{1}{\varepsilon^2}\right)$ | $k_\varepsilon \sim \mathcal{O}\left(\frac{1}{\sqrt{\varepsilon}}\right)$ | $k_\varepsilon \sim \mathcal{O}\left(\frac{1}{\sqrt{\varepsilon}}\right)$ | $k_\varepsilon \sim \mathcal{O}\left(\sqrt{\kappa} \log \frac{1}{\varepsilon}\right)$ |

<sup>3</sup>Nesterov, Lectures on Convex Optimization

<sup>4</sup>Carmon, Duchi, Hinder, Sidford, 2017

<sup>5</sup>Nemirovski, Yudin, 1979

# Итерация «чёрного ящика»

Итерация градиентного спуска:

$$\begin{aligned}x^{k+1} &= x^k - \alpha^k \nabla f(x^k) \\&= x^{k-1} - \alpha^{k-1} \nabla f(x^{k-1}) - \alpha^k \nabla f(x^k) \\&\vdots \\&= x^0 - \sum_{i=0}^k \alpha^{k-i} \nabla f(x^{k-i})\end{aligned}$$

# Итерация «чёрного ящика»

Итерация градиентного спуска:

$$\begin{aligned}x^{k+1} &= x^k - \alpha^k \nabla f(x^k) \\&= x^{k-1} - \alpha^{k-1} \nabla f(x^{k-1}) - \alpha^k \nabla f(x^k) \\&\vdots \\&= x^0 - \sum_{i=0}^k \alpha^{k-i} \nabla f(x^{k-i})\end{aligned}$$

Рассмотрим семейство методов первого порядка, для которых

$$\begin{aligned}x^{k+1} &\in x^0 + \text{span} \{ \nabla f(x^0), \nabla f(x^1), \dots, \nabla f(x^k) \} && f - \text{smooth} \\x^{k+1} &\in x^0 + \text{span} \{ g_0, g_1, \dots, g_k \}, \text{ where } g_i \in \partial f(x^i) && f - \text{non-smooth}\end{aligned} \tag{1}$$



## Итерация «чёрного ящика»

Итерация градиентного спуска:

$$\begin{aligned}x^{k+1} &= x^k - \alpha^k \nabla f(x^k) \\&= x^{k-1} - \alpha^{k-1} \nabla f(x^{k-1}) - \alpha^k \nabla f(x^k) \\&\vdots \\&= x^0 - \sum_{i=0}^k \alpha^{k-i} \nabla f(x^{k-i})\end{aligned}$$

Рассмотрим семейство методов первого порядка, для которых

$$\begin{aligned}x^{k+1} &\in x^0 + \text{span} \{ \nabla f(x^0), \nabla f(x^1), \dots, \nabla f(x^k) \} && f - \text{smooth} \\x^{k+1} &\in x^0 + \text{span} \{ g_0, g_1, \dots, g_k \}, \text{ where } g_i \in \partial f(x^i) && f - \text{non-smooth}\end{aligned} \tag{1}$$

Чтобы построить нижнюю оценку, нужно найти функцию  $f$  из соответствующего класса так, чтобы любой метод из семейства 1 работал не быстрее, чем предсказано нижней оценкой.

## Негладкий выпуклый случай

### i Theorem

Существует функция  $f$ , которая является  $G$ -липшицевой и выпуклой, такая что любой метод 1 удовлетворяет

$$\min_{i \in [1, k]} f(x^i) - \min_{x \in \mathbb{B}(R)} f(x) \geq \frac{GR}{2(1 + \sqrt{k})}$$

для  $R > 0$  и  $k \leq n$ , где  $n$  — размерность задачи.

## Негладкий выпуклый случай

### i Theorem

Существует функция  $f$ , которая является  $G$ -липшицевой и выпуклой, такая что любой метод 1 удовлетворяет

$$\min_{i \in [1, k]} f(x^i) - \min_{x \in \mathbb{B}(R)} f(x) \geq \frac{GR}{2(1 + \sqrt{k})}$$

для  $R > 0$  и  $k \leq n$ , где  $n$  — размерность задачи.

**Идея доказательства:** построить такую функцию  $f$ , что для любого метода 1 выполняется

$$\text{span} \{g_0, g_1, \dots, g_k\} \subset \text{span} \{e_1, e_2, \dots, e_i\}$$

где  $e_i$  —  $i$ -й вектор стандартного базиса. На итерации  $k \leq n$  как минимум  $n - k$  координат  $x$  равны 0. Это помогает получить оценку погрешности.

## Негладкий случай (доказательство)

Рассмотрим функцию:

$$f(x) = \beta \max_{i \in [1, k]} x[i] + \frac{\alpha}{2} \|x\|_2^2,$$

где  $\alpha, \beta \in \mathbb{R}$  — параметры, а  $x[1 : k]$  обозначает первые  $k$  компонент вектора  $x$ .

## Негладкий случай (доказательство)

Рассмотрим функцию:

$$f(x) = \beta \max_{i \in [1, k]} x[i] + \frac{\alpha}{2} \|x\|_2^2,$$

где  $\alpha, \beta \in \mathbb{R}$  — параметры, а  $x[1 : k]$  обозначает первые  $k$  компонент вектора  $x$ .

**Ключевые свойства:**

- Функция  $f(x)$  является  $\alpha$ -сильно выпуклой благодаря квадратичному слагаемому  $\frac{\alpha}{2} \|x\|_2^2$ .

# Негладкий случай (доказательство)

Рассмотрим функцию:

$$f(x) = \beta \max_{i \in [1, k]} x[i] + \frac{\alpha}{2} \|x\|_2^2,$$

где  $\alpha, \beta \in \mathbb{R}$  — параметры, а  $x[1 : k]$  обозначает первые  $k$  компонент вектора  $x$ .

**Ключевые свойства:**

- Функция  $f(x)$  является  $\alpha$ -сильно выпуклой благодаря квадратичному слагаемому  $\frac{\alpha}{2} \|x\|_2^2$ .
- Функция негладкая, потому что первое слагаемое недифференцируемо в точке, где достигается максимум по координатам  $x$ .

# Негладкий случай (доказательство)

Рассмотрим функцию:

$$f(x) = \beta \max_{i \in [1, k]} x[i] + \frac{\alpha}{2} \|x\|_2^2,$$

где  $\alpha, \beta \in \mathbb{R}$  — параметры, а  $x[1 : k]$  обозначает первые  $k$  компонент вектора  $x$ .

**Ключевые свойства:**

- Функция  $f(x)$  является  $\alpha$ -сильно выпуклой благодаря квадратичному слагаемому  $\frac{\alpha}{2} \|x\|_2^2$ .
- Функция негладкая, потому что первое слагаемое недифференцируемо в точке, где достигается максимум по координатам  $x$ .

## Негладкий случай (доказательство)

Рассмотрим функцию:

$$f(x) = \beta \max_{i \in [1, k]} x[i] + \frac{\alpha}{2} \|x\|_2^2,$$

где  $\alpha, \beta \in \mathbb{R}$  — параметры, а  $x[1 : k]$  обозначает первые  $k$  компонент вектора  $x$ .

**Ключевые свойства:**

- Функция  $f(x)$  является  $\alpha$ -сильно выпуклой благодаря квадратичному слагаемому  $\frac{\alpha}{2} \|x\|_2^2$ .
- Функция негладкая, потому что первое слагаемое недифференцируемо в точке, где достигается максимум по координатам  $x$ .

Рассмотрим субдифференциал  $f(x)$  в точке  $x$ :

$$\begin{aligned} \partial f(x) &= \partial \left( \beta \max_{i \in [1, k]} x[i] \right) + \partial \left( \frac{\alpha}{2} \|x\|_2^2 \right) \\ &= \beta \partial \left( \max_{i \in [1, k]} x[i] \right) + \alpha x \\ &= \beta \text{conv} \left\{ e_i \mid i : x[i] = \max_j x[j] \right\} + \alpha x \end{aligned}$$



## Негладкий случай (доказательство)

Рассмотрим функцию:

$$f(x) = \beta \max_{i \in [1, k]} x[i] + \frac{\alpha}{2} \|x\|_2^2,$$

где  $\alpha, \beta \in \mathbb{R}$  — параметры, а  $x[1 : k]$  обозначает первые  $k$  компонент вектора  $x$ .

**Ключевые свойства:**

- Функция  $f(x)$  является  $\alpha$ -сильно выпуклой благодаря квадратичному слагаемому  $\frac{\alpha}{2} \|x\|_2^2$ .
- Функция негладкая, потому что первое слагаемое недифференцируемо в точке, где достигается максимум по координатам  $x$ .

Рассмотрим субдифференциал  $f(x)$  в точке  $x$ :

$$\begin{aligned} \partial f(x) &= \partial \left( \beta \max_{i \in [1, k]} x[i] \right) + \partial \left( \frac{\alpha}{2} \|x\|_2^2 \right) \\ &= \beta \partial \left( \max_{i \in [1, k]} x[i] \right) + \alpha x \\ &= \beta \operatorname{conv} \left\{ e_i \mid i : x[i] = \max_j x[j] \right\} + \alpha x \end{aligned}$$

Легко видеть, что если  $g \in \partial f(x)$  и  $\|x\| \leq R$ , то

$$\|g\| \leq \alpha R + \beta$$

Следовательно,  $f$  является  $\alpha R + \beta$ -липшицевой на  $B(R)$ .

## Негладкий случай (доказательство)

Далее опишем оракул первого порядка для этой функции. При запросе субградиента в точке  $x$  оракул возвращает

$$\alpha x + \beta e_i,$$

где  $i$  — *первая* координата, для которой  $x[i] = \max_{1 \leq j \leq k} x[j]$ .

- Гарантируем  $\|x^0\| \leq R$ , начиная с  $x^0 = 0$ .

## Негладкий случай (доказательство)

Далее опишем оракул первого порядка для этой функции. При запросе субградиента в точке  $x$  оракул возвращает

$$\alpha x + \beta e_i,$$

где  $i$  — *первая* координата, для которой  $x[i] = \max_{1 \leq j \leq k} x[j]$ .

- Гарантируем  $\|x^0\| \leq R$ , начиная с  $x^0 = 0$ .
- При запросе в точке  $x^0 = 0$  оракул возвращает  $e_1$ . Следовательно,  $x^1$  лежит на прямой, порождённой  $e_1$ .

## Негладкий случай (доказательство)

Далее опишем оракул первого порядка для этой функции. При запросе субградиента в точке  $x$  оракул возвращает

$$\alpha x + \beta e_i,$$

где  $i$  — первая координата, для которой  $x[i] = \max_{1 \leq j \leq k} x[j]$ .

- Гарантируем  $\|x^0\| \leq R$ , начиная с  $x^0 = 0$ .
- При запросе в точке  $x^0 = 0$  оракул возвращает  $e_1$ . Следовательно,  $x^1$  лежит на прямой, порождённой  $e_1$ .
- По индукции можно показать, что для всех  $i$  итерат  $x^i$  лежит в линейной оболочке  $\{e_1, \dots, e_i\}$ . В частности, при  $i \leq k$  координата  $k+1$  у  $x_i$  равна нулю, и из структуры  $f(x)$  следует:

$$f(x^i) \geq 0.$$

## Негладкий случай (доказательство)

- Осталось вычислить минимальное значение  $f$ . Определим точку  $y \in \mathbb{R}^n$  как

$$y[i] = -\frac{\beta}{\alpha k} \quad \text{for } 1 \leq i \leq k, \quad y[i] = 0 \quad \text{for } k+1 \leq i \leq n.$$

## Негладкий случай (доказательство)

- Осталось вычислить минимальное значение  $f$ . Определим точку  $y \in \mathbb{R}^n$  как

$$y[i] = -\frac{\beta}{\alpha k} \quad \text{for } 1 \leq i \leq k, \quad y[i] = 0 \quad \text{for } k+1 \leq i \leq n.$$

- Заметим, что  $0 \in \partial f(y)$ :

$$\begin{aligned} \partial f(y) &= \alpha y + \beta \text{conv} \left\{ e_i \mid i : y[i] = \max_j y[j] \right\} \\ &= \alpha y + \beta \text{conv} \{ e_i \mid i : y[i] = 0 \} \\ 0 &\in \partial f(y). \end{aligned}$$

## Негладкий случай (доказательство)

- Осталось вычислить минимальное значение  $f$ . Определим точку  $y \in \mathbb{R}^n$  как

$$y[i] = -\frac{\beta}{\alpha k} \quad \text{for } 1 \leq i \leq k, \quad y[i] = 0 \quad \text{for } k+1 \leq i \leq n.$$

- Заметим, что  $0 \in \partial f(y)$ :

$$\begin{aligned} \partial f(y) &= \alpha y + \beta \text{conv} \left\{ e_i \mid i : y[i] = \max_j y[j] \right\} \\ &= \alpha y + \beta \text{conv} \{ e_i \mid i : y[i] = 0 \} \\ 0 &\in \partial f(y). \end{aligned}$$

- Следовательно, минимальное значение  $f = f(y) = f(x^*)$  равно

$$f(y) = -\frac{\beta^2}{\alpha k} + \frac{\alpha}{2} \cdot \frac{\beta^2}{\alpha^2 k} = -\frac{\beta^2}{2\alpha k}.$$

## Негладкий случай (доказательство)

- Осталось вычислить минимальное значение  $f$ . Определим точку  $y \in \mathbb{R}^n$  как

$$y[i] = -\frac{\beta}{\alpha k} \quad \text{for } 1 \leq i \leq k, \quad y[i] = 0 \quad \text{for } k+1 \leq i \leq n.$$

- Заметим, что  $0 \in \partial f(y)$ :

$$\begin{aligned} \partial f(y) &= \alpha y + \beta \text{conv} \left\{ e_i \mid i : y[i] = \max_j y[j] \right\} \\ &= \alpha y + \beta \text{conv} \{ e_i \mid i : y[i] = 0 \} \\ 0 &\in \partial f(y). \end{aligned}$$

- Следовательно, минимальное значение  $f = f(y) = f(x^*)$  равно

$$f(y) = -\frac{\beta^2}{\alpha k} + \frac{\alpha}{2} \cdot \frac{\beta^2}{\alpha^2 k} = -\frac{\beta^2}{2\alpha k}.$$

- Тогда имеем:

$$f(x^i) - f(x^*) \geq 0 - \left( -\frac{\beta^2}{2\alpha k} \right) \geq \frac{\beta^2}{2\alpha k}.$$



## Негладкий случай (доказательство)

Мы получили:  $f(x^i) - f(x^*) \geq \frac{\beta^2}{2\alpha k}$ , но нам нужно доказать, что  $\min_{i \in [1, k]} f(x^i) - f(x^*) \geq \frac{GR}{2(1+\sqrt{k})}$ .

## Негладкий случай (доказательство)

Мы получили:  $f(x^i) - f(x^*) \geq \frac{\beta^2}{2\alpha k}$ , но нам нужно доказать, что  $\min_{i \in [1, k]} f(x^i) - f(x^*) \geq \frac{GR}{2(1+\sqrt{k})}$ .

### Выпуклый случай

$$\alpha = \frac{G}{R} \frac{1}{1 + \sqrt{k}} \quad \beta = \frac{\sqrt{k}}{1 + \sqrt{k}}$$

$$\frac{\beta^2}{2\alpha} = \frac{GRk}{2(1 + \sqrt{k})}$$

Заметим, в частности, что  $\|y\|_2^2 = \frac{\beta^2}{\alpha^2 k} = R^2$  при этих параметрах

$$\min_{i \in [1, k]} f(x^i) - f(x^*) \geq \frac{\beta^2}{2\alpha k} = \frac{GR}{2(1 + \sqrt{k})}$$

## Негладкий случай (доказательство)

Мы получили:  $f(x^i) - f(x^*) \geq \frac{\beta^2}{2\alpha k}$ , но нам нужно доказать, что  $\min_{i \in [1, k]} f(x^i) - f(x^*) \geq \frac{GR}{2(1+\sqrt{k})}$ .

Выпуклый случай

$$\alpha = \frac{G}{R} \frac{1}{1 + \sqrt{k}} \quad \beta = \frac{\sqrt{k}}{1 + \sqrt{k}}$$

$$\frac{\beta^2}{2\alpha} = \frac{GRk}{2(1 + \sqrt{k})}$$

Заметим, в частности, что  $\|y\|_2^2 = \frac{\beta^2}{\alpha^2 k} = R^2$  при этих параметрах

$$\min_{i \in [1, k]} f(x^i) - f(x^*) \geq \frac{\beta^2}{2\alpha k} = \frac{GR}{2(1 + \sqrt{k})}$$

Сильно выпуклый случай

$$\alpha = \frac{G}{2R} \quad \beta = \frac{G}{2}$$

Заметим, в частности, что  $\|y\|_2^2 = \frac{\beta^2}{\alpha^2 k} = \frac{G^2}{4\alpha^2 k} = R^2$  при этих параметрах

$$\min_{i \in [1, k]} f(x^i) - f(x^*) \geq \frac{G^2}{8\alpha k}$$

## Приложения

# Линейные наименьшие квадраты с $l_1$ -регуляризацией



$$\min_{x \in \mathbb{R}^n} \frac{1}{2} \|Ax - b\|_2^2 + \lambda \|x\|_1$$

Алгоритм можно записать так:

$$x_{k+1} = x_k - \alpha_k (A^\top (Ax_k - b) + \lambda \text{sign}(x_k)) ,$$

где функция знака применяется поэлементно.

LLS with  $l_1$  regularization. 2 runs.  $\lambda = 1$



## Логистическая регрессия с регуляризацией

Пусть  $(x_i, y_i) \in \mathbb{R}^p \times \{0, 1\}$  для  $i = 1, \dots, n$ . Тогда функция логистической регрессии задаётся как:

$$f(\theta) = \sum_{i=1}^n (-y_i x_i^T \theta + \log(1 + \exp(x_i^T \theta)))$$

Это гладкая выпуклая функция; её градиент равен:

$$\nabla f(\theta) = \sum_{i=1}^n (y_i - s_i(\theta)) x_i$$

где  $s_i(\theta) = \frac{\exp(x_i^T \theta)}{1 + \exp(x_i^T \theta)}$ ,  $i = 1, \dots, n$ . Рассмотрим регуляризованную задачу:

$$f(\theta) + \lambda r(\theta) \rightarrow \min_{\theta}$$

где  $r(\theta) = \|\theta\|_2^2$  соответствует гребневой (ridge) регуляризации, а  $r(\theta) = \|\theta\|_1$  — лассо (lasso).

# Метод опорных векторов

Пусть  $D = \{(x_i, y_i) \mid x_i \in \mathbb{R}^n, y_i \in \{\pm 1\}\}$

Нужно найти  $\theta \in \mathbb{R}^n$  и  $b \in \mathbb{R}$  такие, что

$$\min_{\theta \in \mathbb{R}^n, b \in \mathbb{R}} \frac{1}{2} \|\theta\|_2^2 + C \sum_{i=1}^m \max[0, 1 - y_i(\theta^\top x_i + b)]$$

## Метод опорных векторов. Субградиент

Субградиент hinge loss  $h(\theta) = \max[0, 1 - y_i(\theta^\top x_i + b)]$ :

$$\partial_\theta h = \begin{cases} 0, & \text{если } y_i(\theta^\top x_i + b) > 1 \\ -y_i x_i, & \text{если } y_i(\theta^\top x_i + b) < 1 \\ [-y_i x_i, 0], & \text{если } y_i(\theta^\top x_i + b) = 1 \end{cases}$$



## Метод опорных векторов. Субградиент

Субградиент hinge loss  $h(\theta) = \max[0, 1 - y_i(\theta^\top x_i + b)]$ :

$$\partial_\theta h = \begin{cases} 0, & \text{если } y_i(\theta^\top x_i + b) > 1 \\ -y_i x_i, & \text{если } y_i(\theta^\top x_i + b) < 1 \\ [-y_i x_i, 0], & \text{если } y_i(\theta^\top x_i + b) = 1 \end{cases}$$

Итерация субградиентного метода (для упрощённой SVM без  $b$ ):

$$\theta_{k+1} = \theta_k - \alpha_k \left( \theta_k - C \frac{1}{m} \sum_{i: y_i \theta_k^\top x_i < 1} y_i x_i \right)$$

# Метод опорных векторов. Численные эксперименты

SVM (Hinge Loss +  $\ell_2$ -регуляризация).  $m=400$ ,  $n=30$ ,  $C=1.0$




Рис. 21: Субградиентный метод для SVM. Сравнение различных стратегий выбора шага

# Метод опорных векторов. Немонотонность

SVM. Немонотонность субградиентного метода.  $m=400$ ,  $n=30$ ,  $C=1.0$




Рис. 22: Немонотонность  $f(\theta_k)$  при постоянном шаге. Убывающий шаг уменьшает осцилляции. Сходимость по аргументу зависит от стратегии


## Дополнительные эксперименты

# Скорость сходимости: теория vs практика


$$f(x) = \frac{1}{m} \|Ax - b\|_1$$

Скорость сходимости субградиентного метода: теория vs практика

Выпуклый:  $f(x) = \frac{1}{m} \|Ax - b\|_1$



Сильно выпуклый:  $f(x) = \frac{1}{m} \|Ax - b\|_1 + \frac{\mu}{2} \|x\|^2$




## Шаг Поляка

$$\alpha_k = \frac{f(x_k) - f^*}{\|g_k\|^2}$$


Если известно оптимальное значение  $f^*$ , шаг Поляка значительно ускоряет сходимость субградиентного метода.

$f(x) = \frac{1}{m} \|Ax - b\|_1$ . Шаг Поляка vs стандартные стратегии.  $m=200$ ,  $n=50$


Function Gap



Distance to Optimal Solution



Polyak: немонотонность




$\alpha_k = 0.1$      $\alpha_k = R/(G\sqrt{k})$      $\alpha_k = 2/k$     Polyak:  $(f(x_k) - f^*)/\|g_k\|^2$

## Влияние размерности задачи


$$f(x) = \frac{1}{m} \|Ax - b\|_1, \quad \alpha_k = \frac{R}{G\sqrt{k}}$$

Влияние размерности  $n$  на сходимость.  $f(x) = \frac{1}{m} \|Ax - b\|_1$ ,  $m = 500$ ,  $\alpha_k = R/(G\sqrt{k})$

Линейная шкала



Лог-лог шкала



- Subgradient Methods Stephen Boyd (with help from Jaehyun Park)