




Проксимальный градиентный метод.

Даниил Меркулов

Методы оптимизации. МФТИ

Субградиентный метод

Негладкие задачи

ℓ_1 induces sparsity

ℓ_2 regularization. $\|Xw - y\|_2^2 \rightarrow \min_{\|w\|_2 \leq 1}$



ℓ_1 regularization. $\|Xw - y\|_2^2 \rightarrow \min_{\|w\|_1 \leq 1}$



@fminxyz

Субградиентный метод

Субградиентный метод:

$$\min_{x \in \mathbb{R}^n} f(x)$$

$$x_{k+1} = x_k - \alpha_k g_k, \quad g_k \in \partial f(x_k)$$

Субградиентный метод

Субградиентный метод:

$$\min_{x \in \mathbb{R}^n} f(x)$$

$$x_{k+1} = x_k - \alpha_k g_k, \quad g_k \in \partial f(x_k)$$

выпуклый (негладкий)

$$f(x_k) - f^* \sim \mathcal{O}\left(\frac{1}{\sqrt{k}}\right)$$
$$k_\varepsilon \sim \mathcal{O}\left(\frac{1}{\varepsilon^2}\right)$$

сильно выпуклый (негладкий)

$$f(x_k) - f^* \sim \mathcal{O}\left(\frac{1}{k}\right)$$
$$k_\varepsilon \sim \mathcal{O}\left(\frac{1}{\varepsilon}\right)$$

Субградиентный метод

Субградиентный метод:

$$\min_{x \in \mathbb{R}^n} f(x)$$

$$x_{k+1} = x_k - \alpha_k g_k, \quad g_k \in \partial f(x_k)$$

выпуклый (негладкий)

$$f(x_k) - f^* \sim \mathcal{O}\left(\frac{1}{\sqrt{k}}\right)$$
$$k_\varepsilon \sim \mathcal{O}\left(\frac{1}{\varepsilon^2}\right)$$

сильно выпуклый (негладкий)

$$f(x_k) - f^* \sim \mathcal{O}\left(\frac{1}{k}\right)$$
$$k_\varepsilon \sim \mathcal{O}\left(\frac{1}{\varepsilon}\right)$$

i Theorem

Пусть f является G -липшицевой и выпуклой, тогда субградиентный метод сходится как:

где

- $\alpha = \frac{R}{G\sqrt{k}}$

$$f(\bar{x}) - f^* \leq \frac{GR}{\sqrt{k}},$$

Субградиентный метод

Субградиентный метод:

$$\min_{x \in \mathbb{R}^n} f(x)$$

$$x_{k+1} = x_k - \alpha_k g_k, \quad g_k \in \partial f(x_k)$$

выпуклый (негладкий)

$$f(x_k) - f^* \sim \mathcal{O}\left(\frac{1}{\sqrt{k}}\right)$$
$$k_\varepsilon \sim \mathcal{O}\left(\frac{1}{\varepsilon^2}\right)$$

сильно выпуклый (негладкий)

$$f(x_k) - f^* \sim \mathcal{O}\left(\frac{1}{k}\right)$$
$$k_\varepsilon \sim \mathcal{O}\left(\frac{1}{\varepsilon}\right)$$

i Theorem

Пусть f является G -липшицевой и выпуклой, тогда субградиентный метод сходится как:

где

- $\alpha = \frac{R}{G\sqrt{k}}$
- $R = \|x_0 - x^*\|$

$$f(\bar{x}) - f^* \leq \frac{GR}{\sqrt{k}},$$

Субградиентный метод

Субградиентный метод:

$$\min_{x \in \mathbb{R}^n} f(x)$$

$$x_{k+1} = x_k - \alpha_k g_k, \quad g_k \in \partial f(x_k)$$

выпуклый (негладкий)

$$f(x_k) - f^* \sim \mathcal{O}\left(\frac{1}{\sqrt{k}}\right)$$
$$k_\varepsilon \sim \mathcal{O}\left(\frac{1}{\varepsilon^2}\right)$$

сильно выпуклый (негладкий)

$$f(x_k) - f^* \sim \mathcal{O}\left(\frac{1}{k}\right)$$
$$k_\varepsilon \sim \mathcal{O}\left(\frac{1}{\varepsilon}\right)$$

i Theorem

Пусть f является G -липшицевой и выпуклой, тогда субградиентный метод сходится как:

$$f(\bar{x}) - f^* \leq \frac{GR}{\sqrt{k}},$$

где

- $\alpha = \frac{R}{G\sqrt{k}}$
- $R = \|x_0 - x^*\|$
- $\bar{x} = \frac{1}{k} \sum_{i=0}^{k-1} x_i$

Нижние оценки для негладкой выпуклой оптимизации

выпуклый (негладкий)

$$f(x_k) - f^* \sim \mathcal{O}\left(\frac{1}{\sqrt{k}}\right)$$
$$k_\varepsilon \sim \mathcal{O}\left(\frac{1}{\varepsilon^2}\right)$$

сильно выпуклый (негладкий)

$$f(x_k) - f^* \sim \mathcal{O}\left(\frac{1}{k}\right)$$
$$k_\varepsilon \sim \mathcal{O}\left(\frac{1}{\varepsilon}\right)$$

Нижние оценки для негладкой выпуклой оптимизации

выпуклый (негладкий)

$$f(x_k) - f^* \sim \mathcal{O}\left(\frac{1}{\sqrt{k}}\right)$$
$$k_\varepsilon \sim \mathcal{O}\left(\frac{1}{\varepsilon^2}\right)$$

сильно выпуклый (негладкий)

$$f(x_k) - f^* \sim \mathcal{O}\left(\frac{1}{k}\right)$$
$$k_\varepsilon \sim \mathcal{O}\left(\frac{1}{\varepsilon}\right)$$

- Субградиентный метод является оптимальным для приведённых выше задач.

Нижние оценки для негладкой выпуклой оптимизации

выпуклый (негладкий)

$$f(x_k) - f^* \sim \mathcal{O}\left(\frac{1}{\sqrt{k}}\right)$$
$$k_\varepsilon \sim \mathcal{O}\left(\frac{1}{\varepsilon^2}\right)$$

сильно выпуклый (негладкий)

$$f(x_k) - f^* \sim \mathcal{O}\left(\frac{1}{k}\right)$$
$$k_\varepsilon \sim \mathcal{O}\left(\frac{1}{\varepsilon}\right)$$

- Субградиентный метод является оптимальным для приведённых выше задач.
- Можно использовать зеркальный спуск (обобщение субградиентного метода на случай неевклидова расстояния) с той же скоростью сходимости, чтобы лучше учитывать геометрию задачи.

Нижние оценки для негладкой выпуклой оптимизации

выпуклый (негладкий)

$$f(x_k) - f^* \sim \mathcal{O}\left(\frac{1}{\sqrt{k}}\right)$$
$$k_\varepsilon \sim \mathcal{O}\left(\frac{1}{\varepsilon^2}\right)$$

сильно выпуклый (негладкий)

$$f(x_k) - f^* \sim \mathcal{O}\left(\frac{1}{k}\right)$$
$$k_\varepsilon \sim \mathcal{O}\left(\frac{1}{\varepsilon}\right)$$

- Субградиентный метод является оптимальным для приведённых выше задач.
- Можно использовать зеркальный спуск (обобщение субградиентного метода на случай неевклидова расстояния) с той же скоростью сходимости, чтобы лучше учитывать геометрию задачи.
- Однако мы можем достичь стандартной скорости градиентного спуска $\mathcal{O}\left(\frac{1}{k}\right)$ (и даже ускоренной $\mathcal{O}\left(\frac{1}{k^2}\right)$), если будем использовать структуру задачи.

Проксимальный оператор

Интуиция проксимального отображения через схему Эйлера

Рассмотрим ODE градиентного потока:

$$\frac{dx}{dt} = -\nabla f(x)$$

Явная схема Эйлера:

Интуиция проксимального отображения через схему Эйлера

Рассмотрим ODE градиентного потока:

$$\frac{dx}{dt} = -\nabla f(x)$$

Явная схема Эйлера:

$$\frac{x_{k+1} - x_k}{\alpha} = -\nabla f(x_k)$$

Приводит к обычному методу градиентного спуска

Интуиция проксимального отображения через схему Эйлера

Рассмотрим ODE градиентного потока:

$$\frac{dx}{dt} = -\nabla f(x)$$

Явная схема Эйлера:

$$\frac{x_{k+1} - x_k}{\alpha} = -\nabla f(x_k)$$

Неявная схема Эйлера:

$$\frac{x_{k+1} - x_k}{\alpha} = -\nabla f(x_{k+1})$$

Приводит к обычному методу градиентного спуска

Интуиция проксимального отображения через схему Эйлера

Рассмотрим ODE градиентного потока:

$$\frac{dx}{dt} = -\nabla f(x)$$

Явная схема Эйлера:

$$\frac{x_{k+1} - x_k}{\alpha} = -\nabla f(x_k)$$

Приводит к обычному методу градиентного спуска

Неявная схема Эйлера:

$$\begin{aligned}\frac{x_{k+1} - x_k}{\alpha} &= -\nabla f(x_{k+1}) \\ \frac{x_{k+1} - x_k}{\alpha} + \nabla f(x_{k+1}) &= 0\end{aligned}$$

Интуиция проксимального отображения через схему Эйлера

Рассмотрим ODE градиентного потока:

$$\frac{dx}{dt} = -\nabla f(x)$$

Явная схема Эйлера:

$$\frac{x_{k+1} - x_k}{\alpha} = -\nabla f(x_k)$$

Приводит к обычному методу градиентного спуска

Неявная схема Эйлера:

$$\frac{x_{k+1} - x_k}{\alpha} = -\nabla f(x_{k+1})$$

$$\frac{x_{k+1} - x_k}{\alpha} + \nabla f(x_{k+1}) = 0$$

$$\frac{x - x_k}{\alpha} + \nabla f(x) \Big|_{x=x_{k+1}} = 0$$

Интуиция проксимального отображения через схему Эйлера

Рассмотрим ODE градиентного потока:

$$\frac{dx}{dt} = -\nabla f(x)$$

Явная схема Эйлера:

$$\frac{x_{k+1} - x_k}{\alpha} = -\nabla f(x_k)$$

Приводит к обычному методу градиентного спуска

Неявная схема Эйлера:

$$\frac{x_{k+1} - x_k}{\alpha} = -\nabla f(x_{k+1})$$

$$\frac{x_{k+1} - x_k}{\alpha} + \nabla f(x_{k+1}) = 0$$

$$\frac{x - x_k}{\alpha} + \nabla f(x) \Big|_{x=x_{k+1}} = 0$$

$$\nabla \left[\frac{1}{2\alpha} \|x - x_k\|_2^2 + f(x) \right] \Big|_{x=x_{k+1}} = 0$$

Интуиция проксимального отображения через схему Эйлера

Рассмотрим ODE градиентного потока:

$$\frac{dx}{dt} = -\nabla f(x)$$

Явная схема Эйлера:

$$\frac{x_{k+1} - x_k}{\alpha} = -\nabla f(x_k)$$

Приводит к обычному методу градиентного спуска

Неявная схема Эйлера:

$$\frac{x_{k+1} - x_k}{\alpha} = -\nabla f(x_{k+1})$$

$$\frac{x_{k+1} - x_k}{\alpha} + \nabla f(x_{k+1}) = 0$$

$$\frac{x - x_k}{\alpha} + \nabla f(x) \Big|_{x=x_{k+1}} = 0$$

$$\nabla \left[\frac{1}{2\alpha} \|x - x_k\|_2^2 + f(x) \right] \Big|_{x=x_{k+1}} = 0$$

$$x_{k+1} = \arg \min_{x \in \mathbb{R}^n} \left[f(x) + \frac{1}{2\alpha} \|x - x_k\|_2^2 \right]$$

Интуиция проксимального отображения через схему Эйлера

Рассмотрим ODE градиентного потока:

$$\frac{dx}{dt} = -\nabla f(x)$$

Явная схема Эйлера:

$$\frac{x_{k+1} - x_k}{\alpha} = -\nabla f(x_k)$$

Приводит к обычному методу градиентного спуска

Неявная схема Эйлера:

$$\frac{x_{k+1} - x_k}{\alpha} = -\nabla f(x_{k+1})$$

$$\frac{x_{k+1} - x_k}{\alpha} + \nabla f(x_{k+1}) = 0$$

$$\frac{x - x_k}{\alpha} + \nabla f(x) \Big|_{x=x_{k+1}} = 0$$

$$\nabla \left[\frac{1}{2\alpha} \|x - x_k\|_2^2 + f(x) \right] \Big|_{x=x_{k+1}} = 0$$

$$x_{k+1} = \arg \min_{x \in \mathbb{R}^n} \left[f(x) + \frac{1}{2\alpha} \|x - x_k\|_2^2 \right]$$

Интуиция проксимального отображения через схему Эйлера

Рассмотрим ODE градиентного потока:

$$\frac{dx}{dt} = -\nabla f(x)$$

Явная схема Эйлера:

$$\frac{x_{k+1} - x_k}{\alpha} = -\nabla f(x_k)$$

Приводит к обычному методу градиентного спуска

Неявная схема Эйлера:

$$\frac{x_{k+1} - x_k}{\alpha} = -\nabla f(x_{k+1})$$

$$\frac{x_{k+1} - x_k}{\alpha} + \nabla f(x_{k+1}) = 0$$

$$\frac{x - x_k}{\alpha} + \nabla f(x) \Big|_{x=x_{k+1}} = 0$$

$$\nabla \left[\frac{1}{2\alpha} \|x - x_k\|_2^2 + f(x) \right] \Big|_{x=x_{k+1}} = 0$$

$$x_{k+1} = \arg \min_{x \in \mathbb{R}^n} \left[f(x) + \frac{1}{2\alpha} \|x - x_k\|_2^2 \right]$$

! Проксимальный оператор

$$\text{prox}_{f,\alpha}(x_k) = \arg \min_{x \in \mathbb{R}^n} \left[f(x) + \frac{1}{2\alpha} \|x - x_k\|_2^2 \right]$$

Визуализация проксимального оператора

$$\text{Prox}_f(x) = \operatorname{argmin}_{x'} \frac{1}{2} \|x - x'\|^2 + f(x')$$




Рис. 1: Источник

Связь проксимального оператора с ГС и методом Ньютона

- Градиентный спуск из проксимального метода. Вернёмся к дискретизации:

Связь проксимального оператора с ГС и методом Ньютона

- Градиентный спуск из проксимального метода. Вернёмся к дискретизации:

$$x_{k+1} + \alpha \nabla f(x_{k+1}) = x_k$$

Связь проксимального оператора с ГС и методом Ньютона

- **Градиентный спуск из проксимального метода.** Вернёмся к дискретизации:

$$x_{k+1} + \alpha \nabla f(x_{k+1}) = x_k$$

$$(I + \alpha \nabla f)(x_{k+1}) = x_k$$

Связь проксимального оператора с ГС и методом Ньютона

- Градиентный спуск из проксимального метода. Вернёмся к дискретизации:

$$x_{k+1} + \alpha \nabla f(x_{k+1}) = x_k$$

$$(I + \alpha \nabla f)(x_{k+1}) = x_k$$

$$x_{k+1} = (I + \alpha \nabla f)^{-1} x_k \stackrel{\alpha \rightarrow 0}{\approx} (I - \alpha \nabla f) x_k$$

Связь проксимального оператора с ГС и методом Ньютона

- Градиентный спуск из проксимального метода. Вернёмся к дискретизации:

$$x_{k+1} + \alpha \nabla f(x_{k+1}) = x_k$$

$$(I + \alpha \nabla f)(x_{k+1}) = x_k$$

$$x_{k+1} = (I + \alpha \nabla f)^{-1} x_k \stackrel{\alpha \rightarrow 0}{\approx} (I - \alpha \nabla f) x_k$$

Связь проксимального оператора с ГС и методом Ньютона

- **Градиентный спуск из проксимального метода.** Вернёмся к дискретизации:

$$x_{k+1} + \alpha \nabla f(x_{k+1}) = x_k$$

$$(I + \alpha \nabla f)(x_{k+1}) = x_k$$

$$x_{k+1} = (I + \alpha \nabla f)^{-1} x_k \stackrel{\alpha \rightarrow 0}{\approx} (I - \alpha \nabla f) x_k$$

Таким образом, при $\alpha \rightarrow 0$ мы получаем обычный градиентный спуск: $x_{k+1} = x_k - \alpha \nabla f(x_k)$

- **Метод Ньютона из проксимального метода.** Рассмотрим проксимальное отображение от квадратичной аппроксимации Тейлора функции $f_{x_k}^{II}(x)$:

Связь проксимального оператора с ГС и методом Ньютона

- **Градиентный спуск из проксимального метода.** Вернёмся к дискретизации:

$$x_{k+1} + \alpha \nabla f(x_{k+1}) = x_k$$

$$(I + \alpha \nabla f)(x_{k+1}) = x_k$$

$$x_{k+1} = (I + \alpha \nabla f)^{-1} x_k \stackrel{\alpha \rightarrow 0}{\approx} (I - \alpha \nabla f) x_k$$

Таким образом, при $\alpha \rightarrow 0$ мы получаем обычный градиентный спуск: $x_{k+1} = x_k - \alpha \nabla f(x_k)$

- **Метод Ньютона из проксимального метода.** Рассмотрим проксимальное отображение от квадратичной аппроксимации Тейлора функции $f_{x_k}^{II}(x)$:

$$x_{k+1} = \text{prox}_{f_{x_k}^{II}, \alpha}(x_k) = \arg \min_{x \in \mathbb{R}^n} \left[f(x_k) + \langle \nabla f(x_k), x - x_k \rangle + \frac{1}{2} \langle \nabla^2 f(x_k)(x - x_k), x - x_k \rangle + \frac{1}{2\alpha} \|x - x_k\|_2^2 \right]$$

Связь проксимального оператора с ГС и методом Ньютона

- Градиентный спуск из проксимального метода. Вернёмся к дискретизации:

$$\begin{aligned}x_{k+1} + \alpha \nabla f(x_{k+1}) &= x_k \\(I + \alpha \nabla f)(x_{k+1}) &= x_k \\x_{k+1} &= (I + \alpha \nabla f)^{-1} x_k \stackrel{\alpha \rightarrow 0}{\approx} (I - \alpha \nabla f) x_k\end{aligned}$$

Таким образом, при $\alpha \rightarrow 0$ мы получаем обычный градиентный спуск: $x_{k+1} = x_k - \alpha \nabla f(x_k)$

- Метод Ньютона из проксимального метода.** Рассмотрим проксимальное отображение от квадратичной аппроксимации Тейлора функции $f_{x_k}^{II}(x)$:

$$\begin{aligned}x_{k+1} = \text{prox}_{f_{x_k}^{II}, \alpha}(x_k) &= \arg \min_{x \in \mathbb{R}^n} \left[f(x_k) + \langle \nabla f(x_k), x - x_k \rangle + \frac{1}{2} \langle \nabla^2 f(x_k)(x - x_k), x - x_k \rangle + \frac{1}{2\alpha} \|x - x_k\|_2^2 \right] \\ \nabla f(x_k) + \nabla^2 f(x_k)(x - x_k) + \frac{1}{\alpha}(x - x_k) \Big|_{x=x_{k+1}} &= 0\end{aligned}$$

Связь проксимального оператора с ГС и методом Ньютона

- **Градиентный спуск из проксимального метода.** Вернёмся к дискретизации:

$$\begin{aligned}x_{k+1} + \alpha \nabla f(x_{k+1}) &= x_k \\(I + \alpha \nabla f)(x_{k+1}) &= x_k \\x_{k+1} &= (I + \alpha \nabla f)^{-1} x_k \stackrel{\alpha \rightarrow 0}{\approx} (I - \alpha \nabla f) x_k\end{aligned}$$

Таким образом, при $\alpha \rightarrow 0$ мы получаем обычный градиентный спуск: $x_{k+1} = x_k - \alpha \nabla f(x_k)$

- **Метод Ньютона из проксимального метода.** Рассмотрим проксимальное отображение от квадратичной аппроксимации Тейлора функции $f_{x_k}^{II}(x)$:

$$\begin{aligned}x_{k+1} &= \text{prox}_{f_{x_k}^{II}, \alpha}(x_k) = \arg \min_{x \in \mathbb{R}^n} \left[f(x_k) + \langle \nabla f(x_k), x - x_k \rangle + \frac{1}{2} \langle \nabla^2 f(x_k)(x - x_k), x - x_k \rangle + \frac{1}{2\alpha} \|x - x_k\|_2^2 \right] \\&\quad \left. \nabla f(x_k) + \nabla^2 f(x_k)(x - x_k) + \frac{1}{\alpha}(x - x_k) \right|_{x=x_{k+1}} = 0 \\x_{k+1} &= x_k - \left[\nabla^2 f(x_k) + \frac{1}{\alpha} I \right]^{-1} \nabla f(x_k)\end{aligned}$$

От проекций к проксимальности

Пусть $\mathbb{I}_S$ — индикаторная функция замкнутого выпуклого множества S . Напомним определение ортогональной проекции $\pi_S(y)$

От проекций к проксимальности

Пусть $\mathbb{I}_S$ — индикаторная функция замкнутого выпуклого множества S . Напомним определение ортогональной проекции $\pi_S(y)$

$$\pi_S(y) := \arg \min_{x \in S} \frac{1}{2} \|x - y\|_2^2.$$

От проекций к проксимальности

Пусть $\mathbb{I}_S$ — индикаторная функция замкнутого выпуклого множества S . Напомним определение ортогональной проекции $\pi_S(y)$

$$\pi_S(y) := \arg \min_{x \in S} \frac{1}{2} \|x - y\|_2^2.$$

С помощью индикаторной функции

$$\mathbb{I}_S(x) = \begin{cases} 0, & x \in S, \\ \infty, & x \notin S, \end{cases}$$

От проекций к проксимальности

Пусть $\mathbb{I}_S$ — индикаторная функция замкнутого выпуклого множества S . Напомним определение ортогональной проекции $\pi_S(y)$

$$\pi_S(y) := \arg \min_{x \in S} \frac{1}{2} \|x - y\|_2^2.$$

С помощью индикаторной функции

$$\mathbb{I}_S(x) = \begin{cases} 0, & x \in S, \\ \infty, & x \notin S, \end{cases}$$

Перепишем ортогональную проекцию $\pi_S(y)$ как

$$\pi_S(y) := \arg \min_{x \in \mathbb{R}^n} \frac{1}{2} \|x - y\|^2 + \mathbb{I}_S(x).$$

От проекций к проксимальности

Пусть $\mathbb{I}_S$ — индикаторная функция замкнутого выпуклого множества S . Напомним определение ортогональной проекции $\pi_S(y)$

$$\pi_S(y) := \arg \min_{x \in S} \frac{1}{2} \|x - y\|_2^2.$$

С помощью индикаторной функции

$$\mathbb{I}_S(x) = \begin{cases} 0, & x \in S, \\ \infty, & x \notin S, \end{cases}$$

Перепишем ортогональную проекцию $\pi_S(y)$ как

$$\pi_S(y) := \arg \min_{x \in \mathbb{R}^n} \frac{1}{2} \|x - y\|^2 + \mathbb{I}_S(x).$$

Проксимальность: заменим $\mathbb{I}_S$ на произвольную выпуклую функцию!

$$\text{prox}_r(y) = \text{prox}_{r,1}(y) := \arg \min_x \frac{1}{2} \|x - y\|^2 + r(x)$$

Композитная оптимизация


Регуляризованные / Композитные целевые функции

Многие негладкие задачи имеют вид

$$\min_{x \in \mathbb{R}^n} \varphi(x) = f(x) + r(x)$$

- **Lasso, L1-MHK, compressed sensing**

$$f(x) = \frac{1}{2} \|Ax - b\|_2^2, r(x) = \lambda \|x\|_1$$



Регуляризованные / Композитные целевые функции

Многие негладкие задачи имеют вид


$$\min_{x \in \mathbb{R}^n} \varphi(x) = f(x) + r(x)$$

- **Lasso, L1-МНК, compressed sensing**

$$f(x) = \frac{1}{2} \|Ax - b\|_2^2, r(x) = \lambda \|x\|_1$$

- **L1-логистическая регрессия, разреженная ЛР**

$$f(x) = -y \log h(x) - (1-y) \log(1-h(x)), r(x) = \lambda \|x\|_1$$



Проксимальный градиентный метод из условий оптимальности

Условия оптимальности:

$$0 \in \nabla f(x^*) + \partial r(x^*)$$

Проксимальный градиентный метод из условий оптимальности

Условия оптимальности:

$$0 \in \nabla f(x^*) + \partial r(x^*)$$

$$0 \in \alpha \nabla f(x^*) + \alpha \partial r(x^*)$$

Проксимальный градиентный метод из условий оптимальности

Условия оптимальности:

$$0 \in \nabla f(x^*) + \partial r(x^*)$$

$$0 \in \alpha \nabla f(x^*) + \alpha \partial r(x^*)$$

$$x^* \in \alpha \nabla f(x^*) + (I + \alpha \partial r)(x^*)$$

Проксимальный градиентный метод из условий оптимальности

Условия оптимальности:

$$0 \in \nabla f(x^*) + \partial r(x^*)$$

$$0 \in \alpha \nabla f(x^*) + \alpha \partial r(x^*)$$

$$x^* \in \alpha \nabla f(x^*) + (I + \alpha \partial r)(x^*)$$

$$x^* - \alpha \nabla f(x^*) \in (I + \alpha \partial r)(x^*)$$

Проксимальный градиентный метод из условий оптимальности

Условия оптимальности:

$$0 \in \nabla f(x^*) + \partial r(x^*)$$

$$0 \in \alpha \nabla f(x^*) + \alpha \partial r(x^*)$$

$$x^* \in \alpha \nabla f(x^*) + (I + \alpha \partial r)(x^*)$$

$$x^* - \alpha \nabla f(x^*) \in (I + \alpha \partial r)(x^*)$$

$$x^* = (I + \alpha \partial r)^{-1}(x^* - \alpha \nabla f(x^*))$$

Проксимальный градиентный метод из условий оптимальности

Условия оптимальности:

$$0 \in \nabla f(x^*) + \partial r(x^*)$$

$$0 \in \alpha \nabla f(x^*) + \alpha \partial r(x^*)$$

$$x^* \in \alpha \nabla f(x^*) + (I + \alpha \partial r)(x^*)$$

$$x^* - \alpha \nabla f(x^*) \in (I + \alpha \partial r)(x^*)$$

$$x^* = (I + \alpha \partial r)^{-1}(x^* - \alpha \nabla f(x^*))$$

$$x^* = \text{prox}_{r,\alpha}(x^* - \alpha \nabla f(x^*))$$

Проксимальный градиентный метод из условий оптимальности

Условия оптимальности:

$$0 \in \nabla f(x^*) + \partial r(x^*)$$

$$0 \in \alpha \nabla f(x^*) + \alpha \partial r(x^*)$$

$$x^* \in \alpha \nabla f(x^*) + (I + \alpha \partial r)(x^*)$$

$$x^* - \alpha \nabla f(x^*) \in (I + \alpha \partial r)(x^*)$$

$$x^* = (I + \alpha \partial r)^{-1}(x^* - \alpha \nabla f(x^*))$$

$$x^* = \text{prox}_{r,\alpha}(x^* - \alpha \nabla f(x^*))$$

Проксимальный градиентный метод из условий оптимальности

Условия оптимальности:

$$0 \in \nabla f(x^*) + \partial r(x^*)$$

$$0 \in \alpha \nabla f(x^*) + \alpha \partial r(x^*)$$

$$x^* \in \alpha \nabla f(x^*) + (I + \alpha \partial r)(x^*)$$

$$x^* - \alpha \nabla f(x^*) \in (I + \alpha \partial r)(x^*)$$

$$x^* = (I + \alpha \partial r)^{-1}(x^* - \alpha \nabla f(x^*))$$

$$x^* = \text{prox}_{r,\alpha}(x^* - \alpha \nabla f(x^*))$$

Что приводит к проксимальному градиентному методу:

$$x_{k+1} = \text{prox}_{r,\alpha}(x_k - \alpha \nabla f(x_k))$$

И этот метод сходится со скоростью $\mathcal{O}(\frac{1}{k})$!

Проксимальный градиентный метод из условий оптимальности

Условия оптимальности:

$$0 \in \nabla f(x^*) + \partial r(x^*)$$

$$0 \in \alpha \nabla f(x^*) + \alpha \partial r(x^*)$$

$$x^* \in \alpha \nabla f(x^*) + (I + \alpha \partial r)(x^*)$$

$$x^* - \alpha \nabla f(x^*) \in (I + \alpha \partial r)(x^*)$$

$$x^* = (I + \alpha \partial r)^{-1}(x^* - \alpha \nabla f(x^*))$$

$$x^* = \text{prox}_{r,\alpha}(x^* - \alpha \nabla f(x^*))$$

Что приводит к проксимальному градиентному методу:

$$x_{k+1} = \text{prox}_{r,\alpha}(x_k - \alpha \nabla f(x_k))$$

И этот метод сходится со скоростью $\mathcal{O}(\frac{1}{k})$!

i Альтернативная форма проксимального оператора

$$\text{prox}_{f,\alpha}(x_k) = \text{prox}_{\alpha f}(x_k) = \arg \min_{x \in \mathbb{R}^n} \left[\alpha f(x) + \frac{1}{2} \|x - x_k\|_2^2 \right] \quad \text{prox}_f(x_k) = \arg \min_{x \in \mathbb{R}^n} \left[f(x) + \frac{1}{2} \|x - x_k\|_2^2 \right]$$

Примеры проксимальных операторов

- $r(x) = \lambda \|x\|_1, \lambda > 0$

$$[\text{prox}_r(x)]_i = [|x_i| - \lambda]_+ \cdot \text{sign}(x_i),$$

что также известно как оператор мягкого порогового отсека (soft-thresholding).

Примеры проксимальных операторов

- $r(x) = \lambda \|x\|_1, \lambda > 0$

$$[\text{prox}_r(x)]_i = [|x_i| - \lambda]_+ \cdot \text{sign}(x_i),$$

что также известно как оператор мягкого порогового отсека (soft-thresholding).

- $r(x) = \frac{\lambda}{2} \|x\|_2^2, \lambda > 0$

$$\text{prox}_r(x) = \frac{x}{1 + \lambda}.$$

Примеры проксимальных операторов

- $r(x) = \lambda \|x\|_1, \lambda > 0$

$$[\text{prox}_r(x)]_i = [|x_i| - \lambda]_+ \cdot \text{sign}(x_i),$$

что также известно как оператор мягкого порогового отсека (soft-thresholding).

- $r(x) = \frac{\lambda}{2} \|x\|_2^2, \lambda > 0$

$$\text{prox}_r(x) = \frac{x}{1 + \lambda}.$$

- $r(x) = \mathbb{I}_S(x).$

$$\text{prox}_r(x_k - \alpha \nabla f(x_k)) = \text{proj}_S(x_k - \alpha \nabla f(x_k))$$

Свойства проксимального оператора

Theorem

Пусть $r : \mathbb{R}^n \rightarrow \mathbb{R} \cup \{+\infty\}$ — выпуклая функция, для которой определён prox_r . Если существует такая точка $\hat{x} \in \mathbb{R}^n$, что $r(\hat{x}) < +\infty$, то проксимальный оператор определён однозначно (т.е. всегда возвращает единственное значение).

Доказательство:

Свойства проксимального оператора

Theorem

Пусть $r : \mathbb{R}^n \rightarrow \mathbb{R} \cup \{+\infty\}$ — выпуклая функция, для которой определён prox_r . Если существует такая точка $\hat{x} \in \mathbb{R}^n$, что $r(\hat{x}) < +\infty$, то проксимальный оператор определён однозначно (т.е. всегда возвращает единственное значение).

Доказательство:

Проксимальный оператор возвращает минимум некоторой задачи оптимизации.

Свойства проксимального оператора

Theorem

Пусть $r : \mathbb{R}^n \rightarrow \mathbb{R} \cup \{+\infty\}$ — выпуклая функция, для которой определён prox_r . Если существует такая точка $\hat{x} \in \mathbb{R}^n$, что $r(\hat{x}) < +\infty$, то проксимальный оператор определён однозначно (т.е. всегда возвращает единственное значение).

Доказательство:

Проксимальный оператор возвращает минимум некоторой задачи оптимизации.

Вопрос: что можно сказать об этой задаче?

Свойства проксимального оператора

Theorem

Пусть $r : \mathbb{R}^n \rightarrow \mathbb{R} \cup \{+\infty\}$ — выпуклая функция, для которой определён prox_r . Если существует такая точка $\hat{x} \in \mathbb{R}^n$, что $r(\hat{x}) < +\infty$, то проксимальный оператор определён однозначно (т.е. всегда возвращает единственное значение).

Доказательство:

Проксимальный оператор возвращает минимум некоторой задачи оптимизации.

Вопрос: что можно сказать об этой задаче?

Она является сильно выпуклой, а значит имеет ровно один минимум (существование $\hat{x}$ необходимо для того, чтобы $r(\tilde{x}) + \frac{1}{2}\|x - \tilde{x}\|_2^2$ принимало конечное значение хотя бы в одной точке).

Свойства проксимального оператора

i Theorem

Пусть $r : \mathbb{R}^n \rightarrow \mathbb{R} \cup \{+\infty\}$ — выпуклая функция, для которой определён prox_r . Тогда для любых $x, y \in \mathbb{R}^n$ следующие три условия эквивалентны:

- $\text{prox}_r(x) = y,$

Доказательство

Свойства проксимального оператора

i Theorem

Пусть $r : \mathbb{R}^n \rightarrow \mathbb{R} \cup \{+\infty\}$ — выпуклая функция, для которой определён prox_r . Тогда для любых $x, y \in \mathbb{R}^n$ следующие три условия эквивалентны:

- $\text{prox}_r(x) = y$,
- $x - y \in \partial r(y)$,

Доказательство

Свойства проксимального оператора

i Theorem

Пусть $r : \mathbb{R}^n \rightarrow \mathbb{R} \cup \{+\infty\}$ — выпуклая функция, для которой определён prox_r . Тогда для любых $x, y \in \mathbb{R}^n$ следующие три условия эквивалентны:

- $\text{prox}_r(x) = y$,
- $x - y \in \partial r(y)$,
- $\langle x - y, z - y \rangle \leq r(z) - r(y)$ для любого $z \in \mathbb{R}^n$.

Доказательство

Свойства проксимального оператора

i Theorem

Пусть $r : \mathbb{R}^n \rightarrow \mathbb{R} \cup \{+\infty\}$ — выпуклая функция, для которой определён prox_r . Тогда для любых $x, y \in \mathbb{R}^n$ следующие три условия эквивалентны:

- $\text{prox}_r(x) = y$,
- $x - y \in \partial r(y)$,
- $\langle x - y, z - y \rangle \leq r(z) - r(y)$ для любого $z \in \mathbb{R}^n$.

Доказательство

1. Установим эквивалентность первого и второго условий. Первое условие можно переписать как

$$y = \arg \min_{\tilde{x} \in \mathbb{R}^n} \left(r(\tilde{x}) + \frac{1}{2} \|x - \tilde{x}\|^2 \right).$$

Из условия оптимальности для выпуклой функции r это эквивалентно:

$$0 \in \partial \left(r(\tilde{x}) + \frac{1}{2} \|x - \tilde{x}\|^2 \right) \Big|_{\tilde{x}=y} = \partial r(y) + y - x.$$

Свойства проксимального оператора

i Theorem

Пусть $r : \mathbb{R}^n \rightarrow \mathbb{R} \cup \{+\infty\}$ — выпуклая функция, для которой определён prox_r . Тогда для любых $x, y \in \mathbb{R}^n$ следующие три условия эквивалентны:

- $\text{prox}_r(x) = y$,
- $x - y \in \partial r(y)$,
- $\langle x - y, z - y \rangle \leq r(z) - r(y)$ для любого $z \in \mathbb{R}^n$.

Доказательство

1. Установим эквивалентность первого и второго условий. Первое условие можно переписать как

$$y = \arg \min_{\tilde{x} \in \mathbb{R}^n} \left(r(\tilde{x}) + \frac{1}{2} \|x - \tilde{x}\|^2 \right).$$

Из условия оптимальности для выпуклой функции r это эквивалентно:

$$0 \in \partial \left(r(\tilde{x}) + \frac{1}{2} \|x - \tilde{x}\|^2 \right) \Big|_{\tilde{x}=y} = \partial r(y) + y - x.$$

2. Из определения субдифференциала для любого субградиента $g \in \partial r(y)$ и для любого $z \in \mathbb{R}^n$:

$$\langle g, z - y \rangle \leq r(z) - r(y).$$

В частности, это выполняется для $g = x - y$.
Обратно, это также очевидно: для $g = x - y$ приведённое неравенство выполняется, что означает $g \in \partial r(y)$.

Свойства проксимального оператора

i Theorem

Оператор $\text{prox}_r(x)$ является строго нестягивающим (FNE)

$$\|\text{prox}_r(x) - \text{prox}_r(y)\|_2^2 \leq \langle \text{prox}_r(x) - \text{prox}_r(y), x - y \rangle$$

и нестягивающим:

$$\|\text{prox}_r(x) - \text{prox}_r(y)\|_2 \leq \|x - y\|_2$$

Доказательство

1. Пусть $u = \text{prox}_r(x)$, $v = \text{prox}_r(y)$. Тогда из предыдущего свойства:

$$\langle x - u, z_1 - u \rangle \leq r(z_1) - r(u)$$

$$\langle y - v, z_2 - v \rangle \leq r(z_2) - r(v).$$

Свойства проксимального оператора

i Theorem

Оператор $\text{prox}_r(x)$ является строго нестягивающим (FNE)

$$\|\text{prox}_r(x) - \text{prox}_r(y)\|_2^2 \leq \langle \text{prox}_r(x) - \text{prox}_r(y), x - y \rangle$$

и нестягивающим:

$$\|\text{prox}_r(x) - \text{prox}_r(y)\|_2 \leq \|x - y\|_2$$

Доказательство

1. Пусть $u = \text{prox}_r(x)$, $v = \text{prox}_r(y)$. Тогда из предыдущего свойства:

$$\langle x - u, z_1 - u \rangle \leq r(z_1) - r(u)$$

$$\langle y - v, z_2 - v \rangle \leq r(z_2) - r(v).$$

2. Подставим $z_1 = v$ и $z_2 = u$. Складывая, получаем:

$$\langle x - u, v - u \rangle + \langle y - v, u - v \rangle \leq 0,$$

$$\langle x - y, v - u \rangle + \|v - u\|_2^2 \leq 0.$$

Свойства проксимального оператора

i Theorem

Оператор $\text{prox}_r(x)$ является строго нестягивающим (FNE)

$$\|\text{prox}_r(x) - \text{prox}_r(y)\|_2^2 \leq \langle \text{prox}_r(x) - \text{prox}_r(y), x - y \rangle$$

и нестягивающим:

$$\|\text{prox}_r(x) - \text{prox}_r(y)\|_2 \leq \|x - y\|_2$$

Доказательство

1. Пусть $u = \text{prox}_r(x)$, $v = \text{prox}_r(y)$. Тогда из предыдущего свойства:

$$\langle x - u, z_1 - u \rangle \leq r(z_1) - r(u)$$

$$\langle y - v, z_2 - v \rangle \leq r(z_2) - r(v).$$

2. Подставим $z_1 = v$ и $z_2 = u$. Складывая, получаем:

$$\langle x - u, v - u \rangle + \langle y - v, u - v \rangle \leq 0,$$

$$\langle x - y, v - u \rangle + \|v - u\|_2^2 \leq 0.$$

3. Что в точности является тем, что нужно доказать после подстановки u, v :

$$\|u - v\|_2^2 \leq \langle x - y, u - v \rangle$$

Свойства проксимального оператора

i Theorem

Оператор $\text{prox}_r(x)$ является строго нестягивающим (FNE)

$$\|\text{prox}_r(x) - \text{prox}_r(y)\|_2^2 \leq \langle \text{prox}_r(x) - \text{prox}_r(y), x - y \rangle$$

и нестягивающим:

$$\|\text{prox}_r(x) - \text{prox}_r(y)\|_2 \leq \|x - y\|_2$$

Доказательство

1. Пусть $u = \text{prox}_r(x)$, $v = \text{prox}_r(y)$. Тогда из предыдущего свойства:

$$\langle x - u, z_1 - u \rangle \leq r(z_1) - r(u)$$

$$\langle y - v, z_2 - v \rangle \leq r(z_2) - r(v).$$

2. Подставим $z_1 = v$ и $z_2 = u$. Складывая, получаем:

$$\langle x - u, v - u \rangle + \langle y - v, u - v \rangle \leq 0,$$

$$\langle x - y, v - u \rangle + \|v - u\|_2^2 \leq 0.$$

3. Что в точности является тем, что нужно доказать после подстановки u, v :

$$\|u - v\|_2^2 \leq \langle x - y, u - v \rangle$$

4. Нестяжимость следует из неравенства Коши — Буняковского — Шварца.

Свойства проксимального оператора

i Theorem

Пусть $f : \mathbb{R}^n \rightarrow \mathbb{R} \cup \{+\infty\}$ и $r : \mathbb{R}^n \rightarrow \mathbb{R} \cup \{+\infty\}$ — выпуклые функции. Дополнительно предположим, что f непрерывно дифференцируема и L -гладкая, а для r определён prox_r . Тогда x^* является решением композитной задачи оптимизации тогда и только тогда, когда для любого $\alpha > 0$ выполняется:

$$x^* = \text{prox}_{r,\alpha}(x^* - \alpha \nabla f(x^*))$$

Доказательство

1. Условия оптимальности:

Свойства проксимального оператора

i Theorem

Пусть $f : \mathbb{R}^n \rightarrow \mathbb{R} \cup \{+\infty\}$ и $r : \mathbb{R}^n \rightarrow \mathbb{R} \cup \{+\infty\}$ — выпуклые функции. Дополнительно предположим, что f непрерывно дифференцируема и L -гладкая, а для r определён prox_r . Тогда x^* является решением композитной задачи оптимизации тогда и только тогда, когда для любого $\alpha > 0$ выполняется:

$$x^* = \text{prox}_{r,\alpha}(x^* - \alpha \nabla f(x^*))$$

Доказательство

1. Условия оптимальности:

$$0 \in \nabla f(x^*) + \partial r(x^*)$$

Свойства проксимального оператора

i Theorem

Пусть $f : \mathbb{R}^n \rightarrow \mathbb{R} \cup \{+\infty\}$ и $r : \mathbb{R}^n \rightarrow \mathbb{R} \cup \{+\infty\}$ — выпуклые функции. Дополнительно предположим, что f непрерывно дифференцируема и L -гладкая, а для r определён prox_r . Тогда x^* является решением композитной задачи оптимизации тогда и только тогда, когда для любого $\alpha > 0$ выполняется:

$$x^* = \text{prox}_{r,\alpha}(x^* - \alpha \nabla f(x^*))$$

Доказательство

1. Условия оптимальности:

$$\begin{aligned} 0 &\in \nabla f(x^*) + \partial r(x^*) \\ -\alpha \nabla f(x^*) &\in \alpha \partial r(x^*) \end{aligned}$$

Свойства проксимального оператора

i Theorem

Пусть $f : \mathbb{R}^n \rightarrow \mathbb{R} \cup \{+\infty\}$ и $r : \mathbb{R}^n \rightarrow \mathbb{R} \cup \{+\infty\}$ — выпуклые функции. Дополнительно предположим, что f непрерывно дифференцируема и L -гладкая, а для r определён prox_r . Тогда x^* является решением композитной задачи оптимизации тогда и только тогда, когда для любого $\alpha > 0$ выполняется:

$$x^* = \text{prox}_{r,\alpha}(x^* - \alpha \nabla f(x^*))$$

Доказательство

1. Условия оптимальности:

$$\begin{aligned} 0 &\in \nabla f(x^*) + \partial r(x^*) \\ -\alpha \nabla f(x^*) &\in \alpha \partial r(x^*) \\ x^* - \alpha \nabla f(x^*) - x^* &\in \alpha \partial r(x^*) \end{aligned}$$

Свойства проксимального оператора

i Theorem

Пусть $f : \mathbb{R}^n \rightarrow \mathbb{R} \cup \{+\infty\}$ и $r : \mathbb{R}^n \rightarrow \mathbb{R} \cup \{+\infty\}$ — выпуклые функции. Дополнительно предположим, что f непрерывно дифференцируема и L -гладкая, а для r определён prox_r . Тогда x^* является решением комpositной задачи оптимизации тогда и только тогда, когда для любого $\alpha > 0$ выполняется:

$$x^* = \text{prox}_{r,\alpha}(x^* - \alpha \nabla f(x^*))$$

Доказательство

1. Условия оптимальности:

$$\begin{aligned} 0 &\in \nabla f(x^*) + \partial r(x^*) \\ -\alpha \nabla f(x^*) &\in \alpha \partial r(x^*) \\ x^* - \alpha \nabla f(x^*) - x^* &\in \alpha \partial r(x^*) \end{aligned}$$

2. Из предыдущей леммы (применённой к αr):

$$\text{prox}_{\alpha r}(x) = y \Leftrightarrow x - y \in \alpha \partial r(y)$$

Свойства проксимального оператора

i Theorem

Пусть $f : \mathbb{R}^n \rightarrow \mathbb{R} \cup \{+\infty\}$ и $r : \mathbb{R}^n \rightarrow \mathbb{R} \cup \{+\infty\}$ — выпуклые функции. Дополнительно предположим, что f непрерывно дифференцируема и L -гладкая, а для r определён prox_r . Тогда x^* является решением комpositной задачи оптимизации тогда и только тогда, когда для любого $\alpha > 0$ выполняется:

$$x^* = \text{prox}_{r,\alpha}(x^* - \alpha \nabla f(x^*))$$

Доказательство

1. Условия оптимальности:

$$\begin{aligned} 0 &\in \nabla f(x^*) + \partial r(x^*) \\ -\alpha \nabla f(x^*) &\in \alpha \partial r(x^*) \\ x^* - \alpha \nabla f(x^*) - x^* &\in \alpha \partial r(x^*) \end{aligned}$$

2. Из предыдущей леммы (применённой к αr):

$$\text{prox}_{\alpha r}(x) = y \Leftrightarrow x - y \in \alpha \partial r(y)$$

3. Следовательно,

$$x^* = \text{prox}_{\alpha r}(x^* - \alpha \nabla f(x^*)) = \text{prox}_{r,\alpha}(x^* - \alpha \nabla f(x^*))$$

Теоретические инструменты для анализа сходимости

Инструменты для анализа сходимости

i Theorem

Пусть $f : \mathbb{R}^n \rightarrow \mathbb{R}$ — L -гладкая выпуклая функция. Тогда для любых $x, y \in \mathbb{R}^n$ выполняется неравенство:

$$f(x) + \langle \nabla f(x), y - x \rangle + \frac{1}{2L} \|\nabla f(x) - \nabla f(y)\|_2^2 \leq f(y) \text{ или, эквивалентно,}$$
$$\|\nabla f(y) - \nabla f(x)\|_2^2 = \|\nabla f(x) - \nabla f(y)\|_2^2 \leq 2L (f(x) - f(y) - \langle \nabla f(y), x - y \rangle)$$

Доказательство

1. Рассмотрим вспомогательную функцию $\varphi(y) = f(y) - \langle \nabla f(x), y \rangle$. Очевидно, что это выпуклая функция (как сумма выпуклых). Легко проверить, что она L -гладкая по определению, поскольку $\nabla \varphi(y) = \nabla f(y) - \nabla f(x)$ и $\|\nabla \varphi(y_1) - \nabla \varphi(y_2)\| = \|\nabla f(y_1) - \nabla f(y_2)\| \leq L\|y_1 - y_2\|$.

Инструменты для анализа сходимости

i Theorem

Пусть $f : \mathbb{R}^n \rightarrow \mathbb{R}$ — L -гладкая выпуклая функция. Тогда для любых $x, y \in \mathbb{R}^n$ выполняется неравенство:

$$f(x) + \langle \nabla f(x), y - x \rangle + \frac{1}{2L} \|\nabla f(x) - \nabla f(y)\|_2^2 \leq f(y) \text{ или, эквивалентно,}$$
$$\|\nabla f(y) - \nabla f(x)\|_2^2 = \|\nabla f(x) - \nabla f(y)\|_2^2 \leq 2L (f(x) - f(y) - \langle \nabla f(y), x - y \rangle)$$

Доказательство

1. Рассмотрим вспомогательную функцию $\varphi(y) = f(y) - \langle \nabla f(x), y \rangle$. Очевидно, что это выпуклая функция (как сумма выпуклых). Легко проверить, что она L -гладкая по определению, поскольку $\nabla \varphi(y) = \nabla f(y) - \nabla f(x)$ и $\|\nabla \varphi(y_1) - \nabla \varphi(y_2)\| = \|\nabla f(y_1) - \nabla f(y_2)\| \leq L\|y_1 - y_2\|$.
2. Запишем свойство параболы гладкости для функции $\varphi(y)$:

Инструменты для анализа сходимости

i Theorem

Пусть $f : \mathbb{R}^n \rightarrow \mathbb{R}$ — L -гладкая выпуклая функция. Тогда для любых $x, y \in \mathbb{R}^n$ выполняется неравенство:

$$f(x) + \langle \nabla f(x), y - x \rangle + \frac{1}{2L} \|\nabla f(x) - \nabla f(y)\|_2^2 \leq f(y) \text{ или, эквивалентно,}$$
$$\|\nabla f(y) - \nabla f(x)\|_2^2 = \|\nabla f(x) - \nabla f(y)\|_2^2 \leq 2L (f(x) - f(y) - \langle \nabla f(y), x - y \rangle)$$

Доказательство

1. Рассмотрим вспомогательную функцию $\varphi(y) = f(y) - \langle \nabla f(x), y \rangle$. Очевидно, что это выпуклая функция (как сумма выпуклых). Легко проверить, что она L -гладкая по определению, поскольку $\nabla \varphi(y) = \nabla f(y) - \nabla f(x)$ и $\|\nabla \varphi(y_1) - \nabla \varphi(y_2)\| = \|\nabla f(y_1) - \nabla f(y_2)\| \leq L\|y_1 - y_2\|$.
2. Запишем свойство параболы гладкости для функции $\varphi(y)$:

$$\varphi(y) \leq \varphi(x) + \langle \nabla \varphi(x), y - x \rangle + \frac{L}{2} \|y - x\|_2^2$$

Инструменты для анализа сходимости

i Theorem

Пусть $f : \mathbb{R}^n \rightarrow \mathbb{R}$ — L -гладкая выпуклая функция. Тогда для любых $x, y \in \mathbb{R}^n$ выполняется неравенство:

$$f(x) + \langle \nabla f(x), y - x \rangle + \frac{1}{2L} \|\nabla f(x) - \nabla f(y)\|_2^2 \leq f(y) \text{ или, эквивалентно,}$$
$$\|\nabla f(y) - \nabla f(x)\|_2^2 = \|\nabla f(x) - \nabla f(y)\|_2^2 \leq 2L (f(x) - f(y) - \langle \nabla f(y), x - y \rangle)$$

Доказательство

1. Рассмотрим вспомогательную функцию $\varphi(y) = f(y) - \langle \nabla f(x), y \rangle$. Очевидно, что это выпуклая функция (как сумма выпуклых). Легко проверить, что она L -гладкая по определению, поскольку $\nabla \varphi(y) = \nabla f(y) - \nabla f(x)$ и $\|\nabla \varphi(y_1) - \nabla \varphi(y_2)\| = \|\nabla f(y_1) - \nabla f(y_2)\| \leq L\|y_1 - y_2\|$.
2. Запишем свойство параболы гладкости для функции $\varphi(y)$:

$$\varphi(y) \leq \varphi(x) + \langle \nabla \varphi(x), y - x \rangle + \frac{L}{2} \|y - x\|_2^2$$
$$x:=y, y:=y - \frac{1}{L} \nabla \varphi(y) \quad \varphi\left(y - \frac{1}{L} \nabla \varphi(y)\right) \leq \varphi(y) + \left\langle \nabla \varphi(y), -\frac{1}{L} \nabla \varphi(y) \right\rangle + \frac{1}{2L} \|\nabla \varphi(y)\|_2^2$$

Инструменты для анализа сходимости

i Theorem

Пусть $f : \mathbb{R}^n \rightarrow \mathbb{R}$ — L -гладкая выпуклая функция. Тогда для любых $x, y \in \mathbb{R}^n$ выполняется неравенство:

$$f(x) + \langle \nabla f(x), y - x \rangle + \frac{1}{2L} \|\nabla f(x) - \nabla f(y)\|_2^2 \leq f(y) \text{ или, эквивалентно,}$$
$$\|\nabla f(y) - \nabla f(x)\|_2^2 = \|\nabla f(x) - \nabla f(y)\|_2^2 \leq 2L (f(x) - f(y) - \langle \nabla f(y), x - y \rangle)$$

Доказательство

1. Рассмотрим вспомогательную функцию $\varphi(y) = f(y) - \langle \nabla f(x), y \rangle$. Очевидно, что это выпуклая функция (как сумма выпуклых). Легко проверить, что она L -гладкая по определению, поскольку $\nabla \varphi(y) = \nabla f(y) - \nabla f(x)$ и $\|\nabla \varphi(y_1) - \nabla \varphi(y_2)\| = \|\nabla f(y_1) - \nabla f(y_2)\| \leq L\|y_1 - y_2\|$.
2. Запишем свойство параболы гладкости для функции $\varphi(y)$:

$$\varphi(y) \leq \varphi(x) + \langle \nabla \varphi(x), y - x \rangle + \frac{L}{2} \|y - x\|_2^2$$
$$x:=y, y:=y - \frac{1}{L} \nabla \varphi(y) \quad \varphi\left(y - \frac{1}{L} \nabla \varphi(y)\right) \leq \varphi(y) + \left\langle \nabla \varphi(y), -\frac{1}{L} \nabla \varphi(y) \right\rangle + \frac{1}{2L} \|\nabla \varphi(y)\|_2^2$$
$$\varphi\left(y - \frac{1}{L} \nabla \varphi(y)\right) \leq \varphi(y) - \frac{1}{2L} \|\nabla \varphi(y)\|_2^2$$

Инструменты для анализа сходимости

3. Из условий оптимальности первого порядка для выпуклой функции $\nabla\varphi(y) = \nabla f(y) - \nabla f(x) = 0$. Можно заключить, что для любого x минимум функции $\varphi(y)$ достигается в точке $y = x$. Следовательно:

$$\varphi(x) \leq \varphi\left(y - \frac{1}{L}\nabla\varphi(y)\right) \leq \varphi(y) - \frac{1}{2L}\|\nabla\varphi(y)\|_2^2$$

Инструменты для анализа сходимости

3. Из условий оптимальности первого порядка для выпуклой функции $\nabla\varphi(y) = \nabla f(y) - \nabla f(x) = 0$. Можно заключить, что для любого x минимум функции $\varphi(y)$ достигается в точке $y = x$. Следовательно:

$$\varphi(x) \leq \varphi\left(y - \frac{1}{L}\nabla\varphi(y)\right) \leq \varphi(y) - \frac{1}{2L}\|\nabla\varphi(y)\|_2^2$$

4. Подставим $\varphi(y) = f(y) - \langle \nabla f(x), y \rangle$:

Инструменты для анализа сходимости

3. Из условий оптимальности первого порядка для выпуклой функции $\nabla\varphi(y) = \nabla f(y) - \nabla f(x) = 0$. Можно заключить, что для любого x минимум функции $\varphi(y)$ достигается в точке $y = x$. Следовательно:

$$\varphi(x) \leq \varphi\left(y - \frac{1}{L}\nabla\varphi(y)\right) \leq \varphi(y) - \frac{1}{2L}\|\nabla\varphi(y)\|_2^2$$

4. Подставим $\varphi(y) = f(y) - \langle \nabla f(x), y \rangle$:

$$f(x) - \langle \nabla f(x), x \rangle \leq f(y) - \langle \nabla f(x), y \rangle - \frac{1}{2L}\|\nabla f(y) - \nabla f(x)\|_2^2$$

Инструменты для анализа сходимости

3. Из условий оптимальности первого порядка для выпуклой функции $\nabla\varphi(y) = \nabla f(y) - \nabla f(x) = 0$. Можно заключить, что для любого x минимум функции $\varphi(y)$ достигается в точке $y = x$. Следовательно:

$$\varphi(x) \leq \varphi\left(y - \frac{1}{L}\nabla\varphi(y)\right) \leq \varphi(y) - \frac{1}{2L}\|\nabla\varphi(y)\|_2^2$$

4. Подставим $\varphi(y) = f(y) - \langle \nabla f(x), y \rangle$:

$$f(x) - \langle \nabla f(x), x \rangle \leq f(y) - \langle \nabla f(x), y \rangle - \frac{1}{2L}\|\nabla f(y) - \nabla f(x)\|_2^2$$

$$f(x) + \langle \nabla f(x), y - x \rangle + \frac{1}{2L}\|\nabla f(x) - \nabla f(y)\|_2^2 \leq f(y)$$

Инструменты для анализа сходимости

3. Из условий оптимальности первого порядка для выпуклой функции $\nabla\varphi(y) = \nabla f(y) - \nabla f(x) = 0$. Можно заключить, что для любого x минимум функции $\varphi(y)$ достигается в точке $y = x$. Следовательно:

$$\varphi(x) \leq \varphi\left(y - \frac{1}{L}\nabla\varphi(y)\right) \leq \varphi(y) - \frac{1}{2L}\|\nabla\varphi(y)\|_2^2$$

4. Подставим $\varphi(y) = f(y) - \langle \nabla f(x), y \rangle$:

$$f(x) - \langle \nabla f(x), x \rangle \leq f(y) - \langle \nabla f(x), y \rangle - \frac{1}{2L}\|\nabla f(y) - \nabla f(x)\|_2^2$$

$$f(x) + \langle \nabla f(x), y - x \rangle + \frac{1}{2L}\|\nabla f(x) - \nabla f(y)\|_2^2 \leq f(y)$$

$$\|\nabla f(y) - \nabla f(x)\|_2^2 \leq 2L(f(y) - f(x) - \langle \nabla f(x), y - x \rangle)$$

Инструменты для анализа сходимости

3. Из условий оптимальности первого порядка для выпуклой функции $\nabla\varphi(y) = \nabla f(y) - \nabla f(x) = 0$. Можно заключить, что для любого x минимум функции $\varphi(y)$ достигается в точке $y = x$. Следовательно:

$$\varphi(x) \leq \varphi\left(y - \frac{1}{L}\nabla\varphi(y)\right) \leq \varphi(y) - \frac{1}{2L}\|\nabla\varphi(y)\|_2^2$$

4. Подставим $\varphi(y) = f(y) - \langle \nabla f(x), y \rangle$:

$$f(x) - \langle \nabla f(x), x \rangle \leq f(y) - \langle \nabla f(x), y \rangle - \frac{1}{2L}\|\nabla f(y) - \nabla f(x)\|_2^2$$

$$f(x) + \langle \nabla f(x), y - x \rangle + \frac{1}{2L}\|\nabla f(x) - \nabla f(y)\|_2^2 \leq f(y)$$

$$\|\nabla f(y) - \nabla f(x)\|_2^2 \leq 2L(f(y) - f(x) - \langle \nabla f(x), y - x \rangle)$$

меняем x и y

$$\|\nabla f(x) - \nabla f(y)\|_2^2 \leq 2L(f(x) - f(y) - \langle \nabla f(y), x - y \rangle)$$

Инструменты для анализа сходимости

3. Из условий оптимальности первого порядка для выпуклой функции $\nabla\varphi(y) = \nabla f(y) - \nabla f(x) = 0$. Можно заключить, что для любого x минимум функции $\varphi(y)$ достигается в точке $y = x$. Следовательно:

$$\varphi(x) \leq \varphi\left(y - \frac{1}{L}\nabla\varphi(y)\right) \leq \varphi(y) - \frac{1}{2L}\|\nabla\varphi(y)\|_2^2$$

4. Подставим $\varphi(y) = f(y) - \langle \nabla f(x), y \rangle$:

$$f(x) - \langle \nabla f(x), x \rangle \leq f(y) - \langle \nabla f(x), y \rangle - \frac{1}{2L}\|\nabla f(y) - \nabla f(x)\|_2^2$$

$$f(x) + \langle \nabla f(x), y - x \rangle + \frac{1}{2L}\|\nabla f(x) - \nabla f(y)\|_2^2 \leq f(y)$$

$$\|\nabla f(y) - \nabla f(x)\|_2^2 \leq 2L(f(y) - f(x) - \langle \nabla f(x), y - x \rangle)$$

меняем x и y

$$\|\nabla f(x) - \nabla f(y)\|_2^2 \leq 2L(f(x) - f(y) - \langle \nabla f(y), x - y \rangle)$$

Инструменты для анализа сходимости

3. Из условий оптимальности первого порядка для выпуклой функции $\nabla\varphi(y) = \nabla f(y) - \nabla f(x) = 0$. Можно заключить, что для любого x минимум функции $\varphi(y)$ достигается в точке $y = x$. Следовательно:

$$\varphi(x) \leq \varphi\left(y - \frac{1}{L}\nabla\varphi(y)\right) \leq \varphi(y) - \frac{1}{2L}\|\nabla\varphi(y)\|_2^2$$

4. Подставим $\varphi(y) = f(y) - \langle \nabla f(x), y \rangle$:

$$f(x) - \langle \nabla f(x), x \rangle \leq f(y) - \langle \nabla f(x), y \rangle - \frac{1}{2L}\|\nabla f(y) - \nabla f(x)\|_2^2$$

$$f(x) + \langle \nabla f(x), y - x \rangle + \frac{1}{2L}\|\nabla f(x) - \nabla f(y)\|_2^2 \leq f(y)$$

$$\|\nabla f(y) - \nabla f(x)\|_2^2 \leq 2L(f(y) - f(x) - \langle \nabla f(x), y - x \rangle)$$

меняем x и y

$$\|\nabla f(x) - \nabla f(y)\|_2^2 \leq 2L(f(x) - f(y) - \langle \nabla f(y), x - y \rangle)$$

Лемма доказана. На первый взгляд она не имеет большого геометрического смысла, но мы будем использовать её как удобный инструмент для оценки разности градиентов.

Инструменты для анализа сходимости

i Theorem

Пусть $f : \mathbb{R}^n \rightarrow \mathbb{R}$ непрерывно дифференцируема на $\mathbb{R}^n$. Тогда функция f является μ -сильно выпуклой тогда и только тогда, когда для любых $x, y \in \mathbb{R}^n$ выполняется:

$$\text{Сильно выпуклый случай } \mu > 0 \quad \langle \nabla f(x) - \nabla f(y), x - y \rangle \geq \mu \|x - y\|^2$$

$$\text{Выпуклый случай } \mu = 0 \quad \langle \nabla f(x) - \nabla f(y), x - y \rangle \geq 0$$

Доказательство

1. Докажем только сильно выпуклый случай, выпуклый следует из него при $\mu = 0$. Начнём с необходимости. Для сильно выпуклой функции

$$f(y) \geq f(x) + \langle \nabla f(x), y - x \rangle + \frac{\mu}{2} \|x - y\|_2^2$$

$$f(x) \geq f(y) + \langle \nabla f(y), x - y \rangle + \frac{\mu}{2} \|x - y\|_2^2$$

$$\text{сумма} \quad \langle \nabla f(x) - \nabla f(y), x - y \rangle \geq \mu \|x - y\|^2$$

Инструменты для анализа сходимости

2. Для достаточности предполагаем, что $\langle \nabla f(x) - \nabla f(y), x - y \rangle \geq \mu \|x - y\|^2$. Используя формулу Ньютона — Лейбница $f(x) = f(y) + \int_0^1 \langle \nabla f(y + t(x - y)), x - y \rangle dt$:

Инструменты для анализа сходимости

2. Для достаточности предполагаем, что $\langle \nabla f(x) - \nabla f(y), x - y \rangle \geq \mu \|x - y\|^2$. Используя формулу Ньютона — Лейбница $f(x) = f(y) + \int_0^1 \langle \nabla f(y + t(x - y)), x - y \rangle dt$:

$$f(x) - f(y) - \langle \nabla f(y), x - y \rangle = \int_0^1 \langle \nabla f(y + t(x - y)), x - y \rangle dt - \langle \nabla f(y), x - y \rangle$$

Инструменты для анализа сходимости

2. Для достаточности предполагаем, что $\langle \nabla f(x) - \nabla f(y), x - y \rangle \geq \mu \|x - y\|^2$. Используя формулу Ньютона — Лейбница $f(x) = f(y) + \int_0^1 \langle \nabla f(y + t(x - y)), x - y \rangle dt$:

$$f(x) - f(y) - \langle \nabla f(y), x - y \rangle = \int_0^1 \langle \nabla f(y + t(x - y)), x - y \rangle dt - \langle \nabla f(y), x - y \rangle$$

$$\langle \nabla f(y), x - y \rangle = \int_0^1 \langle \nabla f(y), x - y \rangle dt \quad = \int_0^1 \langle \nabla f(y + t(x - y)) - \nabla f(y), (x - y) \rangle dt$$

Инструменты для анализа сходимости

2. Для достаточности предполагаем, что $\langle \nabla f(x) - \nabla f(y), x - y \rangle \geq \mu \|x - y\|^2$. Используя формулу Ньютона — Лейбница $f(x) = f(y) + \int_0^1 \langle \nabla f(y + t(x - y)), x - y \rangle dt$:

$$\begin{aligned} f(x) - f(y) - \langle \nabla f(y), x - y \rangle &= \int_0^1 \langle \nabla f(y + t(x - y)), x - y \rangle dt - \langle \nabla f(y), x - y \rangle \\ \langle \nabla f(y), x - y \rangle &= \int_0^1 \langle \nabla f(y), x - y \rangle dt \\ y + t(x - y) - y &= t(x - y) \\ &= \int_0^1 \langle \nabla f(y + t(x - y)) - \nabla f(y), t(x - y) \rangle dt \end{aligned}$$

Инструменты для анализа сходимости

2. Для достаточности предполагаем, что $\langle \nabla f(x) - \nabla f(y), x - y \rangle \geq \mu \|x - y\|^2$. Используя формулу Ньютона — Лейбница $f(x) = f(y) + \int_0^1 \langle \nabla f(y + t(x - y)), x - y \rangle dt$:

$$\begin{aligned} f(x) - f(y) - \langle \nabla f(y), x - y \rangle &= \int_0^1 \langle \nabla f(y + t(x - y)), x - y \rangle dt - \langle \nabla f(y), x - y \rangle \\ \langle \nabla f(y), x - y \rangle &= \int_0^1 \langle \nabla f(y), x - y \rangle dt \\ y + t(x - y) - y &= t(x - y) \\ &= \int_0^1 \langle \nabla f(y + t(x - y)) - \nabla f(y), t(x - y) \rangle dt \\ &\geq \int_0^1 t^{-1} \mu \|t(x - y)\|^2 dt \end{aligned}$$

Инструменты для анализа сходимости

2. Для достаточности предполагаем, что $\langle \nabla f(x) - \nabla f(y), x - y \rangle \geq \mu \|x - y\|^2$. Используя формулу Ньютона — Лейбница $f(x) = f(y) + \int_0^1 \langle \nabla f(y + t(x - y)), x - y \rangle dt$:

$$\begin{aligned} f(x) - f(y) - \langle \nabla f(y), x - y \rangle &= \int_0^1 \langle \nabla f(y + t(x - y)), x - y \rangle dt - \langle \nabla f(y), x - y \rangle \\ \langle \nabla f(y), x - y \rangle &= \int_0^1 \langle \nabla f(y), x - y \rangle dt \\ y + t(x - y) - y &= t(x - y) \\ &= \int_0^1 \langle \nabla f(y + t(x - y)) - \nabla f(y), t(x - y) \rangle dt \\ &\geq \int_0^1 t^{-1} \mu \|t(x - y)\|^2 dt = \mu \|x - y\|^2 \int_0^1 t dt \end{aligned}$$

Инструменты для анализа сходимости

2. Для достаточности предполагаем, что $\langle \nabla f(x) - \nabla f(y), x - y \rangle \geq \mu \|x - y\|^2$. Используя формулу Ньютона — Лейбница $f(x) = f(y) + \int_0^1 \langle \nabla f(y + t(x - y)), x - y \rangle dt$:

$$\begin{aligned} f(x) - f(y) - \langle \nabla f(y), x - y \rangle &= \int_0^1 \langle \nabla f(y + t(x - y)), x - y \rangle dt - \langle \nabla f(y), x - y \rangle \\ \langle \nabla f(y), x - y \rangle &= \int_0^1 \langle \nabla f(y), x - y \rangle dt \\ y + t(x - y) - y &= t(x - y) \\ &= \int_0^1 \langle \nabla f(y + t(x - y)) - \nabla f(y), t(x - y) \rangle dt \\ &\geq \int_0^1 t^{-1} \mu \|t(x - y)\|^2 dt = \mu \|x - y\|^2 \int_0^1 t dt = \frac{\mu}{2} \|x - y\|_2^2 \end{aligned}$$

Инструменты для анализа сходимости

2. Для достаточности предполагаем, что $\langle \nabla f(x) - \nabla f(y), x - y \rangle \geq \mu \|x - y\|^2$. Используя формулу Ньютона — Лейбница $f(x) = f(y) + \int_0^1 \langle \nabla f(y + t(x - y)), x - y \rangle dt$:

$$\begin{aligned} f(x) - f(y) - \langle \nabla f(y), x - y \rangle &= \int_0^1 \langle \nabla f(y + t(x - y)), x - y \rangle dt - \langle \nabla f(y), x - y \rangle \\ \langle \nabla f(y), x - y \rangle &= \int_0^1 \langle \nabla f(y), x - y \rangle dt \\ y + t(x - y) - y &= t(x - y) \\ &= \int_0^1 \langle \nabla f(y + t(x - y)) - \nabla f(y), t(x - y) \rangle dt \\ &\geq \int_0^1 t^{-1} \mu \|t(x - y)\|^2 dt = \mu \|x - y\|^2 \int_0^1 t dt = \frac{\mu}{2} \|x - y\|_2^2 \end{aligned}$$

Инструменты для анализа сходимости

2. Для достаточности предполагаем, что $\langle \nabla f(x) - \nabla f(y), x - y \rangle \geq \mu \|x - y\|^2$. Используя формулу Ньютона — Лейбница $f(x) = f(y) + \int_0^1 \langle \nabla f(y + t(x - y)), x - y \rangle dt$:

$$\begin{aligned} f(x) - f(y) - \langle \nabla f(y), x - y \rangle &= \int_0^1 \langle \nabla f(y + t(x - y)), x - y \rangle dt - \langle \nabla f(y), x - y \rangle \\ \langle \nabla f(y), x - y \rangle &= \int_0^1 \langle \nabla f(y), x - y \rangle dt \\ y + t(x - y) - y &= t(x - y) \\ &= \int_0^1 \langle \nabla f(y + t(x - y)) - \nabla f(y), t(x - y) \rangle dt \\ &\geq \int_0^1 t^{-1} \mu \|t(x - y)\|^2 dt = \mu \|x - y\|^2 \int_0^1 t dt = \frac{\mu}{2} \|x - y\|_2^2 \end{aligned}$$

Таким образом, критерий сильной выпуклости выполнен

$$f(x) \geq f(y) + \langle \nabla f(y), x - y \rangle + \frac{\mu}{2} \|x - y\|_2^2$$

Инструменты для анализа сходимости

2. Для достаточности предполагаем, что $\langle \nabla f(x) - \nabla f(y), x - y \rangle \geq \mu \|x - y\|^2$. Используя формулу Ньютона — Лейбница $f(x) = f(y) + \int_0^1 \langle \nabla f(y + t(x - y)), x - y \rangle dt$:

$$\begin{aligned} f(x) - f(y) - \langle \nabla f(y), x - y \rangle &= \int_0^1 \langle \nabla f(y + t(x - y)), x - y \rangle dt - \langle \nabla f(y), x - y \rangle \\ \langle \nabla f(y), x - y \rangle &= \int_0^1 \langle \nabla f(y), x - y \rangle dt \\ y + t(x - y) - y &= t(x - y) \\ &= \int_0^1 \langle \nabla f(y + t(x - y)) - \nabla f(y), t(x - y) \rangle dt \\ &\geq \int_0^1 t^{-1} \mu \|t(x - y)\|^2 dt = \mu \|x - y\|^2 \int_0^1 t dt = \frac{\mu}{2} \|x - y\|_2^2 \end{aligned}$$

Таким образом, критерий сильной выпуклости выполнен

$$f(x) \geq f(y) + \langle \nabla f(y), x - y \rangle + \frac{\mu}{2} \|x - y\|_2^2 \text{ или, эквивалентно:}$$

Инструменты для анализа сходимости

2. Для достаточности предполагаем, что $\langle \nabla f(x) - \nabla f(y), x - y \rangle \geq \mu \|x - y\|^2$. Используя формулу Ньютона — Лейбница $f(x) = f(y) + \int_0^1 \langle \nabla f(y + t(x - y)), x - y \rangle dt$:

$$\begin{aligned} f(x) - f(y) - \langle \nabla f(y), x - y \rangle &= \int_0^1 \langle \nabla f(y + t(x - y)), x - y \rangle dt - \langle \nabla f(y), x - y \rangle \\ \langle \nabla f(y), x - y \rangle &= \int_0^1 \langle \nabla f(y), x - y \rangle dt \\ y + t(x - y) - y &= t(x - y) \\ &= \int_0^1 \langle \nabla f(y + t(x - y)) - \nabla f(y), t(x - y) \rangle dt \\ &\geq \int_0^1 t^{-1} \mu \|t(x - y)\|^2 dt = \mu \|x - y\|^2 \int_0^1 t dt = \frac{\mu}{2} \|x - y\|_2^2 \end{aligned}$$

Таким образом, критерий сильной выпуклости выполнен

$$f(x) \geq f(y) + \langle \nabla f(y), x - y \rangle + \frac{\mu}{2} \|x - y\|_2^2 \text{ или, эквивалентно:}$$

$$\text{меняем } x \text{ и } y \quad - \langle \nabla f(x), x - y \rangle \leq - \left(f(x) - f(y) + \frac{\mu}{2} \|x - y\|_2^2 \right)$$

Проксимальный градиентный метод. Выпуклый случай

i Theorem

Рассмотрим проксимальный градиентный метод

$$x_{k+1} = \text{prox}_{\alpha r}(x_k - \alpha \nabla f(x_k))$$

Для критерия $\varphi(x) = f(x) + r(x)$ предполагаем:

- f выпукла, дифференцируема, $\text{dom}(f) = \mathbb{R}^n$, и ∇f липшицев с константой $L > 0$.
- r выпукла, и $\text{prox}_{\alpha r}(x_k) = \arg \min_{x \in \mathbb{R}^n} [\alpha r(x) + \frac{1}{2} \|x - x_k\|_2^2]$ может быть вычислен.

Проксимальный градиентный спуск с фиксированным шагом $\alpha = 1/L$ удовлетворяет

$$\varphi(x_k) - \varphi^* \leq \frac{L \|x_0 - x^*\|^2}{2k},$$

Проксимальный градиентный спуск имеет скорость сходимости $O(1/k)$ или $O(1/\varepsilon)$. Это совпадает со скоростью обычного градиентного спуска! (Но помните о стоимости проксимальной операции)

Сходимость

Доказательство

1. Введём **градиентное отображение**, обозначаемое $G_\alpha(x)$, которое играет роль «градиентоподобного объекта»:

$$x_{k+1} = \text{prox}_{\alpha r}(x_k - \alpha \nabla f(x_k))$$

$$x_{k+1} = x_k - \alpha G_\alpha(x_k).$$

где $G_\alpha(x)$ определяется как:

$$G_\alpha(x) = \frac{1}{\alpha} (x - \text{prox}_{\alpha r}(x - \alpha \nabla f(x)))$$

Заметим, что $G_\alpha(x) = 0$ тогда и только тогда, когда x оптимально. Таким образом, G_α аналогичен ∇f . Если x локально оптимально, то $G_\alpha(x) = 0$ даже для невыпуклой f . Это показывает, что проксимальный градиентный метод эффективно комбинирует градиентный спуск по f с проксимальным оператором от r , позволяя работать с негладкими компонентами.

Сходимость

Доказательство

1. Введём **градиентное отображение**, обозначаемое $G_\alpha(x)$, которое играет роль «градиентоподобного объекта»:

$$x_{k+1} = \text{prox}_{\alpha r}(x_k - \alpha \nabla f(x_k))$$

$$x_{k+1} = x_k - \alpha G_\alpha(x_k).$$

где $G_\alpha(x)$ определяется как:

$$G_\alpha(x) = \frac{1}{\alpha} (x - \text{prox}_{\alpha r}(x - \alpha \nabla f(x)))$$

Заметим, что $G_\alpha(x) = 0$ тогда и только тогда, когда x оптимально. Таким образом, G_α аналогичен ∇f . Если x локально оптимально, то $G_\alpha(x) = 0$ даже для невыпуклой f . Это показывает, что проксимальный градиентный метод эффективно комбинирует градиентный спуск по f с проксимальным оператором от r , позволяя работать с негладкими компонентами.

2. Используем гладкость и выпуклость f для произвольной точки x :

Сходимость

Доказательство

1. Введём **градиентное отображение**, обозначаемое $G_\alpha(x)$, которое играет роль «градиентоподобного объекта»:

$$x_{k+1} = \text{prox}_{\alpha r}(x_k - \alpha \nabla f(x_k))$$

$$x_{k+1} = x_k - \alpha G_\alpha(x_k).$$

где $G_\alpha(x)$ определяется как:

$$G_\alpha(x) = \frac{1}{\alpha} (x - \text{prox}_{\alpha r}(x - \alpha \nabla f(x)))$$

Заметим, что $G_\alpha(x) = 0$ тогда и только тогда, когда x оптимально. Таким образом, G_α аналогичен ∇f . Если x локально оптимально, то $G_\alpha(x) = 0$ даже для невыпуклой f . Это показывает, что проксимальный градиентный метод эффективно комбинирует градиентный спуск по f с проксимальным оператором от r , позволяя работать с негладкими компонентами.

2. Используем гладкость и выпуклость f для произвольной точки x :

$$\text{гладкость} \quad f(x_{k+1}) \leq f(x_k) + \langle \nabla f(x_k), x_{k+1} - x_k \rangle + \frac{L}{2} \|x_{k+1} - x_k\|_2^2$$

Сходимость

Доказательство

1. Введём **градиентное отображение**, обозначаемое $G_\alpha(x)$, которое играет роль «градиентоподобного объекта»:

$$x_{k+1} = \text{prox}_{\alpha r}(x_k - \alpha \nabla f(x_k))$$

$$x_{k+1} = x_k - \alpha G_\alpha(x_k).$$

где $G_\alpha(x)$ определяется как:

$$G_\alpha(x) = \frac{1}{\alpha} (x - \text{prox}_{\alpha r}(x - \alpha \nabla f(x)))$$

Заметим, что $G_\alpha(x) = 0$ тогда и только тогда, когда x оптимально. Таким образом, G_α аналогичен ∇f . Если x локально оптимально, то $G_\alpha(x) = 0$ даже для невыпуклой f . Это показывает, что проксимальный градиентный метод эффективно комбинирует градиентный спуск по f с проксимальным оператором от r , позволяя работать с негладкими компонентами.

2. Используем гладкость и выпуклость f для произвольной точки x :

$$\text{гладкость } f(x_{k+1}) \leq f(x_k) + \langle \nabla f(x_k), x_{k+1} - x_k \rangle + \frac{L}{2} \|x_{k+1} - x_k\|_2^2$$

$$\text{выпуклость } f(x) \geq f(x_k) + \langle \nabla f(x_k), x - x_k \rangle$$

Сходимость

Доказательство

1. Введём **градиентное отображение**, обозначаемое $G_\alpha(x)$, которое играет роль «градиентоподобного объекта»:

$$x_{k+1} = \text{prox}_{\alpha r}(x_k - \alpha \nabla f(x_k))$$

$$x_{k+1} = x_k - \alpha G_\alpha(x_k).$$

где $G_\alpha(x)$ определяется как:

$$G_\alpha(x) = \frac{1}{\alpha} (x - \text{prox}_{\alpha r}(x - \alpha \nabla f(x)))$$

Заметим, что $G_\alpha(x) = 0$ тогда и только тогда, когда x оптимально. Таким образом, G_α аналогичен ∇f . Если x локально оптимально, то $G_\alpha(x) = 0$ даже для невыпуклой f . Это показывает, что проксимальный градиентный метод эффективно комбинирует градиентный спуск по f с проксимальным оператором от r , позволяя работать с негладкими компонентами.

2. Используем гладкость и выпуклость f для произвольной точки x :

$$\text{гладкость } f(x_{k+1}) \leq f(x_k) + \langle \nabla f(x_k), x_{k+1} - x_k \rangle + \frac{L}{2} \|x_{k+1} - x_k\|_2^2$$

$$\text{выпуклость } f(x) \geq f(x_k) + \langle \nabla f(x_k), x - x_k \rangle \quad \leq f(x) - \langle \nabla f(x_k), x - x_k \rangle + \langle \nabla f(x_k), x_{k+1} - x_k \rangle + \frac{\alpha^2 L}{2} \|G_\alpha(x_k)\|_2^2$$

Сходимость

Доказательство

1. Введём **градиентное отображение**, обозначаемое $G_\alpha(x)$, которое играет роль «градиентоподобного объекта»:

$$x_{k+1} = \text{prox}_{\alpha r}(x_k - \alpha \nabla f(x_k))$$

$$x_{k+1} = x_k - \alpha G_\alpha(x_k).$$

где $G_\alpha(x)$ определяется как:

$$G_\alpha(x) = \frac{1}{\alpha} (x - \text{prox}_{\alpha r}(x - \alpha \nabla f(x)))$$

Заметим, что $G_\alpha(x) = 0$ тогда и только тогда, когда x оптимально. Таким образом, G_α аналогичен ∇f . Если x локально оптимально, то $G_\alpha(x) = 0$ даже для невыпуклой f . Это показывает, что проксимальный градиентный метод эффективно комбинирует градиентный спуск по f с проксимальным оператором от r , позволяя работать с негладкими компонентами.

2. Используем гладкость и выпуклость f для произвольной точки x :

$$\text{гладкость } f(x_{k+1}) \leq f(x_k) + \langle \nabla f(x_k), x_{k+1} - x_k \rangle + \frac{L}{2} \|x_{k+1} - x_k\|_2^2$$

$$\text{выпуклость } f(x) \geq f(x_k) + \langle \nabla f(x_k), x - x_k \rangle \quad \leq f(x) - \langle \nabla f(x_k), x - x_k \rangle + \langle \nabla f(x_k), x_{k+1} - x_k \rangle + \frac{\alpha^2 L}{2} \|G_\alpha(x_k)\|_2^2$$

$$\leq f(x) + \langle \nabla f(x_k), x_{k+1} - x_k \rangle + \frac{\alpha^2 L}{2} \|G_\alpha(x_k)\|_2^2$$

Сходимость

3. Теперь используем свойство проксимального отображения, доказанное ранее:

Сходимость

3. Теперь используем свойство проксимального отображения, доказанное ранее:

$$x_{k+1} = \text{prox}_{\alpha r}(x_k - \alpha \nabla f(x_k)) \quad \Leftrightarrow \quad x_k - \alpha \nabla f(x_k) - x_{k+1} \in \partial \alpha r(x_{k+1})$$

Сходимость

3. Теперь используем свойство проксимального отображения, доказанное ранее:

$$\begin{aligned} x_{k+1} = \text{prox}_{\alpha r}(x_k - \alpha \nabla f(x_k)) &\Leftrightarrow x_k - \alpha \nabla f(x_k) - x_{k+1} \in \partial \alpha r(x_{k+1}) \\ \text{Поскольку } x_{k+1} - x_k = -\alpha G_\alpha(x_k) &\Rightarrow \alpha G_\alpha(x_k) - \alpha \nabla f(x_k) \in \partial \alpha r(x_{k+1}) \end{aligned}$$

Сходимость

3. Теперь используем свойство проксимального отображения, доказанное ранее:

$$\begin{aligned} x_{k+1} = \text{prox}_{\alpha r}(x_k - \alpha \nabla f(x_k)) &\Leftrightarrow x_k - \alpha \nabla f(x_k) - x_{k+1} \in \partial \alpha r(x_{k+1}) \\ \text{Поскольку } x_{k+1} - x_k = -\alpha G_\alpha(x_k) &\Rightarrow \alpha G_\alpha(x_k) - \alpha \nabla f(x_k) \in \partial \alpha r(x_{k+1}) \\ &G_\alpha(x_k) - \nabla f(x_k) \in \partial r(x_{k+1}) \end{aligned}$$

Сходимость

3. Теперь используем свойство проксимального отображения, доказанное ранее:

$$\begin{aligned} x_{k+1} = \text{prox}_{\alpha r}(x_k - \alpha \nabla f(x_k)) &\Leftrightarrow x_k - \alpha \nabla f(x_k) - x_{k+1} \in \partial \alpha r(x_{k+1}) \\ \text{Поскольку } x_{k+1} - x_k = -\alpha G_\alpha(x_k) &\Rightarrow \alpha G_\alpha(x_k) - \alpha \nabla f(x_k) \in \partial \alpha r(x_{k+1}) \\ &G_\alpha(x_k) - \nabla f(x_k) \in \partial r(x_{k+1}) \end{aligned}$$

4. По определению субградиента выпуклой функции r для любой точки x :

Сходимость

3. Теперь используем свойство проксимального отображения, доказанное ранее:

$$\begin{aligned} x_{k+1} = \operatorname{prox}_{\alpha r}(x_k - \alpha \nabla f(x_k)) &\Leftrightarrow x_k - \alpha \nabla f(x_k) - x_{k+1} \in \partial \alpha r(x_{k+1}) \\ \text{Поскольку } x_{k+1} - x_k = -\alpha G_\alpha(x_k) &\Rightarrow \alpha G_\alpha(x_k) - \alpha \nabla f(x_k) \in \partial \alpha r(x_{k+1}) \\ &G_\alpha(x_k) - \nabla f(x_k) \in \partial r(x_{k+1}) \end{aligned}$$

4. По определению субградиента выпуклой функции r для любой точки x :

$$r(x) \geq r(x_{k+1}) + \langle g, x - x_{k+1} \rangle, \quad g \in \partial r(x_{k+1})$$

Сходимость

3. Теперь используем свойство проксимального отображения, доказанное ранее:

$$\begin{aligned}x_{k+1} = \text{prox}_{\alpha r}(x_k - \alpha \nabla f(x_k)) &\Leftrightarrow x_k - \alpha \nabla f(x_k) - x_{k+1} \in \partial \alpha r(x_{k+1}) \\ \text{Поскольку } x_{k+1} - x_k = -\alpha G_\alpha(x_k) &\Rightarrow \alpha G_\alpha(x_k) - \alpha \nabla f(x_k) \in \partial \alpha r(x_{k+1}) \\ &G_\alpha(x_k) - \nabla f(x_k) \in \partial r(x_{k+1})\end{aligned}$$

4. По определению субградиента выпуклой функции r для любой точки x :

$$\begin{aligned}r(x) &\geq r(x_{k+1}) + \langle g, x - x_{k+1} \rangle, \quad g \in \partial r(x_{k+1}) \\ \text{подставляем конкретный субградиент} \quad r(x) &\geq r(x_{k+1}) + \langle G_\alpha(x_k) - \nabla f(x_k), x - x_{k+1} \rangle\end{aligned}$$

Сходимость

3. Теперь используем свойство проксимального отображения, доказанное ранее:

$$\begin{aligned}x_{k+1} = \text{prox}_{\alpha r}(x_k - \alpha \nabla f(x_k)) &\Leftrightarrow x_k - \alpha \nabla f(x_k) - x_{k+1} \in \partial \alpha r(x_{k+1}) \\ \text{Поскольку } x_{k+1} - x_k = -\alpha G_\alpha(x_k) &\Rightarrow \alpha G_\alpha(x_k) - \alpha \nabla f(x_k) \in \partial \alpha r(x_{k+1}) \\ &G_\alpha(x_k) - \nabla f(x_k) \in \partial r(x_{k+1})\end{aligned}$$

4. По определению субградиента выпуклой функции r для любой точки x :

$$\begin{aligned}r(x) &\geq r(x_{k+1}) + \langle g, x - x_{k+1} \rangle, \quad g \in \partial r(x_{k+1}) \\ \text{подставляем конкретный субградиент} \quad r(x) &\geq r(x_{k+1}) + \langle G_\alpha(x_k) - \nabla f(x_k), x - x_{k+1} \rangle \\ r(x) &\geq r(x_{k+1}) + \langle G_\alpha(x_k), x - x_{k+1} \rangle - \langle \nabla f(x_k), x - x_{k+1} \rangle\end{aligned}$$

Сходимость

3. Теперь используем свойство проксимального отображения, доказанное ранее:

$$\begin{aligned}x_{k+1} = \text{prox}_{\alpha r}(x_k - \alpha \nabla f(x_k)) &\Leftrightarrow x_k - \alpha \nabla f(x_k) - x_{k+1} \in \partial \alpha r(x_{k+1}) \\ \text{Поскольку } x_{k+1} - x_k = -\alpha G_\alpha(x_k) &\Rightarrow \alpha G_\alpha(x_k) - \alpha \nabla f(x_k) \in \partial \alpha r(x_{k+1}) \\ &G_\alpha(x_k) - \nabla f(x_k) \in \partial r(x_{k+1})\end{aligned}$$

4. По определению субградиента выпуклой функции r для любой точки x :

$$\begin{aligned}r(x) &\geq r(x_{k+1}) + \langle g, x - x_{k+1} \rangle, \quad g \in \partial r(x_{k+1}) \\ \text{подставляем конкретный субградиент} \quad r(x) &\geq r(x_{k+1}) + \langle G_\alpha(x_k) - \nabla f(x_k), x - x_{k+1} \rangle \\ r(x) &\geq r(x_{k+1}) + \langle G_\alpha(x_k), x - x_{k+1} \rangle - \langle \nabla f(x_k), x - x_{k+1} \rangle \\ \langle \nabla f(x_k), x_{k+1} - x \rangle &\leq r(x) - r(x_{k+1}) - \langle G_\alpha(x_k), x - x_{k+1} \rangle\end{aligned}$$

Сходимость

3. Теперь используем свойство проксимального отображения, доказанное ранее:

$$\begin{aligned}x_{k+1} = \text{prox}_{\alpha r}(x_k - \alpha \nabla f(x_k)) &\Leftrightarrow x_k - \alpha \nabla f(x_k) - x_{k+1} \in \partial \alpha r(x_{k+1}) \\ \text{Поскольку } x_{k+1} - x_k = -\alpha G_\alpha(x_k) &\Rightarrow \alpha G_\alpha(x_k) - \alpha \nabla f(x_k) \in \partial \alpha r(x_{k+1}) \\ &G_\alpha(x_k) - \nabla f(x_k) \in \partial r(x_{k+1})\end{aligned}$$

4. По определению субградиента выпуклой функции r для любой точки x :

$$\begin{aligned}r(x) &\geq r(x_{k+1}) + \langle g, x - x_{k+1} \rangle, \quad g \in \partial r(x_{k+1}) \\ \text{подставляем конкретный субградиент} \quad r(x) &\geq r(x_{k+1}) + \langle G_\alpha(x_k) - \nabla f(x_k), x - x_{k+1} \rangle \\ r(x) &\geq r(x_{k+1}) + \langle G_\alpha(x_k), x - x_{k+1} \rangle - \langle \nabla f(x_k), x - x_{k+1} \rangle \\ \langle \nabla f(x_k), x_{k+1} - x \rangle &\leq r(x) - r(x_{k+1}) - \langle G_\alpha(x_k), x - x_{k+1} \rangle\end{aligned}$$

5. Учитывая полученную оценку, вернёмся к гладкости и выпуклости:

Сходимость

3. Теперь используем свойство проксимального отображения, доказанное ранее:

$$\begin{aligned}x_{k+1} = \text{prox}_{\alpha r}(x_k - \alpha \nabla f(x_k)) &\Leftrightarrow x_k - \alpha \nabla f(x_k) - x_{k+1} \in \partial \alpha r(x_{k+1}) \\ \text{Поскольку } x_{k+1} - x_k = -\alpha G_\alpha(x_k) &\Rightarrow \alpha G_\alpha(x_k) - \alpha \nabla f(x_k) \in \partial \alpha r(x_{k+1}) \\ &G_\alpha(x_k) - \nabla f(x_k) \in \partial r(x_{k+1})\end{aligned}$$

4. По определению субградиента выпуклой функции r для любой точки x :

$$\begin{aligned}r(x) &\geq r(x_{k+1}) + \langle g, x - x_{k+1} \rangle, \quad g \in \partial r(x_{k+1}) \\ \text{подставляем конкретный субградиент} \quad r(x) &\geq r(x_{k+1}) + \langle G_\alpha(x_k) - \nabla f(x_k), x - x_{k+1} \rangle \\ r(x) &\geq r(x_{k+1}) + \langle G_\alpha(x_k), x - x_{k+1} \rangle - \langle \nabla f(x_k), x - x_{k+1} \rangle \\ \langle \nabla f(x_k), x_{k+1} - x \rangle &\leq r(x) - r(x_{k+1}) - \langle G_\alpha(x_k), x - x_{k+1} \rangle\end{aligned}$$

5. Учитывая полученную оценку, вернёмся к гладкости и выпуклости:

$$f(x_{k+1}) \leq f(x) + \langle \nabla f(x_k), x_{k+1} - x \rangle + \frac{\alpha^2 L}{2} \|G_\alpha(x_k)\|_2^2$$

Сходимость

3. Теперь используем свойство проксимального отображения, доказанное ранее:

$$\begin{aligned}x_{k+1} = \text{prox}_{\alpha r}(x_k - \alpha \nabla f(x_k)) &\Leftrightarrow x_k - \alpha \nabla f(x_k) - x_{k+1} \in \partial \alpha r(x_{k+1}) \\ \text{Поскольку } x_{k+1} - x_k = -\alpha G_\alpha(x_k) &\Rightarrow \alpha G_\alpha(x_k) - \alpha \nabla f(x_k) \in \partial \alpha r(x_{k+1}) \\ &G_\alpha(x_k) - \nabla f(x_k) \in \partial r(x_{k+1})\end{aligned}$$

4. По определению субградиента выпуклой функции r для любой точки x :

$$\begin{aligned}r(x) &\geq r(x_{k+1}) + \langle g, x - x_{k+1} \rangle, \quad g \in \partial r(x_{k+1}) \\ \text{подставляем конкретный субградиент} \quad r(x) &\geq r(x_{k+1}) + \langle G_\alpha(x_k) - \nabla f(x_k), x - x_{k+1} \rangle \\ r(x) &\geq r(x_{k+1}) + \langle G_\alpha(x_k), x - x_{k+1} \rangle - \langle \nabla f(x_k), x - x_{k+1} \rangle \\ \langle \nabla f(x_k), x_{k+1} - x \rangle &\leq r(x) - r(x_{k+1}) - \langle G_\alpha(x_k), x - x_{k+1} \rangle\end{aligned}$$

5. Учитывая полученную оценку, вернёмся к гладкости и выпуклости:

$$\begin{aligned}f(x_{k+1}) &\leq f(x) + \langle \nabla f(x_k), x_{k+1} - x \rangle + \frac{\alpha^2 L}{2} \|G_\alpha(x_k)\|_2^2 \\ f(x_{k+1}) &\leq f(x) + r(x) - r(x_{k+1}) - \langle G_\alpha(x_k), x - x_{k+1} \rangle + \frac{\alpha^2 L}{2} \|G_\alpha(x_k)\|_2^2\end{aligned}$$

Сходимость

3. Теперь используем свойство проксимального отображения, доказанное ранее:

$$\begin{aligned}x_{k+1} = \text{prox}_{\alpha r}(x_k - \alpha \nabla f(x_k)) &\Leftrightarrow x_k - \alpha \nabla f(x_k) - x_{k+1} \in \partial \alpha r(x_{k+1}) \\ \text{Поскольку } x_{k+1} - x_k = -\alpha G_\alpha(x_k) &\Rightarrow \alpha G_\alpha(x_k) - \alpha \nabla f(x_k) \in \partial \alpha r(x_{k+1}) \\ &G_\alpha(x_k) - \nabla f(x_k) \in \partial r(x_{k+1})\end{aligned}$$

4. По определению субградиента выпуклой функции r для любой точки x :

$$\begin{aligned}r(x) &\geq r(x_{k+1}) + \langle g, x - x_{k+1} \rangle, \quad g \in \partial r(x_{k+1}) \\ \text{подставляем конкретный субградиент} \quad r(x) &\geq r(x_{k+1}) + \langle G_\alpha(x_k) - \nabla f(x_k), x - x_{k+1} \rangle \\ r(x) &\geq r(x_{k+1}) + \langle G_\alpha(x_k), x - x_{k+1} \rangle - \langle \nabla f(x_k), x - x_{k+1} \rangle \\ \langle \nabla f(x_k), x_{k+1} - x \rangle &\leq r(x) - r(x_{k+1}) - \langle G_\alpha(x_k), x - x_{k+1} \rangle\end{aligned}$$

5. Учитывая полученную оценку, вернёмся к гладкости и выпуклости:

$$\begin{aligned}f(x_{k+1}) &\leq f(x) + \langle \nabla f(x_k), x_{k+1} - x \rangle + \frac{\alpha^2 L}{2} \|G_\alpha(x_k)\|_2^2 \\ f(x_{k+1}) &\leq f(x) + r(x) - r(x_{k+1}) - \langle G_\alpha(x_k), x - x_{k+1} \rangle + \frac{\alpha^2 L}{2} \|G_\alpha(x_k)\|_2^2 \\ f(x_{k+1}) + r(x_{k+1}) &\leq f(x) + r(x) - \langle G_\alpha(x_k), x - x_k + \alpha G_\alpha(x_k) \rangle + \frac{\alpha^2 L}{2} \|G_\alpha(x_k)\|_2^2\end{aligned}$$

6. Используя $\varphi(x) = f(x) + r(x)$, докажем чрезвычайно полезное неравенство, которое позволит продемонстрировать монотонное убывание итерации:

6. Используя $\varphi(x) = f(x) + r(x)$, докажем чрезвычайно полезное неравенство, которое позволит продемонстрировать монотонное убывание итерации:

$$\varphi(x_{k+1}) \leq \varphi(x) - \langle G_\alpha(x_k), x - x_k \rangle - \langle G_\alpha(x_k), \alpha G_\alpha(x_k) \rangle + \frac{\alpha^2 L}{2} \|G_\alpha(x_k)\|_2^2$$

6. Используя $\varphi(x) = f(x) + r(x)$, докажем чрезвычайно полезное неравенство, которое позволит продемонстрировать монотонное убывание итерации:

$$\begin{aligned}\varphi(x_{k+1}) &\leq \varphi(x) - \langle G_\alpha(x_k), x - x_k \rangle - \langle G_\alpha(x_k), \alpha G_\alpha(x_k) \rangle + \frac{\alpha^2 L}{2} \|G_\alpha(x_k)\|_2^2 \\ \varphi(x_{k+1}) &\leq \varphi(x) + \langle G_\alpha(x_k), x_k - x \rangle + \frac{\alpha}{2} (\alpha L - 2) \|G_\alpha(x_k)\|_2^2\end{aligned}$$

6. Используя $\varphi(x) = f(x) + r(x)$, докажем чрезвычайно полезное неравенство, которое позволит продемонстрировать монотонное убывание итерации:

$$\begin{aligned}\varphi(x_{k+1}) &\leq \varphi(x) - \langle G_\alpha(x_k), x - x_k \rangle - \langle G_\alpha(x_k), \alpha G_\alpha(x_k) \rangle + \frac{\alpha^2 L}{2} \|G_\alpha(x_k)\|_2^2 \\ \varphi(x_{k+1}) &\leq \varphi(x) + \langle G_\alpha(x_k), x_k - x \rangle + \frac{\alpha}{2} (\alpha L - 2) \|G_\alpha(x_k)\|_2^2\end{aligned}$$

$$\alpha \leq \frac{1}{L} \Rightarrow \frac{\alpha}{2} (\alpha L - 2) \leq -\frac{\alpha}{2}$$

6. Используя $\varphi(x) = f(x) + r(x)$, докажем чрезвычайно полезное неравенство, которое позволит продемонстрировать монотонное убывание итерации:

$$\varphi(x_{k+1}) \leq \varphi(x) - \langle G_\alpha(x_k), x - x_k \rangle - \langle G_\alpha(x_k), \alpha G_\alpha(x_k) \rangle + \frac{\alpha^2 L}{2} \|G_\alpha(x_k)\|_2^2$$

$$\varphi(x_{k+1}) \leq \varphi(x) + \langle G_\alpha(x_k), x_k - x \rangle + \frac{\alpha}{2} (\alpha L - 2) \|G_\alpha(x_k)\|_2^2$$

$$\alpha \leq \frac{1}{L} \Rightarrow \frac{\alpha}{2} (\alpha L - 2) \leq -\frac{\alpha}{2} \quad \varphi(x_{k+1}) \leq \varphi(x) + \langle G_\alpha(x_k), x_k - x \rangle - \frac{\alpha}{2} \|G_\alpha(x_k)\|_2^2$$

6. Используя $\varphi(x) = f(x) + r(x)$, докажем чрезвычайно полезное неравенство, которое позволит продемонстрировать монотонное убывание итерации:

$$\varphi(x_{k+1}) \leq \varphi(x) - \langle G_\alpha(x_k), x - x_k \rangle - \langle G_\alpha(x_k), \alpha G_\alpha(x_k) \rangle + \frac{\alpha^2 L}{2} \|G_\alpha(x_k)\|_2^2$$

$$\varphi(x_{k+1}) \leq \varphi(x) + \langle G_\alpha(x_k), x_k - x \rangle + \frac{\alpha}{2} (\alpha L - 2) \|G_\alpha(x_k)\|_2^2$$

$$\alpha \leq \frac{1}{L} \Rightarrow \frac{\alpha}{2} (\alpha L - 2) \leq -\frac{\alpha}{2} \quad \varphi(x_{k+1}) \leq \varphi(x) + \langle G_\alpha(x_k), x_k - x \rangle - \frac{\alpha}{2} \|G_\alpha(x_k)\|_2^2$$

7. Теперь легко проверить, что при $x = x_k$ мы получаем монотонное убывание для проксимального градиентного алгоритма:

$$\varphi(x_{k+1}) \leq \varphi(x_k) - \frac{\alpha}{2} \|G_\alpha(x_k)\|_2^2$$

Сходимость

8. При $x = x^*$:

8. При $x = x^*$:

$$\varphi(x_{k+1}) \leq \varphi(x^*) + \langle G_\alpha(x_k), x_k - x^* \rangle - \frac{\alpha}{2} \|G_\alpha(x_k)\|_2^2$$

8. При $x = x^*$:

$$\varphi(x_{k+1}) \leq \varphi(x^*) + \langle G_\alpha(x_k), x_k - x^* \rangle - \frac{\alpha}{2} \|G_\alpha(x_k)\|_2^2$$

$$\varphi(x_{k+1}) - \varphi(x^*) \leq \langle G_\alpha(x_k), x_k - x^* \rangle - \frac{\alpha}{2} \|G_\alpha(x_k)\|_2^2$$

8. При $x = x^*$:

$$\begin{aligned}\varphi(x_{k+1}) &\leq \varphi(x^*) + \langle G_\alpha(x_k), x_k - x^* \rangle - \frac{\alpha}{2} \|G_\alpha(x_k)\|_2^2 \\ \varphi(x_{k+1}) - \varphi(x^*) &\leq \langle G_\alpha(x_k), x_k - x^* \rangle - \frac{\alpha}{2} \|G_\alpha(x_k)\|_2^2 \\ &\leq \frac{1}{2\alpha} [2\langle \alpha G_\alpha(x_k), x_k - x^* \rangle - \|\alpha G_\alpha(x_k)\|_2^2]\end{aligned}$$

8. При $x = x^*$:

$$\begin{aligned}\varphi(x_{k+1}) &\leq \varphi(x^*) + \langle G_\alpha(x_k), x_k - x^* \rangle - \frac{\alpha}{2} \|G_\alpha(x_k)\|_2^2 \\ \varphi(x_{k+1}) - \varphi(x^*) &\leq \langle G_\alpha(x_k), x_k - x^* \rangle - \frac{\alpha}{2} \|G_\alpha(x_k)\|_2^2 \\ &\leq \frac{1}{2\alpha} [2\langle \alpha G_\alpha(x_k), x_k - x^* \rangle - \|\alpha G_\alpha(x_k)\|_2^2] \\ &\leq \frac{1}{2\alpha} [2\langle \alpha G_\alpha(x_k), x_k - x^* \rangle - \|\alpha G_\alpha(x_k)\|_2^2 - \|x_k - x^*\|_2^2 + \|x_k - x^*\|_2^2]\end{aligned}$$

8. При $x = x^*$:

$$\begin{aligned}\varphi(x_{k+1}) &\leq \varphi(x^*) + \langle G_\alpha(x_k), x_k - x^* \rangle - \frac{\alpha}{2} \|G_\alpha(x_k)\|_2^2 \\ \varphi(x_{k+1}) - \varphi(x^*) &\leq \langle G_\alpha(x_k), x_k - x^* \rangle - \frac{\alpha}{2} \|G_\alpha(x_k)\|_2^2 \\ &\leq \frac{1}{2\alpha} [2\langle \alpha G_\alpha(x_k), x_k - x^* \rangle - \|\alpha G_\alpha(x_k)\|_2^2] \\ &\leq \frac{1}{2\alpha} [2\langle \alpha G_\alpha(x_k), x_k - x^* \rangle - \|\alpha G_\alpha(x_k)\|_2^2 - \|x_k - x^*\|_2^2 + \|x_k - x^*\|_2^2] \\ &\leq \frac{1}{2\alpha} [-\|x_k - x^* - \alpha G_\alpha(x_k)\|_2^2 + \|x_k - x^*\|_2^2]\end{aligned}$$

8. При $x = x^*$:

$$\begin{aligned}\varphi(x_{k+1}) &\leq \varphi(x^*) + \langle G_\alpha(x_k), x_k - x^* \rangle - \frac{\alpha}{2} \|G_\alpha(x_k)\|_2^2 \\ \varphi(x_{k+1}) - \varphi(x^*) &\leq \langle G_\alpha(x_k), x_k - x^* \rangle - \frac{\alpha}{2} \|G_\alpha(x_k)\|_2^2 \\ &\leq \frac{1}{2\alpha} [2\langle \alpha G_\alpha(x_k), x_k - x^* \rangle - \|\alpha G_\alpha(x_k)\|_2^2] \\ &\leq \frac{1}{2\alpha} [2\langle \alpha G_\alpha(x_k), x_k - x^* \rangle - \|\alpha G_\alpha(x_k)\|_2^2 - \|x_k - x^*\|_2^2 + \|x_k - x^*\|_2^2] \\ &\leq \frac{1}{2\alpha} [-\|x_k - x^* - \alpha G_\alpha(x_k)\|_2^2 + \|x_k - x^*\|_2^2] \\ &\leq \frac{1}{2\alpha} [\|x_k - x^*\|_2^2 - \|x_{k+1} - x^*\|_2^2]\end{aligned}$$

Сходимость

9. Запишем неравенство выше для всех итераций $i = 0, \dots, k - 1$ и просуммируем:

Что даёт стандартную оценку $\frac{L\|x_0 - x^*\|_2^2}{2k}$ при $\alpha = \frac{1}{L}$, т.е. скорость $\mathcal{O}\left(\frac{1}{k}\right)$ для гладких выпуклых задач с градиентным спуском!

Сходимость

9. Запишем неравенство выше для всех итераций $i = 0, \dots, k-1$ и просуммируем:

$$\sum_{i=0}^{k-1} [\varphi(x_{i+1}) - \varphi(x^*)] \leq \frac{1}{2\alpha} [\|x_0 - x^*\|_2^2 - \|x_k - x^*\|_2^2]$$

Что даёт стандартную оценку $\frac{L\|x_0 - x^*\|_2^2}{2k}$ при $\alpha = \frac{1}{L}$, т.е. скорость $\mathcal{O}\left(\frac{1}{k}\right)$ для гладких выпуклых задач с градиентным спуском!

Сходимость

9. Запишем неравенство выше для всех итераций $i = 0, \dots, k-1$ и просуммируем:

$$\begin{aligned} \sum_{i=0}^{k-1} [\varphi(x_{i+1}) - \varphi(x^*)] &\leq \frac{1}{2\alpha} [\|x_0 - x^*\|_2^2 - \|x_k - x^*\|_2^2] \\ &\leq \frac{1}{2\alpha} \|x_0 - x^*\|_2^2 \end{aligned}$$

Что даёт стандартную оценку $\frac{L\|x_0 - x^*\|_2^2}{2k}$ при $\alpha = \frac{1}{L}$, т.е. скорость $\mathcal{O}\left(\frac{1}{k}\right)$ для гладких выпуклых задач с градиентным спуском!

Сходимость

9. Запишем неравенство выше для всех итераций $i = 0, \dots, k-1$ и просуммируем:

$$\begin{aligned}\sum_{i=0}^{k-1} [\varphi(x_{i+1}) - \varphi(x^*)] &\leq \frac{1}{2\alpha} [\|x_0 - x^*\|_2^2 - \|x_k - x^*\|_2^2] \\ &\leq \frac{1}{2\alpha} \|x_0 - x^*\|_2^2\end{aligned}$$

10. Поскольку $\varphi(x_k)$ является убывающей последовательностью, следует:

Что даёт стандартную оценку $\frac{L\|x_0 - x^*\|_2^2}{2k}$ при $\alpha = \frac{1}{L}$, т.е. скорость $\mathcal{O}\left(\frac{1}{k}\right)$ для гладких выпуклых задач с градиентным спуском!

Сходимость

9. Запишем неравенство выше для всех итераций $i = 0, \dots, k-1$ и просуммируем:

$$\begin{aligned}\sum_{i=0}^{k-1} [\varphi(x_{i+1}) - \varphi(x^*)] &\leq \frac{1}{2\alpha} [\|x_0 - x^*\|_2^2 - \|x_k - x^*\|_2^2] \\ &\leq \frac{1}{2\alpha} \|x_0 - x^*\|_2^2\end{aligned}$$

10. Поскольку $\varphi(x_k)$ является убывающей последовательностью, следует:

$$\sum_{i=0}^{k-1} \varphi(x_k) = k\varphi(x_k) \leq \sum_{i=0}^{k-1} \varphi(x_{i+1})$$

Что даёт стандартную оценку $\frac{L\|x_0 - x^*\|_2^2}{2k}$ при $\alpha = \frac{1}{L}$, т.е. скорость $\mathcal{O}\left(\frac{1}{k}\right)$ для гладких выпуклых задач с градиентным спуском!

Сходимость

9. Запишем неравенство выше для всех итераций $i = 0, \dots, k-1$ и просуммируем:

$$\begin{aligned}\sum_{i=0}^{k-1} [\varphi(x_{i+1}) - \varphi(x^*)] &\leq \frac{1}{2\alpha} [\|x_0 - x^*\|_2^2 - \|x_k - x^*\|_2^2] \\ &\leq \frac{1}{2\alpha} \|x_0 - x^*\|_2^2\end{aligned}$$

10. Поскольку $\varphi(x_k)$ является убывающей последовательностью, следует:

$$\begin{aligned}\sum_{i=0}^{k-1} \varphi(x_k) &= k\varphi(x_k) \leq \sum_{i=0}^{k-1} \varphi(x_{i+1}) \\ \varphi(x_k) &\leq \frac{1}{k} \sum_{i=0}^{k-1} \varphi(x_{i+1})\end{aligned}$$

Что даёт стандартную оценку $\frac{L\|x_0 - x^*\|_2^2}{2k}$ при $\alpha = \frac{1}{L}$, т.е. скорость $\mathcal{O}\left(\frac{1}{k}\right)$ для гладких выпуклых задач с градиентным спуском!

Сходимость

9. Запишем неравенство выше для всех итераций $i = 0, \dots, k-1$ и просуммируем:

$$\begin{aligned}\sum_{i=0}^{k-1} [\varphi(x_{i+1}) - \varphi(x^*)] &\leq \frac{1}{2\alpha} [\|x_0 - x^*\|_2^2 - \|x_k - x^*\|_2^2] \\ &\leq \frac{1}{2\alpha} \|x_0 - x^*\|_2^2\end{aligned}$$

10. Поскольку $\varphi(x_k)$ является убывающей последовательностью, следует:

$$\begin{aligned}\sum_{i=0}^{k-1} \varphi(x_k) &= k\varphi(x_k) \leq \sum_{i=0}^{k-1} \varphi(x_{i+1}) \\ \varphi(x_k) &\leq \frac{1}{k} \sum_{i=0}^{k-1} \varphi(x_{i+1}) \\ \varphi(x_k) - \varphi(x^*) &\leq \frac{1}{k} \sum_{i=0}^{k-1} [\varphi(x_{i+1}) - \varphi(x^*)] \leq \frac{\|x_0 - x^*\|_2^2}{2\alpha k}\end{aligned}$$

Что даёт стандартную оценку $\frac{L\|x_0 - x^*\|_2^2}{2k}$ при $\alpha = \frac{1}{L}$, т.е. скорость $\mathcal{O}\left(\frac{1}{k}\right)$ для гладких выпуклых задач с градиентным спуском!

Проксимальный градиентный метод. Сильно выпуклый случай

i Theorem

Рассмотрим проксимальный градиентный метод

$$x_{k+1} = \text{prox}_{\alpha r}(x_k - \alpha \nabla f(x_k))$$

Для критерия $\varphi(x) = f(x) + r(x)$ предполагаем:

- f является μ -сильно выпуклой, дифференцируемой, $\text{dom}(f) = \mathbb{R}^n$, и ∇f липшицев с константой $L > 0$.
- r выпукла, и $\text{prox}_{\alpha r}(x_k) = \arg \min_{x \in \mathbb{R}^n} [\alpha r(x) + \frac{1}{2} \|x - x_k\|_2^2]$ может быть вычислен.

Проксимальный градиентный спуск с фиксированным шагом $\alpha \leq 1/L$ удовлетворяет

$$\|x_k - x^*\|_2^2 \leq (1 - \alpha\mu)^k \|x_0 - x^*\|_2^2$$

Это в точности скорость сходимости градиентного спуска. Заметим, что исходная задача даже негладкая!

Сходимость

Доказательство

1. Рассмотрим расстояние до решения и используем лемму о стационарной точке:

Сходимость

Доказательство

1. Рассмотрим расстояние до решения и используем лемму о стационарной точке:

$$\|x_{k+1} - x^*\|_2^2 = \|\text{prox}_{\alpha r}(x_k - \alpha \nabla f(x_k)) - x^*\|_2^2$$

Доказательство

1. Рассмотрим расстояние до решения и используем лемму о стационарной точке:

$$\begin{aligned}\|x_{k+1} - x^*\|_2^2 &= \|\text{prox}_{\alpha r}(x_k - \alpha \nabla f(x_k)) - x^*\|_2^2 \\ \text{лемма о стац. точке} &= \|\text{prox}_{\alpha r}(x_k - \alpha \nabla f(x_k)) - \text{prox}_{\alpha r}(x^* - \alpha \nabla f(x^*))\|_2^2\end{aligned}$$

Доказательство

1. Рассмотрим расстояние до решения и используем лемму о стационарной точке:

$$\begin{aligned}\|x_{k+1} - x^*\|_2^2 &= \|\text{prox}_{\alpha r}(x_k - \alpha \nabla f(x_k)) - x^*\|_2^2 \\ \text{лемма о стац. точке} &= \|\text{prox}_{\alpha r}(x_k - \alpha \nabla f(x_k)) - \text{prox}_{\alpha r}(x^* - \alpha \nabla f(x^*))\|_2^2 \\ \text{нерастяжимость} &\leq \|x_k - \alpha \nabla f(x_k) - x^* + \alpha \nabla f(x^*)\|_2^2\end{aligned}$$

Доказательство

1. Рассмотрим расстояние до решения и используем лемму о стационарной точке:

$$\begin{aligned}\|x_{k+1} - x^*\|_2^2 &= \|\text{prox}_{\alpha r}(x_k - \alpha \nabla f(x_k)) - x^*\|_2^2 \\ \text{лемма о стац. точке} &= \|\text{prox}_{\alpha r}(x_k - \alpha \nabla f(x_k)) - \text{prox}_{\alpha r}(x^* - \alpha \nabla f(x^*))\|_2^2 \\ \text{нерастяжимость} &\leq \|x_k - \alpha \nabla f(x_k) - x^* + \alpha \nabla f(x^*)\|_2^2 \\ &= \|x_k - x^*\|^2 - 2\alpha \langle \nabla f(x_k) - \nabla f(x^*), x_k - x^* \rangle + \alpha^2 \|\nabla f(x_k) - \nabla f(x^*)\|_2^2\end{aligned}$$

Доказательство

1. Рассмотрим расстояние до решения и используем лемму о стационарной точке:

$$\begin{aligned}\|x_{k+1} - x^*\|_2^2 &= \|\text{prox}_{\alpha r}(x_k - \alpha \nabla f(x_k)) - x^*\|_2^2 \\ \text{лемма о стац. точке} &= \|\text{prox}_{\alpha r}(x_k - \alpha \nabla f(x_k)) - \text{prox}_{\alpha r}(x^* - \alpha \nabla f(x^*))\|_2^2 \\ \text{нерастяжимость} &\leq \|x_k - \alpha \nabla f(x_k) - x^* + \alpha \nabla f(x^*)\|_2^2 \\ &= \|x_k - x^*\|^2 - 2\alpha \langle \nabla f(x_k) - \nabla f(x^*), x_k - x^* \rangle + \alpha^2 \|\nabla f(x_k) - \nabla f(x^*)\|_2^2\end{aligned}$$

2. Используем лемму о гладкости из инструментов сходимости и сильную выпуклость:

Доказательство

1. Рассмотрим расстояние до решения и используем лемму о стационарной точке:

$$\begin{aligned}\|x_{k+1} - x^*\|_2^2 &= \|\text{prox}_{\alpha r}(x_k - \alpha \nabla f(x_k)) - x^*\|_2^2 \\ \text{лемма о стац. точке} &= \|\text{prox}_{\alpha r}(x_k - \alpha \nabla f(x_k)) - \text{prox}_{\alpha r}(x^* - \alpha \nabla f(x^*))\|_2^2 \\ \text{нерастяжимость} &\leq \|x_k - \alpha \nabla f(x_k) - x^* + \alpha \nabla f(x^*)\|_2^2 \\ &= \|x_k - x^*\|^2 - 2\alpha \langle \nabla f(x_k) - \nabla f(x^*), x_k - x^* \rangle + \alpha^2 \|\nabla f(x_k) - \nabla f(x^*)\|_2^2\end{aligned}$$

2. Используем лемму о гладкости из инструментов сходимости и сильную выпуклость:

$$\text{гладкость} \quad \|\nabla f(x_k) - \nabla f(x^*)\|_2^2 \leq 2L (f(x_k) - f(x^*) - \langle \nabla f(x^*), x_k - x^* \rangle)$$

Доказательство

1. Рассмотрим расстояние до решения и используем лемму о стационарной точке:

$$\begin{aligned}\|x_{k+1} - x^*\|_2^2 &= \|\text{prox}_{\alpha r}(x_k - \alpha \nabla f(x_k)) - x^*\|_2^2 \\ \text{лемма о стац. точке} &= \|\text{prox}_{\alpha r}(x_k - \alpha \nabla f(x_k)) - \text{prox}_{\alpha r}(x^* - \alpha \nabla f(x^*))\|_2^2 \\ \text{нерастяжимость} &\leq \|x_k - \alpha \nabla f(x_k) - x^* + \alpha \nabla f(x^*)\|_2^2 \\ &= \|x_k - x^*\|^2 - 2\alpha \langle \nabla f(x_k) - \nabla f(x^*), x_k - x^* \rangle + \alpha^2 \|\nabla f(x_k) - \nabla f(x^*)\|_2^2\end{aligned}$$

2. Используем лемму о гладкости из инструментов сходимости и сильную выпуклость:

$$\begin{aligned}\text{гладкость} \quad \|\nabla f(x_k) - \nabla f(x^*)\|_2^2 &\leq 2L (f(x_k) - f(x^*) - \langle \nabla f(x^*), x_k - x^* \rangle) \\ \text{сильная выпуклость} \quad -\langle \nabla f(x_k) - \nabla f(x^*), x_k - x^* \rangle &\leq -\left(f(x_k) - f(x^*) + \frac{\mu}{2} \|x_k - x^*\|_2^2\right) - \langle \nabla f(x^*), x_k - x^* \rangle\end{aligned}$$

Сходимость

3. Подставим:

3. Подставим:

$$\begin{aligned}\|x_{k+1} - x^*\|_2^2 &\leq \|x_k - x^*\|^2 - 2\alpha \left(f(x_k) - f(x^*) + \frac{\mu}{2} \|x_k - x^*\|_2^2 \right) - 2\alpha \langle \nabla f(x^*), x_k - x^* \rangle + \\ &\quad + \alpha^2 2L (f(x_k) - f(x^*) - \langle \nabla f(x^*), x_k - x^* \rangle)\end{aligned}$$

3. Подставим:

$$\begin{aligned}\|x_{k+1} - x^*\|_2^2 &\leq \|x_k - x^*\|^2 - 2\alpha \left(f(x_k) - f(x^*) + \frac{\mu}{2} \|x_k - x^*\|_2^2 \right) - 2\alpha \langle \nabla f(x^*), x_k - x^* \rangle + \\ &\quad + \alpha^2 2L (f(x_k) - f(x^*) - \langle \nabla f(x^*), x_k - x^* \rangle) \\ &\leq (1 - \alpha\mu) \|x_k - x^*\|^2 + 2\alpha(\alpha L - 1) (f(x_k) - f(x^*) - \langle \nabla f(x^*), x_k - x^* \rangle)\end{aligned}$$

3. Подставим:

$$\begin{aligned}\|x_{k+1} - x^*\|_2^2 &\leq \|x_k - x^*\|^2 - 2\alpha \left(f(x_k) - f(x^*) + \frac{\mu}{2} \|x_k - x^*\|_2^2 \right) - 2\alpha \langle \nabla f(x^*), x_k - x^* \rangle + \\ &\quad + \alpha^2 2L (f(x_k) - f(x^*) - \langle \nabla f(x^*), x_k - x^* \rangle) \\ &\leq (1 - \alpha\mu) \|x_k - x^*\|^2 + 2\alpha(\alpha L - 1) (f(x_k) - f(x^*) - \langle \nabla f(x^*), x_k - x^* \rangle)\end{aligned}$$

4. В силу выпуклости f : $f(x_k) - f(x^*) - \langle \nabla f(x^*), x_k - x^* \rangle \geq 0$. Следовательно, при $\alpha \leq \frac{1}{L}$:

$$\|x_{k+1} - x^*\|_2^2 \leq (1 - \alpha\mu) \|x_k - x^*\|^2,$$

что в точности является линейной сходимостью метода со скоростью до $1 - \frac{\mu}{L}$.

Ускоренный проксимальный метод

i Ускоренный проксимальный метод

Пусть $x_0 = y_0 \in \text{dom}(r)$. Для $k \geq 1$:

$$x_k = \text{prox}_{\alpha_k r}(y_{k-1} - \alpha_k \nabla f(y_{k-1}))$$

$$y_k = x_k + \frac{k-1}{k+2}(x_k - x_{k-1})$$

Достигает

$$\varphi(x_k) - \varphi^* \leq \frac{2L\|x_0 - x^*\|^2}{k^2}.$$

Ускоренный проксимальный метод

i Ускоренный проксимальный метод

Пусть $x_0 = y_0 \in \text{dom}(r)$. Для $k \geq 1$:

$$x_k = \text{prox}_{\alpha_k r}(y_{k-1} - \alpha_k \nabla f(y_{k-1}))$$

$$y_k = x_k + \frac{k-1}{k+2}(x_k - x_{k-1})$$

Достигает

$$\varphi(x_k) - \varphi^* \leq \frac{2L\|x_0 - x^*\|^2}{k^2}.$$

Схема предложена: Нестеров (1983, 2004); также Бек, Тебулле (2009). Упрощённый анализ: Цэн (2008).

- Использует дополнительную «память» для интерполяции

Ускоренный проксимальный метод

i Ускоренный проксимальный метод

Пусть $x_0 = y_0 \in \text{dom}(r)$. Для $k \geq 1$:

$$x_k = \text{prox}_{\alpha_k r}(y_{k-1} - \alpha_k \nabla f(y_{k-1}))$$

$$y_k = x_k + \frac{k-1}{k+2}(x_k - x_{k-1})$$

Достигает

$$\varphi(x_k) - \varphi^* \leq \frac{2L\|x_0 - x^*\|^2}{k^2}.$$

Схема предложена: Нестеров (1983, 2004); также Бек, Тебулле (2009). Упрощённый анализ: Цэн (2008).

- Использует дополнительную «память» для интерполяции
- Та же вычислительная стоимость, что и у обычного проксимального градиентного метода

Ускоренный проксимальный метод

i Ускоренный проксимальный метод

Пусть $x_0 = y_0 \in \text{dom}(r)$. Для $k \geq 1$:

$$x_k = \text{prox}_{\alpha_k r}(y_{k-1} - \alpha_k \nabla f(y_{k-1}))$$

$$y_k = x_k + \frac{k-1}{k+2}(x_k - x_{k-1})$$

Достигает

$$\varphi(x_k) - \varphi^* \leq \frac{2L\|x_0 - x^*\|^2}{k^2}.$$

Схема предложена: Нестеров (1983, 2004); также Бек, Тебулле (2009). Упрощённый анализ: Цэн (2008).

- Использует дополнительную «память» для интерполяции
- Та же вычислительная стоимость, что и у обычного проксимального градиентного метода
- Скорость сходимости теоретически оптимальна

Численные эксперименты

Квадратичный случай

$$f(x) = \frac{1}{2m} \|Ax - b\|_2^2 + \lambda \|x\|_1 \rightarrow \min_{x \in \mathbb{R}^n}, \quad A \in \mathbb{R}^{m \times n}, \quad \lambda \left(\frac{1}{m} A^T A \right) \in [\mu; L].$$

Linear Least Squares with ℓ_1 Regularization (LASSO).

$m=1000$, $n=100$, $\lambda=0$, $\mu=0$, $L=10$. Optimal sparsity: 0.0e+00




Рис. 2: Гладкий выпуклый случай. Сублинейная сходимость, нет сходимости в области, нет разницы между субградиентным и проксимальным методами

Квадратичный случай

$$f(x) = \frac{1}{2m} \|Ax - b\|_2^2 + \lambda \|x\|_1 \rightarrow \min_{x \in \mathbb{R}^n}, \quad A \in \mathbb{R}^{m \times n}, \quad \lambda \left(\frac{1}{m} A^T A \right) \in [\mu; L].$$

Linear Least Squares with ℓ_1 Regularization (LASSO).
m=1000, n=100, $\lambda=1$, $\mu=0$, L=10. Optimal sparsity: 2.3e-01




Рис. 3: Негладкий выпуклый случай. Сублинейная сходимость. В начале субградиентный и проксимальный методы близки.

Квадратичный случай

$$f(x) = \frac{1}{2m} \|Ax - b\|_2^2 + \lambda \|x\|_1 \rightarrow \min_{x \in \mathbb{R}^n}, \quad A \in \mathbb{R}^{m \times n}, \quad \lambda \left(\frac{1}{m} A^T A \right) \in [\mu; L].$$

Linear Least Squares with ℓ_1 Regularization (LASSO).
m=1000, n=100, $\lambda=1$, $\mu=0$, L=10. Optimal sparsity: 2.3e-01




Рис. 4: Негладкий выпуклый случай. При большем числе итераций проксимальный метод сходится с постоянным шагом, чего нет у субградиентного метода. Разница колоссальная при одинаковой стоимости итерации.

Бинарная логистическая регрессия

$$f(x) = \frac{1}{m} \sum_{i=1}^m \log(1 + \exp(-b_i(A_i x))) + \lambda \|x\|_1 \rightarrow \min_{x \in \mathbb{R}^n}, \quad A_i \in \mathbb{R}^n, \quad b_i \in \{-1, 1\}$$

Binary Logistic Regression with ℓ_1 Regularization.
m=300, n=50, $\lambda=0.1$. Optimal sparsity: 8.6e-01





Рис. 5: Логистическая регрессия с ℓ_1 -регуляризацией

Мультиклассовая регрессия softmax

Convex multiclass regression. lam=0.01.



Пример: ISTA

Итеративный алгоритм мягкого порогового отсека (ISTA)

ISTA — популярный метод для решения задач оптимизации с L1-регуляризацией, таких как Lasso. Он комбинирует градиентный спуск с оператором мягкого порогового отсека для эффективной работы с негладким L1-штрафом.

- **Алгоритм:**

Пример: ISTA

Итеративный алгоритм мягкого порогового отсека (ISTA)

ISTA — популярный метод для решения задач оптимизации с L1-регуляризацией, таких как Lasso. Он комбинирует градиентный спуск с оператором мягкого порогового отсека для эффективной работы с негладким L1-штрафом.

- **Алгоритм:**

- Задано x_0 , для $k \geq 0$ повторять:

$$x_{k+1} = \text{prox}_{\lambda\alpha\|\cdot\|_1}(x_k - \alpha\nabla f(x_k)),$$

где $\text{prox}_{\lambda\alpha\|\cdot\|_1}(v)$ применяет мягкое пороговое отсека к каждой компоненте v .

Пример: ISTA

Итеративный алгоритм мягкого порогового отсека (ISTA)

ISTA — популярный метод для решения задач оптимизации с L1-регуляризацией, таких как Lasso. Он комбинирует градиентный спуск с оператором мягкого порогового отсека для эффективной работы с негладким L1-штрафом.

- **Алгоритм:**

- Задано x_0 , для $k \geq 0$ повторять:

$$x_{k+1} = \text{prox}_{\lambda\alpha\|\cdot\|_1}(x_k - \alpha\nabla f(x_k)),$$

где $\text{prox}_{\lambda\alpha\|\cdot\|_1}(v)$ применяет мягкое пороговое отсека к каждой компоненте v .

- **Сходимость:**

Пример: ISTA

Итеративный алгоритм мягкого порогового отсека (ISTA)

ISTA — популярный метод для решения задач оптимизации с L1-регуляризацией, таких как Lasso. Он комбинирует градиентный спуск с оператором мягкого порогового отсека для эффективной работы с негладким L1-штрафом.

- **Алгоритм:**

- Задано x_0 , для $k \geq 0$ повторять:

$$x_{k+1} = \text{prox}_{\lambda\alpha\|\cdot\|_1}(x_k - \alpha\nabla f(x_k)),$$

где $\text{prox}_{\lambda\alpha\|\cdot\|_1}(v)$ применяет мягкое пороговое отсечение к каждой компоненте v .

- **Сходимость:**

- Сходится со скоростью $O(1/k)$ при подходящем размере шага α .

Пример: ISTA

Итеративный алгоритм мягкого порогового отсека (ISTA)

ISTA — популярный метод для решения задач оптимизации с L1-регуляризацией, таких как Lasso. Он комбинирует градиентный спуск с оператором мягкого порогового отсека для эффективной работы с негладким L1-штрафом.

- **Алгоритм:**

- Задано x_0 , для $k \geq 0$ повторять:

$$x_{k+1} = \text{prox}_{\lambda\alpha\|\cdot\|_1}(x_k - \alpha\nabla f(x_k)),$$

где $\text{prox}_{\lambda\alpha\|\cdot\|_1}(v)$ применяет мягкое пороговое отсека к каждой компоненте v .

- **Сходимость:**

- Сходится со скоростью $O(1/k)$ при подходящем размере шага α .

- **Применение:**

Пример: ISTA

Итеративный алгоритм мягкого порогового отсечения (ISTA)

ISTA — популярный метод для решения задач оптимизации с L1-регуляризацией, таких как Lasso. Он комбинирует градиентный спуск с оператором мягкого порогового отсечения для эффективной работы с негладким L1-штрафом.

- **Алгоритм:**

- Задано x_0 , для $k \geq 0$ повторять:

$$x_{k+1} = \text{prox}_{\lambda\alpha\|\cdot\|_1}(x_k - \alpha\nabla f(x_k)),$$

где $\text{prox}_{\lambda\alpha\|\cdot\|_1}(v)$ применяет мягкое пороговое отсечение к каждой компоненте v .

- **Сходимость:**

- Сходится со скоростью $O(1/k)$ при подходящем размере шага α .

- **Применение:**

- Эффективен для восстановления разреженных сигналов, обработки изображений и compressed sensing.

Пример: FISTA

Быстрый итеративный алгоритм мягкого порогового отсечения (FISTA)

FISTA улучшает скорость сходимости ISTA за счёт добавления момента, вдохновлённого ускоренным методом Нестерова.

- **Алгоритм:**

Пример: FISTA

Быстрый итеративный алгоритм мягкого порогового отсека (FISTA)

FISTA улучшает скорость сходимости ISTA за счёт добавления момента, вдохновлённого ускоренным методом Нестерова.

- **Алгоритм:**
 - Инициализация: $x_0 = y_0$, $t_0 = 1$.

Пример: FISTA

Быстрый итеративный алгоритм мягкого порогового отсека (FISTA)

FISTA улучшает скорость сходимости ISTA за счёт добавления момента, вдохновлённого ускоренным методом Нестерова.

- **Алгоритм:**

- Инициализация: $x_0 = y_0$, $t_0 = 1$.
- Для $k \geq 1$ обновление:

$$x_k = \text{prox}_{\lambda\alpha\|\cdot\|_1}(y_{k-1} - \alpha\nabla f(y_{k-1})),$$

$$t_k = \frac{1 + \sqrt{1 + 4t_{k-1}^2}}{2},$$

$$y_k = x_k + \frac{t_{k-1} - 1}{t_k}(x_k - x_{k-1}).$$

Пример: FISTA

Быстрый итеративный алгоритм мягкого порогового отсечения (FISTA)

FISTA улучшает скорость сходимости ISTA за счёт добавления момента, вдохновлённого ускоренным методом Нестерова.

- **Алгоритм:**

- Инициализация: $x_0 = y_0$, $t_0 = 1$.
- Для $k \geq 1$ обновление:

$$x_k = \text{prox}_{\lambda\alpha\|\cdot\|_1}(y_{k-1} - \alpha\nabla f(y_{k-1})),$$

$$t_k = \frac{1 + \sqrt{1 + 4t_{k-1}^2}}{2},$$

$$y_k = x_k + \frac{t_{k-1} - 1}{t_k}(x_k - x_{k-1}).$$

- **Сходимость:**

Пример: FISTA

Быстрый итеративный алгоритм мягкого порогового отсечения (FISTA)

FISTA улучшает скорость сходимости ISTA за счёт добавления момента, вдохновлённого ускоренным методом Нестерова.

- **Алгоритм:**

- Инициализация: $x_0 = y_0$, $t_0 = 1$.
- Для $k \geq 1$ обновление:

$$x_k = \text{prox}_{\lambda\alpha\|\cdot\|_1}(y_{k-1} - \alpha\nabla f(y_{k-1})),$$

$$t_k = \frac{1 + \sqrt{1 + 4t_{k-1}^2}}{2},$$

$$y_k = x_k + \frac{t_{k-1} - 1}{t_k}(x_k - x_{k-1}).$$

- **Сходимость:**

- Улучшает скорость сходимости до $O(1/k^2)$.

Пример: FISTA

Быстрый итеративный алгоритм мягкого порогового отсечения (FISTA)

FISTA улучшает скорость сходимости ISTA за счёт добавления момента, вдохновлённого ускоренным методом Нестерова.

- **Алгоритм:**

- Инициализация: $x_0 = y_0$, $t_0 = 1$.
- Для $k \geq 1$ обновление:

$$x_k = \text{prox}_{\lambda\alpha\|\cdot\|_1}(y_{k-1} - \alpha\nabla f(y_{k-1})),$$

$$t_k = \frac{1 + \sqrt{1 + 4t_{k-1}^2}}{2},$$

$$y_k = x_k + \frac{t_{k-1} - 1}{t_k}(x_k - x_{k-1}).$$

- **Сходимость:**

- Улучшает скорость сходимости до $O(1/k^2)$.

- **Применение:**

Пример: FISTA

Быстрый итеративный алгоритм мягкого порогового отсечения (FISTA)

FISTA улучшает скорость сходимости ISTA за счёт добавления момента, вдохновлённого ускоренным методом Нестерова.

- **Алгоритм:**

- Инициализация: $x_0 = y_0, t_0 = 1$.
- Для $k \geq 1$ обновление:

$$x_k = \text{prox}_{\lambda\alpha\|\cdot\|_1}(y_{k-1} - \alpha\nabla f(y_{k-1})),$$

$$t_k = \frac{1 + \sqrt{1 + 4t_{k-1}^2}}{2},$$

$$y_k = x_k + \frac{t_{k-1} - 1}{t_k}(x_k - x_{k-1}).$$

- **Сходимость:**

- Улучшает скорость сходимости до $O(1/k^2)$.

- **Применение:**

- Особенно полезен для крупномасштабных задач машинного обучения и обработки сигналов, где L1-штраф индуцирует разреженность.

Пример: Восполнение матриц

Решение задачи восполнения матриц

Задачи восполнения матриц направлены на заполнение отсутствующих элементов частично наблюдаемой матрицы при определённых предположениях, обычно о низком ранге. Это может быть сформулировано как задача минимизации с ядерной нормой (суммой сингулярных значений), которая способствует решениям низкого ранга.

- Постановка задачи:

$$\min_X \frac{1}{2} \|P_\Omega(X) - P_\Omega(M)\|_F^2 + \lambda \|X\|_*,$$

где P_Ω — проекция на наблюдаемое множество Ω , а $\|\cdot\|_*$ обозначает ядерную норму.

Пример: Восполнение матриц

Решение задачи восполнения матриц

Задачи восполнения матриц направлены на заполнение отсутствующих элементов частично наблюдаемой матрицы при определённых предположениях, обычно о низком ранге. Это может быть сформулировано как задача минимизации с ядерной нормой (суммой сингулярных значений), которая способствует решениям низкого ранга.

- **Постановка задачи:**

$$\min_X \frac{1}{2} \|P_\Omega(X) - P_\Omega(M)\|_F^2 + \lambda \|X\|_*,$$

где P_Ω — проекция на наблюдаемое множество Ω , а $\|\cdot\|_*$ обозначает ядерную норму.

- **Проксимальный оператор:**

Пример: Восполнение матриц

Решение задачи восполнения матриц

Задачи восполнения матриц направлены на заполнение отсутствующих элементов частично наблюдаемой матрицы при определённых предположениях, обычно о низком ранге. Это может быть сформулировано как задача минимизации с ядерной нормой (суммой сингулярных значений), которая способствует решениям низкого ранга.

- **Постановка задачи:**

$$\min_X \frac{1}{2} \|P_\Omega(X) - P_\Omega(M)\|_F^2 + \lambda \|X\|_*,$$

где P_Ω — проекция на наблюдаемое множество Ω , а $\|\cdot\|_*$ обозначает ядерную норму.

- **Проксимальный оператор:**
 - Проксимальный оператор для ядерной нормы включает сингулярное разложение (SVD) и мягкое пороговое отсечение сингулярных значений.

Пример: Восполнение матриц

Решение задачи восполнения матриц

Задачи восполнения матриц направлены на заполнение отсутствующих элементов частично наблюдаемой матрицы при определённых предположениях, обычно о низком ранге. Это может быть сформулировано как задача минимизации с ядерной нормой (суммой сингулярных значений), которая способствует решениям низкого ранга.

- **Постановка задачи:**

$$\min_X \frac{1}{2} \|P_\Omega(X) - P_\Omega(M)\|_F^2 + \lambda \|X\|_*,$$

где P_Ω — проекция на наблюдаемое множество Ω , а $\|\cdot\|_*$ обозначает ядерную норму.

- **Проксимальный оператор:**
 - Проксимальный оператор для ядерной нормы включает сингулярное разложение (SVD) и мягкое пороговое отсечение сингулярных значений.
- **Алгоритм:**

Пример: Восполнение матриц

Решение задачи восполнения матриц

Задачи восполнения матриц направлены на заполнение отсутствующих элементов частично наблюдаемой матрицы при определённых предположениях, обычно о низком ранге. Это может быть сформулировано как задача минимизации с ядерной нормой (суммой сингулярных значений), которая способствует решениям низкого ранга.

- **Постановка задачи:**

$$\min_X \frac{1}{2} \|P_\Omega(X) - P_\Omega(M)\|_F^2 + \lambda \|X\|_*,$$

где P_Ω — проекция на наблюдаемое множество Ω , а $\|\cdot\|_*$ обозначает ядерную норму.

- **Проксимальный оператор:**

- Проксимальный оператор для ядерной нормы включает сингулярное разложение (SVD) и мягкое пороговое отсечение сингулярных значений.

- **Алгоритм:**

- Аналогичные проксимальные градиентные или ускоренные проксимальные градиентные методы могут быть применены, где основная вычислительная нагрузка заключается в выполнении частичных SVD.

Пример: Восполнение матриц

Решение задачи восполнения матриц

Задачи восполнения матриц направлены на заполнение отсутствующих элементов частично наблюдаемой матрицы при определённых предположениях, обычно о низком ранге. Это может быть сформулировано как задача минимизации с ядерной нормой (суммой сингулярных значений), которая способствует решениям низкого ранга.

- **Постановка задачи:**

$$\min_X \frac{1}{2} \|P_\Omega(X) - P_\Omega(M)\|_F^2 + \lambda \|X\|_*,$$

где P_Ω — проекция на наблюдаемое множество Ω , а $\|\cdot\|_*$ обозначает ядерную норму.

- **Проксимальный оператор:**

- Проксимальный оператор для ядерной нормы включает сингулярное разложение (SVD) и мягкое пороговое отсечение сингулярных значений.

- **Алгоритм:**

- Аналогичные проксимальные градиентные или ускоренные проксимальные градиентные методы могут быть применены, где основная вычислительная нагрузка заключается в выполнении частичных SVD.

- **Применение:**

Пример: Восполнение матриц

Решение задачи восполнения матриц

Задачи восполнения матриц направлены на заполнение отсутствующих элементов частично наблюдаемой матрицы при определённых предположениях, обычно о низком ранге. Это может быть сформулировано как задача минимизации с ядерной нормой (суммой сингулярных значений), которая способствует решениям низкого ранга.

- **Постановка задачи:**

$$\min_X \frac{1}{2} \|P_\Omega(X) - P_\Omega(M)\|_F^2 + \lambda \|X\|_*,$$

где P_Ω — проекция на наблюдаемое множество Ω , а $\|\cdot\|_*$ обозначает ядерную норму.

- **Проксимальный оператор:**
 - Проксимальный оператор для ядерной нормы включает сингулярное разложение (SVD) и мягкое пороговое отсечение сингулярных значений.
- **Алгоритм:**
 - Аналогичные проксимальные градиентные или ускоренные проксимальные градиентные методы могут быть применены, где основная вычислительная нагрузка заключается в выполнении частичных SVD.
- **Применение:**
 - Широко используется в рекомендательных системах, восстановлении изображений и других областях, где данные естественно представлены в матричной форме, но частично наблюдаемы.

Итоги

- Если мы используем структуру задачи, мы можем преодолеть нижние оценки для неструктурированной задачи.

Итоги

- Если мы используем структуру задачи, мы можем преодолеть нижние оценки для неструктурированной задачи.
- Проксимальный градиентный метод для композитной задачи с L -гладкой выпуклой функцией f и выпуклой проксимально-дружественной функцией r имеет ту же скорость сходимости, что и градиентный спуск для функции f . Свойства гладкости/негладкости r не влияют на сходимость.

Итоги

- Если мы используем структуру задачи, мы можем преодолеть нижние оценки для неструктурированной задачи.
- Проксимальный градиентный метод для композитной задачи с L -гладкой выпуклой функцией f и выпуклой проксимально-дружественной функцией r имеет ту же скорость сходимости, что и градиентный спуск для функции f . Свойства гладкости/негладкости r не влияют на сходимость.
- Кажется, что положив $f = 0$, любую негладкую задачу можно решить с помощью такого метода. Вопрос: верно ли это?

Итоги

- Если мы используем структуру задачи, мы можем преодолеть нижние оценки для неструктурированной задачи.
- Проксимальный градиентный метод для композитной задачи с L -гладкой выпуклой функцией f и выпуклой проксимально-дружественной функцией r имеет ту же скорость сходимости, что и градиентный спуск для функции f . Свойства гладкости/негладкости r не влияют на сходимость.
- Кажется, что положив $f = 0$, любую негладкую задачу можно решить с помощью такого метода. Вопрос: верно ли это?

Итоги

- Если мы используем структуру задачи, мы можем преодолеть нижние оценки для неструктурированной задачи.
- Проксимальный градиентный метод для композитной задачи с L -гладкой выпуклой функцией f и выпуклой проксимально-дружественной функцией r имеет ту же скорость сходимости, что и градиентный спуск для функции f . Свойства гладкости/негладкости r не влияют на сходимость.
- Кажется, что положив $f = 0$, любую негладкую задачу можно решить с помощью такого метода. Вопрос: верно ли это?

Если допустить неточное вычисление проксимального оператора (численно), то действительно любую негладкую задачу оптимизации можно решить. Но это не лучше с точки зрения теории, чем решение задачи субградиентным спуском, поскольку для решения проксимальной подзадачи используется некоторый вспомогательный метод (например, тот же субградиентный спуск).

- Проксимальный метод является общей современной основой для многих численных методов. Дальнейшее развитие включает ускоренные, стохастические, прямо-двойственные модификации и т.д.

- Если мы используем структуру задачи, мы можем преодолеть нижние оценки для неструктурированной задачи.
- Проксимальный градиентный метод для композитной задачи с L -гладкой выпуклой функцией f и выпуклой проксимально-дружественной функцией r имеет ту же скорость сходимости, что и градиентный спуск для функции f . Свойства гладкости/негладкости r не влияют на сходимость.
- Кажется, что положив $f = 0$, любую негладкую задачу можно решить с помощью такого метода. Вопрос: верно ли это?

Если допустить неточное вычисление проксимального оператора (численно), то действительно любую негладкую задачу оптимизации можно решить. Но это не лучше с точки зрения теории, чем решение задачи субградиентным спуском, поскольку для решения проксимальной подзадачи используется некоторый вспомогательный метод (например, тот же субградиентный спуск).

- Проксимальный метод является общей современной основой для многих численных методов. Дальнейшее развитие включает ускоренные, стохастические, прямо-двойственные модификации и т.д.
- Дополнительная литература: Proximal operator splitting, Douglas-Rachford splitting, Best approximation problem, Three operator splitting.