

Задача минимизации конечной суммы

Задача минимизации конечной суммы

Рассмотрим классическую задачу минимизации среднего по конечной выборке:

$$\min_{x \in \mathbb{R}^p} f(x) = \min_{x \in \mathbb{R}^p} \frac{1}{n} \sum_{i=1}^n f_i(x)$$

Градиентный спуск записывается следующим образом:

$$x_{k+1} = x_k - \frac{\alpha_k}{n} \sum_{i=1}^n \nabla f_i(x) \quad (\text{GD})$$

- Сходимость при постоянном α или линейном поиске.

Задача минимизации конечной суммы

Рассмотрим классическую задачу минимизации среднего по конечной выборке:

$$\min_{x \in \mathbb{R}^p} f(x) = \min_{x \in \mathbb{R}^p} \frac{1}{n} \sum_{i=1}^n f_i(x)$$

Градиентный спуск записывается следующим образом:

$$x_{k+1} = x_k - \frac{\alpha_k}{n} \sum_{i=1}^n \nabla f_i(x) \quad (\text{GD})$$

- Сходимость при постоянном α или линейном поиске.
- Стоимость итерации линейна по n . Для ImageNet $n \approx 1,4 \cdot 10^7$, для WikiText $n \approx 10^8$. Для FineWeb $n \approx 15 \cdot 10^{12}$ токенов.

Задача минимизации конечной суммы

Рассмотрим классическую задачу минимизации среднего по конечной выборке:

$$\min_{x \in \mathbb{R}^p} f(x) = \min_{x \in \mathbb{R}^p} \frac{1}{n} \sum_{i=1}^n f_i(x)$$

Градиентный спуск записывается следующим образом:

$$x_{k+1} = x_k - \frac{\alpha_k}{n} \sum_{i=1}^n \nabla f_i(x) \quad (\text{GD})$$

- Сходимость при постоянном α или линейном поиске.
- Стоимость итерации линейна по n . Для ImageNet $n \approx 1,4 \cdot 10^7$, для WikiText $n \approx 10^8$. Для FineWeb $n \approx 15 \cdot 10^{12}$ токенов.

Задача минимизации конечной суммы

Рассмотрим классическую задачу минимизации среднего по конечной выборке:

$$\min_{x \in \mathbb{R}^p} f(x) = \min_{x \in \mathbb{R}^p} \frac{1}{n} \sum_{i=1}^n f_i(x)$$

Градиентный спуск записывается следующим образом:

$$x_{k+1} = x_k - \frac{\alpha_k}{n} \sum_{i=1}^n \nabla f_i(x) \quad (\text{GD})$$

- Сходимость при постоянном α или линейном поиске.
- Стоимость итерации линейна по n . Для ImageNet $n \approx 1,4 \cdot 10^7$, для WikiText $n \approx 10^8$. Для FineWeb $n \approx 15 \cdot 10^{12}$ токенов.

Перейдём от полного вычисления градиента к его несмещённой оценке, случайно выбирая индекс i_k на каждой итерации равномерно:

$$x_{k+1} = x_k - \alpha_k \nabla f_{i_k}(x_k) \quad (\text{SGD})$$

При $p(i_k = i) = \frac{1}{n}$ стохастический градиент является несмещённой оценкой градиента:

$$\mathbb{E}[\nabla f_{i_k}(x)] = \sum_{i=1}^n p(i_k = i) \nabla f_i(x) = \sum_{i=1}^n \frac{1}{n} \nabla f_i(x) = \frac{1}{n} \sum_{i=1}^n \nabla f_i(x) = \nabla f(x)$$

Это означает, что математическое ожидание стохастического градиента равно истинному градиенту $\nabla f(x)$.

Результаты для градиентного спуска

Стохастические итерации в n раз быстрее, но сколько итераций нужно?

Если ∇f липшицев, то имеем:

Предположение	Детерминированный GD	Стохастический GD
PL	$\mathcal{O}(\log(1/\varepsilon))$	
Выпуклый	$\mathcal{O}(1/\varepsilon)$	
Невыпуклый	$\mathcal{O}(1/\varepsilon)$	

Результаты для градиентного спуска

Стохастические итерации в n раз быстрее, но сколько итераций нужно?

Если ∇f липшицев, то имеем:

Предположение	Детерминированный GD	Стохастический GD
PL	$\mathcal{O}(\log(1/\varepsilon))$	$\mathcal{O}(1/\varepsilon)$
Выпуклый	$\mathcal{O}(1/\varepsilon)$	$\mathcal{O}(1/\varepsilon^2)$
Невыпуклый	$\mathcal{O}(1/\varepsilon)$	$\mathcal{O}(1/\varepsilon^2)$

- Стохастический метод имеет дешёвые итерации, но медленную сходимость.

Результаты для градиентного спуска

Стохастические итерации в n раз быстрее, но сколько итераций нужно?

Если ∇f липшицев, то имеем:

Предположение	Детерминированный GD	Стохастический GD
PL	$\mathcal{O}(\log(1/\varepsilon))$	$\mathcal{O}(1/\varepsilon)$
Выпуклый	$\mathcal{O}(1/\varepsilon)$	$\mathcal{O}(1/\varepsilon^2)$
Невыпуклый	$\mathcal{O}(1/\varepsilon)$	$\mathcal{O}(1/\varepsilon^2)$

- Стохастический метод имеет дешёвые итерации, но медленную сходимость.
 - Сублинейная сходимость даже в сильно выпуклом случае.

Результаты для градиентного спуска

Стохастические итерации в n раз быстрее, но сколько итераций нужно?

Если ∇f липшицев, то имеем:

Предположение	Детерминированный GD	Стохастический GD
PL	$\mathcal{O}(\log(1/\varepsilon))$	$\mathcal{O}(1/\varepsilon)$
Выпуклый	$\mathcal{O}(1/\varepsilon)$	$\mathcal{O}(1/\varepsilon^2)$
Невыпуклый	$\mathcal{O}(1/\varepsilon)$	$\mathcal{O}(1/\varepsilon^2)$

- Стохастический метод имеет дешёвые итерации, но медленную сходимость.
 - Сублинейная сходимость даже в сильно выпуклом случае.
 - Оценки неулучшаемы при стандартных предположениях.

Результаты для градиентного спуска

Стохастические итерации в n раз быстрее, но сколько итераций нужно?

Если ∇f липшицев, то имеем:

Предположение	Детерминированный GD	Стохастический GD
PL	$\mathcal{O}(\log(1/\varepsilon))$	$\mathcal{O}(1/\varepsilon)$
Выпуклый	$\mathcal{O}(1/\varepsilon)$	$\mathcal{O}(1/\varepsilon^2)$
Невыпуклый	$\mathcal{O}(1/\varepsilon)$	$\mathcal{O}(1/\varepsilon^2)$

- Стохастический метод имеет дешёвые итерации, но медленную сходимость.
 - Сублинейная сходимость даже в сильно выпуклом случае.
 - Оценки неулучшаемы при стандартных предположениях.
 - Оракул возвращает несмещённую аппроксимацию градиента с ограниченной дисперсией.

Результаты для градиентного спуска

Стохастические итерации в n раз быстрее, но сколько итераций нужно?

Если ∇f липшицев, то имеем:



Предположение	Детерминированный GD	Стохастический GD
PL	$\mathcal{O}(\log(1/\varepsilon))$	$\mathcal{O}(1/\varepsilon)$
Выпуклый	$\mathcal{O}(1/\varepsilon)$	$\mathcal{O}(1/\varepsilon^2)$
Невыпуклый	$\mathcal{O}(1/\varepsilon)$	$\mathcal{O}(1/\varepsilon^2)$

- Стохастический метод имеет дешёвые итерации, но медленную сходимость.
 - Сублинейная сходимость даже в сильно выпуклом случае.
 - Оценки неулучшаемы при стандартных предположениях.
 - Оракул возвращает несмещённую аппроксимацию градиента с ограниченной дисперсией.
- Моментные и квазиньютоновские методы **не улучшают** скорость в стохастическом случае. Могут улучшить только константы (узкое место — дисперсия, а не число обусловленности).

Стохастический градиентный спуск (SGD)

Типичное поведение

Stochastic Gradient Descent. Batch = 2



Сходимость

Из липшицевости градиента следует:

$$f(x_{k+1}) \leq f(x_k) + \langle \nabla f(x_k), x_{k+1} - x_k \rangle + \frac{L}{2} \|x_{k+1} - x_k\|^2$$

Сходимость

Из липшицевости градиента следует:

$$f(x_{k+1}) \leq f(x_k) + \langle \nabla f(x_k), x_{k+1} - x_k \rangle + \frac{L}{2} \|x_{k+1} - x_k\|^2$$

Используя (SGD):

$$f(x_{k+1}) \leq f(x_k) - \alpha_k \langle \nabla f(x_k), \nabla f_{i_k}(x_k) \rangle + \alpha_k^2 \frac{L}{2} \|\nabla f_{i_k}(x_k)\|^2$$

Сходимость

Из липшицевости градиента следует:

$$f(x_{k+1}) \leq f(x_k) + \langle \nabla f(x_k), x_{k+1} - x_k \rangle + \frac{L}{2} \|x_{k+1} - x_k\|^2$$

Используя (SGD):

$$f(x_{k+1}) \leq f(x_k) - \alpha_k \langle \nabla f(x_k), \nabla f_{i_k}(x_k) \rangle + \alpha_k^2 \frac{L}{2} \|\nabla f_{i_k}(x_k)\|^2$$

Возьмём математическое ожидание по i_k :

$$\mathbb{E}[f(x_{k+1})] \leq \mathbb{E}[f(x_k) - \alpha_k \langle \nabla f(x_k), \nabla f_{i_k}(x_k) \rangle + \alpha_k^2 \frac{L}{2} \|\nabla f_{i_k}(x_k)\|^2]$$

Сходимость

Из липшицевости градиента следует:

$$f(x_{k+1}) \leq f(x_k) + \langle \nabla f(x_k), x_{k+1} - x_k \rangle + \frac{L}{2} \|x_{k+1} - x_k\|^2$$

Используя (SGD):

$$f(x_{k+1}) \leq f(x_k) - \alpha_k \langle \nabla f(x_k), \nabla f_{i_k}(x_k) \rangle + \alpha_k^2 \frac{L}{2} \|\nabla f_{i_k}(x_k)\|^2$$

Возьмём математическое ожидание по i_k :

$$\mathbb{E}[f(x_{k+1})] \leq \mathbb{E}[f(x_k) - \alpha_k \langle \nabla f(x_k), \nabla f_{i_k}(x_k) \rangle + \alpha_k^2 \frac{L}{2} \|\nabla f_{i_k}(x_k)\|^2]$$

По линейности мат. ожидания:

$$\mathbb{E}[f(x_{k+1})] \leq f(x_k) - \alpha_k \langle \nabla f(x_k), \mathbb{E}[\nabla f_{i_k}(x_k)] \rangle + \alpha_k^2 \frac{L}{2} \mathbb{E}[\|\nabla f_{i_k}(x_k)\|^2]$$

Сходимость

Из липшицевости градиента следует:

$$f(x_{k+1}) \leq f(x_k) + \langle \nabla f(x_k), x_{k+1} - x_k \rangle + \frac{L}{2} \|x_{k+1} - x_k\|^2$$

Используя (SGD):

$$f(x_{k+1}) \leq f(x_k) - \alpha_k \langle \nabla f(x_k), \nabla f_{i_k}(x_k) \rangle + \alpha_k^2 \frac{L}{2} \|\nabla f_{i_k}(x_k)\|^2$$

Возьмём математическое ожидание по i_k :

$$\mathbb{E}[f(x_{k+1})] \leq \mathbb{E}[f(x_k) - \alpha_k \langle \nabla f(x_k), \nabla f_{i_k}(x_k) \rangle + \alpha_k^2 \frac{L}{2} \|\nabla f_{i_k}(x_k)\|^2]$$

По линейности мат. ожидания:

$$\mathbb{E}[f(x_{k+1})] \leq f(x_k) - \alpha_k \langle \nabla f(x_k), \mathbb{E}[\nabla f_{i_k}(x_k)] \rangle + \alpha_k^2 \frac{L}{2} \mathbb{E}[\|\nabla f_{i_k}(x_k)\|^2]$$

Поскольку равномерная выборка даёт несмещённую оценку: $\mathbb{E}[\nabla f_{i_k}(x_k)] = \nabla f(x_k)$:

$$\mathbb{E}[f(x_{k+1})] \leq f(x_k) - \alpha_k \|\nabla f(x_k)\|^2 + \alpha_k^2 \frac{L}{2} \mathbb{E}[\|\nabla f_{i_k}(x_k)\|^2] \quad (1)$$

Гладкий PL-случай. Постоянный шаг

- i** Пусть f — L -гладкая функция, удовлетворяющая условию Поляка-Лоясиевича (PL) с константой $\mu > 0$, а дисперсия стохастического градиента ограничена: $\mathbb{E}[\|\nabla f_i(x_k)\|^2] \leq \sigma^2$. Тогда SGD с постоянным шагом $\alpha < \frac{1}{2\mu}$ гарантирует

$$\mathbb{E}[f(x_k) - f^*] \leq (1 - 2\alpha\mu)^k [f(x_0) - f^*] + \frac{L\sigma^2\alpha}{4\mu}.$$

Начнём с неравенства (1):

$$\mathbb{E}[f(x_{k+1})] \leq f(x_k) - \alpha_k \|\nabla f(x_k)\|^2 + \alpha_k^2 \frac{L}{2} \mathbb{E}[\|\nabla f_{i_k}(x_k)\|^2]$$

Гладкий PL-случай. Постоянный шаг

- i** Пусть f — L -гладкая функция, удовлетворяющая условию Поляка-Лоясиевича (PL) с константой $\mu > 0$, а дисперсия стохастического градиента ограничена: $\mathbb{E}[\|\nabla f_i(x_k)\|^2] \leq \sigma^2$. Тогда SGD с постоянным шагом $\alpha < \frac{1}{2\mu}$ гарантирует

$$\mathbb{E}[f(x_k) - f^*] \leq (1 - 2\alpha\mu)^k [f(x_0) - f^*] + \frac{L\sigma^2\alpha}{4\mu}.$$

Начнём с неравенства (1):

$$\mathbb{E}[f(x_{k+1})] \leq f(x_k) - \alpha_k \|\nabla f(x_k)\|^2 + \alpha_k^2 \frac{L}{2} \mathbb{E}[\|\nabla f_{i_k}(x_k)\|^2]$$

$$\text{PL: } \|\nabla f(x_k)\|^2 \geq 2\mu(f(x_k) - f^*)$$

Гладкий PL-случай. Постоянный шаг

- i** Пусть f — L -гладкая функция, удовлетворяющая условию Поляка-Лоясиевича (PL) с константой $\mu > 0$, а дисперсия стохастического градиента ограничена: $\mathbb{E}[\|\nabla f_i(x_k)\|^2] \leq \sigma^2$. Тогда SGD с постоянным шагом $\alpha < \frac{1}{2\mu}$ гарантирует

$$\mathbb{E}[f(x_k) - f^*] \leq (1 - 2\alpha\mu)^k [f(x_0) - f^*] + \frac{L\sigma^2\alpha}{4\mu}.$$

Начнём с неравенства (1):

$$\begin{aligned}\mathbb{E}[f(x_{k+1})] &\leq f(x_k) - \alpha_k \|\nabla f(x_k)\|^2 + \alpha_k^2 \frac{L}{2} \mathbb{E}[\|\nabla f_{i_k}(x_k)\|^2] \\ \text{PL: } \|\nabla f(x_k)\|^2 &\geq 2\mu(f(x_k) - f^*) \quad \leq f(x_k) - 2\alpha_k\mu(f(x_k) - f^*) + \alpha_k^2 \frac{L}{2} \mathbb{E}[\|\nabla f_{i_k}(x_k)\|^2]\end{aligned}$$

Гладкий PL-случай. Постоянный шаг

- i** Пусть f — L -гладкая функция, удовлетворяющая условию Поляка-Лоясиевича (PL) с константой $\mu > 0$, а дисперсия стохастического градиента ограничена: $\mathbb{E}[\|\nabla f_i(x_k)\|^2] \leq \sigma^2$. Тогда SGD с постоянным шагом $\alpha < \frac{1}{2\mu}$ гарантирует

$$\mathbb{E}[f(x_k) - f^*] \leq (1 - 2\alpha\mu)^k [f(x_0) - f^*] + \frac{L\sigma^2\alpha}{4\mu}.$$

Начнём с неравенства (1):

$$\begin{aligned}\mathbb{E}[f(x_{k+1})] &\leq f(x_k) - \alpha_k \|\nabla f(x_k)\|^2 + \alpha_k^2 \frac{L}{2} \mathbb{E}[\|\nabla f_{i_k}(x_k)\|^2] \\ \text{PL: } \|\nabla f(x_k)\|^2 &\geq 2\mu(f(x_k) - f^*) \quad \leq f(x_k) - 2\alpha_k\mu(f(x_k) - f^*) + \alpha_k^2 \frac{L}{2} \mathbb{E}[\|\nabla f_{i_k}(x_k)\|^2]\end{aligned}$$

Вычитаем f^*

Гладкий PL-случай. Постоянный шаг

i Пусть f — L -гладкая функция, удовлетворяющая условию Поляка-Лоясиевича (PL) с константой $\mu > 0$, а дисперсия стохастического градиента ограничена: $\mathbb{E}[\|\nabla f_i(x_k)\|^2] \leq \sigma^2$. Тогда SGD с постоянным шагом $\alpha < \frac{1}{2\mu}$ гарантирует

$$\mathbb{E}[f(x_k) - f^*] \leq (1 - 2\alpha\mu)^k [f(x_0) - f^*] + \frac{L\sigma^2\alpha}{4\mu}.$$

Начнём с неравенства (1):

$$\mathbb{E}[f(x_{k+1})] \leq f(x_k) - \alpha_k \|\nabla f(x_k)\|^2 + \alpha_k^2 \frac{L}{2} \mathbb{E}[\|\nabla f_{i_k}(x_k)\|^2]$$

$$\text{PL: } \|\nabla f(x_k)\|^2 \geq 2\mu(f(x_k) - f^*) \quad \leq f(x_k) - 2\alpha_k\mu(f(x_k) - f^*) + \alpha_k^2 \frac{L}{2} \mathbb{E}[\|\nabla f_{i_k}(x_k)\|^2]$$

$$\text{Вычитаем } f^* \quad \mathbb{E}[f(x_{k+1})] - f^* \leq (1 - 2\alpha_k\mu)[f(x_k) - f^*] + \alpha_k^2 \frac{L}{2} \mathbb{E}[\|\nabla f_{i_k}(x_k)\|^2]$$

Гладкий PL-случай. Постоянный шаг

i Пусть f — L -гладкая функция, удовлетворяющая условию Поляка-Лоясиевича (PL) с константой $\mu > 0$, а дисперсия стохастического градиента ограничена: $\mathbb{E}[\|\nabla f_i(x_k)\|^2] \leq \sigma^2$. Тогда SGD с постоянным шагом $\alpha < \frac{1}{2\mu}$ гарантирует

$$\mathbb{E}[f(x_k) - f^*] \leq (1 - 2\alpha\mu)^k [f(x_0) - f^*] + \frac{L\sigma^2\alpha}{4\mu}.$$

Начнём с неравенства (1):

$$\mathbb{E}[f(x_{k+1})] \leq f(x_k) - \alpha_k \|\nabla f(x_k)\|^2 + \alpha_k^2 \frac{L}{2} \mathbb{E}[\|\nabla f_{i_k}(x_k)\|^2]$$

$$\text{PL: } \|\nabla f(x_k)\|^2 \geq 2\mu(f(x_k) - f^*) \quad \leq f(x_k) - 2\alpha_k\mu(f(x_k) - f^*) + \alpha_k^2 \frac{L}{2} \mathbb{E}[\|\nabla f_{i_k}(x_k)\|^2]$$

$$\text{Вычитаем } f^* \quad \mathbb{E}[f(x_{k+1})] - f^* \leq (1 - 2\alpha_k\mu)[f(x_k) - f^*] + \alpha_k^2 \frac{L}{2} \mathbb{E}[\|\nabla f_{i_k}(x_k)\|^2]$$

$$\text{Огр. дисперсия: } \mathbb{E}[\|\nabla f_i(x_k)\|^2] \leq \sigma^2$$

Гладкий PL-случай. Постоянный шаг

i Пусть f — L -гладкая функция, удовлетворяющая условию Поляка-Лоясиевича (PL) с константой $\mu > 0$, а дисперсия стохастического градиента ограничена: $\mathbb{E}[\|\nabla f_i(x_k)\|^2] \leq \sigma^2$. Тогда SGD с постоянным шагом $\alpha < \frac{1}{2\mu}$ гарантирует

$$\mathbb{E}[f(x_k) - f^*] \leq (1 - 2\alpha\mu)^k [f(x_0) - f^*] + \frac{L\sigma^2\alpha}{4\mu}.$$

Начнём с неравенства (1):

$$\mathbb{E}[f(x_{k+1})] \leq f(x_k) - \alpha_k \|\nabla f(x_k)\|^2 + \alpha_k^2 \frac{L}{2} \mathbb{E}[\|\nabla f_{i_k}(x_k)\|^2]$$

$$\text{PL: } \|\nabla f(x_k)\|^2 \geq 2\mu(f(x_k) - f^*) \quad \leq f(x_k) - 2\alpha_k\mu(f(x_k) - f^*) + \alpha_k^2 \frac{L}{2} \mathbb{E}[\|\nabla f_{i_k}(x_k)\|^2]$$

$$\text{Вычитаем } f^* \quad \mathbb{E}[f(x_{k+1})] - f^* \leq (1 - 2\alpha_k\mu)[f(x_k) - f^*] + \alpha_k^2 \frac{L}{2} \mathbb{E}[\|\nabla f_{i_k}(x_k)\|^2]$$

$$\text{Огр. дисперсия: } \mathbb{E}[\|\nabla f_i(x_k)\|^2] \leq \sigma^2 \quad \leq (1 - 2\alpha_k\mu)[f(x_k) - f^*] + \frac{L\sigma^2\alpha_k^2}{2}.$$

Гладкий PL-случай. Убывающий шаг

i Пусть f — L -гладкая функция, удовлетворяющая PL с константой $\mu > 0$, а дисперсия стохастического градиента ограничена: $\mathbb{E}[\|\nabla f_i(x_k)\|^2] \leq \sigma^2$. Тогда SGD с убывающим шагом $\alpha_k = \frac{2k+1}{2\mu(k+1)^2}$ гарантирует

$$\mathbb{E}[f(x_k) - f^*] \leq \frac{L\sigma^2}{2\mu^2 k}$$

1. Рассмотрим **стратегию убывающего шага** $\alpha_k = \frac{2k+1}{2\mu(k+1)^2}$:

Гладкий PL-случай. Убывающий шаг

- i** Пусть f — L -гладкая функция, удовлетворяющая PL с константой $\mu > 0$, а дисперсия стохастического градиента ограничена: $\mathbb{E}[\|\nabla f_i(x_k)\|^2] \leq \sigma^2$. Тогда SGD с убывающим шагом $\alpha_k = \frac{2k+1}{2\mu(k+1)^2}$ гарантирует

$$\mathbb{E}[f(x_k) - f^*] \leq \frac{L\sigma^2}{2\mu^2 k}$$

1. Рассмотрим **стратегию убывающего шага** $\alpha_k = \frac{2k+1}{2\mu(k+1)^2}$:

$$1 - 2\alpha_k \mu = \frac{k^2}{(k+1)^2}$$

Гладкий PL-случай. Убывающий шаг

i Пусть f — L -гладкая функция, удовлетворяющая PL с константой $\mu > 0$, а дисперсия стохастического градиента ограничена: $\mathbb{E}[\|\nabla f_i(x_k)\|^2] \leq \sigma^2$. Тогда SGD с убывающим шагом $\alpha_k = \frac{2k+1}{2\mu(k+1)^2}$ гарантирует

$$\mathbb{E}[f(x_k) - f^*] \leq \frac{L\sigma^2}{2\mu^2 k}$$

1. Рассмотрим **стратегию убывающего шага** $\alpha_k = \frac{2k+1}{2\mu(k+1)^2}$:

$$1 - 2\alpha_k \mu = \frac{k^2}{(k+1)^2} \quad \mathbb{E}[f(x_{k+1}) - f^*] \leq \frac{k^2}{(k+1)^2} [f(x_k) - f^*] + \frac{L\sigma^2(2k+1)^2}{8\mu^2(k+1)^4}$$

Гладкий PL-случай. Убывающий шаг

i Пусть f — L -гладкая функция, удовлетворяющая PL с константой $\mu > 0$, а дисперсия стохастического градиента ограничена: $\mathbb{E}[\|\nabla f_i(x_k)\|^2] \leq \sigma^2$. Тогда SGD с убывающим шагом $\alpha_k = \frac{2k+1}{2\mu(k+1)^2}$ гарантирует

$$\mathbb{E}[f(x_k) - f^*] \leq \frac{L\sigma^2}{2\mu^2 k}$$

1. Рассмотрим стратегию убывающего шага $\alpha_k = \frac{2k+1}{2\mu(k+1)^2}$:

$$\begin{aligned} 1 - 2\alpha_k \mu &= \frac{k^2}{(k+1)^2} & \mathbb{E}[f(x_{k+1}) - f^*] &\leq \frac{k^2}{(k+1)^2} [f(x_k) - f^*] + \frac{L\sigma^2(2k+1)^2}{8\mu^2(k+1)^4} \\ (2k+1)^2 < (2k+2)^2 &= 4(k+1)^2 & &\leq \frac{k^2}{(k+1)^2} [f(x_k) - f^*] + \frac{L\sigma^2}{2\mu^2(k+1)^2} \end{aligned}$$

Гладкий PL-случай. Убывающий шаг

i Пусть f — L -гладкая функция, удовлетворяющая PL с константой $\mu > 0$, а дисперсия стохастического градиента ограничена: $\mathbb{E}[\|\nabla f_i(x_k)\|^2] \leq \sigma^2$. Тогда SGD с убывающим шагом $\alpha_k = \frac{2k+1}{2\mu(k+1)^2}$ гарантирует

$$\mathbb{E}[f(x_k) - f^*] \leq \frac{L\sigma^2}{2\mu^2 k}$$

1. Рассмотрим стратегию убывающего шага $\alpha_k = \frac{2k+1}{2\mu(k+1)^2}$:

$$\begin{aligned} 1 - 2\alpha_k \mu &= \frac{k^2}{(k+1)^2} & \mathbb{E}[f(x_{k+1}) - f^*] &\leq \frac{k^2}{(k+1)^2} [f(x_k) - f^*] + \frac{L\sigma^2(2k+1)^2}{8\mu^2(k+1)^4} \\ (2k+1)^2 &< (2k+2)^2 = 4(k+1)^2 & &\leq \frac{k^2}{(k+1)^2} [f(x_k) - f^*] + \frac{L\sigma^2}{2\mu^2(k+1)^2} \end{aligned}$$

2. Домножая обе части на $(k+1)^2$ и обозначая $\delta_f(k) \equiv k^2 \mathbb{E}[f(x_k) - f^*]$:

$$\delta_f(k+1) \leq \delta_f(k) + \frac{L\sigma^2}{2\mu^2}.$$

Гладкий PL-случай. Убывающий шаг

3. Суммируя предыдущее неравенство от $i = 0$ до k и используя $\delta_f(0) = 0$:

что даёт заявленную скорость.

Гладкий PL-случай. Убывающий шаг

3. Суммируя предыдущее неравенство от $i = 0$ до k и используя $\delta_f(0) = 0$:

$$\delta_f(k+1) \leq \frac{L\sigma^2(k+1)}{2\mu^2}$$

что даёт заявленную скорость.

Гладкий PL-случай. Убывающий шаг

3. Суммируя предыдущее неравенство от $i = 0$ до k и используя $\delta_f(0) = 0$:

$$\begin{aligned}\delta_f(k+1) &\leq \frac{L\sigma^2(k+1)}{2\mu^2} \\ (k+1)^2 \mathbb{E}[f(x_{k+1}) - f^*] &\leq \frac{L\sigma^2(k+1)}{2\mu^2}\end{aligned}$$

что даёт заявленную скорость.

Гладкий PL-случай. Убывающий шаг

3. Суммируя предыдущее неравенство от $i = 0$ до k и используя $\delta_f(0) = 0$:

$$\begin{aligned}\delta_f(k+1) &\leq \frac{L\sigma^2(k+1)}{2\mu^2} \\ (k+1)^2 \mathbb{E}[f(x_{k+1}) - f^*] &\leq \frac{L\sigma^2(k+1)}{2\mu^2} \\ \mathbb{E}[f(x_k) - f^*] &\leq \frac{L\sigma^2}{2\mu^2 k}\end{aligned}$$

что даёт заявленную скорость.

Гладкий выпуклый случай. Постоянный шаг

i Пусть f — выпуклая функция, а дисперсия стохастического градиента ограничена $\mathbb{E}[\|\nabla f_{i_k}(x_k)\|^2] \leq \sigma^2 \quad \forall k$. Если SGD использует постоянный шаг $\alpha_t \equiv \alpha > 0$, то для любого $k \geq 1$

$$\mathbb{E}[f(\bar{x}_k) - f^*] \leq \frac{\|x_0 - x^*\|^2}{2\alpha k} + \frac{\alpha \sigma^2}{2}$$

где $\bar{x}_k = \frac{1}{k} \sum_{t=0}^{k-1} x_t$.

При выборе $\alpha = \frac{\|x_0 - x^*\|}{\sigma \sqrt{k}}$ имеем

$$\mathbb{E}[f(\bar{x}_k) - f^*] \leq \frac{\|x_0 - x^*\| \sigma}{\sqrt{k}} = \mathcal{O}\left(\frac{1}{\sqrt{k}}\right).$$

Гладкий выпуклый случай. Постоянный шаг

1. Начнём с разложения квадрата расстояния до минимума:

$$\|x_{k+1} - x^*\|^2 = \|x_k - \alpha \nabla f_{i_k}(x_k) - x^*\|^2 = \|x_k - x^*\|^2 - 2\alpha \langle \nabla f_{i_k}(x_k), x_k - x^* \rangle + \alpha^2 \|\nabla f_{i_k}(x_k)\|^2.$$

Гладкий выпуклый случай. Постоянный шаг

1. Начнём с разложения квадрата расстояния до минимума:

$$\|x_{k+1} - x^*\|^2 = \|x_k - \alpha \nabla f_{i_k}(x_k) - x^*\|^2 = \|x_k - x^*\|^2 - 2\alpha \langle \nabla f_{i_k}(x_k), x_k - x^* \rangle + \alpha^2 \|\nabla f_{i_k}(x_k)\|^2.$$

2. Берём условное матожидание по i_k (обозначим $\mathbb{E}_k[\cdot] = \mathbb{E}[\cdot | x_k]$), используем свойство $\mathbb{E}_k[\nabla f_{i_k}(x_k)] = \nabla f(x_k)$, ограниченность дисперсии $\mathbb{E}_k[\|\nabla f_{i_k}(x_k)\|^2] \leq \sigma^2$ и выпуклость f (которая даёт $\langle \nabla f(x_k), x_k - x^* \rangle \geq f(x_k) - f^*$):

$$\begin{aligned} \mathbb{E}_k[\|x_{k+1} - x^*\|^2] &= \|x_k - x^*\|^2 - 2\alpha \langle \nabla f(x_k), x_k - x^* \rangle + \alpha^2 \mathbb{E}_k[\|\nabla f_{i_k}(x_k)\|^2] \\ &\leq \|x_k - x^*\|^2 - 2\alpha(f(x_k) - f^*) + \alpha^2 \sigma^2. \end{aligned}$$

Гладкий выпуклый случай. Постоянный шаг

1. Начнём с разложения квадрата расстояния до минимума:

$$\|x_{k+1} - x^*\|^2 = \|x_k - \alpha \nabla f_{i_k}(x_k) - x^*\|^2 = \|x_k - x^*\|^2 - 2\alpha \langle \nabla f_{i_k}(x_k), x_k - x^* \rangle + \alpha^2 \|\nabla f_{i_k}(x_k)\|^2.$$

2. Берём условное матожидание по i_k (обозначим $\mathbb{E}_k[\cdot] = \mathbb{E}[\cdot | x_k]$), используем свойство $\mathbb{E}_k[\nabla f_{i_k}(x_k)] = \nabla f(x_k)$, ограниченность дисперсии $\mathbb{E}_k[\|\nabla f_{i_k}(x_k)\|^2] \leq \sigma^2$ и выпуклость f (которая даёт $\langle \nabla f(x_k), x_k - x^* \rangle \geq f(x_k) - f^*$):

$$\begin{aligned} \mathbb{E}_k[\|x_{k+1} - x^*\|^2] &= \|x_k - x^*\|^2 - 2\alpha \langle \nabla f(x_k), x_k - x^* \rangle + \alpha^2 \mathbb{E}_k[\|\nabla f_{i_k}(x_k)\|^2] \\ &\leq \|x_k - x^*\|^2 - 2\alpha(f(x_k) - f^*) + \alpha^2 \sigma^2. \end{aligned}$$

3. Переносим член с $f(x_k)$ влево и берём полное матожидание:

$$2\alpha \mathbb{E}[f(x_k) - f^*] \leq \mathbb{E}[\|x_k - x^*\|^2] - \mathbb{E}[\|x_{k+1} - x^*\|^2] + \alpha^2 \sigma^2.$$

Гладкий выпуклый случай. Постоянный шаг

1. Начнём с разложения квадрата расстояния до минимума:

$$\|x_{k+1} - x^*\|^2 = \|x_k - \alpha \nabla f_{i_k}(x_k) - x^*\|^2 = \|x_k - x^*\|^2 - 2\alpha \langle \nabla f_{i_k}(x_k), x_k - x^* \rangle + \alpha^2 \|\nabla f_{i_k}(x_k)\|^2.$$

2. Берём условное матожидание по i_k (обозначим $\mathbb{E}_k[\cdot] = \mathbb{E}[\cdot | x_k]$), используем свойство $\mathbb{E}_k[\nabla f_{i_k}(x_k)] = \nabla f(x_k)$, ограниченность дисперсии $\mathbb{E}_k[\|\nabla f_{i_k}(x_k)\|^2] \leq \sigma^2$ и выпуклость f (которая даёт $\langle \nabla f(x_k), x_k - x^* \rangle \geq f(x_k) - f^*$):

$$\begin{aligned} \mathbb{E}_k[\|x_{k+1} - x^*\|^2] &= \|x_k - x^*\|^2 - 2\alpha \langle \nabla f(x_k), x_k - x^* \rangle + \alpha^2 \mathbb{E}_k[\|\nabla f_{i_k}(x_k)\|^2] \\ &\leq \|x_k - x^*\|^2 - 2\alpha(f(x_k) - f^*) + \alpha^2 \sigma^2. \end{aligned}$$

3. Переносим член с $f(x_k)$ влево и берём полное матожидание:

$$2\alpha \mathbb{E}[f(x_k) - f^*] \leq \mathbb{E}[\|x_k - x^*\|^2] - \mathbb{E}[\|x_{k+1} - x^*\|^2] + \alpha^2 \sigma^2.$$

4. Суммируем (телескопируем) по $t = 0, \dots, k-1$:

$$\begin{aligned} \sum_{t=0}^{k-1} 2\alpha \mathbb{E}[f(x_t) - f^*] &\leq \sum_{t=0}^{k-1} (\mathbb{E}[\|x_t - x^*\|^2] - \mathbb{E}[\|x_{t+1} - x^*\|^2]) + \sum_{t=0}^{k-1} \alpha^2 \sigma^2 \\ &= \mathbb{E}[\|x_0 - x^*\|^2] - \mathbb{E}[\|x_k - x^*\|^2] + k \alpha^2 \sigma^2 \\ &\leq \|x_0 - x^*\|^2 + k \alpha^2 \sigma^2. \end{aligned}$$

Гладкий выпуклый случай. Постоянный шаг

5. Делим на $2\alpha k$:

$$\frac{1}{k} \sum_{t=0}^{k-1} \mathbb{E}[f(x_t) - f^*] \leq \frac{\|x_0 - x^*\|^2}{2\alpha k} + \frac{\alpha\sigma^2}{2}.$$

Гладкий выпуклый случай. Постоянный шаг

5. Делим на $2\alpha k$:

$$\frac{1}{k} \sum_{t=0}^{k-1} \mathbb{E}[f(x_t) - f^*] \leq \frac{\|x_0 - x^*\|^2}{2\alpha k} + \frac{\alpha\sigma^2}{2}.$$

6. Используя выпуклость f и неравенство Йенсена для усреднённой точки $\bar{x}_k = \frac{1}{k} \sum_{t=0}^{k-1} x_t$:

$$\mathbb{E}[f(\bar{x}_k)] \leq \mathbb{E} \left[\frac{1}{k} \sum_{t=0}^{k-1} f(x_t) \right] = \frac{1}{k} \sum_{t=0}^{k-1} \mathbb{E}[f(x_t)].$$

Вычитая f^* из обеих частей, получаем:

$$\mathbb{E}[f(\bar{x}_k) - f^*] \leq \frac{1}{k} \sum_{t=0}^{k-1} \mathbb{E}[f(x_t) - f^*].$$

Гладкий выпуклый случай. Постоянный шаг

5. Делим на $2\alpha k$:

$$\frac{1}{k} \sum_{t=0}^{k-1} \mathbb{E}[f(x_t) - f^*] \leq \frac{\|x_0 - x^*\|^2}{2\alpha k} + \frac{\alpha \sigma^2}{2}.$$

6. Используя выпуклость f и неравенство Йенсена для усреднённой точки $\bar{x}_k = \frac{1}{k} \sum_{t=0}^{k-1} x_t$:

$$\mathbb{E}[f(\bar{x}_k)] \leq \mathbb{E} \left[\frac{1}{k} \sum_{t=0}^{k-1} f(x_t) \right] = \frac{1}{k} \sum_{t=0}^{k-1} \mathbb{E}[f(x_t)].$$

Вычитая f^* из обеих частей, получаем:

$$\mathbb{E}[f(\bar{x}_k) - f^*] \leq \frac{1}{k} \sum_{t=0}^{k-1} \mathbb{E}[f(x_t) - f^*].$$

7. Объединяя (5) и (6), получаем искомую оценку:

$$\mathbb{E}[f(\bar{x}_k) - f^*] \leq \frac{\|x_0 - x^*\|^2}{2\alpha k} + \frac{\alpha \sigma^2}{2}.$$

Гладкий выпуклый случай. Убывающий шаг

$$\alpha_k = \frac{\alpha_0}{\sqrt{k+1}}, \quad 0 < \alpha_0 \leq \frac{1}{4L}$$

i При тех же предположениях, но со спадом шага $\alpha_k = \frac{\alpha_0}{\sqrt{k+1}}$

$$\mathbb{E}[f(\bar{x}_k) - f^*] \leq \frac{5\|x_0 - x^*\|^2}{4\alpha_0\sqrt{k}} + 5\alpha_0\sigma^2 \frac{\log(k+1)}{\sqrt{k}} = \mathcal{O}\left(\frac{\log k}{\sqrt{k}}\right).$$

Мини-батч SGD

Мини-батч SGD

Подход: контроль размера выборки

Детерминированный метод использует все n градиентов:

$$\nabla f(x_k) = \frac{1}{n} \sum_{i=1}^n \nabla f_i(x_k).$$

Стохастический метод аппроксимирует это одним семплом:

$$\nabla f_{i_k}(x_k) \approx \frac{1}{n} \sum_{i=1}^n \nabla f_i(x_k).$$

Распространённый вариант — использовать большую выборку B_k («мини-батч»):

$$\frac{1}{|B_k|} \sum_{i \in B_k} \nabla f_i(x_k) \approx \frac{1}{n} \sum_{i=1}^n \nabla f_i(x_k),$$

что особенно удобно для векторизации и параллелизации.

Например, при 16 ядрах ставим $|B_k| = 16$ и считаем 16 градиентов одновременно.

Мини-батч как ГС с ошибкой

SGD с мини-батчем B_k использует итерации:

$$x_{k+1} = x_k - \alpha_k \left(\frac{1}{|B_k|} \sum_{i \in B_k} \nabla f_i(x_k) \right).$$

Рассмотрим это как «градиентный метод с ошибкой»:

$$x_{k+1} = x_k - \alpha_k (\nabla f(x_k) + e_k),$$

где e_k — разность между приближённым и истинным градиентами.

При $\alpha_k = \frac{1}{L}$, используя лемму спуска:


$$f(x_{k+1}) \leq f(x_k) - \frac{1}{2L} \|\nabla f(x_k)\|^2 + \frac{1}{2L} \|e_k\|^2,$$

для любой ошибки e_k .


Идея SGD и батчей

Данные


Идея SGD и батчей




Идея SGD и батчей



Идея SGD и батчей




Идея SGD и батчей




Детерминированный vs стохастический

Градиентный спуск сходится к локальному минимуму




Детерминированный vs стохастический

Градиентный спуск
сходится к локальному минимуму



SGD помогает убежать из локальных минимумов


Стохастический градиентный спуск
выпрыгивает из локальных минимумов



Главная проблема SGD

$$f(x) = \frac{\mu}{2} \|x\|_2^2 + \frac{1}{m} \sum_{i=1}^m \log(1 + \exp(-y_i \langle a_i, x \rangle)) \rightarrow \min_{x \in \mathbb{R}^n}$$

Strongly convex binary logistic regression. $m=200$, $n=10$, $\mu=1$.



Основные результаты сходимости SGD

i Пусть f — L -гладкая μ -сильно выпуклая функция, а дисперсия стохастического градиента конечна ($\mathbb{E}[\|\nabla f_i(x_k)\|^2] \leq \sigma^2$). Тогда SGD с постоянным шагом $\alpha < \frac{1}{2\mu}$ гарантирует:

$$\mathbb{E}[f(x_{k+1}) - f^*] \leq (1 - 2\alpha\mu)^k [f(x_0) - f^*] + \frac{L\sigma^2\alpha}{4\mu}.$$

Основные результаты сходимости SGD

- i** Пусть f — L -гладкая μ -сильно выпуклая функция, а дисперсия стохастического градиента конечна ($\mathbb{E}[\|\nabla f_i(x_k)\|^2] \leq \sigma^2$). Тогда SGD с постоянным шагом $\alpha < \frac{1}{2\mu}$ гарантирует:

$$\mathbb{E}[f(x_{k+1}) - f^*] \leq (1 - 2\alpha\mu)^k [f(x_0) - f^*] + \frac{L\sigma^2\alpha}{4\mu}.$$

- i** Пусть f — L -гладкая μ -сильно выпуклая функция, а дисперсия стохастического градиента конечна ($\mathbb{E}[\|\nabla f_i(x_k)\|^2] \leq \sigma^2$). Тогда SGD с убывающим шагом $\alpha_k = \frac{2k+1}{2\mu(k+1)^2}$ гарантирует:

$$\mathbb{E}[f(x_{k+1}) - f^*] \leq \frac{L\sigma^2}{2\mu^2(k+1)}$$

Выводы по SGD

- SGD с постоянным шагом **не сходится** даже в PL (сильно выпуклом) случае — остаётся «окрестность» $\frac{L\sigma^2\alpha}{4\mu}$

Выводы по SGD

- SGD с постоянным шагом **не сходится** даже в PL (сильно выпуклом) случае — остаётся «окрестность» $\frac{L\sigma^2\alpha}{4\mu}$
- SGD достигает сублинейной сходимости $\mathcal{O}\left(\frac{1}{k}\right)$ в PL-случае с убывающим шагом

Выводы по SGD

- SGD с постоянным шагом **не сходится** даже в PL (сильно выпуклом) случае — остаётся «окрестность» $\frac{L\sigma^2\alpha}{4\mu}$
- SGD достигает сублинейной сходимости $\mathcal{O}\left(\frac{1}{k}\right)$ в PL-случае с убывающим шагом
- Ускорения Нестерова/Поляка **не улучшают** скорость сходимости в стохастическом случае

Выводы по SGD

- SGD с постоянным шагом **не сходится** даже в PL (сильно выпуклом) случае — остаётся «окрестность» $\frac{L\sigma^2\alpha}{4\mu}$
- SGD достигает сублинейной сходимости $\mathcal{O}\left(\frac{1}{k}\right)$ в PL-случае с убывающим шагом
- Ускорения Нестерова/Поляка **не улучшают** скорость сходимости в стохастическом случае
- Можно ли достичь линейной сходимости как у GD при стоимости итерации как у SGD? **Да — методы редукции дисперсии.**

Методы редукции дисперсии

Ключевая идея редукции дисперсии

Принцип: уменьшение дисперсии выборки X с помощью выборки из другой случайной величины Y с известным мат. ожиданием:

$$Z_\alpha = \alpha(X - Y) + \mathbb{E}[Y]$$

- $\mathbb{E}[Z_\alpha] = \alpha\mathbb{E}[X] + (1 - \alpha)\mathbb{E}[Y]$

Ключевая идея редукции дисперсии

Принцип: уменьшение дисперсии выборки X с помощью выборки из другой случайной величины Y с известным мат. ожиданием:

$$Z_\alpha = \alpha(X - Y) + \mathbb{E}[Y]$$

- $\mathbb{E}[Z_\alpha] = \alpha\mathbb{E}[X] + (1 - \alpha)\mathbb{E}[Y]$
- $\text{var}(Z_\alpha) = \alpha^2 (\text{var}(X) + \text{var}(Y) - 2\text{cov}(X, Y))$

Ключевая идея редукции дисперсии

Принцип: уменьшение дисперсии выборки X с помощью выборки из другой случайной величины Y с известным мат. ожиданием:

$$Z_\alpha = \alpha(X - Y) + \mathbb{E}[Y]$$

- $\mathbb{E}[Z_\alpha] = \alpha\mathbb{E}[X] + (1 - \alpha)\mathbb{E}[Y]$
- $\text{var}(Z_\alpha) = \alpha^2(\text{var}(X) + \text{var}(Y) - 2\text{cov}(X, Y))$
 - Если $\alpha = 1$: нет смещения

Ключевая идея редукции дисперсии

Принцип: уменьшение дисперсии выборки X с помощью выборки из другой случайной величины Y с известным мат. ожиданием:

$$Z_\alpha = \alpha(X - Y) + \mathbb{E}[Y]$$

- $\mathbb{E}[Z_\alpha] = \alpha\mathbb{E}[X] + (1 - \alpha)\mathbb{E}[Y]$
- $\text{var}(Z_\alpha) = \alpha^2 (\text{var}(X) + \text{var}(Y) - 2\text{cov}(X, Y))$
 - Если $\alpha = 1$: нет смещения
 - Если $\alpha < 1$: потенциальное смещение (но уменьшенная дисперсия).

Ключевая идея редукции дисперсии

Принцип: уменьшение дисперсии выборки X с помощью выборки из другой случайной величины Y с известным мат. ожиданием:

$$Z_\alpha = \alpha(X - Y) + \mathbb{E}[Y]$$

- $\mathbb{E}[Z_\alpha] = \alpha\mathbb{E}[X] + (1 - \alpha)\mathbb{E}[Y]$
- $\text{var}(Z_\alpha) = \alpha^2 (\text{var}(X) + \text{var}(Y) - 2\text{cov}(X, Y))$
 - Если $\alpha = 1$: нет смещения
 - Если $\alpha < 1$: потенциальное смещение (но уменьшенная дисперсия).
- Полезно, если Y положительно коррелирует с X .

Ключевая идея редукции дисперсии

Принцип: уменьшение дисперсии выборки X с помощью выборки из другой случайной величины Y с известным мат. ожиданием:

$$Z_\alpha = \alpha(X - Y) + \mathbb{E}[Y]$$

- $\mathbb{E}[Z_\alpha] = \alpha\mathbb{E}[X] + (1 - \alpha)\mathbb{E}[Y]$
- $\text{var}(Z_\alpha) = \alpha^2 (\text{var}(X) + \text{var}(Y) - 2\text{cov}(X, Y))$
 - Если $\alpha = 1$: нет смещения
 - Если $\alpha < 1$: потенциальное смещение (но уменьшенная дисперсия).
- Полезно, если Y положительно коррелирует с X .

Ключевая идея редукции дисперсии

Принцип: уменьшение дисперсии выборки X с помощью выборки из другой случайной величины Y с известным мат. ожиданием:

$$Z_\alpha = \alpha(X - Y) + \mathbb{E}[Y]$$

- $\mathbb{E}[Z_\alpha] = \alpha\mathbb{E}[X] + (1 - \alpha)\mathbb{E}[Y]$
- $\text{var}(Z_\alpha) = \alpha^2 (\text{var}(X) + \text{var}(Y) - 2\text{cov}(X, Y))$
 - Если $\alpha = 1$: нет смещения
 - Если $\alpha < 1$: потенциальное смещение (но уменьшенная дисперсия).
- Полезно, если Y положительно коррелирует с X .

Применение к оценке градиента:

- SVRG: Пусть $X = \nabla f_{i_k}(x^{(k-1)})$ и $Y = \nabla f_{i_k}(\tilde{x})$, при $\alpha = 1$ и запомненном $\tilde{x}$.

Ключевая идея редукции дисперсии

Принцип: уменьшение дисперсии выборки X с помощью выборки из другой случайной величины Y с известным мат. ожиданием:

$$Z_\alpha = \alpha(X - Y) + \mathbb{E}[Y]$$

- $\mathbb{E}[Z_\alpha] = \alpha\mathbb{E}[X] + (1 - \alpha)\mathbb{E}[Y]$
- $\text{var}(Z_\alpha) = \alpha^2(\text{var}(X) + \text{var}(Y) - 2\text{cov}(X, Y))$
 - Если $\alpha = 1$: нет смещения
 - Если $\alpha < 1$: потенциальное смещение (но уменьшенная дисперсия).
- Полезно, если Y положительно коррелирует с X .

Применение к оценке градиента:

- SVRG: Пусть $X = \nabla f_{i_k}(x^{(k-1)})$ и $Y = \nabla f_{i_k}(\tilde{x})$, при $\alpha = 1$ и запомненном $\tilde{x}$.
- $\mathbb{E}[Y] = \frac{1}{n} \sum_{i=1}^n \nabla f_i(\tilde{x})$ — полный градиент в $\tilde{x}$;

Ключевая идея редукции дисперсии

Принцип: уменьшение дисперсии выборки X с помощью выборки из другой случайной величины Y с известным мат. ожиданием:

$$Z_\alpha = \alpha(X - Y) + \mathbb{E}[Y]$$

- $\mathbb{E}[Z_\alpha] = \alpha\mathbb{E}[X] + (1 - \alpha)\mathbb{E}[Y]$
- $\text{var}(Z_\alpha) = \alpha^2(\text{var}(X) + \text{var}(Y) - 2\text{cov}(X, Y))$
 - Если $\alpha = 1$: нет смещения
 - Если $\alpha < 1$: потенциальное смещение (но уменьшенная дисперсия).
- Полезно, если Y положительно коррелирует с X .

Применение к оценке градиента:

- SVRG: Пусть $X = \nabla f_{i_k}(x^{(k-1)})$ и $Y = \nabla f_{i_k}(\tilde{x})$, при $\alpha = 1$ и запомненном $\tilde{x}$.
- $\mathbb{E}[Y] = \frac{1}{n} \sum_{i=1}^n \nabla f_i(\tilde{x})$ — полный градиент в $\tilde{x}$;
- $X - Y = \nabla f_{i_k}(x^{(k-1)}) - \nabla f_{i_k}(\tilde{x})$ — разность стремится к нулю вблизи решения.

SAG (Stochastic Average Gradient, Schmidt, Le Roux, Bach 2013)

- Хранить таблицу градиентов g_i от f_i , $i = 1, \dots, n$

SAG (Stochastic Average Gradient, Schmidt, Le Roux, Bach 2013)

- Хранить таблицу градиентов g_i от f_i , $i = 1, \dots, n$
- Инициализация $x^{(0)}$, и $g_i^{(0)} = \nabla f_i(x^{(0)})$, $i = 1, \dots, n$

SAG (Stochastic Average Gradient, Schmidt, Le Roux, Bach 2013)

- Хранить таблицу градиентов g_i от f_i , $i = 1, \dots, n$
- Инициализация $x^{(0)}$, и $g_i^{(0)} = \nabla f_i(x^{(0)})$, $i = 1, \dots, n$
- На шаге $k = 1, 2, 3, \dots$, выбрать случайный $i_k \in \{1, \dots, n\}$, затем

$$g_{i_k}^{(k)} = \nabla f_{i_k}(x^{(k-1)}) \quad (\text{обновление последнего градиента } f_{i_k})$$

Все остальные $g_i^{(k)} = g_i^{(k-1)}$, $i \neq i_k$, т.е. остаются без изменений

SAG (Stochastic Average Gradient, Schmidt, Le Roux, Bach 2013)

- Хранить таблицу градиентов g_i от f_i , $i = 1, \dots, n$
- Инициализация $x^{(0)}$, и $g_i^{(0)} = \nabla f_i(x^{(0)})$, $i = 1, \dots, n$
- На шаге $k = 1, 2, 3, \dots$, выбрать случайный $i_k \in \{1, \dots, n\}$, затем

$$g_{i_k}^{(k)} = \nabla f_{i_k}(x^{(k-1)}) \quad (\text{обновление последнего градиента } f_{i_k})$$

Все остальные $g_i^{(k)} = g_i^{(k-1)}$, $i \neq i_k$, т.е. остаются без изменений

- Обновление

$$x^{(k)} = x^{(k-1)} - \alpha_k \frac{1}{n} \sum_{i=1}^n g_i^{(k)}$$

SAG (Stochastic Average Gradient, Schmidt, Le Roux, Bach 2013)

- Хранить таблицу градиентов g_i от f_i , $i = 1, \dots, n$
- Инициализация $x^{(0)}$, и $g_i^{(0)} = \nabla f_i(x^{(0)})$, $i = 1, \dots, n$
- На шаге $k = 1, 2, 3, \dots$, выбрать случайный $i_k \in \{1, \dots, n\}$, затем

$$g_{i_k}^{(k)} = \nabla f_{i_k}(x^{(k-1)}) \quad (\text{обновление последнего градиента } f_{i_k})$$

Все остальные $g_i^{(k)} = g_i^{(k-1)}$, $i \neq i_k$, т.е. остаются без изменений

- Обновление

$$x^{(k)} = x^{(k-1)} - \alpha_k \frac{1}{n} \sum_{i=1}^n g_i^{(k)}$$

- Оценки градиента SAG **не являются несмещёнными**, но имеют значительно уменьшенную дисперсию

SAG (Stochastic Average Gradient, Schmidt, Le Roux, Bach 2013)

- Хранить таблицу градиентов g_i от f_i , $i = 1, \dots, n$
- Инициализация $x^{(0)}$, и $g_i^{(0)} = \nabla f_i(x^{(0)})$, $i = 1, \dots, n$
- На шаге $k = 1, 2, 3, \dots$, выбрать случайный $i_k \in \{1, \dots, n\}$, затем

$$g_{i_k}^{(k)} = \nabla f_{i_k}(x^{(k-1)}) \quad (\text{обновление последнего градиента } f_{i_k})$$

Все остальные $g_i^{(k)} = g_i^{(k-1)}$, $i \neq i_k$, т.е. остаются без изменений

- Обновление

$$x^{(k)} = x^{(k-1)} - \alpha_k \frac{1}{n} \sum_{i=1}^n g_i^{(k)}$$

- Оценки градиента SAG **не являются несмещёнными**, но имеют значительно уменьшенную дисперсию
- Не дорого ли усреднять все эти градиенты? Столь же эффективно, как SGD, при правильной реализации:

$$x^{(k)} = x^{(k-1)} - \alpha_k \underbrace{\left(\frac{1}{n} g_{i_k}^{(k)} - \frac{1}{n} g_{i_k}^{(k-1)} + \underbrace{\frac{1}{n} \sum_{i=1}^n g_i^{(k-1)}}_{\text{старое среднее таблицы}} \right)}_{\text{новое среднее таблицы}}$$

Сходимость SAG

Предположим, что $f(x) = \frac{1}{n} \sum_{i=1}^n f_i(x)$, где каждая f_i дифференцируема, и ∇f_i липшицев с константой L .

Обозначим $\bar{x}^{(k)} = \frac{1}{k} \sum_{l=0}^{k-1} x^{(l)}$ — среднюю итерацию после $k - 1$ шагов.

i Theorem

SAG с фиксированным шагом $\alpha = \frac{1}{16L}$ и инициализацией

$$g_i^{(0)} = \nabla f_i(x^{(0)}) - \nabla f(x^{(0)}), \quad i = 1, \dots, n$$

удовлетворяет

$$\mathbb{E}[f(\bar{x}^{(k)})] - f^* \leq \frac{48n}{k} [f(x^{(0)}) - f^*] + \frac{128L}{k} \|x^{(0)} - x^*\|^2$$

Сходимость SAG

Предположим, что $f(x) = \frac{1}{n} \sum_{i=1}^n f_i(x)$, где каждая f_i дифференцируема, и ∇f_i липшицев с константой L .

Обозначим $\bar{x}^{(k)} = \frac{1}{k} \sum_{l=0}^{k-1} x^{(l)}$ — среднюю итерацию после $k - 1$ шагов.

i Theorem

SAG с фиксированным шагом $\alpha = \frac{1}{16L}$ и инициализацией

$$g_i^{(0)} = \nabla f_i(x^{(0)}) - \nabla f(x^{(0)}), \quad i = 1, \dots, n$$

удовлетворяет

$$\mathbb{E}[f(\bar{x}^{(k)})] - f^* \leq \frac{48n}{k} [f(x^{(0)}) - f^*] + \frac{128L}{k} \|x^{(0)} - x^*\|^2$$

- Скорость $\mathcal{O}\left(\frac{1}{k}\right)$ для SAG. Сравните: $\mathcal{O}\left(\frac{1}{k}\right)$ для GD и $\mathcal{O}\left(\frac{1}{\sqrt{k}}\right)$ для SGD.

Сходимость SAG

Предположим, что $f(x) = \frac{1}{n} \sum_{i=1}^n f_i(x)$, где каждая f_i дифференцируема, и ∇f_i липшицев с константой L .

Обозначим $\bar{x}^{(k)} = \frac{1}{k} \sum_{l=0}^{k-1} x^{(l)}$ — среднюю итерацию после $k - 1$ шагов.

i Theorem

SAG с фиксированным шагом $\alpha = \frac{1}{16L}$ и инициализацией

$$g_i^{(0)} = \nabla f_i(x^{(0)}) - \nabla f(x^{(0)}), \quad i = 1, \dots, n$$

удовлетворяет

$$\mathbb{E}[f(\bar{x}^{(k)})] - f^* \leq \frac{48n}{k} [f(x^{(0)}) - f^*] + \frac{128L}{k} \|x^{(0)} - x^*\|^2$$

- Скорость $\mathcal{O}\left(\frac{1}{k}\right)$ для SAG. Сравните: $\mathcal{O}\left(\frac{1}{k}\right)$ для GD и $\mathcal{O}\left(\frac{1}{\sqrt{k}}\right)$ для SGD.
- Но константы различаются! Первый член в оценке SAG страдает от множителя n .

Сходимость SAG. Сильно выпуклый случай

Предположим дополнительно, что каждая f_i сильно выпукла с параметром μ .

Theorem

SAG с шагом $\alpha = \frac{1}{16L}$ удовлетворяет

$$\mathbb{E}[f(x^{(k)})] - f^* \leq \left(1 - \min\left(\frac{\mu}{16L}, \frac{1}{8n}\right)\right)^k \left(\frac{3}{2}(f(x^{(0)}) - f^*) + \frac{4L}{n}\|x^{(0)} - x^*\|^2\right)$$

Сходимость SAG. Сильно выпуклый случай

Предположим дополнительно, что каждая f_i сильно выпукла с параметром μ .

i Theorem

SAG с шагом $\alpha = \frac{1}{16L}$ удовлетворяет

$$\mathbb{E}[f(x^{(k)})] - f^* \leq \left(1 - \min\left(\frac{\mu}{16L}, \frac{1}{8n}\right)\right)^k \left(\frac{3}{2}(f(x^{(0)}) - f^*) + \frac{4L}{n}\|x^{(0)} - x^*\|^2\right)$$

- **Линейная** сходимость $\mathcal{O}(\gamma^k)$ для SAG. Сравните: $\mathcal{O}(\gamma^k)$ для GD и только $\mathcal{O}\left(\frac{1}{k}\right)$ для SGD.

Сходимость SAG. Сильно выпуклый случай

Предположим дополнительно, что каждая f_i сильно выпукла с параметром μ .

i Theorem

SAG с шагом $\alpha = \frac{1}{16L}$ удовлетворяет

$$\mathbb{E}[f(x^{(k)})] - f^* \leq \left(1 - \min\left(\frac{\mu}{16L}, \frac{1}{8n}\right)\right)^k \left(\frac{3}{2}(f(x^{(0)}) - f^*) + \frac{4L}{n}\|x^{(0)} - x^*\|^2\right)$$

- **Линейная** сходимость $\mathcal{O}(\gamma^k)$ для SAG. Сравните: $\mathcal{O}(\gamma^k)$ для GD и только $\mathcal{O}\left(\frac{1}{k}\right)$ для SGD.
- SAG адаптивен к сильной выпуклости, как и GD.

Сходимость SAG. Сильно выпуклый случай

Предположим дополнительно, что каждая f_i сильно выпукла с параметром μ .

Theorem

SAG с шагом $\alpha = \frac{1}{16L}$ удовлетворяет

$$\mathbb{E}[f(x^{(k)})] - f^* \leq \left(1 - \min\left(\frac{\mu}{16L}, \frac{1}{8n}\right)\right)^k \left(\frac{3}{2}(f(x^{(0)}) - f^*) + \frac{4L}{n}\|x^{(0)} - x^*\|^2\right)$$

- **Линейная** сходимость $\mathcal{O}(\gamma^k)$ для SAG. Сравните: $\mathcal{O}(\gamma^k)$ для GD и только $\mathcal{O}(\frac{1}{k})$ для SGD.
- SAG адаптивен к сильной выпуклости, как и GD.
- Как и GD, SAG достигает линейной сходимости, но при стоимости итерации как у SGD.

Замечания по SAG

- Метод в классической формулировке **не применим для больших нейросетей** из-за требований к памяти (нужно хранить n градиентов).

Замечания по SAG

- Метод в классической формулировке **не применим для больших нейросетей** из-за требований к памяти (нужно хранить n градиентов).
- На практике можно использовать backtracking для оценки константы Липшица.

Замечания по SAG

- Метод в классической формулировке **не применим для больших нейросетей** из-за требований к памяти (нужно хранить n градиентов).
- На практике можно использовать backtracking для оценки константы Липшица.
- Поскольку стохастический градиент $g(x^k) \rightarrow \nabla f(x^k)$, можно отслеживать сходимость по его норме (что неверно для SGD!).

Замечания по SAG

- Метод в классической формулировке **не применим для больших нейросетей** из-за требований к памяти (нужно хранить n градиентов).
- На практике можно использовать backtracking для оценки константы Липшица.
- Поскольку стохастический градиент $g(x^k) \rightarrow \nabla f(x^k)$, можно отслеживать сходимость по его норме (что неверно для SGD!).
- Для обобщённых линейных моделей (LogReg, LLS) память $\mathcal{O}(n)$ вместо $\mathcal{O}(pn)$:

$$f_i(w) = \varphi(w^T x_i) \leftrightarrow \nabla f_i(w) = \varphi'(w^T x_i) x_i$$

SVRG (Stochastic Variance Reduced Gradient)

- Инициализация: $\tilde{x} \in \mathbb{R}^d$

SVRG (Stochastic Variance Reduced Gradient)

- Инициализация: $\tilde{x} \in \mathbb{R}^d$
- Для $i_{\text{epoch}} = 1$ до число эпох

SVRG (Stochastic Variance Reduced Gradient)

- Инициализация: $\tilde{x} \in \mathbb{R}^d$
- Для $i_{\text{epoch}} = 1$ до число эпох
 - Вычислить все градиенты $\nabla f_i(\tilde{x})$; сохранить $\nabla f(\tilde{x}) = \frac{1}{n} \sum_{i=1}^n \nabla f_i(\tilde{x})$

SVRG (Stochastic Variance Reduced Gradient)

- Инициализация: $\tilde{x} \in \mathbb{R}^d$
- Для $i_{\text{epoch}} = 1$ до число эпох
 - Вычислить все градиенты $\nabla f_i(\tilde{x})$; сохранить $\nabla f(\tilde{x}) = \frac{1}{n} \sum_{i=1}^n \nabla f_i(\tilde{x})$
 - Инициализировать $x_0 = \tilde{x}$

SVRG (Stochastic Variance Reduced Gradient)

- Инициализация: $\tilde{x} \in \mathbb{R}^d$
- Для $i_{\text{epoch}} = 1$ до число эпох
 - Вычислить все градиенты $\nabla f_i(\tilde{x})$; сохранить $\nabla f(\tilde{x}) = \frac{1}{n} \sum_{i=1}^n \nabla f_i(\tilde{x})$
 - Инициализировать $x_0 = \tilde{x}$
 - Для $t = 1$ до длина эпохи (m)

SVRG (Stochastic Variance Reduced Gradient)

- Инициализация: $\tilde{x} \in \mathbb{R}^d$
- Для $i_{\text{epoch}} = 1$ до число эпох
 - Вычислить все градиенты $\nabla f_i(\tilde{x})$; сохранить $\nabla f(\tilde{x}) = \frac{1}{n} \sum_{i=1}^n \nabla f_i(\tilde{x})$
 - Инициализировать $x_0 = \tilde{x}$
 - Для $t = 1$ до длина эпохи (m)
 - Выбрать $i_t \in \{1, \dots, n\}$ равномерно

SVRG (Stochastic Variance Reduced Gradient)

- Инициализация: $\tilde{x} \in \mathbb{R}^d$
- Для $i_{\text{epoch}} = 1$ до число эпох
 - Вычислить все градиенты $\nabla f_i(\tilde{x})$; сохранить $\nabla f(\tilde{x}) = \frac{1}{n} \sum_{i=1}^n \nabla f_i(\tilde{x})$
 - Инициализировать $x_0 = \tilde{x}$
 - Для $t = 1$ до длина эпохи (m)
 - Выбрать $i_t \in \{1, \dots, n\}$ равномерно
 - $x_t = x_{t-1} - \alpha [\nabla f_{i_t}(x_{t-1}) - \nabla f_{i_t}(\tilde{x}) + \nabla f(\tilde{x})]$

SVRG (Stochastic Variance Reduced Gradient)

- Инициализация: $\tilde{x} \in \mathbb{R}^d$
- Для $i_{\text{epoch}} = 1$ до число эпох
 - Вычислить все градиенты $\nabla f_i(\tilde{x})$; сохранить $\nabla f(\tilde{x}) = \frac{1}{n} \sum_{i=1}^n \nabla f_i(\tilde{x})$
 - Инициализировать $x_0 = \tilde{x}$
 - Для $t = 1$ до длина эпохи (m)
 - Выбрать $i_t \in \{1, \dots, n\}$ равномерно
 - $x_t = x_{t-1} - \alpha [\nabla f_{i_t}(x_{t-1}) - \nabla f_{i_t}(\tilde{x}) + \nabla f(\tilde{x})]$
 - Обновить $\tilde{x} = x_m$

SVRG (Stochastic Variance Reduced Gradient)

- Инициализация: $\tilde{x} \in \mathbb{R}^d$
- Для $i_{\text{epoch}} = 1$ до число эпох
 - Вычислить все градиенты $\nabla f_i(\tilde{x})$; сохранить $\nabla f(\tilde{x}) = \frac{1}{n} \sum_{i=1}^n \nabla f_i(\tilde{x})$
 - Инициализировать $x_0 = \tilde{x}$
 - Для $t = 1$ до длина эпохи (m)
 - Выбрать $i_t \in \{1, \dots, n\}$ равномерно
 - $x_t = x_{t-1} - \alpha [\nabla f_{i_t}(x_{t-1}) - \nabla f_{i_t}(\tilde{x}) + \nabla f(\tilde{x})]$
 - Обновить $\tilde{x} = x_m$

SVRG (Stochastic Variance Reduced Gradient)

- Инициализация: $\tilde{x} \in \mathbb{R}^d$
- Для $i_{\text{epoch}} = 1$ до число эпох
 - Вычислить все градиенты $\nabla f_i(\tilde{x})$; сохранить $\nabla f(\tilde{x}) = \frac{1}{n} \sum_{i=1}^n \nabla f_i(\tilde{x})$
 - Инициализировать $x_0 = \tilde{x}$
 - Для $t = 1$ до длина эпохи (m)
 - Выбрать $i_t \in \{1, \dots, n\}$ равномерно
 - $x_t = x_{t-1} - \alpha [\nabla f_{i_t}(x_{t-1}) - \nabla f_{i_t}(\tilde{x}) + \nabla f(\tilde{x})]$
 - Обновить $\tilde{x} = x_m$

Замечания:

- Два вычисления градиента на каждом внутреннем шаге.

SVRG (Stochastic Variance Reduced Gradient)

- Инициализация: $\tilde{x} \in \mathbb{R}^d$
- Для $i_{\text{epoch}} = 1$ до число эпох
 - Вычислить все градиенты $\nabla f_i(\tilde{x})$; сохранить $\nabla f(\tilde{x}) = \frac{1}{n} \sum_{i=1}^n \nabla f_i(\tilde{x})$
 - Инициализировать $x_0 = \tilde{x}$
 - Для $t = 1$ до длина эпохи (m)
 - Выбрать $i_t \in \{1, \dots, n\}$ равномерно
 - $x_t = x_{t-1} - \alpha [\nabla f_{i_t}(x_{t-1}) - \nabla f_{i_t}(\tilde{x}) + \nabla f(\tilde{x})]$
 - Обновить $\tilde{x} = x_m$

Замечания:

- Два вычисления градиента на каждом внутреннем шаге.
- Два параметра: длина эпохи + шаг α .

SVRG (Stochastic Variance Reduced Gradient)

- **Инициализация:** $\tilde{x} \in \mathbb{R}^d$
- **Для** $i_{\text{epoch}} = 1$ **до** число эпох
 - Вычислить все градиенты $\nabla f_i(\tilde{x})$; сохранить $\nabla f(\tilde{x}) = \frac{1}{n} \sum_{i=1}^n \nabla f_i(\tilde{x})$
 - Инициализировать $x_0 = \tilde{x}$
 - **Для** $t = 1$ **до** длина эпохи (m)
 - Выбрать $i_t \in \{1, \dots, n\}$ равномерно
 - $x_t = x_{t-1} - \alpha [\nabla f_{i_t}(x_{t-1}) - \nabla f_{i_t}(\tilde{x}) + \nabla f(\tilde{x})]$
 - Обновить $\tilde{x} = x_m$

Замечания:

- Два вычисления градиента на каждом внутреннем шаге.
- Два параметра: длина эпохи + шаг α .
- Линейная сходимость, простое доказательство.

SVRG (Stochastic Variance Reduced Gradient)

- **Инициализация:** $\tilde{x} \in \mathbb{R}^d$
- **Для** $i_{\text{epoch}} = 1$ **до** число эпох
 - Вычислить все градиенты $\nabla f_i(\tilde{x})$; сохранить $\nabla f(\tilde{x}) = \frac{1}{n} \sum_{i=1}^n \nabla f_i(\tilde{x})$
 - Инициализировать $x_0 = \tilde{x}$
 - **Для** $t = 1$ **до** длина эпохи (m)
 - Выбрать $i_t \in \{1, \dots, n\}$ равномерно
 - $x_t = x_{t-1} - \alpha [\nabla f_{i_t}(x_{t-1}) - \nabla f_{i_t}(\tilde{x}) + \nabla f(\tilde{x})]$
 - Обновить $\tilde{x} = x_m$

Замечания:

- Два вычисления градиента на каждом внутреннем шаге.
- Два параметра: длина эпохи + шаг α .
- Линейная сходимость, простое доказательство.
- Не требует хранения n градиентов (в отличие от SAG).

Численный эксперимент: SGD vs SVRG

Логистическая регрессия с ℓ_2 -регуляризацией. $m = 200, n = 10, \mu = 0.1$




Рис. 2: Слева: сходимость $f(x_k) - f^*$. Справа: дисперсия оценки градиента. SVRG уменьшает дисперсию на порядки по мере приближения к решению, в то время как дисперсия SGD остаётся постоянной.

Сравнение GD, SGD и SVRG

Strongly convex quadratics, $m=150$, $n=300$, $\mu=1$.




Рис. 3: Линейная регрессия с МНК

Strongly convex binary logistic regression, $m=200$, $n=10$, $\mu=0.1$.




Рис. 4: Логистическая регрессия

Сравнение GD, SGD и SVRG

Strongly convex quadratics, $m=150$, $n=300$, $\mu=1$.




Рис. 3: Линейная регрессия с МНК

Strongly convex binary logistic regression, $m=200$, $n=10$, $\mu=0.1$.





Рис. 4: Логистическая регрессия

Метод	Стоимость итерации	Сходимость (сильно вып.)	Память
GD	$O(n)$	линейная $(1 - \frac{\mu}{L})^k$	$O(p)$
SGD	$O(1)$	сублинейная $\frac{1}{k}$	$O(p)$
SAG	$O(1)$	линейная $(1 - \min(\frac{\mu}{16L}, \frac{1}{8n}))^k$	$O(np)$
SVRG	$O(1)$	линейная	$O(p)$


Ширина локальных минимумов

Узкие и широкие локальные минимумы




Ширина локальных минимумов

Узкие и широкие локальные минимумы




Ширина локальных минимумов

Узкие и широкие локальные минимумы




GD сходится к ближайшему минимуму

Градиентный спуск с маленьким шагом
сходится в узкий локальный минимум



SGD расходится вблизи минимума

Градиентный спуск с большим шагом избегает узкого локального минимума



- **SGD** — дешёвые итерации ($O(1)$ вместо $O(n)$), но медленная сублинейная сходимость $O(1/k)$ вместо линейной у GD

Итоги

- **SGD** — дешёвые итерации ($O(1)$ вместо $O(n)$), но медленная сублинейная сходимость $O(1/k)$ вместо линейной у GD
- **Постоянный шаг**: SGD не сходится к точному решению — остаётся «окрестность» размера $\frac{L\sigma^2\alpha}{4\mu}$

- **SGD** — дешёвые итерации ($O(1)$ вместо $O(n)$), но медленная сублинейная сходимость $O(1/k)$ вместо линейной у GD
- **Постоянный шаг**: SGD не сходится к точному решению — остаётся «окрестность» размера $\frac{L\sigma^2\alpha}{4\mu}$
- **Убывающий шаг**: сходимость к точному решению, но сублинейно

- **SGD** — дешёвые итерации ($O(1)$ вместо $O(n)$), но медленная сублинейная сходимость $O(1/k)$ вместо линейной у GD
- **Постоянный шаг**: SGD не сходится к точному решению — остаётся «окрестность» размера $\frac{L\sigma^2\alpha}{4\mu}$
- **Убывающий шаг**: сходимость к точному решению, но сублинейно
- **Методы редукции дисперсии** (SAG, SVRG) достигают **линейной** сходимости при стоимости итерации как у SGD

- **SGD** — дешёвые итерации ($O(1)$ вместо $O(n)$), но медленная сублинейная сходимость $O(1/k)$ вместо линейной у GD
- **Постоянный шаг**: SGD не сходится к точному решению — остаётся «окрестность» размера $\frac{L\sigma^2\alpha}{4\mu}$
- **Убывающий шаг**: сходимость к точному решению, но сублинейно
- **Методы редукции дисперсии** (SAG, SVRG) достигают **линейной** сходимости при стоимости итерации как у SGD
 - SAG: требует $O(np)$ памяти

- **SGD** — дешёвые итерации ($O(1)$ вместо $O(n)$), но медленная сублинейная сходимость $O(1/k)$ вместо линейной у GD
- **Постоянный шаг**: SGD не сходится к точному решению — остаётся «окрестность» размера $\frac{L\sigma^2\alpha}{4\mu}$
- **Убывающий шаг**: сходимость к точному решению, но сублинейно
- **Методы редукции дисперсии** (SAG, SVRG) достигают **линейной** сходимости при стоимости итерации как у SGD
 - SAG: требует $O(np)$ памяти
 - SVRG: требует только $O(p)$ памяти, но два вычисления градиента на шаг

- **SGD** — дешёвые итерации ($O(1)$ вместо $O(n)$), но медленная сублинейная сходимость $O(1/k)$ вместо линейной у GD
- **Постоянный шаг**: SGD не сходится к точному решению — остаётся «окрестность» размера $\frac{L\sigma^2\alpha}{4\mu}$
- **Убывающий шаг**: сходимость к точному решению, но сублинейно
- **Методы редукции дисперсии** (SAG, SVRG) достигают **линейной** сходимости при стоимости итерации как у SGD
 - SAG: требует $O(np)$ памяти
 - SVRG: требует только $O(p)$ памяти, но два вычисления градиента на шаг
- SGD помогает убежать из «узких» локальных минимумов → лучшая обобщающая способность в глубоком обучении

- **SGD** — дешёвые итерации ($O(1)$ вместо $O(n)$), но медленная сублинейная сходимость $O(1/k)$ вместо линейной у GD
- **Постоянный шаг**: SGD не сходится к точному решению — остаётся «окрестность» размера $\frac{L\sigma^2\alpha}{4\mu}$
- **Убывающий шаг**: сходимость к точному решению, но сублинейно
- **Методы редукции дисперсии** (SAG, SVRG) достигают **линейной** сходимости при стоимости итерации как у SGD
 - SAG: требует $O(np)$ памяти
 - SVRG: требует только $O(p)$ памяти, но два вычисления градиента на шаг
- SGD помогает убежать из «узких» локальных минимумов → лучшая обобщающая способность в глубоком обучении
- Моментные методы не улучшают скорость SGD (узкое место — дисперсия, не число обусловленности)