



**Введение в стохастические градиентные  
методы. SGD. SAG, SVRG.**

**Даниил Меркулов**

Методы оптимизации. МФТИ

## Задача минимизации конечной суммы

## Задача минимизации конечной суммы

Рассмотрим классическую задачу минимизации среднего по конечной выборке:

$$\min_{x \in \mathbb{R}^p} f(x) = \min_{x \in \mathbb{R}^p} \frac{1}{n} \sum_{i=1}^n f_i(x)$$

Градиентный спуск записывается следующим образом:

$$x_{k+1} = x_k - \frac{\alpha_k}{n} \sum_{i=1}^n \nabla f_i(x) \quad (\text{GD})$$

- Сходимость при постоянном  $\alpha$  или линейном поиске.

## Задача минимизации конечной суммы

Рассмотрим классическую задачу минимизации среднего по конечной выборке:

$$\min_{x \in \mathbb{R}^p} f(x) = \min_{x \in \mathbb{R}^p} \frac{1}{n} \sum_{i=1}^n f_i(x)$$

Градиентный спуск записывается следующим образом:

$$x_{k+1} = x_k - \frac{\alpha_k}{n} \sum_{i=1}^n \nabla f_i(x) \quad (\text{GD})$$

- Сходимость при постоянном  $\alpha$  или линейном поиске.
- Стоимость итерации линейна по  $n$ . Для ImageNet  $n \approx 1,4 \cdot 10^7$ , для WikiText  $n \approx 10^8$ . Для FineWeb  $n \approx 15 \cdot 10^{12}$  токенов.

## Задача минимизации конечной суммы

Рассмотрим классическую задачу минимизации среднего по конечной выборке:

$$\min_{x \in \mathbb{R}^p} f(x) = \min_{x \in \mathbb{R}^p} \frac{1}{n} \sum_{i=1}^n f_i(x)$$

Градиентный спуск записывается следующим образом:

$$x_{k+1} = x_k - \frac{\alpha_k}{n} \sum_{i=1}^n \nabla f_i(x) \quad (\text{GD})$$

- Сходимость при постоянном  $\alpha$  или линейном поиске.
- Стоимость итерации линейна по  $n$ . Для ImageNet  $n \approx 1,4 \cdot 10^7$ , для WikiText  $n \approx 10^8$ . Для FineWeb  $n \approx 15 \cdot 10^{12}$  токенов.

## Задача минимизации конечной суммы

Рассмотрим классическую задачу минимизации среднего по конечной выборке:

$$\min_{x \in \mathbb{R}^p} f(x) = \min_{x \in \mathbb{R}^p} \frac{1}{n} \sum_{i=1}^n f_i(x)$$

Градиентный спуск записывается следующим образом:

$$x_{k+1} = x_k - \frac{\alpha_k}{n} \sum_{i=1}^n \nabla f_i(x) \quad (\text{GD})$$

- Сходимость при постоянном  $\alpha$  или линейном поиске.
- Стоимость итерации линейна по  $n$ . Для ImageNet  $n \approx 1,4 \cdot 10^7$ , для WikiText  $n \approx 10^8$ . Для FineWeb  $n \approx 15 \cdot 10^{12}$  токенов.

Перейдём от полного вычисления градиента к его несмещённой оценке, случайно выбирая индекс  $i_k$  на каждой итерации равномерно:

$$x_{k+1} = x_k - \alpha_k \nabla f_{i_k}(x_k) \quad (\text{SGD})$$

При  $p(i_k = i) = \frac{1}{n}$  стохастический градиент является несмещённой оценкой градиента:

$$\mathbb{E}[\nabla f_{i_k}(x)] = \sum_{i=1}^n p(i_k = i) \nabla f_i(x) = \sum_{i=1}^n \frac{1}{n} \nabla f_i(x) = \frac{1}{n} \sum_{i=1}^n \nabla f_i(x) = \nabla f(x)$$

Это означает, что математическое ожидание стохастического градиента равно истинному градиенту  $\nabla f(x)$ .

## Результаты для градиентного спуска

Стохастические итерации в  $n$  раз быстрее, но сколько итераций нужно?

Если  $\nabla f$  липшицев, то имеем:

| Предположение | Детерминированный GD               | Стохастический GD |
|---------------|------------------------------------|-------------------|
| PL            | $\mathcal{O}(\log(1/\varepsilon))$ |                   |
| Выпуклый      | $\mathcal{O}(1/\varepsilon)$       |                   |
| Невыпуклый    | $\mathcal{O}(1/\varepsilon)$       |                   |

## Результаты для градиентного спуска

Стохастические итерации в  $n$  раз быстрее, но сколько итераций нужно?

Если  $\nabla f$  липшицев, то имеем:

| Предположение | Детерминированный GD               | Стохастический GD              |
|---------------|------------------------------------|--------------------------------|
| PL            | $\mathcal{O}(\log(1/\varepsilon))$ | $\mathcal{O}(1/\varepsilon)$   |
| Выпуклый      | $\mathcal{O}(1/\varepsilon)$       | $\mathcal{O}(1/\varepsilon^2)$ |
| Невыпуклый    | $\mathcal{O}(1/\varepsilon)$       | $\mathcal{O}(1/\varepsilon^2)$ |

- Стохастический метод имеет дешёвые итерации, но медленную сходимость.



## Результаты для градиентного спуска

Стохастические итерации в  $n$  раз быстрее, но сколько итераций нужно?

Если  $\nabla f$  липшицев, то имеем:

| Предположение | Детерминированный GD               | Стохастический GD              |
|---------------|------------------------------------|--------------------------------|
| PL            | $\mathcal{O}(\log(1/\varepsilon))$ | $\mathcal{O}(1/\varepsilon)$   |
| Выпуклый      | $\mathcal{O}(1/\varepsilon)$       | $\mathcal{O}(1/\varepsilon^2)$ |
| Невыпуклый    | $\mathcal{O}(1/\varepsilon)$       | $\mathcal{O}(1/\varepsilon^2)$ |

- Стохастический метод имеет дешёвые итерации, но медленную сходимость.
  - Сублинейная сходимость даже в сильно выпуклом случае.

## Результаты для градиентного спуска

Стохастические итерации в  $n$  раз быстрее, но сколько итераций нужно?

Если  $\nabla f$  липшицев, то имеем:

| Предположение | Детерминированный GD               | Стохастический GD              |
|---------------|------------------------------------|--------------------------------|
| PL            | $\mathcal{O}(\log(1/\varepsilon))$ | $\mathcal{O}(1/\varepsilon)$   |
| Выпуклый      | $\mathcal{O}(1/\varepsilon)$       | $\mathcal{O}(1/\varepsilon^2)$ |
| Невыпуклый    | $\mathcal{O}(1/\varepsilon)$       | $\mathcal{O}(1/\varepsilon^2)$ |

- Стохастический метод имеет дешёвые итерации, но медленную сходимость.
  - Сублинейная сходимость даже в сильно выпуклом случае.
  - Оценки неулучшаемы при стандартных предположениях.

## Результаты для градиентного спуска

Стохастические итерации в  $n$  раз быстрее, но сколько итераций нужно?

Если  $\nabla f$  липшицев, то имеем:

| Предположение | Детерминированный GD               | Стохастический GD              |
|---------------|------------------------------------|--------------------------------|
| PL            | $\mathcal{O}(\log(1/\varepsilon))$ | $\mathcal{O}(1/\varepsilon)$   |
| Выпуклый      | $\mathcal{O}(1/\varepsilon)$       | $\mathcal{O}(1/\varepsilon^2)$ |
| Невыпуклый    | $\mathcal{O}(1/\varepsilon)$       | $\mathcal{O}(1/\varepsilon^2)$ |

- Стохастический метод имеет дешёвые итерации, но медленную сходимость.
  - Сублинейная сходимость даже в сильно выпуклом случае.
  - Оценки неулучшаемы при стандартных предположениях.
  - Оракул возвращает несмещённую аппроксимацию градиента с ограниченной дисперсией.

## Результаты для градиентного спуска

Стохастические итерации в  $n$  раз быстрее, но сколько итераций нужно?

Если  $\nabla f$  липшицев, то имеем:



| Предположение | Детерминированный GD               | Стохастический GD              |
|---------------|------------------------------------|--------------------------------|
| PL            | $\mathcal{O}(\log(1/\varepsilon))$ | $\mathcal{O}(1/\varepsilon)$   |
| Выпуклый      | $\mathcal{O}(1/\varepsilon)$       | $\mathcal{O}(1/\varepsilon^2)$ |
| Невыпуклый    | $\mathcal{O}(1/\varepsilon)$       | $\mathcal{O}(1/\varepsilon^2)$ |

- Стохастический метод имеет дешёвые итерации, но медленную сходимость.
  - Сублинейная сходимость даже в сильно выпуклом случае.
  - Оценки неулучшаемы при стандартных предположениях.
  - Оракул возвращает несмещённую аппроксимацию градиента с ограниченной дисперсией.
- Моментные и квазиньютоновские методы **не улучшают** скорость в стохастическом случае. Могут улучшить только константы (узкое место — дисперсия, а не число обусловленности).

## Стохастический градиентный спуск (SGD)

# Типичное поведение

Stochastic Gradient Descent. Batch = 2



## Сходимость

Из липшицевости градиента следует:

$$f(x_{k+1}) \leq f(x_k) + \langle \nabla f(x_k), x_{k+1} - x_k \rangle + \frac{L}{2} \|x_{k+1} - x_k\|^2$$

## Сходимость

Из липшицевости градиента следует:

$$f(x_{k+1}) \leq f(x_k) + \langle \nabla f(x_k), x_{k+1} - x_k \rangle + \frac{L}{2} \|x_{k+1} - x_k\|^2$$

Используя (SGD):

$$f(x_{k+1}) \leq f(x_k) - \alpha_k \langle \nabla f(x_k), \nabla f_{i_k}(x_k) \rangle + \alpha_k^2 \frac{L}{2} \|\nabla f_{i_k}(x_k)\|^2$$



## Сходимость

Из липшицевости градиента следует:

$$f(x_{k+1}) \leq f(x_k) + \langle \nabla f(x_k), x_{k+1} - x_k \rangle + \frac{L}{2} \|x_{k+1} - x_k\|^2$$

Используя (SGD):

$$f(x_{k+1}) \leq f(x_k) - \alpha_k \langle \nabla f(x_k), \nabla f_{i_k}(x_k) \rangle + \alpha_k^2 \frac{L}{2} \|\nabla f_{i_k}(x_k)\|^2$$

Возьмём математическое ожидание по  $i_k$ :

$$\mathbb{E}[f(x_{k+1})] \leq \mathbb{E}[f(x_k) - \alpha_k \langle \nabla f(x_k), \nabla f_{i_k}(x_k) \rangle + \alpha_k^2 \frac{L}{2} \|\nabla f_{i_k}(x_k)\|^2]$$

## Сходимость

Из липшицевости градиента следует:

$$f(x_{k+1}) \leq f(x_k) + \langle \nabla f(x_k), x_{k+1} - x_k \rangle + \frac{L}{2} \|x_{k+1} - x_k\|^2$$

Используя (SGD):

$$f(x_{k+1}) \leq f(x_k) - \alpha_k \langle \nabla f(x_k), \nabla f_{i_k}(x_k) \rangle + \alpha_k^2 \frac{L}{2} \|\nabla f_{i_k}(x_k)\|^2$$

Возьмём математическое ожидание по  $i_k$ :

$$\mathbb{E}[f(x_{k+1})] \leq \mathbb{E}[f(x_k) - \alpha_k \langle \nabla f(x_k), \nabla f_{i_k}(x_k) \rangle + \alpha_k^2 \frac{L}{2} \|\nabla f_{i_k}(x_k)\|^2]$$

По линейности мат. ожидания:

$$\mathbb{E}[f(x_{k+1})] \leq f(x_k) - \alpha_k \langle \nabla f(x_k), \mathbb{E}[\nabla f_{i_k}(x_k)] \rangle + \alpha_k^2 \frac{L}{2} \mathbb{E}[\|\nabla f_{i_k}(x_k)\|^2]$$

## Сходимость

Из липшицевости градиента следует:

$$f(x_{k+1}) \leq f(x_k) + \langle \nabla f(x_k), x_{k+1} - x_k \rangle + \frac{L}{2} \|x_{k+1} - x_k\|^2$$

Используя (SGD):

$$f(x_{k+1}) \leq f(x_k) - \alpha_k \langle \nabla f(x_k), \nabla f_{i_k}(x_k) \rangle + \alpha_k^2 \frac{L}{2} \|\nabla f_{i_k}(x_k)\|^2$$

Возьмём математическое ожидание по  $i_k$ :

$$\mathbb{E}[f(x_{k+1})] \leq \mathbb{E}[f(x_k) - \alpha_k \langle \nabla f(x_k), \nabla f_{i_k}(x_k) \rangle + \alpha_k^2 \frac{L}{2} \|\nabla f_{i_k}(x_k)\|^2]$$

По линейности мат. ожидания:

$$\mathbb{E}[f(x_{k+1})] \leq f(x_k) - \alpha_k \langle \nabla f(x_k), \mathbb{E}[\nabla f_{i_k}(x_k)] \rangle + \alpha_k^2 \frac{L}{2} \mathbb{E}[\|\nabla f_{i_k}(x_k)\|^2]$$

Поскольку равномерная выборка даёт несмещённую оценку:  $\mathbb{E}[\nabla f_{i_k}(x_k)] = \nabla f(x_k)$ :

$$\mathbb{E}[f(x_{k+1})] \leq f(x_k) - \alpha_k \|\nabla f(x_k)\|^2 + \alpha_k^2 \frac{L}{2} \mathbb{E}[\|\nabla f_{i_k}(x_k)\|^2] \quad (1)$$

## Гладкий PL-случай. Постоянный шаг

- i** Пусть  $f$  —  $L$ -гладкая функция, удовлетворяющая условию Поляка-Лоясиевича (PL) с константой  $\mu > 0$ , а дисперсия стохастического градиента ограничена:  $\mathbb{E}[\|\nabla f_i(x_k)\|^2] \leq \sigma^2$ . Тогда SGD с постоянным шагом  $\alpha < \frac{1}{2\mu}$  гарантирует

$$\mathbb{E}[f(x_k) - f^*] \leq (1 - 2\alpha\mu)^k [f(x_0) - f^*] + \frac{L\sigma^2\alpha}{4\mu}.$$

Начнём с неравенства (1):

$$\mathbb{E}[f(x_{k+1})] \leq f(x_k) - \alpha_k \|\nabla f(x_k)\|^2 + \alpha_k^2 \frac{L}{2} \mathbb{E}[\|\nabla f_{i_k}(x_k)\|^2]$$

## Гладкий PL-случай. Постоянный шаг

- i** Пусть  $f$  —  $L$ -гладкая функция, удовлетворяющая условию Поляка-Лоясиевича (PL) с константой  $\mu > 0$ , а дисперсия стохастического градиента ограничена:  $\mathbb{E}[\|\nabla f_i(x_k)\|^2] \leq \sigma^2$ . Тогда SGD с постоянным шагом  $\alpha < \frac{1}{2\mu}$  гарантирует

$$\mathbb{E}[f(x_k) - f^*] \leq (1 - 2\alpha\mu)^k [f(x_0) - f^*] + \frac{L\sigma^2\alpha}{4\mu}.$$

Начнём с неравенства (1):

$$\mathbb{E}[f(x_{k+1})] \leq f(x_k) - \alpha_k \|\nabla f(x_k)\|^2 + \alpha_k^2 \frac{L}{2} \mathbb{E}[\|\nabla f_{i_k}(x_k)\|^2]$$

$$\text{PL: } \|\nabla f(x_k)\|^2 \geq 2\mu(f(x_k) - f^*)$$

## Гладкий PL-случай. Постоянный шаг

- i** Пусть  $f$  —  $L$ -гладкая функция, удовлетворяющая условию Поляка-Лоясиевича (PL) с константой  $\mu > 0$ , а дисперсия стохастического градиента ограничена:  $\mathbb{E}[\|\nabla f_i(x_k)\|^2] \leq \sigma^2$ . Тогда SGD с постоянным шагом  $\alpha < \frac{1}{2\mu}$  гарантирует

$$\mathbb{E}[f(x_k) - f^*] \leq (1 - 2\alpha\mu)^k [f(x_0) - f^*] + \frac{L\sigma^2\alpha}{4\mu}.$$

Начнём с неравенства (1):

$$\begin{aligned}\mathbb{E}[f(x_{k+1})] &\leq f(x_k) - \alpha_k \|\nabla f(x_k)\|^2 + \alpha_k^2 \frac{L}{2} \mathbb{E}[\|\nabla f_{i_k}(x_k)\|^2] \\ \text{PL: } \|\nabla f(x_k)\|^2 &\geq 2\mu(f(x_k) - f^*) \quad \leq f(x_k) - 2\alpha_k\mu(f(x_k) - f^*) + \alpha_k^2 \frac{L}{2} \mathbb{E}[\|\nabla f_{i_k}(x_k)\|^2]\end{aligned}$$

## Гладкий PL-случай. Постоянный шаг

- i** Пусть  $f$  —  $L$ -гладкая функция, удовлетворяющая условию Поляка-Лоясиевича (PL) с константой  $\mu > 0$ , а дисперсия стохастического градиента ограничена:  $\mathbb{E}[\|\nabla f_i(x_k)\|^2] \leq \sigma^2$ . Тогда SGD с постоянным шагом  $\alpha < \frac{1}{2\mu}$  гарантирует

$$\mathbb{E}[f(x_k) - f^*] \leq (1 - 2\alpha\mu)^k [f(x_0) - f^*] + \frac{L\sigma^2\alpha}{4\mu}.$$

Начнём с неравенства (1):

$$\begin{aligned}\mathbb{E}[f(x_{k+1})] &\leq f(x_k) - \alpha_k \|\nabla f(x_k)\|^2 + \alpha_k^2 \frac{L}{2} \mathbb{E}[\|\nabla f_{i_k}(x_k)\|^2] \\ \text{PL: } \|\nabla f(x_k)\|^2 &\geq 2\mu(f(x_k) - f^*) \quad \leq f(x_k) - 2\alpha_k\mu(f(x_k) - f^*) + \alpha_k^2 \frac{L}{2} \mathbb{E}[\|\nabla f_{i_k}(x_k)\|^2]\end{aligned}$$

Вычитаем  $f^*$

## Гладкий PL-случай. Постоянный шаг

**i** Пусть  $f$  —  $L$ -гладкая функция, удовлетворяющая условию Поляка-Лоясиевича (PL) с константой  $\mu > 0$ , а дисперсия стохастического градиента ограничена:  $\mathbb{E}[\|\nabla f_i(x_k)\|^2] \leq \sigma^2$ . Тогда SGD с постоянным шагом  $\alpha < \frac{1}{2\mu}$  гарантирует

$$\mathbb{E}[f(x_k) - f^*] \leq (1 - 2\alpha\mu)^k [f(x_0) - f^*] + \frac{L\sigma^2\alpha}{4\mu}.$$

Начнём с неравенства (1):

$$\mathbb{E}[f(x_{k+1})] \leq f(x_k) - \alpha_k \|\nabla f(x_k)\|^2 + \alpha_k^2 \frac{L}{2} \mathbb{E}[\|\nabla f_{i_k}(x_k)\|^2]$$

$$\text{PL: } \|\nabla f(x_k)\|^2 \geq 2\mu(f(x_k) - f^*) \quad \leq f(x_k) - 2\alpha_k\mu(f(x_k) - f^*) + \alpha_k^2 \frac{L}{2} \mathbb{E}[\|\nabla f_{i_k}(x_k)\|^2]$$

$$\text{Вычитаем } f^* \quad \mathbb{E}[f(x_{k+1})] - f^* \leq (1 - 2\alpha_k\mu)[f(x_k) - f^*] + \alpha_k^2 \frac{L}{2} \mathbb{E}[\|\nabla f_{i_k}(x_k)\|^2]$$



## Гладкий PL-случай. Постоянный шаг

**i** Пусть  $f$  —  $L$ -гладкая функция, удовлетворяющая условию Поляка-Лоясиевича (PL) с константой  $\mu > 0$ , а дисперсия стохастического градиента ограничена:  $\mathbb{E}[\|\nabla f_i(x_k)\|^2] \leq \sigma^2$ . Тогда SGD с постоянным шагом  $\alpha < \frac{1}{2\mu}$  гарантирует

$$\mathbb{E}[f(x_k) - f^*] \leq (1 - 2\alpha\mu)^k [f(x_0) - f^*] + \frac{L\sigma^2\alpha}{4\mu}.$$

Начнём с неравенства (1):

$$\mathbb{E}[f(x_{k+1})] \leq f(x_k) - \alpha_k \|\nabla f(x_k)\|^2 + \alpha_k^2 \frac{L}{2} \mathbb{E}[\|\nabla f_{i_k}(x_k)\|^2]$$

$$\text{PL: } \|\nabla f(x_k)\|^2 \geq 2\mu(f(x_k) - f^*) \quad \leq f(x_k) - 2\alpha_k\mu(f(x_k) - f^*) + \alpha_k^2 \frac{L}{2} \mathbb{E}[\|\nabla f_{i_k}(x_k)\|^2]$$

$$\text{Вычитаем } f^* \quad \mathbb{E}[f(x_{k+1})] - f^* \leq (1 - 2\alpha_k\mu)[f(x_k) - f^*] + \alpha_k^2 \frac{L}{2} \mathbb{E}[\|\nabla f_{i_k}(x_k)\|^2]$$

$$\text{Огр. дисперсия: } \mathbb{E}[\|\nabla f_i(x_k)\|^2] \leq \sigma^2$$

## Гладкий PL-случай. Постоянный шаг

**i** Пусть  $f$  —  $L$ -гладкая функция, удовлетворяющая условию Поляка-Лоясиевича (PL) с константой  $\mu > 0$ , а дисперсия стохастического градиента ограничена:  $\mathbb{E}[\|\nabla f_i(x_k)\|^2] \leq \sigma^2$ . Тогда SGD с постоянным шагом  $\alpha < \frac{1}{2\mu}$  гарантирует

$$\mathbb{E}[f(x_k) - f^*] \leq (1 - 2\alpha\mu)^k [f(x_0) - f^*] + \frac{L\sigma^2\alpha}{4\mu}.$$

Начнём с неравенства (1):

$$\mathbb{E}[f(x_{k+1})] \leq f(x_k) - \alpha_k \|\nabla f(x_k)\|^2 + \alpha_k^2 \frac{L}{2} \mathbb{E}[\|\nabla f_{i_k}(x_k)\|^2]$$

$$\text{PL: } \|\nabla f(x_k)\|^2 \geq 2\mu(f(x_k) - f^*) \quad \leq f(x_k) - 2\alpha_k\mu(f(x_k) - f^*) + \alpha_k^2 \frac{L}{2} \mathbb{E}[\|\nabla f_{i_k}(x_k)\|^2]$$

$$\text{Вычитаем } f^* \quad \mathbb{E}[f(x_{k+1})] - f^* \leq (1 - 2\alpha_k\mu)[f(x_k) - f^*] + \alpha_k^2 \frac{L}{2} \mathbb{E}[\|\nabla f_{i_k}(x_k)\|^2]$$

$$\text{Огр. дисперсия: } \mathbb{E}[\|\nabla f_i(x_k)\|^2] \leq \sigma^2 \quad \leq (1 - 2\alpha_k\mu)[f(x_k) - f^*] + \frac{L\sigma^2\alpha_k^2}{2}.$$

## Гладкий PL-случай. Убывающий шаг

- i** Пусть  $f$  —  $L$ -гладкая функция, удовлетворяющая PL с константой  $\mu > 0$ , а дисперсия стохастического градиента ограничена:  $\mathbb{E}[\|\nabla f_i(x_k)\|^2] \leq \sigma^2$ . Тогда SGD с убывающим шагом  $\alpha_k = \frac{2k+1}{2\mu(k+1)^2}$  гарантирует

$$\mathbb{E}[f(x_k) - f^*] \leq \frac{L\sigma^2}{2\mu^2 k}$$

1. Рассмотрим **стратегию убывающего шага**  $\alpha_k = \frac{2k+1}{2\mu(k+1)^2}$ :

## Гладкий PL-случай. Убывающий шаг

- i** Пусть  $f$  —  $L$ -гладкая функция, удовлетворяющая PL с константой  $\mu > 0$ , а дисперсия стохастического градиента ограничена:  $\mathbb{E}[\|\nabla f_i(x_k)\|^2] \leq \sigma^2$ . Тогда SGD с убывающим шагом  $\alpha_k = \frac{2k+1}{2\mu(k+1)^2}$  гарантирует

$$\mathbb{E}[f(x_k) - f^*] \leq \frac{L\sigma^2}{2\mu^2 k}$$

1. Рассмотрим **стратегию убывающего шага**  $\alpha_k = \frac{2k+1}{2\mu(k+1)^2}$ :

$$1 - 2\alpha_k \mu = \frac{k^2}{(k+1)^2}$$

## Гладкий PL-случай. Убывающий шаг

**i** Пусть  $f$  —  $L$ -гладкая функция, удовлетворяющая PL с константой  $\mu > 0$ , а дисперсия стохастического градиента ограничена:  $\mathbb{E}[\|\nabla f_i(x_k)\|^2] \leq \sigma^2$ . Тогда SGD с убывающим шагом  $\alpha_k = \frac{2k+1}{2\mu(k+1)^2}$  гарантирует

$$\mathbb{E}[f(x_k) - f^*] \leq \frac{L\sigma^2}{2\mu^2 k}$$

1. Рассмотрим **стратегию убывающего шага**  $\alpha_k = \frac{2k+1}{2\mu(k+1)^2}$ :

$$1 - 2\alpha_k \mu = \frac{k^2}{(k+1)^2} \quad \mathbb{E}[f(x_{k+1}) - f^*] \leq \frac{k^2}{(k+1)^2} [f(x_k) - f^*] + \frac{L\sigma^2(2k+1)^2}{8\mu^2(k+1)^4}$$

## Гладкий PL-случай. Убывающий шаг

**i** Пусть  $f$  —  $L$ -гладкая функция, удовлетворяющая PL с константой  $\mu > 0$ , а дисперсия стохастического градиента ограничена:  $\mathbb{E}[\|\nabla f_i(x_k)\|^2] \leq \sigma^2$ . Тогда SGD с убывающим шагом  $\alpha_k = \frac{2k+1}{2\mu(k+1)^2}$  гарантирует

$$\mathbb{E}[f(x_k) - f^*] \leq \frac{L\sigma^2}{2\mu^2 k}$$

1. Рассмотрим стратегию убывающего шага  $\alpha_k = \frac{2k+1}{2\mu(k+1)^2}$ :

$$\begin{aligned} 1 - 2\alpha_k \mu &= \frac{k^2}{(k+1)^2} & \mathbb{E}[f(x_{k+1}) - f^*] &\leq \frac{k^2}{(k+1)^2} [f(x_k) - f^*] + \frac{L\sigma^2(2k+1)^2}{8\mu^2(k+1)^4} \\ (2k+1)^2 &< (2k+2)^2 = 4(k+1)^2 & &\leq \frac{k^2}{(k+1)^2} [f(x_k) - f^*] + \frac{L\sigma^2}{2\mu^2(k+1)^2} \end{aligned}$$

## Гладкий PL-случай. Убывающий шаг

**i** Пусть  $f$  —  $L$ -гладкая функция, удовлетворяющая PL с константой  $\mu > 0$ , а дисперсия стохастического градиента ограничена:  $\mathbb{E}[\|\nabla f_i(x_k)\|^2] \leq \sigma^2$ . Тогда SGD с убывающим шагом  $\alpha_k = \frac{2k+1}{2\mu(k+1)^2}$  гарантирует

$$\mathbb{E}[f(x_k) - f^*] \leq \frac{L\sigma^2}{2\mu^2 k}$$

1. Рассмотрим стратегию убывающего шага  $\alpha_k = \frac{2k+1}{2\mu(k+1)^2}$ :

$$\begin{aligned} 1 - 2\alpha_k \mu &= \frac{k^2}{(k+1)^2} & \mathbb{E}[f(x_{k+1}) - f^*] &\leq \frac{k^2}{(k+1)^2} [f(x_k) - f^*] + \frac{L\sigma^2(2k+1)^2}{8\mu^2(k+1)^4} \\ (2k+1)^2 &< (2k+2)^2 = 4(k+1)^2 & &\leq \frac{k^2}{(k+1)^2} [f(x_k) - f^*] + \frac{L\sigma^2}{2\mu^2(k+1)^2} \end{aligned}$$

2. Домножая обе части на  $(k+1)^2$  и обозначая  $\delta_f(k) \equiv k^2 \mathbb{E}[f(x_k) - f^*]$ :

$$\delta_f(k+1) \leq \delta_f(k) + \frac{L\sigma^2}{2\mu^2}.$$

## Гладкий PL-случай. Убывающий шаг

3. Суммируя предыдущее неравенство от  $i = 0$  до  $k$  и используя  $\delta_f(0) = 0$ :

что даёт заявленную скорость.



## Гладкий PL-случай. Убывающий шаг

3. Суммируя предыдущее неравенство от  $i = 0$  до  $k$  и используя  $\delta_f(0) = 0$ :

$$\delta_f(k+1) \leq \frac{L\sigma^2(k+1)}{2\mu^2}$$

что даёт заявленную скорость.

## Гладкий PL-случай. Убывающий шаг

3. Суммируя предыдущее неравенство от  $i = 0$  до  $k$  и используя  $\delta_f(0) = 0$ :

$$\begin{aligned}\delta_f(k+1) &\leq \frac{L\sigma^2(k+1)}{2\mu^2} \\ (k+1)^2 \mathbb{E}[f(x_{k+1}) - f^*] &\leq \frac{L\sigma^2(k+1)}{2\mu^2}\end{aligned}$$

что даёт заявленную скорость.

## Гладкий PL-случай. Убывающий шаг

3. Суммируя предыдущее неравенство от  $i = 0$  до  $k$  и используя  $\delta_f(0) = 0$ :

$$\begin{aligned}\delta_f(k+1) &\leq \frac{L\sigma^2(k+1)}{2\mu^2} \\ (k+1)^2 \mathbb{E}[f(x_{k+1}) - f^*] &\leq \frac{L\sigma^2(k+1)}{2\mu^2} \\ \mathbb{E}[f(x_k) - f^*] &\leq \frac{L\sigma^2}{2\mu^2 k}\end{aligned}$$

что даёт заявленную скорость.

## Гладкий выпуклый случай. Постоянный шаг

**i** Пусть  $f$  — выпуклая функция, а дисперсия стохастического градиента ограничена  $\mathbb{E}[\|\nabla f_{i_k}(x_k)\|^2] \leq \sigma^2 \quad \forall k$ . Если SGD использует постоянный шаг  $\alpha_t \equiv \alpha > 0$ , то для любого  $k \geq 1$

$$\mathbb{E}[f(\bar{x}_k) - f^*] \leq \frac{\|x_0 - x^*\|^2}{2\alpha k} + \frac{\alpha \sigma^2}{2}$$

где  $\bar{x}_k = \frac{1}{k} \sum_{t=0}^{k-1} x_t$ .

При выборе  $\alpha = \frac{\|x_0 - x^*\|}{\sigma \sqrt{k}}$  имеем

$$\mathbb{E}[f(\bar{x}_k) - f^*] \leq \frac{\|x_0 - x^*\| \sigma}{\sqrt{k}} = \mathcal{O}\left(\frac{1}{\sqrt{k}}\right).$$

## Гладкий выпуклый случай. Постоянный шаг

1. Начнём с разложения квадрата расстояния до минимума:

$$\|x_{k+1} - x^*\|^2 = \|x_k - \alpha \nabla f_{i_k}(x_k) - x^*\|^2 = \|x_k - x^*\|^2 - 2\alpha \langle \nabla f_{i_k}(x_k), x_k - x^* \rangle + \alpha^2 \|\nabla f_{i_k}(x_k)\|^2.$$

## Гладкий выпуклый случай. Постоянный шаг

1. Начнём с разложения квадрата расстояния до минимума:

$$\|x_{k+1} - x^*\|^2 = \|x_k - \alpha \nabla f_{i_k}(x_k) - x^*\|^2 = \|x_k - x^*\|^2 - 2\alpha \langle \nabla f_{i_k}(x_k), x_k - x^* \rangle + \alpha^2 \|\nabla f_{i_k}(x_k)\|^2.$$

2. Берём условное матожидание по  $i_k$  (обозначим  $\mathbb{E}_k[\cdot] = \mathbb{E}[\cdot | x_k]$ ), используем свойство  $\mathbb{E}_k[\nabla f_{i_k}(x_k)] = \nabla f(x_k)$ , ограниченность дисперсии  $\mathbb{E}_k[\|\nabla f_{i_k}(x_k)\|^2] \leq \sigma^2$  и выпуклость  $f$  (которая даёт  $\langle \nabla f(x_k), x_k - x^* \rangle \geq f(x_k) - f^*$ ):

$$\begin{aligned} \mathbb{E}_k[\|x_{k+1} - x^*\|^2] &= \|x_k - x^*\|^2 - 2\alpha \langle \nabla f(x_k), x_k - x^* \rangle + \alpha^2 \mathbb{E}_k[\|\nabla f_{i_k}(x_k)\|^2] \\ &\leq \|x_k - x^*\|^2 - 2\alpha(f(x_k) - f^*) + \alpha^2 \sigma^2. \end{aligned}$$

## Гладкий выпуклый случай. Постоянный шаг

1. Начнём с разложения квадрата расстояния до минимума:

$$\|x_{k+1} - x^*\|^2 = \|x_k - \alpha \nabla f_{i_k}(x_k) - x^*\|^2 = \|x_k - x^*\|^2 - 2\alpha \langle \nabla f_{i_k}(x_k), x_k - x^* \rangle + \alpha^2 \|\nabla f_{i_k}(x_k)\|^2.$$

2. Берём условное матожидание по  $i_k$  (обозначим  $\mathbb{E}_k[\cdot] = \mathbb{E}[\cdot | x_k]$ ), используем свойство  $\mathbb{E}_k[\nabla f_{i_k}(x_k)] = \nabla f(x_k)$ , ограниченность дисперсии  $\mathbb{E}_k[\|\nabla f_{i_k}(x_k)\|^2] \leq \sigma^2$  и выпуклость  $f$  (которая даёт  $\langle \nabla f(x_k), x_k - x^* \rangle \geq f(x_k) - f^*$ ):

$$\begin{aligned} \mathbb{E}_k[\|x_{k+1} - x^*\|^2] &= \|x_k - x^*\|^2 - 2\alpha \langle \nabla f(x_k), x_k - x^* \rangle + \alpha^2 \mathbb{E}_k[\|\nabla f_{i_k}(x_k)\|^2] \\ &\leq \|x_k - x^*\|^2 - 2\alpha(f(x_k) - f^*) + \alpha^2 \sigma^2. \end{aligned}$$

3. Переносим член с  $f(x_k)$  влево и берём полное матожидание:

$$2\alpha \mathbb{E}[f(x_k) - f^*] \leq \mathbb{E}[\|x_k - x^*\|^2] - \mathbb{E}[\|x_{k+1} - x^*\|^2] + \alpha^2 \sigma^2.$$

## Гладкий выпуклый случай. Постоянный шаг

1. Начнём с разложения квадрата расстояния до минимума:

$$\|x_{k+1} - x^*\|^2 = \|x_k - \alpha \nabla f_{i_k}(x_k) - x^*\|^2 = \|x_k - x^*\|^2 - 2\alpha \langle \nabla f_{i_k}(x_k), x_k - x^* \rangle + \alpha^2 \|\nabla f_{i_k}(x_k)\|^2.$$

2. Берём условное матожидание по  $i_k$  (обозначим  $\mathbb{E}_k[\cdot] = \mathbb{E}[\cdot | x_k]$ ), используем свойство  $\mathbb{E}_k[\nabla f_{i_k}(x_k)] = \nabla f(x_k)$ , ограниченность дисперсии  $\mathbb{E}_k[\|\nabla f_{i_k}(x_k)\|^2] \leq \sigma^2$  и выпуклость  $f$  (которая даёт  $\langle \nabla f(x_k), x_k - x^* \rangle \geq f(x_k) - f^*$ ):

$$\begin{aligned} \mathbb{E}_k[\|x_{k+1} - x^*\|^2] &= \|x_k - x^*\|^2 - 2\alpha \langle \nabla f(x_k), x_k - x^* \rangle + \alpha^2 \mathbb{E}_k[\|\nabla f_{i_k}(x_k)\|^2] \\ &\leq \|x_k - x^*\|^2 - 2\alpha (f(x_k) - f^*) + \alpha^2 \sigma^2. \end{aligned}$$

3. Переносим член с  $f(x_k)$  влево и берём полное матожидание:

$$2\alpha \mathbb{E}[f(x_k) - f^*] \leq \mathbb{E}[\|x_k - x^*\|^2] - \mathbb{E}[\|x_{k+1} - x^*\|^2] + \alpha^2 \sigma^2.$$

4. Суммируем (телескопируем) по  $t = 0, \dots, k-1$ :

$$\begin{aligned} \sum_{t=0}^{k-1} 2\alpha \mathbb{E}[f(x_t) - f^*] &\leq \sum_{t=0}^{k-1} (\mathbb{E}[\|x_t - x^*\|^2] - \mathbb{E}[\|x_{t+1} - x^*\|^2]) + \sum_{t=0}^{k-1} \alpha^2 \sigma^2 \\ &= \mathbb{E}[\|x_0 - x^*\|^2] - \mathbb{E}[\|x_k - x^*\|^2] + k \alpha^2 \sigma^2 \\ &\leq \|x_0 - x^*\|^2 + k \alpha^2 \sigma^2. \end{aligned}$$



## Гладкий выпуклый случай. Постоянный шаг

5. Делим на  $2\alpha k$ :

$$\frac{1}{k} \sum_{t=0}^{k-1} \mathbb{E}[f(x_t) - f^*] \leq \frac{\|x_0 - x^*\|^2}{2\alpha k} + \frac{\alpha\sigma^2}{2}.$$

## Гладкий выпуклый случай. Постоянный шаг

5. Делим на  $2\alpha k$ :

$$\frac{1}{k} \sum_{t=0}^{k-1} \mathbb{E}[f(x_t) - f^*] \leq \frac{\|x_0 - x^*\|^2}{2\alpha k} + \frac{\alpha\sigma^2}{2}.$$

6. Используя выпуклость  $f$  и неравенство Йенсена для усреднённой точки  $\bar{x}_k = \frac{1}{k} \sum_{t=0}^{k-1} x_t$ :

$$\mathbb{E}[f(\bar{x}_k)] \leq \mathbb{E} \left[ \frac{1}{k} \sum_{t=0}^{k-1} f(x_t) \right] = \frac{1}{k} \sum_{t=0}^{k-1} \mathbb{E}[f(x_t)].$$

Вычитая  $f^*$  из обеих частей, получаем:

$$\mathbb{E}[f(\bar{x}_k) - f^*] \leq \frac{1}{k} \sum_{t=0}^{k-1} \mathbb{E}[f(x_t) - f^*].$$

## Гладкий выпуклый случай. Постоянный шаг

5. Делим на  $2\alpha k$ :

$$\frac{1}{k} \sum_{t=0}^{k-1} \mathbb{E}[f(x_t) - f^*] \leq \frac{\|x_0 - x^*\|^2}{2\alpha k} + \frac{\alpha \sigma^2}{2}.$$

6. Используя выпуклость  $f$  и неравенство Йенсена для усреднённой точки  $\bar{x}_k = \frac{1}{k} \sum_{t=0}^{k-1} x_t$ :

$$\mathbb{E}[f(\bar{x}_k)] \leq \mathbb{E} \left[ \frac{1}{k} \sum_{t=0}^{k-1} f(x_t) \right] = \frac{1}{k} \sum_{t=0}^{k-1} \mathbb{E}[f(x_t)].$$

Вычитая  $f^*$  из обеих частей, получаем:

$$\mathbb{E}[f(\bar{x}_k) - f^*] \leq \frac{1}{k} \sum_{t=0}^{k-1} \mathbb{E}[f(x_t) - f^*].$$

7. Объединяя (5) и (6), получаем искомую оценку:

$$\mathbb{E}[f(\bar{x}_k) - f^*] \leq \frac{\|x_0 - x^*\|^2}{2\alpha k} + \frac{\alpha \sigma^2}{2}.$$

## Гладкий выпуклый случай. Убывающий шаг

$$\alpha_k = \frac{\alpha_0}{\sqrt{k+1}}, \quad 0 < \alpha_0 \leq \frac{1}{4L}$$

**i** При тех же предположениях, но со спадом шага  $\alpha_k = \frac{\alpha_0}{\sqrt{k+1}}$

$$\mathbb{E}[f(\bar{x}_k) - f^*] \leq \frac{5\|x_0 - x^*\|^2}{4\alpha_0\sqrt{k}} + 5\alpha_0\sigma^2 \frac{\log(k+1)}{\sqrt{k}} = \mathcal{O}\left(\frac{\log k}{\sqrt{k}}\right).$$

## Мини-батч SGD

# Мини-батч SGD

Подход: контроль размера выборки

Детерминированный метод использует все  $n$  градиентов:

$$\nabla f(x_k) = \frac{1}{n} \sum_{i=1}^n \nabla f_i(x_k).$$

Стохастический метод аппроксимирует это одним семплом:

$$\nabla f_{i_k}(x_k) \approx \frac{1}{n} \sum_{i=1}^n \nabla f_i(x_k).$$

Распространённый вариант — использовать большую выборку  $B_k$  («мини-батч»):

$$\frac{1}{|B_k|} \sum_{i \in B_k} \nabla f_i(x_k) \approx \frac{1}{n} \sum_{i=1}^n \nabla f_i(x_k),$$

что особенно удобно для векторизации и параллелизации.

Например, при 16 ядрах ставим  $|B_k| = 16$  и считаем 16 градиентов одновременно.

## Мини-батч как ГС с ошибкой

SGD с мини-батчем  $B_k$  использует итерации:

$$x_{k+1} = x_k - \alpha_k \left( \frac{1}{|B_k|} \sum_{i \in B_k} \nabla f_i(x_k) \right).$$

Рассмотрим это как «градиентный метод с ошибкой»:

$$x_{k+1} = x_k - \alpha_k (\nabla f(x_k) + e_k),$$

где  $e_k$  — разность между приближённым и истинным градиентами.

При  $\alpha_k = \frac{1}{L}$ , используя лемму спуска:

$$f(x_{k+1}) \leq f(x_k) - \frac{1}{2L} \|\nabla f(x_k)\|^2 + \frac{1}{2L} \|e_k\|^2,$$

для любой ошибки  $e_k$ .


## Идея SGD и батчей

Данные


|  |  |  |  |  |  |
|--|--|--|--|--|--|
|  |  |  |  |  |  |
|  |  |  |  |  |  |
|  |  |  |  |  |  |
|  |  |  |  |  |  |
|  |  |  |  |  |  |
|  |  |  |  |  |  |
|  |  |  |  |  |  |
|  |  |  |  |  |  |
|  |  |  |  |  |  |
|  |  |  |  |  |  |
|  |  |  |  |  |  |
|  |  |  |  |  |  |




## Идея SGD и батчей




## Идея SGD и батчей



## Идея SGD и батчей




## Идея SGD и батчей




## Детерминированный vs стохастический

Градиентный спуск сходится к локальному минимуму




## Детерминированный vs стохастический

Градиентный спуск  
сходится к локальному минимуму



## SGD помогает убежать из локальных минимумов


Стохастический градиентный спуск  
выпрыгивает из локальных минимумов



# Главная проблема SGD

$$f(x) = \frac{\mu}{2} \|x\|_2^2 + \frac{1}{m} \sum_{i=1}^m \log(1 + \exp(-y_i \langle a_i, x \rangle)) \rightarrow \min_{x \in \mathbb{R}^n}$$

Strongly convex binary logistic regression.  $m=200$ ,  $n=10$ ,  $\mu=1$ .





# Основные результаты сходимости SGD

**i** Пусть  $f$  —  $L$ -гладкая  $\mu$ -сильно выпуклая функция, а дисперсия стохастического градиента конечна ( $\mathbb{E}[\|\nabla f_i(x_k)\|^2] \leq \sigma^2$ ). Тогда SGD с постоянным шагом  $\alpha < \frac{1}{2\mu}$  гарантирует:

$$\mathbb{E}[f(x_{k+1}) - f^*] \leq (1 - 2\alpha\mu)^k [f(x_0) - f^*] + \frac{L\sigma^2\alpha}{4\mu}.$$

# Основные результаты сходимости SGD

- i** Пусть  $f$  —  $L$ -гладкая  $\mu$ -сильно выпуклая функция, а дисперсия стохастического градиента конечна ( $\mathbb{E}[\|\nabla f_i(x_k)\|^2] \leq \sigma^2$ ). Тогда SGD с постоянным шагом  $\alpha < \frac{1}{2\mu}$  гарантирует:

$$\mathbb{E}[f(x_{k+1}) - f^*] \leq (1 - 2\alpha\mu)^k [f(x_0) - f^*] + \frac{L\sigma^2\alpha}{4\mu}.$$

- i** Пусть  $f$  —  $L$ -гладкая  $\mu$ -сильно выпуклая функция, а дисперсия стохастического градиента конечна ( $\mathbb{E}[\|\nabla f_i(x_k)\|^2] \leq \sigma^2$ ). Тогда SGD с убывающим шагом  $\alpha_k = \frac{2k+1}{2\mu(k+1)^2}$  гарантирует:

$$\mathbb{E}[f(x_{k+1}) - f^*] \leq \frac{L\sigma^2}{2\mu^2(k+1)}$$

## Выводы по SGD

- SGD с постоянным шагом **не сходится** даже в PL (сильно выпуклом) случае — остаётся «окрестность»  $\frac{L\sigma^2\alpha}{4\mu}$

## Выводы по SGD

- SGD с постоянным шагом **не сходится** даже в PL (сильно выпуклом) случае — остаётся «окрестность»  $\frac{L\sigma^2\alpha}{4\mu}$
- SGD достигает сублинейной сходимости  $\mathcal{O}\left(\frac{1}{k}\right)$  в PL-случае с убывающим шагом

## Выводы по SGD

- SGD с постоянным шагом **не сходится** даже в PL (сильно выпуклом) случае — остаётся «окрестность»  $\frac{L\sigma^2\alpha}{4\mu}$
- SGD достигает сублинейной сходимости  $\mathcal{O}\left(\frac{1}{k}\right)$  в PL-случае с убывающим шагом
- Ускорения Нестерова/Поляка **не улучшают** скорость сходимости в стохастическом случае

## Выводы по SGD

- SGD с постоянным шагом **не сходится** даже в PL (сильно выпуклом) случае — остаётся «окрестность»  $\frac{L\sigma^2\alpha}{4\mu}$
- SGD достигает сублинейной сходимости  $\mathcal{O}\left(\frac{1}{k}\right)$  в PL-случае с убывающим шагом
- Ускорения Нестерова/Поляка **не улучшают** скорость сходимости в стохастическом случае
- Можно ли достичь линейной сходимости как у GD при стоимости итерации как у SGD? **Да — методы редукции дисперсии.**

## Методы редукции дисперсии

## Ключевая идея редукции дисперсии

**Принцип:** уменьшение дисперсии выборки  $X$  с помощью выборки из другой случайной величины  $Y$  с известным мат. ожиданием:

$$Z_\alpha = \alpha(X - Y) + \mathbb{E}[Y]$$

- $\mathbb{E}[Z_\alpha] = \alpha\mathbb{E}[X] + (1 - \alpha)\mathbb{E}[Y]$



## Ключевая идея редукции дисперсии

**Принцип:** уменьшение дисперсии выборки  $X$  с помощью выборки из другой случайной величины  $Y$  с известным мат. ожиданием:

$$Z_\alpha = \alpha(X - Y) + \mathbb{E}[Y]$$

- $\mathbb{E}[Z_\alpha] = \alpha\mathbb{E}[X] + (1 - \alpha)\mathbb{E}[Y]$
- $\text{var}(Z_\alpha) = \alpha^2(\text{var}(X) + \text{var}(Y) - 2\text{cov}(X, Y))$

# Ключевая идея редукции дисперсии

**Принцип:** уменьшение дисперсии выборки  $X$  с помощью выборки из другой случайной величины  $Y$  с известным мат. ожиданием:

$$Z_\alpha = \alpha(X - Y) + \mathbb{E}[Y]$$

- $\mathbb{E}[Z_\alpha] = \alpha\mathbb{E}[X] + (1 - \alpha)\mathbb{E}[Y]$
- $\text{var}(Z_\alpha) = \alpha^2(\text{var}(X) + \text{var}(Y) - 2\text{cov}(X, Y))$ 
  - Если  $\alpha = 1$ : нет смещения

# Ключевая идея редукции дисперсии

**Принцип:** уменьшение дисперсии выборки  $X$  с помощью выборки из другой случайной величины  $Y$  с известным мат. ожиданием:

$$Z_\alpha = \alpha(X - Y) + \mathbb{E}[Y]$$

- $\mathbb{E}[Z_\alpha] = \alpha\mathbb{E}[X] + (1 - \alpha)\mathbb{E}[Y]$
- $\text{var}(Z_\alpha) = \alpha^2 (\text{var}(X) + \text{var}(Y) - 2\text{cov}(X, Y))$ 
  - Если  $\alpha = 1$ : нет смещения
  - Если  $\alpha < 1$ : потенциальное смещение (но уменьшенная дисперсия).

# Ключевая идея редукции дисперсии

**Принцип:** уменьшение дисперсии выборки  $X$  с помощью выборки из другой случайной величины  $Y$  с известным мат. ожиданием:

$$Z_\alpha = \alpha(X - Y) + \mathbb{E}[Y]$$

- $\mathbb{E}[Z_\alpha] = \alpha\mathbb{E}[X] + (1 - \alpha)\mathbb{E}[Y]$
- $\text{var}(Z_\alpha) = \alpha^2 (\text{var}(X) + \text{var}(Y) - 2\text{cov}(X, Y))$ 
  - Если  $\alpha = 1$ : нет смещения
  - Если  $\alpha < 1$ : потенциальное смещение (но уменьшенная дисперсия).
- Полезно, если  $Y$  положительно коррелирует с  $X$ .

# Ключевая идея редукции дисперсии

**Принцип:** уменьшение дисперсии выборки  $X$  с помощью выборки из другой случайной величины  $Y$  с известным мат. ожиданием:

$$Z_\alpha = \alpha(X - Y) + \mathbb{E}[Y]$$

- $\mathbb{E}[Z_\alpha] = \alpha\mathbb{E}[X] + (1 - \alpha)\mathbb{E}[Y]$
- $\text{var}(Z_\alpha) = \alpha^2 (\text{var}(X) + \text{var}(Y) - 2\text{cov}(X, Y))$ 
  - Если  $\alpha = 1$ : нет смещения
  - Если  $\alpha < 1$ : потенциальное смещение (но уменьшенная дисперсия).
- Полезно, если  $Y$  положительно коррелирует с  $X$ .

# Ключевая идея редукции дисперсии

**Принцип:** уменьшение дисперсии выборки  $X$  с помощью выборки из другой случайной величины  $Y$  с известным мат. ожиданием:

$$Z_\alpha = \alpha(X - Y) + \mathbb{E}[Y]$$

- $\mathbb{E}[Z_\alpha] = \alpha\mathbb{E}[X] + (1 - \alpha)\mathbb{E}[Y]$
- $\text{var}(Z_\alpha) = \alpha^2 (\text{var}(X) + \text{var}(Y) - 2\text{cov}(X, Y))$ 
  - Если  $\alpha = 1$ : нет смещения
  - Если  $\alpha < 1$ : потенциальное смещение (но уменьшенная дисперсия).
- Полезно, если  $Y$  положительно коррелирует с  $X$ .

**Применение к оценке градиента:**

- SVRG: Пусть  $X = \nabla f_{i_k}(x^{(k-1)})$  и  $Y = \nabla f_{i_k}(\tilde{x})$ , при  $\alpha = 1$  и запомненном  $\tilde{x}$ .

# Ключевая идея редукции дисперсии

**Принцип:** уменьшение дисперсии выборки  $X$  с помощью выборки из другой случайной величины  $Y$  с известным мат. ожиданием:

$$Z_\alpha = \alpha(X - Y) + \mathbb{E}[Y]$$

- $\mathbb{E}[Z_\alpha] = \alpha\mathbb{E}[X] + (1 - \alpha)\mathbb{E}[Y]$
- $\text{var}(Z_\alpha) = \alpha^2(\text{var}(X) + \text{var}(Y) - 2\text{cov}(X, Y))$ 
  - Если  $\alpha = 1$ : нет смещения
  - Если  $\alpha < 1$ : потенциальное смещение (но уменьшенная дисперсия).
- Полезно, если  $Y$  положительно коррелирует с  $X$ .

**Применение к оценке градиента:**

- SVRG: Пусть  $X = \nabla f_{i_k}(x^{(k-1)})$  и  $Y = \nabla f_{i_k}(\tilde{x})$ , при  $\alpha = 1$  и запомненном  $\tilde{x}$ .
- $\mathbb{E}[Y] = \frac{1}{n} \sum_{i=1}^n \nabla f_i(\tilde{x})$  — полный градиент в  $\tilde{x}$ ;

## Ключевая идея редукции дисперсии

**Принцип:** уменьшение дисперсии выборки  $X$  с помощью выборки из другой случайной величины  $Y$  с известным мат. ожиданием:

$$Z_\alpha = \alpha(X - Y) + \mathbb{E}[Y]$$

- $\mathbb{E}[Z_\alpha] = \alpha\mathbb{E}[X] + (1 - \alpha)\mathbb{E}[Y]$
- $\text{var}(Z_\alpha) = \alpha^2(\text{var}(X) + \text{var}(Y) - 2\text{cov}(X, Y))$ 
  - Если  $\alpha = 1$ : нет смещения
  - Если  $\alpha < 1$ : потенциальное смещение (но уменьшенная дисперсия).
- Полезно, если  $Y$  положительно коррелирует с  $X$ .

**Применение к оценке градиента:**

- SVRG: Пусть  $X = \nabla f_{i_k}(x^{(k-1)})$  и  $Y = \nabla f_{i_k}(\tilde{x})$ , при  $\alpha = 1$  и запомненном  $\tilde{x}$ .
- $\mathbb{E}[Y] = \frac{1}{n} \sum_{i=1}^n \nabla f_i(\tilde{x})$  — полный градиент в  $\tilde{x}$ ;
- $X - Y = \nabla f_{i_k}(x^{(k-1)}) - \nabla f_{i_k}(\tilde{x})$  — разность стремится к нулю вблизи решения.



# SAG (Stochastic Average Gradient, Schmidt, Le Roux, Bach 2013)

- Хранить таблицу градиентов  $g_i$  от  $f_i$ ,  $i = 1, \dots, n$

## SAG (Stochastic Average Gradient, Schmidt, Le Roux, Bach 2013)

- Хранить таблицу градиентов  $g_i$  от  $f_i$ ,  $i = 1, \dots, n$
- Инициализация  $x^{(0)}$ , и  $g_i^{(0)} = \nabla f_i(x^{(0)})$ ,  $i = 1, \dots, n$

## SAG (Stochastic Average Gradient, Schmidt, Le Roux, Bach 2013)

- Хранить таблицу градиентов  $g_i$  от  $f_i$ ,  $i = 1, \dots, n$
- Инициализация  $x^{(0)}$ , и  $g_i^{(0)} = \nabla f_i(x^{(0)})$ ,  $i = 1, \dots, n$
- На шаге  $k = 1, 2, 3, \dots$ , выбрать случайный  $i_k \in \{1, \dots, n\}$ , затем

$$g_{i_k}^{(k)} = \nabla f_{i_k}(x^{(k-1)}) \quad (\text{обновление последнего градиента } f_{i_k})$$

Все остальные  $g_i^{(k)} = g_i^{(k-1)}$ ,  $i \neq i_k$ , т.е. остаются без изменений

## SAG (Stochastic Average Gradient, Schmidt, Le Roux, Bach 2013)

- Хранить таблицу градиентов  $g_i$  от  $f_i$ ,  $i = 1, \dots, n$
- Инициализация  $x^{(0)}$ , и  $g_i^{(0)} = \nabla f_i(x^{(0)})$ ,  $i = 1, \dots, n$
- На шаге  $k = 1, 2, 3, \dots$ , выбрать случайный  $i_k \in \{1, \dots, n\}$ , затем

$$g_{i_k}^{(k)} = \nabla f_{i_k}(x^{(k-1)}) \quad (\text{обновление последнего градиента } f_{i_k})$$

Все остальные  $g_i^{(k)} = g_i^{(k-1)}$ ,  $i \neq i_k$ , т.е. остаются без изменений

- Обновление

$$x^{(k)} = x^{(k-1)} - \alpha_k \frac{1}{n} \sum_{i=1}^n g_i^{(k)}$$

## SAG (Stochastic Average Gradient, Schmidt, Le Roux, Bach 2013)

- Хранить таблицу градиентов  $g_i$  от  $f_i$ ,  $i = 1, \dots, n$
- Инициализация  $x^{(0)}$ , и  $g_i^{(0)} = \nabla f_i(x^{(0)})$ ,  $i = 1, \dots, n$
- На шаге  $k = 1, 2, 3, \dots$ , выбрать случайный  $i_k \in \{1, \dots, n\}$ , затем

$$g_{i_k}^{(k)} = \nabla f_{i_k}(x^{(k-1)}) \quad (\text{обновление последнего градиента } f_{i_k})$$

Все остальные  $g_i^{(k)} = g_i^{(k-1)}$ ,  $i \neq i_k$ , т.е. остаются без изменений

- Обновление

$$x^{(k)} = x^{(k-1)} - \alpha_k \frac{1}{n} \sum_{i=1}^n g_i^{(k)}$$

- Оценки градиента SAG **не являются несмещёнными**, но имеют значительно уменьшенную дисперсию

## SAG (Stochastic Average Gradient, Schmidt, Le Roux, Bach 2013)

- Хранить таблицу градиентов  $g_i$  от  $f_i$ ,  $i = 1, \dots, n$
- Инициализация  $x^{(0)}$ , и  $g_i^{(0)} = \nabla f_i(x^{(0)})$ ,  $i = 1, \dots, n$
- На шаге  $k = 1, 2, 3, \dots$ , выбрать случайный  $i_k \in \{1, \dots, n\}$ , затем

$$g_{i_k}^{(k)} = \nabla f_{i_k}(x^{(k-1)}) \quad (\text{обновление последнего градиента } f_{i_k})$$

Все остальные  $g_i^{(k)} = g_i^{(k-1)}$ ,  $i \neq i_k$ , т.е. остаются без изменений

- Обновление

$$x^{(k)} = x^{(k-1)} - \alpha_k \frac{1}{n} \sum_{i=1}^n g_i^{(k)}$$

- Оценки градиента SAG **не являются несмещёнными**, но имеют значительно уменьшенную дисперсию
- Не дорого ли усреднять все эти градиенты? Столь же эффективно, как SGD, при правильной реализации:

$$x^{(k)} = x^{(k-1)} - \alpha_k \underbrace{\left( \frac{1}{n} g_{i_k}^{(k)} - \frac{1}{n} g_{i_k}^{(k-1)} + \underbrace{\frac{1}{n} \sum_{i=1}^n g_i^{(k-1)}}_{\text{старое среднее таблицы}} \right)}_{\text{новое среднее таблицы}}$$

# Сходимость SAG

Предположим, что  $f(x) = \frac{1}{n} \sum_{i=1}^n f_i(x)$ , где каждая  $f_i$  дифференцируема, и  $\nabla f_i$  липшицев с константой  $L$ .

Обозначим  $\bar{x}^{(k)} = \frac{1}{k} \sum_{l=0}^{k-1} x^{(l)}$  — среднюю итерацию после  $k - 1$  шагов.

## i Theorem

SAG с фиксированным шагом  $\alpha = \frac{1}{16L}$  и инициализацией

$$g_i^{(0)} = \nabla f_i(x^{(0)}) - \nabla f(x^{(0)}), \quad i = 1, \dots, n$$

удовлетворяет

$$\mathbb{E}[f(\bar{x}^{(k)})] - f^* \leq \frac{48n}{k} [f(x^{(0)}) - f^*] + \frac{128L}{k} \|x^{(0)} - x^*\|^2$$

# Сходимость SAG

Предположим, что  $f(x) = \frac{1}{n} \sum_{i=1}^n f_i(x)$ , где каждая  $f_i$  дифференцируема, и  $\nabla f_i$  липшицев с константой  $L$ .

Обозначим  $\bar{x}^{(k)} = \frac{1}{k} \sum_{l=0}^{k-1} x^{(l)}$  — среднюю итерацию после  $k - 1$  шагов.

## i Theorem

SAG с фиксированным шагом  $\alpha = \frac{1}{16L}$  и инициализацией

$$g_i^{(0)} = \nabla f_i(x^{(0)}) - \nabla f(x^{(0)}), \quad i = 1, \dots, n$$

удовлетворяет

$$\mathbb{E}[f(\bar{x}^{(k)})] - f^* \leq \frac{48n}{k} [f(x^{(0)}) - f^*] + \frac{128L}{k} \|x^{(0)} - x^*\|^2$$

- Скорость  $\mathcal{O}\left(\frac{1}{k}\right)$  для SAG. Сравните:  $\mathcal{O}\left(\frac{1}{k}\right)$  для GD и  $\mathcal{O}\left(\frac{1}{\sqrt{k}}\right)$  для SGD.



# Сходимость SAG

Предположим, что  $f(x) = \frac{1}{n} \sum_{i=1}^n f_i(x)$ , где каждая  $f_i$  дифференцируема, и  $\nabla f_i$  липшицев с константой  $L$ .

Обозначим  $\bar{x}^{(k)} = \frac{1}{k} \sum_{l=0}^{k-1} x^{(l)}$  — среднюю итерацию после  $k - 1$  шагов.

## i Theorem

SAG с фиксированным шагом  $\alpha = \frac{1}{16L}$  и инициализацией

$$g_i^{(0)} = \nabla f_i(x^{(0)}) - \nabla f(x^{(0)}), \quad i = 1, \dots, n$$

удовлетворяет

$$\mathbb{E}[f(\bar{x}^{(k)})] - f^* \leq \frac{48n}{k} [f(x^{(0)}) - f^*] + \frac{128L}{k} \|x^{(0)} - x^*\|^2$$

- Скорость  $\mathcal{O}\left(\frac{1}{k}\right)$  для SAG. Сравните:  $\mathcal{O}\left(\frac{1}{k}\right)$  для GD и  $\mathcal{O}\left(\frac{1}{\sqrt{k}}\right)$  для SGD.
- Но константы различаются! Первый член в оценке SAG страдает от множителя  $n$ .

## Сходимость SAG. Сильно выпуклый случай

Предположим дополнительно, что каждая  $f_i$  сильно выпукла с параметром  $\mu$ .

### Theorem

SAG с шагом  $\alpha = \frac{1}{16L}$  удовлетворяет

$$\mathbb{E}[f(x^{(k)})] - f^* \leq \left(1 - \min\left(\frac{\mu}{16L}, \frac{1}{8n}\right)\right)^k \left(\frac{3}{2}(f(x^{(0)}) - f^*) + \frac{4L}{n}\|x^{(0)} - x^*\|^2\right)$$

## Сходимость SAG. Сильно выпуклый случай

Предположим дополнительно, что каждая  $f_i$  сильно выпукла с параметром  $\mu$ .

### i Theorem

SAG с шагом  $\alpha = \frac{1}{16L}$  удовлетворяет

$$\mathbb{E}[f(x^{(k)})] - f^* \leq \left(1 - \min\left(\frac{\mu}{16L}, \frac{1}{8n}\right)\right)^k \left(\frac{3}{2}(f(x^{(0)}) - f^*) + \frac{4L}{n}\|x^{(0)} - x^*\|^2\right)$$

- **Линейная** сходимость  $\mathcal{O}(\gamma^k)$  для SAG. Сравните:  $\mathcal{O}(\gamma^k)$  для GD и только  $\mathcal{O}\left(\frac{1}{k}\right)$  для SGD.

## Сходимость SAG. Сильно выпуклый случай

Предположим дополнительно, что каждая  $f_i$  сильно выпукла с параметром  $\mu$ .

### Theorem

SAG с шагом  $\alpha = \frac{1}{16L}$  удовлетворяет

$$\mathbb{E}[f(x^{(k)})] - f^* \leq \left(1 - \min\left(\frac{\mu}{16L}, \frac{1}{8n}\right)\right)^k \left(\frac{3}{2}(f(x^{(0)}) - f^*) + \frac{4L}{n}\|x^{(0)} - x^*\|^2\right)$$

- **Линейная** сходимость  $\mathcal{O}(\gamma^k)$  для SAG. Сравните:  $\mathcal{O}(\gamma^k)$  для GD и только  $\mathcal{O}\left(\frac{1}{k}\right)$  для SGD.
- SAG адаптивен к сильной выпуклости, как и GD.

## Сходимость SAG. Сильно выпуклый случай

Предположим дополнительно, что каждая  $f_i$  сильно выпукла с параметром  $\mu$ .

### i Theorem

SAG с шагом  $\alpha = \frac{1}{16L}$  удовлетворяет

$$\mathbb{E}[f(x^{(k)})] - f^* \leq \left(1 - \min\left(\frac{\mu}{16L}, \frac{1}{8n}\right)\right)^k \left(\frac{3}{2}(f(x^{(0)}) - f^*) + \frac{4L}{n}\|x^{(0)} - x^*\|^2\right)$$

- **Линейная** сходимость  $\mathcal{O}(\gamma^k)$  для SAG. Сравните:  $\mathcal{O}(\gamma^k)$  для GD и только  $\mathcal{O}(\frac{1}{k})$  для SGD.
- SAG адаптивен к сильной выпуклости, как и GD.
- Как и GD, SAG достигает линейной сходимости, но при стоимости итерации как у SGD.

## Замечания по SAG

- Метод в классической формулировке **не применим для больших нейросетей** из-за требований к памяти (нужно хранить  $n$  градиентов).

## Замечания по SAG

- Метод в классической формулировке **не применим для больших нейросетей** из-за требований к памяти (нужно хранить  $n$  градиентов).
- На практике можно использовать backtracking для оценки константы Липшица.

## Замечания по SAG

- Метод в классической формулировке **не применим для больших нейросетей** из-за требований к памяти (нужно хранить  $n$  градиентов).
- На практике можно использовать backtracking для оценки константы Липшица.
- Поскольку стохастический градиент  $g(x^k) \rightarrow \nabla f(x^k)$ , можно отслеживать сходимость по его норме (что неверно для SGD!).



## Замечания по SAG

- Метод в классической формулировке **не применим для больших нейросетей** из-за требований к памяти (нужно хранить  $n$  градиентов).
- На практике можно использовать backtracking для оценки константы Липшица.
- Поскольку стохастический градиент  $g(x^k) \rightarrow \nabla f(x^k)$ , можно отслеживать сходимость по его норме (что неверно для SGD!).
- Для обобщённых линейных моделей (LogReg, LLS) память  $\mathcal{O}(n)$  вместо  $\mathcal{O}(pn)$ :

$$f_i(w) = \varphi(w^T x_i) \leftrightarrow \nabla f_i(w) = \varphi'(w^T x_i) x_i$$

# SVRG (Stochastic Variance Reduced Gradient)

- Инициализация:  $\tilde{x} \in \mathbb{R}^d$

# SVRG (Stochastic Variance Reduced Gradient)

- Инициализация:  $\tilde{x} \in \mathbb{R}^d$
- Для  $i_{\text{epoch}} = 1$  до число эпох

# SVRG (Stochastic Variance Reduced Gradient)

- Инициализация:  $\tilde{x} \in \mathbb{R}^d$
- Для  $i_{\text{epoch}} = 1$  до число эпох
  - Вычислить все градиенты  $\nabla f_i(\tilde{x})$ ; сохранить  $\nabla f(\tilde{x}) = \frac{1}{n} \sum_{i=1}^n \nabla f_i(\tilde{x})$

# SVRG (Stochastic Variance Reduced Gradient)

- Инициализация:  $\tilde{x} \in \mathbb{R}^d$
- Для  $i_{\text{epoch}} = 1$  до число эпох
  - Вычислить все градиенты  $\nabla f_i(\tilde{x})$ ; сохранить  $\nabla f(\tilde{x}) = \frac{1}{n} \sum_{i=1}^n \nabla f_i(\tilde{x})$
  - Инициализировать  $x_0 = \tilde{x}$

# SVRG (Stochastic Variance Reduced Gradient)

- Инициализация:  $\tilde{x} \in \mathbb{R}^d$
- Для  $i_{\text{epoch}} = 1$  до число эпох
  - Вычислить все градиенты  $\nabla f_i(\tilde{x})$ ; сохранить  $\nabla f(\tilde{x}) = \frac{1}{n} \sum_{i=1}^n \nabla f_i(\tilde{x})$
  - Инициализировать  $x_0 = \tilde{x}$
  - Для  $t = 1$  до длина эпохи ( $m$ )

# SVRG (Stochastic Variance Reduced Gradient)

- Инициализация:  $\tilde{x} \in \mathbb{R}^d$
- Для  $i_{\text{epoch}} = 1$  до число эпох
  - Вычислить все градиенты  $\nabla f_i(\tilde{x})$ ; сохранить  $\nabla f(\tilde{x}) = \frac{1}{n} \sum_{i=1}^n \nabla f_i(\tilde{x})$
  - Инициализировать  $x_0 = \tilde{x}$
  - Для  $t = 1$  до длина эпохи ( $m$ )
    - Выбрать  $i_t \in \{1, \dots, n\}$  равномерно

# SVRG (Stochastic Variance Reduced Gradient)

- Инициализация:  $\tilde{x} \in \mathbb{R}^d$
- Для  $i_{\text{epoch}} = 1$  до число эпох
  - Вычислить все градиенты  $\nabla f_i(\tilde{x})$ ; сохранить  $\nabla f(\tilde{x}) = \frac{1}{n} \sum_{i=1}^n \nabla f_i(\tilde{x})$
  - Инициализировать  $x_0 = \tilde{x}$
  - Для  $t = 1$  до длина эпохи ( $m$ )
    - Выбрать  $i_t \in \{1, \dots, n\}$  равномерно
    - $x_t = x_{t-1} - \alpha [\nabla f_{i_t}(x_{t-1}) - \nabla f_{i_t}(\tilde{x}) + \nabla f(\tilde{x})]$



# SVRG (Stochastic Variance Reduced Gradient)

- Инициализация:  $\tilde{x} \in \mathbb{R}^d$
- Для  $i_{\text{epoch}} = 1$  до число эпох
  - Вычислить все градиенты  $\nabla f_i(\tilde{x})$ ; сохранить  $\nabla f(\tilde{x}) = \frac{1}{n} \sum_{i=1}^n \nabla f_i(\tilde{x})$
  - Инициализировать  $x_0 = \tilde{x}$
  - Для  $t = 1$  до длина эпохи ( $m$ )
    - Выбрать  $i_t \in \{1, \dots, n\}$  равномерно
    - $x_t = x_{t-1} - \alpha [\nabla f_{i_t}(x_{t-1}) - \nabla f_{i_t}(\tilde{x}) + \nabla f(\tilde{x})]$
  - Обновить  $\tilde{x} = x_m$

# SVRG (Stochastic Variance Reduced Gradient)

- Инициализация:  $\tilde{x} \in \mathbb{R}^d$
- Для  $i_{\text{epoch}} = 1$  до число эпох
  - Вычислить все градиенты  $\nabla f_i(\tilde{x})$ ; сохранить  $\nabla f(\tilde{x}) = \frac{1}{n} \sum_{i=1}^n \nabla f_i(\tilde{x})$
  - Инициализировать  $x_0 = \tilde{x}$
  - Для  $t = 1$  до длина эпохи ( $m$ )
    - Выбрать  $i_t \in \{1, \dots, n\}$  равномерно
    - $x_t = x_{t-1} - \alpha [\nabla f_{i_t}(x_{t-1}) - \nabla f_{i_t}(\tilde{x}) + \nabla f(\tilde{x})]$
  - Обновить  $\tilde{x} = x_m$

# SVRG (Stochastic Variance Reduced Gradient)

- Инициализация:  $\tilde{x} \in \mathbb{R}^d$
- Для  $i_{\text{epoch}} = 1$  до число эпох
  - Вычислить все градиенты  $\nabla f_i(\tilde{x})$ ; сохранить  $\nabla f(\tilde{x}) = \frac{1}{n} \sum_{i=1}^n \nabla f_i(\tilde{x})$
  - Инициализировать  $x_0 = \tilde{x}$
  - Для  $t = 1$  до длина эпохи ( $m$ )
    - Выбрать  $i_t \in \{1, \dots, n\}$  равномерно
    - $x_t = x_{t-1} - \alpha [\nabla f_{i_t}(x_{t-1}) - \nabla f_{i_t}(\tilde{x}) + \nabla f(\tilde{x})]$
  - Обновить  $\tilde{x} = x_m$

## Замечания:

- Два вычисления градиента на каждом внутреннем шаге.

# SVRG (Stochastic Variance Reduced Gradient)

- Инициализация:  $\tilde{x} \in \mathbb{R}^d$
- Для  $i_{\text{epoch}} = 1$  до число эпох
  - Вычислить все градиенты  $\nabla f_i(\tilde{x})$ ; сохранить  $\nabla f(\tilde{x}) = \frac{1}{n} \sum_{i=1}^n \nabla f_i(\tilde{x})$
  - Инициализировать  $x_0 = \tilde{x}$
  - Для  $t = 1$  до длина эпохи ( $m$ )
    - Выбрать  $i_t \in \{1, \dots, n\}$  равномерно
    - $x_t = x_{t-1} - \alpha [\nabla f_{i_t}(x_{t-1}) - \nabla f_{i_t}(\tilde{x}) + \nabla f(\tilde{x})]$
  - Обновить  $\tilde{x} = x_m$

## Замечания:

- Два вычисления градиента на каждом внутреннем шаге.
- Два параметра: длина эпохи + шаг  $\alpha$ .

# SVRG (Stochastic Variance Reduced Gradient)

- **Инициализация:**  $\tilde{x} \in \mathbb{R}^d$
- **Для**  $i_{\text{epoch}} = 1$  **до** число эпох
  - Вычислить все градиенты  $\nabla f_i(\tilde{x})$ ; сохранить  $\nabla f(\tilde{x}) = \frac{1}{n} \sum_{i=1}^n \nabla f_i(\tilde{x})$
  - Инициализировать  $x_0 = \tilde{x}$
  - **Для**  $t = 1$  **до** длина эпохи ( $m$ )
    - Выбрать  $i_t \in \{1, \dots, n\}$  равномерно
    - $x_t = x_{t-1} - \alpha [\nabla f_{i_t}(x_{t-1}) - \nabla f_{i_t}(\tilde{x}) + \nabla f(\tilde{x})]$
  - Обновить  $\tilde{x} = x_m$

## Замечания:

- Два вычисления градиента на каждом внутреннем шаге.
- Два параметра: длина эпохи + шаг  $\alpha$ .
- Линейная сходимость, простое доказательство.

# SVRG (Stochastic Variance Reduced Gradient)

- **Инициализация:**  $\tilde{x} \in \mathbb{R}^d$
- **Для**  $i_{\text{epoch}} = 1$  **до** число эпох
  - Вычислить все градиенты  $\nabla f_i(\tilde{x})$ ; сохранить  $\nabla f(\tilde{x}) = \frac{1}{n} \sum_{i=1}^n \nabla f_i(\tilde{x})$
  - Инициализировать  $x_0 = \tilde{x}$
  - **Для**  $t = 1$  **до** длина эпохи ( $m$ )
    - Выбрать  $i_t \in \{1, \dots, n\}$  равномерно
    - $x_t = x_{t-1} - \alpha [\nabla f_{i_t}(x_{t-1}) - \nabla f_{i_t}(\tilde{x}) + \nabla f(\tilde{x})]$
  - Обновить  $\tilde{x} = x_m$

## Замечания:

- Два вычисления градиента на каждом внутреннем шаге.
- Два параметра: длина эпохи + шаг  $\alpha$ .
- Линейная сходимость, простое доказательство.
- Не требует хранения  $n$  градиентов (в отличие от SAG).

# Численный эксперимент: SGD vs SVRG

Логистическая регрессия с  $\ell_2$ -регуляризацией.  $m = 200, n = 10, \mu = 0.1$




Рис. 2: Слева: сходимость  $f(x_k) - f^*$ . Справа: дисперсия оценки градиента. SVRG уменьшает дисперсию на порядки по мере приближения к решению, в то время как дисперсия SGD остаётся постоянной.

# Сравнение GD, SGD и SVRG

Strongly convex quadratics,  $m=150$ ,  $n=300$ ,  $\mu=1$ .




Рис. 3: Линейная регрессия с МНК

Strongly convex binary logistic regression,  $m=200$ ,  $n=10$ ,  $\mu=0.1$ .




Рис. 4: Логистическая регрессия



# Сравнение GD, SGD и SVRG

Strongly convex quadratics,  $m=150$ ,  $n=300$ ,  $\mu=1$ .




Рис. 3: Линейная регрессия с МНК

Strongly convex binary logistic regression,  $m=200$ ,  $n=10$ ,  $\mu=0.1$ .





Рис. 4: Логистическая регрессия

| Метод | Стоимость итерации | Сходимость (сильно вып.)                               | Память  |
|-------|--------------------|--------------------------------------------------------|---------|
| GD    | $O(n)$             | линейная $(1 - \frac{\mu}{L})^k$                       | $O(p)$  |
| SGD   | $O(1)$             | сублинейная $\frac{1}{k}$                              | $O(p)$  |
| SAG   | $O(1)$             | линейная $(1 - \min(\frac{\mu}{16L}, \frac{1}{8n}))^k$ | $O(np)$ |
| SVRG  | $O(1)$             | линейная                                               | $O(p)$  |


## Ширина локальных минимумов

Узкие и широкие локальные минимумы




## Ширина локальных минимумов

Узкие и широкие локальные минимумы




## Ширина локальных минимумов

Узкие и широкие локальные минимумы




## GD сходится к ближайшему минимуму

Градиентный спуск с маленьким шагом  
сходится в узкий локальный минимум



## SGD расходится вблизи минимума

Градиентный спуск с большим шагом избегает узкого локального минимума



- **SGD** — дешёвые итерации ( $O(1)$  вместо  $O(n)$ ), но медленная сублинейная сходимость  $O(1/k)$  вместо линейной у GD

- **SGD** — дешёвые итерации ( $O(1)$  вместо  $O(n)$ ), но медленная сублинейная сходимость  $O(1/k)$  вместо линейной у GD
- **Постоянный шаг**: SGD не сходится к точному решению — остаётся «окрестность» размера  $\frac{L\sigma^2\alpha}{4\mu}$



## Итоги

- **SGD** — дешёвые итерации ( $O(1)$  вместо  $O(n)$ ), но медленная сублинейная сходимость  $O(1/k)$  вместо линейной у GD
- **Постоянный шаг**: SGD не сходится к точному решению — остаётся «окрестность» размера  $\frac{L\sigma^2\alpha}{4\mu}$
- **Убывающий шаг**: сходимость к точному решению, но сублинейно

- **SGD** — дешёвые итерации ( $O(1)$  вместо  $O(n)$ ), но медленная сублинейная сходимость  $O(1/k)$  вместо линейной у GD
- **Постоянный шаг**: SGD не сходится к точному решению — остаётся «окрестность» размера  $\frac{L\sigma^2\alpha}{4\mu}$
- **Убывающий шаг**: сходимость к точному решению, но сублинейно
- **Методы редукции дисперсии** (SAG, SVRG) достигают **линейной** сходимости при стоимости итерации как у SGD

- **SGD** — дешёвые итерации ( $O(1)$  вместо  $O(n)$ ), но медленная сублинейная сходимость  $O(1/k)$  вместо линейной у GD
- **Постоянный шаг**: SGD не сходится к точному решению — остаётся «окрестность» размера  $\frac{L\sigma^2\alpha}{4\mu}$
- **Убывающий шаг**: сходимость к точному решению, но сублинейно
- **Методы редукции дисперсии** (SAG, SVRG) достигают **линейной** сходимости при стоимости итерации как у SGD
  - SAG: требует  $O(np)$  памяти

- **SGD** — дешёвые итерации ( $O(1)$  вместо  $O(n)$ ), но медленная сублинейная сходимость  $O(1/k)$  вместо линейной у GD
- **Постоянный шаг**: SGD не сходится к точному решению — остаётся «окрестность» размера  $\frac{L\sigma^2\alpha}{4\mu}$
- **Убывающий шаг**: сходимость к точному решению, но сублинейно
- **Методы редукции дисперсии** (SAG, SVRG) достигают **линейной** сходимости при стоимости итерации как у SGD
  - SAG: требует  $O(np)$  памяти
  - SVRG: требует только  $O(p)$  памяти, но два вычисления градиента на шаг

- **SGD** — дешёвые итерации ( $O(1)$  вместо  $O(n)$ ), но медленная сублинейная сходимость  $O(1/k)$  вместо линейной у GD
- **Постоянный шаг**: SGD не сходится к точному решению — остаётся «окрестность» размера  $\frac{L\sigma^2\alpha}{4\mu}$
- **Убывающий шаг**: сходимость к точному решению, но сублинейно
- **Методы редукции дисперсии** (SAG, SVRG) достигают **линейной** сходимости при стоимости итерации как у SGD
  - SAG: требует  $O(np)$  памяти
  - SVRG: требует только  $O(p)$  памяти, но два вычисления градиента на шаг
- SGD помогает убежать из «узких» локальных минимумов → лучшая обобщающая способность в глубоком обучении

- **SGD** — дешёвые итерации ( $O(1)$  вместо  $O(n)$ ), но медленная сублинейная сходимость  $O(1/k)$  вместо линейной у GD
- **Постоянный шаг**: SGD не сходится к точному решению — остаётся «окрестность» размера  $\frac{L\sigma^2\alpha}{4\mu}$
- **Убывающий шаг**: сходимость к точному решению, но сублинейно
- **Методы редукции дисперсии** (SAG, SVRG) достигают **линейной** сходимости при стоимости итерации как у SGD
  - SAG: требует  $O(np)$  памяти
  - SVRG: требует только  $O(p)$  памяти, но два вычисления градиента на шаг
- SGD помогает убежать из «узких» локальных минимумов → лучшая обобщающая способность в глубоком обучении
- Моментные методы не улучшают скорость SGD (узкое место — дисперсия, не число обусловленности)