



**Двойственные методы: двойственный
градиентный подъём, метод дополненного
лагранжиана, ADMM**

Даниил Меркулов

Методы оптимизации. МФТИ

Введение в двойственные методы

Зачем решать двойственные задачи?

Прямая задача

$$\begin{aligned} & f_0(x) \rightarrow \min_{x \in \mathbb{R}^n} \\ \text{s.t.} \quad & f_i(x) \leq 0, \quad i = 1, \dots, m \\ & h_i(x) = 0, \quad i = 1, \dots, p \end{aligned}$$

Двойственная задача

$$\begin{aligned} & g(\lambda, \nu) = \min_{x \in \mathcal{D}} L(x, \lambda, \nu) = \\ \min_{x \in \mathcal{D}} & \left(f_0(x) + \sum_{i=1}^m \lambda_i f_i(x) + \sum_{i=1}^p \nu_i h_i(x) \right) \rightarrow \max_{\lambda \in \mathbb{R}^m, \nu \in \mathbb{R}^p} \\ \text{s.t.} \quad & \lambda \succeq 0 \end{aligned}$$

- **Теневые цены (shadow prices).** В экономике и задачах распределения ресурсов двойственные переменные можно интерпретировать как теневые цены; это даёт экономический смысл использованию ресурсов и ограничениям.

Зачем решать двойственные задачи?

Прямая задача

$$\begin{aligned} & f_0(x) \rightarrow \min_{x \in \mathbb{R}^n} \\ \text{s.t.} \quad & f_i(x) \leq 0, \quad i = 1, \dots, m \\ & h_i(x) = 0, \quad i = 1, \dots, p \end{aligned}$$

Двойственная задача

$$\begin{aligned} & g(\lambda, \nu) = \min_{x \in \mathcal{D}} L(x, \lambda, \nu) = \\ \min_{x \in \mathcal{D}} & \left(f_0(x) + \sum_{i=1}^m \lambda_i f_i(x) + \sum_{i=1}^p \nu_i h_i(x) \right) \rightarrow \max_{\lambda \in \mathbb{R}^m, \nu \in \mathbb{R}^p} \\ \text{s.t.} \quad & \lambda \succeq 0 \end{aligned}$$

- **Теневые цены (shadow prices).** В экономике и задачах распределения ресурсов двойственные переменные можно интерпретировать как теневые цены; это даёт экономический смысл использованию ресурсов и ограничениям.
- **Рыночное равновесие (market equilibrium).** Двойственные задачи часто описывают условия рыночного равновесия, поэтому они важны для экономического моделирования и анализа.

Зачем решать двойственные задачи?

Прямая задача

$$\begin{aligned} f_0(x) &\rightarrow \min_{x \in \mathbb{R}^n} \\ \text{s.t. } \quad &f_i(x) \leq 0, \quad i = 1, \dots, m \\ &h_i(x) = 0, \quad i = 1, \dots, p \end{aligned}$$

Двойственная задача

$$\begin{aligned} g(\lambda, \nu) &= \min_{x \in \mathcal{D}} L(x, \lambda, \nu) = \\ \min_{x \in \mathcal{D}} \left(f_0(x) + \sum_{i=1}^m \lambda_i f_i(x) + \sum_{i=1}^p \nu_i h_i(x) \right) &\rightarrow \max_{\lambda \in \mathbb{R}^m, \nu \in \mathbb{R}^p} \\ \text{s.t. } \lambda &\succeq 0 \end{aligned}$$

- **Теневые цены (shadow prices).** В экономике и задачах распределения ресурсов двойственные переменные можно интерпретировать как теневые цены; это даёт экономический смысл использованию ресурсов и ограничениям.
- **Рыночное равновесие (market equilibrium).** Двойственные задачи часто описывают условия рыночного равновесия, поэтому они важны для экономического моделирования и анализа.
- **Двойственные оценки (bounds).** Двойственные задачи часто дают оценки оптимального значения прямой задачи. Это полезно для оценки качества приближённых решений.

Зачем решать двойственные задачи?

Прямая задача

$$\begin{aligned} f_0(x) &\rightarrow \min_{x \in \mathbb{R}^n} \\ \text{s.t. } f_i(x) &\leq 0, \quad i = 1, \dots, m \\ h_i(x) &= 0, \quad i = 1, \dots, p \end{aligned}$$

Двойственная задача

$$\begin{aligned} g(\lambda, \nu) &= \min_{x \in \mathcal{D}} L(x, \lambda, \nu) = \\ \min_{x \in \mathcal{D}} \left(f_0(x) + \sum_{i=1}^m \lambda_i f_i(x) + \sum_{i=1}^p \nu_i h_i(x) \right) &\rightarrow \max_{\lambda \in \mathbb{R}^m, \nu \in \mathbb{R}^p} \\ \text{s.t. } \lambda &\succeq 0 \end{aligned}$$

- **Теневые цены (shadow prices).** В экономике и задачах распределения ресурсов двойственные переменные можно интерпретировать как теневые цены; это даёт экономический смысл использованию ресурсов и ограничениям.
- **Рыночное равновесие (market equilibrium).** Двойственные задачи часто описывают условия рыночного равновесия, поэтому они важны для экономического моделирования и анализа.
- **Двойственные оценки (bounds).** Двойственные задачи часто дают оценки оптимального значения прямой задачи. Это полезно для оценки качества приближённых решений.
- **Зазор двойственности (duality gap).** Разница между значениями прямой и двойственной задач даёт информацию об оптимальности решения.


Сопряжённые функции

Сопряжённые функции


Напомним, что для $f : \mathbb{R}^n \rightarrow \mathbb{R}$ функция, заданная как

$$f^*(y) = \max_x [y^T x - f(x)]$$



называется сопряжённой к f .



Геометрическая интуиция



Геометрическая интуиция



Свойства сопряжённой функции

Напомним, что для $f : \mathbb{R}^n \rightarrow \mathbb{R}$ функция, заданная как

$$f^*(y) = \max_x [y^T x - f(x)]$$

называется сопряжённой к f .

- Сопряжённые функции часто возникают в двойственных задачах, поскольку

$$-f^*(y) = \min_x [f(x) - y^T x]$$

Свойства сопряжённой функции

Напомним, что для $f : \mathbb{R}^n \rightarrow \mathbb{R}$ функция, заданная как

$$f^*(y) = \max_x [y^T x - f(x)]$$

называется сопряжённой к f .

- Сопряжённые функции часто возникают в двойственных задачах, поскольку

$$-f^*(y) = \min_x [f(x) - y^T x]$$

- Если f замкнута и выпукла, то $f^{**} = f$. Кроме того,

$$x \in \partial f^*(y) \Leftrightarrow y \in \partial f(x) \Leftrightarrow x \in \arg \min_z [f(z) - y^T z]$$

Свойства сопряжённой функции

Напомним, что для $f : \mathbb{R}^n \rightarrow \mathbb{R}$ функция, заданная как

$$f^*(y) = \max_x [y^T x - f(x)]$$

называется сопряжённой к f .

- Сопряжённые функции часто возникают в двойственных задачах, поскольку

$$-f^*(y) = \min_x [f(x) - y^T x]$$

- Если f замкнута и выпукла, то $f^{**} = f$. Кроме того,

$$x \in \partial f^*(y) \Leftrightarrow y \in \partial f(x) \Leftrightarrow x \in \arg \min_z [f(z) - y^T z]$$

- Если f строго выпукла, то

$$\nabla f^*(y) = \arg \min_z [f(z) - y^T z]$$

Свойства сопряжённой функции (доказательства)

Покажем, что $x \in \partial f^*(y) \Leftrightarrow y \in \partial f(x)$, предполагая, что f выпукла и замкнута.

- **Доказательство** $\Leftarrow$: Пусть $y \in \partial f(x)$. Тогда $x \in M_y$, где M_y — множество точек, в которых достигается максимум $y^T z - f(z)$ по z . Но

$$f^*(y) = \max_z \{y^T z - f(z)\} \quad \text{и} \quad \partial f^*(y) = \text{cl}(\text{conv}(\bigcup_{z \in M_y} \{z\})).$$

Поэтому $x \in \partial f^*(y)$.

Свойства сопряжённой функции (доказательства)

Покажем, что $x \in \partial f^*(y) \Leftrightarrow y \in \partial f(x)$, предполагая, что f выпукла и замкнута.

- **Доказательство** $\Leftarrow$: Пусть $y \in \partial f(x)$. Тогда $x \in M_y$, где M_y — множество точек, в которых достигается максимум $y^T z - f(z)$ по z . Но

$$f^*(y) = \max_z \{y^T z - f(z)\} \quad \text{и} \quad \partial f^*(y) = \text{cl}(\text{conv}(\bigcup_{z \in M_y} \{z\})).$$

Поэтому $x \in \partial f^*(y)$.

- **Доказательство** $\Rightarrow$: Из уже показанного выше, если $x \in \partial f^*(y)$, то $y \in \partial f^*(x)$, но $f^{**} = f$.

Свойства сопряжённой функции (доказательства)

Покажем, что $x \in \partial f^*(y) \Leftrightarrow y \in \partial f(x)$, предполагая, что f выпукла и замкнута.

- **Доказательство** $\Leftarrow$: Пусть $y \in \partial f(x)$. Тогда $x \in M_y$, где M_y — множество точек, в которых достигается максимум $y^T z - f(z)$ по z . Но

$$f^*(y) = \max_z \{y^T z - f(z)\} \quad \text{и} \quad \partial f^*(y) = \text{cl}(\text{conv}(\bigcup_{z \in M_y} \{z\})).$$

Поэтому $x \in \partial f^*(y)$.

- **Доказательство** $\Rightarrow$: Из уже показанного выше, если $x \in \partial f^*(y)$, то $y \in \partial f^*(x)$, но $f^{**} = f$.

Свойства сопряжённой функции (доказательства)

Покажем, что $x \in \partial f^*(y) \Leftrightarrow y \in \partial f(x)$, предполагая, что f выпукла и замкнута.

- **Доказательство** $\Leftarrow$: Пусть $y \in \partial f(x)$. Тогда $x \in M_y$, где M_y — множество точек, в которых достигается максимум $y^T z - f(z)$ по z . Но

$$f^*(y) = \max_z \{y^T z - f(z)\} \quad \text{и} \quad \partial f^*(y) = \text{cl}(\text{conv}(\bigcup_{z \in M_y} \{z\})).$$

Поэтому $x \in \partial f^*(y)$.

- **Доказательство** $\Rightarrow$: Из уже показанного выше, если $x \in \partial f^*(y)$, то $y \in \partial f^*(x)$, но $f^{**} = f$.

Очевидно, $y \in \partial f(x) \Leftrightarrow x \in \arg \min_z \{f(z) - y^T z\}$

Наконец, если f строго выпукла, то $f(z) - y^T z$ имеет единственную точку минимума по z , и этой точкой является $\nabla f^*(y)$.

Двойственный подъём (Dual ascent)

Двойственный (суб)градиентный метод

Даже если двойственную задачу не удаётся вывести в замкнутой форме, можно применять к ней градиентные или субградиентные методы.

Рассмотрим задачу:

$$\min_x f(x) \quad \text{при} \quad Ax = b$$

Двойственный (суб)градиентный метод

Даже если двойственную задачу не удаётся вывести в замкнутой форме, можно применять к ней градиентные или субградиентные методы.

Рассмотрим задачу:

$$\min_x f(x) \quad \text{при} \quad Ax = b$$

Её двойственная задача:

$$\max_u -f^*(-A^T u) - b^T u$$

где f^* — сопряжённая к f . Обозначив $g(u) = -f^*(-A^T u) - b^T u$, заметим:

$$\partial g(u) = A \partial f^*(-A^T u) - b$$

Двойственный (суб)градиентный метод

Даже если двойственную задачу не удаётся вывести в замкнутой форме, можно применять к ней градиентные или субградиентные методы.

Рассмотрим задачу:

$$\min_x f(x) \quad \text{при} \quad Ax = b$$

Её двойственная задача:

$$\max_u -f^*(-A^T u) - b^T u$$

где f^* — сопряжённая к f . Обозначив $g(u) = -f^*(-A^T u) - b^T u$, заметим:

$$\partial g(u) = A \partial f^*(-A^T u) - b$$

Следовательно, используя известные свойства сопряжённых функций,

$$\partial g(u) = Ax - b \quad \text{где} \quad x \in \arg \min_z [f(z) + u^T Az]$$

Двойственный (суб)градиентный метод

Даже если двойственную задачу не удаётся вывести в замкнутой форме, можно применять к ней градиентные или субградиентные методы.

Рассмотрим задачу:

$$\min_x f(x) \quad \text{при} \quad Ax = b$$

Её двойственная задача:

$$\max_u -f^*(-A^T u) - b^T u$$

где f^* — сопряжённая к f . Обозначив $g(u) = -f^*(-A^T u) - b^T u$, заметим:

$$\partial g(u) = A \partial f^*(-A^T u) - b$$

Следовательно, используя известные свойства сопряжённых функций,

$$\partial g(u) = Ax - b \quad \text{где} \quad x \in \arg \min_z [f(z) + u^T Az]$$

Dual ascent:

$$x_k \in \arg \min_x [f(x) + (u_{k-1})^T Ax]$$

$$u_k = u_{k-1} + \alpha_k (Ax_k - b)$$

- Шаги α_k , $k = 1, 2, 3, \dots$, выбираются стандартными способами.

Двойственный (суб)градиентный метод

Даже если двойственную задачу не удаётся вывести в замкнутой форме, можно применять к ней градиентные или субградиентные методы.

Рассмотрим задачу:

$$\min_x f(x) \quad \text{при} \quad Ax = b$$

Её двойственная задача:

$$\max_u -f^*(-A^T u) - b^T u$$

где f^* — сопряжённая к f . Обозначив $g(u) = -f^*(-A^T u) - b^T u$, заметим:

$$\partial g(u) = A \partial f^*(-A^T u) - b$$

Следовательно, используя известные свойства сопряжённых функций,

$$\partial g(u) = Ax - b \quad \text{где} \quad x \in \arg \min_z [f(z) + u^T Az]$$



Dual ascent:

$$x_k \in \arg \min_x [f(x) + (u_{k-1})^T Ax]$$

$$u_k = u_{k-1} + \alpha_k (Ax_k - b)$$

- Шаги α_k , $k = 1, 2, 3, \dots$, выбираются стандартными способами.
- Проксимальные градиентные методы и ускорение (acceleration) применяются так же, как обычно.

Наклоны f и f^*



Наклоны f и f^*

Предположим, что f — замкнутая выпуклая функция. Тогда f сильно выпукла с параметром $\mu \Leftrightarrow \nabla f^*$ липшицева с параметром $1/\mu$.

Наклоны f и f^*

Предположим, что f — замкнутая выпуклая функция. Тогда f сильно выпукла с параметром $\mu \Leftrightarrow \nabla f^*$ липшицева с параметром $1/\mu$.

Доказательство “ $\Rightarrow$ ”: Напомним, если g сильно выпукла и достигает минимума в точке x , то

$$g(y) \geq g(x) + \frac{\mu}{2} \|y - x\|^2, \quad \text{для всех } y$$

Наклоны f и f^*

Предположим, что f — замкнутая выпуклая функция. Тогда f сильно выпукла с параметром $\mu \Leftrightarrow \nabla f^*$ липшицева с параметром $1/\mu$.

Доказательство “ $\Rightarrow$ ”: Напомним, если g сильно выпукла и достигает минимума в точке x , то

$$g(y) \geq g(x) + \frac{\mu}{2} \|y - x\|^2, \quad \text{для всех } y$$

Поэтому, обозначив $x_u = \nabla f^*(u)$ и $x_v = \nabla f^*(v)$, получаем

$$f(x_v) - u^T x_v \geq f(x_u) - u^T x_u + \frac{\mu}{2} \|x_u - x_v\|^2$$

$$f(x_u) - v^T x_u \geq f(x_v) - v^T x_v + \frac{\mu}{2} \|x_u - x_v\|^2$$

Наклоны f и f^*

Предположим, что f — замкнутая выпуклая функция. Тогда f сильно выпукла с параметром $\mu \Leftrightarrow \nabla f^*$ липшицева с параметром $1/\mu$.

Доказательство “ $\Rightarrow$ ”: Напомним, если g сильно выпукла и достигает минимума в точке x , то

$$g(y) \geq g(x) + \frac{\mu}{2} \|y - x\|^2, \quad \text{для всех } y$$

Поэтому, обозначив $x_u = \nabla f^*(u)$ и $x_v = \nabla f^*(v)$, получаем

$$\begin{aligned} f(x_v) - u^T x_v &\geq f(x_u) - u^T x_u + \frac{\mu}{2} \|x_u - x_v\|^2 \\ f(x_u) - v^T x_u &\geq f(x_v) - v^T x_v + \frac{\mu}{2} \|x_u - x_v\|^2 \end{aligned}$$

Сложив эти неравенства, применив неравенство Коши-Буняковского-Шварца и перегруппировав слагаемые, получаем

$$\|x_u - x_v\|^2 \leq \frac{1}{\mu} \|u - v\|^2$$

Наклоны f и f^*

Доказательство “ $\Leftarrow$ ”: для простоты обозначим $g = f^*$ и $L = \frac{1}{\mu}$. Поскольку ∇g липшицева с константой L , функция $g_x(z) = g(z) - \nabla g(x)^T z$ также обладает этим свойством, поэтому

$$g_x(z) \leq g_x(y) + \nabla g_x(y)^T (z - y) + \frac{L}{2} \|z - y\|_2^2$$

Наклоны f и f^*

Доказательство “ $\Leftarrow$ ”: для простоты обозначим $g = f^*$ и $L = \frac{1}{\mu}$. Поскольку ∇g липшицева с константой L , функция $g_x(z) = g(z) - \nabla g(x)^T z$ также обладает этим свойством, поэтому

$$g_x(z) \leq g_x(y) + \nabla g_x(y)^T (z - y) + \frac{L}{2} \|z - y\|_2^2$$

Минимизируя обе части по z и перегруппировывая слагаемые, получаем

$$\frac{1}{2L} \|\nabla g(x) - \nabla g(y)\|^2 \leq g(y) - g(x) + \nabla g(x)^T (x - y)$$

Наклоны f и f^*

Доказательство “ $\Leftarrow$ ”: для простоты обозначим $g = f^*$ и $L = \frac{1}{\mu}$. Поскольку ∇g липшицева с константой L , функция $g_x(z) = g(z) - \nabla g(x)^T z$ также обладает этим свойством, поэтому

$$g_x(z) \leq g_x(y) + \nabla g_x(y)^T (z - y) + \frac{L}{2} \|z - y\|_2^2$$

Минимизируя обе части по z и перегруппировывая слагаемые, получаем

$$\frac{1}{2L} \|\nabla g(x) - \nabla g(y)\|^2 \leq g(y) - g(x) + \nabla g(x)^T (x - y)$$

Поменяв роли x и y и сложив неравенства, получаем

$$\frac{1}{L} \|\nabla g(x) - \nabla g(y)\|^2 \leq (\nabla g(x) - \nabla g(y))^T (x - y)$$

Наклоны f и f^*

Доказательство “ $\Leftarrow$ ”: для простоты обозначим $g = f^*$ и $L = \frac{1}{\mu}$. Поскольку ∇g липшицева с константой L , функция $g_x(z) = g(z) - \nabla g(x)^T z$ также обладает этим свойством, поэтому

$$g_x(z) \leq g_x(y) + \nabla g_x(y)^T (z - y) + \frac{L}{2} \|z - y\|_2^2$$

Минимизируя обе части по z и перегруппировывая слагаемые, получаем

$$\frac{1}{2L} \|\nabla g(x) - \nabla g(y)\|^2 \leq g(y) - g(x) + \nabla g(x)^T (x - y)$$

Поменяв роли x и y и сложив неравенства, получаем

$$\frac{1}{L} \|\nabla g(x) - \nabla g(y)\|^2 \leq (\nabla g(x) - \nabla g(y))^T (x - y)$$

Пусть $u = \nabla g(x)$, $v = \nabla g(y)$; тогда $x \in \partial g^*(u)$, $y \in \partial g^*(v)$, а предыдущее неравенство принимает вид $(x - y)^T (u - v) \geq \frac{\|u - v\|^2}{L}$, что и даёт требуемый результат.

Гарантии сходимости

Следующие результаты получаются из последнего факта и известных свойств градиентного спуска (gradient descent): (здесь мы игнорируем роль A , что соответствует случаю, когда все сингулярные значения A близки к 1. Более точно, шаги здесь должны быть: $\frac{\mu}{\sigma_{\max}(A)^2}$ (первый случай) и $\frac{2}{\frac{\sigma_{\max}(A)^2}{\mu} + \frac{\sigma_{\min}(A)^2}{L}}$ (второй случай).)

- Если f сильно выпукла с параметром μ , то двойственный градиентный подъём (dual gradient ascent) с постоянными шагами $\alpha_k = \mu$ сходится сублинейно со скоростью $O(\frac{1}{\epsilon})$.

Гарантии сходимости

Следующие результаты получаются из последнего факта и известных свойств градиентного спуска (gradient descent): (здесь мы игнорируем роль A , что соответствует случаю, когда все сингулярные значения A близки к 1. Более точно, шаги здесь должны быть: $\frac{\mu}{\sigma_{\max}(A)^2}$ (первый случай) и $\frac{2}{\frac{\sigma_{\max}(A)^2}{\mu} + \frac{\sigma_{\min}(A)^2}{L}}$ (второй случай).)

- Если f сильно выпукла с параметром μ , то двойственный градиентный подъём (dual gradient ascent) с постоянными шагами $\alpha_k = \mu$ сходится сублинейно со скоростью $O(\frac{1}{\epsilon})$.
- Если f сильно выпукла с параметром μ и ∇f липшицев с параметром L , то двойственный градиентный подъём (dual gradient ascent) с шагами $\alpha_k = \frac{2}{\frac{1}{\mu} + \frac{1}{L}}$ сходится линейно со скоростью $O(\log(\frac{1}{\epsilon}))$.

Гарантии сходимости

Следующие результаты получаются из последнего факта и известных свойств градиентного спуска (gradient descent): (здесь мы игнорируем роль A , что соответствует случаю, когда все сингулярные значения A близки к 1. Более точно, шаги здесь должны быть: $\frac{\mu}{\sigma_{\max}(A)^2}$ (первый случай) и $\frac{2}{\frac{\sigma_{\max}(A)^2}{\mu} + \frac{\sigma_{\min}(A)^2}{L}}$ (второй случай).)

- Если f сильно выпукла с параметром μ , то двойственный градиентный подъём (dual gradient ascent) с постоянными шагами $\alpha_k = \mu$ сходится сублинейно со скоростью $O(\frac{1}{\epsilon})$.
- Если f сильно выпукла с параметром μ и ∇f липшицев с параметром L , то двойственный градиентный подъём (dual gradient ascent) с шагами $\alpha_k = \frac{2}{\frac{1}{\mu} + \frac{1}{L}}$ сходится линейно со скоростью $O(\log(\frac{1}{\epsilon}))$.
- Заметим, что здесь описана сходимость в двойственной задаче. Сходимость в прямой задаче требует дополнительных предположений.

Скорости dual ascent: теория vs эмпирика

Dual ascent: теория vs эмпирика





Рис. 2: Слева — сходимость dual ascent для квадратичных задач с разной обусловленностью $\kappa = L/\mu$. Справа — эмпирический коэффициент сжатия ρ (наклон лог-графика) совпадает с теоретическим $(\kappa_d - 1)/(\kappa_d + 1)$, где κ_d — обусловленность двойственной задачи.

Пример: квадратичная минимизация с ограничениями-равенствами

$$f(x) = \frac{1}{2}x^T A x - b^T x \rightarrow \min_{x \in \mathbb{R}^n} \quad \text{при} \quad Cx = d, \quad A \in \mathbb{S}_+^n, C \in \mathbb{R}^{m \times n}, m < n.$$

Quadratic constrained optimization. $n=10, m=5, \mu=1, L=10$.




Нужно найти минимум квадратичной функции на некотором линейном подпространстве, заданном решением линейного уравнения $Cx = d$. Это задача условной оптимизации; начнём с сильно выпуклого случая.

Пример: квадратичная минимизация с ограничениями-равенствами

$$f(x) = \frac{1}{2}x^T A x - b^T x \rightarrow \min_{x \in \mathbb{R}^n} \quad \text{при} \quad Cx = d, \quad A \in \mathbb{S}_+^n, C \in \mathbb{R}^{m \times n}, m < n.$$

Quadratic constrained optimization. $n=10$, $m=5$, $\mu=0.001$, $L=10$.



Ситуация ухудшается, как только мы теряем сильную выпуклость: без сильной выпуклости прямой задачи двойственная функция перестаёт быть сильно вогнутой, и сходимость становится сублинейной — на практике крайне медленной.

Двойственная декомпозиция

Рассмотрим

$$\min_x \sum_{i=1}^B f_i(x_i) \quad \text{при} \quad Ax = b$$

Двойственная декомпозиция

Рассмотрим

$$\min_x \sum_{i=1}^B f_i(x_i) \quad \text{при} \quad Ax = b$$

Здесь $x = (x_1, \dots, x_B) \in \mathbb{R}^n$ разбивается на B блоков переменных, причём $x_i \in \mathbb{R}^{n_i}$. Матрицу A также можно разбить согласованным образом:

$$A = [A_1 \dots A_B], \quad \text{где} \quad A_i \in \mathbb{R}^{m \times n_i}$$

Двойственная декомпозиция

Рассмотрим

$$\min_x \sum_{i=1}^B f_i(x_i) \quad \text{при} \quad Ax = b$$

Здесь $x = (x_1, \dots, x_B) \in \mathbb{R}^n$ разбивается на B блоков переменных, причём $x_i \in \mathbb{R}^{n_i}$. Матрицу A также можно разбить согласованным образом:

$$A = [A_1 \dots A_B], \quad \text{где} \quad A_i \in \mathbb{R}^{m \times n_i}$$

Простое, но важное наблюдение при вычислении субградиента: минимизация раскладывается на B отдельных задач:

$$x^{\text{new}} \in \arg \min_x \left(\sum_{i=1}^B f_i(x_i) + u^T Ax \right)$$

$$\Rightarrow x_i^{\text{new}} \in \arg \min_{x_i} (f_i(x_i) + u^T A_i x_i), \quad i = 1, \dots, B$$

$$x_i^k \in \arg \min_{x_i} (f_i(x_i) + (u^{k-1})^T A_i x_i), \quad i = 1, \dots, B$$

$$u^k = u^{k-1} + \alpha_k \left(\sum_{i=1}^B A_i x_i^k - b \right)$$

Двойственная декомпозиция

Рассмотрим

$$\min_x \sum_{i=1}^B f_i(x_i) \quad \text{при} \quad Ax = b$$

Здесь $x = (x_1, \dots, x_B) \in \mathbb{R}^n$ разбивается на B блоков переменных, причём $x_i \in \mathbb{R}^{n_i}$. Матрицу A также можно разбить согласованным образом:

$$A = [A_1 \dots A_B], \text{ где } A_i \in \mathbb{R}^{m \times n_i}$$

Простое, но важное наблюдение при вычислении субградиента: минимизация раскладывается на B отдельных задач:

$$x^{\text{new}} \in \arg \min_x \left(\sum_{i=1}^B f_i(x_i) + u^T Ax \right)$$

$$\Rightarrow x_i^{\text{new}} \in \arg \min_{x_i} (f_i(x_i) + u^T A_i x_i), \quad i = 1, \dots, B$$

$$x_i^k \in \arg \min_{x_i} (f_i(x_i) + (u^{k-1})^T A_i x_i), \quad i = 1, \dots, B$$

$$u^k = u^{k-1} + \alpha_k \left(\sum_{i=1}^B A_i x_i^k - b \right)$$

Параллельная интерпретация:

- **Рассылка (broadcast):** разослать u и параллельно найти x_i .

Двойственная декомпозиция

Рассмотрим

$$\min_x \sum_{i=1}^B f_i(x_i) \quad \text{при} \quad Ax = b$$

Здесь $x = (x_1, \dots, x_B) \in \mathbb{R}^n$ разбивается на B блоков переменных, причём $x_i \in \mathbb{R}^{n_i}$. Матрицу A также можно разбить согласованным образом:

$$A = [A_1 \dots A_B], \quad \text{где} \quad A_i \in \mathbb{R}^{m \times n_i}$$

Простое, но важное наблюдение при вычислении субградиента: минимизация раскладывается на B отдельных задач:

$$x^{\text{new}} \in \arg \min_x \left(\sum_{i=1}^B f_i(x_i) + u^T Ax \right)$$

$$\Rightarrow x_i^{\text{new}} \in \arg \min_{x_i} (f_i(x_i) + u^T A_i x_i), \quad i = 1, \dots, B$$

$$x_i^k \in \arg \min_{x_i} (f_i(x_i) + (u^{k-1})^T A_i x_i), \quad i = 1, \dots, B$$

$$u^k = u^{k-1} + \alpha_k \left(\sum_{i=1}^B A_i x_i^k - b \right)$$

Параллельная интерпретация:

- **Рассылка (broadcast):** разослать u и параллельно найти x_i .
- **Сбор (gather):** собрать $A_i x_i$ и обновить u .

Dual decomposition в действии

Распределённая аллокация ресурса: 8 агентов, $\sum x_i = 5.0$




Рис. 3: $B = 8$ агентов с локальными квадратичными целями $f_i(x_i) = \frac{1}{2}a_i x_i^2 - b_i x_i$ делят общий ресурс $\sum_i x_i = 5$. Слева — динамика цены λ_k ; в центре — локальные решения агентов в закрытой форме $x_i^{(k)} = (b_i - \lambda_k)/a_i$; справа — сходимость к глобальному оптимуму. Алгоритм сходится за единицы итераций.

Ограничения-неравенства

Рассмотрим задачу оптимизации:

$$\min_x \sum_{i=1}^B f_i(x_i) \quad \text{при} \quad \sum_{i=1}^B A_i x_i \leq b$$

Ограничения-неравенства

Рассмотрим задачу оптимизации:

$$\min_x \sum_{i=1}^B f_i(x_i) \quad \text{при} \quad \sum_{i=1}^B A_i x_i \leq b$$

Используя **двойственную декомпозицию (dual decomposition)**, а именно **метод проецируемого субградиента (projected subgradient method)**, итерации можно записать так:

- Шаг обновления прямой переменной:

$$x_i^k \in \arg \min_{x_i} \left[f_i(x_i) + (u^{k-1})^T A_i x_i \right], \quad i = 1, \dots, B$$

Ограничения-неравенства

Рассмотрим задачу оптимизации:

$$\min_x \sum_{i=1}^B f_i(x_i) \quad \text{при} \quad \sum_{i=1}^B A_i x_i \leq b$$

Используя **двойственную декомпозицию (dual decomposition)**, а именно **метод проецируемого субградиента (projected subgradient method)**, итерации можно записать так:

- Шаг обновления прямой переменной:

$$x_i^k \in \arg \min_{x_i} \left[f_i(x_i) + (u^{k-1})^T A_i x_i \right], \quad i = 1, \dots, B$$

- Шаг обновления двойственной переменной:

$$u^k = \left(u^{k-1} + \alpha_k \left(\sum_{i=1}^B A_i x_i^k - b \right) \right)_+$$

где $(u)_+$ обозначает положительную часть u , то есть $(u_+)_i = \max\{0, u_i\}$ для $i = 1, \dots, m$.

Интерпретация координации цен (price coordination, Vandenberghe)

- **Обзор системы:** рассмотрим систему с B агентами, где каждый агент независимо выбирает свою переменную решения x_i , определяющую распределение его товаров.

Интерпретация координации цен (price coordination, Vandenberghe)

- **Обзор системы:** рассмотрим систему с B агентами, где каждый агент независимо выбирает свою переменную решения x_i , определяющую распределение его товаров.
- **Ресурсные ограничения:** это ограничения на общие ресурсы, заданные строками A . Каждая компонента двойственной переменной u_j задаёт цену ресурса j .

Интерпретация координации цен (price coordination, Vandenberghe)

- **Обзор системы:** рассмотрим систему с B агентами, где каждый агент независимо выбирает свою переменную решения x_i , определяющую распределение его товаров.
- **Ресурсные ограничения:** это ограничения на общие ресурсы, заданные строками A . Каждая компонента двойственной переменной u_j задаёт цену ресурса j .
- **Правило обновления двойственной переменной:**

$$u_j^{\text{new}} = (u_j - ts_j)_+, \quad j = 1, \dots, m$$

где $s = b - \sum_{i=1}^B A_i x_i$ задаёт slack-переменные.

Интерпретация координации цен (price coordination, Vandenberghe)

- **Обзор системы:** рассмотрим систему с B агентами, где каждый агент независимо выбирает свою переменную решения x_i , определяющую распределение его товаров.
- **Ресурсные ограничения:** это ограничения на общие ресурсы, заданные строками A . Каждая компонента двойственной переменной u_j задаёт цену ресурса j .
- **Правило обновления двойственной переменной:**

$$u_j^{\text{new}} = (u_j - ts_j)_+, \quad j = 1, \dots, m$$

где $s = b - \sum_{i=1}^B A_i x_i$ задаёт slack-переменные.

- **Корректировка цен:**

Интерпретация координации цен (price coordination, Vandenberghe)

- **Обзор системы:** рассмотрим систему с B агентами, где каждый агент независимо выбирает свою переменную решения x_i , определяющую распределение его товаров.
- **Ресурсные ограничения:** это ограничения на общие ресурсы, заданные строками A . Каждая компонента двойственной переменной u_j задаёт цену ресурса j .

- **Правило обновления двойственной переменной:**

$$u_j^{\text{new}} = (u_j - ts_j)_+, \quad j = 1, \dots, m$$

где $s = b - \sum_{i=1}^B A_i x_i$ задаёт slack-переменные.

- **Корректировка цен:**
 - **Увеличивать** цену u_j , если ресурс j перегружен ($s_j < 0$).

Интерпретация координации цен (price coordination, Vandenberghe)

- **Обзор системы:** рассмотрим систему с B агентами, где каждый агент независимо выбирает свою переменную решения x_i , определяющую распределение его товаров.
- **Ресурсные ограничения:** это ограничения на общие ресурсы, заданные строками A . Каждая компонента двойственной переменной u_j задаёт цену ресурса j .

- **Правило обновления двойственной переменной:**

$$u_j^{\text{new}} = (u_j - ts_j)_+, \quad j = 1, \dots, m$$

где $s = b - \sum_{i=1}^B A_i x_i$ задаёт slack-переменные.

- **Корректировка цен:**
 - **Увеличивать цену** u_j , если ресурс j перегружен ($s_j < 0$).
 - **Уменьшать цену** u_j , если ресурс j недоиспользован ($s_j > 0$).

Интерпретация координации цен (price coordination, Vandenberghe)

- **Обзор системы:** рассмотрим систему с B агентами, где каждый агент независимо выбирает свою переменную решения x_i , определяющую распределение его товаров.
- **Ресурсные ограничения:** это ограничения на общие ресурсы, заданные строками A . Каждая компонента двойственной переменной u_j задаёт цену ресурса j .

- **Правило обновления двойственной переменной:**

$$u_j^{\text{new}} = (u_j - ts_j)_+, \quad j = 1, \dots, m$$

где $s = b - \sum_{i=1}^B A_i x_i$ задаёт slack-переменные.

- **Корректировка цен:**

- **Увеличивать цену** u_j , если ресурс j перегружен ($s_j < 0$).
- **Уменьшать цену** u_j , если ресурс j недоиспользован ($s_j > 0$).
- **Не позволять ценам становиться отрицательными;** поэтому используется положительная часть $(\cdot)_+$.

Метод дополненного лагранжиана (Augmented Lagrangian method)

Метод дополненного лагранжиана, или метод множителей

Недостаток двойственного подъёма (dual ascent): для сходимости нужны сильные условия. Метод дополненного лагранжиана преобразует прямую задачу:

$$\begin{aligned} \min_x \quad & f(x) + \frac{\rho}{2} \|Ax - b\|^2 \\ \text{s.t.} \quad & Ax = b \end{aligned}$$

Метод дополненного лагранжиана, или метод множителей

Недостаток двойственного подъёма (dual ascent): для сходимости нужны сильные условия. Метод дополненного лагранжиана преобразует прямую задачу:

$$\begin{aligned} \min_x \quad & f(x) + \frac{\rho}{2} \|Ax - b\|^2 \\ \text{s.t.} \quad & Ax = b \end{aligned}$$

где $\rho > 0$ — параметр. Эта постановка, очевидно, эквивалентна исходной задаче. Задача сильно выпукла, если матрица A имеет полный столбцовый ранг.

Метод дополненного лагранжиана, или метод множителей

Недостаток двойственного подъёма (dual ascent): для сходимости нужны сильные условия. Метод дополненного лагранжиана преобразует прямую задачу:

$$\begin{aligned} \min_x \quad & f(x) + \frac{\rho}{2} \|Ax - b\|^2 \\ \text{s.t.} \quad & Ax = b \end{aligned}$$

где $\rho > 0$ — параметр. Эта постановка, очевидно, эквивалентна исходной задаче. Задача сильно выпукла, если матрица A имеет полный столбцовый ранг.

Двойственный градиентный подъём: итерационные обновления задаются как

$$\begin{aligned} x_k &= \arg \min_x \left[f(x) + (u_{k-1})^T Ax + \frac{\rho}{2} \|Ax - b\|^2 \right] \\ u_k &= u_{k-1} + \rho(Ax_k - b) \end{aligned}$$

Метод дополненного лагранжиана, или метод множителей

Обратите внимание на выбор шага $\alpha_k = \rho$ в двойственном алгоритме. Почему?

Поскольку x_k является точкой минимума функции

$$f(x) + (u_{k-1})^T Ax + \frac{\rho}{2} \|Ax - b\|^2$$

по x , имеем условие стационарности:

$$0 \in \partial f(x_k) + A^T (u_{k-1} + \rho(Ax_k - b))$$

которое упрощается до:

$$0 \in \partial f(x_k) + A^T u_k$$

Метод дополненного лагранжиана, или метод множителей

Обратите внимание на выбор шага $\alpha_k = \rho$ в двойственном алгоритме. Почему?

Поскольку x_k является точкой минимума функции

$$f(x) + (u_{k-1})^T Ax + \frac{\rho}{2} \|Ax - b\|^2$$

по x , имеем условие стационарности:

$$0 \in \partial f(x_k) + A^T (u_{k-1} + \rho(Ax_k - b))$$

которое упрощается до:

$$0 \in \partial f(x_k) + A^T u_k$$

Это условие стационарности для исходной прямой задачи; при мягких условиях $Ax_k - b \rightarrow 0$ при $k \rightarrow \infty$, поэтому условия ККТ выполняются в пределе, а x_k и u_k сходятся к решениям.

- **Преимущество:** расширенный лагранжиан даёт лучшую сходимость.

Метод дополненного лагранжиана, или метод множителей

Обратите внимание на выбор шага $\alpha_k = \rho$ в двойственном алгоритме. Почему?

Поскольку x_k является точкой минимума функции

$$f(x) + (u_{k-1})^T Ax + \frac{\rho}{2} \|Ax - b\|^2$$

по x , имеем условие стационарности:

$$0 \in \partial f(x_k) + A^T (u_{k-1} + \rho(Ax_k - b))$$

которое упрощается до:

$$0 \in \partial f(x_k) + A^T u_k$$


Это условие стационарности для исходной прямой задачи; при мягких условиях $Ax_k - b \rightarrow 0$ при $k \rightarrow \infty$, поэтому условия ККТ выполняются в пределе, а x_k и u_k сходятся к решениям.

- **Преимущество:** расширенный лагранжиан даёт лучшую сходимость.
- **Недостаток:** мы теряем декомпозируемость! (сепарабельность нарушается)

Пример: квадратичная минимизация с ограничениями-равенствами

$$f(x) = \frac{1}{2}x^T A x - b^T x \rightarrow \min_{x \in \mathbb{R}^n} \quad \text{при} \quad Cx = d, \quad A \in \mathbb{S}_+^n, C \in \mathbb{R}^{m \times n}, m < n.$$

Quadratic constrained optimization. $n=10, m=5, \mu=1, L=10$.




В сильно выпуклом случае ALM даёт быструю линейную сходимость уже при умеренных ρ — за счёт штрафа $\frac{\rho}{2}\|Cx - d\|^2$ задача становится «более выпуклой».

Пример: квадратичная минимизация с ограничениями-равенствами

$$f(x) = \frac{1}{2}x^T A x - b^T x \rightarrow \min_{x \in \mathbb{R}^n} \quad \text{при} \quad Cx = d, \quad A \in \mathbb{S}_+^n, C \in \mathbb{R}^{m \times n}, m < n.$$

Quadratic constrained optimization. $n=10, m=5, \mu=0.001, L=10$.



При потере сильной выпуклости ALM продолжает сходиться (за счёт штрафа $\frac{\rho}{2}\|Cx - d\|^2$, который сам по себе делает расширенную задачу сильно выпуклой при C полного ранга), тогда как обычный Dual ascent — уже нет.

Введение в ADMM

Метод переменных направлений множителей (ADMM)

Метод переменных направлений множителей (ADMM) стремится совместить преимущества обоих подходов. Рассмотрим следующую задачу оптимизации:

Минимизировать функцию:

$$\min_{x,z} f(x) + g(z)$$

$$\text{s.t. } Ax + Bz = c$$

Метод переменных направлений множителей (ADMM)

Метод переменных направлений множителей (ADMM) стремится совместить преимущества обоих подходов. Рассмотрим следующую задачу оптимизации:

Минимизировать функцию:

$$\min_{x,z} f(x) + g(z)$$

$$\text{s.t. } Ax + Bz = c$$

Добавим к целевой функции штраф за нарушение ограничения:

$$\min_{x,z} f(x) + g(z) + \frac{\rho}{2} \|Ax + Bz - c\|^2$$

$$\text{s.t. } Ax + Bz = c$$

Метод переменных направлений множителей (ADMM)

Метод переменных направлений множителей (ADMM) стремится совместить преимущества обоих подходов. Рассмотрим следующую задачу оптимизации:

Минимизировать функцию:

$$\min_{x,z} f(x) + g(z)$$

$$\text{s.t. } Ax + Bz = c$$

Добавим к целевой функции штраф за нарушение ограничения:

$$\min_{x,z} f(x) + g(z) + \frac{\rho}{2} \|Ax + Bz - c\|^2$$

$$\text{s.t. } Ax + Bz = c$$

где $\rho > 0$ — параметр. Расширенный лагранжиан для этой задачи определяется как

$$L_\rho(x, z, u) = f(x) + g(z) + u^T(Ax + Bz - c) + \frac{\rho}{2} \|Ax + Bz - c\|^2$$

Метод переменных направлений множителей (ADMM)

ADMM повторяет следующие шаги для $k = 1, 2, 3, \dots$:

1. Обновить x :

$$x_k = \arg \min_x L_\rho(x, z_{k-1}, u_{k-1})$$

Метод переменных направлений множителей (ADMM)

ADMM повторяет следующие шаги для $k = 1, 2, 3, \dots$:

1. Обновить x :

$$x_k = \arg \min_x L_\rho(x, z_{k-1}, u_{k-1})$$

2. Обновить z :

$$z_k = \arg \min_z L_\rho(x_k, z, u_{k-1})$$

Метод переменных направлений множителей (ADMM)

ADMM повторяет следующие шаги для $k = 1, 2, 3, \dots$:

1. Обновить x :

$$x_k = \arg \min_x L_\rho(x, z_{k-1}, u_{k-1})$$

2. Обновить z :

$$z_k = \arg \min_z L_\rho(x_k, z, u_{k-1})$$

3. Обновить u :

$$u_k = u_{k-1} + \rho(Ax_k + Bz_k - c)$$

Метод переменных направлений множителей (ADMM)

ADMM повторяет следующие шаги для $k = 1, 2, 3, \dots$:

1. Обновить x :

$$x_k = \arg \min_x L_\rho(x, z_{k-1}, u_{k-1})$$

2. Обновить z :

$$z_k = \arg \min_z L_\rho(x_k, z, u_{k-1})$$

3. Обновить u :

$$u_k = u_{k-1} + \rho(Ax_k + Bz_k - c)$$

Метод переменных направлений множителей (ADMM)

ADMM повторяет следующие шаги для $k = 1, 2, 3, \dots$:

1. Обновить x :

$$x_k = \arg \min_x L_\rho(x, z_{k-1}, u_{k-1})$$

2. Обновить z :

$$z_k = \arg \min_z L_\rho(x_k, z, u_{k-1})$$

3. Обновить u :

$$u_k = u_{k-1} + \rho(Ax_k + Bz_k - c)$$

Замечание: обычный метод множителей заменил бы первые два шага совместной минимизацией:

$$(x^{(k)}, z^{(k)}) = \arg \min_{x, z} L_\rho(x, z, u^{(k-1)})$$

Пример: метод альтернирующих проекций

Рассмотрим задачу поиска точки в пересечении выпуклых множеств $U, V \subseteq \mathbb{R}^n$:

$$\min_x I_U(x) + I_V(x)$$

Чтобы привести эту задачу к форме ADMM, запишем её как


$$\min_{x,z} I_U(x) + I_V(z) \quad \text{при} \quad x - z = 0$$

Каждый цикл ADMM включает две проекции:

$$x_k = P_U(z_{k-1} - w_{k-1})$$

$$z_k = P_V(x_k + w_{k-1})$$

$$w_k = w_{k-1} + x_k - z_k$$



Пример: LASSO через ADMM

Задача LASSO:

$$\min_x \frac{1}{2} \|Ax - b\|^2 + \lambda \|x\|_1.$$

Расщепляем переменную $x = z$, тогда $f(x) = \frac{1}{2} \|Ax - b\|^2$ — гладкая квадратичная, $g(z) = \lambda \|z\|_1$ — негладкая. Шаги ADMM (в скейлинге u):

$$x_{k+1} = (A^T A + \rho I)^{-1} (A^T b + \rho(z_k - u_k)),$$

$$z_{k+1} = S_{\lambda/\rho}(x_{k+1} + u_k),$$


$$u_{k+1} = u_k + (x_{k+1} - z_{k+1}),$$

где $S_\tau(v) = \text{sign}(v) \cdot \max(|v| - \tau, 0)$ — оператор soft-thresholding.

LASSO через ADMM: сравнение с ISTA / FISTA

LASSO через ADMM: split на x (квадратичная задача) и z (soft-threshold)

LASSO: $m = 200$, $n = 500$, $\|x^*\|_0 = 25$



ADMM: prim/dual residuals




Рис. 4: $m = 200$, $n = 500$, $\|x^*\|_0 = 25$. ADMM выигрывает за счёт замкнутой формы для z -шага (soft-thresholding) и быстрого затухания primal/dual residuals — стандартный диагностический инструмент ADMM.

- Ryan Tibshirani. Convex Optimization 10-725

- Ryan Tibshirani. Convex Optimization 10-725
- Boyd S., Vandenberghe L. *Convex Optimization*, Cambridge University Press, 2004 (гл. 5).

- Ryan Tibshirani. Convex Optimization 10-725
- Boyd S., Vandenberghe L. *Convex Optimization*, Cambridge University Press, 2004 (гл. 5).
- Boyd S., Parikh N., Chu E., Peleato B., Eckstein J. *Distributed Optimization and Statistical Learning via the Alternating Direction Method of Multipliers*, Foundations and Trends in ML, 2011.