



Градиентные методы для задач с ограничениями. Метод проекции градиента. Метод Франк-Вульфа. Метод зеркального спуска

Даня Меркулов

Методы Оптимизации

МФТИ





# Условная оптимизация

## Безусловная оптимизация

$$\min_{x \in \mathbb{R}^n} f(x)$$

- Любая точка  $x_0 \in \mathbb{R}^n$  допустима и может быть решением.

# Условная оптимизация

## Безусловная оптимизация

$$\min_{x \in \mathbb{R}^n} f(x)$$

- Любая точка  $x_0 \in \mathbb{R}^n$  допустима и может быть решением.

# Условная оптимизация

## Безусловная оптимизация

$$\min_{x \in \mathbb{R}^n} f(x)$$

- Любая точка  $x_0 \in \mathbb{R}^n$  допустима и может быть решением.

## Условная оптимизация

$$\min_{x \in S} f(x)$$

- Не все  $x \in \mathbb{R}^n$  допустимы и могут быть решением.

# Условная оптимизация

## Безусловная оптимизация

$$\min_{x \in \mathbb{R}^n} f(x)$$

- Любая точка  $x_0 \in \mathbb{R}^n$  допустима и может быть решением.

## Условная оптимизация

$$\min_{x \in S} f(x)$$

- Не все  $x \in \mathbb{R}^n$  допустимы и могут быть решением.
- Решение должно лежать внутри множества  $S$ .

# Условная оптимизация

## Безусловная оптимизация

$$\min_{x \in \mathbb{R}^n} f(x)$$

- Любая точка  $x_0 \in \mathbb{R}^n$  допустима и может быть решением.

## Условная оптимизация

$$\min_{x \in S} f(x)$$

- Не все  $x \in \mathbb{R}^n$  допустимы и могут быть решением.
- Решение должно лежать внутри множества  $S$ .
- Пример:

$$\frac{1}{2} \|Ax - b\|_2^2 \rightarrow \min_{\|x\|_2^2 \leq 1}$$

# Условная оптимизация

## Безусловная оптимизация

$$\min_{x \in \mathbb{R}^n} f(x)$$

- Любая точка  $x_0 \in \mathbb{R}^n$  допустима и может быть решением.

## Условная оптимизация

$$\min_{x \in S} f(x)$$

- Не все  $x \in \mathbb{R}^n$  допустимы и могут быть решением.
- Решение должно лежать внутри множества  $S$ .
- Пример:

$$\frac{1}{2} \|Ax - b\|_2^2 \rightarrow \min_{\|x\|_2^2 \leq 1}$$

# Условная оптимизация

## Безусловная оптимизация

$$\min_{x \in \mathbb{R}^n} f(x)$$

- Любая точка  $x_0 \in \mathbb{R}^n$  допустима и может быть решением.

## Условная оптимизация

$$\min_{x \in S} f(x)$$

- Не все  $x \in \mathbb{R}^n$  допустимы и могут быть решением.
- Решение должно лежать внутри множества  $S$ .
- Пример:

$$\frac{1}{2} \|Ax - b\|_2^2 \rightarrow \min_{\|x\|_2^2 \leq 1}$$

Градиентный спуск — отличный способ решения безусловных задач

$$x_{k+1} = x_k - \alpha_k \nabla f(x_k)$$

(GD)

Можно ли адаптировать градиентный спуск для задачи с ограничениями?

# Условная оптимизация

## Безусловная оптимизация

$$\min_{x \in \mathbb{R}^n} f(x)$$

- Любая точка  $x_0 \in \mathbb{R}^n$  допустима и может быть решением.

## Условная оптимизация

$$\min_{x \in S} f(x)$$

- Не все  $x \in \mathbb{R}^n$  допустимы и могут быть решением.
- Решение должно лежать внутри множества  $S$ .
- Пример:

$$\frac{1}{2} \|Ax - b\|_2^2 \rightarrow \min_{\|x\|_2^2 \leq 1}$$

Градиентный спуск — отличный способ решения безусловных задач

$$x_{k+1} = x_k - \alpha_k \nabla f(x_k) \quad (\text{GD})$$

Можно ли адаптировать градиентный спуск для задачи с ограничениями?

**Да.** Для этого нужно использовать проекции, чтобы обеспечить допустимость на каждой итерации.

## Пример: adversarial white-box attacks





Рис. 1: Источник

- Математически нейронная сеть — это функция  $f(w; x)$


$$\min_{\delta} \text{size}(\delta) \quad \text{s.t.} \quad \text{pred}[f(w; x + \delta)] \neq y$$

или

$$\max_{\delta} l(w; x + \delta, y) \quad \text{s.t.} \quad \text{size}(\delta) \leq \epsilon, \quad 0 \leq x + \delta \leq 1$$



## Пример: adversarial white-box attacks



- Математически нейронная сеть — это функция  $f(w; x)$
- Обычно вход  $x$  задан, а веса сети  $w$  оптимизируются


$$\min_{\delta} \text{size}(\delta) \quad \text{s.t.} \quad \text{pred}[f(w; x + \delta)] \neq y$$

или

$$\max_{\delta} l(w; x + \delta, y) \quad \text{s.t.} \quad \text{size}(\delta) \leq \epsilon, \quad 0 \leq x + \delta \leq 1$$

Рис. 1: Источник

## Пример: adversarial white-box attacks



- Математически нейронная сеть — это функция  $f(w; x)$
- Обычно вход  $x$  задан, а веса сети  $w$  оптимизируются
- Но можно зафиксировать веса  $w$  и оптимизировать  $x$ !

$$\min_{\delta} \text{size}(\delta) \quad \text{s.t.} \quad \text{pred}[f(w; x + \delta)] \neq y$$

или

$$\max_{\delta} l(w; x + \delta, y) \quad \text{s.t.} \quad \text{size}(\delta) \leq \epsilon, \quad 0 \leq x + \delta \leq 1$$

Рис. 1: Источник

## Идея метода проекции градиента




Рис. 2: Предположим, мы стартуем из точки  $x_k$ .

## Идея метода проекции градиента




Рис. 3: И движемся в направлении  $-\nabla f(x_k)$ .

## Идея метода проекции градиента

$$y_k = x_k - \alpha_k \nabla f(x_k)$$




Рис. 4: Иногда мы можем оказаться за пределами допустимого множества.

## Идея метода проекции градиента




Рис. 5: Решим эту маленькую проблему с помощью проекции!

## Идея метода проекции градиента

$$x_{k+1} = \text{proj}_S(x_k - \alpha_k \nabla f(x_k)) \Leftrightarrow \begin{aligned} y_k &= x_k - \alpha_k \nabla f(x_k) \\ x_{k+1} &= \text{proj}_S(y_k) \end{aligned}$$

$$\text{П}_S(y_k)$$

$$y_k = x_k - \alpha_k \nabla f(x_k)$$





Рис. 6: Иллюстрация метода проекции градиента

## Проекция

## Проекция

Расстояние  $d$  от точки  $\mathbf{y} \in \mathbb{R}^n$  до замкнутого множества  $S \subset \mathbb{R}^n$ :

$$d(\mathbf{y}, S, \|\cdot\|) = \inf\{\|\mathbf{x} - \mathbf{y}\| \mid \mathbf{x} \in S\}$$



## Проекция

Расстояние  $d$  от точки  $\mathbf{y} \in \mathbb{R}^n$  до замкнутого множества  $S \subset \mathbb{R}^n$ :

$$d(\mathbf{y}, S, \|\cdot\|) = \inf\{\|\mathbf{x} - \mathbf{y}\| \mid \mathbf{x} \in S\}$$

Мы сосредоточимся на евклидовой проекции (возможны и другие варианты) точки  $\mathbf{y} \in \mathbb{R}^n$  на множество  $S \subseteq \mathbb{R}^n$  — это точка  $\text{proj}_S(\mathbf{y}) \in S$ :

$$\text{proj}_S(\mathbf{y}) = \underset{\mathbf{x} \in S}{\operatorname{argmin}} \frac{1}{2} \|\mathbf{x} - \mathbf{y}\|_2^2$$

## Проекция

Расстояние  $d$  от точки  $\mathbf{y} \in \mathbb{R}^n$  до замкнутого множества  $S \subset \mathbb{R}^n$ :

$$d(\mathbf{y}, S, \|\cdot\|) = \inf\{\|\mathbf{x} - \mathbf{y}\| \mid \mathbf{x} \in S\}$$

Мы сосредоточимся на евклидовой проекции (возможны и другие варианты) точки  $\mathbf{y} \in \mathbb{R}^n$  на множество  $S \subseteq \mathbb{R}^n$  — это точка  $\text{proj}_S(\mathbf{y}) \in S$ :

$$\text{proj}_S(\mathbf{y}) = \underset{\mathbf{x} \in S}{\operatorname{argmin}} \frac{1}{2} \|\mathbf{x} - \mathbf{y}\|_2^2$$

- **Достаточные условия существования проекции.** Если  $S \subseteq \mathbb{R}^n$  — замкнутое множество, то проекция на множество  $S$  существует для любой точки.

## Проекция

Расстояние  $d$  от точки  $\mathbf{y} \in \mathbb{R}^n$  до замкнутого множества  $S \subset \mathbb{R}^n$ :

$$d(\mathbf{y}, S, \|\cdot\|) = \inf\{\|\mathbf{x} - \mathbf{y}\| \mid \mathbf{x} \in S\}$$

Мы сосредоточимся на евклидовой проекции (возможны и другие варианты) точки  $\mathbf{y} \in \mathbb{R}^n$  на множество  $S \subseteq \mathbb{R}^n$  — это точка  $\text{proj}_S(\mathbf{y}) \in S$ :

$$\text{proj}_S(\mathbf{y}) = \operatorname{argmin}_{\mathbf{x} \in S} \frac{1}{2} \|\mathbf{x} - \mathbf{y}\|_2^2$$

- **Достаточные условия существования проекции.** Если  $S \subseteq \mathbb{R}^n$  — замкнутое множество, то проекция на множество  $S$  существует для любой точки.
- **Достаточные условия единственности проекции.** Если  $S \subseteq \mathbb{R}^n$  — замкнутое выпуклое множество, то проекция на множество  $S$  единственна для любой точки.

## Проекция

Расстояние  $d$  от точки  $\mathbf{y} \in \mathbb{R}^n$  до замкнутого множества  $S \subset \mathbb{R}^n$ :

$$d(\mathbf{y}, S, \|\cdot\|) = \inf\{\|\mathbf{x} - \mathbf{y}\| \mid \mathbf{x} \in S\}$$

Мы сосредоточимся на евклидовой проекции (возможны и другие варианты) точки  $\mathbf{y} \in \mathbb{R}^n$  на множество  $S \subseteq \mathbb{R}^n$  — это точка  $\text{proj}_S(\mathbf{y}) \in S$ :

$$\text{proj}_S(\mathbf{y}) = \underset{\mathbf{x} \in S}{\operatorname{argmin}} \frac{1}{2} \|\mathbf{x} - \mathbf{y}\|_2^2$$

- **Достаточные условия существования проекции.** Если  $S \subseteq \mathbb{R}^n$  — замкнутое множество, то проекция на множество  $S$  существует для любой точки.
- **Достаточные условия единственности проекции.** Если  $S \subseteq \mathbb{R}^n$  — замкнутое выпуклое множество, то проекция на множество  $S$  единственна для любой точки.
- Если множество открытое, а точка лежит вне этого множества, то её проекция на него может не существовать.

## Проекция

Расстояние  $d$  от точки  $\mathbf{y} \in \mathbb{R}^n$  до замкнутого множества  $S \subset \mathbb{R}^n$ :

$$d(\mathbf{y}, S, \|\cdot\|) = \inf\{\|\mathbf{x} - \mathbf{y}\| \mid \mathbf{x} \in S\}$$

Мы сосредоточимся на евклидовой проекции (возможны и другие варианты) точки  $\mathbf{y} \in \mathbb{R}^n$  на множество  $S \subseteq \mathbb{R}^n$  — это точка  $\text{proj}_S(\mathbf{y}) \in S$ :

$$\text{proj}_S(\mathbf{y}) = \underset{\mathbf{x} \in S}{\operatorname{argmin}} \frac{1}{2} \|\mathbf{x} - \mathbf{y}\|_2^2$$

- **Достаточные условия существования проекции.** Если  $S \subseteq \mathbb{R}^n$  — замкнутое множество, то проекция на множество  $S$  существует для любой точки.
- **Достаточные условия единственности проекции.** Если  $S \subseteq \mathbb{R}^n$  — замкнутое выпуклое множество, то проекция на множество  $S$  единственна для любой точки.
- Если множество открытое, а точка лежит вне этого множества, то её проекция на него может не существовать.
- Если точка принадлежит множеству, то её проекция — это она сама.

## Критерий проекции (неравенство Бурбаки-Чейни-Гольдштейна)

### Theorem

Пусть  $S \subseteq \mathbb{R}^n$  — замкнутое и выпуклое множество,  $\forall x \in S, y \in \mathbb{R}^n$ . Тогда

$$\langle y - \text{proj}_S(y), x - \text{proj}_S(y) \rangle \leq 0 \quad (1)$$

$$\|x - \text{proj}_S(y)\|^2 + \|y - \text{proj}_S(y)\|^2 \leq \|x - y\|^2 \quad (2)$$

1.  $\text{proj}_S(y)$  - минимизатор дифференцируемой выпуклой функции  $d(y, S, \|\cdot\|) = \|x - y\|^2$  на множестве  $S$ . Оптимальность:




Рис. 7: Угол должен быть тупым или прямым для любой точки  $x \in S$

# Критерий проекции (неравенство Бурбаки-Чейни-Гольдштейна)

## Theorem

Пусть  $S \subseteq \mathbb{R}^n$  — замкнутое и выпуклое множество,  $\forall x \in S, y \in \mathbb{R}^n$ . Тогда

$$\langle y - \text{proj}_S(y), x - \text{proj}_S(y) \rangle \leq 0 \quad (1)$$

$$\|x - \text{proj}_S(y)\|^2 + \|y - \text{proj}_S(y)\|^2 \leq \|x - y\|^2 \quad (2)$$

1.  $\text{proj}_S(y)$  - минимизатор дифференцируемой выпуклой функции  $d(y, S, \|\cdot\|) = \|x - y\|^2$  на множестве  $S$ . Оптимальность:

$$\nabla d(\text{proj}_S(y))^T(x - \text{proj}_S(y)) \geq 0$$




Рис. 7: Угол должен быть тупым или прямым для любой точки  $x \in S$

# Критерий проекции (неравенство Бурбаки-Чейни-Гольдштейна)

## Theorem

Пусть  $S \subseteq \mathbb{R}^n$  — замкнутое и выпуклое множество,  $\forall x \in S, y \in \mathbb{R}^n$ . Тогда

$$\langle y - \text{proj}_S(y), x - \text{proj}_S(y) \rangle \leq 0 \quad (1)$$

$$\|x - \text{proj}_S(y)\|^2 + \|y - \text{proj}_S(y)\|^2 \leq \|x - y\|^2 \quad (2)$$

1.  $\text{proj}_S(y)$  - минимизатор дифференцируемой выпуклой функции  $d(y, S, \|\cdot\|) = \|x - y\|^2$  на множестве  $S$ . Оптимальность:

$$\nabla d(\text{proj}_S(y))^T (x - \text{proj}_S(y)) \geq 0$$

$$2 (\text{proj}_S(y) - y)^T (x - \text{proj}_S(y)) \geq 0$$




Рис. 7: Угол должен быть тупым или прямым для любой точки  $x \in S$

# Критерий проекции (неравенство Бурбаки-Чейни-Гольдштейна)

## Theorem

Пусть  $S \subseteq \mathbb{R}^n$  — замкнутое и выпуклое множество,  $\forall x \in S, y \in \mathbb{R}^n$ . Тогда

$$\langle y - \text{proj}_S(y), x - \text{proj}_S(y) \rangle \leq 0 \quad (1)$$

$$\|x - \text{proj}_S(y)\|^2 + \|y - \text{proj}_S(y)\|^2 \leq \|x - y\|^2 \quad (2)$$

1.  $\text{proj}_S(y)$  - минимизатор дифференцируемой выпуклой функции  $d(y, S, \|\cdot\|) = \|x - y\|^2$  на множестве  $S$ . Оптимальность:

$$\nabla d(\text{proj}_S(y))^T (x - \text{proj}_S(y)) \geq 0$$

$$2 (\text{proj}_S(y) - y)^T (x - \text{proj}_S(y)) \geq 0$$

$$(y - \text{proj}_S(y))^T (x - \text{proj}_S(y)) \leq 0$$




Рис. 7: Угол должен быть тупым или прямым для любой точки  $x \in S$


# Критерий проекции (неравенство Бурбаки-Чейни-Гольдштейна)

## Theorem

Пусть  $S \subseteq \mathbb{R}^n$  — замкнутое и выпуклое множество,  $\forall x \in S, y \in \mathbb{R}^n$ . Тогда

$$\langle y - \text{proj}_S(y), x - \text{proj}_S(y) \rangle \leq 0 \quad (1)$$

$$\|x - \text{proj}_S(y)\|^2 + \|y - \text{proj}_S(y)\|^2 \leq \|x - y\|^2 \quad (2)$$



1.  $\text{proj}_S(y)$  - минимизатор дифференцируемой выпуклой функции  $d(y, S, \|\cdot\|) = \|x - y\|^2$  на множестве  $S$ . Оптимальность:

$$\nabla d(\text{proj}_S(y))^T(x - \text{proj}_S(y)) \geq 0$$

$$2(\text{proj}_S(y) - y)^T(x - \text{proj}_S(y)) \geq 0$$

$$(y - \text{proj}_S(y))^T(x - \text{proj}_S(y)) \leq 0$$

2. Используем теорему косинусов  $2x^T y = \|x\|^2 + \|y\|^2 - \|x - y\|^2$  с  $x = x - \text{proj}_S(y)$  и  $y = y - \text{proj}_S(y)$ .

$$\langle x, y \rangle = \|x\| \cdot \|y\| \cdot \cos \alpha$$

Рис. 7: Угол должен быть тупым или прямым для любой точки  $x \in S$

# Критерий проекции (неравенство Бурбаки-Чейни-Гольдштейна)

## Theorem

Пусть  $S \subseteq \mathbb{R}^n$  — замкнутое и выпуклое множество,  $\forall x \in S, y \in \mathbb{R}^n$ . Тогда

$$\langle y - \text{proj}_S(y), x - \text{proj}_S(y) \rangle \leq 0 \quad (1)$$

$$\|x - \text{proj}_S(y)\|^2 + \|y - \text{proj}_S(y)\|^2 \leq \|x - y\|^2 \quad (2)$$

1.  $\text{proj}_S(y)$  - минимизатор дифференцируемой выпуклой функции  $d(y, S, \|\cdot\|) = \|x - y\|^2$  на множестве  $S$ . Оптимальность:

$$\nabla d(\text{proj}_S(y))^T (x - \text{proj}_S(y)) \geq 0$$

$$2 (\text{proj}_S(y) - y)^T (x - \text{proj}_S(y)) \geq 0$$

$$(y - \text{proj}_S(y))^T (x - \text{proj}_S(y)) \leq 0$$

2. Используем теорему косинусов  $2x^T y = \|x\|^2 + \|y\|^2 - \|x - y\|^2$  с  $x = x - \text{proj}_S(y)$  и  $y = y - \text{proj}_S(y)$ .

$$0 \geq 2x^T y = \|x - \text{proj}_S(y)\|^2 + \|y - \text{proj}_S(y)\|^2 - \|x - y\|^2$$

но н.т.




Рис. 7: Угол должен быть тупым или прямым для любой точки  $x \in S$

# Критерий проекции (неравенство Бурбаки-Чейни-Гольдштейна)

## Theorem

Пусть  $S \subseteq \mathbb{R}^n$  — замкнутое и выпуклое множество,  $\forall x \in S, y \in \mathbb{R}^n$ . Тогда

$$\langle y - \text{proj}_S(y), x - \text{proj}_S(y) \rangle \leq 0 \quad (1)$$

$$\|x - \text{proj}_S(y)\|^2 + \|y - \text{proj}_S(y)\|^2 \leq \|x - y\|^2 \quad (2)$$

1.  $\text{proj}_S(y)$  - минимизатор дифференцируемой выпуклой функции  $d(y, S, \|\cdot\|) = \|x - y\|^2$  на множестве  $S$ . Оптимальность:

$$\nabla d(\text{proj}_S(y))^T (x - \text{proj}_S(y)) \geq 0$$

$$2 (\text{proj}_S(y) - y)^T (x - \text{proj}_S(y)) \geq 0$$

$$(y - \text{proj}_S(y))^T (x - \text{proj}_S(y)) \leq 0$$

2. Используем теорему косинусов  $2x^T y = \|x\|^2 + \|y\|^2 - \|x - y\|^2$  с  $x = x - \text{proj}_S(y)$  и  $y = y - \text{proj}_S(y)$ .

$$\begin{aligned} 0 &\geq 2x^T y = \|x - \text{proj}_S(y)\|^2 + \|y + \text{proj}_S(y)\|^2 - \|x - y\|^2 \\ &\quad \|x - \text{proj}_S(y)\|^2 + \|y + \text{proj}_S(y)\|^2 \leq \|x - y\|^2 \end{aligned}$$




Рис. 7: Угол должен быть тупым или прямым для любой точки  $x \in S$

## Оператор проекции - нерастягивающий

$L < 1$   
сжимающим

- Функция  $f$  называется нерастягивающей, если она является  $L$ -липшицевой с константой  $L \leq 1$ <sup>1</sup>. То есть для любых двух точек  $x, y \in \text{dom } f$

$$\|f(x) - f(y)\| \leq L\|x - y\|, \text{ где } L \leq 1.$$

Это означает, что расстояние между образами точек не превосходит расстояния между самими точками.

<sup>1</sup>Нерастягивающая функция становится сжимающей при  $L < 1$ .


## Оператор проекции - нерастягивающий

- Функция  $f$  называется нерастягивающей, если она является  $L$ -липшицевой с константой  $L \leq 1$ <sup>1</sup>. То есть для любых двух точек  $x, y \in \text{dom } f$

$$\|f(x) - f(y)\| \leq L\|x - y\|, \text{ где } L \leq 1.$$

Это означает, что расстояние между образами точек не превосходит расстояния между самими точками.

- Оператор проекции является нерастягивающим:



<sup>1</sup>Нерастягивающая функция становится сжимающей при  $L < 1$ .

## Оператор проекции - нерастягивающий

- Функция  $f$  называется нерастягивающей, если она является  $L$ -липшицевой с константой  $L \leq 1$ <sup>1</sup>. То есть для любых двух точек  $x, y \in \text{dom } f$

$$\|f(x) - f(y)\| \leq L\|x - y\|, \text{ где } L \leq 1.$$

Это означает, что расстояние между образами точек не превосходит расстояния между самими точками.

- Оператор проекции является нерастягивающим:

$$\|\text{proj}(x) - \text{proj}(y)\|_2 \leq \|x - y\|_2.$$

- Далее покажем, что из неравенства Бурбаки-Чейни-Гольдштейна следует свойство нерастягиваемости, а именно:

$$\langle y - \text{proj}(y), x - \text{proj}(y) \rangle \leq 0 \quad \forall x \in S \quad \Rightarrow \quad \|\text{proj}(x) - \text{proj}(y)\|_2 \leq \|x - y\|_2.$$

$X = \text{PROJ}(\bar{x})$

<sup>1</sup>Нерастягивающая функция становится сжимающей при  $L < 1$ .

## Оператор проекции - нерастягивающий

Сокращённая запись: пусть  $\pi = \text{proj}$  и  $\pi(x)$  обозначает  $\underline{\text{proj}}(x)$ .

## Оператор проекции - нерастягивающий

Сокращённая запись: пусть  $\pi = \text{proj}$  и  $\pi(x)$  обозначает  $\text{proj}(x)$ .

Начнём с неравенства Бурбаки-Чейни-Гольдштейна

**БЧГ**

$$\langle y - \pi(y), x - \pi(y) \rangle \leq 0 \quad \forall x \in S. \quad (3)$$

## Оператор проекции - нерастягивающий

Сокращённая запись: пусть  $\pi = \text{proj}$  и  $\pi(x)$  обозначает  $\text{proj}(x)$ .

Начнём с неравенства Бурбаки-Чейни-Гольдштейна

$$\langle y - \pi(y), x - \pi(y) \rangle \leq 0 \quad \forall x \in S. \quad (3)$$

Заменим  $x$  на  $\pi(x)$  в (3)

$$x = \pi(x)$$

$$\langle y - \pi(y), \pi(x) - \pi(y) \rangle \leq 0. \quad (4)$$

## Оператор проекции - нерастягивающий

Сокращённая запись: пусть  $\pi = \text{proj}$  и  $\pi(x)$  обозначает  $\text{proj}(x)$ .

Начнём с неравенства Бурбаки-Чейни-Гольдштейна

$$\langle y - \pi(y), x - \pi(y) \rangle \leq 0 \quad \forall x \in S. \quad (3)$$

Заменим  $x$  на  $\pi(x)$  в (3)

$$\langle y - \pi(y), \pi(x) - \pi(y) \rangle \leq 0. \quad (4)$$



(4)


Заменим  $y$  на  $x$  и  $x$  на  $\pi(y)$  в (3)

$$\langle x - \pi(x), \pi(y) - \pi(x) \rangle \leq 0. \quad (5)$$



(5)

## Оператор проекции - нерастягивающий



Сокращённая запись: пусть  $\pi = \text{proj}$  и  $\pi(x)$  обозначает  $\text{proj}(x)$ .

Начнём с неравенства Бурбаки-Чейни-Гольдштейна

$$\langle y - \pi(y), x - \pi(y) \rangle \leq 0 \quad \forall x \in S. \quad (3)$$

Заменим  $x$  на  $\pi(x)$  в (3)

$$\langle y - \pi(y), \pi(x) - \pi(y) \rangle \leq 0. \quad (4)$$

Заменим  $y$  на  $x$  и  $x$  на  $\pi(y)$  в (3)

$$\langle x - \pi(x), \underline{\pi(y)} - \underline{\pi(x)} \rangle \leq 0. \quad (5)$$

(4)+(5) сократят  $\pi(y) - \pi(x)$ , что нежелательно. Поэтому сменим знак в (5):

$$\langle \pi(x) - x, \pi(x) - \pi(y) \rangle \leq 0. \quad (6)$$

## Оператор проекции - нерастягивающий

Сокращённая запись: пусть  $\pi = \text{proj}$  и  $\pi(x)$  обозначает  $\text{proj}(x)$ .

Начнём с неравенства Бурбаки-Чейни-Гольдштейна

$$\langle y - \pi(y), x - \pi(y) \rangle \leq 0 \quad \forall x \in S. \quad (3)$$

Заменим  $x$  на  $\pi(x)$  в (3)

$$\langle y - \pi(y), \pi(x) - \pi(y) \rangle \leq 0. \quad (4)$$

Заменим  $y$  на  $x$  и  $x$  на  $\pi(y)$  в (3)  
 $\langle \pi(x) - x, \pi(y) - \pi(y) \rangle \leq 0$

$$\langle x - \pi(x), \pi(y) - \pi(x) \rangle \leq 0. \quad (5)$$

(4)+(5) сократят  $\pi(y) - \pi(x)$ , что нежелательно. Поэтому сменим знак в (5):

$$y - \pi(y) + \pi(x) - x \quad \langle \pi(x) - x, \pi(x) - \pi(y) \rangle \leq 0. \quad (6)$$

$$\begin{aligned} & \langle y - \pi(y) + \pi(x) - x, \pi(x) - \pi(y) \rangle \leq 0 \\ & \langle y - x, \pi(x) - \pi(y) \rangle \leq -\langle \pi(x) - \pi(y), \pi(x) - \pi(y) \rangle \\ & \langle y - x, \pi(y) - \pi(x) \rangle \geq \|\pi(x) - \pi(y)\|_2^2 \\ & \|(y - x)^\top (\pi(y) - \pi(x))\|_2 \geq \|\pi(x) - \pi(y)\|_2^2 \end{aligned}$$

## Оператор проекции - нерастягивающий

$$\|\pi(x) - \pi(y)\| \neq 0$$

Сокращённая запись: пусть  $\pi = \text{proj}$  и  $\pi(x)$  обозначает  $\text{proj}(x)$ .

Начнём с неравенства Бурбаки-Чейни-Гольдштейна

$$\langle y - \pi(y), x - \pi(y) \rangle \leq 0 \quad \forall x \in S. \quad (3)$$

Заменим  $x$  на  $\pi(x)$  в (3)

$$\langle y - \pi(y), \pi(x) - \pi(y) \rangle \leq 0. \quad (4)$$

Заменим  $y$  на  $x$  и  $x$  на  $\pi(y)$  в (3)

$$\langle x - \pi(x), \pi(y) - \pi(x) \rangle \leq 0. \quad (5)$$

(4)+(5) сократят  $\pi(y) - \pi(x)$ , что нежелательно. Поэтому сменим знак в (5):

$$\langle \pi(x) - x, \pi(x) - \pi(y) \rangle \leq 0. \quad (6)$$

$$\langle y - \pi(y) + \pi(x) - x, \pi(x) - \pi(y) \rangle \leq 0$$

По неравенству КБШ левая часть

ограничена сверху величиной

$$\langle y - x, \pi(x) - \pi(y) \rangle \leq -\langle \pi(x) - \pi(y), \pi(x) - \pi(y) \rangle$$

$\|y - x\|_2 \|\pi(y) - \pi(x)\|_2$ , откуда следует

$$\langle y - x, \pi(y) - \pi(x) \rangle \geq \|\pi(x) - \pi(y)\|_2^2$$

$\|y - x\|_2 \|\pi(y) - \pi(x)\|_2 \geq \|\pi(x) - \pi(y)\|_2^2$ .

$$\geq \|(y - x)^\top (\pi(y) - \pi(x))\|_2 \geq \|\pi(x) - \pi(y)\|_2^2$$

Сокращая на  $\|\pi(x) - \pi(y)\|_2$ , завершаем доказательство.

$f \rightarrow \min_{x,y,z}$  Проекция



## Пример: проекция на шар

Найдём  $\pi_S(y) = \pi$ , если  $S = \{x \in \mathbb{R}^n \mid \|x - x_0\| \leq R\}$ ,  $y \notin S$

## Пример: проекция на шар

Найдём  $\pi_S(y) = \pi$ , если  $S = \{x \in \mathbb{R}^n \mid \|x - x_0\| \leq R\}$ ,  $y \notin S$

Построим гипотезу по рисунку:  $\pi = x_0 + R \cdot \frac{y-x_0}{\|y-x_0\|}$

## Пример: проекция на шар

Найдём  $\pi_S(y) = \pi$ , если  $S = \{x \in \mathbb{R}^n \mid \|x - x_0\| \leq R\}$ ,  $y \notin S$

Построим гипотезу по рисунку:  $\pi = x_0 + R \cdot \frac{y-x_0}{\|y-x_0\|}$

Проверим неравенство для замкнутого выпуклого множества:

$$(\pi - y)^T(x - \pi) \geq 0$$

## Пример: проекция на шар

Найдём  $\pi_S(y) = \pi$ , если  $S = \{x \in \mathbb{R}^n \mid \|x - x_0\| \leq R\}$ ,  $y \notin S$

Построим гипотезу по рисунку:  $\pi = x_0 + R \cdot \frac{y - x_0}{\|y - x_0\|}$

Проверим неравенство для замкнутого выпуклого множества:

$$(\pi - y)^T(x - \pi) \geq 0$$

$$\left( x_0 - y + R \frac{y - x_0}{\|y - x_0\|} \right)^T \left( x - x_0 - R \frac{y - x_0}{\|y - x_0\|} \right) =$$

$$\left( \frac{(y - x_0)(R - \|y - x_0\|)}{\|y - x_0\|} \right)^T \left( \frac{(x - x_0)\|y - x_0\| - R(y - x_0)}{\|y - x_0\|} \right) =$$

$$\frac{R - \|y - x_0\|}{\|y - x_0\|^2} (y - x_0)^T ((x - x_0) \|y - x_0\| - R(y - x_0)) =$$

$$\frac{R - \|y - x_0\|}{\|y - x_0\|} \left( (y - x_0)^T (x - x_0) - R \|y - x_0\| \right) =$$

$$(R - \|y - x_0\|) \left( \frac{(y - x_0)^T (x - x_0)}{\|y - x_0\|} - R \right)$$

## Пример: проекция на шар

Найдём  $\pi_S(y) = \pi$ , если  $S = \{x \in \mathbb{R}^n \mid \|x - x_0\| \leq R\}$ ,  $y \notin S$

Построим гипотезу по рисунку:  $\pi = x_0 + R \cdot \frac{y - x_0}{\|y - x_0\|}$

Проверим неравенство для замкнутого выпуклого множества:

$$(\pi - y)^T(x - \pi) \geq 0$$

Первый множитель отрицателен по выбору точки  $y$ . Второй множитель также отрицателен, что следует из КБШ:

$$\left( x_0 - y + R \frac{y - x_0}{\|y - x_0\|} \right)^T \left( x - x_0 - R \frac{y - x_0}{\|y - x_0\|} \right) =$$

$$\left( \frac{(y - x_0)(R - \|y - x_0\|)}{\|y - x_0\|} \right)^T \left( \frac{(x - x_0)\|y - x_0\| - R(y - x_0)}{\|y - x_0\|} \right) =$$

$$\frac{R - \|y - x_0\|}{\|y - x_0\|^2} (y - x_0)^T ((x - x_0) \|y - x_0\| - R(y - x_0)) =$$

$$\frac{R - \|y - x_0\|}{\|y - x_0\|} \left( (y - x_0)^T (x - x_0) - R \|y - x_0\| \right) =$$

$$(R - \|y - x_0\|) \left( \frac{(y - x_0)^T (x - x_0)}{\|y - x_0\|} - R \right)$$

## Пример: проекция на шар

Найдём  $\pi_S(y) = \pi$ , если  $S = \{x \in \mathbb{R}^n \mid \|x - x_0\| \leq R\}$ ,  $y \notin S$

Построим гипотезу по рисунку:  $\pi = x_0 + R \cdot \frac{y - x_0}{\|y - x_0\|}$

Проверим неравенство для замкнутого выпуклого множества:

$$(\pi - y)^T(x - \pi) \geq 0$$

Первый множитель отрицателен по выбору точки  $y$ . Второй множитель также отрицателен, что следует из КБШ:

$$\left( x_0 - y + R \frac{y - x_0}{\|y - x_0\|} \right)^T \left( x - x_0 - R \frac{y - x_0}{\|y - x_0\|} \right) =$$


$$\left( \frac{(y - x_0)(R - \|y - x_0\|)}{\|y - x_0\|} \right)^T \left( \frac{(x - x_0)\|y - x_0\| - R(y - x_0)}{\|y - x_0\|} \right) =$$

$$\frac{R - \|y - x_0\|}{\|y - x_0\|^2} (y - x_0)^T ((x - x_0)\|y - x_0\| - R(y - x_0)) =$$

$$\frac{R - \|y - x_0\|}{\|y - x_0\|} \left( (y - x_0)^T (x - x_0) - R\|y - x_0\| \right) =$$

$$(R - \|y - x_0\|) \left( \frac{(y - x_0)^T (x - x_0)}{\|y - x_0\|} - R \right)$$

$$(y - x_0)^T (x - x_0) \leq \|y - x_0\| \|x - x_0\|$$
$$\frac{(y - x_0)^T (x - x_0)}{\|y - x_0\|} - R \leq \frac{\|y - x_0\| \|x - x_0\|}{\|y - x_0\|} - R$$



## Пример: проекция на полупространство

Найдём  $\pi_S(y) = \pi$ , если  $S = \{x \in \mathbb{R}^n \mid c^T x = b\}$ ,  $y \notin S$ . Построим гипотезу по рисунку:  $\pi = y + \alpha c$ . Коэффициент  $\alpha$  выбирается так, чтобы  $\pi \in S$ :  $c^T \pi = b$ , тогда:

## Пример: проекция на полупространство

$$c^T x \leq b$$

Найдём  $\pi_S(y) = \pi$ , если  $S = \{x \in \mathbb{R}^n \mid c^T x = b\}$ ,  $y \notin S$ . Построим гипотезу по рисунку:  $\pi = y + \alpha c$ . Коэффициент  $\alpha$  выбирается так, чтобы  $\pi \in S$ :  $c^T \pi = b$ , тогда:




Рис. 9: Гиперплоскость

## Пример: проекция на полупространство

Найдём  $\pi_S(y) = \pi$ , если  $S = \{x \in \mathbb{R}^n \mid c^T x = b\}$ ,  $y \notin S$ . Построим гипотезу по рисунку:  $\pi = y + \alpha c$ . Коэффициент  $\alpha$  выбирается так, чтобы  $\pi \in S$ :  $c^T \pi = b$ , тогда:




Рис. 9: Гиперплоскость

$$\begin{aligned}c^T x &= b \\c^T(y + \alpha c) &= b \\c^T y + \alpha c^T c &= b \\c^T y &= b - \alpha c^T c\end{aligned}$$

Проверим неравенство для замкнутого выпуклого множества:  $(\pi - y)^T(x - \pi) \geq 0$

$$\begin{aligned}(y + \alpha c - y)^T(x - y - \alpha c) &= \\ \alpha c^T(x - y - \alpha c) &= \\ \alpha(c^T x) - \alpha(c^T y) - \alpha^2(c^T c) &= \\ \alpha b - \alpha(b - \alpha c^T c) - \alpha^2 c^T c &= \\ \alpha b - \alpha b + \alpha^2 c^T c - \alpha^2 c^T c &= 0 \geq 0\end{aligned}$$

## Метод проекции градиента (PGD)

## Идея

$$x_{k+1} = \text{proj}_S(x_k - \alpha_k \nabla f(x_k)) \quad \Leftrightarrow \quad \begin{aligned} y_k &= x_k - \alpha_k \nabla f(x_k) \\ x_{k+1} &= \text{proj}_S(y_k) \end{aligned}$$

$$y_k = x_k - \alpha_k \nabla f(x_k)$$




Рис. 10: Иллюстрация алгоритма метода проекции градиента



### Theorem

Пусть  $f : \mathbb{R}^n \rightarrow \mathbb{R}$  — выпуклая функция с  $L$ -липшицевым градиентом. Тогда для любых  $x, y \in \mathbb{R}^n$  выполняется следующее неравенство:

$$f(x) + \langle \nabla f(x), y - x \rangle + \frac{1}{2L} \|\nabla f(x) - \nabla f(y)\|_2^2 \leq f(y) \text{ или, эквивалентно,}$$

$$\|\nabla f(y) - \nabla f(x)\|_2^2 = \|\nabla f(x) - \nabla f(y)\|_2^2 \leq 2L(f(x) - f(y) - \langle \nabla f(y), x - y \rangle)$$

1. Для доказательства рассмотрим вспомогательную функцию  $\varphi(y) = f(y) - \langle \nabla f(x), y \rangle$ . Она является выпуклой (как сумма выпуклых функций). Легко проверить, что она является  $L$ -гладкой по определению, поскольку  $\nabla \varphi(y) = \nabla f(y) - \nabla f(x)$  и  $\|\nabla \varphi(y_1) - \nabla \varphi(y_2)\| = \|\nabla f(y_1) - \nabla f(y_2)\| \leq L\|y_1 - y_2\|$ .



### Theorem

Пусть  $f : \mathbb{R}^n \rightarrow \mathbb{R}$  — выпуклая функция с  $L$ -липшицевым градиентом. Тогда для любых  $x, y \in \mathbb{R}^n$  выполняется следующее неравенство:

$$f(x) + \langle \nabla f(x), y - x \rangle + \frac{1}{2L} \|\nabla f(x) - \nabla f(y)\|_2^2 \leq f(y) \text{ или, эквивалентно,}$$

$$\|\nabla f(y) - \nabla f(x)\|_2^2 = \|\nabla f(x) - \nabla f(y)\|_2^2 \leq 2L(f(x) - f(y) - \langle \nabla f(y), x - y \rangle)$$

- Для доказательства рассмотрим вспомогательную функцию  $\varphi(y) = f(y) - \langle \nabla f(x), y \rangle$ . Она является выпуклой (как сумма выпуклых функций). Легко проверить, что она является  $L$ -гладкой по определению, поскольку  $\nabla \varphi(y) = \nabla f(y) - \nabla f(x)$  и  $\|\nabla \varphi(y_1) - \nabla \varphi(y_2)\| = \|\nabla f(y_1) - \nabla f(y_2)\| \leq L\|y_1 - y_2\|$ .
- Теперь рассмотрим свойство липшицевой параболы для гладкой функции  $\varphi(y)$ :



## Theorem

Пусть  $f : \mathbb{R}^n \rightarrow \mathbb{R}$  — выпуклая функция с  $L$ -липшицевым градиентом. Тогда для любых  $x, y \in \mathbb{R}^n$  выполняется следующее неравенство:

$$f(x) + \langle \nabla f(x), y - x \rangle + \frac{1}{2L} \|\nabla f(x) - \nabla f(y)\|_2^2 \leq f(y) \text{ или, эквивалентно,}$$

$$\|\nabla f(y) - \nabla f(x)\|_2^2 = \|\nabla f(x) - \nabla f(y)\|_2^2 \leq 2L(f(x) - f(y) - \langle \nabla f(y), x - y \rangle)$$

- Для доказательства рассмотрим вспомогательную функцию  $\varphi(y) = f(y) - \langle \nabla f(x), y \rangle$ . Она является выпуклой (как сумма выпуклых функций). Легко проверить, что она является  $L$ -гладкой по определению, поскольку  $\nabla \varphi(y) = \nabla f(y) - \nabla f(x)$  и  $\|\nabla \varphi(y_1) - \nabla \varphi(y_2)\| = \|\nabla f(y_1) - \nabla f(y_2)\| \leq L\|y_1 - y_2\|$ .
- Теперь рассмотрим свойство липшицевой параболы для гладкой функции  $\varphi(y)$ :

$$\varphi(y) \leq \varphi(x) + \langle \nabla \varphi(x), y - x \rangle + \frac{L}{2} \|y - x\|_2^2$$



## i Theorem

Пусть  $f : \mathbb{R}^n \rightarrow \mathbb{R}$  — выпуклая функция с  $L$ -липшицевым градиентом. Тогда для любых  $x, y \in \mathbb{R}^n$  выполняется следующее неравенство:

$$f(x) + \langle \nabla f(x), y - x \rangle + \frac{1}{2L} \|\nabla f(x) - \nabla f(y)\|_2^2 \leq f(y) \text{ или, эквивалентно,}$$

$$\|\nabla f(y) - \nabla f(x)\|_2^2 = \|\nabla f(x) - \nabla f(y)\|_2^2 \leq 2L(f(x) - f(y) - \langle \nabla f(y), x - y \rangle)$$

- Для доказательства рассмотрим вспомогательную функцию  $\varphi(y) = f(y) - \langle \nabla f(x), y \rangle$ . Она является выпуклой (как сумма выпуклых функций). Легко проверить, что она является  $L$ -гладкой по определению, поскольку  $\nabla \varphi(y) = \nabla f(y) - \nabla f(x)$  и  $\|\nabla \varphi(y_1) - \nabla \varphi(y_2)\| = \|\nabla f(y_1) - \nabla f(y_2)\| \leq L\|y_1 - y_2\|$ .
- Теперь рассмотрим свойство липшицевой параболы для гладкой функции  $\varphi(y)$ :

$$\varphi(y) \leq \varphi(x) + \langle \nabla \varphi(x), y - x \rangle + \frac{L}{2} \|y - x\|_2^2$$

$$x := y, y := y - \frac{1}{L} \nabla \varphi(y) \quad \varphi\left(y - \frac{1}{L} \nabla \varphi(y)\right) \leq \varphi(y) + \left\langle \nabla \varphi(y), -\frac{1}{L} \nabla \varphi(y) \right\rangle + \frac{1}{2L} \|\nabla \varphi(y)\|_2^2$$



## i Theorem

Пусть  $f : \mathbb{R}^n \rightarrow \mathbb{R}$  — выпуклая функция с  $L$ -липшицевым градиентом. Тогда для любых  $x, y \in \mathbb{R}^n$  выполняется следующее неравенство:

$$f(x) + \langle \nabla f(x), y - x \rangle + \frac{1}{2L} \|\nabla f(x) - \nabla f(y)\|_2^2 \leq f(y) \text{ или, эквивалентно,}$$

$$\|\nabla f(y) - \nabla f(x)\|_2^2 = \|\nabla f(x) - \nabla f(y)\|_2^2 \leq 2L(f(x) - f(y) - \langle \nabla f(y), x - y \rangle)$$

- Для доказательства рассмотрим вспомогательную функцию  $\varphi(y) = f(y) - \langle \nabla f(x), y \rangle$ . Она является выпуклой (как сумма выпуклых функций). Легко проверить, что она является  $L$ -гладкой по определению, поскольку  $\nabla \varphi(y) = \nabla f(y) - \nabla f(x)$  и  $\|\nabla \varphi(y_1) - \nabla \varphi(y_2)\| = \|\nabla f(y_1) - \nabla f(y_2)\| \leq L\|y_1 - y_2\|$ .
- Теперь рассмотрим свойство липшицевой параболы для гладкой функции  $\varphi(y)$ :

$$\varphi(y) \leq \varphi(x) + \langle \nabla \varphi(x), y - x \rangle + \frac{L}{2} \|y - x\|_2^2$$

$$x:=y, y:=y - \frac{1}{L} \nabla \varphi(y) \quad \varphi\left(y - \frac{1}{L} \nabla \varphi(y)\right) \leq \varphi(y) + \left\langle \nabla \varphi(y), -\frac{1}{L} \nabla \varphi(y) \right\rangle + \frac{1}{2L} \|\nabla \varphi(y)\|_2^2$$

$$\varphi\left(y - \frac{1}{L} \nabla \varphi(y)\right) \leq \varphi(y) - \frac{1}{2L} \|\nabla \varphi(y)\|_2^2$$

## Инструменты для доказательства сходимости



3. Из условий оптимальности первого порядка для выпуклой функции  $\nabla\varphi(y) = \nabla f(y) - \nabla f(x) = 0$ . Можно заключить, что для любого  $x$  минимум функции  $\varphi(y)$  достигается в точке  $y = x$ . Следовательно:

$$\varphi(x) \leq \varphi\left(y - \frac{1}{L}\nabla\varphi(y)\right) \leq \varphi(y) - \frac{1}{2L}\|\nabla\varphi(y)\|_2^2$$

## Инструменты для доказательства сходимости



3. Из условий оптимальности первого порядка для выпуклой функции  $\nabla\varphi(y) = \nabla f(y) - \nabla f(x) = 0$ . Можно заключить, что для любого  $x$  минимум функции  $\varphi(y)$  достигается в точке  $y = x$ . Следовательно:

$$\varphi(x) \leq \varphi\left(y - \frac{1}{L}\nabla\varphi(y)\right) \leq \varphi(y) - \frac{1}{2L}\|\nabla\varphi(y)\|_2^2$$

4. Теперь подставим  $\varphi(y) = f(y) - \langle \nabla f(x), y \rangle$ :

## Инструменты для доказательства сходимости



3. Из условий оптимальности первого порядка для выпуклой функции  $\nabla\varphi(y) = \nabla f(y) - \nabla f(x) = 0$ . Можно заключить, что для любого  $x$  минимум функции  $\varphi(y)$  достигается в точке  $y = x$ . Следовательно:

$$\varphi(x) \leq \varphi\left(y - \frac{1}{L}\nabla\varphi(y)\right) \leq \varphi(y) - \frac{1}{2L}\|\nabla\varphi(y)\|_2^2$$

4. Теперь подставим  $\varphi(y) = f(y) - \langle \nabla f(x), y \rangle$ :

$$f(x) - \langle \nabla f(x), x \rangle \leq f(y) - \langle \nabla f(x), y \rangle - \frac{1}{2L}\|\nabla f(y) - \nabla f(x)\|_2^2$$

## Инструменты для доказательства сходимости



3. Из условий оптимальности первого порядка для выпуклой функции  $\nabla\varphi(y) = \nabla f(y) - \nabla f(x) = 0$ . Можно заключить, что для любого  $x$  минимум функции  $\varphi(y)$  достигается в точке  $y = x$ . Следовательно:

$$\varphi(x) \leq \varphi\left(y - \frac{1}{L}\nabla\varphi(y)\right) \leq \varphi(y) - \frac{1}{2L}\|\nabla\varphi(y)\|_2^2$$

4. Теперь подставим  $\varphi(y) = f(y) - \langle \nabla f(x), y \rangle$ :

$$f(x) - \langle \nabla f(x), x \rangle \leq f(y) - \langle \nabla f(x), y \rangle - \frac{1}{2L}\|\nabla f(y) - \nabla f(x)\|_2^2$$

$$f(x) + \langle \nabla f(x), y - x \rangle + \frac{1}{2L}\|\nabla f(x) - \nabla f(y)\|_2^2 \leq f(y)$$

## Инструменты для доказательства сходимости



3. Из условий оптимальности первого порядка для выпуклой функции  $\nabla\varphi(y) = \nabla f(y) - \nabla f(x) = 0$ . Можно заключить, что для любого  $x$  минимум функции  $\varphi(y)$  достигается в точке  $y = x$ . Следовательно:

$$\varphi(x) \leq \varphi\left(y - \frac{1}{L}\nabla\varphi(y)\right) \leq \varphi(y) - \frac{1}{2L}\|\nabla\varphi(y)\|_2^2$$

4. Теперь подставим  $\varphi(y) = f(y) - \langle \nabla f(x), y \rangle$ :

$$f(x) - \langle \nabla f(x), x \rangle \leq f(y) - \langle \nabla f(x), y \rangle - \frac{1}{2L}\|\nabla f(y) - \nabla f(x)\|_2^2$$

$$f(x) + \langle \nabla f(x), y - x \rangle + \frac{1}{2L}\|\nabla f(x) - \nabla f(y)\|_2^2 \leq f(y)$$

$$\|\nabla f(y) - \nabla f(x)\|_2^2 \leq 2L(f(y) - f(x) - \langle \nabla f(x), y - x \rangle)$$

## Инструменты для доказательства сходимости



3. Из условий оптимальности первого порядка для выпуклой функции  $\nabla\varphi(y) = \nabla f(y) - \nabla f(x) = 0$ . Можно заключить, что для любого  $x$  минимум функции  $\varphi(y)$  достигается в точке  $y = x$ . Следовательно:

$$\varphi(x) \leq \varphi\left(y - \frac{1}{L}\nabla\varphi(y)\right) \leq \varphi(y) - \frac{1}{2L}\|\nabla\varphi(y)\|_2^2$$

4. Теперь подставим  $\varphi(y) = f(y) - \langle \nabla f(x), y \rangle$ :

$$f(x) - \langle \nabla f(x), x \rangle \leq f(y) - \langle \nabla f(x), y \rangle - \frac{1}{2L}\|\nabla f(y) - \nabla f(x)\|_2^2$$

$$f(x) + \langle \nabla f(x), y - x \rangle + \frac{1}{2L}\|\nabla f(x) - \nabla f(y)\|_2^2 \leq f(y)$$

$$\|\nabla f(y) - \nabla f(x)\|_2^2 \leq 2L(f(y) - f(x) - \langle \nabla f(x), y - x \rangle)$$

меняем  $x$  и  $y$      $\|\nabla f(x) - \nabla f(y)\|_2^2 \leq 2L(f(x) - f(y) - \langle \nabla f(y), x - y \rangle)$

## Инструменты для доказательства сходимости



3. Из условий оптимальности первого порядка для выпуклой функции  $\nabla\varphi(y) = \nabla f(y) - \nabla f(x) = 0$ . Можно заключить, что для любого  $x$  минимум функции  $\varphi(y)$  достигается в точке  $y = x$ . Следовательно:

$$\varphi(x) \leq \varphi\left(y - \frac{1}{L}\nabla\varphi(y)\right) \leq \varphi(y) - \frac{1}{2L}\|\nabla\varphi(y)\|_2^2$$

4. Теперь подставим  $\varphi(y) = f(y) - \langle \nabla f(x), y \rangle$ :

$$f(x) - \langle \nabla f(x), x \rangle \leq f(y) - \langle \nabla f(x), y \rangle - \frac{1}{2L}\|\nabla f(y) - \nabla f(x)\|_2^2$$

$$f(x) + \langle \nabla f(x), y - x \rangle + \frac{1}{2L}\|\nabla f(x) - \nabla f(y)\|_2^2 \leq f(y)$$

$$\|\nabla f(y) - \nabla f(x)\|_2^2 \leq 2L(f(y) - f(x) - \langle \nabla f(x), y - x \rangle)$$

меняем  $x$  и  $y$      $\|\nabla f(x) - \nabla f(y)\|_2^2 \leq 2L(f(x) - f(y) - \langle \nabla f(y), x - y \rangle)$

## Инструменты для доказательства сходимости



3. Из условий оптимальности первого порядка для выпуклой функции  $\nabla\varphi(y) = \nabla f(y) - \nabla f(x) = 0$ . Можно заключить, что для любого  $x$  минимум функции  $\varphi(y)$  достигается в точке  $y = x$ . Следовательно:

$$\varphi(x) \leq \varphi\left(y - \frac{1}{L}\nabla\varphi(y)\right) \leq \varphi(y) - \frac{1}{2L}\|\nabla\varphi(y)\|_2^2$$

4. Теперь подставим  $\varphi(y) = f(y) - \langle \nabla f(x), y \rangle$ :

$$f(x) - \langle \nabla f(x), x \rangle \leq f(y) - \langle \nabla f(x), y \rangle - \frac{1}{2L}\|\nabla f(y) - \nabla f(x)\|_2^2$$

$$f(x) + \langle \nabla f(x), y - x \rangle + \frac{1}{2L}\|\nabla f(x) - \nabla f(y)\|_2^2 \leq f(y)$$

$$\|\nabla f(y) - \nabla f(x)\|_2^2 \leq 2L(f(y) - f(x) - \langle \nabla f(x), y - x \rangle)$$

меняя  $x$  и  $y$      $\|\nabla f(x) - \nabla f(y)\|_2^2 \leq 2L(f(x) - f(y) - \langle \nabla f(y), x - y \rangle)$

Лемма доказана. На первый взгляд она не имеет очевидной геометрической интерпретации, но мы будем использовать её как удобный инструмент для оценки разности градиентов.



## i Theorem

Пусть  $f : \mathbb{R}^n \rightarrow \mathbb{R}$  — непрерывно дифференцируемая функция на  $\mathbb{R}^n$ . Тогда функция  $f$  является  $\mu$ -сильно выпуклой тогда и только тогда, когда для любых  $x, y \in \mathbb{R}^d$  выполняется:

$$\text{Сильно выпуклый случай } \mu > 0 \quad \langle \nabla f(x) - \nabla f(y), x - y \rangle \geq \mu \|x - y\|^2$$

$$\text{Выпуклый случай } \mu = 0 \quad \langle \nabla f(x) - \nabla f(y), x - y \rangle \geq 0$$

## Доказательство

- Приведём доказательство только для сильно выпуклого случая; выпуклый следует из него при  $\mu = 0$ . Начнём с необходимости. Для сильно выпуклой функции

$$f(y) \geq f(x) + \langle \nabla f(x), y - x \rangle + \frac{\mu}{2} \|x - y\|_2^2$$

$$f(x) \geq f(y) + \langle \nabla f(y), x - y \rangle + \frac{\mu}{2} \|x - y\|_2^2$$

$$\text{сумма} \quad \langle \nabla f(x) - \nabla f(y), x - y \rangle \geq \mu \|x - y\|^2$$

## Инструменты для доказательства сходимости



2. Для достаточности предположим, что  $\langle \nabla f(x) - \nabla f(y), x - y \rangle \geq \mu \|x - y\|^2$ . Используя формулу Ньютона-Лейбница  $f(x) = f(y) + \int_0^1 \langle \nabla f(y + t(x - y)), x - y \rangle dt$ :

## Инструменты для доказательства сходимости



2. Для достаточности предположим, что  $\langle \nabla f(x) - \nabla f(y), x - y \rangle \geq \mu \|x - y\|^2$ . Используя формулу Ньютона-Лейбница  $f(x) = f(y) + \int_0^1 \langle \nabla f(y + t(x - y)), x - y \rangle dt$ :

$$f(x) - f(y) - \langle \nabla f(y), x - y \rangle = \int_0^1 \langle \nabla f(y + t(x - y)), x - y \rangle dt - \langle \nabla f(y), x - y \rangle$$

## Инструменты для доказательства сходимости



2. Для достаточности предположим, что  $\langle \nabla f(x) - \nabla f(y), x - y \rangle \geq \mu \|x - y\|^2$ . Используя формулу Ньютона-Лейбница  $f(x) = f(y) + \int_0^1 \langle \nabla f(y + t(x - y)), x - y \rangle dt$ :

$$\begin{aligned} f(x) - f(y) - \langle \nabla f(y), x - y \rangle &= \int_0^1 \langle \nabla f(y + t(x - y)), x - y \rangle dt - \langle \nabla f(y), x - y \rangle \\ \langle \nabla f(y), x - y \rangle &= \int_0^1 \langle \nabla f(y + t(x - y)) - \nabla f(y), (x - y) \rangle dt \end{aligned}$$

## Инструменты для доказательства сходимости



2. Для достаточности предположим, что  $\langle \nabla f(x) - \nabla f(y), x - y \rangle \geq \mu \|x - y\|^2$ . Используя формулу Ньютона-Лейбница  $f(x) = f(y) + \int_0^1 \langle \nabla f(y + t(x - y)), x - y \rangle dt$ :

$$\begin{aligned} f(x) - f(y) - \langle \nabla f(y), x - y \rangle &= \int_0^1 \langle \nabla f(y + t(x - y)), x - y \rangle dt - \langle \nabla f(y), x - y \rangle \\ \langle \nabla f(y), x - y \rangle &= \int_0^1 \langle \nabla f(y + t(x - y)) - \nabla f(y), (x - y) \rangle dt \\ y + t(x - y) - y &= t(x - y) \end{aligned}$$

## Инструменты для доказательства сходимости



2. Для достаточности предположим, что  $\langle \nabla f(x) - \nabla f(y), x - y \rangle \geq \mu \|x - y\|^2$ . Используя формулу Ньютона-Лейбница  $f(x) = f(y) + \int_0^1 \langle \nabla f(y + t(x - y)), x - y \rangle dt$ :

$$\begin{aligned} f(x) - f(y) - \langle \nabla f(y), x - y \rangle &= \int_0^1 \langle \nabla f(y + t(x - y)), x - y \rangle dt - \langle \nabla f(y), x - y \rangle \\ &\stackrel{\langle \nabla f(y), x - y \rangle = \int_0^1 \langle \nabla f(y), x - y \rangle dt}{=} \int_0^1 \langle \nabla f(y + t(x - y)) - \nabla f(y), (x - y) \rangle dt \\ &\stackrel{y+t(x-y)-y=t(x-y)}{=} \int_0^1 t^{-1} \langle \nabla f(y + t(x - y)) - \nabla f(y), t(x - y) \rangle dt \\ &\geq \int_0^1 t^{-1} \mu \|t(x - y)\|^2 dt \end{aligned}$$

## Инструменты для доказательства сходимости



2. Для достаточности предположим, что  $\langle \nabla f(x) - \nabla f(y), x - y \rangle \geq \mu \|x - y\|^2$ . Используя формулу Ньютона-Лейбница  $f(x) = f(y) + \int_0^1 \langle \nabla f(y + t(x - y)), x - y \rangle dt$ :

$$\begin{aligned} f(x) - f(y) - \langle \nabla f(y), x - y \rangle &= \int_0^1 \langle \nabla f(y + t(x - y)), x - y \rangle dt - \langle \nabla f(y), x - y \rangle \\ \langle \nabla f(y), x - y \rangle &= \int_0^1 \langle \nabla f(y + t(x - y)) - \nabla f(y), (x - y) \rangle dt \\ y + t(x - y) - y &= t(x - y) \\ &= \int_0^1 t^{-1} \langle \nabla f(y + t(x - y)) - \nabla f(y), t(x - y) \rangle dt \\ &\geq \int_0^1 t^{-1} \mu \|t(x - y)\|^2 dt = \mu \|x - y\|^2 \int_0^1 t dt \end{aligned}$$

## Инструменты для доказательства сходимости



2. Для достаточности предположим, что  $\langle \nabla f(x) - \nabla f(y), x - y \rangle \geq \mu \|x - y\|^2$ . Используя формулу Ньютона-Лейбница  $f(x) = f(y) + \int_0^1 \langle \nabla f(y + t(x - y)), x - y \rangle dt$ :

$$\begin{aligned} f(x) - f(y) - \langle \nabla f(y), x - y \rangle &= \int_0^1 \langle \nabla f(y + t(x - y)), x - y \rangle dt - \langle \nabla f(y), x - y \rangle \\ &\stackrel{\langle \nabla f(y), x - y \rangle = \int_0^1 \langle \nabla f(y), x - y \rangle dt}{=} \int_0^1 \langle \nabla f(y + t(x - y)) - \nabla f(y), (x - y) \rangle dt \\ &\stackrel{y+t(x-y)-y=t(x-y)}{=} \int_0^1 t^{-1} \langle \nabla f(y + t(x - y)) - \nabla f(y), t(x - y) \rangle dt \\ &\geq \int_0^1 t^{-1} \mu \|t(x - y)\|^2 dt = \mu \|x - y\|^2 \int_0^1 t dt = \frac{\mu}{2} \|x - y\|_2^2 \end{aligned}$$

## Инструменты для доказательства сходимости



2. Для достаточности предположим, что  $\langle \nabla f(x) - \nabla f(y), x - y \rangle \geq \mu \|x - y\|^2$ . Используя формулу Ньютона-Лейбница  $f(x) = f(y) + \int_0^1 \langle \nabla f(y + t(x - y)), x - y \rangle dt$ :

$$\begin{aligned} f(x) - f(y) - \langle \nabla f(y), x - y \rangle &= \int_0^1 \langle \nabla f(y + t(x - y)), x - y \rangle dt - \langle \nabla f(y), x - y \rangle \\ &\stackrel{\langle \nabla f(y), x - y \rangle = \int_0^1 \langle \nabla f(y), x - y \rangle dt}{=} \int_0^1 \langle \nabla f(y + t(x - y)) - \nabla f(y), (x - y) \rangle dt \\ &\stackrel{y+t(x-y)-y=t(x-y)}{=} \int_0^1 t^{-1} \langle \nabla f(y + t(x - y)) - \nabla f(y), t(x - y) \rangle dt \\ &\geq \int_0^1 t^{-1} \mu \|t(x - y)\|^2 dt = \mu \|x - y\|^2 \int_0^1 t dt = \frac{\mu}{2} \|x - y\|_2^2 \end{aligned}$$

## Инструменты для доказательства сходимости



2. Для достаточности предположим, что  $\langle \nabla f(x) - \nabla f(y), x - y \rangle \geq \mu \|x - y\|^2$ . Используя формулу Ньютона-Лейбница  $f(x) = f(y) + \int_0^1 \langle \nabla f(y + t(x - y)), x - y \rangle dt$ :

$$\begin{aligned} f(x) - f(y) - \langle \nabla f(y), x - y \rangle &= \int_0^1 \langle \nabla f(y + t(x - y)), x - y \rangle dt - \langle \nabla f(y), x - y \rangle \\ &\stackrel{\langle \nabla f(y), x - y \rangle = \int_0^1 \langle \nabla f(y), x - y \rangle dt}{=} \int_0^1 \langle \nabla f(y + t(x - y)) - \nabla f(y), (x - y) \rangle dt \\ &\stackrel{y+t(x-y)-y=t(x-y)}{=} \int_0^1 t^{-1} \langle \nabla f(y + t(x - y)) - \nabla f(y), t(x - y) \rangle dt \\ &\geq \int_0^1 t^{-1} \mu \|t(x - y)\|^2 dt = \mu \|x - y\|^2 \int_0^1 t dt = \frac{\mu}{2} \|x - y\|_2^2 \end{aligned}$$

Таким образом, критерий сильной выпуклости выполнен

$$f(x) \geq f(y) + \langle \nabla f(y), x - y \rangle + \frac{\mu}{2} \|x - y\|_2^2$$

## Инструменты для доказательства сходимости



2. Для достаточности предположим, что  $\langle \nabla f(x) - \nabla f(y), x - y \rangle \geq \mu \|x - y\|^2$ . Используя формулу Ньютона-Лейбница  $f(x) = f(y) + \int_0^1 \langle \nabla f(y + t(x - y)), x - y \rangle dt$ :

$$\begin{aligned} f(x) - f(y) - \langle \nabla f(y), x - y \rangle &= \int_0^1 \langle \nabla f(y + t(x - y)), x - y \rangle dt - \langle \nabla f(y), x - y \rangle \\ &\stackrel{\langle \nabla f(y), x - y \rangle = \int_0^1 \langle \nabla f(y), x - y \rangle dt}{=} \int_0^1 \langle \nabla f(y + t(x - y)) - \nabla f(y), (x - y) \rangle dt \\ &\stackrel{y+t(x-y)-y=t(x-y)}{=} \int_0^1 t^{-1} \langle \nabla f(y + t(x - y)) - \nabla f(y), t(x - y) \rangle dt \\ &\geq \int_0^1 t^{-1} \mu \|t(x - y)\|^2 dt = \mu \|x - y\|^2 \int_0^1 t dt = \frac{\mu}{2} \|x - y\|_2^2 \end{aligned}$$

Таким образом, критерий сильной выпуклости выполнен

$$f(x) \geq f(y) + \langle \nabla f(y), x - y \rangle + \frac{\mu}{2} \|x - y\|_2^2 \text{ или, эквивалентно:}$$

## Инструменты для доказательства сходимости



2. Для достаточности предположим, что  $\langle \nabla f(x) - \nabla f(y), x - y \rangle \geq \mu \|x - y\|^2$ . Используя формулу Ньютона-Лейбница  $f(x) = f(y) + \int_0^1 \langle \nabla f(y + t(x - y)), x - y \rangle dt$ :

$$\begin{aligned}
 f(x) - f(y) - \langle \nabla f(y), x - y \rangle &= \int_0^1 \langle \nabla f(y + t(x - y)), x - y \rangle dt - \langle \nabla f(y), x - y \rangle \\
 \langle \nabla f(y), x - y \rangle = \int_0^1 \langle \nabla f(y), x - y \rangle dt &= \int_0^1 \langle \nabla f(y + t(x - y)) - \nabla f(y), (x - y) \rangle dt \\
 y + t(x - y) - y = t(x - y) &= \int_0^1 t^{-1} \langle \nabla f(y + t(x - y)) - \nabla f(y), t(x - y) \rangle dt \\
 &\geq \int_0^1 t^{-1} \mu \|t(x - y)\|^2 dt = \mu \|x - y\|^2 \int_0^1 t dt = \frac{\mu}{2} \|x - y\|_2^2
 \end{aligned}$$

Таким образом, критерий сильной выпуклости выполнен

$$f(x) \geq f(y) + \langle \nabla f(y), x - y \rangle + \frac{\mu}{2} \|x - y\|_2^2 \text{ или, эквивалентно:}$$

$$\text{меняем } x \text{ и } y \quad - \langle \nabla f(x), x - y \rangle \leq - \left( f(x) - f(y) + \frac{\mu}{2} \|x - y\|_2^2 \right)$$



Theorem

Пусть  $f : \mathbb{R}^n \rightarrow \mathbb{R}$  — выпуклая и дифференцируемая функция. Пусть  $S \subseteq \mathbb{R}^n$  — замкнутое выпуклое множество, и существует минимизатор  $x^*$  функции  $f$  на  $S$ ; кроме того, предположим, что  $f$  является гладкой на  $S$  с параметром  $L$ . Алгоритм метода проекции градиента с шагом  $\frac{1}{L}$  обеспечивает следующую сходимость после  $k > 0$  итераций:

$$f(x_k) - f^* \leq \frac{L\|x_0 - x^*\|_2^2}{2k}$$

$$f(x) = \frac{1}{2}x^4 + \frac{1}{2}x^2$$

$$f'' = x^2 + 1$$

↗  
В точности совпадает  
с GD

# Скорость сходимости для гладкого выпуклого случая



## Theorem

Пусть  $f : \mathbb{R}^n \rightarrow \mathbb{R}$  — выпуклая и дифференцируемая функция. Пусть  $S \subseteq \mathbb{R}^n$  — замкнутое выпуклое множество, и существует минимизатор  $x^*$  функции  $f$  на  $S$ ; кроме того, предположим, что  $f$  является гладкой на  $S$  с параметром  $L$ . Алгоритм метода проекции градиента с шагом  $\frac{1}{L}$  обеспечивает следующую сходимость после  $k > 0$  итераций:

$$f(x_k) - f^* \leq \frac{L\|x_0 - x^*\|_2^2}{2k}$$

$$x_{k+1} = \Pi_S(y_k)$$

- Докажем лемму о достаточном убывании, полагая  $y_k = x_k - \frac{1}{L}\nabla f(x_k)$  и используя теорему косинусов  
 $2x^T y = \|x\|^2 + \|y\|^2 - \|x - y\|^2$ :



### Theorem

Пусть  $f : \mathbb{R}^n \rightarrow \mathbb{R}$  — выпуклая и дифференцируемая функция. Пусть  $S \subseteq \mathbb{R}^n$  — замкнутое выпуклое множество, и существует минимизатор  $x^*$  функции  $f$  на  $S$ ; кроме того, предположим, что  $f$  является гладкой на  $S$  с параметром  $L$ . Алгоритм метода проекции градиента с шагом  $\frac{1}{L}$  обеспечивает следующую сходимость после  $k > 0$  итераций:

$$f(x_k) - f^* \leq \frac{L\|x_0 - x^*\|_2^2}{2k}$$

1. Докажем лемму о достаточном убывании, полагая  $y_k = x_k - \frac{1}{L}\nabla f(x_k)$  и используя теорему косинусов  $2x^T y = \|x\|^2 + \|y\|^2 - \|x - y\|^2$ :

Гладкость:

$$f(x_{k+1}) \leq f(x_k) + \langle \nabla f(x_k), x_{k+1} - x_k \rangle + \frac{L}{2} \|x_{k+1} - x_k\|^2$$

*лишнее  
написано*

# Скорость сходимости для гладкого выпуклого случая



## Theorem

Пусть  $f : \mathbb{R}^n \rightarrow \mathbb{R}$  — выпуклая и дифференцируемая функция. Пусть  $S \subseteq \mathbb{R}^n$  — замкнутое выпуклое множество, и существует минимизатор  $x^*$  функции  $f$  на  $S$ ; кроме того, предположим, что  $f$  является гладкой на  $S$  с параметром  $L$ . Алгоритм метода проекции градиента с шагом  $\frac{1}{L}$  обеспечивает следующую сходимость после  $k > 0$  итераций:

$$f(x_k) - f^* \leq \frac{L\|x_0 - x^*\|_2^2}{2k}$$

1. Докажем лемму о достаточном убывании, полагая  $y_k = x_k - \frac{1}{L}\nabla f(x_k)$  и используя теорему косинусов  $2x^T y = \|x\|^2 + \|y\|^2 - \|x - y\|^2$ :

$$\nabla f(x_k) = (x_k - y_k) \cdot L$$

Гладкость:  $f(x_{k+1}) \leq f(x_k) + \langle \nabla f(x_k), x_{k+1} - x_k \rangle + \frac{L}{2} \|x_{k+1} - x_k\|^2$

Метод:  $= f(x_k) - L\langle y_k - x_k, x_{k+1} - x_k \rangle + \frac{L}{2} \|x_{k+1} - x_k\|^2$

# Скорость сходимости для гладкого выпуклого случая



## Theorem

Пусть  $f : \mathbb{R}^n \rightarrow \mathbb{R}$  — выпуклая и дифференцируемая функция. Пусть  $S \subseteq \mathbb{R}^n$  — замкнутое выпуклое множество, и существует минимизатор  $x^*$  функции  $f$  на  $S$ ; кроме того, предположим, что  $f$  является гладкой на  $S$  с параметром  $L$ . Алгоритм метода проекции градиента с шагом  $\frac{1}{L}$  обеспечивает следующую сходимость после  $k > 0$  итераций:

$$f(x_k) - f^* \leq \frac{L\|x_0 - x^*\|_2^2}{2k}$$

1. Докажем лемму о достаточном убывании, полагая  $y_k = x_k - \frac{1}{L}\nabla f(x_k)$  и используя теорему косинусов

$$2x^T y = \|x\|^2 + \|y\|^2 - \|x - y\|^2:$$

Гладкость:

$$f(x_{k+1}) \leq f(x_k) + \langle \nabla f(x_k), x_{k+1} - x_k \rangle + \frac{L}{2} \|x_{k+1} - x_k\|^2$$

Метод:

$$= f(x_k) - L\langle y_k - x_k, x_{k+1} - x_k \rangle + \frac{L}{2} \|x_{k+1} - x_k\|^2$$

Теорема косинусов:

$$= f(x_k) - \frac{L}{2} (\underbrace{\|y_k - x_k\|^2}_{\text{---}} + \underbrace{\|x_{k+1} - x_k\|^2}_{\text{---}} - \underbrace{\|y_k - x_{k+1}\|^2}_{\text{---}}) + \frac{L}{2} \|x_{k+1} - x_k\|^2$$

# Скорость сходимости для гладкого выпуклого случая



## Theorem

Пусть  $f : \mathbb{R}^n \rightarrow \mathbb{R}$  — выпуклая и дифференцируемая функция. Пусть  $S \subseteq \mathbb{R}^n$  — замкнутое выпуклое множество, и существует минимизатор  $x^*$  функции  $f$  на  $S$ ; кроме того, предположим, что  $f$  является гладкой на  $S$  с параметром  $L$ . Алгоритм метода проекции градиента с шагом  $\frac{1}{L}$  обеспечивает следующую сходимость после  $k > 0$  итераций:

$$f(x_k) - f^* \leq \frac{L\|x_0 - x^*\|_2^2}{2k}$$

- Докажем лемму о достаточном убывании, полагая  $y_k = x_k - \frac{1}{L}\nabla f(x_k)$  и используя теорему косинусов  
 $2x^T y = \|x\|^2 + \|y\|^2 - \|x - y\|^2$ :

~~Гладкость:  $\frac{\|x-y\|^2}{2} = \frac{1}{2}(x^T y + y^T x - \|x\|^2 - \|y\|^2)$~~

$$f(x_{k+1}) \leq f(x_k) + \langle \nabla f(x_k), x_{k+1} - x_k \rangle + \frac{L}{2} \|x_{k+1} - x_k\|^2$$

Метод:

$$= f(x_k) - L\langle y_k - x_k, x_{k+1} - x_k \rangle + \frac{L}{2} \|x_{k+1} - x_k\|^2$$

Теорема косинусов:

$$\frac{1}{2L} \|\nabla f(x_k)\|^2 \leq f(x_k) - f(x_{k+1}) = f(x_k) - \frac{L}{2} (\|y_k - x_k\|^2 + \|x_{k+1} - x_k\|^2 - \|y_k - x_{k+1}\|^2) + \frac{L}{2} \|x_{k+1} - x_k\|^2$$
$$= f(x_k) - \frac{1}{2L} \|\nabla f(x_k)\|^2 + \frac{L}{2} \|y_k - x_{k+1}\|^2$$

## Скорость сходимости для гладкого выпуклого случая



2. Пока что мы не получаем немедленного прогресса на каждом шаге. Снова используем теорему косинусов:

$$\left\langle \frac{1}{L} \nabla f(x_k), \underline{x_k - x^*} \right\rangle = \frac{1}{2} \left( \frac{1}{L^2} \|\nabla f(x_k)\|^2 + \|x_k - x^*\|^2 - \|x_k - x^* - \frac{1}{L} \nabla f(x_k)\|^2 \right)$$

*Уk*

$$\langle \nabla f(x_k), x_k - x^* \rangle = \frac{L}{2} \left( \frac{1}{L^2} \|\nabla f(x_k)\|^2 + \|x_k - x^*\|^2 - \|y_k - x^*\|^2 \right)$$

## Скорость сходимости для гладкого выпуклого случая



2. Пока что мы не получаем немедленного прогресса на каждом шаге. Снова используем теорему косинусов:

$$\left\langle \frac{1}{L} \nabla f(x_k), x_k - x^* \right\rangle = \frac{1}{2} \left( \frac{1}{L^2} \|\nabla f(x_k)\|^2 + \|x_k - x^*\|^2 - \|x_k - x^* - \frac{1}{L} \nabla f(x_k)\|^2 \right)$$

$$\langle \nabla f(x_k), x_k - x^* \rangle = \frac{L}{2} \left( \frac{1}{L^2} \|\nabla f(x_k)\|^2 + \|x_k - x^*\|^2 - \|y_k - x^*\|^2 \right)$$

3. Теперь используем свойство проекции:  $\|x - \text{proj}_S(y)\|^2 + \|y - \text{proj}_S(y)\|^2 \leq \|x - y\|^2$  с  $x = x^*, y = y_k$ :

$$\|x^* - \text{proj}_S(y_k)\|^2 + \|y_k - \text{proj}_S(y_k)\|^2 \leq \|x^* - y_k\|^2$$

$$\underline{\|y_k - x^*\|^2} \geq \|x^* - x_{k+1}\|^2 + \|y_k - x_{k+1}\|^2$$

PROJ( $y_k$ ) =  $x_{k+1}$

## Скорость сходимости для гладкого выпуклого случая



2. Пока что мы не получаем немедленного прогресса на каждом шаге. Снова используем теорему косинусов:

$$\begin{aligned}\left\langle \frac{1}{L} \nabla f(x_k), x_k - x^* \right\rangle &= \frac{1}{2} \left( \frac{1}{L^2} \|\nabla f(x_k)\|^2 + \|x_k - x^*\|^2 - \|x_k - x^* - \frac{1}{L} \nabla f(x_k)\|^2 \right) \\ \langle \nabla f(x_k), x_k - x^* \rangle &= \frac{L}{2} \left( \frac{1}{L^2} \|\nabla f(x_k)\|^2 + \|x_k - x^*\|^2 - \|y_k - x^*\|^2 \right)\end{aligned}$$

3. Теперь используем свойство проекции:  $\|x - \text{proj}_S(y)\|^2 + \|y - \text{proj}_S(y)\|^2 \leq \|x - y\|^2$  с  $x = x^*, y = y_k$ :

$$\begin{aligned}\|x^* - \text{proj}_S(y_k)\|^2 + \|y_k - \text{proj}_S(y_k)\|^2 &\leq \|x^* - y_k\|^2 \\ \|y_k - x^*\|^2 &\geq \|x^* - x_{k+1}\|^2 + \|y_k - x_{k+1}\|^2\end{aligned}$$

4. Теперь, используя выпуклость и предыдущую часть:

## Скорость сходимости для гладкого выпуклого случая



2. Пока что мы не получаем немедленного прогресса на каждом шаге. Снова используем теорему косинусов:

$$\begin{aligned}\left\langle \frac{1}{L} \nabla f(x_k), x_k - x^* \right\rangle &= \frac{1}{2} \left( \frac{1}{L^2} \|\nabla f(x_k)\|^2 + \|x_k - x^*\|^2 - \|x_k - x^* - \frac{1}{L} \nabla f(x_k)\|^2 \right) \\ \langle \nabla f(x_k), x_k - x^* \rangle &= \frac{L}{2} \left( \frac{1}{L^2} \|\nabla f(x_k)\|^2 + \|x_k - x^*\|^2 - \|y_k - x^*\|^2 \right)\end{aligned}$$

3. Теперь используем свойство проекции:  $\|x - \text{proj}_S(y)\|^2 + \|y - \text{proj}_S(y)\|^2 \leq \|x - y\|^2$  с  $x = x^*, y = y_k$ :

$$\begin{aligned}\|x^* - \text{proj}_S(y_k)\|^2 + \|y_k - \text{proj}_S(y_k)\|^2 &\leq \|x^* - y_k\|^2 \\ \|y_k - x^*\|^2 &\geq \|x^* - x_{k+1}\|^2 + \|y_k - x_{k+1}\|^2\end{aligned}$$

4. Теперь, используя выпуклость и предыдущую часть:

Выпуклость:

$$f(x_k) - f^* \leq \langle \nabla f(x_k), x_k - x^* \rangle$$

## Скорость сходимости для гладкого выпуклого случая



2. Пока что мы не получаем немедленного прогресса на каждом шаге. Снова используем теорему косинусов:

$$\left\langle \frac{1}{L} \nabla f(x_k), x_k - x^* \right\rangle = \frac{1}{2} \left( \frac{1}{L^2} \|\nabla f(x_k)\|^2 + \|x_k - x^*\|^2 - \|x_k - x^* - \frac{1}{L} \nabla f(x_k)\|^2 \right)$$

$$\langle \nabla f(x_k), x_k - x^* \rangle = \frac{L}{2} \left( \underbrace{\frac{1}{L^2} \|\nabla f(x_k)\|^2}_{\text{red}} + \underbrace{\|x_k - x^*\|^2}_{\text{blue}} - \underbrace{\|y_k - x^*\|^2}_{\text{orange}} \right)$$

3. Теперь используем свойство проекции:  $\|x - \text{proj}_S(y)\|^2 + \|y - \text{proj}_S(y)\|^2 \leq \|x - y\|^2$  с  $x = x^*, y = y_k$ :

$$\begin{aligned} \|x^* - \text{proj}_S(y_k)\|^2 + \|y_k - \text{proj}_S(y_k)\|^2 &\leq \|x^* - y_k\|^2 \\ \underbrace{- \|y_k - x^*\|^2}_{\text{orange}} &\leq \|x^* - x_{k+1}\|^2 + \underbrace{\|y_k - x_{k+1}\|^2}_{\text{orange}} \end{aligned}$$

4. Теперь, используя выпуклость и предыдущую часть:

Выпуклость:

$$f(x_k) - f^* \leq \langle \nabla f(x_k), x_k - x^* \rangle$$

$$\leq \frac{L}{2} \left( \underbrace{\frac{1}{L^2} \|\nabla f(x_k)\|^2}_{\text{red}} + \underbrace{\|x_k - x^*\|^2}_{\text{blue}} - \underbrace{\|x_{k+1} - x^*\|^2}_{\text{orange}} - \underbrace{\|y_k - x_{k+1}\|^2}_{\text{orange}} \right)$$

## Скорость сходимости для гладкого выпуклого случая



2. Пока что мы не получаем немедленного прогресса на каждом шаге. Снова используем теорему косинусов:

$$\left\langle \frac{1}{L} \nabla f(x_k), x_k - x^* \right\rangle = \frac{1}{2} \left( \frac{1}{L^2} \|\nabla f(x_k)\|^2 + \|x_k - x^*\|^2 - \|x_k - x^* - \frac{1}{L} \nabla f(x_k)\|^2 \right)$$

$$\langle \nabla f(x_k), x_k - x^* \rangle = \frac{L}{2} \left( \frac{1}{L^2} \|\nabla f(x_k)\|^2 + \|x_k - x^*\|^2 - \|y_k - x^*\|^2 \right)$$

3. Теперь используем свойство проекции:  $\|x - \text{proj}_S(y)\|^2 + \|y - \text{proj}_S(y)\|^2 \leq \|x - y\|^2$  с  $x = x^*, y = y_k$ :

$$\begin{aligned} \|x^* - \text{proj}_S(y_k)\|^2 + \|y_k - \text{proj}_S(y_k)\|^2 &\leq \|x^* - y_k\|^2 \\ \|y_k - x^*\|^2 &\geq \|x^* - x_{k+1}\|^2 + \|y_k - x_{k+1}\|^2 \end{aligned}$$

4. Теперь, используя выпуклость и предыдущую часть:

Выпуклость:

$$f(x_k) - f^* \leq \langle \nabla f(x_k), x_k - x^* \rangle$$

$$\leq \frac{L}{2} \left( \frac{1}{L^2} \|\nabla f(x_k)\|^2 + \|x_k - x^*\|^2 - \|x_{k+1} - x^*\|^2 - \|y_k - x_{k+1}\|^2 \right)$$

Сумма для  $i = 0, k-1$

$$\sum_{i=0}^{k-1} [f(x_i) - f^*] \leq \sum_{i=0}^{k-1} \frac{1}{2L} \|\nabla f(x_i)\|^2 + \frac{L}{2} \|x_0 - x^*\|^2 - \frac{L}{2} \sum_{i=0}^{i-1} \|y_i - x_{i+1}\|^2$$

ТЕЛЕСКОПИЧЕСКАЯ СУММА

## Скорость сходимости для гладкого выпуклого случая



5. Оценим градиенты с помощью неравенства достаточного убывания 7:

## Скорость сходимости для гладкого выпуклого случая



5. Оценим градиенты с помощью неравенства достаточного убывания 7:

$$\sum_{i=0}^{k-1} [f(x_i) - f^*] \leq \sum_{i=0}^{k-1} \left[ f(x_i) - f(x_{i+1}) + \frac{L}{2} \|y_i - x_{i+1}\|^2 \right] + \frac{L}{2} \|x_0 - x^*\|^2 - \frac{L}{2} \sum_{i=0}^{i-1} \|y_i - x_{i+1}\|^2$$

## Скорость сходимости для гладкого выпуклого случая



5. Оценим градиенты с помощью неравенства достаточного убывания 7:

$$\begin{aligned} \sum_{i=0}^{k-1} [f(x_i) - f^*] &\leq \sum_{i=0}^{k-1} \left[ f(x_i) - f(x_{i+1}) + \frac{L}{2} \|y_i - x_{i+1}\|^2 \right] + \cancel{\frac{L}{2} \|x_0 - x^*\|^2} - \cancel{\frac{L}{2} \sum_{i=0}^{i-1} \|y_i - x_{i+1}\|^2} \\ &\leq \cancel{f(x_0) - f(x_k)} + \cancel{\frac{L}{2} \sum_{i=0}^{i-1} \|y_i - x_{i+1}\|^2} + \cancel{\frac{L}{2} \|x_0 - x^*\|^2} - \cancel{\frac{L}{2} \sum_{i=0}^{i-1} \|y_i - x_{i+1}\|^2} \end{aligned}$$

## Скорость сходимости для гладкого выпуклого случая



5. Оценим градиенты с помощью неравенства достаточного убывания 7:

$$\begin{aligned} \sum_{i=0}^{k-1} [f(x_i) - f^*] &\leq \sum_{i=0}^{k-1} \left[ f(x_i) - f(x_{i+1}) + \frac{L}{2} \|y_i - x_{i+1}\|^2 \right] + \frac{L}{2} \|x_0 - x^*\|^2 - \frac{L}{2} \sum_{i=0}^{i-1} \|y_i - x_{i+1}\|^2 \\ &\leq f(x_0) - f(x_k) + \frac{L}{2} \sum_{i=0}^{i-1} \|y_i - x_{i+1}\|^2 + \frac{L}{2} \|x_0 - x^*\|^2 - \frac{L}{2} \sum_{i=0}^{i-1} \|y_i - x_{i+1}\|^2 \\ &\leq f(x_0) - f(x_k) + \frac{L}{2} \|x_0 - x^*\|^2 \end{aligned}$$

## Скорость сходимости для гладкого выпуклого случая



5. Оценим градиенты с помощью неравенства достаточного убывания 7:

$$\begin{aligned} \sum_{i=0}^{k-1} [f(x_i) - f^*] &\leq \sum_{i=0}^{k-1} \left[ f(x_i) - f(x_{i+1}) + \frac{L}{2} \|y_i - x_{i+1}\|^2 \right] + \frac{L}{2} \|x_0 - x^*\|^2 - \frac{L}{2} \sum_{i=0}^{i-1} \|y_i - x_{i+1}\|^2 \\ &\leq f(x_0) - f(x_k) + \frac{L}{2} \sum_{i=0}^{i-1} \|y_i - x_{i+1}\|^2 + \frac{L}{2} \|x_0 - x^*\|^2 - \frac{L}{2} \sum_{i=0}^{i-1} \|y_i - x_{i+1}\|^2 \\ &\leq f(x_0) - f(x_k) + \frac{L}{2} \|x_0 - x^*\|^2 \\ \sum_{i=0}^{k-1} f(x_i) - kf^* &\leq f(x_0) - f(x_k) + \frac{L}{2} \|x_0 - x^*\|^2 \end{aligned}$$

## Скорость сходимости для гладкого выпуклого случая



5. Оценим градиенты с помощью неравенства достаточного убывания 7:

$$\begin{aligned}\sum_{i=0}^{k-1} [f(x_i) - f^*] &\leq \sum_{i=0}^{k-1} \left[ f(x_i) - f(x_{i+1}) + \frac{L}{2} \|y_i - x_{i+1}\|^2 \right] + \frac{L}{2} \|x_0 - x^*\|^2 - \frac{L}{2} \sum_{i=0}^{i-1} \|y_i - x_{i+1}\|^2 \\ &\leq f(x_0) - f(x_k) + \frac{L}{2} \sum_{i=0}^{i-1} \|y_i - x_{i+1}\|^2 + \frac{L}{2} \|x_0 - x^*\|^2 - \frac{L}{2} \sum_{i=0}^{i-1} \|y_i - x_{i+1}\|^2 \\ &\leq f(x_0) - f(x_k) + \frac{L}{2} \|x_0 - x^*\|^2\end{aligned}$$

$$\sum_{i=0}^{k-1} f(x_i) - kf^* \leq f(x_0) - f(x_k) + \frac{L}{2} \|x_0 - x^*\|^2$$

$$\sum_{i=1}^k [f(x_i) - f^*] \leq \frac{L}{2} \|x_0 - x^*\|^2$$



## Скорость сходимости для гладкого выпуклого случая ⚡⚡⚡⚡⚡

6. Из неравенства достаточного убывания

$$f(x_{k+1}) \leq f(x_k) - \frac{1}{2L} \|\nabla f(x_k)\|^2 + \frac{L}{2} \|y_k - x_{k+1}\|^2,$$

## Скорость сходимости для гладкого выпуклого случая ⚡⚡⚡⚡⚡

6. Из неравенства достаточного убывания

$$f(x_{k+1}) \leq f(x_k) - \frac{1}{2L} \|\nabla f(x_k)\|^2 + \frac{L}{2} \|y_k - x_{k+1}\|^2,$$

## Скорость сходимости для гладкого выпуклого случая



6. Из неравенства достаточного убывания

$$f(x_{k+1}) \leq f(x_k) - \frac{1}{2L} \|\nabla f(x_k)\|^2 + \frac{L}{2} \|y_k - x_{k+1}\|^2,$$

используем тот факт, что  $\overrightarrow{x_{k+1} = \text{proj}_S(y_k)}$ . По определению проекции,

$$\|y_k - x_{k+1}\| \leq \|y_k - x_k\|,$$



## Скорость сходимости для гладкого выпуклого случая



6. Из неравенства достаточного убывания

$$f(x_{k+1}) \leq f(x_k) - \frac{1}{2L} \|\nabla f(x_k)\|^2 + \frac{L}{2} \|y_k - x_{k+1}\|^2,$$

$$\leq \frac{1}{2} \cdot \frac{1}{L^2} \|\nabla f(x_k)\|_e^2$$

используем тот факт, что  $x_{k+1} = \text{proj}_S(y_k)$ . По определению проекции,

$$\|y_k - x_{k+1}\| \leq \|y_k - x_k\|,$$

и вспомним, что  $y_k = x_k - \frac{1}{L} \nabla f(x_k)$  означает  $\|y_k - x_k\| = \frac{1}{L} \|\nabla f(x_k)\|$ . Следовательно,

$$\frac{L}{2} \|y_k - x_{k+1}\|^2 \leq \frac{L}{2} \|y_k - x_k\|^2 = \frac{L}{2} \frac{1}{L^2} \|\nabla f(x_k)\|^2 = \frac{1}{2L} \|\nabla f(x_k)\|^2.$$

## Скорость сходимости для гладкого выпуклого случая



6. Из неравенства достаточного убывания

$$f(x_{k+1}) \leq f(x_k) - \frac{1}{2L} \|\nabla f(x_k)\|^2 + \frac{L}{2} \|y_k - x_{k+1}\|^2,$$

используем тот факт, что  $x_{k+1} = \text{proj}_S(y_k)$ . По определению проекции,

$$\|y_k - x_{k+1}\| \leq \|y_k - x_k\|,$$

и вспомним, что  $y_k = x_k - \frac{1}{L} \nabla f(x_k)$  означает  $\|y_k - x_k\| = \frac{1}{L} \|\nabla f(x_k)\|$ . Следовательно,

$$\frac{L}{2} \|y_k - x_{k+1}\|^2 \leq \frac{L}{2} \|y_k - x_k\|^2 = \frac{L}{2} \frac{1}{L^2} \|\nabla f(x_k)\|^2 = \frac{1}{2L} \|\nabla f(x_k)\|^2.$$

Подставим обратно в (\*):

$$f(x_{k+1}) \leq f(x_k) - \frac{1}{2L} \|\nabla f(x_k)\|^2 + \frac{1}{2L} \|\nabla f(x_k)\|^2 = f(x_k).$$

## Скорость сходимости для гладкого выпуклого случая



6. Из неравенства достаточного убывания

$$f(x_{k+1}) \leq f(x_k) - \frac{1}{2L} \|\nabla f(x_k)\|^2 + \frac{L}{2} \|y_k - x_{k+1}\|^2,$$

используем тот факт, что  $x_{k+1} = \text{proj}_S(y_k)$ . По определению проекции,

$$\|y_k - x_{k+1}\| \leq \|y_k - x_k\|,$$

и вспомним, что  $y_k = x_k - \frac{1}{L} \nabla f(x_k)$  означает  $\|y_k - x_k\| = \frac{1}{L} \|\nabla f(x_k)\|$ . Следовательно,

$$\frac{L}{2} \|y_k - x_{k+1}\|^2 \leq \frac{L}{2} \|y_k - x_k\|^2 = \frac{L}{2} \frac{1}{L^2} \|\nabla f(x_k)\|^2 = \frac{1}{2L} \|\nabla f(x_k)\|^2.$$

Подставим обратно в (\*):

$$f(x_{k+1}) \leq f(x_k) - \frac{1}{2L} \|\nabla f(x_k)\|^2 + \frac{1}{2L} \|\nabla f(x_k)\|^2 = f(x_k).$$

Таким образом,

$$f(x_{k+1}) \leq f(x_k) \quad \text{для каждого } k,$$

то есть  $\{f(x_k)\}$  — монотонно невозрастающая последовательность.

## Скорость сходимости для гладкого выпуклого случая



7. Итоговая оценка сходимости Из шага 5 мы уже установили

$$\sum_{i=0}^{k-1} [f(x_i) - f^*] \leq \frac{L}{2} \|x_0 - x^*\|_2^2.$$



## Скорость сходимости для гладкого выпуклого случая



7. Итоговая оценка сходимости Из шага 5 мы уже установили

$$\sum_{i=0}^{k-1} [f(x_i) - f^*] \leq \frac{L}{2} \|x_0 - x^*\|_2^2.$$

## Скорость сходимости для гладкого выпуклого случая



7. Итоговая оценка сходимости Из шага 5 мы уже установили

$$\sum_{i=0}^{k-1} [f(x_i) - f^*] \leq \frac{L}{2} \|x_0 - x^*\|_2^2.$$

Поскольку  $f(x_i)$  убывает по  $i$ , в частности  $f(x_k) \leq f(x_i)$  для всех  $i \leq k$ . Следовательно,

$$k [f(x_k) - f^*] \leq \sum_{i=0}^{k-1} [f(x_i) - f^*] \leq \frac{L}{2} \|x_0 - x^*\|_2^2,$$

## Скорость сходимости для гладкого выпуклого случая



7. Итоговая оценка сходимости Из шага 5 мы уже установили

$$\sum_{i=0}^{k-1} [f(x_i) - f^*] \leq \frac{L}{2} \|x_0 - x^*\|_2^2.$$

Поскольку  $f(x_i)$  убывает по  $i$ , в частности  $f(x_k) \leq f(x_i)$  для всех  $i \leq k$ . Следовательно,

$$k [f(x_k) - f^*] \leq \sum_{i=0}^{k-1} [f(x_i) - f^*] \leq \frac{L}{2} \|x_0 - x^*\|_2^2,$$

откуда немедленно получаем

$$f(x_k) - f^* \leq \frac{L\|x_0 - x^*\|_2^2}{2k}.$$



Это завершает доказательство скорости сходимости  $\mathcal{O}(\frac{1}{k})$  для выпуклой  $L$ -гладкой функции  $f$  в условной задаче оптимизации.

# Скорость сходимости для гладкого сильно выпуклого случая



## i Theorem



Пусть  $f : \mathbb{R}^n \rightarrow \mathbb{R}$  —  $\mu$ -сильно выпуклая функция. Пусть  $S \subseteq \mathbb{R}^n$  — замкнутое выпуклое множество, и существует минимизатор  $x^*$  функции  $f$  на  $S$ ; кроме того, предположим, что  $f$  является гладкой на  $S$  с параметром  $L$ . Алгоритм метода проекции градиента с шагом  $\alpha \leq \frac{1}{L}$  обеспечивает следующую сходимость после  $k > 0$  итераций:

$x^*$   $\xrightarrow{\text{PGD}}$   $x^*$

$$\|x_k - x^*\|_2^2 \leq (1 - \alpha\mu)^k \|x_0 - x^*\|_2^2$$

## Доказательство

- Сначала докажем свойство стационарной точки:  $\text{proj}_S(x^* - \alpha\nabla f(x^*)) = x^*$ .

Это следует из критерия проекции и условия оптимальности первого порядка для  $x^*$ . Пусть  $y = x^* - \alpha\nabla f(x^*)$ . Нужно показать, что  $\langle y - x^*, x - x^* \rangle \leq 0$  для всех  $x \in S$ .

$$\langle (x^* - \alpha\nabla f(x^*)) - x^*, x - x^* \rangle = -\alpha \langle \nabla f(x^*), x - x^* \rangle \leq 0$$

Неравенство выполняется, так как  $\alpha > 0$  и  $\langle \nabla f(x^*), x - x^* \rangle \geq 0$  — условие оптимальности для  $x^*$ .

## Скорость сходимости для гладкого сильно выпуклого случая



1. Рассмотрим расстояние до решения, используя свойство стационарной точки:

## Скорость сходимости для гладкого сильно выпуклого случая



1. Рассмотрим расстояние до решения, используя свойство стационарной точки:

$$\|x_{k+1} - x^*\|_2^2 = \|\text{proj}_S(x_k - \alpha \nabla f(x_k)) - x^*\|_2^2$$

# Скорость сходимости для гладкого сильно выпуклого случая



1. Рассмотрим расстояние до решения, используя свойство стационарной точки:

$$\|x_{k+1} - x^*\|_2^2 = \|\text{proj}_S(x_k - \alpha \nabla f(x_k)) - x^*\|_2^2$$

свойство стационарной точки  $= \|\text{proj}_S(x_k - \alpha \nabla f(x_k)) - \text{proj}_S(x^* - \alpha \nabla f(x^*))\|_2^2$

# Скорость сходимости для гладкого сильно выпуклого случая



1. Рассмотрим расстояние до решения, используя свойство стационарной точки:

$$\begin{aligned}\|x_{k+1} - x^*\|_2^2 &= \|\text{proj}_S(x_k - \alpha \nabla f(x_k)) - x^*\|_2^2 \\ \text{свойство стационарной точки} &= \|\text{proj}_S(x_k - \alpha \nabla f(x_k)) - \text{proj}_S(x^* - \alpha \nabla f(x^*))\|_2^2 \\ \text{нерастягиваемость} &\leq \|x_k - \alpha \nabla f(x_k) - (x^* - \alpha \nabla f(x^*))\|_2^2\end{aligned}$$

---

# Скорость сходимости для гладкого сильно выпуклого случая



1. Рассмотрим расстояние до решения, используя свойство стационарной точки:

$$\begin{aligned}\|x_{k+1} - x^*\|_2^2 &= \|\text{proj}_S(x_k - \alpha \nabla f(x_k)) - x^*\|_2^2 \\ \text{свойство стационарной точки} &= \|\text{proj}_S(x_k - \alpha \nabla f(x_k)) - \text{proj}_S(x^* - \alpha \nabla f(x^*))\|_2^2 \\ \text{нерастягиваемость} &\leq \|x_k - \alpha \nabla f(x_k) - (x^* - \alpha \nabla f(x^*))\|_2^2 \\ &= \|x_k - x^*\|^2 - 2\alpha \langle \nabla f(x_k) - \nabla f(x^*), x_k - x^* \rangle + \alpha^2 \|\nabla f(x_k) - \nabla f(x^*)\|_2^2\end{aligned}$$

# Скорость сходимости для гладкого сильно выпуклого случая



1. Рассмотрим расстояние до решения, используя свойство стационарной точки:

$$\begin{aligned}\|x_{k+1} - x^*\|_2^2 &= \|\text{proj}_S(x_k - \alpha \nabla f(x_k)) - x^*\|_2^2 \\ \text{свойство стационарной точки} &= \|\text{proj}_S(x_k - \alpha \nabla f(x_k)) - \text{proj}_S(x^* - \alpha \nabla f(x^*))\|_2^2 \\ \text{нерастягиваемость} &\leq \|x_k - \alpha \nabla f(x_k) - (x^* - \alpha \nabla f(x^*))\|_2^2 \\ &= \|x_k - x^*\|^2 - 2\alpha \langle \nabla f(x_k) - \nabla f(x^*), x_k - x^* \rangle + \alpha^2 \|\nabla f(x_k) - \nabla f(x^*)\|_2^2\end{aligned}$$

2. Теперь используем гладкость из инструментов сходимости и сильную выпуклость:

# Скорость сходимости для гладкого сильно выпуклого случая



1. Рассмотрим расстояние до решения, используя свойство стационарной точки:

$$\begin{aligned}\|x_{k+1} - x^*\|_2^2 &= \|\text{proj}_S(x_k - \alpha \nabla f(x_k)) - x^*\|_2^2 \\ \text{свойство стационарной точки} &= \|\text{proj}_S(x_k - \alpha \nabla f(x_k)) - \text{proj}_S(x^* - \alpha \nabla f(x^*))\|_2^2 \\ \text{нерастягиваемость} &\leq \|x_k - \alpha \nabla f(x_k) - (x^* - \alpha \nabla f(x^*))\|_2^2 \\ &= \|x_k - x^*\|^2 - 2\alpha \langle \nabla f(x_k) - \nabla f(x^*), x_k - x^* \rangle + \alpha^2 \|\nabla f(x_k) - \nabla f(x^*)\|_2^2\end{aligned}$$

2. Теперь используем гладкость из инструментов сходимости и сильную выпуклость:

$$\text{гладкость } \|\nabla f(x_k) - \nabla f(x^*)\|_2^2 \leq 2L(f(x_k) - f(x^*) - \langle \nabla f(x^*), x_k - x^* \rangle)$$

# Скорость сходимости для гладкого сильно выпуклого случая



1. Рассмотрим расстояние до решения, используя свойство стационарной точки:

$$\begin{aligned}\|x_{k+1} - x^*\|_2^2 &= \|\text{proj}_S(x_k - \alpha \nabla f(x_k)) - x^*\|_2^2 \\ \text{свойство стационарной точки} &= \|\text{proj}_S(x_k - \alpha \nabla f(x_k)) - \text{proj}_S(x^* - \alpha \nabla f(x^*))\|_2^2 \\ \text{нерастягиваемость} &\leq \|x_k - \alpha \nabla f(x_k) - (x^* - \alpha \nabla f(x^*))\|_2^2 \\ &= \|x_k - x^*\|^2 - 2\alpha \langle \nabla f(x_k) - \nabla f(x^*), x_k - x^* \rangle + \alpha^2 \|\nabla f(x_k) - \nabla f(x^*)\|_2^2\end{aligned}$$

2. Теперь используем гладкость из инструментов сходимости и сильную выпуклость:

$$\text{гладкость } \|\nabla f(x_k) - \nabla f(x^*)\|_2^2 \leq 2L(f(x_k) - f(x^*) - \langle \nabla f(x^*), x_k - x^* \rangle)$$

$$\text{сильная выпуклость } -\langle \nabla f(x_k) - \nabla f(x^*), x_k - x^* \rangle \leq -\left(f(x_k) - f(x^*) + \frac{\mu}{2} \|x_k - x^*\|_2^2\right) - \langle \nabla f(x^*), x_k - x^* \rangle$$

# Скорость сходимости для гладкого сильно выпуклого случая



3. Подставим:

## Скорость сходимости для гладкого сильно выпуклого случая



3. Подставим:

$$\begin{aligned}\|x_{k+1} - x^*\|_2^2 &\leq \|x_k - x^*\|^2 - 2\alpha \left( f(x_k) - f(x^*) + \frac{\mu}{2} \|x_k - x^*\|_2^2 \right) - 2\alpha \langle \nabla f(x^*), x_k - x^* \rangle + \\ &\quad + \alpha^2 2L (f(x_k) - f(x^*) - \langle \nabla f(x^*), x_k - x^* \rangle)\end{aligned}$$

## Скорость сходимости для гладкого сильно выпуклого случая



3. Подставим:

$$\begin{aligned}\|x_{k+1} - x^*\|_2^2 &\leq \|x_k - x^*\|^2 - 2\alpha \left( f(x_k) - f(x^*) + \frac{\mu}{2} \|x_k - x^*\|_2^2 \right) - 2\alpha \langle \nabla f(x^*), x_k - x^* \rangle + \\ &\quad + \alpha^2 2L (f(x_k) - f(x^*) - \langle \nabla f(x^*), x_k - x^* \rangle) \\ &\leq (1 - \alpha\mu) \|x_k - x^*\|^2 + 2\alpha(\alpha L - 1) (f(x_k) - f(x^*) - \langle \nabla f(x^*), x_k - x^* \rangle)\end{aligned}$$

## Скорость сходимости для гладкого сильно выпуклого случая



3. Подставим:

$$\begin{aligned}\|x_{k+1} - x^*\|_2^2 &\leq \|x_k - x^*\|^2 - 2\alpha \left( f(x_k) - f(x^*) + \frac{\mu}{2} \|x_k - x^*\|_2^2 \right) - 2\alpha \langle \nabla f(x^*), x_k - x^* \rangle + \\ &\quad + \alpha^2 2L (f(x_k) - f(x^*) - \langle \nabla f(x^*), x_k - x^* \rangle) \\ &\leq (1 - \alpha\mu) \|x_k - x^*\|^2 + 2\alpha(\alpha L - 1) (f(x_k) - f(x^*) - \langle \nabla f(x^*), x_k - x^* \rangle)\end{aligned}$$

4. В силу выпуклости  $f$ :  $f(x_k) - f(x^*) - \langle \nabla f(x^*), x_k - x^* \rangle \geq 0$ . Следовательно, при  $\alpha \leq \frac{1}{L}$ :

$$\|x_{k+1} - x^*\|_2^2 \leq (1 - \alpha\mu) \|x_k - x^*\|^2,$$

что означает линейную сходимость метода со скоростью  $1 - \frac{\mu}{L}$ .

$$S = \{ x \in \mathbb{R}^n : x \geq 0 ; 1^T x = 1 \}$$

Метод Франк-Вульфа



Рис. 11: Маргарит Страус Франк (1927-2024)




Рис. 12: Филип Вульф (1927-2016)

## Идея




Рис. 13: Иллюстрация алгоритма Франк-Вульфа (условного градиента)

## Идея

$$f_{x_k}^I(x) = f(x_k) + \nabla f(x_k)^T (x - x_k)$$

$$\operatorname{argmin}_{x \in S'} f_{x_k}^I(x)$$

$$f(x)$$




Рис. 14: Иллюстрация алгоритма Франк-Вульфа (условного градиента)

## Идея

$$y_k = \underset{x \in S}{\operatorname{argmin}} f_{x_k}^I(x) = \\ = \underset{x \in S}{\operatorname{argmin}} \nabla f(x_k)^T x$$




Рис. 15: Иллюстрация алгоритма Франк-Вульфа (условного градиента)

## Идея




Рис. 16: Иллюстрация алгоритма Франк-Вульфа (условного градиента)

## Идея




Рис. 17: Иллюстрация алгоритма Франк-Вульфа (условного градиента)

## Идея




Рис. 18: Иллюстрация алгоритма Франк-Вульфа (условного градиента)

## Идея




Рис. 19: Иллюстрация алгоритма Франк-Вульфа (условного градиента)

## Идея

LMO

$$y_k = \arg \min_{x \in S} f_{x_k}^I(x) = \arg \min_{x \in S} \langle \nabla f(x_k), x \rangle$$
$$x_{k+1} = \gamma_k x_k + (1 - \gamma_k) y_k$$

- convex comb.




Рис. 20: Иллюстрация алгоритма Франк-Вульфа (условного градиента)

## Скорость сходимости для гладкого выпуклого случая ⚡ ⚡ ⚡

### Theorem

Пусть  $f : \mathbb{R}^n \rightarrow \mathbb{R}$  — выпуклая и дифференцируемая функция. Пусть  $S \subseteq \mathbb{R}^n$  — замкнутое выпуклое множество, и существует минимизатор  $x^*$  функции  $f$  на  $S$ ; кроме того, предположим, что  $f$  является гладкой на  $S$  с параметром  $L$ . Алгоритм Франк-Вульфа с размером шага  $\gamma_k = \frac{k-1}{k+1}$  обеспечивает следующую сходимость после  $k > 0$  итераций:

$$f(x_k) - f^* \leq \frac{2LR^2}{k+1}$$

$$k > 1 \quad | \quad \frac{k}{k+2}$$

где  $R = \max_{x,y \in S} \|x - y\|$  — диаметр множества  $S$ .

LMO может дать дешевые проекции

# Скорость сходимости для гладкого выпуклого случая

## Theorem

Пусть  $f : \mathbb{R}^n \rightarrow \mathbb{R}$  — выпуклая и дифференцируемая функция. Пусть  $S \subseteq \mathbb{R}^n$  — замкнутое выпуклое множество, и существует минимизатор  $x^*$  функции  $f$  на  $S$ ; кроме того, предположим, что  $f$  является гладкой на  $S$  с параметром  $L$ . Алгоритм Франк-Вульфа с размером шага  $\gamma_k = \frac{k-1}{k+1}$  обеспечивает следующую сходимость после  $k > 0$  итераций:

$$K \geq 1$$

$$f(x_k) - f^* \leq \frac{2LR^2}{k+1}$$

$$y_k = \underset{x \in S}{\operatorname{argmin}} f_{x_k}^I(x)$$

где  $R = \max_{x,y \in S} \|x - y\|$  — диаметр множества  $S$ .

$$x_{k+1} - x_k = \underbrace{(1-\gamma_k)}_{x_{k+1}-x_k} (y_k - x_k) = \gamma_k x_k - x_k + (1-\gamma_k) y_k = \gamma_k x_k - \gamma_k y_k + y_k$$

1. Из  $L$ -гладкости  $f$  имеем:

$$f(x_{k+1}) - f(x_k) \leq \langle \nabla f(x_k), x_{k+1} - x_k \rangle + \frac{L}{2} \|x_{k+1} - x_k\|^2$$

$$= (1 - \gamma_k) \langle \nabla f(x_k), y_k - x_k \rangle + \frac{L(1 - \gamma_k)^2}{2} \|y_k - x_k\|^2$$

$$x_{k+1} - y_k = \gamma_k (x_k - y_k)$$

$$x_{k+1} - x_k = (1 - \gamma_k) (y_k - x_k)$$



## Скорость сходимости для гладкого выпуклого случая ⚡⚡⚡

2. Из выпуклости  $f$  для любого  $x \in S$ , включая  $x^*$ :

$$\langle \nabla f(x_k), x - x_k \rangle \leq f(x) - f(x_k)$$

В частности, для  $x = x^*$ :

$$\langle \nabla f(x_k), x^* - x_k \rangle \leq f(x^*) - f(x_k)$$

## Скорость сходимости для гладкого выпуклого случая ⚡⚡⚡

2. Из выпуклости  $f$  для любого  $x \in S$ , включая  $x^*$ :

$$\langle \nabla f(x_k), x - x_k \rangle \leq f(x) - f(x_k)$$

В частности, для  $x = x^*$ :

$$\langle \nabla f(x_k), x^* - x_k \rangle \leq f(x^*) - f(x_k)$$

3. По определению  $y_k$  имеем  $\langle \nabla f(x_k), y_k \rangle \leq \langle \nabla f(x_k), x^* \rangle$ , поэтому:

$$\langle \nabla f(x_k), y_k - x_k \rangle \leq \underbrace{\langle \nabla f(x_k), x^* - x_k \rangle}_{\text{поэтому}} \leq f(x^*) - f(x_k)$$

$$y_k = \underset{x \in S}{\operatorname{argmin}} \nabla f(x_k)^T x$$

## Скорость сходимости для гладкого выпуклого случая



2. Из выпуклости  $f$  для любого  $x \in S$ , включая  $x^*$ :

$$\langle \nabla f(x_k), x - x_k \rangle \leq f(x) - f(x_k)$$

В частности, для  $x = x^*$ :

$$\langle \nabla f(x_k), x^* - x_k \rangle \leq f(x^*) - f(x_k)$$

3. По определению  $y_k$  имеем  $\langle \nabla f(x_k), y_k \rangle \leq \langle \nabla f(x_k), x^* \rangle$ , поэтому:

$$\underbrace{\langle \nabla f(x_k), y_k - x_k \rangle}_{\leq \langle \nabla f(x_k), x^* - x_k \rangle} \leq f(x^*) - f(x_k)$$

4. Объединяя приведённые неравенства:

$$\begin{aligned} \underline{f(x_{k+1}) - f(x_k)} &\leq (1 - \gamma_k) \langle \nabla f(x_k), y_k - x_k \rangle + \frac{L(1 - \gamma_k)^2}{2} \|y_k - x_k\|^2 \\ &\leq (1 - \gamma_k) (f(x^*) - f(x_k)) + \frac{L(1 - \gamma_k)^2}{2} R^2 \end{aligned}$$

## Скорость сходимости для гладкого выпуклого случая



2. Из выпуклости  $f$  для любого  $x \in S$ , включая  $x^*$ :

$$\langle \nabla f(x_k), x - x_k \rangle \leq f(x) - f(x_k)$$

В частности, для  $x = x^*$ :

$$\langle \nabla f(x_k), x^* - x_k \rangle \leq f(x^*) - f(x_k)$$

3. По определению  $y_k$  имеем  $\langle \nabla f(x_k), y_k \rangle \leq \langle \nabla f(x_k), x^* \rangle$ , поэтому:

$$\langle \nabla f(x_k), y_k - x_k \rangle \leq \langle \nabla f(x_k), x^* - x_k \rangle \leq f(x^*) - f(x_k)$$

4. Объединяя приведённые неравенства:

$$\begin{aligned} f(x_{k+1}) - f(x_k) &\leq (1 - \gamma_k) \langle \nabla f(x_k), y_k - x_k \rangle + \frac{L(1 - \gamma_k)^2}{2} \|y_k - x_k\|^2 \\ &\leq (1 - \gamma_k) (f(x^*) - f(x_k)) + \frac{L(1 - \gamma_k)^2}{2} R^2 \end{aligned}$$

5. Перегруппируем слагаемые:

$\sim \delta_{k+1}$

$\sim \delta_k$

$$\underline{\underline{f(x_{k+1}) - f(x^*)}} \leq \underline{\underline{\gamma_k (f(x_k) - f(x^*)) + (1 - \gamma_k)^2 \frac{LR^2}{2}}}$$

$| : L \mathbb{R}^2$

## Скорость сходимости для гладкого выпуклого случая ⚡⚡⚡

$$\delta_k \sim f(x_k) - f^*$$

6. Обозначив  $\delta_k = \frac{f(x_k) - f(x^*)}{LR^2}$ , получаем:

$$\underline{\delta_{k+1} \leq \gamma_k \delta_k + \frac{(1-\gamma_k)^2}{2}} = \frac{k-1}{k+1} \delta_k + \frac{2}{(k+1)^2}$$

$\gamma$  от  $\frac{1}{2}$  го 1

$$\gamma_k = \frac{k-1}{k+1} \quad 1 - \gamma_k = \frac{2}{k+1}$$

## Скорость сходимости для гладкого выпуклого случая



6. Обозначив  $\delta_k = \frac{f(x_k) - f(x^*)}{LR^2}$ , получаем:

$$\delta_{k+1} \leq \gamma_k \delta_k + \frac{(1 - \gamma_k)^2}{2} = \frac{k-1}{k+1} \delta_k + \frac{2}{(k+1)^2}$$

7. Докажем по индукции, что  $\delta_k \leq \frac{2}{k+1}$ .

БАЗА:  $k=$

что даёт нам искомый результат:

$$f(x_k) - f^* \leq \frac{2LR^2}{k+1}$$

## Скорость сходимости для гладкого выпуклого случая



6. Обозначив  $\delta_k = \frac{f(x_k) - f(x^*)}{LR^2}$ , получаем:

$$\delta_{k+1} \leq \gamma_k \delta_k + \frac{(1 - \gamma_k)^2}{2} = \frac{k-1}{k+1} \delta_k + \frac{2}{(k+1)^2}$$

7. Докажем по индукции, что  $\delta_k \leq \frac{2}{k+1}$ .

• База:  $\delta_2 \leq \frac{1}{2} < \frac{2}{3}$

$k=1$

$$\delta_1 \leq \frac{2}{2}$$

$$\delta_2 \leq \frac{2}{3}$$

что даёт нам искомый результат:

$$f(x_k) - f^* \leq \frac{2LR^2}{k+1}$$

## Скорость сходимости для гладкого выпуклого случая



6. Обозначив  $\delta_k = \frac{f(x_k) - f(x^*)}{LR^2}$ , получаем:

$$\delta_{k+1} \leq \gamma_k \delta_k + \frac{(1 - \gamma_k)^2}{2} = \frac{k-1}{k+1} \delta_k + \frac{2}{(k+1)^2}$$

7. Докажем по индукции, что  $\delta_k \leq \frac{2}{k+1}$ .

- База:  $\delta_2 \leq \frac{1}{2} < \frac{2}{3}$
- Предположим  $\delta_k \leq \frac{2}{k+1}$

что даёт нам искомый результат:

$$f(x_k) - f^* \leq \frac{2LR^2}{k+1}$$

## Скорость сходимости для гладкого выпуклого случая



$$O\left(\frac{1}{k}\right)$$

6. Обозначив  $\delta_k = \frac{f(x_k) - f(x^*)}{LR^2}$ , получаем:

$$\delta_{k+1} \leq \gamma_k \delta_k + \frac{(1-\gamma_k)^2}{2} = \frac{k-1}{k+1} \delta_k + \frac{2}{(k+1)^2}$$

||

7. Докажем по индукции, что  $\delta_k \leq \frac{2}{k+1}$ .

$$\frac{2}{k+1}$$

- База:  $\delta_2 \leq \frac{1}{2} < \frac{2}{3}$
- Предположим  $\delta_k \leq \frac{2}{k+1}$
- Тогда  $\delta_{k+1} \leq \frac{k-1}{k+1} \left( \frac{2}{k+1} \right) + \frac{2}{(k+1)^2} = \frac{2k}{k^2+2k+1} < \frac{2}{k+2}$

что даёт нам искомый результат:

$$\begin{aligned} \frac{2k}{k^2+2k+1} &< \frac{2k}{k^2+2k} = \\ &= \frac{2}{k+2} \end{aligned}$$

$$f(x_k) - f^* \leq \frac{2LR^2}{k+1}$$

$$\begin{aligned} \delta_k &\leq \frac{2}{k+1} \\ \frac{f_k - f^*}{LR^2} &\leq \frac{2}{k+1} \end{aligned}$$

$$O\left(\frac{1}{k}\right)$$

## Theorem

Рассмотрим произвольный алгоритм, который обращается к допустимому множеству  $S \subseteq \mathbb{R}^n$  только через оракул линейной минимизации (LMO). Пусть диаметр множества  $S$  равен  $R$ . Существует  $L$ -гладкая сильно выпуклая функция  $f : \mathbb{R}^n \rightarrow \mathbb{R}$ , для которой этому алгоритму потребуется не менее

$$\min\left(\frac{n}{2}, \frac{LR^2}{16\varepsilon}\right) \sim O\left(\frac{f}{\varepsilon}\right) \quad O\left(\frac{f}{k}\right)$$

итераций (то есть вызовов LMO), чтобы построить точку  $\hat{x} \in S$  с  $\underbrace{f(\hat{x}) - \min_{x \in S} f(x)}_{\leq \varepsilon}$ . Нижняя оценка справедлива как для выпуклых, так и для сильно выпуклых функций.

$$LMO = \underset{x \in S}{\operatorname{argmin}} \nabla f(x_k)^T x$$

<sup>2</sup> The Complexity of Large-scale Convex Programming under a Linear Optimization Oracle

## Theorem

Рассмотрим произвольный алгоритм, который обращается к допустимому множеству  $S \subseteq \mathbb{R}^n$  только через оракул линейной минимизации (LMO). Пусть диаметр множества  $S$  равен  $R$ . Существует  $L$ -гладкая сильно выпуклая функция  $f : \mathbb{R}^n \rightarrow \mathbb{R}$ , для которой этому алгоритму потребуется не менее

$$\min\left(\frac{n}{2}, \frac{LR^2}{16\varepsilon}\right)$$

итераций (то есть вызовов LMO), чтобы построить точку  $\hat{x} \in S$  с  $f(\hat{x}) - \min_{x \in S} f(x) \leq \varepsilon$ . Нижняя оценка справедлива как для выпуклых, так и для сильно выпуклых функций.

**Набросок доказательства.** Рассмотрим следующую задачу оптимизации:

$$\min_{x \in S} f(x) = \min_{x \in S} \frac{1}{2} \|x\|_2^2$$

$$S = \left\{ x \in \mathbb{R}^n \mid x \geq 0, \sum_{i=1}^n x_i = 1 \right\}$$

Заметим, что:

- $f$  является 1-гладкой;
- диаметр  $S$  равен  $R = 2$ ;
- $f$  сильно выпукла.

<sup>2</sup> The Complexity of Large-scale Convex Programming under a Linear Optimization Oracle

## Нижняя оценка для метода Франк-Вульфа<sup>3</sup>

1. Оптимальное решение:

$$x^* = \frac{1}{n} \mathbf{1} = \frac{1}{n} \sum_{i=1}^n e_i, \quad \text{и} \quad f(x^*) = \frac{1}{2n},$$

где  $e_i = (0, \dots, 0, \underset{\text{позиция } i}{1}, 0, \dots, 0)^\top$  —  $i$ -й стандартный базисный вектор.

## Нижняя оценка для метода Франк-Вульфа<sup>3</sup>

1. Оптимальное решение:

$$x^* = \frac{1}{n} \mathbf{1} = \frac{1}{n} \sum_{i=1}^n e_i, \quad \text{и} \quad f(x^*) = \frac{1}{2n},$$

где  $e_i = (0, \dots, 0, \underset{\substack{\text{позиция} \\ i}}{1}, 0, \dots, 0)^\top$  —  $i$ -й стандартный базисный вектор.

2. Оракул линейной минимизации (LMO) на  $S$  возвращает вершину  $e_i$ . После  $k$  итераций метод обнаружит не более  $k$  различных базисных векторов  $e_{i_1}, \dots, e_{i_k}$ . Наилучшая выпуклая комбинация, которую можно составить:

$$\hat{x} = \frac{1}{k} \sum_{j=1}^k e_{i_j}.$$

## Нижняя оценка для метода Франк-Вульфа<sup>3</sup>

1. Оптимальное решение:

$$x^* = \frac{1}{n} \mathbf{1} = \frac{1}{n} \sum_{i=1}^n e_i, \quad \text{и} \quad f(x^*) = \frac{1}{2n},$$

где  $e_i = (0, \dots, 0, \underset{\substack{\text{позиция} \\ i}}{1}, 0, \dots, 0)^\top$  —  $i$ -й стандартный базисный вектор.

2. Оракул линейной минимизации (LMO) на  $S$  возвращает вершину  $e_i$ . После  $k$  итераций метод обнаружит не более  $k$  различных базисных векторов  $e_{i_1}, \dots, e_{i_k}$ . Наилучшая выпуклая комбинация, которую можно составить:

$$\hat{x} = \frac{1}{k} \sum_{j=1}^k e_{i_j}.$$

3. Вычислив значение функции в точке  $\hat{x}$ , получаем:

$$f(\hat{x}) - f(x^*) \geq \frac{1}{2} \left( \frac{1}{\min\{k, n\}} - \frac{1}{n} \right).$$

## Нижняя оценка для метода Франк-Вульфа<sup>3</sup>

1. Оптимальное решение:

$$x^* = \frac{1}{n} \mathbf{1} = \frac{1}{n} \sum_{i=1}^n e_i, \quad \text{и} \quad f(x^*) = \frac{1}{2n},$$

где  $e_i = (0, \dots, 0, \underset{\substack{\text{позиция} \\ i}}{1}, 0, \dots, 0)^\top$  —  $i$ -й стандартный базисный вектор.

2. Оракул линейной минимизации (LMO) на  $S$  возвращает вершину  $e_i$ . После  $k$  итераций метод обнаружит не более  $k$  различных базисных векторов  $e_{i_1}, \dots, e_{i_k}$ . Наилучшая выпуклая комбинация, которую можно составить:

$$\hat{x} = \frac{1}{k} \sum_{j=1}^k e_{i_j}.$$

3. Вычислив значение функции в точке  $\hat{x}$ , получаем:


$$f(\hat{x}) - f(x^*) \geq \frac{1}{2} \left( \frac{1}{\min\{k, n\}} - \frac{1}{n} \right).$$

4. Чтобы обеспечить  $f(\hat{x}) - f(x^*) \leq \varepsilon$ , необходимо (полное доказательство приведено в статье):

$$k \geq \min \left\{ \frac{n}{2}, \frac{1}{4\varepsilon} \right\} = \min \left\{ \frac{n}{2}, \frac{LR^2}{16\varepsilon} \right\}.$$

<sup>3</sup> The Complexity of Large-scale Convex Programming under a Linear Optimization Oracle

## Итоги метода Франк-Вульфа



- Метод не требует проекций, а в некоторых случаях позволяет вычислять итерации в замкнутой форме

$$\min \frac{1}{2} x^T x$$

$$f^T x = 1$$

$$x \geq 0$$

$$\textcircled{=} \arg \min_x \sum_{i=1}^n f_i(x_k) \cdot x_i$$

$$y_k = \text{LMO}(x_k) = \arg \min_{x \in \mathbb{R}^n} \nabla f(x_k)^T \cdot x \text{ } \textcircled{=}$$

$$\begin{matrix} f^T x = 1 \\ x \geq 0 \end{matrix}$$

$$= (0, \dots, 1, \dots, 0)$$

$$\arg \min_{1 \leq i \leq n} f_i(x_k) \text{ } \text{--- } k$$

## Итоги метода Франк-Вульфа

- Метод не требует проекций, а в некоторых случаях позволяет вычислять итерации в замкнутой форме
- Глобальная скорость сходимости составляет  $O\left(\frac{1}{k}\right)$  для гладких выпуклых функций. Сильная выпуклость не улучшает скорость. Это нижняя оценка для LMO

## Итоги метода Франк-Вульфа

- Метод не требует проекций, а в некоторых случаях позволяет вычислять итерации в замкнутой форме
- Глобальная скорость сходимости составляет  $O\left(\frac{1}{k}\right)$  для гладких выпуклых функций. Сильная выпуклость не улучшает скорость. Это нижняя оценка для LMO
- По сравнению с методом проекции градиента скорость сходимости хуже, однако стоимость итерации может быть ниже, а решения — более разреженными

## Итоги метода Франк-Вульфа

- Метод не требует проекций, а в некоторых случаях позволяет вычислять итерации в замкнутой форме
- Глобальная скорость сходимости составляет  $O\left(\frac{1}{k}\right)$  для гладких выпуклых функций. Сильная выпуклость не улучшает скорость. Это нижняя оценка для LMO
- По сравнению с методом проекции градиента скорость сходимости хуже, однако стоимость итерации может быть ниже, а решения — более разреженными
- Недавно было показано, что для сильно выпуклых множеств скорость может быть улучшена до  $O\left(\frac{1}{k^2}\right)$  ( статья)

## Итоги метода Франк-Вульфа

- Метод не требует проекций, а в некоторых случаях позволяет вычислять итерации в замкнутой форме
- Глобальная скорость сходимости составляет  $O\left(\frac{1}{k}\right)$  для гладких выпуклых функций. Сильная выпуклость не улучшает скорость. Это нижняя оценка для LMO
- По сравнению с методом проекции градиента скорость сходимости хуже, однако стоимость итерации может быть ниже, а решения — более разреженными
- Недавно было показано, что для сильно выпуклых множеств скорость может быть улучшена до  $O\left(\frac{1}{k^2}\right)$  ( статья)
- Если допустить шаги удаления, сходимость становится линейной ( статья) в сильно выпуклом случае

 „**это типа монотония**“

## Итоги метода Франк-Вульфа


- Метод не требует проекций, а в некоторых случаях позволяет вычислять итерации в замкнутой форме
- Глобальная скорость сходимости составляет  $O\left(\frac{1}{k}\right)$  для гладких выпуклых функций. Сильная выпуклость не улучшает скорость. Это нижняя оценка для LMO
- По сравнению с методом проекции градиента скорость сходимости хуже, однако стоимость итерации может быть ниже, а решения — более разреженными
- Недавно было показано, что для сильно выпуклых множеств скорость может быть улучшена до  $O\left(\frac{1}{k^2}\right)$  ( статья)
- Если допустить шаги удаления, сходимость становится линейной ( статья) в сильно выпуклом случае
- В недавних работах показано обобщение на негладкий случай ( статья) со скоростью сходимости  $O\left(\frac{1}{\sqrt{k}}\right)$

## Численные эксперименты

## Двумерный пример. Метод Франк-Вульфа


$$LB \leq X \leq UB$$

Frank-Wolfe Method: Iteration 0




## Двумерный пример. Метод Франк-Вульфа

Frank-Wolfe Method: Iteration 1




## Двумерный пример. Метод Франк-Вульфа

Frank-Wolfe Method: Iteration 2




## Двумерный пример. Метод Франк-Вульфа

Frank-Wolfe Method: Iteration 3




## Двумерный пример. Метод Франк-Вульфа

Frank-Wolfe Method: Iteration 4




## Двумерный пример. Метод Франк-Вульфа

Frank-Wolfe Method: Iteration 5




## Двумерный пример. Метод Франк-Вульфа

Frank-Wolfe Method: Iteration 6



## Двумерный пример. Метод Франк-Вульфа

Frank-Wolfe Method: Iteration 7



## Квадратичная функция. Покоординатные ограничения

$$\min_{\substack{x \in \mathbb{R}^n \\ -1 \leq x \leq 1}} \frac{1}{2} x^\top A x - b^\top x,$$

$$A \in \mathbb{R}^{n \times n}, \quad \lambda(A) \in [\mu; L].$$

Проекция тривиальна:

$$\pi_S(x) = \text{clip}(x, -1, 1).$$

или

$$\pi_S(x) = \max(-1, \min(1, x)).$$


Оракул линейной минимизации (LMO) для заданного градиента  $g$  имеет вид  
 $y = \underset{z \in S}{\operatorname{argmin}} \langle g, z \rangle$ .

Поскольку допустимое множество сепарабельно по координатам, решение вычисляется покоординатно:


$$y_i = \begin{cases} -1, & \text{если } g_i > 0, \\ 1, & \text{если } g_i \leq 0. \end{cases}$$

Constrained convex quadratic problem:  $n=80$ ,  $\mu=0$ ,  $L=10$


Function Gap vs Iterations




Domain Gap vs Iterations



Function Gap vs Time



Domain Gap vs Time



Projected Gradient Descent    Frank-Wolfe

## Квадратичная функция. Покоординатные ограничения

$$\min_{\substack{x \in \mathbb{R}^n \\ -1 \leq x \leq 1}} \frac{1}{2} x^\top A x - b^\top x,$$

$$A \in \mathbb{R}^{n \times n}, \quad \lambda(A) \in [\mu; L].$$

Проекция тривиальна:

$$\pi_S(x) = \text{clip}(x, -1, 1).$$

или


$$\pi_S(x) = \max(-1, \min(1, x)).$$

Оракул линейной минимизации (LMO) для заданного градиента  $g$  имеет вид  
 $y = \underset{z \in S}{\operatorname{argmin}} \langle g, z \rangle$ .

Поскольку допустимое множество сепарабельно по координатам, решение вычисляется покоординатно:

$$y_i = \begin{cases} -1, & \text{если } g_i > 0, \\ 1, & \text{если } g_i \leq 0. \end{cases}$$

Constrained strongly Convex quadratic problem:  $n=80$ ,  $\mu=1$ ,  $L=10$



# Квадратичная функция. Симплексные ограничения (удачная задача с диагональной матрицей)

$$\min_{\substack{x \in \mathbb{R}^n \\ x \geq 0, \mathbf{1}^T x = 1}} \frac{1}{2} x^T A x,$$

$$A \in \mathbb{R}^{n \times n}, \quad \lambda(A) \in [0; 100].$$


Метод	Время шага, мс	Время LMO/проекции, мс
PGD	0.0069	0.0167
FW	0.0070	0.0066

Проекция на единичный симплекс  $\pi_S(x)$  выполняется за  $\mathcal{O}(n \log n)$  или за ожидаемое  $\mathcal{O}(n)$  времени.<sup>4</sup>

LMO для заданного градиента  $g$  имеет вид  
 $y = \operatorname{argmin}_{z \in S} \langle g, z \rangle$ . Решение соответствует вершине  
 симплекса:

$$y = e_j \quad \text{где} \quad j = \operatorname{argmin}_i g_i.$$

<sup>4</sup> Efficient Projections onto the  $\ell_1$ -Ball for Learning in High Dimensions







# Квадратичная функция. Симплексные ограничения

$$\min_{\substack{x \in \mathbb{R}^n \\ x \geq 0, \mathbf{1}^T x = 1}} \frac{1}{2} x^T A x,$$

$A \in \mathbb{R}^{n \times n}$ ,  $\lambda(A) \in [0; 100]$ .

Метод	Время шага, мс	Время LMO/проекции, мс
PGD	0.0069	0.0420
FW	0.0069	0.0066

$$\min_{\substack{\mathbf{1}^T x = 1, x \geq 0}} \frac{1}{2} x^T A x, n = 200$$



— Frank-Wolfe — Projected Gradient Descent





# Квадратичная функция. Симплексные ограничения

$$\min_{\substack{x \in \mathbb{R}^n \\ x \geq 0, 1^T x = 1}} \frac{1}{2} x^T A x,$$

$A \in \mathbb{R}^{n \times n}$ ,  $\lambda(A) \in [0; 100]$ .

Метод	Время шага, мс	Время LMO/проекции, мс
PGD	0.0068	0.0761
FW	0.0069	0.0070

$$\min_{1^T x = 1, x \geq 0} 1/2 x^T A x, n = 300$$



— Frank-Wolfe — Projected Gradient Descent





# Квадратичная функция. Симплексные ограничения

$$\min_{\substack{x \in \mathbb{R}^n \\ x \geq 0, \mathbf{1}^T x = 1}} \frac{1}{2} x^T A x,$$

$A \in \mathbb{R}^{n \times n}$ ,  $\lambda(A) \in [1; 100]$ .

Метод	Время шага, мс	Время LMO/проекции, мс
PGD	0.0068	0.0752
FW	0.0067	0.0068

$$\min_{\substack{\mathbf{1}^T x = 1, x \geq 0}} \frac{1}{2} x^T A x, n = 300$$



— Frank-Wolfe — Projected Gradient Descent

## PGD и метод Франк-Вульфа

Ключевое различие между PGD и FW состоит в том, что PGD требует проекции, тогда как FW — лишь оракул линейной минимизации (LMO).

В недавней статье авторы представили следующую сравнительную таблицу сложностей линейной минимизации и проекций на некоторые выпуклые множества с точностью до аддитивной ошибки  $\epsilon$  в евклидовой норме.

Множество	Линейная минимизация	Проекция
$n$ -мерный $\ell_p$ -шар, $p \neq 1, 2, \infty$	$\mathcal{O}(n)$	$\tilde{\mathcal{O}}\left(\frac{n}{\epsilon^2}\right)$
Шар ядерной нормы для $n \times m$ матриц	$\mathcal{O}\left(\nu \ln(m+n) \frac{\sqrt{\sigma_1}}{\sqrt{\epsilon}}\right)$	$\mathcal{O}(mn \min\{m, n\})$
Потоковый многогранник на графе с $m$ вершинами и $n$ рёбрами (ограничение пропускной способности на рёбрах)	$\mathcal{O}\left((n \log m)(n + m \log m)\right)$	$\tilde{\mathcal{O}}\left(\frac{n}{\epsilon^2}\right)$ или $\mathcal{O}(n^4 \log n)$
Многогранник Биркгофа ( $n \times n$ дважды стохастические матрицы)	$\mathcal{O}(n^3)$	$\tilde{\mathcal{O}}\left(\frac{n^2}{\epsilon^2}\right)$

Когда  $\epsilon$  отсутствует, аддитивной ошибки нет. Обозначение  $\tilde{\mathcal{O}}$  скрывает полилогарифмические множители по размерности и полиномиальные множители в константах, связанных с расстоянием до оптимума. Для шара ядерной нормы (спектраэдра)  $\nu$  обозначает число ненулевых элементов, а  $\sigma_1$  — наибольшее сингулярное




## Траектории PGD и FW на $\ell_2$ -шаре

$$\min_{x \in \mathbb{R}^2} \frac{1}{2} x^\top A x - b^\top x, \quad \|x\|_2 \leq 1$$

PGD: проекция  $\rightarrow$  кратчайший путь к границе, затем движение вдоль неё к оптимуму.

FW: каждый шаг — выпуклая комбинация текущей точки и **антиградиентной точки на границе**. Характерный зигзаг вдоль множества.

Оба метода стартуют из  $x_0 = (-0.5, -0.5)$ .




## Траектории PGD и FW на 2-симплексе

$$\min_{\substack{x \in \mathbb{R}^3 \\ x \geq 0, \mathbf{1}^\top x = 1}} \frac{1}{2} x^\top A x$$

FW на каждом шаге выбирает одну из вершин симплекса ( $e_1, e_2, e_3$ ), движется к ней  $\rightarrow$  траектория проходит через рёбра.  
PGD: проекция на симплекс допускает движение в любом направлении  $\rightarrow$  более прямой путь к оптимуму.

Траектории PGD и FW на 2-симплексе




## $\ell_2$ -шар. Проекция и LMO одинаково дёшевы

$$\min_{\|x\|_2 \leq 2} \frac{1}{2} x^\top A x - b^\top x$$

- $n = 200, \kappa = 50$

сильн  
вып.

Когда проекция и LMO стоят одинаково, PGD выигрывает за счёт **линейной скорости** при сильной выпуклости.




## $\ell_2$ -шар. Проекция и LMO одинаково дёшевы

$$\min_{\|x\|_2 \leq 2} \frac{1}{2} x^\top A x - b^\top x$$

- $n = 200, \kappa = 50$
- Проекция:  $\pi_S(x) = x \cdot \min\left(1, \frac{R}{\|x\|}\right)$  —  $\mathcal{O}(n)$

Когда проекция и LMO стоят одинаково, PGD выигрывает за счёт **линейной скорости** при сильной выпуклости.




## $\ell_2$ -шар. Проекция и LMO одинаково дёшевы

$$\min_{\|x\|_2 \leq 2} \frac{1}{2} x^\top A x - b^\top x$$

- $n = 200, \kappa = 50$
- Проекция:  $\pi_S(x) = x \cdot \min\left(1, \frac{R}{\|x\|}\right) — \mathcal{O}(n)$
- LMO:  $y = -R \frac{g}{\|g\|} — \mathcal{O}(n)$

Когда проекция и LMO стоят одинаково, PGD выигрывает за счёт линейной скорости при сильной выпуклости.




# Разреженность итераций FW на симплексе

$$\min_{\substack{x \geq 0 \\ 1^\top x = 1}} \frac{1}{2} x^\top A x, \quad n = 500$$

Ключевое свойство FW: итерация  $x_k$  есть выпуклая комбинация  $k$  вершин  $\Rightarrow$  не более  $k$  ненулевых компонент.

- PGD: после проекции число ненулевых компонент скачком достигает  $\sim 400$

Это важно, когда нужно получить разреженное решение.




# Разреженность итераций FW на симплексе

$$\min_{\substack{x \geq 0 \\ 1^\top x = 1}} \frac{1}{2} x^\top A x, \quad n = 500$$

Ключевое свойство FW: итерация  $x_k$  есть выпуклая комбинация  $k$  вершин  $\Rightarrow$  не более  $k$  ненулевых компонент.

- PGD: после проекции число ненулевых компонент скачком достигает  $\sim 400$
- FW: число ненулевых растёт линейно с итерациями

Это важно, когда нужно получить разреженное решение.




## Сильная выпуклость: PGD ускоряется, FW — нет

$$\min_{\substack{x \geq 0 \\ 1^\top x = 1}} \frac{1}{2} x^\top A x$$

- $n = 200, \mu = 5, L = 100, \kappa = 20$

PGD с шагом  $\frac{1}{L}$ : **линейная сходимость**  $(1 - \mu/L)^k$ , ведь проекция на выпуклое множество — нерастягивающий оператор.  
FW: остаётся  $\mathcal{O}(1/k)$  — сильная выпуклость **не помогает** со стандартным шагом  
 $\gamma_k = \frac{2}{k+2}$ .




# Скорость сходимости: выпуклая vs сильно выпуклая задача

$$\min_{-1 \leq x \leq 1} \frac{1}{2} x^\top A x, \quad n = 100$$

- Левая панель:  $\mu \approx 0$  — оба метода  $\mathcal{O}(1/k)$ , но PGD быстрее по константе

Главный вывод: сильная выпукłość кардинально меняет картину в пользу PGD.




## Скорость сходимости: выпуклая vs сильно выпуклая задача

$$\min_{-1 \leq x \leq 1} \frac{1}{2} x^\top A x, \quad n = 100$$

- Левая панель:  $\mu \approx 0$  — оба метода  $\mathcal{O}(1/k)$ , но PGD быстрее по константе
- Правая панель:  $\mu = 2$  — PGD получает **экспоненциальную** скорость, FW остаётся сублинейным

Главный вывод: сильная выпуклость кардинально меняет картину в пользу PGD.




# Стоимость итерации: проекция vs LMO на симплексе

Измеряем **только** стоимость проекции и LMO, без вычисления градиента.

- Проекция на симплекс: сортировка +  $O(n)$  — всего  $\mathcal{O}(n \log n)$

При  $n = 10000$  проекция дороже LMO **на порядок**.

В задачах, где градиент считается быстро (разреженная матрица), разница в стоимости шага между PGD и FW определяется именно проекцией/LMO.




# Стоимость итерации: проекция vs LMO на симплексе

Измеряем **только** стоимость проекции и LMO, без вычисления градиента.

- Проекция на симплекс: сортировка +  $O(n)$  — всего  $\mathcal{O}(n \log n)$
- LMO (argmin): один проход —  $\mathcal{O}(n)$

При  $n = 10000$  проекция дороже LMO **на порядок**.

В задачах, где градиент считается быстро (разреженная матрица), разница в стоимости шага между PGD и FW определяется именно проекцией/LMO.



## Ядерная норма: когда FW — единственный возможный вариант


$$\|X\|_* \leq R$$

$$\min_{\|X\|_* \leq R} \frac{1}{2} \|X - B\|_F^2, \quad X \in \mathbb{R}^{n \times n}$$

- PGD: полное SVD  $\mathcal{O}(n^3)$  на каждой итерации

По итерациям PGD выигрывает. Но стоимость одной итерации PGD растёт **кубически**: при  $n = 800$  полное SVD в 75 раз дороже rank-1 SVD.

Для матриц размера  $10^4 \times 10^4$  и больше полное SVD вычислительно неподъёмно — FW становится единственным разумным методом.



$$\|X\|_* = \sum_{i=1}^n \sigma_i(X)$$


# Ядерная норма: когда FW — единственный вариант

$$\min_{\|X\|_* \leq R} \frac{1}{2} \|X - B\|_F^2, \quad X \in \mathbb{R}^{n \times n}$$

- PGD: полное SVD  $\mathcal{O}(n^3)$  на каждой итерации
- FW: rank-1 SVD (power iteration)  $\mathcal{O}(n^2)$

По итерациям PGD выигрывает. Но стоимость одной итерации PGD растёт **кубически**: при  $n = 800$  полное SVD в 75 раз дороже rank-1 SVD.

Для матриц размера  $10^4 \times 10^4$  и больше полное SVD вычислительно неподъёмно — FW становится единственным разумным методом.



# Ядерная норма: определение и свойства

## i Ядерная норма (trace norm)

Ядерная норма матрицы  $X \in \mathbb{R}^{m \times n}$  определяется как сумма её сингулярных чисел:

$$\|X\|_* = \sum_{i=1}^{\min(m,n)} \sigma_i(X) = \text{tr} \left( \sqrt{X^\top X} \right)$$

# Ядерная норма: определение и свойства

## i Ядерная норма (trace norm)

Ядерная норма матрицы  $X \in \mathbb{R}^{m \times n}$  определяется как сумма её сингулярных чисел:

$$\|X\|_* = \sum_{i=1}^{\min(m,n)} \sigma_i(X) = \text{tr} \left( \sqrt{X^\top X} \right)$$

- Ядерная норма — выпуклая оболочка ранга матрицы на единичном спектральном шаре:  
 $\|X\|_* = \text{conv}(\text{rank}(X))$  при  $\|X\|_{\text{op}} \leq 1$ .

# Ядерная норма: определение и свойства

## i Ядерная норма (trace norm)

Ядерная норма матрицы  $X \in \mathbb{R}^{m \times n}$  определяется как сумма её сингулярных чисел:

$$\|X\|_* = \sum_{i=1}^{\min(m,n)} \sigma_i(X) = \text{tr} \left( \sqrt{X^\top X} \right)$$

- Ядерная норма — выпуклая оболочка ранга матрицы на единичном спектральном шаре:  
 $\|X\|_* = \text{conv}(\text{rank}(X))$  при  $\|X\|_{\text{op}} \leq 1$ .
- Поэтому ограничение  $\|X\|_* \leq R$  — стандартный выпуклый релаксант для ограничения на ранг.

# Ядерная норма: определение и свойства

## i Ядерная норма (trace norm)

Ядерная норма матрицы  $X \in \mathbb{R}^{m \times n}$  определяется как сумма её сингулярных чисел:

$$\|X\|_* = \sum_{i=1}^{\min(m,n)} \sigma_i(X) = \text{tr} \left( \sqrt{X^\top X} \right)$$

- Ядерная норма — выпуклая оболочка ранга матрицы на единичном спектральном шаре:  
 $\|X\|_* = \text{conv}(\text{rank}(X))$  при  $\|X\|_{\text{op}} \leq 1$ .
- Поэтому ограничение  $\|X\|_* \leq R$  — стандартный выпуклый релаксант для ограничения на ранг.
- Шар ядерной нормы  $\mathcal{B}_* = \{X \in \mathbb{R}^{m \times n} \mid \|X\|_* \leq R\}$  — выпуклое компактное множество.

# Ядерная норма: определение и свойства

## i Ядерная норма (trace norm)

Ядерная норма матрицы  $X \in \mathbb{R}^{m \times n}$  определяется как сумма её сингулярных чисел:

$$\|X\|_* = \sum_{i=1}^{\min(m,n)} \sigma_i(X) = \text{tr} \left( \sqrt{X^\top X} \right)$$

- Ядерная норма — выпуклая оболочка ранга матрицы на единичном спектральном шаре:  
 $\|X\|_* = \text{conv}(\text{rank}(X))$  при  $\|X\|_{\text{op}} \leq 1$ .
- Поэтому ограничение  $\|X\|_* \leq R$  — стандартный выпуклый релаксант для ограничения на ранг.
- Шар ядерной нормы  $\mathcal{B}_* = \{X \in \mathbb{R}^{m \times n} \mid \|X\|_* \leq R\}$  — выпуклое компактное множество.
- Крайние точки  $\mathcal{B}_*$  — матрицы ранга 1 вида  $R \cdot uv^\top$ , где  $\|u\|_2 = \|v\|_2 = 1$ .

# Ядерная норма: определение и свойства

## i Ядерная норма (trace norm)

Ядерная норма матрицы  $X \in \mathbb{R}^{m \times n}$  определяется как сумма её сингулярных чисел:

$$\|X\|_* = \sum_{i=1}^{\min(m,n)} \sigma_i(X) = \text{tr} \left( \sqrt{X^\top X} \right)$$

- Ядерная норма — выпуклая оболочка ранга матрицы на единичном спектральном шаре:  
 $\|X\|_* = \text{conv}(\text{rank}(X))$  при  $\|X\|_{\text{op}} \leq 1$ .
- Поэтому ограничение  $\|X\|_* \leq R$  — стандартный выпуклый релаксант для ограничения на ранг.
- Шар ядерной нормы  $\mathcal{B}_* = \{X \in \mathbb{R}^{m \times n} \mid \|X\|_* \leq R\}$  — выпуклое компактное множество.
- Крайние точки  $\mathcal{B}_*$  — матрицы ранга 1 вида  $R \cdot uv^\top$ , где  $\|u\|_2 = \|v\|_2 = 1$ .

# Ядерная норма: определение и свойства

## i Ядерная норма (trace norm)

Ядерная норма матрицы  $X \in \mathbb{R}^{m \times n}$  определяется как сумма её сингулярных чисел:

$$\|X\|_* = \sum_{i=1}^{\min(m,n)} \sigma_i(X) = \text{tr} \left( \sqrt{X^\top X} \right)$$

- Ядерная норма — выпуклая оболочка ранга матрицы на единичном спектральном шаре:  
 $\|X\|_* = \text{conv}(\text{rank}(X))$  при  $\|X\|_{\text{op}} \leq 1$ .
- Поэтому ограничение  $\|X\|_* \leq R$  — стандартный выпуклый релаксант для ограничения на ранг.
- Шар ядерной нормы  $\mathcal{B}_* = \{X \in \mathbb{R}^{m \times n} \mid \|X\|_* \leq R\}$  — выпуклое компактное множество.
- Крайние точки  $\mathcal{B}_*$  — матрицы ранга 1 вида  $R \cdot uv^\top$ , где  $\|u\|_2 = \|v\|_2 = 1$ .

**Приложения:** matrix completion (рекомендательные системы), robust PCA, low-rank matrix recovery, сжатие нейронных сетей.

## Итерации PGD и FW на шаре ядерной нормы

**Задача:**  $\min_{\|X\|_* \leq R} f(X)$ , где  $X \in \mathbb{R}^{m \times n}$ .

# Итерации PGD и FW на шаре ядерной нормы

**Задача:**  $\min_{\|X\|_* \leq R} f(X)$ , где  $X \in \mathbb{R}^{m \times n}$ .

## Итерация PGD

$$X_{k+1} = \text{proj}_{\mathcal{B}_*}(X_k - \alpha \nabla f(X_k))$$

1. Вычислить  $Y = X_k - \alpha \nabla f(X_k)$

# Итерации PGD и FW на шаре ядерной нормы

**Задача:**  $\min_{\|X\|_* \leq R} f(X)$ , где  $X \in \mathbb{R}^{m \times n}$ .

## Итерация PGD

$$X_{k+1} = \text{proj}_{\mathcal{B}_*}(X_k - \alpha \nabla f(X_k))$$

1. Вычислить  $Y = X_k - \alpha \nabla f(X_k)$
2. **Полное SVD:**  $Y = U \Sigma V^\top$  — стоимость  $\mathcal{O}(mn \cdot \min(m, n))$

# Итерации PGD и FW на шаре ядерной нормы

**Задача:**  $\min_{\|X\|_* \leq R} f(X)$ , где  $X \in \mathbb{R}^{m \times n}$ .

## Итерация PGD

$$X_{k+1} = \text{proj}_{\mathcal{B}_*}(X_k - \alpha \nabla f(X_k))$$

1. Вычислить  $Y = X_k - \alpha \nabla f(X_k)$
2. **Полное SVD:**  $Y = U \Sigma V^\top$  — стоимость  $\mathcal{O}(mn \cdot \min(m, n))$
3. Мягкое пороговое отсечение (soft thresholding) сингулярных чисел для проекции на  $\mathcal{B}_*$ :

$$\text{proj}_{\mathcal{B}_*}(Y) = U \cdot \text{diag}(\max(\sigma_i - \lambda, 0)) \cdot V^\top$$

где  $\lambda \geq 0$  выбирается так, чтобы

$$\sum_i \max(\sigma_i - \lambda, 0) = R.$$

# Итерации PGD и FW на шаре ядерной нормы

**Задача:**  $\min_{\|X\|_* \leq R} f(X)$ , где  $X \in \mathbb{R}^{m \times n}$ .

## Итерация PGD

$$X_{k+1} = \text{proj}_{\mathcal{B}_*}(X_k - \alpha \nabla f(X_k))$$

1. Вычислить  $Y = X_k - \alpha \nabla f(X_k)$
2. **Полное SVD:**  $Y = U \Sigma V^\top$  — стоимость  $\mathcal{O}(mn \cdot \min(m, n))$
3. Мягкое пороговое отсечение (soft thresholding) сингулярных чисел для проекции на  $\mathcal{B}_*$ :

$$\text{proj}_{\mathcal{B}_*}(Y) = U \cdot \text{diag}(\max(\sigma_i - \lambda, 0)) \cdot V^\top$$

где  $\lambda \geq 0$  выбирается так, чтобы

$$\sum_i \max(\sigma_i - \lambda, 0) = R.$$

# Итерации PGD и FW на шаре ядерной нормы

**Задача:**  $\min_{\|X\|_* \leq R} f(X)$ , где  $X \in \mathbb{R}^{m \times n}$ .

## Итерация PGD

$$X_{k+1} = \text{proj}_{\mathcal{B}_*}(X_k - \alpha \nabla f(X_k))$$

1. Вычислить  $Y = X_k - \alpha \nabla f(X_k)$
2. **Полное SVD:**  $Y = U \Sigma V^\top$  — стоимость  $\mathcal{O}(mn \cdot \min(m, n))$
3. Мягкое пороговое отсечение (soft thresholding) сингулярных чисел для проекции на  $\mathcal{B}_*$ :

$$\text{proj}_{\mathcal{B}_*}(Y) = U \cdot \text{diag}(\max(\sigma_i - \lambda, 0)) \cdot V^\top$$

где  $\lambda \geq 0$  выбирается так, чтобы

$$\sum_i \max(\sigma_i - \lambda, 0) = R.$$

## Итерация FW

$$S_k = \arg \min_{\|S\|_* \leq R} \langle \nabla f(X_k), S \rangle$$

$$X_{k+1} = (1 - \gamma_k)X_k + \gamma_k S_k$$

1. Вычислить  $G = \nabla f(X_k)$

**Бонус:**  $X_k$  имеет ранг  $\leq k$  после  $k$  итераций.

# Итерации PGD и FW на шаре ядерной нормы

**Задача:**  $\min_{\|X\|_* \leq R} f(X)$ , где  $X \in \mathbb{R}^{m \times n}$ .

## Итерация PGD

$$X_{k+1} = \text{proj}_{\mathcal{B}_*}(X_k - \alpha \nabla f(X_k))$$

1. Вычислить  $Y = X_k - \alpha \nabla f(X_k)$
2. **Полное SVD:**  $Y = U \Sigma V^\top$  — стоимость  $\mathcal{O}(mn \cdot \min(m, n))$
3. Мягкое пороговое отсечение (soft thresholding) сингулярных чисел для проекции на  $\mathcal{B}_*$ :

$$\text{proj}_{\mathcal{B}_*}(Y) = U \cdot \text{diag}(\max(\sigma_i - \lambda, 0)) \cdot V^\top$$

где  $\lambda \geq 0$  выбирается так, чтобы

$$\sum_i \max(\sigma_i - \lambda, 0) = R.$$

## Итерация FW

$$S_k = \arg \min_{\|S\|_* \leq R} \langle \nabla f(X_k), S \rangle$$

$$X_{k+1} = (1 - \gamma_k)X_k + \gamma_k S_k$$

1. Вычислить  $G = \nabla f(X_k)$
2. **Rank-1 SVD** (степенная итерация): найти ведущие сингулярные векторы  $u_1, v_1$  матрицы  $-G$  — стоимость  $\mathcal{O}(\text{nnz}(G))$

**Бонус:**  $X_k$  имеет ранг  $\leq k$  после  $k$  итераций.

# Итерации PGD и FW на шаре ядерной нормы

**Задача:**  $\min_{\|X\|_* \leq R} f(X)$ , где  $X \in \mathbb{R}^{m \times n}$ .

## Итерация PGD

$$X_{k+1} = \text{proj}_{\mathcal{B}_*}(X_k - \alpha \nabla f(X_k))$$

1. Вычислить  $Y = X_k - \alpha \nabla f(X_k)$
2. **Полное SVD:**  $Y = U \Sigma V^\top$  — стоимость  $\mathcal{O}(mn \cdot \min(m, n))$
3. Мягкое пороговое отсечение (soft thresholding) сингулярных чисел для проекции на  $\mathcal{B}_*$ :

$$\text{proj}_{\mathcal{B}_*}(Y) = U \cdot \text{diag}(\max(\sigma_i - \lambda, 0)) \cdot V^\top$$

где  $\lambda \geq 0$  выбирается так, чтобы  
 $\sum_i \max(\sigma_i - \lambda, 0) = R$ .



## Итерация FW

$$S_k = \arg \min_{\|S\|_* \leq R} \langle \nabla f(X_k), S \rangle$$

$$X_{k+1} = (1 - \gamma_k)X_k + \gamma_k S_k$$

1. Вычислить  $G = \nabla f(X_k)$
2. **Rank-1 SVD** (степенная итерация): найти ведущие сингулярные векторы  $u_1, v_1$  матрицы  $-G$  — стоимость  $\mathcal{O}(\text{nnz}(G))$
3.  $S_k = R \cdot u_1 v_1^\top$  — ранг-1 матрица

**Бонус:**  $X_k$  имеет ранг  $\leq k$  после  $k$  итераций.

# Итерации PGD и FW на шаре ядерной нормы

**Задача:**  $\min_{\|X\|_* \leq R} f(X)$ , где  $X \in \mathbb{R}^{m \times n}$ .

## Итерация PGD

$$X_{k+1} = \text{proj}_{\mathcal{B}_*}(X_k - \alpha \nabla f(X_k))$$

1. Вычислить  $Y = X_k - \alpha \nabla f(X_k)$
2. **Полное SVD:**  $Y = U \Sigma V^\top$  — стоимость  $\mathcal{O}(mn \cdot \min(m, n))$
3. Мягкое пороговое отсечение (soft thresholding) сингулярных чисел для проекции на  $\mathcal{B}_*$ :

$$\text{proj}_{\mathcal{B}_*}(Y) = U \cdot \text{diag}(\max(\sigma_i - \lambda, 0)) \cdot V^\top$$

где  $\lambda \geq 0$  выбирается так, чтобы  
 $\sum_i \max(\sigma_i - \lambda, 0) = R$ .

## Итерация FW

$$S_k = \arg \min_{\|S\|_* \leq R} \langle \nabla f(X_k), S \rangle$$

$$X_{k+1} = (1 - \gamma_k)X_k + \gamma_k S_k$$

1. Вычислить  $G = \nabla f(X_k)$
2. **Rank-1 SVD** (степенная итерация): найти ведущие сингулярные векторы  $u_1, v_1$  матрицы  $-G$  — стоимость  $\mathcal{O}(\text{nnz}(G))$
3.  $S_k = R \cdot u_1 v_1^\top$  — ранг-1 матрица
4.  $X_{k+1} = (1 - \gamma_k)X_k + \gamma_k S_k$

**Бонус:**  $X_k$  имеет ранг  $\leq k$  после  $k$  итераций.

# FW побеждает: matrix completion + ядерная норма

**Задача:** matrix completion с ограничением


$$\|X\|_* \leq R:$$

$$\min_{\|X\|_* \leq R} \frac{1}{2} \sum_{(i,j) \in \Omega} (X_{ij} - B_{ij})^2$$

**Ключ:** градиент  $\nabla f$  разрежен (ненулевой только на  $\Omega$ ).

- Степенная итерация для rank-1 SVD на разреженном  $\nabla f$ :  $\mathcal{O}(|\Omega|)$

Matrix completion + ядерная норма: FW побеждает по времени



FW компенсирует медленную сходимость  $O(1/k)$  огромным числом дешёвых итераций и побеждает PGD по времени.

# FW побеждает: matrix completion + ядерная норма

**Задача:** matrix completion с ограничением


$$\|X\|_* \leq R:$$

$$\min_{\|X\|_* \leq R} \frac{1}{2} \sum_{(i,j) \in \Omega} (X_{ij} - B_{ij})^2$$

**Ключ:** градиент  $\nabla f$  разрежен (ненулевой только на  $\Omega$ ).

- Степенная итерация для rank-1 SVD на разреженном  $\nabla f$ :  $\mathcal{O}(|\Omega|)$
- Полное SVD плотной матрицы  $Y$ :  $\mathcal{O}(n^3)$

Matrix completion + ядерная норма: FW побеждает по времени



FW компенсирует медленную сходимость  $O(1/k)$  огромным числом дешёвых итераций и побеждает PGD по времени.

# FW побеждает: matrix completion + ядерная норма

**Задача:** matrix completion с ограничением

$$\|X\|_* \leq R:$$


$$\min_{\|X\|_* \leq R} \frac{1}{2} \sum_{(i,j) \in \Omega} (X_{ij} - B_{ij})^2$$

**Ключ:** градиент  $\nabla f$  разрежен (ненулевой только на  $\Omega$ ).

- Степенная итерация для rank-1 SVD на разреженном  $\nabla f$ :  $\mathcal{O}(|\Omega|)$
- Полное SVD плотной матрицы  $Y$ :  $\mathcal{O}(n^3)$
- При  $n = 2500$ ,  $|\Omega| = 3\% \cdot n^2$ : **отношение**  $\approx 900 \times$

FW компенсирует медленную сходимость  $O(1/k)$  огромным числом дешёвых итераций и **побеждает PGD по времени**.

Matrix completion + ядерная норма: FW побеждает по времени



## Matrix completion: почему ядерная норма?

**Задача восстановления матрицы.** Данна матрица  $B \in \mathbb{R}^{m \times n}$ , наблюдаемая лишь на подмножестве индексов  $\Omega \subset [m] \times [n]$ . Нужно восстановить всю матрицу, предполагая, что она имеет малый ранг.

## Matrix completion: почему ядерная норма?

**Задача восстановления матрицы.** Данна матрица  $B \in \mathbb{R}^{m \times n}$ , наблюдаемая лишь на подмножестве индексов  $\Omega \subset [m] \times [n]$ . Нужно восстановить всю матрицу, предполагая, что она имеет малый ранг.

Некорректная (невыпуклая) постановка

$$\min_X \frac{1}{2} \sum_{(i,j) \in \Omega} (X_{ij} - B_{ij})^2 \quad \text{s.t.} \quad \text{rank}(X) \leq r$$

- Ограничение  $\text{rank}(X) \leq r$  — **невыпуклое**

## Matrix completion: почему ядерная норма?

**Задача восстановления матрицы.** Данна матрица  $B \in \mathbb{R}^{m \times n}$ , наблюдаемая лишь на подмножестве индексов  $\Omega \subset [m] \times [n]$ . Нужно восстановить всю матрицу, предполагая, что она имеет малый ранг.

Некорректная (невыпуклая) постановка

$$\min_X \frac{1}{2} \sum_{(i,j) \in \Omega} (X_{ij} - B_{ij})^2 \quad \text{s.t.} \quad \text{rank}(X) \leq r$$

- Ограничение  $\text{rank}(X) \leq r$  — **невыпуклое**
- NP-трудная задача в общем случае

## Matrix completion: почему ядерная норма?

**Задача восстановления матрицы.** Данна матрица  $B \in \mathbb{R}^{m \times n}$ , наблюдаемая лишь на подмножестве индексов  $\Omega \subset [m] \times [n]$ . Нужно восстановить всю матрицу, предполагая, что она имеет малый ранг.

Некорректная (невыпуклая) постановка

$$\min_X \frac{1}{2} \sum_{(i,j) \in \Omega} (X_{ij} - B_{ij})^2 \quad \text{s.t.} \quad \text{rank}(X) \leq r$$

- Ограничение  $\text{rank}(X) \leq r$  — **невыпуклое**
- NP-трудная задача в общем случае
- Нет гарантий глобальной оптимальности

## Matrix completion: почему ядерная норма?

**Задача восстановления матрицы.** Данна матрица  $B \in \mathbb{R}^{m \times n}$ , наблюдаемая лишь на подмножестве индексов  $\Omega \subset [m] \times [n]$ . Нужно восстановить всю матрицу, предполагая, что она имеет малый ранг.

Некорректная (невыпуклая) постановка

$$\min_X \frac{1}{2} \sum_{(i,j) \in \Omega} (X_{ij} - B_{ij})^2 \quad \text{s.t.} \quad \text{rank}(X) \leq r$$

- Ограничение  $\text{rank}(X) \leq r$  — **невыпуклое**
- NP-трудная задача в общем случае
- Нет гарантий глобальной оптимальности

## Matrix completion: почему ядерная норма?

**Задача восстановления матрицы.** Данна матрица  $B \in \mathbb{R}^{m \times n}$ , наблюдаемая лишь на подмножестве индексов  $\Omega \subset [m] \times [n]$ . Нужно восстановить всю матрицу, предполагая, что она имеет малый ранг.

Некорректная (невыпуклая) постановка

$$\min_X \frac{1}{2} \sum_{(i,j) \in \Omega} (X_{ij} - B_{ij})^2 \quad \text{s.t.} \quad \text{rank}(X) \leq r$$

- Ограничение  $\text{rank}(X) \leq r$  — **невыпуклое**
- NP-трудная задача в общем случае
- Нет гарантий глобальной оптимальности

Выпуклая релаксация

$$\min_X \frac{1}{2} \sum_{(i,j) \in \Omega} (X_{ij} - B_{ij})^2 \quad \text{s.t.} \quad \|X\|_* \leq R$$

- Ядерная норма — **выпуклая оболочка** ранга

## Matrix completion: почему ядерная норма?

**Задача восстановления матрицы.** Данна матрица  $B \in \mathbb{R}^{m \times n}$ , наблюдаемая лишь на подмножестве индексов  $\Omega \subset [m] \times [n]$ . Нужно восстановить всю матрицу, предполагая, что она имеет малый ранг.

Некорректная (невыпуклая) постановка

$$\min_X \frac{1}{2} \sum_{(i,j) \in \Omega} (X_{ij} - B_{ij})^2 \quad \text{s.t.} \quad \text{rank}(X) \leq r$$

- Ограничение  $\text{rank}(X) \leq r$  — **невыпуклое**
- NP-трудная задача в общем случае
- Нет гарантий глобальной оптимальности

Выпуклая релаксация

$$\min_X \frac{1}{2} \sum_{(i,j) \in \Omega} (X_{ij} - B_{ij})^2 \quad \text{s.t.} \quad \|X\|_* \leq R$$

- Ядерная норма — **выпуклая оболочка** ранга
- Задача выпуклая, можно применять PGD и FW

# Matrix completion: почему ядерная норма?

**Задача восстановления матрицы.** Данна матрица  $B \in \mathbb{R}^{m \times n}$ , наблюдаемая лишь на подмножестве индексов  $\Omega \subset [m] \times [n]$ . Нужно восстановить всю матрицу, предполагая, что она имеет малый ранг.

Некорректная (невыпуклая) постановка

$$\min_X \frac{1}{2} \sum_{(i,j) \in \Omega} (X_{ij} - B_{ij})^2 \quad \text{s.t.} \quad \text{rank}(X) \leq r$$

- Ограничение  $\text{rank}(X) \leq r$  — **невыпуклое**
- NP-трудная задача в общем случае
- Нет гарантий глобальной оптимальности

Выпуклая релаксация

$$\min_X \frac{1}{2} \sum_{(i,j) \in \Omega} (X_{ij} - B_{ij})^2 \quad \text{s.t.} \quad \|X\|_* \leq R$$

- Ядерная норма — **выпуклая оболочка** ранга
- Задача выпуклая, можно применять PGD и FW
- Гарантии точного восстановления при определённых условиях<sup>5</sup>

<sup>5</sup> Candès, Recht. Exact Matrix Completion via Convex Optimization.

# Matrix completion: почему ядерная норма?

**Задача восстановления матрицы.** Данна матрица  $B \in \mathbb{R}^{m \times n}$ , наблюдаемая лишь на подмножестве индексов  $\Omega \subset [m] \times [n]$ . Нужно восстановить всю матрицу, предполагая, что она имеет малый ранг.

Некорректная (невыпуклая) постановка

$$\min_X \frac{1}{2} \sum_{(i,j) \in \Omega} (X_{ij} - B_{ij})^2 \quad \text{s.t.} \quad \text{rank}(X) \leq r$$

- Ограничение  $\text{rank}(X) \leq r$  — **невыпуклое**
- NP-трудная задача в общем случае
- Нет гарантий глобальной оптимальности

Выпуклая релаксация

$$\min_X \frac{1}{2} \sum_{(i,j) \in \Omega} (X_{ij} - B_{ij})^2 \quad \text{s.t.} \quad \|X\|_* \leq R$$

- Ядерная норма — **выпуклая оболочка** ранга
- Задача выпуклая, можно применять PGD и FW
- Гарантии точного восстановления при определённых условиях<sup>5</sup>

<sup>5</sup> Candès, Recht. Exact Matrix Completion via Convex Optimization.

# Matrix completion: почему ядерная норма?

**Задача восстановления матрицы.** Данна матрица  $B \in \mathbb{R}^{m \times n}$ , наблюдаемая лишь на подмножестве индексов  $\Omega \subset [m] \times [n]$ . Нужно восстановить всю матрицу, предполагая, что она имеет малый ранг.

Некорректная (невыпуклая) постановка

$$\min_X \frac{1}{2} \sum_{(i,j) \in \Omega} (X_{ij} - B_{ij})^2 \quad \text{s.t.} \quad \text{rank}(X) \leq r$$

- Ограничение  $\text{rank}(X) \leq r$  — **невыпуклое**
- NP-трудная задача в общем случае
- Нет гарантий глобальной оптимальности

Выпуклая релаксация

$$\min_X \frac{1}{2} \sum_{(i,j) \in \Omega} (X_{ij} - B_{ij})^2 \quad \text{s.t.} \quad \|X\|_* \leq R$$

- Ядерная норма — **выпуклая оболочка** ранга
- Задача выпуклая, можно применять PGD и FW
- Гарантии точного восстановления при определённых условиях<sup>5</sup>

**Пример из практики:** Netflix Prize — предсказание оценок пользователей для фильмов. Матрица  $\sim 500K \times 17K$ , известно  $\sim 1\%$  записей. Ядерная норма + FW позволяют эффективно решать эту задачу.

<sup>5</sup> Candès, Recht. Exact Matrix Completion via Convex Optimization.

## Метод зеркального спуска

## Мотивация: зачем нужен зеркальный спуск?

Вспомним итерацию метода проекции градиента:

$$x_{k+1} = \text{proj}_S(x_k - \alpha_k \nabla f(x_k))$$

## Мотивация: зачем нужен зеркальный спуск?

Вспомним итерацию метода проекции градиента:

$$x_{k+1} = \text{proj}_S(x_k - \alpha_k \nabla f(x_k))$$

Эта формула опирается на **евклидову норму**  $\|\cdot\|_2$ , как в шаге градиента, так и в проекции. Но что, если:

- Геометрия задачи **неевклидова**? Например, оптимизация на симплексе  $\Delta_n = \{x \geq 0, \mathbf{1}^\top x = 1\}$  — естественная геометрия описывается не  $\ell_2$ , а  $\ell_1$ -нормой.

## Мотивация: зачем нужен зеркальный спуск?

Вспомним итерацию метода проекции градиента:

$$x_{k+1} = \text{proj}_S(x_k - \alpha_k \nabla f(x_k))$$

Эта формула опирается на **евклидову норму**  $\|\cdot\|_2$ , как в шаге градиента, так и в проекции. Но что, если:

- Геометрия задачи **неевклидова**? Например, оптимизация на симплексе  $\Delta_n = \{x \geq 0, \mathbf{1}^\top x = 1\}$  — естественная геометрия описывается не  $\ell_2$ , а  $\ell_1$ -нормой.
- Функция  $f$  гладкая относительно **неевклидовой** нормы  $\|\cdot\|$ ?

$$f(y) \leq f(x) + \langle \nabla f(x), y - x \rangle + \frac{L}{2} \|y - x\|^2$$

## Мотивация: зачем нужен зеркальный спуск?

Вспомним итерацию метода проекции градиента:

$$x_{k+1} = \text{proj}_S(x_k - \alpha_k \nabla f(x_k))$$

Эта формула опирается на **евклидову норму**  $\|\cdot\|_2$ , как в шаге градиента, так и в проекции. Но что, если:

- Геометрия задачи **неевклидова**? Например, оптимизация на симплексе  $\Delta_n = \{x \geq 0, \mathbf{1}^\top x = 1\}$  — естественная геометрия описывается не  $\ell_2$ , а  $\ell_1$ -нормой.
- Функция  $f$  гладкая относительно **неевклидовой** нормы  $\|\cdot\|$ ?

$$f(y) \leq f(x) + \langle \nabla f(x), y - x \rangle + \frac{L}{2} \|y - x\|^2$$

## Мотивация: зачем нужен зеркальный спуск?

Вспомним итерацию метода проекции градиента:

$$x_{k+1} = \text{proj}_S(x_k - \alpha_k \nabla f(x_k))$$

Эта формула опирается на **евклидову норму**  $\|\cdot\|_2$ , как в шаге градиента, так и в проекции. Но что, если:

- Геометрия задачи **неевклидова**? Например, оптимизация на симплексе  $\Delta_n = \{x \geq 0, \mathbf{1}^\top x = 1\}$  — естественная геометрия описывается не  $\ell_2$ , а  $\ell_1$ -нормой.
- Функция  $f$  гладкая относительно **неевклидовой** нормы  $\|\cdot\|$ ?

$$f(y) \leq f(x) + \langle \nabla f(x), y - x \rangle + \frac{L}{2} \|y - x\|^2$$

**Проблема:** PGD с евклидовой проекцией может давать оценку  $\mathcal{O}\left(\frac{L_2 R_2^2}{k}\right)$ , но  $L_2$  и  $R_2$  могут  **зависеть от размерности  $n$** , что делает оценку бессмысленной для задач большой размерности.

## Мотивация: пример на симплексе

Рассмотрим задачу на стандартном симплексе  $\Delta_n = \{x \in \mathbb{R}^n \mid x \geq 0, \mathbf{1}^\top x = 1\}$ :

$$\min_{x \in \Delta_n} f(x)$$

## Мотивация: пример на симплексе

Рассмотрим задачу на стандартном симплексе  $\Delta_n = \{x \in \mathbb{R}^n \mid x \geq 0, \mathbf{1}^\top x = 1\}$ :

$$\min_{x \in \Delta_n} f(x)$$

Пусть  $f$  является  $L_1$ -гладкой относительно  $\ell_1$ -нормы:  $f(y) \leq f(x) + \langle \nabla f(x), y - x \rangle + \frac{L_1}{2} \|y - x\|_1^2$ .

## Мотивация: пример на симплексе

Рассмотрим задачу на стандартном симплексе  $\Delta_n = \{x \in \mathbb{R}^n \mid x \geq 0, \mathbf{1}^\top x = 1\}$ :

$$\min_{x \in \Delta_n} f(x)$$

Пусть  $f$  является  $L_1$ -гладкой относительно  $\ell_1$ -нормы:  $f(y) \leq f(x) + \langle \nabla f(x), y - x \rangle + \frac{L_1}{2} \|y - x\|_1^2$ .

### PGD (евклидова геометрия)

- Гладкость:  $L_2 \leq n \cdot L_1$  (из  $\|x\|_2 \leq \|x\|_1$ )

## Мотивация: пример на симплексе

Рассмотрим задачу на стандартном симплексе  $\Delta_n = \{x \in \mathbb{R}^n \mid x \geq 0, \mathbf{1}^\top x = 1\}$ :

$$\min_{x \in \Delta_n} f(x)$$

Пусть  $f$  является  $L_1$ -гладкой относительно  $\ell_1$ -нормы:  $f(y) \leq f(x) + \langle \nabla f(x), y - x \rangle + \frac{L_1}{2} \|y - x\|_1^2$ .

### PGD (евклидова геометрия)

- Гладкость:  $L_2 \leq n \cdot L_1$  (из  $\|x\|_2 \leq \|x\|_1$ )
- Диаметр:  $R_2 = \sqrt{2}$

## Мотивация: пример на симплексе

Рассмотрим задачу на стандартном симплексе  $\Delta_n = \{x \in \mathbb{R}^n \mid x \geq 0, \mathbf{1}^\top x = 1\}$ :

$$\min_{x \in \Delta_n} f(x)$$

Пусть  $f$  является  $L_1$ -гладкой относительно  $\ell_1$ -нормы:  $f(y) \leq f(x) + \langle \nabla f(x), y - x \rangle + \frac{L_1}{2} \|y - x\|_1^2$ .

### PGD (евклидова геометрия)

- Гладкость:  $L_2 \leq n \cdot L_1$  (из  $\|x\|_2 \leq \|x\|_1$ )
- Диаметр:  $R_2 = \sqrt{2}$
- Оценка:

$$f(x_k) - f^* \leq \frac{n \cdot L_1 \cdot 2}{2k} = \frac{nL_1}{k}$$

## Мотивация: пример на симплексе

Рассмотрим задачу на стандартном симплексе  $\Delta_n = \{x \in \mathbb{R}^n \mid x \geq 0, \mathbf{1}^\top x = 1\}$ :

$$\min_{x \in \Delta_n} f(x)$$

Пусть  $f$  является  $L_1$ -гладкой относительно  $\ell_1$ -нормы:  $f(y) \leq f(x) + \langle \nabla f(x), y - x \rangle + \frac{L_1}{2} \|y - x\|_1^2$ .

### PGD (евклидова геометрия)

- Гладкость:  $L_2 \leq n \cdot L_1$  (из  $\|x\|_2 \leq \|x\|_1$ )
- Диаметр:  $R_2 = \sqrt{2}$
- Оценка:

$$f(x_k) - f^* \leq \frac{n \cdot L_1 \cdot 2}{2k} = \frac{nL_1}{k}$$

## Мотивация: пример на симплексе

Рассмотрим задачу на стандартном симплексе  $\Delta_n = \{x \in \mathbb{R}^n \mid x \geq 0, \mathbf{1}^\top x = 1\}$ :

$$\min_{x \in \Delta_n} f(x)$$

Пусть  $f$  является  $L_1$ -гладкой относительно  $\ell_1$ -нормы:  $f(y) \leq f(x) + \langle \nabla f(x), y - x \rangle + \frac{L_1}{2} \|y - x\|_1^2$ .

### PGD (евклидова геометрия)

- Гладкость:  $L_2 \leq n \cdot L_1$  (из  $\|x\|_2 \leq \|x\|_1$ )
- Диаметр:  $R_2 = \sqrt{2}$
- Оценка:

$$f(x_k) - f^* \leq \frac{n \cdot L_1 \cdot 2}{2k} = \frac{nL_1}{k}$$

### Зеркальный спуск ( $\ell_1$ -геометрия)

- Гладкость:  $L_1$  (без множителя!)

## Мотивация: пример на симплексе

Рассмотрим задачу на стандартном симплексе  $\Delta_n = \{x \in \mathbb{R}^n \mid x \geq 0, \mathbf{1}^\top x = 1\}$ :

$$\min_{x \in \Delta_n} f(x)$$

Пусть  $f$  является  $L_1$ -гладкой относительно  $\ell_1$ -нормы:  $f(y) \leq f(x) + \langle \nabla f(x), y - x \rangle + \frac{L_1}{2} \|y - x\|_1^2$ .

### PGD (евклидова геометрия)

- Гладкость:  $L_2 \leq n \cdot L_1$  (из  $\|x\|_2 \leq \|x\|_1$ )
- Диаметр:  $R_2 = \sqrt{2}$
- Оценка:

$$f(x_k) - f^* \leq \frac{n \cdot L_1 \cdot 2}{2k} = \frac{nL_1}{k}$$

### Зеркальный спуск ( $\ell_1$ -геометрия)

- Гладкость:  $L_1$  (без множителя!)
- «Диаметр»:  $R_1 = \sqrt{2 \ln n}$  (в смысле дивергенции Брэгмана)

## Мотивация: пример на симплексе

Рассмотрим задачу на стандартном симплексе  $\Delta_n = \{x \in \mathbb{R}^n \mid x \geq 0, \mathbf{1}^\top x = 1\}$ :

$$\min_{x \in \Delta_n} f(x)$$

Пусть  $f$  является  $L_1$ -гладкой относительно  $\ell_1$ -нормы:  $f(y) \leq f(x) + \langle \nabla f(x), y - x \rangle + \frac{L_1}{2} \|y - x\|_1^2$ .

### PGD (евклидова геометрия)

- Гладкость:  $L_2 \leq n \cdot L_1$  (из  $\|x\|_2 \leq \|x\|_1$ )
- Диаметр:  $R_2 = \sqrt{2}$
- Оценка:

$$f(x_k) - f^* \leq \frac{n \cdot L_1 \cdot 2}{2k} = \frac{nL_1}{k}$$

### Зеркальный спуск ( $\ell_1$ -геометрия)

- Гладкость:  $L_1$  (без множителя!)
- «Диаметр»:  $R_1 = \sqrt{2 \ln n}$  (в смысле дивергенции Брэгмана)
- Оценка:

$$f(x_k) - f^* \leq \frac{L_1 \cdot 2 \ln n}{2k} = \frac{L_1 \ln n}{k}$$

## Мотивация: пример на симплексе

Рассмотрим задачу на стандартном симплексе  $\Delta_n = \{x \in \mathbb{R}^n \mid x \geq 0, \mathbf{1}^\top x = 1\}$ :

$$\min_{x \in \Delta_n} f(x)$$

Пусть  $f$  является  $L_1$ -гладкой относительно  $\ell_1$ -нормы:  $f(y) \leq f(x) + \langle \nabla f(x), y - x \rangle + \frac{L_1}{2} \|y - x\|_1^2$ .

### PGD (евклидова геометрия)

- Гладкость:  $L_2 \leq n \cdot L_1$  (из  $\|x\|_2 \leq \|x\|_1$ )
- Диаметр:  $R_2 = \sqrt{2}$
- Оценка:

$$f(x_k) - f^* \leq \frac{n \cdot L_1 \cdot 2}{2k} = \frac{nL_1}{k}$$

### Зеркальный спуск ( $\ell_1$ -геометрия)

- Гладкость:  $L_1$  (без множителя!)
- «Диаметр»:  $R_1 = \sqrt{2 \ln n}$  (в смысле дивергенции Брэгмана)
- Оценка:

$$f(x_k) - f^* \leq \frac{L_1 \cdot 2 \ln n}{2k} = \frac{L_1 \ln n}{k}$$

## Мотивация: пример на симплексе

Рассмотрим задачу на стандартном симплексе  $\Delta_n = \{x \in \mathbb{R}^n \mid x \geq 0, \mathbf{1}^\top x = 1\}$ :

$$\min_{x \in \Delta_n} f(x)$$

Пусть  $f$  является  $L_1$ -гладкой относительно  $\ell_1$ -нормы:  $f(y) \leq f(x) + \langle \nabla f(x), y - x \rangle + \frac{L_1}{2} \|y - x\|_1^2$ .

### PGD (евклидова геометрия)

- Гладкость:  $L_2 \leq n \cdot L_1$  (из  $\|x\|_2 \leq \|x\|_1$ )
- Диаметр:  $R_2 = \sqrt{2}$
- Оценка:

$$f(x_k) - f^* \leq \frac{n \cdot L_1 \cdot 2}{2k} = \frac{nL_1}{k}$$

### Зеркальный спуск ( $\ell_1$ -геометрия)

- Гладкость:  $L_1$  (без множителя!)
- «Диаметр»:  $R_1 = \sqrt{2 \ln n}$  (в смысле дивергенции Брэгмана)
- Оценка:

$$f(x_k) - f^* \leq \frac{L_1 \cdot 2 \ln n}{2k} = \frac{L_1 \ln n}{k}$$

Выигрыш:  $\frac{n}{\ln n}$  — экспоненциальный по размерности!

## Мотивация: прямое и двойственное пространство

**Идея.** Градиент  $\nabla f(x)$  живёт в **двойственном** пространстве  $(\mathbb{R}^n)^*$  с нормой  $\|\cdot\|_*$ , а переменная  $x$  — в **прямом** пространстве  $\mathbb{R}^n$  с нормой  $\|\cdot\|$ .

## Мотивация: прямое и двойственное пространство

**Идея.** Градиент  $\nabla f(x)$  живёт в **двойственном** пространстве  $(\mathbb{R}^n)^*$  с нормой  $\|\cdot\|_*$ , а переменная  $x$  — в **прямом** пространстве  $\mathbb{R}^n$  с нормой  $\|\cdot\|$ .

В PGD мы неявно отождествляем прямое и  
двойственное пространство (что корректно только для  
 $\ell_2$ ):

$$x_{k+1} = x_k - \alpha_k \nabla f(x_k)$$

Вычитаем **градиент** (двойственный вектор) из **точки**  
(прямой вектор) напрямую.

## Мотивация: прямое и двойственное пространство

**Идея.** Градиент  $\nabla f(x)$  живёт в **двойственном** пространстве  $(\mathbb{R}^n)^*$  с нормой  $\|\cdot\|_*$ , а переменная  $x$  — в **прямом** пространстве  $\mathbb{R}^n$  с нормой  $\|\cdot\|$ .

В PGD мы неявно отождествляем прямое и двойственное пространство (что корректно только для  $\ell_2$ ):

$$x_{k+1} = x_k - \alpha_k \nabla f(x_k)$$

Вычитаем **градиент** (двойственный вектор) из **точки** (прямой вектор) напрямую.

В зеркальном спуске мы **явно** работаем с двумя пространствами через **зеркальное отображение**  $\nabla\omega$ :

$$\begin{aligned}\nabla\omega(y_{k+1}) &= \nabla\omega(x_k) - \alpha_k \nabla f(x_k) \\ x_{k+1} &= \nabla\omega^*(y_{k+1})\end{aligned}$$

Шаг делается в двойственном пространстве, затем результат отображается обратно.

## Мотивация: прямое и двойственное пространство

**Идея.** Градиент  $\nabla f(x)$  живёт в **двойственном** пространстве  $(\mathbb{R}^n)^*$  с нормой  $\|\cdot\|_*$ , а переменная  $x$  — в **прямом** пространстве  $\mathbb{R}^n$  с нормой  $\|\cdot\|$ .

В PGD мы неявно отождествляем прямое и двойственное пространство (что корректно только для  $\ell_2$ ):

$$x_{k+1} = x_k - \alpha_k \nabla f(x_k)$$

Вычитаем **градиент** (двойственный вектор) из **точки** (прямой вектор) напрямую.

Функция  $\omega$  называется **прокс-функцией** (distance-generating function). Она задаёт геометрию через дивергенцию Брэгмана.

В зеркальном спуске мы **явно** работаем с двумя пространствами через **зеркальное отображение**  $\nabla\omega$ :

$$\begin{aligned}\nabla\omega(y_{k+1}) &= \nabla\omega(x_k) - \alpha_k \nabla f(x_k) \\ x_{k+1} &= \nabla\omega^*(y_{k+1})\end{aligned}$$

Шаг делается в двойственном пространстве, затем результат отображается обратно.

## Дивергенция Брэгмана

### Дивергенция Брэгмана

Пусть  $\omega : \mathbb{R}^n \rightarrow \mathbb{R}$  — непрерывно дифференцируемая и строго выпуклая функция. **Дивергенция Брэгмана**, порождённая функцией  $\omega$ , определяется как:

$$V_\omega(x, y) = \omega(x) - \omega(y) - \langle \nabla \omega(y), x - y \rangle$$

# Дивергенция Брэгмана

## ⓘ Дивергенция Брэгмана

Пусть  $\omega : \mathbb{R}^n \rightarrow \mathbb{R}$  — непрерывно дифференцируемая и строго выпуклая функция. **Дивергенция Брэгмана**, порождённая функцией  $\omega$ , определяется как:

$$V_\omega(x, y) = \omega(x) - \omega(y) - \langle \nabla \omega(y), x - y \rangle$$

### Свойства:

- $V_\omega(x, y) \geq 0$  для всех  $x, y$  (из строгой выпуклости  $\omega$ ).

# Дивергенция Брэгмана

## Дивергенция Брэгмана

Пусть  $\omega : \mathbb{R}^n \rightarrow \mathbb{R}$  — непрерывно дифференцируемая и строго выпуклая функция. **Дивергенция Брэгмана**, порождённая функцией  $\omega$ , определяется как:

$$V_\omega(x, y) = \omega(x) - \omega(y) - \langle \nabla \omega(y), x - y \rangle$$

### Свойства:

- $V_\omega(x, y) \geq 0$  для всех  $x, y$  (из строгой выпуклости  $\omega$ ).
- $V_\omega(x, y) = 0 \Leftrightarrow x = y$ .

# Дивергенция Брэгмана

## Дивергенция Брэгмана

Пусть  $\omega : \mathbb{R}^n \rightarrow \mathbb{R}$  — непрерывно дифференцируемая и строго выпуклая функция. **Дивергенция Брэгмана**, порождённая функцией  $\omega$ , определяется как:

$$V_\omega(x, y) = \omega(x) - \omega(y) - \langle \nabla \omega(y), x - y \rangle$$

### Свойства:

- $V_\omega(x, y) \geq 0$  для всех  $x, y$  (из строгой выпуклости  $\omega$ ).
- $V_\omega(x, y) = 0 \Leftrightarrow x = y$ .
- **Не симметрична** в общем случае:  $V_\omega(x, y) \neq V_\omega(y, x)$ .

# Дивергенция Брэгмана

## Дивергенция Брэгмана

Пусть  $\omega : \mathbb{R}^n \rightarrow \mathbb{R}$  — непрерывно дифференцируемая и строго выпуклая функция. **Дивергенция Брэгмана**, порождённая функцией  $\omega$ , определяется как:

$$V_\omega(x, y) = \omega(x) - \omega(y) - \langle \nabla \omega(y), x - y \rangle$$

### Свойства:

- $V_\omega(x, y) \geq 0$  для всех  $x, y$  (из строгой выпуклости  $\omega$ ).
- $V_\omega(x, y) = 0 \Leftrightarrow x = y$ .
- **Не симметрична** в общем случае:  $V_\omega(x, y) \neq V_\omega(y, x)$ .
- **Не удовлетворяет** неравенству треугольника.

# Дивергенция Брэгмана

## Дивергенция Брэгмана

Пусть  $\omega : \mathbb{R}^n \rightarrow \mathbb{R}$  — непрерывно дифференцируемая и строго выпуклая функция. **Дивергенция Брэгмана**, порождённая функцией  $\omega$ , определяется как:

$$V_\omega(x, y) = \omega(x) - \omega(y) - \langle \nabla \omega(y), x - y \rangle$$

### Свойства:

- $V_\omega(x, y) \geq 0$  для всех  $x, y$  (из строгой выпуклости  $\omega$ ).
- $V_\omega(x, y) = 0 \Leftrightarrow x = y$ .
- **Не симметрична** в общем случае:  $V_\omega(x, y) \neq V_\omega(y, x)$ .
- **Не удовлетворяет** неравенству треугольника.
- Геометрически:  $V_\omega(x, y)$  — разность между  $\omega(x)$  и значением касательной к  $\omega$  в точке  $y$ , вычисленным в точке  $x$ .

## Примеры дивергенций Брэгмана

Евклидова дивергенция

$$\omega(x) = \frac{1}{2} \|x\|_2^2$$

$$V_\omega(x, y) = \frac{1}{2} \|x\|_2^2 - \frac{1}{2} \|y\|_2^2 - \langle y, x - y \rangle = \frac{1}{2} \|x - y\|_2^2$$

Воспроизводит обычный PGD.

## Примеры дивергенций Брэгмана

Евклидова дивергенция

$$\omega(x) = \frac{1}{2} \|x\|_2^2$$

$$V_\omega(x, y) = \frac{1}{2} \|x\|_2^2 - \frac{1}{2} \|y\|_2^2 - \langle y, x - y \rangle = \frac{1}{2} \|x - y\|_2^2$$

Воспроизводит обычный PGD.

Дивергенция Кульбака-Лейблера (KL)

$$\omega(x) = \sum_{i=1}^n x_i \ln x_i \text{ (негативная энтропия) на } \Delta_n$$

$$V_\omega(x, y) = \sum_{i=1}^n x_i \ln \frac{x_i}{y_i}$$

Естественна для задач на симплексе.

# Примеры дивергенций Брэгмана

Евклидова дивергенция

$$\omega(x) = \frac{1}{2} \|x\|_2^2$$

$$V_\omega(x, y) = \frac{1}{2} \|x\|_2^2 - \frac{1}{2} \|y\|_2^2 - \langle y, x - y \rangle = \frac{1}{2} \|x - y\|_2^2$$

Воспроизводит обычный PGD.

Дивергенция Кульбака-Лейблера (KL)

$$\omega(x) = \sum_{i=1}^n x_i \ln x_i \text{ (негативная энтропия) на } \Delta_n$$

$$V_\omega(x, y) = \sum_{i=1}^n x_i \ln \frac{x_i}{y_i}$$

Естественна для задач на симплексе.

Дивергенция Итакура-Сайто

$$\omega(x) = - \sum_{i=1}^n \ln x_i \text{ на } \mathbb{R}_{++}^n$$

$$V_\omega(x, y) = \sum_{i=1}^n \left( \frac{x_i}{y_i} - \ln \frac{x_i}{y_i} - 1 \right)$$

Используется в обработке сигналов.

# Примеры дивергенций Брэгмана

Евклидова дивергенция

$$\omega(x) = \frac{1}{2}\|x\|_2^2$$

$$V_\omega(x, y) = \frac{1}{2}\|x\|_2^2 - \frac{1}{2}\|y\|_2^2 - \langle y, x - y \rangle = \frac{1}{2}\|x - y\|_2^2$$

Воспроизводит обычный PGD.

Дивергенция Кульбака-Лейблера (KL)

$$\omega(x) = \sum_{i=1}^n x_i \ln x_i \text{ (негативная энтропия) на } \Delta_n$$

$$V_\omega(x, y) = \sum_{i=1}^n x_i \ln \frac{x_i}{y_i}$$

Естественна для задач на симплексе.

Дивергенция Итакура-Сайто

$$\omega(x) = -\sum_{i=1}^n \ln x_i \text{ на } \mathbb{R}_{++}^n$$

$$V_\omega(x, y) = \sum_{i=1}^n \left( \frac{x_i}{y_i} - \ln \frac{x_i}{y_i} - 1 \right)$$

Используется в обработке сигналов.

Дивергенция Махаланобиса

$$\omega(x) = \frac{1}{2}x^\top Qx, \text{ где } Q \succ 0$$

$$V_\omega(x, y) = \frac{1}{2}(x - y)^\top Q(x - y)$$

Обобщённая евклидова геометрия.

## Сильная выпуклость относительно нормы

### Definition

Функция  $\omega$  называется  **$\sigma$ -сильно выпуклой относительно нормы  $\|\cdot\|$** , если для всех  $x, y$  из области определения:

$$V_\omega(x, y) \geq \frac{\sigma}{2} \|x - y\|^2$$

# Сильная выпуклость относительно нормы

## Definition

Функция  $\omega$  называется  **$\sigma$ -сильно выпуклой относительно нормы  $\|\cdot\|$** , если для всех  $x, y$  из области определения:

$$V_\omega(x, y) \geq \frac{\sigma}{2} \|x - y\|^2$$

## Ключевые примеры:

- $\omega(x) = \frac{1}{2}\|x\|_2^2$  является 1-сильно выпуклой относительно  $\|\cdot\|_2$ .

# Сильная выпуклость относительно нормы

## Definition

Функция  $\omega$  называется  **$\sigma$ -сильно выпуклой относительно нормы  $\|\cdot\|$** , если для всех  $x, y$  из области определения:

$$V_\omega(x, y) \geq \frac{\sigma}{2} \|x - y\|^2$$

## Ключевые примеры:

- $\omega(x) = \frac{1}{2}\|x\|_2^2$  является 1-сильно выпуклой относительно  $\|\cdot\|_2$ .
- $\omega(x) = \sum_i x_i \ln x_i$  (негативная энтропия) является 1-сильно выпуклой относительно  $\|\cdot\|_1$  на симплексе  $\Delta_n$ .

## Сильная выпуклость относительно нормы

### Definition

Функция  $\omega$  называется  **$\sigma$ -сильно выпуклой относительно нормы  $\|\cdot\|$** , если для всех  $x, y$  из области определения:

$$V_\omega(x, y) \geq \frac{\sigma}{2} \|x - y\|^2$$

### Ключевые примеры:

- $\omega(x) = \frac{1}{2}\|x\|_2^2$  является 1-сильно выпуклой относительно  $\|\cdot\|_2$ .
- $\omega(x) = \sum_i x_i \ln x_i$  (негативная энтропия) является 1-сильно выпуклой относительно  $\|\cdot\|_1$  на симплексе  $\Delta_n$ .
  - Это утверждение известно как **неравенство Пинскера** и является нетривиальным результатом.

## Сильная выпуклость относительно нормы

### Definition

Функция  $\omega$  называется  **$\sigma$ -сильно выпуклой относительно нормы  $\|\cdot\|$** , если для всех  $x, y$  из области определения:

$$V_\omega(x, y) \geq \frac{\sigma}{2} \|x - y\|^2$$

### Ключевые примеры:

- $\omega(x) = \frac{1}{2}\|x\|_2^2$  является 1-сильно выпуклой относительно  $\|\cdot\|_2$ .
- $\omega(x) = \sum_i x_i \ln x_i$  (негативная энтропия) является 1-сильно выпуклой относительно  $\|\cdot\|_1$  на симплексе  $\Delta_n$ .
  - Это утверждение известно как **неравенство Пинскера** и является нетривиальным результатом.

# Сильная выпуклость относительно нормы

## Definition

Функция  $\omega$  называется  **$\sigma$ -сильно выпуклой относительно нормы  $\|\cdot\|$** , если для всех  $x, y$  из области определения:

$$V_\omega(x, y) \geq \frac{\sigma}{2} \|x - y\|^2$$

## Ключевые примеры:

- $\omega(x) = \frac{1}{2}\|x\|_2^2$  является 1-сильно выпуклой относительно  $\|\cdot\|_2$ .
- $\omega(x) = \sum_i x_i \ln x_i$  (негативная энтропия) является 1-сильно выпуклой относительно  $\|\cdot\|_1$  на симплексе  $\Delta_n$ .
  - Это утверждение известно как **неравенство Пинскера** и является нетривиальным результатом.

Именно  $\sigma$ -сильная выпуклость прокс-функции  $\omega$  относительно нормы  $\|\cdot\|$  позволяет дивергенции Брэгмана «измерять расстояния» в геометрии, задаваемой нормой  $\|\cdot\|$ .

## Алгоритм зеркального спуска

**Задача:**  $\min_{x \in S} f(x)$ , где  $f$  — выпуклая функция,  $S$  — замкнутое выпуклое множество.

## Алгоритм зеркального спуска

**Задача:**  $\min_{x \in S} f(x)$ , где  $f$  — выпуклая функция,  $S$  — замкнутое выпуклое множество.

### Метод зеркального спуска (Mirror Descent)

**Вход:**  $x_0 \in S$ , шаги  $\{\alpha_k\}$ , прокс-функция  $\omega$ .

**Для**  $k = 0, 1, 2, \dots$ :

1. Вычислить градиент  $g_k = \nabla f(x_k)$

## Алгоритм зеркального спуска

**Задача:**  $\min_{x \in S} f(x)$ , где  $f$  — выпуклая функция,  $S$  — замкнутое выпуклое множество.

### Метод зеркального спуска (Mirror Descent)

**Вход:**  $x_0 \in S$ , шаги  $\{\alpha_k\}$ , прокс-функция  $\omega$ .

**Для**  $k = 0, 1, 2, \dots$ :

1. Вычислить градиент  $g_k = \nabla f(x_k)$
2. Шаг в двойственном пространстве:

$$x_{k+1} = \arg \min_{x \in S} \left\{ \langle g_k, x \rangle + \frac{1}{\alpha_k} V_\omega(x, x_k) \right\}$$

## Алгоритм зеркального спуска

**Задача:**  $\min_{x \in S} f(x)$ , где  $f$  — выпуклая функция,  $S$  — замкнутое выпуклое множество.

### Метод зеркального спуска (Mirror Descent)

**Вход:**  $x_0 \in S$ , шаги  $\{\alpha_k\}$ , прокс-функция  $\omega$ .

**Для**  $k = 0, 1, 2, \dots$ :

1. Вычислить градиент  $g_k = \nabla f(x_k)$
2. Шаг в двойственном пространстве:

$$x_{k+1} = \arg \min_{x \in S} \left\{ \langle g_k, x \rangle + \frac{1}{\alpha_k} V_\omega(x, x_k) \right\}$$

## Алгоритм зеркального спуска

**Задача:**  $\min_{x \in S} f(x)$ , где  $f$  — выпуклая функция,  $S$  — замкнутое выпуклое множество.

### Метод зеркального спуска (Mirror Descent)

**Вход:**  $x_0 \in S$ , шаги  $\{\alpha_k\}$ , прокс-функция  $\omega$ .

**Для**  $k = 0, 1, 2, \dots$ :

1. Вычислить градиент  $g_k = \nabla f(x_k)$
2. Шаг в двойственном пространстве:

$$x_{k+1} = \arg \min_{x \in S} \left\{ \langle g_k, x \rangle + \frac{1}{\alpha_k} V_\omega(x, x_k) \right\}$$

**Интерпретация:** на каждом шаге минимизируем линейное приближение  $f$  с регуляризацией дивергенцией Брэгмана вместо  $\frac{1}{2\alpha} \|x - x_k\|_2^2$ .

## Алгоритм зеркального спуска

**Задача:**  $\min_{x \in S} f(x)$ , где  $f$  — выпуклая функция,  $S$  — замкнутое выпуклое множество.

### Метод зеркального спуска (Mirror Descent)

**Вход:**  $x_0 \in S$ , шаги  $\{\alpha_k\}$ , прокс-функция  $\omega$ .

**Для**  $k = 0, 1, 2, \dots$ :

1. Вычислить градиент  $g_k = \nabla f(x_k)$
2. Шаг в двойственном пространстве:

$$x_{k+1} = \arg \min_{x \in S} \left\{ \langle g_k, x \rangle + \frac{1}{\alpha_k} V_\omega(x, x_k) \right\}$$

**Интерпретация:** на каждом шаге минимизируем линейное приближение  $f$  с регуляризацией дивергенцией Брэгмана вместо  $\frac{1}{2\alpha} \|x - x_k\|_2^2$ .

**Частный случай:** при  $\omega(x) = \frac{1}{2}\|x\|_2^2$  получаем  $V_\omega(x, y) = \frac{1}{2}\|x - y\|_2^2$ , и итерация принимает вид:

$$x_{k+1} = \arg \min_{x \in S} \left\{ \langle \nabla f(x_k), x \rangle + \frac{1}{2\alpha_k} \|x - x_k\|_2^2 \right\} = \text{proj}_S(x_k - \alpha_k \nabla f(x_k))$$

то есть стандартный PGD.

## Зеркальный спуск: эквивалентные формы итерации

Итерацию зеркального спуска можно записать в нескольких эквивалентных формах:

## Зеркальный спуск: эквивалентные формы итерации

Итерацию зеркального спуска можно записать в нескольких эквивалентных формах:

### 1. Проксимальная форма (основная):

$$x_{k+1} = \arg \min_{x \in S} \{ \alpha_k \langle \nabla f(x_k), x \rangle + V_\omega(x, x_k) \}$$

## Зеркальный спуск: эквивалентные формы итерации

Итерацию зеркального спуска можно записать в нескольких эквивалентных формах:

### 1. Проксимальная форма (основная):

$$x_{k+1} = \arg \min_{x \in S} \{ \alpha_k \langle \nabla f(x_k), x \rangle + V_\omega(x, x_k) \}$$

### 2. Двойственная форма (через зеркальное отображение):

Для безусловной задачи ( $S = \mathbb{R}^n$ ), используя условие оптимальности  $\nabla_x V_\omega(x, x_k) = \nabla \omega(x) - \nabla \omega(x_k)$ :

$$\nabla \omega(x_{k+1}) = \nabla \omega(x_k) - \alpha_k \nabla f(x_k)$$

# Зеркальный спуск: эквивалентные формы итерации

Итерацию зеркального спуска можно записать в нескольких эквивалентных формах:

## 1. Проксимальная форма (основная):

$$x_{k+1} = \arg \min_{x \in S} \{ \alpha_k \langle \nabla f(x_k), x \rangle + V_\omega(x, x_k) \}$$

## 2. Двойственная форма (через зеркальное отображение):

Для безусловной задачи ( $S = \mathbb{R}^n$ ), используя условие оптимальности  $\nabla_x V_\omega(x, x_k) = \nabla \omega(x) - \nabla \omega(x_k)$ :

$$\nabla \omega(x_{k+1}) = \nabla \omega(x_k) - \alpha_k \nabla f(x_k)$$

## 3. Проекция Брэгмана (для условной задачи):

$$y_{k+1} : \quad \nabla \omega(y_{k+1}) = \nabla \omega(x_k) - \alpha_k \nabla f(x_k)$$

$$x_{k+1} = \arg \min_{x \in S} V_\omega(x, y_{k+1})$$

# Зеркальный спуск: эквивалентные формы итерации

Итерацию зеркального спуска можно записать в нескольких эквивалентных формах:

## 1. Проксимальная форма (основная):

$$x_{k+1} = \arg \min_{x \in S} \{ \alpha_k \langle \nabla f(x_k), x \rangle + V_\omega(x, x_k) \}$$

## 2. Двойственная форма (через зеркальное отображение):

Для безусловной задачи ( $S = \mathbb{R}^n$ ), используя условие оптимальности  $\nabla_x V_\omega(x, x_k) = \nabla \omega(x) - \nabla \omega(x_k)$ :

$$\nabla \omega(x_{k+1}) = \nabla \omega(x_k) - \alpha_k \nabla f(x_k)$$

## 3. Проекция Брэгмана (для условной задачи):

$$\begin{aligned} y_{k+1} : \quad & \nabla \omega(y_{k+1}) = \nabla \omega(x_k) - \alpha_k \nabla f(x_k) \\ & x_{k+1} = \arg \min_{x \in S} V_\omega(x, y_{k+1}) \end{aligned}$$

В евклидовом случае ( $\omega = \frac{1}{2} \|\cdot\|_2^2$ ) проекция Брэгмана совпадает с евклидовой проекцией.

## Зеркальный спуск на симплексе: Exponentiated Gradient

Важнейший частный случай:  $S = \Delta_n$ ,  $\omega(x) = \sum_i x_i \ln x_i$ .

## Зеркальный спуск на симплексе: Exponentiated Gradient

Важнейший частный случай:  $S = \Delta_n$ ,  $\omega(x) = \sum_i x_i \ln x_i$ .

Итерация зеркального спуска принимает **замкнутую форму**:

$$x_{k+1,i} = \frac{x_{k,i} \exp(-\alpha_k [\nabla f(x_k)]_i)}{\sum_{j=1}^n x_{k,j} \exp(-\alpha_k [\nabla f(x_k)]_j)}, \quad i = 1, \dots, n$$

## Зеркальный спуск на симплексе: Exponentiated Gradient

Важнейший частный случай:  $S = \Delta_n$ ,  $\omega(x) = \sum_i x_i \ln x_i$ .

Итерация зеркального спуска принимает **замкнутую форму**:

$$x_{k+1,i} = \frac{x_{k,i} \exp(-\alpha_k [\nabla f(x_k)]_i)}{\sum_{j=1}^n x_{k,j} \exp(-\alpha_k [\nabla f(x_k)]_j)}, \quad i = 1, \dots, n$$

Этот метод известен как **Exponentiated Gradient** (EG) или **Multiplicative Weights Update**.

## Зеркальный спуск на симплексе: Exponentiated Gradient

Важнейший частный случай:  $S = \Delta_n$ ,  $\omega(x) = \sum_i x_i \ln x_i$ .

Итерация зеркального спуска принимает **замкнутую форму**:

$$x_{k+1,i} = \frac{x_{k,i} \exp(-\alpha_k [\nabla f(x_k)]_i)}{\sum_{j=1}^n x_{k,j} \exp(-\alpha_k [\nabla f(x_k)]_j)}, \quad i = 1, \dots, n$$

Этот метод известен как **Exponentiated Gradient (EG)** или **Multiplicative Weights Update**.

**Вывод.** Из условия оптимальности:  $\ln x_{k+1,i} + 1 - \ln x_{k,i} - 1 + \alpha_k g_i + \lambda = 0$ , где  $\lambda$  — множитель Лагранжа для ограничения  $\sum_i x_i = 1$ . Тогда  $x_{k+1,i} \propto x_{k,i} \exp(-\alpha_k g_i)$ , и нормировка даёт формулу выше.

## Зеркальный спуск на симплексе: Exponentiated Gradient

Важнейший частный случай:  $S = \Delta_n$ ,  $\omega(x) = \sum_i x_i \ln x_i$ .

Итерация зеркального спуска принимает **замкнутую форму**:

$$x_{k+1,i} = \frac{x_{k,i} \exp(-\alpha_k [\nabla f(x_k)]_i)}{\sum_{j=1}^n x_{k,j} \exp(-\alpha_k [\nabla f(x_k)]_j)}, \quad i = 1, \dots, n$$

Этот метод известен как **Exponentiated Gradient (EG)** или **Multiplicative Weights Update**.

**Вывод.** Из условия оптимальности:  $\ln x_{k+1,i} + 1 - \ln x_{k,i} - 1 + \alpha_k g_i + \lambda = 0$ , где  $\lambda$  — множитель Лагранжа для ограничения  $\sum_i x_i = 1$ . Тогда  $x_{k+1,i} \propto x_{k,i} \exp(-\alpha_k g_i)$ , и нормировка даёт формулу выше.

**Стоимость:**  $\mathcal{O}(n)$  — не требуется сортировка (в отличие от евклидовой проекции на симплекс, которая стоит  $\mathcal{O}(n \log n)$ ).

# Скорость сходимости зеркального спуска



## Theorem

Пусть  $f : S \rightarrow \mathbb{R}$  — выпуклая функция с  $L$ -липшицевым градиентом относительно нормы  $\|\cdot\|$ :

$$\|\nabla f(x) - \nabla f(y)\|_* \leq L\|x - y\| \quad \forall x, y \in S$$

Пусть прокс-функция  $\omega$  является  $\sigma$ -сильно выпуклой относительно  $\|\cdot\|$ , и  $R^2 = \max_{x \in S} V_\omega(x, x_0)$ . Тогда зеркальный спуск с шагом  $\alpha_k = \frac{1}{L/\sigma}$  обеспечивает:

$$f(x_k) - f^* \leq \frac{LR^2}{\sigma k}$$

# Скорость сходимости зеркального спуска



## Theorem

Пусть  $f : S \rightarrow \mathbb{R}$  — выпуклая функция с  $L$ -липшицевым градиентом относительно нормы  $\|\cdot\|$ :

$$\|\nabla f(x) - \nabla f(y)\|_* \leq L\|x - y\| \quad \forall x, y \in S$$

Пусть прокс-функция  $\omega$  является  $\sigma$ -сильно выпуклой относительно  $\|\cdot\|$ , и  $R^2 = \max_{x \in S} V_\omega(x, x_0)$ . Тогда зеркальный спуск с шагом  $\alpha_k = \frac{1}{L/\sigma}$  обеспечивает:

$$f(x_k) - f^* \leq \frac{LR^2}{\sigma k}$$

## Сравнение с PGD:

	PGD	Зеркальный спуск
Норма	$\ \cdot\ _2$	$\ \cdot\ $ (произвольная)
Гладкость	$L_2$	$L$ (отн. $\ \cdot\ $ )
«Радиус»	$R_2 = \ x_0 - x^*\ _2$	$R^2 = V_\omega(x^*, x_0)$
Оценка	$\frac{L_2 R_2^2}{k}$	$\frac{LR^2}{\sigma k}$

## Доказательство сходимости ⚡⚡⚡

1. Из  $L$ -гладкости  $f$  относительно нормы  $\|\cdot\|$  при шаге  $\alpha = \sigma/L$ :

$$f(x_{k+1}) \leq f(x_k) + \langle \nabla f(x_k), x_{k+1} - x_k \rangle + \frac{L}{2} \|x_{k+1} - x_k\|^2$$

## Доказательство сходимости ⚡⚡⚡

1. Из  $L$ -гладкости  $f$  относительно нормы  $\|\cdot\|$  при шаге  $\alpha = \sigma/L$ :

$$f(x_{k+1}) \leq f(x_k) + \langle \nabla f(x_k), x_{k+1} - x_k \rangle + \frac{L}{2} \|x_{k+1} - x_k\|^2$$

## Доказательство сходимости



1. Из  $L$ -гладкости  $f$  относительно нормы  $\|\cdot\|$  при шаге  $\alpha = \sigma/L$ :

$$f(x_{k+1}) \leq f(x_k) + \langle \nabla f(x_k), x_{k+1} - x_k \rangle + \frac{L}{2} \|x_{k+1} - x_k\|^2$$

2. Из  $\sigma$ -сильной выпуклости  $\omega$ :  $\frac{L}{2} \|x_{k+1} - x_k\|^2 \leq \frac{L}{\sigma} V_\omega(x_{k+1}, x_k)$ . Следовательно:

$$f(x_{k+1}) \leq f(x_k) + \langle \nabla f(x_k), x_{k+1} - x_k \rangle + \frac{L}{\sigma} V_\omega(x_{k+1}, x_k)$$

## Доказательство сходимости



1. Из  $L$ -гладкости  $f$  относительно нормы  $\|\cdot\|$  при шаге  $\alpha = \sigma/L$ :

$$f(x_{k+1}) \leq f(x_k) + \langle \nabla f(x_k), x_{k+1} - x_k \rangle + \frac{L}{2} \|x_{k+1} - x_k\|^2$$

2. Из  $\sigma$ -сильной выпуклости  $\omega$ :  $\frac{L}{2} \|x_{k+1} - x_k\|^2 \leq \frac{L}{\sigma} V_\omega(x_{k+1}, x_k)$ . Следовательно:

$$f(x_{k+1}) \leq f(x_k) + \langle \nabla f(x_k), x_{k+1} - x_k \rangle + \frac{L}{\sigma} V_\omega(x_{k+1}, x_k)$$

## Доказательство сходимости



- Из  $L$ -гладкости  $f$  относительно нормы  $\|\cdot\|$  при шаге  $\alpha = \sigma/L$ :

$$f(x_{k+1}) \leq f(x_k) + \langle \nabla f(x_k), x_{k+1} - x_k \rangle + \frac{L}{2} \|x_{k+1} - x_k\|^2$$

- Из  $\sigma$ -сильной выпуклости  $\omega$ :  $\frac{L}{2} \|x_{k+1} - x_k\|^2 \leq \frac{L}{\sigma} V_\omega(x_{k+1}, x_k)$ . Следовательно:

$$f(x_{k+1}) \leq f(x_k) + \langle \nabla f(x_k), x_{k+1} - x_k \rangle + \frac{L}{\sigma} V_\omega(x_{k+1}, x_k)$$

- Из определения итерации (условие оптимальности) и выпуклости  $f$  для любого  $x \in S$ :

$$\alpha_k \langle \nabla f(x_k), x_{k+1} - x \rangle \leq V_\omega(x, x_k) - V_\omega(x, x_{k+1}) - V_\omega(x_{k+1}, x_k)$$

## Доказательство сходимости



- Из  $L$ -гладкости  $f$  относительно нормы  $\|\cdot\|$  при шаге  $\alpha = \sigma/L$ :

$$f(x_{k+1}) \leq f(x_k) + \langle \nabla f(x_k), x_{k+1} - x_k \rangle + \frac{L}{2} \|x_{k+1} - x_k\|^2$$

- Из  $\sigma$ -сильной выпуклости  $\omega$ :  $\frac{L}{2} \|x_{k+1} - x_k\|^2 \leq \frac{L}{\sigma} V_\omega(x_{k+1}, x_k)$ . Следовательно:

$$f(x_{k+1}) \leq f(x_k) + \langle \nabla f(x_k), x_{k+1} - x_k \rangle + \frac{L}{\sigma} V_\omega(x_{k+1}, x_k)$$

- Из определения итерации (условие оптимальности) и выпуклости  $f$  для любого  $x \in S$ :

$$\alpha_k \langle \nabla f(x_k), x_{k+1} - x \rangle \leq V_\omega(x, x_k) - V_\omega(x, x_{k+1}) - V_\omega(x_{k+1}, x_k)$$

## Доказательство сходимости



1. Из  $L$ -гладкости  $f$  относительно нормы  $\|\cdot\|$  при шаге  $\alpha = \sigma/L$ :

$$f(x_{k+1}) \leq f(x_k) + \langle \nabla f(x_k), x_{k+1} - x_k \rangle + \frac{L}{2} \|x_{k+1} - x_k\|^2$$

2. Из  $\sigma$ -сильной выпуклости  $\omega$ :  $\frac{L}{2} \|x_{k+1} - x_k\|^2 \leq \frac{L}{\sigma} V_\omega(x_{k+1}, x_k)$ . Следовательно:

$$f(x_{k+1}) \leq f(x_k) + \langle \nabla f(x_k), x_{k+1} - x_k \rangle + \frac{L}{\sigma} V_\omega(x_{k+1}, x_k)$$

3. Из определения итерации (условие оптимальности) и выпуклости  $f$  для любого  $x \in S$ :

$$\alpha_k \langle \nabla f(x_k), x_{k+1} - x \rangle \leq V_\omega(x, x_k) - V_\omega(x, x_{k+1}) - V_\omega(x_{k+1}, x_k)$$

Это **лемма трёх точек** (three-point identity) для дивергенции Брэгмана:

$$V_\omega(x, x_k) - V_\omega(x, x_{k+1}) = \langle \nabla \omega(x_{k+1}) - \nabla \omega(x_k), x - x_{k+1} \rangle + V_\omega(x_{k+1}, x_k)$$

## Доказательство сходимости (продолжение)

4. Подставляя  $x = x^*$  и используя выпуклость  $f(x_k) - f^* \leq \langle \nabla f(x_k), x_k - x^* \rangle$ :

$$\begin{aligned}\alpha_k(f(x_k) - f^*) &\leq \alpha_k \langle \nabla f(x_k), x_k - x^* \rangle \\ &= \alpha_k \langle \nabla f(x_k), x_k - x_{k+1} \rangle + \alpha_k \langle \nabla f(x_k), x_{k+1} - x^* \rangle \\ &\leq \alpha_k \langle \nabla f(x_k), x_k - x_{k+1} \rangle + V_\omega(x^*, x_k) - V_\omega(x^*, x_{k+1}) - V_\omega(x_{k+1}, x_k)\end{aligned}$$

## Доказательство сходимости (продолжение)

4. Подставляя  $x = x^*$  и используя выпуклость  $f(x_k) - f^* \leq \langle \nabla f(x_k), x_k - x^* \rangle$ :

$$\begin{aligned}\alpha_k(f(x_k) - f^*) &\leq \alpha_k \langle \nabla f(x_k), x_k - x^* \rangle \\ &= \alpha_k \langle \nabla f(x_k), x_k - x_{k+1} \rangle + \alpha_k \langle \nabla f(x_k), x_{k+1} - x^* \rangle \\ &\leq \alpha_k \langle \nabla f(x_k), x_k - x_{k+1} \rangle + V_\omega(x^*, x_k) - V_\omega(x^*, x_{k+1}) - V_\omega(x_{k+1}, x_k)\end{aligned}$$

## Доказательство сходимости (продолжение)

4. Подставляя  $x = x^*$  и используя выпуклость  $f(x_k) - f^* \leq \langle \nabla f(x_k), x_k - x^* \rangle$ :

$$\begin{aligned}\alpha_k(f(x_k) - f^*) &\leq \alpha_k \langle \nabla f(x_k), x_k - x^* \rangle \\ &= \alpha_k \langle \nabla f(x_k), x_k - x_{k+1} \rangle + \alpha_k \langle \nabla f(x_k), x_{k+1} - x^* \rangle \\ &\leq \alpha_k \langle \nabla f(x_k), x_k - x_{k+1} \rangle + V_\omega(x^*, x_k) - V_\omega(x^*, x_{k+1}) - V_\omega(x_{k+1}, x_k)\end{aligned}$$

5. Суммируя по  $k = 0, \dots, K - 1$  и используя телескопирование:

$$\sum_{k=0}^{K-1} \alpha_k(f(x_k) - f^*) \leq V_\omega(x^*, x_0) + \sum_{k=0}^{K-1} [\alpha_k \langle \nabla f(x_k), x_k - x_{k+1} \rangle - V_\omega(x_{k+1}, x_k)]$$

## Доказательство сходимости (продолжение)

4. Подставляя  $x = x^*$  и используя выпуклость  $f(x_k) - f^* \leq \langle \nabla f(x_k), x_k - x^* \rangle$ :

$$\begin{aligned}\alpha_k(f(x_k) - f^*) &\leq \alpha_k \langle \nabla f(x_k), x_k - x^* \rangle \\ &= \alpha_k \langle \nabla f(x_k), x_k - x_{k+1} \rangle + \alpha_k \langle \nabla f(x_k), x_{k+1} - x^* \rangle \\ &\leq \alpha_k \langle \nabla f(x_k), x_k - x_{k+1} \rangle + V_\omega(x^*, x_k) - V_\omega(x^*, x_{k+1}) - V_\omega(x_{k+1}, x_k)\end{aligned}$$

5. Суммируя по  $k = 0, \dots, K - 1$  и используя телескопирование:

$$\sum_{k=0}^{K-1} \alpha_k(f(x_k) - f^*) \leq V_\omega(x^*, x_0) + \sum_{k=0}^{K-1} [\alpha_k \langle \nabla f(x_k), x_k - x_{k+1} \rangle - V_\omega(x_{k+1}, x_k)]$$

## Доказательство сходимости (продолжение)

4. Подставляя  $x = x^*$  и используя выпуклость  $f(x_k) - f^* \leq \langle \nabla f(x_k), x_k - x^* \rangle$ :

$$\begin{aligned}\alpha_k(f(x_k) - f^*) &\leq \alpha_k \langle \nabla f(x_k), x_k - x^* \rangle \\ &= \alpha_k \langle \nabla f(x_k), x_k - x_{k+1} \rangle + \alpha_k \langle \nabla f(x_k), x_{k+1} - x^* \rangle \\ &\leq \alpha_k \langle \nabla f(x_k), x_k - x_{k+1} \rangle + V_\omega(x^*, x_k) - V_\omega(x^*, x_{k+1}) - V_\omega(x_{k+1}, x_k)\end{aligned}$$

5. Суммируя по  $k = 0, \dots, K - 1$  и используя телескопирование:

$$\sum_{k=0}^{K-1} \alpha_k(f(x_k) - f^*) \leq V_\omega(x^*, x_0) + \sum_{k=0}^{K-1} [\alpha_k \langle \nabla f(x_k), x_k - x_{k+1} \rangle - V_\omega(x_{k+1}, x_k)]$$

6. Используя шаг 2 для оценки каждого слагаемого и монотонность  $f(x_k)$ :

$$K \cdot (f(x_K) - f^*) \leq \frac{L}{\sigma} V_\omega(x^*, x_0) = \frac{LR^2}{\sigma}$$

откуда  $f(x_K) - f^* \leq \frac{LR^2}{\sigma K}$ , что и требовалось доказать.

## Пример: зеркальный спуск vs PGD на симплексе

Рассмотрим задачу

$$\min_{x \in \Delta_n} f(x) = \frac{1}{2} \|Ax - b\|_2^2$$

- PGD: евклидова проекция на  $\Delta_n$ ,  $\mathcal{O}(n \log n)$  на шаг

## Пример: зеркальный спуск vs PGD на симплексе

Рассмотрим задачу

$$\min_{x \in \Delta_n} f(x) = \frac{1}{2} \|Ax - b\|_2^2$$

- PGD: евклидова проекция на  $\Delta_n$ ,  $\mathcal{O}(n \log n)$  на шаг
- MD (EG): мультипликативное обновление,  $\mathcal{O}(n)$  на шаг

## Пример: зеркальный спуск vs PGD на симплексе

Рассмотрим задачу

$$\min_{x \in \Delta_n} f(x) = \frac{1}{2} \|Ax - b\|_2^2$$

- PGD: евклидова проекция на  $\Delta_n$ ,  $\mathcal{O}(n \log n)$  на шаг
- MD (EG): мультипликативное обновление,  $\mathcal{O}(n)$  на шаг

## Пример: зеркальный спуск vs PGD на симплексе

Рассмотрим задачу

$$\min_{x \in \Delta_n} f(x) = \frac{1}{2} \|Ax - b\|_2^2$$

- PGD: евклидова проекция на  $\Delta_n$ ,  $\mathcal{O}(n \log n)$  на шаг
- MD (EG): мультипликативное обновление,  $\mathcal{O}(n)$  на шаг

Когда  $A$  имеет слабую корреляцию между столбцами:  
 $L_2 \approx n \cdot L_\infty$ . Тогда:

- PGD:  $\mathcal{O}\left(\frac{nL_\infty}{k}\right)$

Параметр	PGD	MD (EG)
Гладкость	$L_2 = \ A^\top A\ _{\text{op}}$	$L_\infty = \max_{ij}  A^\top A _{ij}$
«Радиус»	$R_2^2 \leq 2$	$R^2 \leq \ln n$
Оценка	$\frac{L_2}{k}$	$\frac{L_\infty \ln n}{k}$

## Пример: зеркальный спуск vs PGD на симплексе

Рассмотрим задачу

$$\min_{x \in \Delta_n} f(x) = \frac{1}{2} \|Ax - b\|_2^2$$

- PGD: евклидова проекция на  $\Delta_n$ ,  $\mathcal{O}(n \log n)$  на шаг
- MD (EG): мультипликативное обновление,  $\mathcal{O}(n)$  на шаг

Когда  $A$  имеет слабую корреляцию между столбцами:  
 $L_2 \approx n \cdot L_\infty$ . Тогда:

- PGD:  $\mathcal{O}\left(\frac{nL_\infty}{k}\right)$
- MD:  $\mathcal{O}\left(\frac{L_\infty \ln n}{k}\right)$

Параметр	PGD	MD (EG)
Гладкость	$L_2 = \ A^\top A\ _{\text{op}}$	$L_\infty = \max_{ij}  A^\top A _{ij}$
«Радиус»	$R_2^2 \leq 2$	$R^2 \leq \ln n$
Оценка	$\frac{L_2}{k}$	$\frac{L_\infty \ln n}{k}$

## Пример: зеркальный спуск vs PGD на симплексе

Рассмотрим задачу

$$\min_{x \in \Delta_n} f(x) = \frac{1}{2} \|Ax - b\|_2^2$$

- PGD: евклидова проекция на  $\Delta_n$ ,  $\mathcal{O}(n \log n)$  на шаг
- MD (EG): мультипликативное обновление,  $\mathcal{O}(n)$  на шаг

Когда  $A$  имеет слабую корреляцию между столбцами:  
 $L_2 \approx n \cdot L_\infty$ . Тогда:

- PGD:  $\mathcal{O}\left(\frac{nL_\infty}{k}\right)$
- MD:  $\mathcal{O}\left(\frac{L_\infty \ln n}{k}\right)$

Параметр	PGD	MD (EG)
Гладкость	$L_2 = \ A^\top A\ _{\text{op}}$	$L_\infty = \max_{ij}  A^\top A _{ij}$
«Радиус»	$R_2^2 \leq 2$	$R^2 \leq \ln n$
Оценка	$\frac{L_2}{k}$	$\frac{L_\infty \ln n}{k}$

## Пример: зеркальный спуск vs PGD на симплексе

Рассмотрим задачу

$$\min_{x \in \Delta_n} f(x) = \frac{1}{2} \|Ax - b\|_2^2$$

- PGD: евклидова проекция на  $\Delta_n$ ,  $\mathcal{O}(n \log n)$  на шаг
- MD (EG): мультипликативное обновление,  $\mathcal{O}(n)$  на шаг

Когда  $A$  имеет слабую корреляцию между столбцами:  
 $L_2 \approx n \cdot L_\infty$ . Тогда:

- PGD:  $\mathcal{O}\left(\frac{nL_\infty}{k}\right)$
- MD:  $\mathcal{O}\left(\frac{L_\infty \ln n}{k}\right)$

Выигрыш:  $\frac{n}{\ln n}$  раз!

Параметр	PGD	MD (EG)
Гладкость	$L_2 = \ A^\top A\ _{\text{оп}}$	$L_\infty = \max_{ij}  A^\top A _{ij}$
«Радиус»	$R_2^2 \leq 2$	$R^2 \leq \ln n$
Оценка	$\frac{L_2}{k}$	$\frac{L_\infty \ln n}{k}$

## Пример: зеркальный спуск vs PGD на симплексе

Рассмотрим задачу

$$\min_{x \in \Delta_n} f(x) = \frac{1}{2} \|Ax - b\|_2^2$$

- PGD: евклидова проекция на  $\Delta_n$ ,  $\mathcal{O}(n \log n)$  на шаг
- MD (EG): мультипликативное обновление,  $\mathcal{O}(n)$  на шаг

Когда  $A$  имеет слабую корреляцию между столбцами:  
 $L_2 \approx n \cdot L_\infty$ . Тогда:

- PGD:  $\mathcal{O}\left(\frac{nL_\infty}{k}\right)$
- MD:  $\mathcal{O}\left(\frac{L_\infty \ln n}{k}\right)$

Выигрыш:  $\frac{n}{\ln n}$  раз!





Для  $n = 1000$ : выигрыш  $\approx 145$  раз.

Для  $n = 10^6$ : выигрыш  $\approx 72\,400$  раз.

Параметр	PGD	MD (EG)
Гладкость	$L_2 = \ A^\top A\ _{\text{оп}}$	$L_\infty = \max_{ij}  A^\top A _{ij}$
«Радиус»	$R_2^2 \leq 2$	$R^2 \leq \ln n$
Оценка	$\frac{L_2}{k}$	$\frac{L_\infty \ln n}{k}$





# Численные эксперименты: MD vs PGD vs FW

$\Delta_{500}: L_2 = 17.1, L_\infty = 1.825$ , отношение  $9 \times$




# Численные эксперименты: MD vs PGD vs FW

$\Delta_{500}: L_2 = 17.1, L_\infty = 1.825$ , отношение  $9 \times$







- MD с шагом  $\alpha = 1/L_\infty$  сходится быстрее PGD с шагом  $\alpha = 1/L_2$




# Численные эксперименты: MD vs PGD vs FW

$\Delta_{500}: L_2 = 17.1, L_\infty = 1.825$ , отношение  $9 \times$







- MD с шагом  $\alpha = 1/L_\infty$  сходится быстрее PGD с шагом  $\alpha = 1/L_2$
- Отношение  $L_2/L_\infty$  растёт с размерностью




# Численные эксперименты: MD vs PGD vs FW

$\Delta_{500}: L_2 = 17.1, L_\infty = 1.825$ , отношение  $9 \times$



- MD с шагом  $\alpha = 1/L_\infty$  сходится быстрее PGD с шагом  $\alpha = 1/L_2$
- Отношение  $L_2/L_\infty$  растёт с размерностью



- Стоимость шага MD —  $\mathcal{O}(n)$ , дешевле PGD

## Итоги: зеркальный спуск

- **Обобщение PGD:** заменяем евклидову проекцию дивергенцией Брэгмана, адаптируя геометрию метода к задаче.

## Итоги: зеркальный спуск

- **Обобщение PGD:** заменяем евклидову проекцию дивергенцией Брэгмана, адаптируя геометрию метода к задаче.
- **Скорость сходимости:**  $\mathcal{O}\left(\frac{LR^2}{\sigma k}\right)$  — та же структура, что у PGD, но с параметрами, адаптированными к «правильной» норме.

## Итоги: зеркальный спуск

- **Обобщение PGD:** заменяем евклидову проекцию дивергенцией Брэгмана, адаптируя геометрию метода к задаче.
- **Скорость сходимости:**  $\mathcal{O}\left(\frac{LR^2}{\sigma k}\right)$  — та же структура, что у PGD, но с параметрами, адаптированными к «правильной» норме.
- **Когда выигрывает:** задачи, где евклидова геометрия не соответствует структуре множества или функции:

## Итоги: зеркальный спуск

- **Обобщение PGD:** заменяем евклидову проекцию дивергенцией Брэгмана, адаптируя геометрию метода к задаче.
- **Скорость сходимости:**  $\mathcal{O}\left(\frac{LR^2}{\sigma k}\right)$  — та же структура, что у PGD, но с параметрами, адаптированными к «правильной» норме.
- **Когда выигрывает:** задачи, где евклидова геометрия не соответствует структуре множества или функции:
  - Оптимизация на **симплексе** ( $\ell_1$ -геометрия, негативная энтропия)

## Итоги: зеркальный спуск

- **Обобщение PGD:** заменяем евклидову проекцию дивергенцией Брэгмана, адаптируя геометрию метода к задаче.
- **Скорость сходимости:**  $\mathcal{O}\left(\frac{LR^2}{\sigma k}\right)$  — та же структура, что у PGD, но с параметрами, адаптированными к «правильной» норме.
- **Когда выигрывает:** задачи, где евклидова геометрия не соответствует структуре множества или функции:
  - Оптимизация на **симплексе** ( $\ell_1$ -геометрия, негативная энтропия)
  - Задачи с **разреженными** решениями

## Итоги: зеркальный спуск

- **Обобщение PGD:** заменяем евклидову проекцию дивергенцией Брэгмана, адаптируя геометрию метода к задаче.
- **Скорость сходимости:**  $\mathcal{O}\left(\frac{LR^2}{\sigma k}\right)$  — та же структура, что у PGD, но с параметрами, адаптированными к «правильной» норме.
- **Когда выигрывает:** задачи, где евклидова геометрия не соответствует структуре множества или функции:
  - Оптимизация на **симплексе** ( $\ell_1$ -геометрия, негативная энтропия)
  - Задачи с **разреженными** решениями
  - Оптимизация в пространствах большой **размерности**, где  $\ell_2$ -оценки зависят от  $n$

## Итоги: зеркальный спуск

- **Обобщение PGD:** заменяем евклидову проекцию дивергенцией Брэгмана, адаптируя геометрию метода к задаче.
- **Скорость сходимости:**  $\mathcal{O}\left(\frac{LR^2}{\sigma k}\right)$  — та же структура, что у PGD, но с параметрами, адаптированными к «правильной» норме.
- **Когда выигрывает:** задачи, где евклидова геометрия не соответствует структуре множества или функции:
  - Оптимизация на **симплексе** ( $\ell_1$ -геометрия, негативная энтропия)
  - Задачи с **разреженными** решениями
  - Оптимизация в пространствах большой **размерности**, где  $\ell_2$ -оценки зависят от  $n$
- **Ключевой результат на симплексе:** с прокс-функцией  $\omega(x) = \sum_i x_i \ln x_i$  зеркальный спуск даёт оценку  $\mathcal{O}\left(\frac{L_\infty \ln n}{k}\right)$  вместо  $\mathcal{O}\left(\frac{nL_\infty}{k}\right)$  у PGD — экспоненциальный выигрыш по размерности.

## Итоги: зеркальный спуск

- **Обобщение PGD:** заменяем евклидову проекцию дивергенцией Брэгмана, адаптируя геометрию метода к задаче.
- **Скорость сходимости:**  $\mathcal{O}\left(\frac{LR^2}{\sigma k}\right)$  — та же структура, что у PGD, но с параметрами, адаптированными к «правильной» норме.
- **Когда выигрывает:** задачи, где евклидова геометрия не соответствует структуре множества или функции:
  - Оптимизация на **симплексе** ( $\ell_1$ -геометрия, негативная энтропия)
  - Задачи с **разреженными** решениями
  - Оптимизация в пространствах большой **размерности**, где  $\ell_2$ -оценки зависят от  $n$
- **Ключевой результат на симплексе:** с прокс-функцией  $\omega(x) = \sum_i x_i \ln x_i$  зеркальный спуск даёт оценку  $\mathcal{O}\left(\frac{L_\infty \ln n}{k}\right)$  вместо  $\mathcal{O}\left(\frac{nL_\infty}{k}\right)$  у PGD — экспоненциальный выигрыш по размерности.
- Выбор прокс-функции  $\omega$  — ключевое решение при применении метода. Общее правило:  $\omega$  должна быть сильно выпуклой относительно нормы, в которой  $f$  является гладкой.